



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Εντοπισμός Αναπνευστικών Ασθενειών μέσω
ήχου με χρήση Μηχανικής Μάθησης και
Acoustic Domain Adaptation

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΜΑΝΤΕ ΜΗΛΤΙΑΔΗ
Α.Μ. 1084661

Επιβλέπων: Σωτήριος Νικολετσέας

Πάτρα, Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Εντοπισμός Αναπνευστικών Ασθενειών μέσω ήχου με χρήση Μηχανικής Μάθησης και Acoustic Domain Adaptation

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΜΑΝΤΕ ΜΗΛΤΙΑΔΗ
Α.Μ. 1084661

Επιβλέπων: Σωτήριος Νικολετσέας

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....
Σωτήριος Νικολετσέας
Καθηγητής

.....
Εύη Παπαϊωάννου
Επίκουρη Καθηγήτρια

.....
Χρήστος Μακρής
Αναπληρωτής Καθηγητής

Πάτρα, Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Copyright ©–All rights reserved Μηλτιάδης Μαντές, 2025.

Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

Υπεύθυνη Δήλωση

Βεβαιώνω ότι είμαι συγγραφέας αυτής της πτυχιακής εργασίας, και ότι κάθε βοήθεια την οποία είχα για την προετοιμασία της είναι πλήρως αναγνωρισμένη και αναφέρεται στην πτυχιακή εργασία. Επίσης έχω αναφέρει τις όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε αυτές αναφέρονται ακριβώς είτε παραφρασμένες. Επίσης, βεβαιώνω ότι αυτή η πτυχιακή εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για τις απαιτήσεις του προγράμματος σπουδών του τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

(Υπογραφή)

.....

Μηλτιάδης Μαντές

Περίληψη

Η παρούσα διπλωματική εργασία ασχολείται με την ανάλυση αναπνευστικών ήχων για την αναγνώριση παθολογικών καταστάσεων, αξιοποιώντας τεχνικές Μηχανικής Μάθησης και μεθόδους Acoustic Domain Adaptation. Οι αναπνευστικοί ήχοι παρουσιάζουν σημαντική διακύμανση λόγω της χρήσης διαφορετικών συσκευών καταγραφής, γεγονός που επιφέρει φαινόμενα domain shift και υποβαθμίζει τη γενικευσιμότητα των μοντέλων. Για την αντιμετώπιση αυτού του προβλήματος, εφαρμόζονται σύγχρονες τεχνικές προσαρμογής πεδίου, όπως οι DANN και CDAN, οι οποίες στοχεύουν στην εκμάθηση χαρακτηριστικών που είναι ταυτόχρονα διακριτικά ως προς την κλάση αλλά και αμετάβλητα ως προς το πεδίο (συσκευή).

Το προτεινόμενο σύστημα περιλαμβάνει προεπεξεργασία σημάτων, εξαγωγή ακουστικών χαρακτηριστικών, κανονικοποίηση, και ταξινόμηση με παραδοσιακούς αλγορίθμους όπως KNN, SVM, Random Forest και XGBoost. Εν συνεχεία, υλοποιούνται μοντέλα προσαρμογής πεδίου για τη βελτίωση της απόδοσης σε δεδομένα που προέρχονται από μη ορατές συσκευές. Η αξιολόγηση βασίζεται σε μετρικές όπως η ακρίβεια, η ευαισθησία, η ειδικότητα, η ακρίβεια θετικών προβλέψεων και ο συντελεστής συσχέτισης Ματthews.

Τα αποτελέσματα υποδεικνύουν ότι η ενσωμάτωση τεχνικών domain adaptation μπορεί να ενισχύσει τη γενικευσιμότητα των μοντέλων ταξινόμησης σε ηχητικά δεδομένα από ετερογενείς πηγές, καθιστώντας εφικτή την πιο αξιόπιστη αυτόματη ανίχνευση αναπνευστικών παθήσεων σε πραγματικές συνθήκες.

Λέξεις Κλειδιά

Σύστημα ομότιμων κόμβων, Σύστημα ομότιμων κόμβων βασισμένο σε σχήματα, Σημασιολογικός Ιστός, RDF/S, RQL, Jxta

Abstract

A peer-to-peer system is a set of autonomous computing nodes (the peers) which cooperate in order to exchange data. The peers in the peer-to-peer systems that are widely used today, rely on simple keyword selection in order to search for data. The need for richer facilities in exchanging data, as well as, the evolution of the Semantic Web, led to the evolution of the schema-based peer-to-peer systems. In those systems every node uses a schema to organize the local data. So there are two ways in order for data search to be feasible. The first but not so flexible way implies that every node uses the same schema. The second way gives every node the flexibility to choose a schema according with its needs, but on the same time requires the existence of mapping rules in order for queries to be replied. This way though, doesn't offer automatic creation and dynamic renewal of the mapping rules which would be essential for peer-to-peer systems.

This diploma thesis aims to the development of a schema-based peer-to-peer system that allows a certain flexibility for schema selection and on the same time enables query transformation without the use of mapping rules. The peers use RDF schemas that are subsets (views) of a big common schema called global schema.

Keywords

adventitious respiratory sound, domain shift, acoustic domain adaptation, DANN, CDAN, VAE

Στην οικογένεια και στους φίλους μου!

Ευχαριστίες

Θα ήθελα καταρχάς να εκφράσω την ειλικρινή μου ευγνωμοσύνη στον επιβλέποντα καθηγητή μου, κ. Σωτήριο Νικολετσέα, για την εμπιστοσύνη και την ευκαιρία που μου έδωσε ώστε να ασχοληθώ με ένα τόσο ενδιαφέρον και επίκαιρο θέμα. Η διαθεσιμότητά του και η ενθάρρυνση που μου προσέφερε συνέβαλαν σημαντικά στην εξέλιξή μου τόσο σε ακαδημαϊκό όσο και σε προσωπικό επίπεδο. Ακόμη, θα ήθελα να ευχαριστήσω τον Γιώργο Κοντογιάννη για τη βοήθεια αλλά και για τις ουσιαστικές διορθώσεις καθ' όλη τη διάρκεια υλοποίησης αυτής της εργασίας. Ευχαριστώ επίσης τα μέλη της επιτροπής αξιολόγησης, κα Εύη Παπαϊωάννου και κ. Χρήστο Μακρή, για το ειλικρινές ενδιαφέρον και το χρόνο που αφιέρωσαν για την αξιολόγηση της εργασίας μου. Ιδιαίτερες ευχαριστίες οφείλω στην οικογένειά μου για τη συνεχή στήριξη αλλά και την υπομονή τους σε όλη τη διάρκεια των σπουδών μου. Η αμέριστη ηθική και συναισθηματική τους υποστήριξη αποτέλεσε για μένα πολύτιμο στήριγμα. Τέλος, ευχαριστώ τους φίλους και συμφοιτητές μου για τη συντροφιά, τη συνεργασία και τις στιγμές που μοιραστήκαμε όλα αυτά τα χρόνια, καθώς και για την ενθάρρυνση που μου προσέφεραν στις πιο απαιτητικές στιγμές της φοιτητικής μου πορείας.

Περιεχόμενα

Περίληψη	i
Abstract	iii
Ευχαριστίες	vii
Περιεχόμενα	xi
Κατάλογος Σχημάτων	xvii
Κατάλογος Πινάκων	xix
1 Εισαγωγή	1
1.1 Διάρθρωση της διπλωματικής εργασίας	1
1.2 Σημασία του προβλήματος	2
1.3 Προηγούμενες έρευνες	4
1.4 Στόχοι και συνεισφορά της διπλωματικής εργασίας	5
2 Αναπνευστικοί ήχοι και σήματα	7
2.1 Ανατομία και φυσιολογία του αναπνευστικού συστήματος	7
2.1.1 Δημιουργία αναπνευστικών ήχων	7
2.1.2 Διαχωρισμός φυσιολογικών και παθολογικών ήχων	9
2.2 Αναπνευστικά σήματα	11
2.2.1 Ορισμός, μεγέθη και ιδιότητες	11
2.2.2 Στηθοσκόπια και συσκευές καταγραφής	14
2.2.3 Ψηφιοποίηση	16
3 Ψηφιακή επεξεργασία αναπνευστικών σημάτων	19
3.1 Αναπαράσταση αναπνευστικών σημάτων	19
3.1.1 Πεδίο χρόνου (Κυματομορφή)	19
3.1.2 Πεδίο χρόνου-συχνότητας (Φασματογράφημα)	21
3.2 Προεπεξεργασία αναπνευστικών σημάτων	25
3.2.1 Επαναδειγματοληψία	26

3.2.2	Καθορισμός χρονικών ορίων	27
3.2.3	Κανονικοποίηση πλάτους	30
3.2.4	Αποθορυβοποίηση	31
3.2.5	Επαύξηση δεδομένων με <i>VTLP</i>	34
3.3	Εξαγωγή χαρακτηριστικών	36
3.3.1	Χρονικά χαρακτηριστικά	37
3.3.2	Φασματικά χαρακτηριστικά	39
3.3.3	MFCCs	42
3.3.4	Ζώνες Log-Mel	44
4	Μηχανική μάθηση για αναγνώριση αναπνευστικών ασθενειών	47
4.1	Εισαγωγή στη μηχανική μάθηση	47
4.1.1	Επιβλεπόμενη μάθηση	49
4.1.2	Μη επιβλεπόμενη μάθηση	51
4.2	Παραδοσιακοί Αλγόριθμοι Ταξινόμησης	53
4.2.1	k-Nearest Neighbors (k-NN)	53
4.2.2	Support Vector Machines (SVM)	54
4.2.3	Random Forest (RF)	56
4.2.4	XGBoost	57
4.3	Νευρωνικά δίκτυα	58
4.3.1	Αρχιτεκτονική ενός MLP	59
4.3.2	Αρχιτεκτονική ενός Autoencoder	60
4.3.3	Συναρτήσεις ενεργοποίησης (Activation functions)	61
4.3.4	Συναρτήσεις κόστους (Loss functions)	62
4.3.5	Αλγόριθμοι βελτιστοποίησης (Optimizers)	63
4.4	Ρύθμιση μοντέλων	64
4.4.1	Κλιμάκωση	65
4.4.2	Επιλογή χαρακτηριστικών	66
4.4.3	Ρύθμιση υπερπαραμέτρων	73
4.5	Αξιολόγηση Μοντέλων	75
4.5.1	Cross-Validation (k-fold)	76
4.5.2	Μετρικές απόδοσης ανά κλάση	76
4.5.3	Μετρικές συνολικής απόδοσης	78
4.5.4	Καμπύλες ROC και Precision-Recall	79
5	Acoustic Domain Adaptation	81
5.1	Εισαγωγή στο domain shift	81
5.2	Ανάγκη για acoustic domain adaptation	83
5.3	Επιβλεπόμενο και Μη επιβλεπόμενο acoustic domain adaptation	87
5.4	Βασικές κατηγορίες acoustic domain adaptation	87
5.5	Βασικές προσεγγίσεις acoustic domain adaptation	88

5.6	Επιλεγμένες Προσεγγίσεις	91
5.6.1	Spectrum correction	92
5.6.2	Domain Adversarial Neural Network (DANN) και παραλλαγές του . .	99
6	Ανάλυση και υλοποίηση συστήματος	117
6.1	Περιγραφή dataset και συσκευών εγγραφής	117
6.2	Τεχνολογίες και εργαλεία υλοποίησης	119
6.3	Περιγραφή συνολικού pipeline	120
6.4	Υλοποίηση επιμέρους υπομονάδων	123
6.4.1	Preprocessing module	123
6.4.2	Feature extraction module	125
6.4.3	Domain adaptation module	128
6.4.4	Classification module	128
7	Επίλογος	129
7.1	Αποτελέσματα ταξινόμησης	129
7.1.1	Ανάλυση συνολικών αποτελεσμάτων	129
7.1.2	Ανάλυση αποτελεσμάτων ανά μοντέλο ταξινόμησης	130
7.2	Συμπεράσματα	137
7.3	Μελλοντικές επεκτάσεις	139

Κατάλογος Σχημάτων

2.1	Αναπνευστικό δέντρο.	7
2.2	Στρωτή ροή αέρα.	8
2.3	Τυρβώδης ροή αέρα.	8
2.4	Οπτική αναπαράσταση του διαχωρισμού μεταξύ φυσιολογικών και παθολογικών αναπνευστικών ήχων.	9
2.5	Συσκευές καταγραφής αναπνευστικών ήχων.	15
2.6	Pipeline ψηφιοποίησης αναπνευστικών ηχητικών σημάτων.	16
3.1	Κυματομορφές αναπνευστικών καταγραφών του dataset.	20
3.2	Τεμαχισμός σήματος σε frames με επικάλυψη.	23
3.3	Συνήθεις συναρτήσεις παραθύρου.	24
3.4	Φασματογραφήματα αναπνευστικών καταγραφών του dataset.	25
3.5	Κατανομή της διάρκειας των αναπνευστικών κύκλων στο dataset.	29
3.6	Παραδείγματα εφαρμογής trimming σε αναπνευστικούς κύκλους του dataset.	30
3.7	Παραδείγματα εφαρμογής circular padding σε αναπνευστικούς κύκλους του dataset.	30
3.8	Παραδείγματα εφαρμογής κανονικοποίησης πλάτους σε αναπνευστικούς κύκλους του dataset.	31
3.9	Είδη ψηφιακών φίλτρων.	32
3.10	Παραδείγματα εφαρμογής high-pass φίλτρου σε αναπνευστικούς κύκλους του dataset.	32
3.11	1ο παράδειγμα προεπεξεργασίας.	33
3.12	2ο παράδειγμα προεπεξεργασίας.	33
3.13	3ο παράδειγμα προεπεξεργασίας.	34
3.14	Παραδείγματα εφαρμογής VTLP-Patch Aug στο dataset.	35
3.15	Μέση χρονική εξέλιξη του ZCR για κάθε κατηγορία ήχου.	38
3.16	Μέση χρονική εξέλιξη του RMS Energy για κάθε κατηγορία ήχου.	39
3.17	Μέση χρονική εξέλιξη του Onset Envelope για κάθε κατηγορία ήχου.	39
3.18	Μέση χρονική εξέλιξη του Spectral Centroid για κάθε κατηγορία ήχου.	40
3.19	Χρονική εξέλιξη του Spectral Bandwidth για κάθε κατηγορία ήχου.	40
3.20	Μέση χρονική εξέλιξη του Spectral Rolloff για κάθε κατηγορία ήχου.	41
3.21	Μέση χρονική εξέλιξη του Spectral Flux για κάθε κατηγορία ήχου.	41

3.22 Μέση χρονική εξέλιξη του Spectral Flatness για κάθε κατηγορία ήχου.	42
3.23 Διαδικασία εξαγωγής MFCCs.	43
3.24 Παραδείγματα MFCCs από ενδεικτικούς αναπνευστικούς κύκλους.	44
3.25 Μέση χρονική εξέλιξη των MFCCs για κάθε κατηγορία ήχου.	44
3.26 Μέση χρονική εξέλιξη των Log-Mel filterbank energies για κάθε κατηγορία ήχου.	45
4.1 Σχέση ανάμεσα σε τεχνητή νοημοσύνη, μηχανική μάθηση και βαθιά μάθηση.	48
4.2 Κατηγορίες μηχανικής μάθησης.	49
4.3 2D απεικόνιση των δεδομένων του dataset με χρήση PCA.	52
4.4 2D απεικόνιση των δεδομένων του dataset με χρήση tSNE.	53
4.5 Ταξινομητής k-NN.	54
4.6 Γραμμικός ταξινομητής SVM.	55
4.7 Ταξινομητής Random Forest.	57
4.8 Ταξινομητής XGBoost.	58
4.9 Αρχιτεκτονική ενός MLP.	60
4.10 Αρχιτεκτονική ενός Autoencoder.	61
4.11 KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά label.	67
4.12 Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά label.	68
4.13 Feature-Class heatmap των εξαγμένων χαρακτηριστικών.	69
4.14 Correlation heatmap των εξαγμένων χαρακτηριστικών.	70
4.15 Κατάταξη χαρακτηριστικών βάσει F -score από ANOVA test ως προς το label.	72
4.16 p -values των χαρακτηριστικών από ANOVA test.	72
4.17 Μεταβολή απόδοσης ταξινόμησης ως προς το πλήθος χαρακτηριστικών που χρησιμοποιήθηκαν.	73
4.18 Βέλτιστοι συνδυασμοί υπερπαραμέτρων για κάθε μοντέλο ταξινόμησης.	75
4.19 Stratified k-fold cross-validation.	76
4.20 Μητρώο σύγχυσης.	79
5.1 Είδη μετατόπισης τομέα.	82
5.2 Απεικόνιση της μέσης απόκρισης συχνότητας των διαφορετικών συσκευών καταγραφής.	84
5.3 Μητρώο σύγχυσης για το μοντέλο ταξινόμησης συσκευών.	85
5.4 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής.	85
5.5 KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά συσκευή καταγραφής.	86
5.6 Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά συσκευή καταγραφής.	86
5.7 Απεικόνιση των συντελεστών διόρθωσης ως προς τη συσκευή Meditron.	94
5.8 1ο παράδειγμα φασματικής διόρθωσης.	95
5.9 2ο παράδειγμα φασματικής διόρθωσης.	95
5.10 3ο παράδειγμα φασματικής διόρθωσης.	96

5.11	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά τη διόρθωση φάσματος.	96
5.12	KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά συσκευή καταγραφής μετά τη φασματική διόρθωση.	97
5.13	Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά συσκευή καταγραφής μετά τη φασματική διόρθωση.	97
5.14	Μητρώο σύγχυσης για το μοντέλο ταξινόμησης συσκευών μετά τη διόρθωση φάσματος.	98
5.15	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά τη διόρθωση φάσματος.	99
5.16	Αρχιτεκτονική ενός DANN.	100
5.17	Συναρτήσεις κόστους του DANN.	103
5.18	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή DANN.	104
5.19	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή DANN.	104
5.20	Αρχιτεκτονική ενός CDAN.	106
5.21	Συναρτήσεις κόστους του CDAN.	107
5.22	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή CDAN.	108
5.23	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή CDAN.	108
5.24	Αρχιτεκτονική ενός VAE.	110
5.25	Συναρτήσεις κόστους κατά την ταυτόχρονη εκπαίδευση.	112
5.26	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την ταυτόχρονη εκπαίδευση.	113
5.27	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την ταυτόχρονη εκπαίδευση.	113
5.28	Συναρτήσεις κόστους κατά την διαδοχική εκπαίδευση.	114
5.29	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την διαδοχική εκπαίδευση.	115
5.30	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την διαδοχική εκπαίδευση.	115
6.1	Pipeline υλοποίησης.	121
6.2	Training, test sets.	121
6.3	Κατανομές χαρακτηριστικών σε training, test sets.	122
6.4	Block diagram για το Preprocessing Module.	123
6.5	Block diagram για το Feature Extraction Module.	125
6.6	Block diagram για το Domain Adaptation Module.	128
6.7	Block diagram για το Classification Module.	128

7.1	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN χωρίς προσαρμογή τομέα (baseline).	130
7.2	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση Spectrum Correction.	130
7.3	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση DANN.	131
7.4	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση CDAN.	131
7.5	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση DANN και VAE (1 φάση).	131
7.6	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση DANN και VAE (2 φάσεις).	131
7.7	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost χωρίς προσαρμογή τομέα (baseline).	132
7.8	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση Spectrum Correction.	132
7.9	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση DANN.	132
7.10	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση CDAN.	133
7.11	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση DANN και VAE (1 φάση).	133
7.12	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση DANN και VAE (2 φάσεις).	133
7.13	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest χωρίς προσαρμογή τομέα (baseline).	134
7.14	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση Spectrum Correction.	134
7.15	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση DANN.	134
7.16	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση CDAN.	134
7.17	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση DANN και VAE (1 φάση).	135
7.18	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση DANN και VAE (2 φάσεις).	135
7.19	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM χωρίς προσαρμογή τομέα (baseline).	135
7.20	Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση Spectrum Correction.	136

7.21 Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση DANN.	136
7.22 Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση CDAN.	136
7.23 Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση DANN και VAE (1 φάση).	136
7.24 Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση DANN και VAE (2 φάσεις).	137

Κατάλογος Πινάκων

1.1	Σύνοψη <i>state-of-the-art</i> αποτελεσμάτων στην αυτόματη ανάλυση αναπνευστικών ήχων και στην ακουστική προσαρμογή τομέα.	5
2.1	Συγκριτικός πίνακας φυσιολογικών και παθολογικών αναπνευστικών ήχων (Pranomo, Bowyer, et al. 2017)	10
3.1	Καταγραφή αναπνευστικών σημάτων από τις τέσσερις διαφορετικές συσκευές.	27
3.2	Πλήθος εξαγμένων χαρακτηριστικών.	37
4.1	Τα 20 κορυφαία επιλεγμένα χαρακτηριστικά	73
5.1	Απόσταση Wasserstein από τον τομέα στόχο Meditron πριν και μετά την εφαρμογή της διόρθωσης φάσματος.	97
5.2	Αρχιτεκτονική του Feature Extractor στο DANN.	101
5.3	Αρχιτεκτονική του Label Classifier στο DANN.	102
5.4	Αρχιτεκτονική του Domain Classifier στο DANN.	102
5.5	Αρχιτεκτονική του Feature Extractor στο CDAN.	106
5.6	Αρχιτεκτονική του Label Classifier στο CDAN.	107
5.7	Αρχιτεκτονική του Encoder στο VAE.	111
5.8	Αρχιτεκτονική του Decoder στο VAE.	111
5.9	Αρχιτεκτονική του Label Classifier.	111
5.10	Αρχιτεκτονική του Domain Classifier.	111
6.1	Κατανομή των κατηγοριών αναπνευστικών ήχων ανά συσκευή καταγραφής.	119
7.1	Συνολικές μετρικές ταξινόμησης για κάθε μέθοδο προσαρμογής τομέα.	129
7.2	Μετρικές ταξινόμησης για τη κλάση Normal για κάθε μέθοδο προσαρμογής τομέα.	129
7.3	Μετρικές ταξινόμησης για τη κλάση Crackle για κάθε μέθοδο προσαρμογής τομέα.	130
7.4	Μετρικές ταξινόμησης για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής τομέα.	130

Κεφάλαιο 1

Εισαγωγή

1.1 Διάρθρωση της διπλωματικής εργασίας

Η παρούσα διπλωματική εργασία οργανώνεται σε επτά κύρια κεφάλαια, ακολουθώντας μια ροή η οποία ξεκινάει από τη θεωρητική θεμελίωση και καταλήγει στην πειραματική αξιολόγηση και τα τελικά συμπεράσματα και επεκτάσεις. Συγκεκριμένα:

- **Κεφάλαιο 1 – Εισαγωγή**

Παρουσιάζεται το υπόβαθρο και το γενικό πλαίσιο της εργασίας, η σημασία της ανάλυσης και ταξινόμησης αναπνευστικών ήχων, καθώς και οι προκλήσεις που εισάγει το domain shift στην ταξινόμηση αναπνευστικών ήχων σύμφωνα και με προηγούμενες μελέτες. Διατυπώνονται επίσης οι στόχοι, η συνεισφορά και η δομή της εργασίας, καθώς και τυχόν κενά στην υπάρχουσα βιβλιογραφία.

- **Κεφάλαιο 2 – Αναπνευστικοί ήχοι και σήματα**

Περιγράφεται συνοπτικά η λειτουργία του αναπνευστικού συστήματος, ενώ παράλληλα διατυπώνονται οι βασικές διαφορές ανάμεσα σε φυσιολογικούς και παθολογικούς αναπνευστικούς ήχους. Επίσης, παρουσιάζονται ορισμένες εισαγωγικές έννοιες της θεωρίας σημάτων και γίνεται αναφορά στις υπάρχουσες μεθόδους ακρόασης και καταγραφής, καθώς και στη διαδικασία ψηφιοποίησης των σημάτων.

- **Κεφάλαιο 3 – Ψηφιακή επεξεργασία αναπνευστικών σημάτων**

Δίνεται έμφαση σε βασικές έννοιες του κλάδου της ψηφιακής επεξεργασίας σημάτων και παρουσιάζονται αρχικά οι διαφορετικές μέθοδοι αναπαράστασης των αναπνευστικών σημάτων στο πεδίο του χρόνου και του χρόνου-συχνότητας. Επίσης, αναλύονται οι τεχνικές προεπεξεργασίας που εφαρμόστηκαν πάνω στα καταγεγραμμένα σήματα, καθώς και οι μέθοδοι εξαγωγής χαρακτηριστικών, από τις οποίες προκύπτουν χρονικά και φασματικά χαρακτηριστικά, καθώς και οι συντελεστές MFCC και οι ζώνες Log-Mel. Τέλος, γίνεται μια σύντομη περιγραφή των χαρακτηριστικών αυτών και της σημασίας τους στη διάγνωση αναπνευστικών παθήσεων.

- **Κεφάλαιο 4 – Μηχανική μάθηση για αναγνώριση αναπνευστικών α-**

σθενειών

Αναλύονται θεμελιώδεις αρχές τόσο της επιβλεπόμενης όσο και της μη επιβλεπόμενης μηχανικής μάθησης. Επίσης, γίνεται θεωρητική θεμελίωση κάποιων παραδοσιακών (k-NN, SVM, Random Forest) αλλά και πιο σύγχρονων (XGBoost) αλγορίθμων ταξινόμησης, καθώς και αρχιτεκτονικών νευρωνικών δικτύων (MLP, Autoencoder) για χρήση σε βαθιά μάθηση. Τέλος, παρουσιάζονται βασικά στοιχεία της εκπαίδευσης των νευρωνικών δικτύων όπως συναρτήσεις ενεργοποίησης και κόστους, καθώς και οι μέθοδοι ρύθμισης και αξιολόγησης των μοντέλων ταξινόμησης.

• Κεφάλαιο 5 – Acoustic Domain Adaptation

Παρουσιάζεται η έννοια του domain shift μαζί με την ανάγκη που προκύπτει για αντιμετώπισή του μέσω της προσαρμογής τομέα. Ακολουθώντας, γίνεται θεωρητική θεμελίωση των βασικών εννοιών που διέπουν την προσαρμογή τομέα (domain adaptation), καθώς και παρουσίαση των διαφορετικών κατηγοριών και μεθόδων υλοποίησής του πάνω στα ακουστικά δεδομένα. Δίνεται έμφαση στις βαθιές αρχιτεκτονικές προσαρμογής τομέα, οι οποίες ενσωματώνουν την προσαρμογή στη διαδικασία εκμάθησης αναπαραστάσεων, οι οποίες αποδεικνύονται κατάλληλες για πολύπλοκα ακουστικά περιβάλλοντα με υψηλή ετερογένεια. Τέλος, αναλύονται οι επιλεγμένες μέθοδοι που υλοποιήθηκαν στην συγκεκριμένη εργασία, όπως το Spectrum Correction, το DANN και παραλλαγές του όπως CDAN και DANN με χρήση VAE για μετασχηματισμό των χαρακτηριστικών.

• Κεφάλαιο 6 – Ανάλυση και υλοποίηση συστήματος

Περιγράφεται το dataset και οι συσκευές εγγραφής που το συνοδεύουν, καθώς και τα εργαλεία και οι τεχνολογίες υλοποίησης της μεθοδολογίας που περιγράψαμε. Επίσης, παρουσιάζεται η συνολική αρχιτεκτονική του συστήματος με αναλυτικά βήματα μαζί με ξεχωριστή ανάλυση για κάθε επιμέρους υπομονάδα.

• Κεφάλαιο 7 – Επίλογος

Παρουσιάζονται τα συνολικά αποτελέσματα της ταξινόμησης, τα συμπεράσματα της έρευνας, καθώς και οι μελλοντικές προοπτικές βελτίωσης και επέκτασης του συστήματος.

1.2 Σημασία του προβλήματος

Είναι γνωστό ότι οι αναπνευστικές παθήσεις όπως η χρόνια αποφρακτική πνευμονοπάθεια (ΧΑΠ), το άσθμα και η πνευμονία αποτελούν παγκοσμίως μείζονα αιτία νοσηρότητας και θνησιμότητας, επηρεάζοντας εκατομμύρια ανθρώπους και επιβαρύνοντας σημαντικά τα συστήματα υγείας. Η έγκαιρη και ακριβής διάγνωση αυτών των παθήσεων είναι καίριας σημασίας για την αποτελεσματική αντιμετώπισή τους αλλά και για τη βελτίωση της πρόγνωσης των ασθενειών.

Η παρουσία παθολογικών αναπνευστικών ήχων στους αναπνευστικούς κύκλους καθώς και τα χαρακτηριστικά των ήχων αυτών αποτελούν σημαντικούς βιοδείκτες για την κλινική αξιολόγηση των παραπάνω νοσημάτων. Πιο συγκεκριμένα, ήχοι όπως τα wheezes (συριγμοί) και τα crackles (ρόγχοι) προκύπτουν από μη φυσιολογικές ροές αέρα ή αποφράξεις στους

αεραγωγούς και συνδέονται άμεσα με τις προαναφερθείσες παθήσεις. Για παράδειγμα, οι συριγμοί παρατηρούνται συχνά στο άσθμα και στη ΧΑΠ λόγω στένωσης των βρόγχων, ενώ οι λεπτοί ρόγχοι σχετίζονται με πνευμονία ή πνευμονική ίνωση. Η ανίχνευση, η καταγραφή και η ανάλυση αυτών των ήχων παρέχουν στον θεράποντα ιατρό κρίσιμη πληροφορία τόσο για τη διάγνωση όσο και την παρακολούθηση της πορείας της νόσου.

Η ανάλυση των αναπνευστικών ήχων μέσω της παραδοσιακής διαδικασίας ακρόασης θα λέγαμε ότι προσφέρει μία μη επεμβατική, χαμηλού κόστους και άμεσα διαθέσιμη μέθοδο κλινικής αξιολόγησης. Ωστόσο, η ερμηνεία των ήχων και των συμπτωμάτων τους από τον κλινικό ιατρό είναι μια διαδικασία η οποία χαρακτηρίζεται από μεγάλο βαθμό υποκειμενικότητας, καθώς βασίζεται σε αστάθμητους παράγοντες όπως η εμπειρία του ιατρού, η ακουστική οξύτητα αλλά και οι εκάστοτε συνθήκες ακρόασης. Η ανάπτυξη λοιπόν αυτοματοποιημένων μεθόδων ανάλυσης και ταξινόμησης αναπνευστικών ήχων, βασισμένων σε τεχνικές μηχανικής μάθησης και βαθιάς μάθησης, δύναται να λειτουργήσει υποστηρικτικά στη διαδικασία λήψης ιατρικών αποφάσεων, μειώνοντας την εξάρτηση από την υποκειμενική κρίση.

Παρά τα πλεονεκτήματα και τις υψηλές επιδόσεις που μπορούν να επιτύχουν οι σύγχρονες τεχνικές μηχανικής μάθησης, η αξιοπιστία και η γενίκευση των αποτελεσμάτων τους πολλές φορές τίθενται υπό αμφισβήτηση, καθώς και αυτές όπως και ο ανθρώπινος παράγοντας δεν μπορούν πάντα να λειτουργήσουν αντικειμενικά. Για την ακρίβεια, ένα συχνό φαινόμενο το οποίο αντιμετωπίζουν τα μοντέλα μηχανικής μάθησης με αποτέλεσμα να επηρεάζεται αρνητικά η απόδοσή τους είναι η διαφοροποίηση των δεδομένων ή συνθηκών εκπαίδευσης σε σχέση με το περιβάλλον αξιολόγησής τους. Το φαινόμενο αυτό είναι γνωστό ως domain shift ή μετατόπιση τομέα στα ελληνικά και στο πλαίσιο της επεξεργασίας ακουστικών δεδομένων μπορεί να προκύψει από πληθώρα παραγόντων. Κάποιοι από αυτούς είναι η διαφοροποίηση στον τύπο και τα τεχνικά χαρακτηριστικά των συσκευών ηχογράφησης (π.χ. διαφορετικά ηλεκτρονικά στηθοσκόπια ή μικρόφωνα), οι συνθήκες ηχογράφησης (θόρυβος περιβάλλοντος, ακουστική χώρου) ή ακόμα και οι διαφορές στο προφίλ των ασθενών από όπου συλλέγονται τα δεδομένα (ηλικία, φύλο, φυσική κατάσταση κ.τ.λ.).

Η ύπαρξη τέτοιας ετερογένειας στα δεδομένα μπορεί να οδηγήσει σε αξιοσημείωτη υποβάθμιση της απόδοσης ενός συστήματος όταν αυτό εφαρμόζεται σε δεδομένα που αποκλίνουν στατιστικά από εκείνα που χρησιμοποιήθηκαν κατά την εκπαίδευσή του. Συνεπώς, καθίσταται απαραίτητη η ανάπτυξη τεχνικών και στρατηγικών βελτίωσης της ανθεκτικότητας των μοντέλων σε μεταβολές του πεδίου εφαρμογής, ειδικά σε πραγματικές συνθήκες όπου η ομοιογένεια των δεδομένων δεν είναι σχεδόν ποτέ εγγυημένη.

Η ανάπτυξη και εφαρμογή τεχνικών προσαρμογής τομέα στον ακουστικό χώρο (acoustic domain adaptation) αποτελεί κρίσιμο βήμα για την αντιμετώπιση των προκλήσεων που προκύπτουν από τις διαφορές μεταξύ των συνόλων δεδομένων. Ο βασικός στόχος αυτών των τεχνικών είναι η εκμάθηση αναπαραστάσεων που παραμένουν σταθερές και αξιόπιστες ακόμη και όταν μεταβάλλονται οι συνθήκες καταγραφής ή τα χαρακτηριστικά της πηγής των δεδομένων, διατηρώντας παράλληλα την ικανότητα του συστήματος να διακρίνει με ακρίβεια τις κλάσεις ενδιαφέροντος, δηλαδή τις παθήσεις των αναπνευστικών ήχων. Με αυτόν τον τρόπο, επιτυγχάνεται η ενίσχυση της γενικευσιμότητας και της αξιοπιστίας των μοντέλων διάγνωσης,

καθώς εξασφαλίζεται υψηλή απόδοση κατά τις δοκιμές σε ποικίλα περιβάλλοντα.

Σε κοινωνικό και πρακτικό επίπεδο, η επιτυχής αντιμετώπιση του προβλήματος της μετατόπισης τομέα θα μπορούσε να οδηγήσει στην ανάπτυξη φορητών ή διαδικτυακών διαγνωστικών εργαλείων, αξιοποιήσιμων σε περιβάλλοντα χαμηλών πόρων ή σε συνθήκες τηλεϊατρικής, διευρύνοντας έτσι την πρόσβαση σε έγκαιρη διάγνωση και παρακολούθηση αναπνευστικών παθήσεων σε παγκόσμια κλίμακα.

1.3 Προηγούμενες έρευνες

Η ανάλυση και αυτόματη ταξινόμηση αναπνευστικών ήχων έχει αναδειχθεί τα τελευταία χρόνια σε ένα πεδίο έντονης ερευνητικής δραστηριότητας, με στόχο την ανάπτυξη υπολογιστικών συστημάτων που μπορούν να υποστηρίξουν ή να βελτιώσουν τη διαγνωστική διαδικασία σε πνευμονοπάθειες. Η συστηματική μελέτη της βιβλιογραφίας επιτρέπει την αναγνώριση των τάσεων, των καινοτομιών αλλά και των υφιστάμενων περιορισμών, δημιουργώντας το απαραίτητο υπόβαθρο για τον σχεδιασμό και την υλοποίηση νέων προσεγγίσεων.

Συγκεκριμένα, έχουν πραγματοποιηθεί σημαντικές συστηματικές μελέτες, οι οποίες έχουν καταγράψει τις κυρίαρχες διαθέσιμες μεθοδολογίες, τα χρησιμοποιούμενα σύνολα δεδομένων, τα χαρακτηριστικά και τις επιδόσεις των μοντέλων. Κοινό εύρημα όλων αυτών των προσεγγίσεων είναι ότι η προσαρμογή τομέα μπορεί να επιφέρει σημαντικές βελτιώσεις στην ακρίβεια της ταξινόμησης, αλλά η αποτελεσματικότητά της συνεχίζει να εξαρτάται σε μεγάλο βαθμό από τη φύση και την ένταση του domain shift, καθώς και από τη διαθεσιμότητα επισημασμένων δεδομένων στο target domain. Συνολικά έχει παρατηρηθεί ότι αν και πολλές από τις υφιστάμενες έρευνες επιτυγχάνουν υψηλά ποσοστά ακρίβειας σε ελεγχόμενα πειράματα, η μεταφορά αυτών των αποτελεσμάτων σε πραγματικές κλινικές συνθήκες εξακολουθεί να παραμένει δύσκολη. Παράλληλα, η έλλειψη μεγάλων, ισορροπημένων και δημοσίως διαθέσιμων βάσεων δεδομένων αποτελεί εξίσου σημαντικό εμπόδιο. Οι περισσότερες έρευνες βλέπουμε ότι στηρίζονται σε σχετικά μικρά ή ιδιόκτητα σύνολα δεδομένων, γεγονός που περιορίζει αρκετά τη δυνατότητα σύγκρισης των αποτελεσμάτων και τη γενίκευση των συμπερασμάτων. Η δημιουργία κοινών πρωτοκόλλων καταγραφής, επισημείωσης και αξιολόγησης θα μπορούσε να επιτρέψει την καλύτερη αξιοποίηση και σύγκριση των μεθόδων.

Σε επίπεδο επιδόσεων, οι πλέον πρόσφατες έρευνες καταδεικνύουν ότι οι τεχνικές *state-of-the-art* μπορούν να επιτύχουν πολύ υψηλά ποσοστά ακρίβειας και άλλων δεικτών απόδοσης, ειδικά όταν τα δεδομένα εκπαίδευσης και αξιολόγησης προέρχονται από παρόμοιες συνθήκες. Ενδεικτικά, η χρήση συνελικτικών νευρωνικών δικτύων σε φασματογραφικές αναπαραστάσεις των ηχητικών δεδομένων έχει αναφερθεί να φτάνει ακρίβεια της τάξης του 90% στην αναγνώριση τύπων αναπνευστικών ήχων (Y. Kim et al. 2021). Ακόμη, τεχνικές μεταφοράς μάθησης και αντιθετικής εκπαίδευσης αποδεικνύεται πως μπορούν να διατηρήσουν την ακρίβεια σε σταθερά επίπεδα κοντά στο 80–85% ακόμη και σε σενάρια cross-domain, δηλαδή πολλαπλών τομέων, όπως και στη δικιά μας περίπτωση (J.-W. Kim et al. 2024). Προσεγγίσεις domain adaptation με χρήση βαθιάς μάθησης, όπως το DANN και παραλλαγές του, έχουν επιτύχει βελτιώσεις της τάξης του 5–15 ποσοστιαίων μονάδων σε περιπτώσεις έντονου *device mis-*

match (Wang et al. 2019; Islam and Nirjon 2021), ενώ η φασματική διόρθωση μπορεί να αποκαταστήσει σημαντικά την πτώση απόδοσης που προκαλείται από αλλαγή συσκευής καταγραφής (Kosmider 2020). Ωστόσο, οι επιδόσεις αυτές φαίνεται πως μειώνονται αισθητά όταν το domain shift οφείλεται σε πολύπλευρες μεταβολές, όπως ταυτόχρονη αλλαγή συσκευής, περιβάλλοντος και πληθυσμιακών χαρακτηριστικών, γεγονός που υποδεικνύει ότι η απόλυτη γενίκευση παραμένει ανεκπλήρωτος στόχος.

Πίνακας 1.1: Σύνοψη *state-of-the-art* αποτελεσμάτων στην αυτόματη ανάλυση αναπνευστικών ήχων και στην ακουστική προσαρμογή τομέα.

Μέθοδος	Σενάριο	Τιμή
CNN με Transfer Learning	Same-domain	90–92%
Explainable CNN (<i>XAI</i>)	Same-domain	~88%
Spectrum Correction	Device mismatch	+10–15%*
DANN	Cross-domain	+5–12%*
Sound-Adapter (MSDA)	Multi-source Cross-domain	+8–14%*
Supervised Contrastive Learning	Cross-domain	80–85%
Co-Tuning με Stochastic Normalization	Same-domain	~89%

* αύξηση σε ποσοστιαίες μονάδες σε σχέση με το baseline accuracy χωρίς προσαρμογή τομέα.

Με βάση τα αποτελέσματα του Πίνακα 1.1, οι πλέον πρόσφατες προσεγγίσεις στην αυτόματη ανάλυση και ταξινόμηση αναπνευστικών ήχων επιτυγχάνουν ποσοστά ακρίβειας που κυμαίνονται από περίπου 90% σε συμβατικά same-domain σενάρια έως και 80–85% σε απαιτητικά cross-domain περιβάλλοντα όπου υφίσταται σημαντικό domain shift. Σενάρια με device mismatch ή multi-source δεδομένα δείχνουν ότι οι μέθοδοι προσαρμογής τομέα μπορούν να αποφέρουν βελτιώσεις της τάξης των 5–15 ποσοστιαίων μονάδων σε σχέση με το τρέχον baseline.

1.4 Στόχοι και συνεισφορά της διπλωματικής εργασίας

Η υπάρχουσα βιβλιογραφία ωστόσο παρατηρείται ότι αφήνει σε δεύτερο πλάνο την προσεκτικά επιμελημένη χειροκίνητη εξαγωγή χαρακτηριστικών από τις αναπαραστάσεις των αναπνευστικών σημάτων, καθώς οι περισσότερες έρευνες τείνουν να χρησιμοποιούν πιο σύνθετες μορφές αναπαράστασης των ήχων ως είσοδο για τα μοντέλα, όπως για παράδειγμα τα φασματογράφηματα (spectrograms) με τη μορφή εικόνας. Επίσης, τα σενάρια προσαρμογής τομέα συνήθως περιλαμβάνουν πολύπλευρο domain shift με αποτέλεσμα να μην απομονώνεται καθαρά η συμβολή της άρσης του device mismatch στην ακρίβεια της ταξινόμησης. Ως συνέπεια, παραμένει μερικώς αναπάντητο το κατά πόσο και μέχρι ποιο βαθμό η στοχευμένη απομάκρυνση του device bias από τα ίδια τα εξαγμένα χαρακτηριστικά μπορεί να επιφέρει συγκρίσιμη ή και ανώτερη cross-device απόδοση σε συνδυασμό με πολύ μικρότερο υπολογιστικό αποτύπωμα. Τέλος, από τη μία γνωρίζουμε ότι η διόρθωση φάσματος (spectrum correction) παρέχει άμεσο κέρδος σε cross-device σενάρια με χαμηλό κόστος, αλλά υστερεί όταν οι κα-

τανομές των επιμέρους χαρακτηριστικών πέρα από τη συσχετιζόμενη πληροφορία συσκευής εμπεριέχουν και ουσιώδη διακριτική πληροφορία για τις κλάσεις. Από την άλλη, οι μέθοδοι προσαρμογής με βαθιά μάθηση μπορούν να ενσωματώσουν ρητά την πληροφορία της κλάσης στη διαδικασία προσαρμογής, ελαχιστοποιώντας τον κίνδυνο αυτής της απώλειας. Συνολικά όμως θα λέγαμε πως απουσιάζει μία συστηματική, head-to-head σύγκριση μεταξύ αυτών των δύο προσεγγίσεων σε ελεγχόμενα device-only shift σενάρια.

Η παρούσα εργασία λοιπόν στοχεύει να καλύψει το παραπάνω κενό υλοποιώντας ένα καθαρό πρωτόκολλο αυστηρής απομόνωσης και αφαίρεσης του bias της συσκευής με την υπόθεση ότι βρισκόμαστε σε σταθερά περιβάλλοντα και πληθυσμό, όπου αυτό είναι εφικτό, ώστε να μετρηθεί αποκλειστικά η επίδραση του device mismatch. Επίσης, η χρήση ελαφρύτερων μοντέλων ως τελικά μοντέλα ταξινόμησης των αναπνευστικών ήχων στοχεύει στην αποτίμηση της καθαρής ωφέλειας της προσαρμογής τομέα ανεξάρτητα από πολύπλοκους deep ταξινομητές.

Στο πλαίσιο της παρούσας διπλωματικής εργασίας, όπου η ανάπτυξη, βελτιστοποίηση και εκπαίδευση των μοντέλων πραγματοποιείται με περιορισμένους υπολογιστικούς πόρους και διαθέσιμα δεδομένα, ένα ρεαλιστικό εύρος απόδοσης για απαιτητικά σενάρια cross-device όπως το δικό μας εκτιμάται κοντά στο 75–78%, εξασφαλίζοντας παράλληλα σαφές κέρδος τουλάχιστον 5 ποσοστιαίων μονάδων σε σχέση με το baseline απόδοσης χωρίς προσαρμογή. Επιδόσεις που υπερβαίνουν το 80% θα θεωρούνταν ιδιαίτερα ικανοποιητικές, δεδομένων των προκλήσεων που εισάγει η ετερογένεια του σήματος και των κατανομών μεταξύ των τομέων. Επιπλέον, στη συγκεκριμένη εργασία περιλαμβάνεται και η διεξοδική ανάλυση ευαισθησίας ως προς τα επιμέρους χαρακτηριστικά και τις διαφορετικές συσκευές καταγραφής, μέσω πειραμάτων και οπτικοποίησης του device invariance πριν και μετά την εφαρμογή των μεθόδων προσαρμογής.


Κεφάλαιο 2

Αναπνευστικοί ήχοι και σήματα

2.1 Ανατομία και φυσιολογία του αναπνευστικού συστήματος

2.1.1 Δημιουργία αναπνευστικών ήχων


Οι αναπνευστικοί ήχοι παράγονται ως αποτέλεσμα της αλληλεπίδρασης της ροής του αέρα με τις ανατομικές δομές του αναπνευστικού συστήματος, από την ανώτερη αεροφόρο οδό έως τα περιφερικά τμήματα των πνευμόνων. Η διαδικασία αυτή περιλαμβάνει πολύπλοκες αεροδυναμικές και μηχανικές διεργασίες, οι οποίες διαμορφώνουν το τελικό ακουστικό αποτύπωμα που μπορεί να καταγραφεί στην επιφάνεια του θώρακα ή της τραχείας.




Σχήμα 2.1: Αναπνευστικό δέντρο.

Το αναπνευστικό δέντρο μπορεί να θεωρηθεί ως ένα σύστημα διαδοχικών ακουστικών αγωγών, του οποίου οι συντονισμοί και η απόκριση εξαρτώνται από τη γεωμετρία, το μήκος και τη διάμετρο των επιμέρους τμημάτων του, όπως η τραχεία, οι κύριοι βρόγχοι και τα βρογχιολίδια. Η ροή του αέρα εντός αυτών των δομών μπορεί να είναι είτε στρωτή, είτε τυρβώδης. Η στρωτή ροή (Σχήμα 2.2) είναι ομαλή και χωρίς σημαντικές διακυμάνσεις πίεσης, ενώ η τυρβώδης ροή (Σχήμα 2.3) χαρακτηρίζεται από στροβιλισμούς και έντονες διακυμάνσεις

πίεσης που οδηγούν στη δημιουργία ακουστικών κυμάτων.



Σχήμα 2.2: Στρωτή ροή αέρα.



Σχήμα 2.3: Τυρβώδης ροή αέρα.


Η τυρβώδης ροή εμφανίζεται κυρίως σε σημεία διακλάδωσης (π.χ. στη διαίρεση της τραχείας σε κύριους βρόγχους) ή σε περιοχές στένωσης και αλλαγής διατομής. Οι διακυμάνσεις πίεσης που δημιουργούνται, μεταδίδονται μέσω του πνευμονικού παρεγχύματος και του θωρακικού τοιχώματος και συνεπώς υφίστανται φασματική απορρόφηση και διασπορά κατά τη διάδοση. Το τελικό ακουστικό σήμα που καταγράφεται από έναν αισθητήρα ή στηθοσκόπιο είναι επομένως το αποτέλεσμα τόσο της πρωτογενούς παραγωγής ήχου (πηγή), όσο και της τροποποίησής του λόγω των ιδιοτήτων διάδοσης του ιστού και της γεωμετρίας του θωρακικού τοιχώματος.

Σε φυσιολογικές συνθήκες, οι ήχοι αναπνοής προέρχονται κυρίως από ήπια τύρβη σε μεγάλες αεροφόρες διαμέτρους, με ευρύ φασματικό περιεχόμενο (τυπικά 100–1200 Hz) και χαμηλή ένταση. Η φασματική ενέργεια κατανέμεται ομαλά, χωρίς έντονες αρμονικές αιχμές. Αντίθετα, σε παθολογικές καταστάσεις, όπως φλεγμονές, υπερέκκριση βλέννης ή στένωση αεραγωγών (π.χ. άσθμα, ΧΑΠ), εμφανίζονται χαρακτηριστικά ηχητικά μοτίβα, τα οποία μπορεί να οφείλονται αφενός σε δονήσεις τοιχωμάτων στενωμένων αεραγωγών και αφετέρου σε απότομο άνοιγμα ή κλείσιμο μικρών αεραγωγικών δομών κατά την πρόωγη εισπνοή ή στην όψιμη εκπνοή.

Συνολικά, η παραγωγή και μετάδοση των αναπνευστικών ήχων αποτελεί το αποτέλεσμα **σύνθετης αλληλεπίδρασης** μεταξύ τριών παραγόντων: του **αεροδυναμικού καθεστώτος ροής**, της **ανατομικής γεωμετρίας των αεραγωγών** και των **μηχανικών και ακουστικών ιδιοτήτων των ιστών** κατά τη διάδοση του κύματος (Priftis et al. 2018; Sarkar et al. 2015).

2.1.2 Διαχωρισμός φυσιολογικών και παθολογικών ήχων

Οι ήχοι που παράγονται κατά τη διάρκεια της αναπνοής διακρίνονται καταρχάς σε δύο βασικές κατηγορίες: τους **ήχους αναπνοής** (*breath sounds*) και τους **πρόσθετους ήχους** (*adventitious sounds*), όπως φαίνεται και στο Σχήμα 2.4. Η διαχωριστικότητα αυτών των δύο κατηγοριών βασίζεται κυρίως σε φυσιολογικά, ακουστικά και μορφολογικά χαρακτηριστικά που σχετίζονται με την αεροδυναμική ροή του αέρα, τη δομή των αεραγωγών και την πιθανή παρουσία παθολογικών μεταβολών στο πνευμονικό παρέγχυμα (Priftis et al. 2018).



Σχήμα 2.4: Οπτική αναπαράσταση του διαχωρισμού μεταξύ φυσιολογικών και παθολογικών αναπνευστικών ήχων.

Οι **ήχοι αναπνοής** περιλαμβάνουν αρχικά τους **φυσιολογικούς ήχους** (*normal breath sounds*), όπως οι τραχειακοί, οι κυψελιδικοί και οι βρογχικοί, οι οποίοι παράγονται από τη στρωτή ροή του αέρα στους πνεύμονες και είναι γενικά συνεχείς, προβλέψιμοι και ομαλοί. Αντιπροσωπεύουν θα μπορούσαμε να πούμε την αναμενόμενη ηχητική δραστηριότητα ενός υγιούς πνεύμονα κατά την αναπνοή. Ωστόσο, η παρουσία αλλοιώσεων στους φυσιολογικούς ήχους, όπως εξασθένιση, ενίσχυση ή μετατόπισή τους σε μη αναμενόμενες περιοχές, οδηγεί στην δεύτερη υποκατηγορία των **μη φυσιολογικών ήχων αναπνοής** (*abnormal breath sounds*). Αυτοί οι ήχοι εξακολουθούν να ανήκουν στη βασική κατηγορία των αναπνευστικών ήχων, αλλά διαφοροποιούνται σε σχέση με τη φυσιολογική ακουστική εικόνα ενός υγιούς πνεύμονα.

Από την άλλη πλευρά, οι **πρόσθετοι ήχοι** αποτελούν νέα ακουστικά συμβάντα που δεν υπάρχουν υπό φυσιολογικές συνθήκες και επικαλύπτουν ή προστίθενται στους βασικούς ήχους αναπνοής. Πρόκειται για ήχους που παράγονται συνήθως λόγω μηχανικής απόφραξης, φλεγμονής, εκκρίσεων ή αλλαγών στην ελαστικότητα των πνευμόνων. Οι πιο συχνές υποκατηγορίες **αδεντιπτιους ήχων** είναι οι **ρόγγχοι** (*crackles*), οι **συριγμοί** (*wheezes*) και οι **ρογχώδεις ήχοι** (*rhonchi*), ενώ σε κάποιες περιπτώσεις περιλαμβάνονται και άλλοι συνεχείς ή μη κατηγοριοποιημένοι ήχοι. Οι *adventitious* ήχοι ανήκουν και αυτοί στην ευρύτερη κατηγορία των *abnormal breath sounds*, αλλά διακρίνονται επειδή συνιστούν σαφώς προστιθέμενες ακουστι-

κές εκδηλώσεις και όχι απλώς παραλλαγές των φυσιολογικών. Τέτοιοι ήχοι σχετίζονται με πληθώρα παθολογικών καταστάσεων, όπως η Πνευμονία, η Χρόνια Αποφρακτική Πνευμονοπάθεια (ΧΑΠ), το Άσθμα, η Καρδιακή Ανεπάρκεια και οι διάμεσες Πνευμονοπάθειες.

Για τους σκοπούς της παρούσας εργασίας, η ανάλυση θα εστιάσει σε δύο από τις συνηθέστερες μορφές *adventitious* ήχων: τους **ρόγγχους** (*crackles*) και τους **συριγμούς** (*wheezes*), οι οποίοι αποτελούν καθοριστικούς δείκτες στη διαγνωστική αξιολόγηση και μπορούν να ανιχνευθούν τόσο με την παραδοσιακή ακρόαση όσο και με σύγχρονες τεχνικές ανάλυσης σήματος.

Η αναγνώριση, η περιγραφή και η ακριβής ταξινόμηση των ήχων αυτών είναι κρίσιμη για την αξιόπιστη διάγνωση των αναπνευστικών παθήσεων, αλλά και για την παρακολούθηση της πορείας της νόσου ή της ανταπόκρισης στη θεραπεία. Επιπλέον, αποτελούν τη βάση για την ανάπτυξη αυτοματοποιημένων συστημάτων ανάλυσης αναπνευστικών ήχων με τη χρήση τεχνολογιών επεξεργασίας σήματος και μηχανικής μάθησης.

Πίνακας 2.1: Συγκριτικός πίνακας φυσιολογικών και παθολογικών αναπνευστικών ήχων (Pranomo, Bowyer, et al. 2017)

Τύπος ήχου	Συνέχεια	Διάρκεια	Χρονισμός	Ύψος (Pitch)	Ηχητική ποιότητα
Normal	Συνεχής	Μεταβλητή	Εισπνοή και Εκπνοή	Χαμηλό-μέσο (100–600 Hz)	Ήπιος, μη μουσικός
Wheeze	Συνεχής	>80 ms	Κυρίως εκπνοή, πιο σπάνια εισπνοή ή και τα δύο	Υψηλό (>400 Hz)	Σφυριχτός, μουσικός
Fine Crackle	Ασυνεχής	±5 ms	Κυρίως εισπνοή (τέλη εισπνοής)	Υψηλό (650 Hz)	Μη μουσικός, εκρηκτικός
Coarse Crackle	Ασυνεχής	±15 ms	Πρώιμη εισπνοή, εκπνοή ή και τα δύο	Χαμηλό (350 Hz)	Μη μουσικός, εκρηκτικός

Ρόγγχοι (Crackles) Οι ρόγγχοι γενικά είναι **διαλείποντες, μη μουσικοί, βραχείας διάρκειας και εκρηκτικοί ήχοι**. Ο όρος διαλείποντες αναφέρεται στο γεγονός ότι δεν πρόκειται για συνεχείς ή σταθερούς ήχους, αλλά για ήχους που εμφανίζονται στιγμιαία και ασυνεχώς κατά τη διάρκεια του αναπνευστικού κύκλου, κυρίως κατά την εισπνοή. Επίσης, η περιγραφή μη μουσικοί δηλώνει ότι οι ρόγγχοι δεν έχουν σταθερό τόνο ή μελωδία σε αντίθεση με τους συριγμούς που εμφανίζουν συχνотικά μοτίβα με μουσικό χαρακτήρα. Η βραχεία διάρκεια υποδηλώνει ότι κάθε επιμέρους ήχος διαρκεί ελάχιστα χιλιοστά του δευτερολέπτου, γεγονός

που καθιστά τον εντοπισμό τους ιδιαίτερα δύσκολο χωρίς εξειδικευμένο εξοπλισμό. Τέλος, ο χαρακτηρισμός εκρηκτικοί αποδίδει πιο διαισθητικά την ακουστική τους αίσθηση, καθώς πρόκειται για ήχους που ξεκινούν απότομα και θυμίζουν μικρές εκρήξεις ή σπάσιμο φυσαλίδων, γεγονός που αποδίδεται στις ταχείες μεταβολές πίεσης και τάσης κατά το άνοιγμα ή το κλείσιμο των αεραγωγών. Διακρίνονται σε δύο βασικούς τύπους: τους **λεπτούς ρόγχους** (*fine crackles*) και τους **χονδροειδείς ρόγχους** (*coarse crackles*).

Συριγμοί (Wheezes) Οι συριγμοί είναι **συνεχόμενοι, μουσικοί, υψηλής συχνότητας ήχοι** που παράγονται κυρίως κατά τη φάση της εκπνοής, αν και σε σοβαρότερες περιπτώσεις μπορεί να εμφανίζονται και κατά την εισπνοή ή να έχουν διφασικό χαρακτήρα. Ο όρος συνεχόμενοι δηλώνει ότι παρουσιάζουν παρατεταμένη διάρκεια και ακολουθούν σχετικά σταθερό χρονικό μοτίβο. Ο χαρακτηρισμός μουσικοί υποδηλώνει ότι διαθέτουν σταθερή ή σχεδόν σταθερή συχνότητα, γεγονός που τους προσδίδει ακουστικά την αίσθηση ενός τόνου ή λεπτού σφυρίγματος, σε αντίθεση με τους μη μουσικούς και ακανόνιστους ήχους των *crackles*.

2.2 Αναπνευστικά σήματα

2.2.1 Ορισμός, μεγέθη και ιδιότητες

Σήμα Ορίζεται ως μια συνάρτηση μίας ή παραπάνω μεταβλητών που μεταφέρει πληροφορία σχετικά με τη συμπεριφορά ή τα χαρακτηριστικά ενός φυσικού φαινομένου. Ένα σήμα μπορεί να παριστά ακουστική πίεση, θερμοκρασία, τάση, φωτεινότητα, ή οποιοδήποτε φυσικό μέγεθος μεταβάλλεται ως προς το χρόνο ή οποιαδήποτε άλλη ανεξάρτητη μεταβλητή. Μια τέτοια κατηγορία σημάτων είναι τα ηχητικά ή ακουστικά σήματα (Lerch 2012).

Ηχητικό σήμα Είναι η φυσική αναπαράσταση της διαταραχής που προκαλείται από την κίνηση μορίων ενός μέσου εξαιτίας της ταλάντωσης μιας ηχητικής πηγής. Η διαταραχή αυτή μεταδίδεται υπό μορφή μηχανικών κυμάτων πίεσης και γίνεται αντιληπτή από το ανθρώπινο αυτί ως ήχος. Στην περίπτωση των **αναπνευστικών ήχων**, η ηχητική πηγή δεν είναι ένα εξωτερικό αντικείμενο, αλλά η ίδια η ροή του αέρα στους αεραγωγούς του αναπνευστικού συστήματος. Συνεπώς, με βάση αυτό μπορούμε να ορίσουμε και το αναπνευστικό σήμα ως μια υποκατηγορία ηχητικού σήματος ως εξής:

Αναπνευστικό σήμα Αποτελεί τη χρονική καταγραφή των αναπνευστικών ήχων, όπως αυτοί ανιχνεύονται σε επιλεγμένες επιφάνειες του θωρακικού τοιχώματος ή της τραχείας με κατάλληλες συσκευές καταγραφής, όπως αισθητήρες, μικρόφωνα ή στηθοσκόπια. Το σήμα αυτό περιλαμβάνει πληροφορία για την ένταση, τη συχνότητα, τη διάρκεια και τη χροιά του αναπνευστικού ήχου και μεταβάλλεται φυσιολογικά κατά τη φάση της εισπνοής και της εκπνοής.

Η ανάλυση των αναπνευστικών σημάτων παρέχει σημαντικές ενδείξεις για την καλή ή κακή λειτουργία του αναπνευστικού συστήματος του ασθενούς και αποτελεί αντικείμενο τόσο της ιατρικής διαγνωστικής όσο και της σύγχρονης ψηφιακής επεξεργασίας σήματος. Από

φυσική άποψη, πρόκειται για μη περιοδικά, μη αρμονικά, χαμηλής έως μέσης συχνότητας ηχητικά σήματα, των οποίων το ενεργειακό φάσμα εκτείνεται κατά κύριο λόγο στην περιοχή των 100–1200 Hz.

Στο πλαίσιο της επεξεργασίας σήματος, το αναπνευστικό σήμα αναπαρίσταται ως μια μαθηματική συνάρτηση του χρόνου:

$$x(t), \quad t \in \mathbb{R}$$

όπου $x(t)$ είναι το στιγμιαίο πλάτος του ηχητικού σήματος σε σχέση με τον χρόνο t .

Αρχικά, είναι σημαντικό να ορίσουμε πρώτα κάποια βασικά μεγέθη της θεωρίας σημάτων, μεταξύ των οποίων:

Πλάτος (Amplitude) Είναι η μέγιστη τιμή της απόλυτης τιμής του σήματος σε κάποιο χρονικό διάστημα.

$$A = \max_t |x(t)| \quad (2.1)$$

Στα ηχητικά σήματα αντιστοιχεί στη μέγιστη ακουστική πίεση.

Συχνότητα (Frequency) Ορίζεται για περιοδικά σήματα ως ο αριθμός κύκλων ανά δευτερόλεπτο. Αν η περίοδος του σήματος είναι T , τότε η συχνότητα είναι:

$$f = \frac{1}{T} \quad (2.2)$$

Φάση (Phase) Για αρμονικά σήματα της μορφής $x(t) = A \cos(2\pi ft + \phi)$, η ϕ είναι η αρχική φάση και αντιπροσωπεύει τη χρονική μετατόπιση ενός κύματος ως προς κάποιο σημείο αναφοράς. Στη φασματική ανάλυση, η φάση καθορίζει τη χρονική ευθυγράμμιση μεταξύ συχνοτικών συνιστωσών. Αν και δεν γίνεται απευθείας αντιληπτή από το ανθρώπινο αυτί, είναι κρίσιμη σε εφαρμογές όπως η υπέρθεση σημάτων, η ανασύνθεση κυματομορφών και η τρισδιάστατη ακουστική απεικόνιση.

Ενέργεια (Energy) Η συνολική ενέργεια ενός σήματος εκφράζει το σύνολο της «έντασης» που περιέχει το σήμα σε όλο τον χρόνο. Ορίζεται ως:

$$E = \int_{-\infty}^{\infty} |x(t)|^2 dt \quad (2.3)$$

και αποτελεί ένα μέτρο χρήσιμο για σήματα πεπερασμένης διάρκειας, όπως π.χ. ένας εισπνευστικός ήχος που καταγράφηκε για μερικά δευτερόλεπτα. Όσο μεγαλύτερη η ενέργεια, τόσο εντονότερο είναι και το σήμα.

Ισχύς (Power) Για σήματα θεωρητικά άπειρης διάρκειας ή περιοδικά σήματα, η ενέργεια καθίσταται απερίοριστη, οπότε χρησιμοποιείται η **μέση ισχύς**:

$$P = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T |x(t)|^2 dt \quad (2.4)$$

Η ισχύς αντιπροσωπεύει τη ρυθμό μετάδοσης ενέργειας και είναι χρήσιμη στην αξιολόγηση σήματος σε συνεχή λειτουργία. Αναπνευστικά σήματα περιοδικής φύσης συχνά προσεγγίζονται ως σήματα ισχύος.

Ένταση ήχου (*Sound Intensity*) Η ένταση ήχου είναι ένα φυσικό μέγεθος που εκφράζει τη ροή ηχητικής ενέργειας ανά μονάδα επιφάνειας και μονάδα χρόνου. Ορίζεται ως:

$$I = \frac{P}{A} \quad (2.5)$$

όπου P είναι η ακουστική ισχύς (σε W) και A η επιφάνεια διάδοσης. Η ένταση εκφράζεται συχνά σε λογαριθμική κλίμακα (dB):

$$L_I = 10 \log_{10} \left(\frac{I}{I_0} \right) \text{ dB} \quad (2.6)$$

με $I_0 = 10^{-12} \text{ W/m}^2$ ως τιμή αναφοράς στο κατώφλι ακοής. Για αναπνευστικά σήματα, η ένταση σχετίζεται με τη δύναμη της ροής του αέρα στους αεραγωγούς και διαφέρει σημαντικά μεταξύ φυσιολογικής και παθολογικής αναπνοής.

Ύψος ήχου (*Pitch*) Είναι η ψυχοακουστική αντίληψη του ύψους ενός ήχου, δηλαδή αν ακούγεται ψηλός ή βαθύς. Ενώ στα αρμονικά σήματα σχετίζεται άμεσα με τη θεμελιώδη συχνότητα ($f_0 = 1/T_0$), στους πολύπλοκους και μη αρμονικούς ήχους όπως οι αναπνευστικοί μπορεί να είναι δύσκολο να προσδιοριστεί.

Τα αναπνευστικά σήματα ως μαθηματικές συναρτήσεις χαρακτηρίζονται επίσης και από συγκεκριμένες ιδιότητες που επηρεάζουν καθοριστικά τον τρόπο με τον οποίο αναλύονται και επεξεργάζονται. Η κατανόηση αυτών των ιδιοτήτων είναι απαραίτητη τόσο για την επιλογή κατάλληλων τεχνικών επεξεργασίας όσο και για την ερμηνεία των αποτελεσμάτων, ιδιαίτερα όταν πρόκειται για βιοϊατρικά ακουστικά σήματα όπως οι αναπνευστικοί ήχοι. Οι βασικές ιδιότητες των αναπνευστικών σημάτων που σχετίζονται με την παρούσα μελέτη είναι:

Περιοδικότητα Ένα σήμα $x(t)$ λέγεται περιοδικό αν υπάρχει θετική σταθερά T (περίοδος) τέτοια ώστε:

$$x(t) = x(t + T), \quad \forall t \in \mathbb{R}. \quad (2.7)$$

Τα περιοδικά σήματα έχουν επαναλαμβανόμενη δομή στον χρόνο, γεγονός που επιτρέπει την ανάλυσή τους μέσω αρμονικών συνιστωσών με χρήση σειράς *Fourier*. **Στην περίπτωση των αναπνευστικών σημάτων η περιοδικότητα δεν ισχύει σε αυστηρό μαθηματικό επίπεδο.** Το αναπνευστικό σήμα μεταβάλλεται από κύκλο σε κύκλο, τόσο ως προς τη διάρκεια εισπνοής/εκπνοής όσο και ως προς την ένταση και τη φασματική του δομή. Επομένως, το σήμα θεωρείται **μη περιοδικό**. Ωστόσο, σε ορισμένες παθολογικές καταστάσεις όπως οι συριγμοί παρατηρείται μια ημι-περιοδική συμπεριφορά, δηλαδή το σήμα παρουσιάζει περιοχές σχεδόν περιοδικού μοτίβου, λόγω της στροβιλώδους ροής του αέρα σε στενωμένους αεραγωγούς.

Στασιμότητα Αφορά τη χρονική σταθερότητα των στατιστικών χαρακτηριστικών του αναπνευστικού σήματος. Υπάρχουν δύο βασικοί τύποι:

- **Ασθενής στασιμότητα:** Ένα στοχαστικό σήμα $x(t)$ είναι ασθενώς στάσιμο όταν:

1. Η μέση τιμή του είναι σταθερή και ανεξάρτητη από το χρόνο:

$$\mathbb{E}[x(t)] = \mu, \quad \forall t \quad (2.8)$$

2. Η συνάρτηση αυτοσυσχέτισής του εξαρτάται μόνο από τη χρονική διαφορά $t_1 - t_2$:

$$R_{xx}(t_1, t_2) = R_{xx}(t_1 - t_2) = R_{xx}(\tau) \quad (2.9)$$

- **Ισχυρή στασιμότητα:** Ισχύει όταν η κατανομή πιθανότητας οποιουδήποτε συνδυασμού τιμών του σήματος είναι ανεξάρτητη της χρονικής μετατόπισης, δηλαδή:

$$F_{x(t_1), x(t_2), \dots, x(t_n)} = F_{x(t_1+\tau), x(t_2+\tau), \dots, x(t_n+\tau)}, \quad \forall t_i, \forall \tau \quad (2.10)$$

Τα αναπνευστικά σήματα δεν είναι στάσιμα, καθώς η μέση τιμή, η διακύμανση και το φασματικό περιεχόμενο μεταβάλλονται στη διάρκεια του αναπνευστικού κύκλου και μεταξύ διαφορετικών κύκλων. Αυτό περιορίζει την εφαρμογή κλασικών τεχνικών φασματικής ανάλυσης (όπως *FFT* σε ολόκληρο το σήμα) και απαιτεί τη χρήση εργαλείων όπως ο *Short Time Fourier Transform (STFT)*, ο οποίος θα αναλυθεί εκτενέστερα παρακάτω.

Στοχαστικότητα Ένα σήμα μπορεί να είναι ντετερμινιστικό (*deterministic*) αν η μορφή του μπορεί να προβλεφθεί από έναν συγκεκριμένο μαθηματικό τύπο χωρίς αβεβαιότητα. Από την άλλη, είναι στοχαστικό (*stochastic*) όταν περιέχει τυχαίες συνιστώσες και περιγράφεται μόνο μέσω στατιστικών μέτρων (μέση τιμή, διακύμανση, κατανομή πιθανότητας). **Τα αναπνευστικά σήματα έχουν στοχαστική φύση** για δύο βασικούς λόγους. Πρώτον, η παραγωγή ήχου εξαρτάται από τη φυσιολογία και την ανατομία του κάθε ατόμου, αλλά και από δυναμικούς παράγοντες όπως ο όγκος και η ταχύτητα ροής του αέρα. Δεύτερον, τα σήματα από συσκευές επηρεάζονται από εξωτερικούς ή μη αναπνευστικούς ήχους (καρδιακοί ήχοι, ομιλία, θόρυβος περιβάλλοντος), προσθέτοντας στοχαστική διακύμανση.

2.2.2 Στηθοσκόπια και συσκευές καταγραφής

Η καταγραφή των αναπνευστικών ήχων αποτελεί απαραίτητη προϋπόθεση για την αντικειμενική ανάλυση και αξιολόγησή τους με τη βοήθεια σύγχρονων τεχνικών ψηφιακής επεξεργασίας σήματος (*Digital Signal Processing, DSP*). Για τον σκοπό αυτό, χρησιμοποιούνται εξειδικευμένες ιατρικές συσκευές ικανές να συλλάβουν με υψηλή ακρίβεια τα χαμηλά επίπεδα έντασης και το ευρύ φασματικό περιεχόμενο των ήχων που παράγονται κατά την αναπνοή. Στην κατηγορία αυτή περιλαμβάνονται κυρίως τα **στηθοσκόπια** και οι **ηλεκτρονικοί αισθητήρες υψηλής ευαισθησίας**.

Ακουστικό στηθοσκόπιο Το ακουστικό στηθοσκόπιο αποτελεί το ιστορικά καθιερωμένο εργαλείο κλινικής ακρόασης, βασιζόμενο στη μηχανική μετάδοση του ήχου μέσω ελαστικών σωλήνων από το θωρακικό τοίχωμα στο αυτί του εξεταστή. Παρά τη διαχρονική του αξία, παρουσιάζει ορισμένους περιορισμούς, όπως το ότι δεν υποστηρίζει απευθείας καταγραφή ή ψηφιακή ανάλυση ή ότι η ποιότητα του ακουστικού σήματος επηρεάζεται από θορύβους περιβάλλοντος και από την ακουστική οξύτητα του εξεταστή. Συνεπώς, η ερμηνεία του ήχου εξαρτάται σε μεγάλο βαθμό από την εμπειρία και την υποκειμενική κρίση του χρήστη.

Ψηφιακό ή ηλεκτρονικό στηθοσκόπιο Η τεχνολογική εξέλιξη οδήγησε στην ανάπτυξη των ηλεκτρονικών ή ψηφιακών στηθοσκοπίων, τα οποία ενσωματώνουν μικρόφωνα επαφής υψηλής ευαισθησίας και ηλεκτρονικά κυκλώματα για ενίσχυση, φιλτράρισμα και ψηφιοποίηση του ηχητικού σήματος. Σε σύγκριση με τα κλασικά στηθοσκόπια, προσφέρουν πολλαπλά πλεονεκτήματα, όπως η δυνατότητα καταγραφής για μεταγενέστερη ανάλυση και αρχειοθέτηση, η αποθορυβοποίηση μέσω ψηφιακών φίλτρων και η φασματική ανάλυση σε πραγματικό χρόνο. Ορισμένα σύγχρονα μοντέλα συνοδεύονται επιπλέον από λογισμικό που εμφανίζει την κυματομορφή και το φάσμα σε πραγματικό χρόνο, παρέχοντας στον κλινικό ιατρό πρόσθετες οπτικές πληροφορίες για την αξιολόγηση.

Συστήματα πολλαπλών αισθητήρων και ειδικές συσκευές ηχογράφησης Πέραν των στηθοσκοπίων, για ερευνητικούς και κλινικούς σκοπούς χρησιμοποιούνται συχνά συστοιχίες μικροφώνων ή εξειδικευμένοι αισθητήρες τοποθετημένοι σε προκαθορισμένα σημεία του θώρακα ή της τραχείας. Οι διατάξεις αυτές παρέχουν υψηλή πιστότητα καταγραφής σε ένα ευρύ φάσμα συχνοτήτων, μιας και υποστηρίζουν συχνότητες δειγματοληψίας συνήθως 4 kHz έως 44.1 kHz ή και περισσότερο.




Σχήμα 2.5: Συσκευές καταγραφής αναπνευστικών ήχων.

Η επιλογή συσκευής καταγραφής είναι κρίσιμη, καθώς επηρεάζει άμεσα την ποιότητα του αναπνευστικού σήματος και κατ' επέκταση την αξιοπιστία της φασματικής ανάλυσης και των μεταγενέστερων διαγνωστικών συμπερασμάτων. Τα σήματα που συλλέγονται από τις παραπάνω συσκευές καταγραφής αποθηκεύονται συνήθως σε μορφή αρχείων .wav, τα οποία αποτελούν ένα από τα πιο διαδεδομένα πρότυπα για την αποθήκευση ηχητικών δεδομένων χωρίς απώλειες. Η μορφή αυτή διατηρεί πλήρως την ακουστική πληροφορία που απαιτείται για

αξιόπιστη φασματική ανάλυση και εφαρμογή αλγορίθμων μηχανικής μάθησης.

Ωστόσο, προκειμένου να μπορέσουν τα σήματα να αποθηκευτούν και να υποβληθούν σε περαιτέρω επεξεργασία, είναι απαραίτητο να έχει προηγηθεί η διαδικασία της **ψηφιοποίησης**, η οποία περιγράφεται στην επόμενη υποενότητα.

2.2.3 Ψηφιοποίηση



Σχήμα 2.6: Pipeline ψηφιοποίησης αναπνευστικών ηχητικών σημάτων.

Γενικά, τα αναπνευστικά σήματα ανήκουν γενικά στην κατηγορία των **αναλογικών συνεχών σημάτων**, καθώς το πλάτος και ο χρόνος αποτελούν συνεχείς μεταβλητές. Συνεπώς, η μελέτη των αναπνευστικών ήχων σε ψηφιακή μορφή απαιτεί πρώτα από όλα τη μετατροπή του φυσικού ηχητικού σήματος, το οποίο συνιστά συνεχές αναλογικό μέγεθος, σε διακριτό αριθμητικό σήμα, δηλαδή σε ψηφιακή μορφή κατάλληλη για επεξεργασία από το υπολογιστικό σύστημα. Η διαδικασία αυτή ονομάζεται **ψηφιοποίηση** (*digitization*) και περιλαμβάνει 3 βασικά στάδια: τη **δειγματοληψία** (*sampling*), τη **κβάντιση** (*quantization*) και τη **κωδικοποίηση** (*encoding*) (Lerch 2012).

Δειγματοληψία Η δειγματοληψία είναι η διαδικασία κατά την οποία το συνεχές αναπνευστικό σήμα $x(t)$ μετράται και καταγράφεται σε διακριτά χρονικά διαστήματα. Δημιουργείται έτσι μια ακολουθία τιμών $x[n] = x(nT_s)$, όπου T_s είναι το **διάστημα δειγματοληψίας** και $f_s = \frac{1}{T_s}$ η **συχνότητα δειγματοληψίας** με μονάδα μέτρησης τα Hz. Σύμφωνα με το **Θεώρημα Nyquist–Shannon** προκειμένου να ανακατασκευαστεί πλήρως το αρχικό αναλογικό αναπνευστικό σήμα από τα δείγματά του χωρίς παραμόρφωση, η συχνότητα δειγματοληψίας πρέπει να είναι τουλάχιστον διπλάσια της μέγιστης συχνότητας του σήματος:

$$f_s \geq 2f_{\max} \quad (2.11)$$

Η ακατάλληλη δειγματοληψία οδηγεί σε φαινόμενα επικάλυψης φασματικών συνιστωσών (*aliasing*), τα οποία δεν μπορούν να αποκατασταθούν εκ των υστέρων οδηγώντας έτσι σε απώλεια πληροφορίας. Για τους αναπνευστικούς ήχους συγκεκριμένα, των οποίων το σημαντικό φασματικό περιεχόμενο εντοπίζεται κυρίως μεταξύ 50 και 1200 Hz, η ελάχιστη απαιτούμενη

συχνότητα δειγματοληψίας είναι 2.4 kHz. Στην πράξη ωστόσο χρησιμοποιούνται συσκευές καταγραφής με τιμές συχνότητας δειγματοληψίας όπως 4 kHz, 8 kHz ή και 44.1 kHz (τυπική συχνότητα *CD*), ώστε να διατηρείται υψηλή η πιστότητα του σήματος.

Κβάντιση Αφού το αναπνευστικό σήμα έχει μετατραπεί σε διακριτή ακολουθία χρονικών στιγμών $x[n]$, το επόμενο βήμα είναι να μετατραπούν τα συνεχόμενα πλάτη των δειγμάτων σε διακριτές αριθμητικές τιμές. Η διαδικασία αυτή ονομάζεται **κβάντιση** και πραγματοποιείται μέσω του μετατροπέα A/D (*analog-to-digital converter*) μέσω του οποίου προκύπτει η κβαντισμένη διακριτή ακολουθία $\tilde{x}[n]$. Πιο συγκεκριμένα, ο κβαντιστής χωρίζει το εύρος τιμών του πλάτους σε $L = 2^B$ επίπεδα, όπου B είναι ο αριθμός των **bit ανά δείγμα** (*bit depth*). Όσο μεγαλύτερο είναι το βάθος *bit*, τόσο μεγαλύτερη είναι και η ακρίβεια της αναπαράστασης, αλλά παράλληλα τόσο αυξάνεται και ο απαιτούμενος αποθηκευτικός χώρος. Η διαφορά μεταξύ της πραγματικής τιμής του πλάτους και της πλησιέστερης κβαντισμένης τιμής ονομάζεται **σφάλμα κβάντισης** και ορίζεται ως $e[n] = x[n] - \tilde{x}[n]$. Το σφάλμα αυτό λειτουργεί σαν πρόσθετος θόρυβος και μπορεί να υποβαθμίσει την ποιότητα του σήματος, ειδικά σε χαμηλής έντασης σήματα όπως οι ήχοι του αναπνευστικού. Τέλος, η ποιότητα της ψηφιακής αναπαράστασης εκφράζεται συχνά μέσω του **λόγου σήματος προς σφάλμα κβάντισης** (*Signal-to-Quantization-Noise Ratio, SQNR*), ο οποίος μετρείται σε κλίμακα dB.

Κωδικοποίηση Η διαδικασία της ψηφιοποίησης ολοκληρώνεται με την **κωδικοποίηση** (*encoding*) κατά την οποία οι κβαντισμένες τιμές μετατρέπονται σε δυαδικές ακολουθίες. Κάθε τιμή αντιστοιχίζεται σε έναν μοναδικό συνδυασμό από bits ανάλογα με το βάθος κβάντισης B , δημιουργώντας έτσι τη ψηφιακή αναπαράσταση του σήματος. Για παράδειγμα, σε 8-bit κβάντιση υπάρχουν $2^8 = 256$ επίπεδα και κάθε τιμή κωδικοποιείται με 8 *bits*. Η κωδικοποιημένη μορφή είναι αυτή που χρησιμοποιείται τελικά από το υπολογιστικό σύστημα για αποθήκευση, επεξεργασία ή μετάδοση. Η κωδικοποίηση δεν μεταβάλλει τη φυσική πληροφορία του σήματος, αλλά είναι απαραίτητο βήμα για την ακριβή ψηφιακή αναπαράστασή του.

Στην παρούσα εργασία, τα σήματα που προκύπτουν μετά τη διαδικασία ψηφιοποίησης αποθηκεύονται σε μορφή *.wav* με κωδικοποίηση PCM_S16LE, δηλαδή *Pulse Code Modulation* 16-bit σε διάταξη *little-endian*. Η επιλογή αυτής της μορφής (*s16*) εξασφαλίζει αποθήκευση χωρίς συμπίεση, διατηρώντας πλήρως την ακουστική πληροφορία, ενώ παράλληλα παρέχει ευρεία υποστήριξη από λογισμικό και βιβλιοθήκες επεξεργασίας σήματος.

Κεφάλαιο 3

Ψηφιακή επεξεργασία αναπνευστικών σημάτων

3.1 Αναπαράσταση αναπνευστικών σημάτων

Η αναπαράσταση ενός ακουστικού σήματος το οποίο είναι αποθηκευμένο σε ένα αρχείο .wav αποτελεί θεμελιώδες στάδιο στην ανάλυση και επεξεργασία του, καθώς καθορίζει τον τρόπο με τον οποίο η πληροφορία αποτυπώνεται, ερμηνεύεται και εξάγεται για χρήση σε εφαρμογές αναγνώρισης προτύπων και διάγνωσης. Στην περίπτωση των αναπνευστικών ήχων, η επιλογή κατάλληλης αναπαράστασης είναι ιδιαίτερα κρίσιμη, καθώς τα σήματα αυτά χαρακτηρίζονται από υψηλή διακύμανση, μη στασιμότητα και συχνά περιέχουν σύνθετες παροδικές ή περιοδικές δομές που σχετίζονται με φυσιολογικές ή παθολογικές καταστάσεις.

Η αναπνευστική ηχογράφηση αποτελεί χρονική αποτύπωση της πίεσης του αέρα κατά την εισπνοή και την εκπνοή και περιλαμβάνει πληροφορία που εκτείνεται τόσο στο πεδίο του χρόνου (χρονική εξέλιξη πλάτους) όσο και στο πεδίο της συχνότητας (φασματική κατανομή ενέργειας). Η ενότητα αυτή λοιπόν παρουσιάζει τις κύριες μορφές αναπαράστασης που χρησιμοποιούνται στην παρούσα εργασία, ξεκινώντας από το **πεδίο του χρόνου**, όπου απεικονίζεται η **κυματομορφή του σήματος** και συνεχίζοντας με το **πεδίο του χρόνου-συχνότητας**, όπου εφαρμόζεται ο *Short Time Fourier Transform (STFT)* για την παραγωγή φασματοχρονικών αναπαραστάσεων. Οι αναπαραστάσεις αυτές χρησιμεύουν αφενός για την οπτική αξιολόγηση του σήματος, αφετέρου για την εξαγωγή διαγνωστικά χρήσιμων χαρακτηριστικών που αξιοποιούνται από τα μοντέλα μηχανικής μάθησης.


3.1.1 Πεδίο χρόνου (Κυματομορφή)

Η αναπαράσταση ενός σήματος στο πεδίο του χρόνου είναι η πιο άμεση μορφή απεικόνισης και ανάλυσής του. Πρόκειται για την απεικόνιση του πλάτους του σήματος ως προς τον άξονα του χρόνου, δηλαδή της συνάρτησης $x(t)$ για αναλογικά σήματα ή $x[n]$ για διακριτά. Το γράφημα που προκύπτει ονομάζεται *κυματομορφή (waveform)* και αποτελεί την πρώτη οπτική προσέγγιση της πληροφορίας που φέρει το σήμα.

Στην περίπτωση των αναπνευστικών σημάτων, η αναπαράσταση στο πεδίο του χρόνου αποδίδει με φυσικό τρόπο την ένταση και την ακολουθία των αναπνευστικών φάσεων (εισπνοή-εκπνοή), καθώς και την χρονική εξέλιξη ενδεχόμενων παθολογικών ηχητικών συμβάντων (π.χ. *crackles*, *wheezes*). Η διάρκεια των επιμέρους φάσεων, η συμμετρία ή η ασυμμετρία τους, καθώς και η παρουσία περιοχών ησυχίας ή αιχμών είναι χαρακτηριστικά που καθίστανται άμεσα παρατηρήσιμα στο χρονικό διάγραμμα.

Ωστόσο, η ανάλυση στο πεδίο του χρόνου παρουσιάζει περιορισμούς εφόσον δεν αποκάλυπτει τη συχνотική σύνθεση του σήματος ούτε την ενεργειακή κατανομή ανά συχνότητα. Παρόλο που ορισμένες πληροφορίες όπως η σχετική ένταση, η διάρκεια ή ο ρυθμός εμφάνισης μπορούν να εξαχθούν απευθείας, πολλές φορές απαιτείται η συμπληρωματική ανάλυση στο πεδίο της συχνότητας ή στο πεδίο χρόνου-συχνότητας για την πλήρη κατανόηση της δομής του σήματος.

Πιο κάτω παρουσιάζονται ενδεικτικά οι κυματομορφές από ορισμένες καταγραφές του *dataset* μας πάνω στις οποίες σημειώνονται η αρχή και το τέλος κάθε αναπνευστικού κύκλου της καταγραφής, καθώς και η πάθηση η οποία εντοπίζεται σε αυτόν:



Σχήμα 3.1: Κυματομορφές αναπνευστικών καταγραφών του *dataset*.

Η πρώτη και η τελευταία κυματομορφή εμφανίζουν χαμηλής έντασης, μη περιοδικά σήματα με συμμετρικές φάσεις εισπνοής και εκπνοής, χωρίς απότομες κο-

ρυφές ή επαναλαμβανόμενα μοτίβα. Η μορφολογία τους χαρακτηρίζεται από ακανόνιστες διακυμάνσεις σε εύρος πλάτους, χωρίς έντονες χρονικά εντοπισμένες αποκλίσεις. Αυτά τα χαρακτηριστικά είναι αντιπροσωπευτικά των **φυσιολογικών κυψελιδικών ήχων**, που σχετίζονται με ήπια, διάχυτη ροή αέρα στους περιφερικούς αεραγωγούς. Η απουσία περιοδικότητας, απότομων συμβάντων ή στενών φασματικών αιχμών αποτελεί ένδειξη μη ύπαρξης παθολογικών αλλοιώσεων.

Αντίθετα, η δεύτερη κυματομορφή περιέχει εκτεταμένες χρονικές περιοχές με παρουσία **crackles**, δηλαδή **απότομες, ασύμμετρες αιχμές σύντομης διάρκειας, με οξείες κορυφές και ταχεία αποκατάσταση**. Τα ηχητικά αυτά γεγονότα είναι τυπικά φαινόμενα μικρών αεραγωγών, συνήθως σε περιπτώσεις πνευμονικής ίνωσης, πνευμονίας ή καρδιογενούς πνευμονικού οιδήματος. Η χρονική πυκνότητα και κατανομή αυτών των ριπών ενισχύει την υπόθεση παρουσίας παθολογίας στην αναπνευστική οδό.

Η τρίτη κυματομορφή εμφανίζει παρατεταμένο τμήμα με **wheezes**, δηλαδή **περιοδικά ή ημι-περιοδικά μοτίβα αυξομειούμενης έντασης με σχεδόν σταθερό ρυθμό**. Αυτή η συμπεριφορά υποδηλώνει την ύπαρξη στενώσεων ή απόφραξης σε μεσαίους αεραγωγούς, καθώς τα **wheezes** προκαλούνται από στροβιλώδη ροή αέρα σε περιορισμένα ανοίγματα.

3.1.2 Πεδίο χρόνου-συχνότητας (Φασματογράφημα)

Η αναπαράσταση ενός σήματος στο πεδίο της συχνότητας είναι καίριας σημασίας και επιτρέπει την αποκάλυψη της φασματικής του σύνθεσης, δηλαδή των συχνοτήτων που το απαρτίζουν και της σχετικής έντασης καθενιάς. Ενώ στο πεδίο του χρόνου παρατηρείται η χρονική μεταβολή του πλάτους του σήματος, η φασματική αναπαράσταση απαντά στο ερώτημα: «*Ποιες συχνότητες συνθέτουν αυτό το σήμα και σε ποιο βαθμό*». Για παράδειγμα, ενώ στο πεδίο του χρόνου ένα σήμα μπορεί να εμφανίζεται για παράδειγμα ως πολύπλοκη και ακανόνιστη κυματομορφή, στο πεδίο συχνοτήτων μπορεί να αποδοθεί ως συνδυασμός ημιτονοειδών κυμάτων διαφόρων συχνοτήτων, φάσεων και πλάτων. Αυτό καθιστά δυνατή την απομόνωση, ενίσχυση ή καταστολή συγκεκριμένων συχνοτικών συνιστωσών κατά την επεξεργασία σήματος.

Η βασική μέθοδος για τη μετάβαση από το χρονικό στο συχνοτικό πεδίο είναι ο **Μετασχηματισμός Fourier** ο οποίος για σήματα συνεχούς χρόνου υπολογίζεται ως εξής:

$$X(f) = \int_{-\infty}^{\infty} x(t)e^{-j2\pi ft} dt \quad (3.2)$$

Η τιμή $|X(f)|$ εκφράζει τη «συνεισφορά» της συχνότητας f στο συνολικό σήμα και ονομάζεται **απόκριση πλάτους**. Επιπλέον, η **φασματική πυκνότητα ισχύος** (*spectral power density*) ορίζεται ως:

$$S(f) = |X(f)|^2$$

και εκφράζει πόση ισχύς συγκεντρώνεται σε κάθε συχνότητα. Στην πράξη, η φασματική πυκνότητα είναι ιδιαίτερα χρήσιμη για τη διάκριση μεταξύ φυσιολογικών και παθολογικών αναπνευστικών ήχων.

Ωστόσο, η πλειονότητα των σημάτων που επεξεργάζονται οι υπολογιστές είναι σήματα διακριτού χρόνου πεπερασμένου μήκους $x[n]$, τα οποία όπως αναφέραμε προέρχονται από

τη δειγματοληψία των αντίστοιχων σημάτων συνεχούς χρόνου. Για την ανάλυσή τους στο πεδίο της συχνότητας χρησιμοποιείται λοιπόν ο **Διακριτός Μετασχηματισμός Fourier** (*Discrete Fourier Transform, DFT*), ο οποίος ορίζεται ως:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi \frac{k}{N}n}, \quad k = 0, 1, \dots, N-1 \quad (3.3)$$

όπου N είναι ο αριθμός των δειγμάτων του σήματος.

Ο *DFT* παρέχει μια **διακριτή συχνοτική αναπαράσταση** του σήματος με N φασματικά δείγματα που κατανέμονται ομοιόμορφα στο διάστημα $[0, f_s)$, όπου f_s η συχνότητα δειγματοληψίας. Η εφαρμογή του στην πράξη γίνεται μέσω του αλγορίθμου *Fast Fourier Transform (FFT)*, ο οποίος βασίζεται στη στρατηγική του *Διαίρει και Βασίλευε* και έτσι μειώνεται δραστικά η υπολογιστική πολυπλοκότητα.

Στην περίπτωση των αναπνευστικών σημάτων, η φασματική ανάλυση υλοποιείται με έναν ελαφρώς διαφορετικό τρόπο από αυτόν που μόλις περιγράψαμε. Η διαφορά έγκειται στο γεγονός ότι ο κλασικός Διακριτός Μετασχηματισμός *Fourier* θεωρεί ότι το σήμα είναι στάσιμο και σταθερό στο χρόνο, δηλαδή όλες οι συχνοτικές συνιστώσες του υπάρχουν καθ' όλη τη διάρκειά του. Αυτή η υπόθεση συνεπώς τον καθιστά ακατάλληλο για να εφαρμοστεί πάνω σε ολόκληρα σήματα που είναι μη στάσιμα και στοχαστικά όπως τα περισσότερα αναπνευστικά ηχητικά σήματα. Για να αναλύσουμε τη **χρονική εξέλιξη του φάσματος** ενός τέτοιου σήματος, χρησιμοποιούμε λοιπόν τον **Μετασχηματισμό Fourier Βραχέως Χρόνου** (*Short-Time Fourier Transform (STFT)*).

Απο μαθηματική σκοπιά ο *STFT* για τα διακριτά σήματα θεμελιώνεται ως εξής:

$$X(m, k) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - m] \cdot e^{-j2\pi \frac{k}{N}n} \quad (3.4)$$

όπου $w[n]$ είναι η συνάρτηση παραθύρου μήκους N , m ο δείκτης χρονικής θέσης του παραθύρου και k ο δείκτης συχνότητας.


Στην πρακτική υλοποίηση, όπου το σήμα έχει πεπερασμένο μήκος και το παράθυρο εφαρμόζεται σε τμήματα N δειγμάτων, η εξίσωση μετασχηματίζεται σε:

$$X(m, k) = \sum_{n=0}^{N-1} x[n + m] \cdot w[n] \cdot e^{-j2\pi \frac{k}{N}n} \quad (3.5)$$

Η βασική ιδέα του *STFT* είναι να χωρίσει το σήμα σε διαδοχικά **τοπικά χρονικά καρέ** (*frames*) μέσα στα οποία το σήμα θεωρείται προσεγγιστικά στάσιμο και να εφαρμόσει τον Διακριτό Μετασχηματισμό *Fourier* χωριστά σε κάθε καρέ. Κατά τον χρονικό τεμαχισμό ενός σήματος σε καρέ σταθερού μήκους, εφαρμόζεται συχνά και **επικάλυψη** (*overlap*) μεταξύ διαδοχικών καρέ, δηλαδή διατηρείται κοινό ένα τμήμα του σήματος μεταξύ τους. Ο βαθμός επικάλυψης καθορίζεται από τη διαφορά μεταξύ του μήκους του καρέ (*frame size*) L και του βήματος μετατόπισης (*hop size*) H , με ποσοστό επικάλυψης:

$$\text{overlap} = \frac{L - H}{L} \times 100\%$$

Η χρήση επικάλυψης είναι ιδιαίτερα σημαντική για σήματα όπως οι αναπνευστικοί ήχοι, καθώς τα παθολογικά ηχητικά συμβάντα, όπως τα *crackles*, είναι εξαιρετικά σύντομα και ενδέχεται να πέσουν στα «σύνορα» μεταξύ δύο μη επικαλυπτόμενων καρέ. Σε αυτή την περίπτωση, είτε θα εμφανιστούν τμηματικά, είτε θα χαθούν πλήρως. Με την επικάλυψη, η πιθανότητα σύλληψής τους σε πλήρες καρέ αυξάνεται σημαντικά και έτσι αποφεύγονται ασυνέχειες ή απότομες μεταβολές μεταξύ καρέ.



Σχήμα 3.2: Τεμαχισμός σήματος σε frames με επικάλυψη.

Στη συνέχεια ακολουθεί η διαδικασία της παραθύρωσης (*windowing*), η οποία είναι απαραίτητη ώστε να περιοριστούν τα φαινόμενα **φασματικής διαρροής** που προκύπτουν από την απότομη αποκοπή ενός σήματος σε καρέ πεπερασμένου μήκους. Για τον σκοπό αυτό, κάθε καρέ πολλαπλασιάζεται με μια συνάρτηση παραθύρου $w[n]$, η οποία δίνει μεγαλύτερη έμφαση στο κέντρο και μειώνει σταδιακά την επιρροή των άκρων. Υπάρχουν διάφοροι τύποι παραθύρων:

Ορθογώνιο παράθυρο (*Rectangular window*) Είναι το απλούστερο παράθυρο, χωρίς εξομάλυνση στα άκρα. Παρουσιάζει γενικά σημαντική φασματική διαρροή λόγω των απότομων μεταβάσεων και χρησιμοποιείται κυρίως όταν το σήμα έχει ήδη ομαλά άκρα.


$$w[n] = 1, \quad 0 \leq n < N \quad (3.6)$$

Hann window Παρέχει καλή καταστολή πλευρικών λοβών και χρησιμοποιείται ευρέως στη φασματική ανάλυση για τον υπολογισμό του *STFT*. Έχει μικρό κύριο λοβό και απότομη απόσβεση εκτός αυτού.

$$w[n] = 0.5 \left(1 - \cos \left(\frac{2\pi n}{N-1} \right) \right) \quad (3.7)$$

Hamming window Είναι παρόμοιο με το παράθυρο *Hann* αλλά με μεγαλύτερο κύριο λοβό και μικρότερη πλευρική διαρροή.

$$w[n] = 0.54 - 0.46 \cos \left(\frac{2\pi n}{N-1} \right) \quad (3.8)$$




Σχήμα 3.3: Συνήθεις συναρτήσεις παραθύρου.

Το αποτέλεσμα αυτής της διαδικασίας είναι μια **διδιάστατη αναπαράσταση** $X(m, k)$ που δείχνει την κατανομή συχνοτήτων του σήματος σε κάθε χρονική στιγμή. Από εκεί προκύπτει το τελικό **φασματογράφημα**, δηλαδή ο χάρτης έντασης $|X(m, k)|^2$ με τον χρόνο στον οριζόντιο άξονα, τη συχνότητα στον κατακόρυφο και το χρώμα να δηλώνει την ενέργεια, δηλαδή την ένταση του σήματος στη συχνότητα k για το δείγμα m (Lerch 2012).

Η διαδικασία αυτή που περιγράφουμε είναι ιδιαίτερα κρίσιμη για την ανίχνευση παθολογικών γεγονότων μικρής διάρκειας, όπως τα *crackles*, τα οποία έχουν διάρκεια μόλις 5–20 ms και θα ήταν αδύνατο να εντοπιστούν σε μακροσκοπική ανάλυση. Επιπλέον, ο τεμαχισμός σε καρέ ευνοεί την εφαρμογή τεχνικών μηχανικής μάθησης, καθώς επιτρέπει την εξαγωγή τοπικών χαρακτηριστικών από κάθε καρέ και κατ' επέκταση την εκπαίδευση ταξινομητών με υψηλότερη χρονική ανάλυση.

Πιο κάτω παρατίθενται ενδεικτικά φασματογραφήματα που αντιστοιχούν στις κυματομορφές των καταγραφών του dataset μας. Τα συγκεκριμένα γραμμικά φασματογραφήματα απεικονίζουν την κατανομή ενέργειας του σήματος σε συνάρτηση συχνότητας και χρόνου, χωρίς επιπρόσθετη κλιμάκωση ή συμπίεση της συχνοτικής πληροφορίας. Αν και προσφέρουν άμεση και ακριβή απεικόνιση του φάσματος, δεν αποτελούν την επικρατέστερη μέθοδο αναπαράστασης σε εφαρμογές μηχανικής μάθησης. Αντίθετα, στις περισσότερες σύγχρονες προσεγγίσεις δίνεται προτεραιότητα στα Log-Mel spectrograms, τα οποία προκύπτουν από τη συνδυασμένη εφαρμογή φίλτρων Mel και λογαριθμικής κλίμακας στην ενεργειακή κατανομή. Η μετατροπή στη κλίμακα Mel ευθυγραμμίζεται καλύτερα με την ανθρώπινη ακουστική αντίληψη, δίνοντας μεγαλύτερη ανάλυση σε χαμηλές συχνότητες όπου εντοπίζονται κρίσιμες πληροφορίες για την αναγνώριση παθολογικών αναπνευστικών ήχων. Παράλληλα, η λογαριθμική συμπίεση της ενέργειας καθιστά την αναπαράσταση πιο ανθεκτική σε διαφοροποιήσεις έντασης και βελτιώνει τη διακριτική ικανότητα των νευρωνικών δικτύων. Γι' αυτό το λόγο από εδώ και πέρα θα αναφερόμαστε μόνο σε Log-Mel φασματογραφήματα και μάλιστα η διαδικασία δημιουργίας των Log-Mel ενεργειών περιγράφεται αναλυτικότερα στην πιο κάτω ενότητα κατά την εξαγωγή των φασματικών χαρακτηριστικών.



Σχήμα 3.4: Φασματογραφήματα αναπνευστικών καταγραφών του dataset.

3.2 Προεπεξεργασία αναπνευστικών σημάτων

Η **προεπεξεργασία** (*preprocessing*) αποτελεί κρίσιμο στάδιο στην ανάλυση βιοϊατρικών σημάτων και προϋπόθεση για την επιτυχή εξαγωγή χαρακτηριστικών και τη βελτιστοποίηση της απόδοσης των μεταγενέστερων μοντέλων μηχανικής μάθησης. Τα αναπνευστικά ηχητικά σήματα αν και φέρουν χρήσιμη διαγνωστική πληροφορία καταγράφονται υπό συνθήκες που εισάγουν σημαντικούς θορύβους, ετερογένεια και μη επιθυμητές παραλλαγές, όπως διαφορές στην ένταση, τη διάρκεια ή τη συχνότητα δειγματοληψίας.

Ειδικότερα, στις ηχογραφήσεις αναπνευστικών ήχων που προέρχονται από πολλαπλές συσκευές και διαφορετικά περιβάλλοντα, εμφανίζονται συχνά διαφορές ως προς την ανάλυση, την ενέργεια του σήματος, την παρουσία καρδιακών ήχων, περιβαλλοντικού θορύβου ή ακόμη και σιωπών. Αυτοί οι παράγοντες μπορούν να αλλοιώσουν την αναπαράσταση του σήματος

και να επηρεάσουν δυσμενώς τη γενίκευση των μοντέλων ταξινόμησης.

Για τον λόγο αυτό, στην παρούσα εργασία υιοθετείται μια πλήρης ακολουθία προεπεξεργασίας, η οποία περιλαμβάνει τα εξής στάδια: **επαναδειγματοληψία σε κοινή συχνότητα, κανονικοποίηση πλάτους, αποθορυβοποίηση, χρονική προσαρμογή διάρκειας και εφαρμογή τεχνικών επαύξησης δεδομένων όπως η παραμόρφωση φωνητικού σωλήνα (VTLP)**. Κάθε ένα από αυτά τα στάδια σχεδιάστηκε ώστε να διατηρεί τη διαγνωστική πληροφορία του σήματος, ενώ παράλληλα να περιορίζει τις ανεπιθύμητες διακυμάνσεις που σχετίζονται με εξωγενείς παράγοντες.

Η ενότητα αυτή περιγράφει αναλυτικά τα επιμέρους βήματα προεπεξεργασίας που εφαρμόστηκαν, τεκμηριώνοντας τόσο τις θεωρητικές αρχές όσο και τις πρακτικές επιλογές παραμέτρων που υιοθετήθηκαν.

3.2.1 Επαναδειγματοληψία

Η **επαναδειγματοληψία (resampling)** αποτελεί ένα από τα βασικά βήματα προεπεξεργασίας στην ανάλυση ψηφιακών αναπνευστικών σημάτων. Πρόκειται για τη διαδικασία μετατροπής της συχνότητας δειγματοληψίας ενός διακριτού σήματος από μια αρχική τιμή f_s σε μια νέα, επιθυμητή συχνότητα f'_s . Ουσιαστικά, το σήμα $x[n]$ αναδομείται σε μια νέα μορφή $x'[m]$ που αντιστοιχεί σε διαφορετική χρονική ανάλυση.

Μαθηματικά, η επαναδειγματοληψία ενός διακριτού σήματος $x[n]$ από συχνότητα f_s σε νέα συχνότητα f'_s επιτυγχάνεται μέσω δύο βασικών μεθοδολογιών, ανάλογα με τη σχέση μεταξύ f_s και f'_s :

Downsampling (υποδειγματοληψία) Εφαρμόζεται όταν $f'_s < f_s$. Διατηρείται μόνο ένα κάθε M -οστό δείγμα του αρχικού σήματος:

$$x_d[n] = x[nM] \quad (3.9)$$

Upsampling (υπερδειγματοληψία) Εφαρμόζεται όταν $f'_s > f_s$. Εισάγονται $L - 1$ μηδενικά μεταξύ κάθε δύο διαδοχικών δειγμάτων:

$$x_u[n] = \begin{cases} x \left[\frac{n}{L} \right], & \text{αν } n \bmod L = 0 \\ 0, & \text{διαφορετικά} \end{cases} \quad (3.10)$$

Η ανάγκη για επαναδειγματοληψία προκύπτει από το γεγονός ότι τα σήματα έχουν καταγραφεί με διαφορετικές συχνότητες ανάλογα με τον εξοπλισμό, τη μεθοδολογία ή το χρονικό πλαίσιο της καταγραφής. Συνεπώς, η μετατροπή όλων των σημάτων σε κοινή συχνότητα αναφοράς f'_s επιτρέπει την ομοιόμορφη επεξεργασία και σύγκρισή τους.

Στο πλαίσιο της παρούσας εργασίας, η επαναδειγματοληψία εφαρμόστηκε ως κρίσιμο στάδιο προεπεξεργασίας, προκειμένου να εξομοιωθεί η συχνότητα δειγματοληψίας όλων των αναπνευστικών σημάτων σε κοινό ρυθμό. Το χρησιμοποιούμενο σύνολο δεδομένων περιλαμβάνει καταγραφές από τέσσερις διαφορετικές συσκευές όπως αναλύεται στο Κεφάλαιο 6, εκ των οποίων οι τρεις καταγράφουν σε συχνότητα **4 kHz**, ενώ η τέταρτη χρησιμοποιεί συχνότητα

44.1 kHz που αποτελεί κοινό πρότυπο στην εμπορική ή μουσική ηχογράφηση, αλλά υπερβαίνει κατά πολύ τις ανάγκες της παρούσας εφαρμογής.

Συσκευή	Συχνότητα δειγματοληψίας
Meditron	4 kHz
Litt3200	4 kHz
LittC2SE	4 kHz
AKGC417L	44.1 kHz

Πίνακας 3.1: Καταγραφή αναπνευστικών σημάτων από τις τέσσερις διαφορετικές συσκευές.

Λαμβάνοντας υπόψη την ετερογένεια των αρχικών καταγραφών ως προς τη συχνότητα δειγματοληψίας, κρίθηκε απαραίτητη η **επαναδειγματοληψία μέσω *downsampling*** των σημάτων που καταγράφηκαν από τη συσκευή **AKGC417L** με συχνότητα **4 kHz** αντί για **44.1 kHz**, ώστε να εξομοιωθούν με τις υπόλοιπες καταγραφές.

Η επιλογή της συγκεκριμένης συχνότητας βασίζεται στο γεγονός ότι καλύπτει πλήρως το φασματικό εύρος των αναπνευστικών ήχων που μας ενδιαφέρουν (100–1200 Hz), καθώς βάσει του θεωρήματος *Nyquist-Shannon* με συχνότητα δειγματοληψίας 4 kHz θα καλύπτουμε εύρος συχνότητων από 0-2 kHz, εξισορροπώντας παράλληλα τη διατήρηση κρίσιμης πληροφορίας με την αποδοτικότητα σε αποθήκευση και υπολογιστική ισχύ. Πιο συγκεκριμένα, η χρήση υψηλότερων συχνοτήτων θα αύξανε σημαντικά το μέγεθος των αρχείων και τις απαιτήσεις σε επεξεργαστικό χρόνο, χωρίς να προσφέρει ουσιαστικό όφελος στην αναπαράσταση αναπνευστικών σημάτων που περιέχουν χαμηλοσυχνοτική πληροφορία. Αντιθέτως, υπερβολικά χαμηλές συχνότητες μπορεί να οδηγούσαν σε απώλεια κρίσιμων πληροφοριών.

3.2.2 Καθορισμός χρονικών ορίων

Ένα από τα κρίσιμα βήματα στην προεπεξεργασία των αναπνευστικών σημάτων είναι η **κανονικοποίηση της διάρκειας κάθε αναπνευστικού κύκλου**, ώστε όλοι οι κύκλοι να έχουν ίσο μήκος στο πεδίο του χρόνου. Οι μεγάλες αποκλίσεις στη χρονική διάρκεια των κύκλων είναι συνήθως αποτέλεσμα φυσιολογικών παραγόντων (ηλικία, θέση σώματος, βάθος αναπνοής) ή παθολογικών καταστάσεων (δύσπνοια, απόφραξη αεραγωγών κ.ά.). Αυτή η μεταβλητότητα ωστόσο οδηγεί σε σήματα διαφορετικού μήκους, τα οποία είναι δύσκολο να συγκριθούν ή να υποβληθούν σε ενιαία ανάλυση. Επιπλέον, για την εκπαίδευση των μοντέλων μηχανικής και βαθιάς μάθησης θα χρειαστούμε δεδομένα εισόδου με καθορισμένο μέγεθος, καθώς η σταθερότητα των διαστάσεων διευκολύνει την εξαγωγή χαρακτηριστικών, την κανονικοποίηση και την αξιολόγηση των μοντέλων.

Ο καθορισμός των ορίων του σήματος μπορεί να πραγματοποιηθεί με 2 διαφορετικές τεχνικές, ανάλογα με το αν θέλουμε να μειώσουμε ή να αυξήσουμε τη διάρκεια του αρχικού σήματος:

Trimming Η τεχνική της **αποκοπής** (*trimming*) είναι η διαδικασία κατά την οποία αφαιρούνται συγκεκριμένα τμήματα ενός σήματος μήκους L , με σκοπό τη μείωση του μήκους του ή την εξάλειψη μη χρήσιμης πληροφορίας, διατηρώντας μόνο τα κρίσιμα ακουστικά δεδομένα. Η τεχνική αυτή είναι ιδιαίτερα χρήσιμη σε αναπνευστικά σήματα όταν το σήμα περιέχει εκτεταμένες περιόδους σιγής ή χαμηλής ενέργειας μεταξύ αναπνοών. Η πιο συνήθης πρακτική είναι η αφαίρεση δειγμάτων ξεκινώντας από το τέλος του σήματος, δηλαδή $x[L-1], x[L-2], \dots, x[N+1]$ μέχρις ότου να φτάσουμε στο επιθυμητό μήκος $N < L$.

Padding Η τεχνική της **συμπλήρωσης μήκους** (*padding*) περιλαμβάνει την προσθήκη τεχνητών δειγμάτων σε συγκεκριμένες θέσεις του σήματος μήκους L (συνήθως στην αρχή ή/και στο τέλος) ώστε το συνολικό μήκος να ισούται με μία προκαθορισμένη σταθερή τιμή $N > L$. Υπάρχουν διάφορες στρατηγικές *padding*, με τις πιο διαδεδομένες να είναι:

- **Συμπλήρωση με μηδενικά (Zero padding):** Στη συγκεκριμένη περίπτωση προστίθενται μηδενικές τιμές στο τέλος (ή στην αρχή) του σήματος:

$$x_{\text{padded}}[n] = \begin{cases} x[n], & 0 \leq n < L \\ 0, & L \leq n < N \end{cases} \quad (3.11)$$

Αν και απλή σαν μέθοδος μπορεί να εισάγει ασυνέχειες στα άκρα, ειδικά σε φασματικές αναπαραστάσεις.

- **Συμπλήρωση με κατοπτρισμό (Reflection padding):** Το σήμα συμπληρώνεται με αντίγραφα τμημάτων του εαυτού του, σε συμμετρική διάταξη:

$$x_{\text{padded}}[n] = [x[L-1], \dots, x[0], x[0], \dots, x[L-1]] \quad (3.12)$$

Είναι ιδιαίτερα χρήσιμο σαν μεθοδολογία σε περιπτώσεις όπου θέλουμε συνεχή άκρα και αποφυγή οξύτητας λόγω μηδενισμού.

- **Συμπλήρωση με επανάληψη άκρου (Replication padding):** Το τελικό δείγμα του σήματος επαναλαμβάνεται μέχρι να καλυφθεί το επιθυμητό μήκος:


$$x_{\text{padded}}[n] = [x[0], \dots, x[L-1], x[L-1], \dots, x[L-1]] \quad (3.13)$$

Είναι κατάλληλο όταν το σήμα σταθεροποιείται στο τέλος.

- **Κυκλική συμπλήρωση (Circular padding):** Σε αυτή την τεχνική, η συμπλήρωση γίνεται με *κυκλική επανάληψη* του ίδιου του σήματος, σαν να θεωρείται το σήμα περιοδικό. Δηλαδή, οι τιμές που απαιτούνται στο τέλος του σήματος αντιγράφονται από την αρχή του, και αντίστροφα αν χρειαστεί *padding* και στην αρχή:

$$x_{\text{padded}}[n] = [x[L-k], \dots, x[L-1], x[0], \dots, x[L-1], x[0], \dots, x[k-1]] \quad (3.14)$$


Όσον αφορά τη δικιά μας περίπτωση, στο *Respiratory Sound Database* οι αναπνευστικοί κύκλοι από τις καταγραφές διαφέρουν σημαντικά σε διάρκεια, καθώς η ελάχιστη διάρκεια που έχει καταγραφεί είναι 0.2 s και η μέγιστη αγγίζει τα 16.2 s. Όπως παρατηρούμε και από την πιο κάτω εικόνα η πλειοψηφία των αναπνευστικών κύκλων έχει διάρκεια η οποία κατανέμεται γύρω από τα 2 s.




Σχήμα 3.5: Κατανομή της διάρκειας των αναπνευστικών κύκλων στο dataset.

Συνεπώς, θέλουμε το *target duration* να είναι κάποια τιμή κοντά στα 2 s, δηλαδή κοντά στη μέση τιμή της διάρκειας της αναπνευστικών κύκλων, έτσι ώστε να εξομαλυνθούν οι υπερβολικά μικρές ή υπερβολικά μεγάλες χρονικές διάρκειες. Μετά από δοκιμές με διάφορες χρονικές διάρκειες από 3 ως 8 s καταλήξαμε στο συμπέρασμα ότι **όλα τα σήματα είναι κρίσιμο να κανονικοποιηθούν σε σταθερή διάρκεια ίση με 3 s**, καθώς το χρονικό αυτό παράθυρο επαρκεί για τη καταγραφή τόσο της εισπνευστικής όσο και της εκπνευστικής φάσης, επιτρέποντας ταυτόχρονα την ανίχνευση και διάκριση παθολογικών προτύπων χωρίς αραίωση της κρίσιμης πληροφορίας. Επιπλέον, αποφεύγεται η περιττή αύξηση του μήκους εισόδου στα μοντέλα, η οποία θα μείωνε τη διακριτική ικανότητα των ταξινομητών.

Για τους κύκλους με **μεγαλύτερη χρονική διάρκεια από 3 s** εφαρμόσαμε *trimming* όπως περιγράφηκε προηγουμένως, ενώ για κύκλους με **μικρότερη χρονική διάρκεια από 3 s** επιλέξαμε *circular padding* για το λόγο ότι έτσι δεν εισάγουμε απότομες μεταβάσεις στο σήμα, οι οποίες ενδέχεται να εκληφθούν ως τεχνητοί θόρυβοι ή παθολογικά γεγονότα από τα ταξινομητικά μοντέλα.



Σχήμα 3.6: Παραδείγματα εφαρμογής trimming σε αναπνευστικούς κύκλους του dataset.




Σχήμα 3.7: Παραδείγματα εφαρμογής circular padding σε αναπνευστικούς κύκλους του dataset.

3.2.3 Κανονικοποίηση πλάτους

Κατά την ψηφιακή επεξεργασία ακουστικών σημάτων και ειδικότερα αναπνευστικών ήχων είναι σύνηθες να παρατηρείται σημαντική **διακύμανση στο πλάτος** των καταγραφών. Οι διακυμάνσεις αυτές καθιστούν δύσκολη τη σύγκριση σημάτων και την εκπαίδευση μοντέλων μηχανικής μάθησης, καθώς η μεταβολή στην ένταση μπορεί να επισκιάσει ή να παραποιήσει τα διαγνωστικά ηχητικά χαρακτηριστικά. Για τον λόγο αυτό, εφαρμόζεται η διαδικασία της **κανονικοποίησης πλάτους** (*amplitude normalization*), η οποία στοχεύει στη μετατροπή όλων των σημάτων σε κοινή κλίμακα έντασης. Η κανονικοποίηση πλάτους δεν επηρεάζει το φασματικό περιεχόμενο του σήματος αλλά μεταβάλλει την ακουστική ενέργεια ή το δυναμικό εύρος, ώστε όλα τα σήματα να είναι συγκρίσιμα ως προς την ένταση και να διευκολύνουν την εκπαίδευση ταξινομητών, οι οποίοι διαφορετικά θα εστίαζαν σε άσχετες διαφορές έντασης.

Στην παρούσα μελέτη, εφαρμόστηκε **κανονικοποίηση του πλάτους των σημάτων**

των αναπνευστικών κύκλων στο διάστημα $[-1,1]$.




Σχήμα 3.8: Παραδείγματα εφαρμογής κανονικοποίησης πλάτους σε αναπνευστικούς κύκλους του dataset.

3.2.4 Αποθορυβοποίηση

Σαν τελικό βήμα προεπεξεργασίας είναι συνήθως απαραίτητο να εφαρμοστεί κάποια μορφή **αποθορυβοποίησης**, καθώς τα καταγραφόμενα σήματα είναι συχνά επιβαρυμένα με **θορυβώδεις ή ανεπιθύμητες συνιστώσες** που δεν σχετίζονται με την επιθυμητή φυσιολογική ή παθολογική πληροφορία. Στην περίπτωση των αναπνευστικών σημάτων, αυτοί οι θόρυβοι μπορεί να προέρχονται από **ήχους του περιβάλλοντος** (π.χ. συνομιλίες, κίνηση, ηλεκτρονικά όργανα), **καρδιακούς ήχους** που επικαλύπτουν το αναπνευστικό σήμα σε χαμηλές συχνότητες ή και **μηχανικούς θορύβους** από το ίδιο το στηθοσκόπιο ή την επιφάνεια του σώματος.


Στις πιο διαδεδομένες μεθόδους αποθορυβοποίησης συγκαταλέγονται τα **ψηφιακά φίλτρα**, τα οποία επιτρέπουν ή απορρίπτουν τη διέλευση συχνοτήτων από συγκεκριμένες περιοχές του φάσματος του σήματος:

- **Φίλτρο διέλευσης χαμηλών συχνοτήτων (*low-pass*)**: διατηρεί τις χαμηλές συχνότητες και κόβει τις υψηλές οι οποίες βρίσκονται πάνω από ένα όριο αποκοπής f_c .
- **Φίλτρο διέλευσης υψηλών συχνοτήτων (*high-pass*)**: διατηρεί τις υψηλές συχνότητες και κόβει τις χαμηλές οι οποίες βρίσκονται κάτω από ένα όριο αποκοπής f_c .
- **Ζωνοπερατό φίλτρο (*band-pass*)**: διατηρεί μόνο μια συγκεκριμένη ζώνη συχνοτήτων $[f_1, f_2]$.
- **Ζωνοφρακτικό φίλτρο (*band-stop*)**: αποκόπτει μόνο μια συγκεκριμένη ζώνη συχνοτήτων $[f_1, f_2]$.



Σχήμα 3.9: Είδη ψηφιακών φίλτρων.


Στην παρούσα μελέτη εφαρμόστηκε ψηφιακό φίλτρο διέλευσης υψηλών συχνοτήτων (*high-pass*) με στόχο την απομάκρυνση ανεπιθύμητων χαμηλών συχνοτήτων από τα αναπνευστικά σήματα. Το φίλτρο αυτό σχεδιάστηκε ώστε να εξουδετερώνει τους καρδιακούς ήχους, οι οποίοι κυριαρχούν κάτω από τα 50–100 Hz και τον θόρυβο περιβάλλοντος που βρίσκεται σε πολύ χαμηλές συχνότητες (0–50 Hz). Για το λόγο αυτό, επιλέχθηκε ως συχνότητα αποκοπής η $f_c=100$ Hz, με αποτέλεσμα οι τελικές συχνότητες των σημάτων που θα αξιοποιήσουμε να βρίσκονται εντός της ζώνης [100 Hz, 2000 Hz]. Το φάσμα ενδιαφέροντος των αναπνευστικών ήχων εκτείνεται κυρίως στην περιοχή 100–1200 Hz, με τις περισσότερες διαγνωστικές πληροφορίες να συγκεντρώνονται μεταξύ 150–600 Hz. Η αποκοπή άρα των συχνοτήτων κάτω από το συγκεκριμένο κατώφλι δεν αφαιρεί κάποια σημαντική πληροφορία.




Σχήμα 3.10: Παραδείγματα εφαρμογής high-pass φίλτρου σε αναπνευστικούς κύκλους του dataset.

Παρακάτω βλέπουμε ενδεικτικά ορισμένα παραδείγματα αναπνευστικών κύκλων πριν και μετά την εφαρμογή υψιπερατού φίλτρου. Στην αρχική μορφή των σημάτων παρατηρείται έντονη ενέργεια στις πολύ χαμηλές συχνότητες, η οποία ενδέχεται να προέρχεται από ανεπιθύμητους θορύβους όπως καρδιακοί ήχοι και θόρυβοι περιβάλλοντος κατά την εγγραφή. Μετά την εφαρμογή του φίλτρου η ενέργεια στις πολύ χαμηλές συχνότητες έχει περιοριστεί σημαντικά, ενώ το κυρίως φασματικό περιεχόμενο στην περιοχή 100–1200 Hz όπου εντοπίζονται οι σημαντικότερες πληροφορίες των φυσιολογικών και παθολογικών αναπνευστικών ήχων, διατηρείται αχέραιο. Βλέπουμε ότι ενισχύεται ορατότητα των διακριτών συχνοτικών υπογραφών (όπως οι περιοδικές ραβδώσεις στα *wheezes* ή οι εκρηκτικές αυξήσεις ενέργειας στα *crackles*).


Τέλος, παρατίθενται ορισμένα χαρακτηριστικά παραδείγματα αναπνευστικών κύκλων πριν και μετά την εφαρμογή του συνολικού *pipeline* προεπεξεργασίας που αναλύσαμε:



Σχήμα 3.11: 1ο παράδειγμα προεπεξεργασίας.



Σχήμα 3.12: 2ο παράδειγμα προεπεξεργασίας.



Σχήμα 3.13: 3ο παράδειγμα προεπεξεργασίας.

3.2.5 Επαύξηση δεδομένων με *VTLP*

Στην περίπτωση των αναπνευστικών σημάτων, οι φυσιολογικές διακυμάνσεις στο μήκος του φωνητικού σωλήνα, στη γεωμετρία των αεραγωγών, αλλά και στη στάθμη εγγραφής μεταξύ διαφορετικών συσκευών ή ατόμων, επηρεάζουν σημαντικά το φασματικό αποτύπωμα των ηχητικών δεδομένων.

Για την ενίσχυση της γενίκευσης των μοντέλων και την αύξηση της ανθεκτικότητας στα παραπάνω είδη παραλλακτικότητας, εφαρμόστηκε η τεχνική **Vocal Tract Length Perturbation με τοπική τροποποίηση (VTLP-Patch Augmentation)**, η οποία προσομοιώνει μεταβολές στο μήκος του φωνητικού σωλήνα μεταβάλλοντας το φασματικό περιεχόμενο του σήματος (Dong et al. 2025).

Η βασική ιδέα πίσω από το *VTLP* είναι η τροποποίηση του άξονα συχνοτήτων με μια συνάρτηση ανακατανομής $L(t)$, η οποία αλλάζει τη θέση των φασματικών συχνοτήτων και πιο συγκεκριμένα παραμορφώνει επιλεκτικά τις χαμηλές συχνότητες που περιλαμβάνουν τα περισσότερα φασματικά χαρακτηριστικά ενδιαφέροντος, ενώ παράλληλα διατηρεί σταθερές τις υψηλότερες. Αυτό πραγματοποιείται ώστε να προσομοιωθούν οι φυσιολογικές διαφορές μεταξύ ατόμων ή περιβάλλοντος καταγραφής. Η ανακατανομή αυτή βασίζεται στην εισαγωγή ενός τυχαίου παράγοντα κλιμάκωσης $\alpha \in [0.9, 1.1]$ και εφαρμόζεται μη γραμμικά σε συχνότητες μικρότερες ή μεγαλύτερες ενός ορίου F_{hi} . Στη δικιά μας περίπτωση **ως μέγιστη συχνότητα έχει επιλεγθεί το $F_{hi} = 2000$ Hz**, η οποία είναι η μέγιστη συχνότητα που μπορούμε να αναπαραστήσουμε βάσει της συχνότητας δειγματοληψίας που έχουμε επιλέξει.

Ο μαθηματικός ορισμός της συνάρτησης $L(t)$ είναι:

$$L(t) = \begin{cases} t\alpha, & t \leq \frac{F_{hi} \cdot \min(\alpha, 1)}{\alpha} \\ \frac{S/2 - F_{hi} \cdot \min(\alpha, 1)}{S/2 - F_{hi}} \cdot (S/2 - t), & \text{αλλιώς} \end{cases} \quad (3.15)$$

Το τροποποιημένο ηχητικό σήμα $x_w(t)$ παράγεται ως:


$$x_w(t) = \lambda \cdot x_o \left(F^{-1} (F \cdot L(t)) \right) + \eta(t) \quad (3.16)$$

όπου:

- $x_o(t)$ είναι το κανονικοποιημένο αρχικό σήμα,
- $F(\cdot)$ ο μετασχηματισμός STFT του $x_o(t)$,
- $F^{-1}(\cdot)$ ο αντίστροφος μετασχηματισμός STFT,
- λ ο συντελεστής ενίσχυσης της έντασης,
- $\eta(t)$ προσθετικός λευκός θόρυβος (*Gaussian white noise*).

Η διαδικασία **VTLP-Patch Aug** εφαρμόζεται ακολουθώντας τα εξής βήματα: Πρώτα, εκτελείται ο μετασχηματισμός *Fourier* (*STFT*) στο κανονικοποιημένο σήμα $x_o(t)$. Στη συνέχεια, εφαρμόζεται η μη γραμμική παραμόρφωση μέσω της $L(t)$ στους φασματικούς άξονες. Έπειτα, γίνεται ανακατασκευή του σήματος μέσω αντίστροφου *STFT* και προστίθεται *Gaussian* λευκός θόρυβος $\eta(t)$ για αύξηση της φασματικής ανθεκτικότητας. Η τιμή λ χρησιμοποιείται ως *gain factor* για ενίσχυση της ακουστικής ενέργειας.

Το αποτέλεσμα είναι μια παραλλαγμένη εκδοχή του αρχικού σήματος με τροποποιημένο φάσμα αλλά διατηρημένα τα δομικά του χαρακτηριστικά, επιτρέποντας έτσι στο σύστημα να μάθει να αγνοεί μη χρήσιμες φυσιολογικές διακυμάνσεις (π.χ. διαφορετικό σωματότυπο) και να επικεντρώνεται σε παθολογικά μορφολογικά πρότυπα.



Σχήμα 3.14: Παραδείγματα εφαρμογής VTLP-Patch Aug στο dataset.

Η Εικόνα 3.14 απεικονίζει την επίδραση της τεχνικής *VTLP-Patch Augmentation* όσον αφορά τη δημιουργία δύο νέων αναπνευστικών σημάτων με βάση δύο αρχικά σήματα σαν πρότυπο, τόσο οπτικά μέσω των φασματογραμμάτων όσο και αριθμητικά μέσω της απεικόνισης της συνάρτησης παραμόρφωσης του άξονα συχνοτήτων. Παρατηρείται ότι όντως μέσω της εφαρμογής της μη γραμμικής παραμόρφωσης στον άξονα συχνοτήτων μετατοπίζεται ελαφρώς η θέση των ενεργών φασματικών περιοχών (π.χ. ενισχύσεις ή μετακινήσεις κορυφών), διατηρώντας όμως τη γενική μορφολογία και ροή του σήματος.

Στο πλαίσιο της συγκεκριμένης εργασίας, τέτοιες παραλλαγές εφαρμόστηκαν στο *dataset* με σκοπό τη δημιουργία πλουσιότερου συνόλου εκπαίδευσης, ενισχύοντας τη δυνατότητα γενίκευσης των μοντέλων.

3.3 Εξαγωγή χαρακτηριστικών

Η **εξαγωγή χαρακτηριστικών** (*feature extraction*) αποτελεί κρίσιμο στάδιο όσον αφορά τη διαδικασία ανάλυσης και ταξινόμησης των αναπνευστικών σημάτων. Στην ουσία, τα εξαγμένα χαρακτηριστικά συμπυκνώνουν τη πληροφορία αυτή που αντιλαμβάνεται το ανθρώπινο αυτί διαισθητικά ακούγοντας το σήμα σε αριθμητικές τιμές που είναι εύχρηστες και κατανοητές αποκλειστικά από το υπολογιστικό σύστημα. Έτσι, αντί να χρησιμοποιείται απευθείας η ωμή κυματομορφή, η οποία περιλαμβάνει μεγάλο όγκο δεδομένων και πιθανώς μη χρήσιμες πληροφορίες, εξάγονται στοχευμένες μετρικές που αποτυπώνουν τα βασικά ακουστικά, χρονικά και φασματικά γνωρίσματα του σήματος. Στην περίπτωση των αναπνευστικών ήχων, τα χαρακτηριστικά αυτά συμβάλλουν στην αναγνώριση των παθολογικών προτύπων όπως οι ρόγχοι (*crackles*) και οι συριγμοί (*wheezes*), μέσα από τη μορφολογική, ενεργειακή και συχνοτική ανάλυση των δεδομένων.

Το εργαλείο που αποτελεί τον αχρογωνιαίο λίθο για την εξαγωγή όλων αυτών των χαρακτηριστικών δεν είναι άλλο από το ***Short Time Fourier Transform (STFT)***, του οποίου ο τρόπος λειτουργίας αναλύθηκε εκτενώς στην Υποενότητα 3.2.2. Συνεπώς, ο *STFT* θα λέγαμε ότι δεν λειτουργεί μόνον ως ένα εργαλείο απεικόνισης της πληροφορίας στο πεδίο χρόνου-συχνότητας, αλλά παράλληλα και εργαλείο για την εξαγωγή σημασιολογικά ισχυρών μεταβλητών που περιγράφουν το αναπνευστικό ηχητικό σήμα, επιτρέποντας τη μετατροπή του από κυματομορφή χαμηλής πληροφορίας σε δομημένα διανύσματα εισόδου για στατιστικά ή νευρωνικά μοντέλα μηχανικής και βαθιάς μάθησης (Babaei et al. 2017; Dar et al. 2023; Dong et al. 2025; Pramono, Bowyer, et al. 2017; Garg et al. 2025; Mercaldo et al. 2023).

Για τον υπολογισμό του *STFT* καθώς και την μετέπειτα εξαγωγή των ακουστικών χαρακτηριστικών επιλέξαμε να σπάσουμε τους αναπνευστικούς κύκλους σε ***frames των 60 ms με 50% επικάλυψη***, δηλαδή βήμα μετατόπισης (*hop size*) ίσο με 30 ms. Έτσι, επιτυγχάνουμε επαρκή χρονική ανάλυση για τον εντοπισμό συμβάντων που εμφανίζονται σε σύντομες χρονικές φάσεις του αναπνευστικού κύκλου, χωρίς να θυσιάζεται η διακριτική ικανότητα στο πεδίο της συχνότητας. Ακόμη, η χρήση επικάλυψης 50% εξασφαλίζει ότι κάθε σημείο του σήματος συμμετέχει σε τουλάχιστον δύο καρέ.

Με δεδομένο ότι τα σήματα έχουν διάρκεια 3 s και βήμα 30 ms, ο συνολικός αριθμός

παραγόμενων καρέ ανά αναπνευστικό κύκλο είναι περίπου:

$$\left\lfloor \frac{3s - 60ms}{30ms} \right\rfloor + 1 = 98 \text{ καρέ}$$

Ωστόσο, στην πράξη ενδέχεται να παραχθούν περισσότερα καρέ λόγω του τρόπου υλοποίησης της παραθύρωσης από τη χρησιμοποιούμενη βιβλιοθήκη. Συγκεκριμένα, η αυτόματη προ-σθήκη μηδενικών στην αρχή ή/και στο τέλος του σήματος, καθώς και η χρήση του ορίσματος `center=True` (π.χ. στη `librosa.stft()`), μπορεί να οδηγήσει σε επιπλέον καρέ πέρα από τα αυστηρά χρονικά όρια. Γι' αυτό το λόγο παρατηρούμε πως και στη δική μας περίπτωση λαμβάνουμε εν τέλει 101 καρέ αντί για 98 που υπολογίσαμε θεωρητικά.

Τέλος, κάθε χαρακτηριστικό που εξάγεται θα αποθηκεύεται σε ένα διάνυσμα με διάσταση **(101,)** το οποίο θα αντιπροσωπεύει τη χρονική εξέλιξή του ως προς τα frames. Αφού εξαχθούν και τα 41 χαρακτηριστικά που θα αναλύσουμε παρακάτω, τότε θα ενωθούν όλα τα διανύσματα χαρακτηριστικών σε ένα ενιαίο μητρώο με διαστάσεις **(41, 101)**. Αυτή η διαδικασία που περιγράψαμε επαναλαμβάνεται για κάθε αναπνευστικό κύκλο ξεχωριστά.

Είδος χαρακτηριστικών	Πλήθος
Χρονικά	3
Φασματικά	5
<i>MFCCs</i>	13
<i>Log-Mel filterbanks</i>	20

Πίνακας 3.2: Πλήθος εξαγμένων χαρακτηριστικών.

3.3.1 Χρονικά χαρακτηριστικά

Στο πλαίσιο αυτό, τα **χρονικά χαρακτηριστικά** (*temporal features*) περιγράφουν κυρίως **πτυχές της χρονικής εξέλιξης του πλάτους ή της ενεργειακής κατανομής** του αναπνευστικού σήματος. Παρακάτω αναλύονται τα χρονικά χαρακτηριστικά που επιλέχθηκαν κατά την υλοποίηση της συγκεκριμένης εργασίας, καθώς και η φυσική τους σημασία:

Zero Crossing Rate Είναι ένα θεμελιώδες χρονικό χαρακτηριστικό που μετρά τον αριθμό των φορών που το πλάτος του σήματος αλλάζει πρόσημο εντός ενός χρονικού παραθύρου. Εκφράζει δηλαδή τη συχνότητα με την οποία το σήμα «διέρχεται» από το μηδέν. Η τιμή του σχετίζεται με την περιεκτικότητα του σήματος σε υψηλές συχνότητες και αποτελεί ένδειξη της «τραχύτητας» ή της ταχύτητας των ταλαντώσεών του.


Ο μαθηματικός ορισμός για διακριτό σήμα $x[n]$ μήκους N είναι:

$$ZCR = \frac{1}{2N} \sum_{n=1}^N |\text{sgn}(x[n]) - \text{sgn}(x[n-1])| \quad (3.17)$$

όπου η συνάρτηση πρόσημου ορίζεται ως:

$$\text{sgn}(x) = \begin{cases} 1, & x > 0 \\ -1, & x < 0 \\ 0, & x = 0 \end{cases}$$

Στην πράξη, τα σήματα που περιέχουν γρήγορες ταλαντώσεις και υψηλό φασματικό περιεχόμενο παρουσιάζουν υψηλότερο ZCR σε σχέση με πιο αργούς ήχους. Στη δικιά μας περίπτωση βλέπουμε ότι σαν χαρακτηριστικό προσφέρει σημαντική διαχωριστική πληροφορία τόσο ανάμεσα στους παθολογικούς ήχους όσο και ανάμεσα στους φυσιολογικούς και τους παθολογικούς:




Σχήμα 3.15: Μέση χρονική εξέλιξη του ZCR για κάθε κατηγορία ήχου.

Root Mean Square Energy Αποτελεί ένα μέτρο της στιγμιαίας ισχύος ή έντασης του σήματος εντός ενός καρέ. Υπολογίζεται ως η τετραγωνική ρίζα του μέσου τετραγώνου των τιμών του σήματος και αποτυπώνει τη συνολική ενέργεια που «περιέχει» το σήμα σε δεδομένο χρονικό διάστημα.

Μαθηματικά για διακριτό σήμα $x[n]$ μήκους N ορίζεται ως:


$$\text{RMS} = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2} \quad (3.18)$$

Το *RMS Energy* χρησιμοποιείται για την αναγνώριση περιόδων ενεργής αναπνευστικής δραστηριότητας και διαχωρίζει περιοχές υψηλής έντασης (π.χ. *wheezes*, *crackles*) από περιοχές ησυχίας ή χαμηλής έντασης.



Σχήμα 3.16: Μέση χρονική εξέλιξη του RMS Energy για κάθε κατηγορία ήχου.

Onset Envelope Περιγράφει την εξέλιξη της στιγμιαίας ενεργοποίησης στο σήμα και χρησιμοποιείται για την ανίχνευση χρονικών συμβάντων (onsets), δηλαδή απότομων αλλαγών στην ενέργεια ή τη δομή του σήματος, όπως η εμφάνιση παροδικού παθολογικού ήχου. Αν και δεν έχει έναν μοναδικό μαθηματικό ορισμό, στην πράξη προκύπτει από το φάσμα πλάτους ή ενέργειας κάθε καρέ, συχνά με χρήση φίλτρων ή παραγώγων για την ενίσχυση των μεταβολών.



Σχήμα 3.17: Μέση χρονική εξέλιξη του Onset Envelope για κάθε κατηγορία ήχου.


3.3.2 Φασματικά χαρακτηριστικά

Τα **φασματικά χαρακτηριστικά** (spectral features) περιγράφουν την κατανομή της ενέργειας ενός ηχητικού σήματος στο πεδίο της συχνότητας και προκύπτουν από τη φασματική ανάλυση του σήματος μέσω του μετασχηματισμού STFT. Σε αντίθεση με τα χρονικά χαρακτηριστικά, τα οποία αποτυπώνουν τις μεταβολές του πλάτους στο χρόνο, τα φασματικά χαρακτηριστικά εστιάζουν στη συχνοτική δομή του σήματος και χρησιμοποιούνται εκτενώς στην ανάλυση και ταξινόμηση αναπνευστικών ήχων. Παρακάτω παρουσιάζονται τα βασικότερα χαρακτηριστικά που εξήχθησαν στην παρούσα εργασία.

Spectral Centroid Εκφράζει το «κέντρο μάζας» του φάσματος ενός σήματος και σχετίζεται άμεσα με το αντιληπτό «ύψος» ή την «οξύτητα» του ήχου, δηλαδή το pitch. Ορίζεται ως ο σταθμισμένος μέσος όρος των συχνοτήτων f_k , όπου το βάρος είναι το μέτρο του φάσματος $|X_k|$:

$$SC = \frac{\sum_{k=0}^{N-1} f_k \cdot |X_k|}{\sum_{k=0}^{N-1} |X_k|} \quad (3.19)$$

Υψηλές τιμές spectral centroid υποδεικνύουν την παρουσία έντονης ενέργειας σε υψηλές συχνότητες, χαρακτηριστικό γνώρισμα των συριγμών, ενώ χαμηλές τιμές αντιστοιχούν σε πιο βαθύ ήχο, όπως στους φυσιολογικούς ήχους.




Σχήμα 3.18: Μέση χρονική εξέλιξη του Spectral Centroid για κάθε κατηγορία ήχου.

Spectral Bandwidth Ποσοτικοποιεί τη διασπορά του φάσματος γύρω από το κέντρο βάρους του. Υπολογίζεται μαθηματικά ως η σταθμισμένη τυπική απόκλιση των συχνοτήτων από το spectral centroid:

$$SBW = \sqrt{\frac{\sum_{k=0}^{N-1} |X_k| \cdot (f_k - SC)^2}{\sum_{k=0}^{N-1} |X_k|}} \quad (3.20)$$


Στην πράξη, μεγάλο εύρος υποδηλώνει σήμα με κατανομή ενέργειας σε ευρύ φάσμα, όπως τα crackles, ενώ στενό bandwidth παρατηρείται σε wheezes που εμφανίζουν συγκέντρωση φασματικής ενέργειας σε περιορισμένες συχνότητες.



Σχήμα 3.19: Χρονική εξέλιξη του Spectral Bandwidth για κάθε κατηγορία ήχου.

Spectral Rolloff Ορίζει τη συχνότητα κάτω από την οποία βρίσκεται ένα προκαθορισμένο ποσοστό της συνολικής φασματικής ενέργειας, συνήθως 85% ή 95%. Η τιμή του spectral

rolloff σχετίζεται επίσης με την ασυμμετρία της μορφής του φάσματος. Χρησιμοποιείται για τη διάκριση μεταξύ ήχων με φασματική συμπύκνωση και ήχων με εκτεταμένο φάσμα.




Σχήμα 3.20: Μέση χρονική εξέλιξη του Spectral Rolloff για κάθε κατηγορία ήχου.

Spectral Flux Μετρά την ποσότητα μεταβολής του φάσματος από καρέ σε καρέ. Εκφράζει πόσο αλλάζει το φασματικό περιεχόμενο στο χρόνο και υπολογίζεται ως η Ευκλείδεια απόσταση μεταξύ φασμάτων διαδοχικών χρονικών καρέ:

$$SF = \sum_{k=0}^{N-1} (|X_k[n]| - |X_k[n-1]|)^2 \quad (3.21)$$

Η υψηλή τιμή spectral flux υποδεικνύει απότομες αλλαγές στο φάσμα, χαρακτηριστικό των crackles, ενώ η χαμηλή ροή παρατηρείται σε πιο σταθερά και συνεχόμενα σήματα, όπως τα wheezes.




Σχήμα 3.21: Μέση χρονική εξέλιξη του Spectral Flux για κάθε κατηγορία ήχου.

Spectral Flatness Είναι ένας δείκτης αρμονικότητας ή θορυβώδους φύσης του σήματος. Υπολογίζεται ως ο λόγος της γεωμετρικής προς την αριθμητική μέση τιμή του φάσματος:

$$SFt = \frac{\left(\prod_{k=0}^{N-1} |X_k| \right)^{1/N}}{\frac{1}{N} \sum_{k=0}^{N-1} |X_k|} \quad (3.22)$$

Η τιμή κυμαίνεται μεταξύ 0 και 1. Τείνει στο 1 για φάσματα τύπου λευκού θορύβου (flat) και στο 0 για φάσματα με αιχμές σε επιλεγμένες συχνότητες (αρμονικά ή μουσικά σήματα). Οι φυσιολογικοί ήχοι έχουν γενικά υψηλότερο flatness, ενώ τα wheezes λόγω της στενής φασματικής συγκέντρωσης εμφανίζουν χαμηλότερες τιμές.



Σχήμα 3.22: Μέση χρονική εξέλιξη του Spectral Flatness για κάθε κατηγορία ήχου.

3.3.3 MFCCs

Τα **Mel-Frequency Cepstral Coefficients (MFCCs)** αποτελούν μία από τις πιο διαδεδομένες και καθιερωμένες περιγραφές ηχητικών σημάτων, καθώς παρέχουν μία συμπαγή και θεμελιωμένη αναπαράσταση του φάσματος. Στο πεδίο της αναγνώρισης ήχου και ειδικότερα στη μελέτη αναπνευστικών σημάτων, τα MFCCs έχουν αποδειχθεί εξαιρετικά αποτελεσματικά στην καταγραφή της φασματικής υφής ενός σήματος, αποτυπώνοντας τις δομικές του ιδιαιτερότητες σε ένα σύνολο αριθμητικών χαρακτηριστικών (feature vectors) σταθερής διάστασης.

Η κύρια θεωρητική αρχή των MFCCs είναι η προσαρμογή της φασματικής ανάλυσης στην ακουστική λειτουργία του ανθρώπινου αυτιού. Συγκεκριμένα, το ανθρώπινο ακουστικό σύστημα δεν αντιλαμβάνεται όλες τις συχνότητες με την ίδια ανάλυση, καθώς παρουσιάζει αυξημένη ευαισθησία σε χαμηλές συχνότητες και μειωμένη σε υψηλές. Για να ενσωματωθεί αυτή η ιδιότητα στην ανάλυση, εφαρμόζεται ένας μη γραμμικός μετασχηματισμός των συχνοτήτων από την γραμμική κλίμακα σε μια κλίμακα που καλύπτει την υποκειμενική αντίληψη του ακροατή, γνωστή ως **κλίμακα Mel**.

Η σχέση μεταξύ γραμμικής συχνότητας f και συχνότητας Mel δίνεται προσεγγιστικά από τη σχέση:

$$M(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right) \quad (3.23)$$

Η παραπάνω σχέση προκύπτει από εμπειρικά δεδομένα ακουστικών πειραμάτων και διασφαλίζει ότι μικρές αυξήσεις στη συχνότητα σε χαμηλές περιοχές γίνονται αντιληπτές ως ισοδύναμες με μεγαλύτερες αυξήσεις σε υψηλές περιοχές. Για παράδειγμα, ένα διάστημα από 200–400 Hz θεωρείται ακουστικά «ισοδύναμο» με ένα διάστημα από 2000–3000 Hz.

Η διαδικασία υπολογισμού των MFCCs περιλαμβάνει όπως αναφέραμε τον υπολογισμό του φάσματος πλάτους μέσω STFT, το οποίο στη συνέχεια φιλτράρεται με ένα bank M φίλτρων

(συνήθως $M = 26$) με τριγωνική απόκριση, κατανεμημένα μη γραμμικά στη συχνότητα, σύμφωνα με την κλίμακα Mel. Έπειτα, γίνεται υπολογισμός του λογαρίθμου της ενέργειας κάθε φίλτρου:


$$E_m = \log \left(\sum_{k=0}^{N-1} |X(k)|^2 \cdot H_m(k) \right), \quad m = 1, 2, \dots, M \quad (3.24)$$

όπου $H_m(k)$ είναι η απόκριση του m -οστού Mel φίλτρου στη συχνότητα k . Η λογαριθμική κλίμακα εφαρμόζεται εδώ για δύο βασικούς λόγους: (α) για ενίσχυση των ασθενών συνιστωσών του φάσματος και (β) για να καταστήσει τις διαφορές πιο γραμμικά διακριτές, διευκολύνοντας τη μάθηση από τα νευρωνικά δίκτυα.

Τέλος, τα MFCCs εξάγονται με τη μορφή συμπυκνωμένων συντελεστών εφαρμόζοντας DCT ή Διακριτό Μετασχηματισμό Συνημιτόνου στην M -διάστατη λογαριθμική φασματική αναπαράσταση:

$$c_n = \sum_{m=1}^M E_m \cdot \cos \left[\frac{\pi n}{M} \left(m - \frac{1}{2} \right) \right], \quad n = 0, 1, \dots, K-1 \quad (3.25)$$


όπου K είναι ο αριθμός των συντελεστών που διατηρούνται (συνήθως 12 ή 13).




Σχήμα 3.23: Διαδικασία εξαγωγής MFCCs.

Τα παραγόμενα MFCCs σχηματίζουν ένα συμπαγές και χαμηλής διάστασης φασματικό αποτύπωμα κάθε καρέ, το οποίο είναι σχετικά ανεπηρέαστο από γραμμικές παραμορφώσεις στο φάσμα και φιλικό προς ταξινομητές. Οι πρώτοι συντελεστές φέρουν πληροφορία για τη γενική φασματική κλίση, ενώ οι επόμενοι περιέχουν όλο και πιο λεπτομερή υφή.

Στην παρούσα εργασία **χρησιμοποιήθηκαν τα πρώτα 13 MFCCs** ανά καρέ, τα οποία σε συνδυασμό με τα υπόλοιπα φασματικά και χρονικά χαρακτηριστικά προσφέρουν υψηλής πληροφορίας αναπαράσταση των αναπνευστικών ήχων, διευκολύνοντας την ταξινόμησή τους σε φυσιολογικούς ή παθολογικούς. Κατά τη διδιάστατη απεικόνιση των MFCCs, η κατακόρυφη διάσταση αντιστοιχεί στον δείκτη κάθε MFCC και η οριζόντια στις χρονικές στιγμές του κάθε κύκλου.



Σχήμα 3.24: Παραδείγματα MFCCs από ενδεικτικούς αναπνευστικούς κύκλους.




Σχήμα 3.25: Μέση χρονική εξέλιξη των MFCCs για κάθε κατηγορία ήχου.

3.3.4 Ζώνες Log-Mel

Οι **λογαριθμικές ζώνες Mel** (Log-Mel filterbank energies) σε αντίθεση με τα MFCCs τα οποία συμπυκνώνουν την πληροφορία σε λίγους συντελεστές, διατηρούν πλήρως τη δομή των ζωνών συχνοτήτων, καθιστώντας τες ιδιαίτερα χρήσιμες σε μεθόδους βαθιάς μάθησης, καθώς προσφέρουν περισσότερη χωρική λεπτομέρεια. Με άλλα λόγια, οι λογαριθμικές ζώνες Mel είναι ένα χαρακτηριστικό που συνοψίζει την πληροφορία «πόση ενέργεια υπάρχει σε ένα συγκεκριμένο εύρος συχνοτήτων, τη δεδομένη χρονική στιγμή, μετρώντας την όπως την αντιλαμβάνεται το ανθρώπινο αυτί».

Προκύπτουν μέσω της ίδιας διαδικασίας εξαγωγής που περιγράψαμε και για τα MFCCs χωρίς ωστόσο την εφαρμογή του DCT σαν τελικό βήμα. Έτσι, το αποτέλεσμα θα είναι ένα πιο μεγάλο διάλυσμα M -διαστάσεων, συνήθως $M = 40$ ή 80 , το οποίο αποτυπώνει χαρακτηριστικά μοτίβα υψηλής ευκρίνειας, όπως στενές φασματικές αιχμές σε wheezes ή εκρηκτικές παροδικές ενέργειες σε crackles. Στη δικιά μας περίπτωση ωστόσο **χρησιμοποιήθηκαν τα πρώτα 20 Log-Mel filterbank energies** τόσο ως αυτόνομα χαρακτηριστικά όσο και ως βάση για την εξαγωγή των MFCCs που αναλύσαμε παραπάνω, προσφέροντας υψηλής πληροφορίας

περιγραφή της φασματικής κατανομής των αναπνευστικών ήχων.




Σχήμα 3.26: Μέση χρονική εξέλιξη των Log-Mel filterbank energies για κάθε κατηγορία ήχου.

Κεφάλαιο 4

Μηχανική μάθηση για αναγνώριση αναπνευστικών ασθενειών

4.1 Εισαγωγή στη μηχανική μάθηση

Η **μηχανική μάθηση** (*machine learning*, *ML*) αποτελεί έναν υποτομέα της τεχνητής νοημοσύνης (*AI*), ο οποίος επικεντρώνεται στην ανάπτυξη αλγορίθμων και υπολογιστικών μοντέλων που δίνουν τη δυνατότητα στους υπολογιστές να μαθαίνουν από εμπειρικά δεδομένα και να βελτιώνουν σταδιακά την απόδοσή τους σε συγκεκριμένες εργασίες χωρίς να απαιτείται ρητός προγραμματισμός για κάθε δυνατή περίπτωση (Bishop 2006; Hastie et al. 2009). Ειδικότερα, ο όρος ***machine learning*** εισήχθη για πρώτη φορά από τον *Arthur Samuel* το 1959, ο οποίος τον περιέγραψε ως «την ικανότητα των υπολογιστών να μαθαίνουν χωρίς να έχουν προγραμματιστεί ρητά για αυτό». Από τις πρώιμες προσπάθειες στην αυτόματη αναγνώριση μοτίβων και την τεχνητή νοημοσύνη, η μηχανική μάθηση εξελίχθηκε σε έναν θεμελιώδη κλάδο της σύγχρονης επιστήμης δεδομένων, ειδικά με την ανάπτυξη του υπολογιστικού δυναμικού και τη διαθεσιμότητα μεγάλων συνόλων δεδομένων (*big data*). Η **βαθιά μάθηση** (*deep learning*, *DL*) από την άλλη αποτελεί έναν εξειδικευμένο υποτομέα της μηχανικής μάθησης με κύριο χαρακτηριστικό τη χρήση πολυεπίπεδων νευρωνικών δικτύων (*deep neural networks*), τα οποία έχουν τη δυνατότητα να μαθαίνουν αυτόνομα ιεραρχικές αναπαραστάσεις των δεδομένων από τις ακατέργαστες εισόδους. Η «βαθιά» δομή των δικτύων αντιπροσωπεύει τον μεγάλο αριθμό των στρωμάτων (*layers*) που μπορεί να κυμαίνεται από μερικές δεκάδες έως πολλά εκατοντάδες. Μέσω αυτής της προσέγγισης η βαθιά μάθηση επιτυγχάνει εξαιρετικά αποτελέσματα σε απαιτητικές εφαρμογές, όπως η επεξεργασία εικόνας, ήχου και γλώσσας, συχνά υπερέχοντας σε απόδοση έναντι των παραδοσιακών μεθόδων μηχανικής μάθησης.



Σχήμα 4.1: Σχέση ανάμεσα σε τεχνητή νοημοσύνη, μηχανική μάθηση και βαθιά μάθηση.

Η θεμελιώδης ιδέα της μηχανικής μάθησης έγκειται στην κατασκευή ενός μοντέλου που μπορεί να εντοπίζει πρότυπα και συσχετίσεις μέσα σε δεδομένα, ώστε να γενικεύει τη γνώση του και να λαμβάνει προβλέψεις ή αποφάσεις για νέα, άγνωστα δείγματα. Σε αντίθεση με τους παραδοσιακούς αλγορίθμους, οι οποίοι ακολουθούν ένα αυστηρά προκαθορισμένο σύνολο εντολών, τα μοντέλα Μηχανικής Μάθησης προσαρμόζονται δυναμικά στα χαρακτηριστικά του προβλήματος μέσω διαδικασιών εκπαίδευσης. Η θεμελιώδης αρχή λειτουργίας των μοντέλων Μηχανικής Μάθησης περιλαμβάνει τρία βασικά στάδια:

Εκπαίδευση (*Training*) Το μοντέλο εκπαιδεύεται σε ένα σύνολο παραδειγμάτων εκπαίδευσης $\{(x_i, y_i)\}_{i=1}^N$, όπου x_i είναι το διάνυσμα εισόδου και y_i η αντίστοιχη ετικέτα κατηγορίας. Κατά την εκπαίδευση, το μοντέλο προσαρμόζει τις παραμέτρους του (π.χ. βάρη και μεροληψίες σε ένα νευρωνικό δίκτυο), με στόχο την ελαχιστοποίηση μιας συνάρτησης απώλειας $L(y_i, \hat{y}_i)$ που μετρά τη διαφορά μεταξύ των προβλέψεων $\hat{y}_i$ και των πραγματικών ετικετών. Η εκπαίδευση συνήθως υλοποιείται με τη χρήση αλγορίθμων βελτιστοποίησης, όπως ο *Stochastic Gradient Descent* ή παραλλαγές του.

Αξιολόγηση (*Evaluation*) Μετά την εκπαίδευση, το μοντέλο αξιολογείται σε ένα ανεξάρτητο σύνολο επικύρωσης ή ελέγχου (*validation/test sets*) ώστε να εκτιμηθεί η ικανότητά του να γενικεύει σε νέα, άγνωστα δεδομένα. Σε αυτό το στάδιο υπολογίζονται κατάλληλες μετρικές απόδοσης ανάλογα με τη φύση του προβλήματος.

Πρόβλεψη ή απόφαση (*Inference*) Κατά το στάδιο της πρόβλεψης, το εκπαιδευμένο μοντέλο λαμβάνει νέα δείγματα εισόδου x και παράγει μια έξοδο $\hat{y}$. Στην περίπτωση της ταξινόμησης πολλών κατηγοριών που μας ενδιαφέρει η έξοδος του μοντέλου είναι ένα διάνυσμα από *logits*, δηλαδή μη κανονικοποιημένες τιμές που αντιστοιχούν στο βαθμό ενεργοποίησης κάθε κατηγορίας:

$$z = f(x) = [z_1, z_2, \dots, z_K] \in \mathbb{R}^K \quad (4.1)$$

όπου K είναι ο αριθμός των κατηγοριών και z_k η «βαθμολογία» της k -οστής κατηγορίας.

Οι πιθανότητες κάθε κατηγορίας προκύπτουν με την εφαρμογή της **softmax** συνάρτησης:


$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad \text{για κάθε } k = 1, \dots, K \quad (4.2)$$

Η κατηγορία με τη μέγιστη πιθανότητα επιλέγεται ως τελική πρόβλεψη του μοντέλου:

$$\hat{y} = \arg \max_k \hat{p}_k \quad (4.3)$$

Η χρήση των logits και της softmax επιτρέπει την ερμηνεία της εξόδου ως κανονικοποιημένων πιθανοτήτων για κάθε κατηγορία, κάτι που είναι ιδιαίτερα χρήσιμο για προβλήματα σε ιατρικές διαγνώσεις όπου η βεβαιότητα της πρόβλεψης έχει σημασία.

Οι τεχνικές μηχανικής μάθησης διακρίνονται βάσει του τύπου των διαθέσιμων δεδομένων και του στόχου στις παρακάτω κύριες κατηγορίες: **Επιβλεπόμενη, Μη Επιβλεπόμενη, Ημιεπιβλεπόμενη και Ενισχυτική**.



Σχήμα 4.2: Κατηγορίες μηχανικής μάθησης.

Στη παρούσα εργασία χρησιμοποιήθηκαν ωστόσο αποκλειστικά τεχνικές επιβλεπόμενης και μη επιβλεπόμενης μηχανικής μάθησης, οι οποίες θα αναλυθούν στις παρακάτω ενότητες:

4.1.1 Επιβλεπόμενη μάθηση

Η **επιβλεπόμενη μηχανική μάθηση** (*supervised machine learning*) αποτελεί έναν από τους θεμελιώδεις τομείς της μηχανικής μάθησης. Σύμφωνα με τον *Bishop* πρόκειται για τη διαδικασία κατά την οποία ένα υπολογιστικό σύστημα μαθαίνει να προσεγγίζει μια συνάρτηση $f : \mathcal{X} \rightarrow \mathcal{Y}$, η οποία αντιστοιχίζει δεδομένα εισόδου $x \in \mathcal{X}$ σε επιθυμητές εξόδους ή ετικέτες $y \in \mathcal{Y}$, με βάση ένα σύνολο παραδειγμάτων εκπαίδευσης.

Το σύνολο εκπαίδευσης αποτελείται από ζεύγη (x_i, y_i) , όπου x_i είναι ένα διάνυσμα χαρακτηριστικών και y_i η αντίστοιχη ετικέτα. Ο στόχος της επιβλεπόμενης μάθησης είναι να κατασκευαστεί ένα μοντέλο που θα γενικεύει καλά, δηλαδή θα μπορεί να προβλέπει σωστά τις εξόδους για νέα, άγνωστα δείγματα x , ελαχιστοποιώντας το σφάλμα πρόβλεψης.

Η εκπαίδευση πραγματοποιείται συνήθως μέσω της **ελαχιστοποίησης της εμπειρικής απώλειας** (*empirical risk minimization*), δηλαδή της ελαχιστοποίησης μιας συνάρτησης κόστους $L(y, f(x))$ που μετρά τη διαφορά μεταξύ της προβλεπόμενης και της πραγματικής ετικέτας.

Ανάλογα με τη φύση της εξόδου y , η επιβλεπόμενη μάθηση διακρίνεται σε δύο κύριες κατηγορίες: **παλινδρόμηση** και **ταξινόμηση**.

Παλινδρόμηση (regression) Στα προβλήματα παλινδρόμησης η μεταβλητή εξόδου y είναι **συνεχής** και μπορεί να λάβει απείρως πολλές τιμές εντός ενός διαστήματος. Ο στόχος είναι να προβλεφθεί μια ποσοτική τιμή με τη μικρότερη δυνατή απόκλιση από την πραγματική.

Παραδείγματα περιλαμβάνουν την πρόβλεψη της θερμοκρασίας περιβάλλοντος σε επερχόμενη χρονική στιγμή, των επιπέδων γλυκόζης σε ασθενείς με σακχαρώδη διαβήτη, της τιμής ενός ακινήτου βάσει χαρακτηριστικών όπως το εμβαδόν και η τοποθεσία ή της τιμής ενός χρηματιστηριακού δείκτη.

Τα μοντέλα παλινδρόμησης χρησιμοποιούν μετρικές όπως το **μέσο τετραγωνικό σφάλμα** (*mean squared error*) ή το **μέσο απόλυτο σφάλμα** (*mean absolute error*) για την αξιολόγηση της ακρίβειας των προβλέψεών τους.

Ταξινόμηση (classification) Στα προβλήματα ταξινόμησης η μεταβλητή εξόδου y ανήκει σε ένα **πεπερασμένο και διακριτό σύνολο κατηγοριών**. Ο στόχος είναι η κατασκευή ενός μοντέλου που θα μπορεί να προβλέπει σωστά την κατηγορία στην οποία ανήκει ένα νέο παράδειγμα. Η ταξινόμηση μπορεί να είναι:

- **Binary** όταν υπάρχουν δύο κατηγορίες, π.χ. υγιής ή ασθενής.
- **Multiclass** όταν υπάρχουν περισσότερες από δύο κατηγορίες, π.χ. διάγνωση τύπου αναπνευστικής νόσου (άσθμα, ΧΑΠ, πνευμονία).
- **Multilabel** όταν κάθε παράδειγμα εκπαίδευσης μπορεί να ανήκει ταυτόχρονα σε περισσότερες από μία κατηγορίες.

Ενδεικτικές εφαρμογές ταξινόμησης περιλαμβάνουν τη διάγνωση αναπνευστικών παθήσεων από ηχητικά σήματα, την αναγνώριση χειρογράφων, την ταξινόμηση ειδήσεων ή *email* σε *spam* και *non-spam* και τη διαλογή ιατρικών εικόνων κατά παθολογική κατάσταση.

Τα μοντέλα ταξινόμησης χρησιμοποιούν μετρικές αξιολόγησης της πρόβλεψης όπως η **ακρίβεια** (*accuracy*), η **ανάκληση** (*recall*), το **precision**, το **F1 score**, καθώς και οι **καμπύλες Receiver Operating Characteristic (ROC curves)**. Οι μετρικές αυτές καθώς και επιπλέον τέτοιες μετρικές αναλύονται εκτενέστερα στην Ενότητα 4.5.

Η επιβλεπόμενη μάθηση περιλαμβάνει έναν ευρύ φάσμα αλγορίθμων από το οποίο στη συγκεκριμένη εργασία θα μας απασχολήσουν μόνο τα μοντέλα ταξινόμησης. Αυτά είναι το **Τυχαίο Δάσος** (*Random Forest*), ο ταξινομητής *k*-Πλησιέστερων Γειτόνων (*k*-*Nearest Neighbors*), καθώς και οι **Μηχανές Υποστήριξης Διανυσμάτων** (*Support Vector Machines*).

Σύμφωνα με τους *Jordan* και *Mitchell*, η επιβλεπόμενη μάθηση έχει αναδειχθεί σε κεντρικό εργαλείο για πληθώρα εφαρμογών, από την ανάλυση βιοσημάτων και την επεξεργασία φυσικής γλώσσας έως την αναγνώριση εικόνας και την αυτόματη διάγνωση ασθενειών.

4.1.2 Μη επιβλεπόμενη μάθηση

Η **μη επιβλεπόμενη μηχανική μάθηση** (*unsupervised machine learning*) αφορά μεθόδους κατά τις οποίες το μοντέλο εκπαιδεύεται σε δεδομένα που **δεν συνοδεύονται από ετικέτες εξόδου**. Ο στόχος είναι να ανακαλυφθούν εσωτερικές δομές, συσχετίσεις ή πρότυπα μέσα στα δεδομένα χωρίς την εποπτεία κάποιου «δασκάλου».

Οι δύο κύριες εφαρμογές της μη επιβλεπόμενης μάθησης είναι η **συσταδοποίηση ή ομαδοποίηση** και η **μείωση διαστατικότητας**.

Ομαδοποίηση (*clustering*) Η ομαδοποίηση αποτελεί έναν από τους κύριους στόχους της μη επιβλεπόμενης μάθησης και αναφέρεται στη διαδικασία διαίρεσης ενός συνόλου δεδομένων σε υποσύνολα (*clusters*) με βάση την ομοιότητα μεταξύ των δειγμάτων. Ο σκοπός είναι να τοποθετηθούν παρατηρήσεις με παρόμοια χαρακτηριστικά στην ίδια ομάδα, έτσι ώστε τα μέλη της ίδιας ομάδας να είναι όσο το δυνατόν πιο όμοια μεταξύ τους και όσο το δυνατόν πιο διαφορετικά από τα μέλη άλλων ομάδων.

Η ομαδοποίηση είναι ιδιαίτερα χρήσιμη κατά την αρχική εξερεύνηση των δεδομένων (*Exploratory Data Analysis, EDA*) για τον εντοπισμό υποκείμενων προτύπων ή πληθυσμιακών υποομάδων, όπως ασθενείς με παρόμοια συμπτώματα ή φυσιολογικά χαρακτηριστικά.

Δημοφιλείς αλγόριθμοι ομαδοποίησης είναι ο *k-means*, η **ιεραρχική ομαδοποίηση** (*hierarchical clustering*) και ο *DBSCAN*.

Μείωση διαστατικότητας (*dimensionality reduction*) Η μείωση διαστατικότητας στοχεύει στον μετασχηματισμό ενός συνόλου χαρακτηριστικών υψηλής διάστασης σε έναν νέο χώρο χαμηλότερων διαστάσεων, με τρόπο που να διατηρείται η μέγιστη δυνατή πληροφορία που φέρουν τα αρχικά δεδομένα. Το πρόβλημα προκύπτει συχνά σε εφαρμογές όπου τα δεδομένα περιγράφονται από μεγάλο αριθμό χαρακτηριστικών, όπως στη δικιά μας περίπτωση, γεγονός που καθιστά δύσκολη τη μοντελοποίηση, την αποθήκευση και την οπτικοποίηση.


Συνεπώς, μέσω της μείωσης διαστατικότητας γίνεται αποφυγή της «κατάρτας της διαστατικότητας» (*curse of dimensionality*), ενώ παράλληλα η οπτικοποίηση σε χαμηλότερες διαστάσεις μπορεί να συμβάλει στην επιλογή χαρακτηριστικών από το σύνολο χαρακτηριστικών, μειώνοντας έτσι τη πολυπλοκότητα του μοντέλου.

Τεχνικές όπως η **Ανάλυση σε Κύριες Συνιστώσες** (*Principal Component Analysis, PCA*) και το *t-distributed Stochastic Neighbor Embedding* (*t-SNE*) έχουν καθε-

ρωθεί ως βασικά εργαλεία για την ανάλυση και προβολή δεδομένων υψηλής διαστατικότητας.

Ανάλυση σε Κύριες Συνιστώσες (Principal Component Analysis, PCA) Το PCA είναι μια γραμμική μέθοδος μείωσης διαστατικότητας, η οποία στοχεύει στην εύρεση ενός νέου ορθογώνιου συστήματος συντεταγμένων όπου οι διαστάσεις (κύριες συνιστώσες) ευθυγραμμίζονται με τις κατευθύνσεις μέγιστης διακύμανσης των δεδομένων. Οι κύριες συνιστώσες είναι τα ιδιοδιανύσματα του πίνακα συνδιακύμανσης των δεδομένων, ταξινομημένα κατά φθίνουσα ιδιοτιμή, και κάθε επόμενη συνιστώσα περιγράφει τη μέγιστη δυνατή διακύμανση υπό τον περιορισμό της ορθογωνιότητας ως προς τις προηγούμενες (Jolliffe and Cadima 2016).

Για την εφαρμογή του PCA στα δικά μας δεδομένα, δηλαδή στα 41 ακουστικά χαρακτηριστικά που εξάγαμε, επιλέξαμε να διατηρηθεί το 95% της διασποράς τους.



Σχήμα 4.3: 2D απεικόνιση των δεδομένων του dataset με χρήση PCA.

t-distributed Stochastic Neighbor Embedding (tSNE) Το *tSNE* είναι μια μη γραμμική μέθοδος μείωσης διαστατικότητας που αναπτύχθηκε με σκοπό την αποδοτική οπτικοποίηση πολύπλοκων δεδομένων σε 2 ή 3 διαστάσεις. Σε αντίθεση με το PCA, το *tSNE* δεν επιχειρεί να διατηρήσει τη παγκόσμια δομή, αλλά επικεντρώνεται στη διατήρηση των τοπικών σχέσεων ομοιότητας μεταξύ δειγμάτων. Γι' αυτό το λόγο αποδεικνύεται ιδιαίτερα χρήσιμο για την ανίχνευση κρυφών δομών ή κατηγοριών.


Η βασική ιδέα είναι η μετατροπή των αποστάσεων μεταξύ σημείων στο αρχικό χώρο σε πιθανοκρατικές ομοιότητες και στη συνέχεια η ανακατανομή των σημείων σε χαμηλότερη διάσταση με τρόπο ώστε οι τοπικές πιθανότητες να διατηρούνται όσο το δυνατόν περισσότερο. Αυτό επιτυγχάνεται με τη χρήση της κατανομής *t Student* στον στόχο και της κατανομής *Gauss* στον αρχικό χώρο (Maaten and Hinton 2008).

Σημειώνεται ότι αν και το *tSNE* προσφέρει εξαιρετική οπτικοποίηση δεν είναι κατάλληλο για ταξινόμηση, καθώς δεν διατηρεί σαφή γεωμετρική σχέση των δεδομένων. Επίσης, η επιλογή υπερπαραμέτρων (π.χ. *perplexity*) επηρεάζει έντονα το αποτέλεσμα. Πιο συγκεκριμένα, το *perplexity* ορίζεται ως η εκθετική τιμή της εντροπίας της πιθανοκρατικής κατανομής των γειτονικών σημείων ενός δείγματος:

$$\text{Perplexity}(P_i) = 2^{H(P_i)} = 2^{-\sum_j p_{j|i} \log_2 p_{j|i}} \quad (4.4)$$

όπου $p_{j|i}$ είναι η πιθανοκρατική ομοιότητα του σημείου x_j ως γείτονα του x_i , και $H(P_i)$ η εντροπία της κατανομής.

Η αρχική μελέτη του *van der Maaten* προτείνει την επιλογή του *perplexity* από το εύρος $[5, 50]$, ενώ η κατάλληλη τιμή εξαρτάται σε μεγάλο βαθμό από το μέγεθος και την πυκνότητα του συνόλου δεδομένων. Για μικρά σύνολα δεδομένων προτιμώνται μικρότερες τιμές, ενώ σε μεγαλύτερα σύνολα η αύξηση του *perplexity* μπορεί να βελτιώσει τη διατήρηση της παγκόσμιας δομής. Για το δικό μας σύνολο δεδομένων έχει επιλεγεί η τιμή 30:



Σχήμα 4.4: 2D απεικόνιση των δεδομένων του dataset με χρήση tSNE.

4.2 Παραδοσιακοί Αλγόριθμοι Ταξινόμησης

Στη συγκεκριμένη ενότητα παρουσιάζεται αναλυτικά η λειτουργία των επιλεγμένων αλγορίθμων ταξινόμησης των κατηγοριών των αναπνευστικών ήχων. Πιο συγκεκριμένα, έχουν υλοποιηθεί ένας ταξινομητής *k-NN*, ένα μη γραμμικό *SVM*, ένας ταξινομητής *Random Forest* καθώς και ένας ταξινομητής *XGBoost* για μια πιο εξελιγμένη και σύγχρονη προσέγγιση.


4.2.1 k-Nearest Neighbors (k-NN)

Ο αλγόριθμος *k-Nearest Neighbors (k-NN)* είναι μια απλή αλλά ιδιαίτερα ισχυρή μη παραμετρική μέθοδος ταξινόμησης η οποία βασίζεται στην υπόθεση ότι τα δείγματα που βρίσκονται κοντά μεταξύ τους στον χώρο χαρακτηριστικών πιθανότατα ανήκουν και στην ίδια κατηγορία (Hastie et al. 2009). Σαν αλγόριθμος είναι εύκολος στην κατανόηση και στην υλοποίηση, καθώς δεν απαιτεί εκπαίδευση, γεγονός που τον καθιστά αρκετά εύλικτο. Ωστόσο, χρειάζεται προσεκτικό χειρισμό, καθώς δείχνει ευαισθησία σε θορυβώδη και σε μη ισορροπημένα δεδομένα, ενώ παράλληλα επηρεάζεται σημαντικά από τη διάσταση του χώρου χαρακτηριστικών.

Η βασική ιδέα υλοποίησής του είναι η εξής: για την ταξινόμηση ενός άγνωστου δείγματος x , εντοπίζονται οι k πιο κοντινοί γείτονες από το σύνολο εκπαίδευσης, βάσει μιας επιλεγμένης μετρικής απόστασης. Η επιλογή της μετρικής απόστασης επηρεάζει σημαντικά την απόδοση του k -NN με τις συνηθέστερες επιλογές να είναι:

- **Ευκλείδεια απόσταση** (ℓ_2 -norm): $d(x_i, x_j) = \sqrt{\sum_{l=1}^d (x_i^{(l)} - x_j^{(l)})^2}$
- **Απόσταση Manhattan** (ℓ_1 -norm): $d(x_i, x_j) = \sum_{l=1}^d |x_i^{(l)} - x_j^{(l)}|$
- **Απόσταση Minkowski, Cosine, Mahalanobis** κ.ά.

Τέλος, η ετικέτα του x προβλέπεται ως η πιο συχνή κατηγορία (πλειοψηφία) ανάμεσα στους γείτονες αυτούς.



Σχήμα 4.5: Ταξινομητής k-NN.

Μαθηματικά, ο συγκεκριμένος αλγόριθμος ορίζεται ως εξής: Έστω $x \in \mathbb{R}^d$ το δείγμα προς ταξινόμηση και το σύνολο εκπαίδευσης $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$. Ορίζουμε:

$\mathcal{N}_k(x)$ = το σύνολο των k πλησιέστερων γειτόνων του x ως προς κάποια μετρική d

Η προβλεπόμενη ετικέτα $\hat{y}$ δίνεται από:

$$\hat{y} = \arg \max_{c \in \mathcal{Y}} \sum_{(x_i, y_i) \in \mathcal{N}_k(x)} \mathbb{I}(y_i = c) \quad (4.5)$$

όπου $\mathbb{I}$ είναι η ενδεικτική συνάρτηση και $\mathcal{Y}$ το σύνολο των κατηγοριών.

4.2.2 Support Vector Machines (SVM)

Οι **Μηχανές Υποστήριξης Διανυσμάτων** (*Support Vector Machines, SVMs*) αποτελούν έναν από τους ισχυρότερους και θεωρητικά πιο καλοθεμελιωμένους αλγορίθμους


επιβλεπόμενης μάθησης για προβλήματα ταξινόμησης και παλινδρόμησης. Αναπτύχθηκαν από τον *Vladimir Vapnik* και την *Corinna Cortes* στις αρχές της δεκαετίας του 1990.

Η θεμελιώδης ιδέα του *SVM* είναι να εντοπίσει ένα **υπερεπίπεδο** (*hyperplane*) στον χώρο χαρακτηριστικών, το οποίο να διαχωρίζει γραμμικά τις κλάσεις των δεδομένων με το **μέγιστο δυνατό περιθώριο** (*maximum margin*), δηλαδή με τη μεγαλύτερη δυνατή απόσταση από τα πλησιέστερα σημεία εκπαίδευσης κάθε κατηγορίας.

Έστω ότι έχουμε ένα σύνολο δειγμάτων $x_i \in \mathbb{R}^d$ με αντίστοιχες ετικέτες $y_i \in \{-1, +1\}$. Το ζητούμενο είναι να προσδιοριστεί ένας γραμμικός διαχωριστής της μορφής:

$$f(x) = \mathbf{w}^\top x + b = 0 \quad (4.6)$$

ο οποίος διαχωρίζει σωστά όλα τα δείγματα και μεγιστοποιεί την απόσταση μεταξύ του υπερ-επιπέδου και των πλησιέστερων σημείων κάθε κατηγορίας (γνωστά ως *support vectors*). Η απόσταση αυτή αντιστοιχεί στο **περιθώριο ταξινόμησης** και είναι ίση με $\frac{2}{\|\mathbf{w}\|}$.



Σχήμα 4.6: Γραμμικός ταξινομητής SVM.

Η εκπαίδευση του κλασικού γραμμικού *SVM* περιλαμβάνει την επίλυση του εξής προβλήματος ελαχιστοποίησης:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{υπό τους περιορισμούς:} \quad y_i(\mathbf{w}^\top x_i + b) \geq 1, \quad \forall i \quad (4.7)$$

Αυτή η διατύπωση μεγιστοποιεί το περιθώριο, διατηρώντας σωστό διαχωρισμό των δεδομένων. Στην πράξη, χρησιμοποιείται και η **χαλαρή διατύπωση** (*soft-margin SVM*), όπου επιτρέπονται κάποια σφάλματα ταξινόμησης:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{υπό τους περιορισμούς:} \quad y_i(\mathbf{w}^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (4.8)$$

Η παράμετρος C ελέγχει το *trade-off* μεταξύ μεγάλου περιθωρίου και μικρών σφαλμάτων (*regularization*).

Η χρήση του μέγιστου περιθωρίου καθιστά τα *SVM* ιδιαίτερα ανθεκτικά στη γενίκευση, αφού η λύση εξαρτάται μόνο από ένα υποσύνολο των σημείων εκπαίδευσης, τα *support vectors*. Σε πολλές περιπτώσεις όμως όπως και στη δική μας τα δεδομένα μπορεί να είναι αρκετά σύνθετα και να μην είναι γραμμικά διαχωρίσιμα. Για αυτόν τον λόγο χρησιμοποιήθηκε μη γραμμικό *SVM*, το οποίο εφαρμόζει το *kernel trick*, δηλαδή έναν μη γραμμικό μετασχηματισμό των δεδομένων σε χώρο μεγαλύτερων διαστάσεων όπου ο διαχωρισμός γίνεται γραμμικός. Το μη γραμμικό *SVM* είναι ανθεκτικό στην υπερεκπαίδευση (*overfitting*) ιδίως όταν χρησιμοποιούνται κανονικοποιημένα χαρακτηριστικά. Ωστόσο, μπορεί να απαιτήσει αρκετά υψηλό υπολογιστικό κόστος ειδικά σε μεγάλα *datasets*.

Στις πιο διαδεδομένες συναρτήσεις πυρήνα συγκαταλέγονται οι εξής:

- Πολυωνυμικός πυρήνας (*Polynomial kernel*): $K(x_i, x_j) = (\mathbf{x}_i^\top \mathbf{x}_j + c)^d$
- Πυρήνας *RBF* (*Gaussian kernel*): $K(x_i, x_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$
Η παράμετρος $\gamma > 0$ καθορίζει την «εμβέλεια» επιρροής κάθε δείγματος.
- Σιγμοειδής πυρήνας (*Sigmoid kernel*): $K(x_i, x_j) = \tanh(\alpha \mathbf{x}_i^\top \mathbf{x}_j + \beta)$


Στην συγκεκριμένη εργασία έχει χρησιμοποιηθεί ως συνάρτηση πυρήνα η *RBF* με κατάλληλο συνδυασμό υπερπαραμέτρων γ και C ο οποίος αναλύεται παρακάτω.

4.2.3 Random Forest (RF)

Ο αλγόριθμος *Random Forest (RF)* είναι μια ισχυρή και ευρέως χρησιμοποιούμενη μέθοδος επιβλεπόμενης μάθησης, που ανήκει στην κατηγορία των μεθόδων συλλογικής μάθησης (*ensemble learning*). Εισήχθη από τον *Leo Breiman* το 2001 (*breiman2001random*) και αποτελεί εξέλιξη της μεθόδου των δέντρων απόφασης (*decision trees*) με στόχο τη βελτίωση της ακρίβειας και της γενίκευσης.

Η βασική ιδέα του είναι η κατασκευή ενός μεγάλου αριθμού δέντρων απόφασης κατά την εκπαίδευση και η συνδυασμένη χρήση των προβλέψεών τους κατά την ταξινόμηση. Η τελική απόφαση προκύπτει είτε μέσω πλειοψηφικής ψήφου (στην ταξινόμηση) είτε μέσω μέσου όρου (στην παλινδρόμηση). Ο αλγόριθμος είναι μη παραμετρικός, δηλαδή δεν απαιτεί καμία υπόθεση για την κατανομή των δεδομένων και λειτουργεί αποτελεσματικά ακόμα και σε *datasets* υψηλής διαστατικότητας ή με αλληλεξαρτώμενες μεταβλητές.

Κάθε δέντρο εκπαιδεύεται σε διαφορετικό υποσύνολο του αρχικού συνόλου εκπαίδευσης, το οποίο επιλέγεται με δειγματοληψία με επανάθεση (*bootstrap sampling*). Σε κάθε κόμβο δέντρου η διαίρεση επιλέγεται από ένα τυχαίο υποσύνολο χαρακτηριστικών (και όχι από το πλήρες σύνολο), περιορίζοντας τη συσχέτιση μεταξύ των δέντρων και αυξάνοντας τη διασπορά. Οι δύο αυτοί μηχανισμοί μειώνουν τη μεταβλητότητα του μοντέλου και αυξάνουν τη γενίκευση, χωρίς να αυξάνουν αισθητά τη μεροληψία (*bias*), δημιουργώντας έναν «πληθυσμό» από ισχυρούς αλλά διαφοροποιημένους ταξινομητές.



Σχήμα 4.7: Ταξινομητής Random Forest.

Όμοια με πριν, στη δικιά μας υλοποίηση έχει χρησιμοποιηθεί *Random Forest* με κατάλληλο συνδυασμό υπερπαραμέτρων ο οποίος αναλύεται παρακάτω.

4.2.4 XGBoost

Ο αλγόριθμος **XGBoost** (*eXtreme Gradient Boosting*) είναι ένας εξελεγχμένος αλγόριθμος *ensemble learning*, ο οποίος βασίζεται στη μέθοδο **gradient boosting** και έχει αποδειχθεί ιδιαίτερα αποτελεσματικός σε πληθώρα προβλημάτων ταξινόμησης. Αναπτύχθηκε από τον *Tianqi Chen* και παρουσιάστηκε το 2016.

Το *XGBoost* πιο συγκεκριμένα κατασκευάζει ένα ισχυρό τελικό μοντέλο συνδυάζοντας πολλούς «ασθενείς» ταξινομητές, συνήθως δέντρα απόφασης μικρού βάρους. Το *gradient boosting* είναι μια επαναληπτική μέθοδος που προσθέτει διαδοχικά μοντέλα ώστε να μειώσει το σφάλμα του συνόλου. Σε κάθε επανάληψη t , κατασκευάζεται ένα νέο δέντρο $f_t(x)$ που προσεγγίζει το αρνητικό *gradient* της συνάρτησης απώλειας (*loss function*) σε σχέση με τις προβλέψεις του προηγούμενου μοντέλου. Ορισμένες από τις καινοτομίες του είναι λοιπόν ότι **εισάγει όρους κανονικοποίησης L_1 και L_2** περιορίζοντας την πολυπλοκότητα των δέντρων και βελτιώνοντας τη γενίκευση και ότι **χρησιμοποιούνται στατιστικά βάρη δειγμάτων** για αποδοτική εύρεση *split points* ακόμα και με μεγάλα ή μη ισορροπημένα δεδομένα.


Ο συνολικός στόχος του *XGBoost* είναι η ελαχιστοποίηση μιας κανονικοποιημένης συνάρτησης κόστους της μορφής:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (4.10)$$

όπου:

- l : συνάρτηση απώλειας,
- f_t : το νέο δέντρο στο βήμα t ,

- $\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \|w\|^2$: όρος κανονικοποίησης που εξαρτάται από τον αριθμό κόμβων T και τα βάρη w των φύλλων.



Σχήμα 4.8: Ταξινομητής XGBoost.

4.3 Νευρωνικά δίκτυα

Τα **νευρωνικά δίκτυα** (*neural networks*) αποτελούν ένα από τα σημαντικότερα υποδείγματα μηχανικής μάθησης, εμπνευσμένα από τη λειτουργία των βιολογικών νευρωνικών συστημάτων. Αποτελούνται από διαδοχικά επίπεδα υπολογιστικών μονάδων (**νευρώνες**), τα οποία επεξεργάζονται σήματα εισόδου και μεταδίδουν πληροφορία μέσω μη γραμμικών συναρτήσεων ενεργοποίησης.

Η ραγδαία πρόοδος των υπολογιστικών δυνατοτήτων και η διαθεσιμότητα μεγάλων συνόλων δεδομένων οδήγησαν στη ραγδαία ανάπτυξη της περιοχής των **βαθιών νευρωνικών δικτύων** (*deep neural networks*), η οποία έχει μεταμορφώσει πλήθος εφαρμογών, από την επεξεργασία εικόνας και ήχου, μέχρι τη φυσική γλώσσα και τη βιοϊατρική ανάλυση.

Τα νευρωνικά δίκτυα παρουσιάζουν εξαιρετική ικανότητα γενίκευσης σε πολύπλοκα και υψηλής διαστατικότητας δεδομένα, αρκεί να συνοδεύονται από κατάλληλη προεπεξεργασία, επιλογή αρχιτεκτονικής και τεχνικές ρύθμισης υπερπαραμέτρων.

Στην παρούσα εργασία, τα νευρωνικά δίκτυα χρησιμοποιήθηκαν όχι αποκλειστικά ως ταξινομητές για την αναγνώριση παθολογικών μοτίβων σε αναπνευστικούς κύκλους, αλλά ως μέθοδοι μη επιβλεπόμενης μάθησης για αναπαράσταση και συμπίεση των ακουστικών χαρακτηριστικών στο πλαίσιο του *acoustic domain adaptation*. Επιπλέον, έγινε χρήση δύο διαφορετικών παραλλαγών αρχιτεκτονικών, όπως τα **Multi-Layer Perceptrons (MLP)** και τα **Autoencoders (AE)**.

4.3.1 Αρχιτεκτονική ενός MLP

Το **Multilayer Perceptron (MLP)** αποτελεί ένα από τα βασικά και πλέον θεμελιώδη μοντέλα τεχνητού νευρωνικού δικτύου και ανήκει στην ευρύτερη οικογένεια των **τεχνητών νευρωνικών δικτύων** (Artificial Neural Networks) που αναφέραμε πιο πάνω. Πρόκειται για ένα fully-connected feedforward network στο οποίο η πληροφορία ρέει μόνο από την είσοδο προς την έξοδο χωρίς την ύπαρξη ανατροφοδότησης ή κυκλικών συνδέσεων.

Κάθε νευρώνας συνδέεται με όλους τους νευρώνες του επόμενου επιπέδου, γεγονός που επιτρέπει στο MLP να μάθει πολύπλοκες μη γραμμικές συναρτήσεις από τα δεδομένα. Σύμφωνα με το **θεώρημα καθολικής προσέγγισης** (universal approximation theorem), ένα MLP με τουλάχιστον ένα κρυφό επίπεδο και επαρκή αριθμό νευρώνων μπορεί να προσεγγίσει οποιαδήποτε συνεχώς διαφορίσιμη συνάρτηση με αυθαίρετη ακρίβεια.

Η τυπική αρχιτεκτονική ενός MLP περιλαμβάνει τρία βασικά modules:

Επίπεδο εισόδου (Input layer) Το πρώτο επίπεδο του δικτύου, το οποίο δέχεται τα δεδομένα εισόδου με τη μορφή διανυσμάτων χαρακτηριστικών $x = [x_1, x_2, \dots, x_n] \in \mathbb{R}^n$. Κάθε νευρώνας του επιπέδου αυτού αντιστοιχεί σε ένα χαρακτηριστικό του συνόλου δεδομένων και δεν εκτελεί κάποια επεξεργασία, αλλά απλώς μεταφέρει την πληροφορία στα επόμενα επίπεδα.


Κρυφά επίπεδα (Hidden layers) Σε αυτά πραγματοποιείται η ουσιαστική επεξεργασία και η εκμάθηση των αναπαραστάσεων. Κάθε νευρώνας του επιπέδου l υπολογίζει έναν γραμμικό συνδυασμό των εισόδων του και εφαρμόζει μια μη γραμμική **συνάρτηση ενεργοποίησης**:

$$a_j^{(l)} = f \left(\sum_{i=1}^{d_{l-1}} w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right) \quad (4.11)$$

όπου:

- $a_j^{(l)}$: η έξοδος του j -οστού νευρώνα του επιπέδου l ,
- $w_{ji}^{(l)}$: το βάρος μεταξύ του i -οστού νευρώνα του προηγούμενου επιπέδου και του j -οστού του τρέχοντος επιπέδου,
- $b_j^{(l)}$: η τιμή μεροληψίας (bias),
- $f(\cdot)$: η συνάρτηση ενεργοποίησης.

Επίπεδο εξόδου (Output layer) Παράγει την τελική έξοδο $\hat{y} = [y_1, y_2, \dots, y_m] \in \mathbb{R}^m$ του μοντέλου. Η μορφή του εξαρτάται από τον τύπο του προβλήματος. Για πολυκατηγορική ταξινόμηση περιλαμβάνει m νευρώνες (όπου m το πλήθος των κατηγοριών) με softmax ενεργοποίηση για παραγωγή πιθανοτήτων.



Σχήμα 4.9: Αρχιτεκτονική ενός MLP.

Το MLP εκπαιδεύεται με επιβλεπόμενη μάθηση μέσω της ελαχιστοποίησης μιας **συνάρτησης κόστους**. Η εκπαίδευση γίνεται με χρήση του αλγορίθμου **αντίστροφης διάδοσης** (backpropagation) και ενός αλγορίθμου **στοχαστικής βελτιστοποίησης**.

Το MLP αποτελεί τη βάση για πιο σύνθετες αρχιτεκτονικές βαθιάς μάθησης οι οποίες θα αναλυθούν στο Κεφάλαιο 5, προσφέροντας μια αξιόπιστη και εύκολα ερμηνεύσιμη λύση για προβλήματα όπου τα δεδομένα είναι δομημένα ως διανύσματα σταθερού μήκους.

4.3.2 Αρχιτεκτονική ενός Autoencoder

Τα **autoencoders** είναι ένας τύπος τεχνητών νευρωνικών δικτύων που σχεδιάζονται με σκοπό την **μη επιβλεπόμενη μάθηση** αναπαραστάσεων. Η βασική τους λειτουργία είναι η μάθηση μιας αποδοτικής συμπιεσμένης κωδικοποίησης (encoding) των δεδομένων εισόδου χωρίς την ανάγκη ετικετών. Η έννοια των autoencoders εισήχθη για πρώτη φορά από τους *Rumelhart et al.* (1986) και έκτοτε έχει χρησιμοποιηθεί ευρέως στην εξαγωγή χαρακτηριστικών, μείωση διαστατικότητας και την ανίχνευση ανωμαλιών.


Ένας autoencoder αποτελείται από δύο κύριες συνιστώσες:

Κωδικοποιητής (Encoder) Χαρτογραφεί την είσοδο $x \in \mathbb{R}^n$ σε έναν συμπιεσμένο (latent) χώρο χαρακτηριστικών $z \in \mathbb{R}^m$ με $m < n$ υλοποιώντας έναν μη γραμμικό μετασχηματισμό $z = g(x)$.

Αποκωδικοποιητής (Decoder) Ανακατασκευάζει την είσοδο από τον συμπιεσμένο χώρο παράγοντας $x' = f(z) \in \mathbb{R}^n$ με στόχο την ελαχιστοποίηση της διαφοράς $x' \approx x$.

$$x \xrightarrow{\text{Encoder}} z \xrightarrow{\text{Decoder}} x'$$

Ο ρόλος του z είναι η αποτύπωση των πιο σημαντικών πληροφοριών του x σε συμπιεσμένη μορφή, εξαλείφοντας τον θόρυβο ή τις περιττές διαστάσεις. Η συνολική δομή έχει γενικά ως στόχο την ελαχιστοποίηση μιας οποιασδήποτε **συνάρτησης σφάλματος ανακατασκευής**.



Σχήμα 4.10: Αρχιτεκτονική ενός Autoencoder.

Τα autoencoders εκπαιδεύονται με επιβλεπόμενο τρόπο ως προς το $x \rightarrow x'$, αλλά συνολικά συνιστούν μία μορφή μη επιβλεπόμενης μάθησης, καθώς δεν απαιτούν εξωτερικές ετικέτες (labels).

Γενικά, βρίσκουν ευρεία εφαρμογή ειδικά σε προβλήματα όπως η εξαγωγή ή το **φιλτράρισμα χαρακτηριστικών για επακόλουθη ταξινόμηση**. Υπάρχουν αρκετές παραλλαγές των κλασικών autoencoders, ωστόσο αυτή που θα μας απασχολήσει στη συγκεκριμένη εργασία είναι ο **Variational Autoencoder (VAE)**, ο οποίος αξιοποιείται για τη μη επιβλεπόμενη **συμπύκνωση των εξαγμένων χαρακτηριστικών** από τα αναπνευστικά σήματα, επιτρέποντας την αναπαράστασή τους σε διακριτικό χώρο χαρακτηριστικών προτού χρησιμοποιηθούν στα μοντέλα ταξινόμησης. Ο ρόλος του VAE είναι αντί να μαθαίνει μια σταθερή κωδικοποίηση z , να **μοντελοποιεί κατανομές πιθανότητας** $q(z|x)$ επιτρέποντας τη δειγματοληψία και δημιουργία νέων δεδομένων. Η δομή και η λειτουργία του ωστόσο θα αναληθούν περαιτέρω στην Ενότητα 5.5.

4.3.3 Συναρτήσεις ενεργοποίησης (Activation functions)

Οι **συναρτήσεις ενεργοποίησης** (activation functions) αποτελούν ένα κρίσιμο συστατικό των τεχνητών νευρωνικών δικτύων. Εφαρμόζονται στην έξοδο κάθε νευρώνα και εισάγουν **μη γραμμικότητα** στο μοντέλο, επιτρέποντας στο δίκτυο να μάθει και να προσεγγίσει πολύπλοκες, μη γραμμικές σχέσεις μεταξύ εισόδων και εξόδων. Χωρίς αυτές ένα απλό νευρωνικό δίκτυο θα μπορούσε να εκφράσει μόνο γραμμικούς μετασχηματισμούς, ανεξαρτήτως βάθους.

Όπως αναφέραμε και πριν η είσοδος κάθε νευρώνα είναι ένας γραμμικός συνδυασμός των εισερχόμενων σημάτων και η έξοδος προκύπτει ως το αποτέλεσμα της συνάρτησης ενεργοποίησης με το γραμμικό συνδυασμό σαν όρισμα.

Υπάρχουν διάφοροι τύποι ενεργοποιήσεων και η επιλογή τους εξαρτάται από τη φύση του προβλήματος και το σημείο του δικτύου στο οποίο χρησιμοποιούνται.

Σιγμοειδής (Sigmoid)

$$f(z) = \frac{1}{1 + e^{-z}} \quad (4.12)$$

Παράγει έξοδο στο διάστημα $(0, 1)$ και χρησιμοποιείται σε προβλήματα δυαδικής ταξινόμησης. Παρουσιάζει όμως προβλήματα εξασθένησης κλίσεων (vanishing gradients) ειδικά σε βαθιά δίκτυα.

Υπερβολική εφαπτομένη (tanh)

$$f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (4.13)$$

Παρέχει έξοδο στο διάστημα $(-1, 1)$ και έχει μηδενικό μέσο όρο, γεγονός που συχνά επιταχύνει τη σύγκλιση σε σχέση με τη σιγμοειδ. Ωστόσο, υπόκειται και αυτή στο πρόβλημα των vanishing gradients.

ReLU (Rectified Linear Unit)

$$f(z) = \max(0, z) \quad (4.14)$$

Αποτελεί τη δημοφιλέστερη συνάρτηση ενεργοποίησης για κρυφά επίπεδα λόγω της απλότητας και της αποδοτικότητάς της. Αντιμετωπίζει το πρόβλημα των εξαφανιζόμενων κλίσεων και επιτρέπει γρήγορη εκπαίδευση. Ένα πιθανό μειονέκτημα είναι η εμφάνιση του προβλήματος νεκρών νευρώνων (dead neurons) όταν οι έξοδοι γίνονται μηδενικές και δεν ανανεώνονται τα βάρη.

Leaky ReLU

$$f(z) = \begin{cases} z, & z > 0 \\ \alpha z, & z \leq 0 \end{cases} \quad \text{με } \alpha \ll 1 \quad (4.15)$$

Εισάγει μικρή κλίση για αρνητικές τιμές ώστε να αντιμετωπίζεται το πρόβλημα των νεκρών νευρώνων. Συνήθως $\alpha = 0.01$.

Softmax

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \quad (4.16)$$

Εφαρμόζεται στο επίπεδο εξόδου σε προβλήματα πολυκατηγορικής ταξινόμησης. Παράγει πιθανότητες που αθροίζονται στο 1 και επιτρέπει την επιλογή της πιθανότερης κατηγορίας.

4.3.4 Συναρτήσεις κόστους (Loss functions)

Οι **συναρτήσεις κόστους** (loss functions), γνωστές και ως **συναρτήσεις απώλειας**, παίζουν καθοριστικό ρόλο στην εκπαίδευση των νευρωνικών δικτύων. Ποσοτικοποιούν το σφάλμα ανάμεσα στην επιθυμητή έξοδο y και την πρόβλεψη $\hat{y}$ που παράγει το μοντέλο. Η

ελαχιστοποίηση της συνάρτησης κόστους οδηγεί στην προσαρμογή των παραμέτρων του μοντέλου, ώστε να βελτιωθεί η ακρίβεια των προβλέψεών του.

Μαθηματικά, αν έχουμε ένα σύνολο εκπαίδευσης $\{(x_i, y_i)\}_{i=1}^N$, η συνολική απώλεια δίνεται από:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{y}_i)$$

όπου $L(y_i, \hat{y}_i)$ είναι η ατομική απώλεια για το i -οστό παράδειγμα.

Παρακάτω παρουσιάζονται οι πιο διαδεδομένες από αυτές όσον αφορά τη ταξινόμηση:

Binary Cross-Entropy

$$L(y, \hat{y}) = -[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y})] \quad (4.17)$$

Χρησιμοποιείται για δυαδική ταξινόμηση με έξοδο από sigmoid. Υποθέτει ότι η πρόβλεψη $\hat{y}$ αντιστοιχεί σε πιθανότητα.

Categorical Cross-Entropy

$$L(y, \hat{y}) = - \sum_{k=1}^K y_k \log(\hat{y}_k) \quad (4.18)$$

Χρησιμοποιείται για προβλήματα πολυκατηγορικής ταξινόμησης με έξοδο softmax. Η y_k είναι 1 για τη σωστή κατηγορία και 0 για τις υπόλοιπες (one-hot encoding).

Sparse Categorical Cross-Entropy Όμοια με την προηγούμενη, αλλά η ετικέτα y εκφράζεται ως ακέραιος αριθμός (π.χ. κατηγορία 0, 1, ..., K-1) αντί για one-hot. Είναι αριθμητικά πιο αποδοτική.

Για την παλινδρόμηση συνήθως χρησιμοποιείται το **Μέσο Τετραγωνικό Σφάλμα (Mean Squared Error - MSE)**:

$$L(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2 \quad (4.19)$$

Η επιλογή της σωστής συνάρτησης κόστους έχει καθοριστική επίδραση στη σύγκλιση και την απόδοση του δικτύου. Συνδυάζεται συνήθως με αντίστοιχες συναρτήσεις ενεργοποίησης στην έξοδο (π.χ. sigmoid με BCE, softmax με cross-entropy).

4.3.5 Αλγόριθμοι βελτιστοποίησης (Optimizers)

Οι **αλγόριθμοι βελτιστοποίησης** (optimizers) αποτελούν το βασικό μηχανισμό εκπαίδευσης ενός νευρωνικού δικτύου, καθώς είναι υπεύθυνοι για την προσαρμογή των παραμέτρων του μοντέλου (βάρη και μεροληψίες) μέσω της ελαχιστοποίησης της συνάρτησης κόστους. Η διαδικασία αυτή πραγματοποιείται μέσω επαναληπτικών ενημερώσεων των παραμέτρων με βάση την κατεύθυνση του αρνητικού βαθμιδώδους διανύσματος (gradient descent).

Έστω συνάρτηση κόστους $L(\theta)$ και παράμετροι θ . Η βασική ενημέρωσή της γίνεται ως εξής:

$$\theta^{(t+1)} = \theta^{(t)} - \eta \cdot \nabla_{\theta} L(\theta) \quad (4.20)$$

όπου:

- η : ο ρυθμός μάθησης (learning rate),
- $\nabla_{\theta} L(\theta)$: η κλίση ή αλλιώς gradient της συνάρτησης κόστους ως προς τις παραμέτρους.

Διάφορες παραλλαγές του αλγορίθμου έχουν αναπτυχθεί για να αντιμετωπιστούν προβλήματα όπως η αργή σύγκλιση, οι τοπικά ελάχιστες τιμές ή οι εξασθενημένες κλίσεις. Παρακάτω παρουσιάζονται οι πιο διαδεδομένοι αλγόριθμοι:

Stochastic Gradient Descent (SGD) Χρησιμοποιεί μικρές δειγματοληπτημένες παρτίδες (mini-batches) από το σύνολο εκπαίδευσης για την εκτίμηση του βαθμωτού διανύσματος. Αν και είναι απλός και υπολογιστικά αποδοτικός, μπορεί να παρουσιάσει θορυβώδη σύγκλιση και δυσκολίες στην εύρεση του παγκόσμιου ελαχίστου.

Momentum Εισάγει μια μορφή «αδράνειας» στην ενημέρωση των παραμέτρων:

$$v^{(t+1)} = \mu v^{(t)} - \eta \nabla_{\theta} L(\theta) \quad ; \quad \theta^{(t+1)} = \theta^{(t)} + v^{(t+1)} \quad (4.21)$$

όπου $\mu \in [0, 1)$ είναι ο συντελεστής ορμής. Το σχήμα αυτό επιταχύνει τη σύγκλιση σε «φαράγγια» της επιφάνειας κόστους και μειώνει τις ταλαντώσεις.

Adaptive Moment Estimation (Adam) Αποτελεί έναν από τους πιο δημοφιλείς αλγόριθμους βελτιστοποίησης ο οποίος διατηρεί τρέχουσες εκτιμήσεις και για το πρώτο (m_t) και δεύτερο (v_t) στιγμιότυπο της κλίσης:

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \\ \hat{m}_t &= \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \\ \theta_{t+1} &= \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \end{aligned} \quad (4.22)$$

Οι προεπιλεγμένες τιμές είναι $\beta_1 = 0.9$, $\beta_2 = 0.999$, και $\epsilon = 10^{-8}$. Ο Adam είναι αριθμητικά σταθερός και παρουσιάζει ταχύτατη σύγκλιση.

4.4 Ρύθμιση μοντέλων

Η επίδοση ενός μοντέλου μηχανικής μάθησης εξαρτάται όχι μόνο από την αρχιτεκτονική του ή τον αλγόριθμο που χρησιμοποιείται, αλλά και από την κατάλληλη **ρύθμιση** (tuning)

των παραμέτρων και των εισόδων του. Η διαδικασία ρύθμισης περιλαμβάνει τεχνικές που αποσκοπούν στη βελτιστοποίηση της γενικευσιμότητας του μοντέλου, μειώνοντας ταυτόχρονα την πιθανότητα υπερπροσαρμογής (overfitting) ή υποπροσαρμογής (underfitting).

Στα περισσότερα μοντέλα, διακρίνουμε δύο βασικούς τύπους παραμέτρων:

- **Εσωτερικές παράμετροι (learnable parameters):** Μαθαίνονται κατά τη διαδικασία εκπαίδευσης (π.χ. βάρη σε ένα νευρωνικό δίκτυο) και δεν χρειάζεται να οριστούν από τον χρήστη χειροκίνητα.
- **Υπερπαράμετροι (hyperparameters):** Ρυθμίζονται πριν την εκπαίδευση από τον χρήστη και επηρεάζουν τη συμπεριφορά του μοντέλου (π.χ. learning rate, αριθμός γειτόνων στο k-NN, αριθμός δέντρων σε random forest κ.τ.λ.).

Επιπλέον, η ποιότητα των χαρακτηριστικών που εισάγονται στο μοντέλο (feature space) επηρεάζει άμεσα τη μάθηση. Για αυτόν τον λόγο, η **επιλογή χαρακτηριστικών**, η **κλιμάκωσή τους** και η **ρύθμιση των υπερπαραμέτρων** αποτελούν θεμελιώδη βήματα στην κατασκευή ενός αποτελεσματικού pipeline.

Όλα αυτά τα βήματα που εφαρμόσαμε περιγράφονται λοιπόν λεπτομερώς στη συγκεκριμένη ενότητα.

4.4.1 Κλιμάκωση

Η **κλιμάκωση χαρακτηριστικών** (feature scaling) είναι ένα κρίσιμο βήμα στην προεπεξεργασία των δεδομένων, ιδίως όταν τα χαρακτηριστικά εισόδου έχουν διαφορετικές μονάδες μέτρησης, μεγέθη ή διακυμάνσεις. Πολλοί αλγόριθμοι μηχανικής μάθησης είναι ευαίσθητοι στο εύρος των τιμών των χαρακτηριστικών, καθώς βασίζονται σε αποστάσεις (π.χ. k-NN, SVM) ή στη γραμμικότητα (νευρωνικά δίκτυα), οπότε είναι κρίσιμο όλα τα δεδομένα να εκφράζονται στην **ίδια κλίμακα**.

Παρακάτω παρουσιάζονται οι πιο ευρέως χρησιμοποιούμενες τεχνικές:

Κανονικοποίηση ελαχίστου-μεγίστου (Min–Max scaling) Μετασχηματίζει γραμμικά τα δεδομένα ενός χαρακτηριστικού ώστε να περιορίζονται εντός προκαθορισμένου διαστήματος $[a, b]$, συνήθως $[0, 1]$ ή $[-1, 1]$. Ο μετασχηματισμός δίνεται από τη σχέση:

$$x' = a + \frac{(b - a)(x - \min(x))}{\max(x) - \min(x)} \quad (4.23)$$

όπου:

- x είναι η αρχική τιμή του χαρακτηριστικού,
- x' η κανονικοποιημένη τιμή,
- $\min(x)$ και $\max(x)$ είναι οι ελάχιστες και μέγιστες τιμές του χαρακτηριστικού στο σύνολο εκπαίδευσης,
- $[a, b]$ είναι το επιθυμητό εύρος τιμών.

Αυτού του τύπου η κανονικοποίηση διατηρεί την αναλογική σχέση μεταξύ των δειγμάτων και τα κατανέμει συμμετρικά γύρω από το μηδέν.

Κανονικοποίηση z-score (Standardization) Μετασχηματίζει τα δεδομένα ώστε να ακολουθούν κανονική κατανομή μέσο όρο 0 και διακύμανση 1:

$$x' = \frac{x - \mu}{\sigma} \quad (4.24)$$

όπου μ είναι ο μέσος όρος και σ η τυπική απόκλιση.

Κλιμάκωση σε μοναδιαίο διάνυσμα (Vector normalization) Εφαρμόζεται κυρίως σε προβλήματα κειμένου ή συστημάτων σύστασης. Κανονικοποιεί κάθε δείγμα ώστε να έχει μοναδιαίο μέτρο:

$$x' = \frac{x}{\|x\|_p} \quad (4.25)$$

όπου $\|x\|_p$ είναι η p -νόρμα του διανύσματος, συχνότερα η Ευκλείδεια ($p = 2$).

Η κλιμάκωση πρέπει να εφαρμόζεται **μετά τη διάσπαση** των δεδομένων σε σύνολο εκπαίδευσης και ελέγχου, ώστε οι στατιστικές (μέση τιμή, διακύμανση κ.λπ.) να υπολογίζονται **μόνο από τα δεδομένα εκπαίδευσης** και να εφαρμόζονται ομοίμορφα και στο validation/test set. Αυτό αποτρέπει τη διαρροή πληροφορίας (data leakage).


Στην παρούσα εργασία χρησιμοποιήθηκε η **κανονικοποίηση Min-Max στο διάστημα $[-1, 1]$** πριν την εφαρμογή των περισσότερων αλγορίθμων ταξινόμησης, εξαιρουμένων των δέντρων απόφασης και παραγώγων τους (RF, XGBoost), οι οποίοι δεν επηρεάζονται από την κλίμακα των χαρακτηριστικών.

4.4.2 Επιλογή χαρακτηριστικών

Η **επιλογή των κατάλληλων χαρακτηριστικών** (feature selection) αποτελεί ένα από τα σημαντικότερα στάδια στην προεπεξεργασία δεδομένων και στη ρύθμιση μοντέλων μηχανικής μάθησης. Η ποιότητα, η διακριτική ικανότητα και η αλληλεπικάλυψη των χαρακτηριστικών επηρεάζουν άμεσα την απόδοση, τη γενικευσιμότητα και τη σταθερότητα ενός ταξινομητή.

Μια καλή πρακτική για την αρχική διερεύνηση της καταλληλότητας των χαρακτηριστικών είναι η **στατιστική ανάλυση κατανομών**, η οποία επιτρέπει την οπτική και ποσοτική αξιολόγηση της διακριτικής δύναμης κάθε μεταβλητής ως προς τις ετικέτες των δεδομένων. Για να επιτύχουμε κάτι τέτοιο έχουμε εφαρμόσει τις ακόλουθες τεχνικές:

KDE plots Η **Εκτίμηση Πυκνότητας Πυρήνα** (Kernel Density Estimation, KDE) παρέχει μία λεία εκτίμηση της κατανομής πιθανότητας μιας συνεχούς μεταβλητής. Η απεικόνιση των KDE plots ανά κατηγορία (label) επιτρέπει την αξιολόγηση της επικαλυπτόμενης πυκνότητας μεταξύ κλάσεων. Όσο μικρότερη είναι η επικάλυψη των καμπυλών, τόσο πιο διακριτικό είναι το χαρακτηριστικό.



Σχήμα 4.11: KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά label.

Παρατηρείται ότι για ορισμένα χαρακτηριστικά, όπως τα MFCC_3, MFCC_5, MFCC_7, το Spectral Rolloff, το RMS Energy ή ορισμένα Log-Mel Energies, οι κατανομές των κλάσεων παρουσιάζουν σημαντική επικάλυψη, γεγονός που υποδηλώνει περιορισμένη δυνατότητα διαχωρισμού τους βάσει μόνο αυτών των χαρακτηριστικών. Σε αντίθεση, υπάρχουν χαρακτηριστικά, όπως τα ZCR, Spectral Bandwidth, Spectral Centroid, Spectral Flatness, MFCC_0, MFCC_8, MFCC_12, όπου οι μέγιστες τιμές πυκνότητας (κορυφές) εμφανίζονται εμφανώς μετατοπισμένες μεταξύ των κλάσεων, στοιχείο που υποδεικνύει αυξημένη συνεισφορά τους στη διάκριση μεταξύ των κατηγοριών. Η μορφή των κατανομών ποικίλλει, με ορισμένες να προσεγγίζουν την κανονική κατανομή (*Gaussian-like*), ενώ άλλες εμφανίζουν μεγαλύτερη κύρτωση ή ασυμμετρία. Συνολικά, η απεικόνιση KDE καθιστά οπτικά σαφές ότι, παρότι μεμονωμένα χαρακτηριστικά μπορεί να παρουσιάζουν περιορισμένη διαχωριστική ικανότητα, ο συνδυασμός πολλαπλών χαρακτηριστικών ενδέχεται να ενισχύσει σημαντικά την απόδοση των ταξινομητών, στοιχείο που δικαιολογεί τη χρήση πολυδιάστατων διανυσμάτων χαρακτηριστικών.

Boxplots Ένα boxplot απεικονίζει συνοπτικά την κεντρική τάση, τη διασπορά και την παρουσία πιθανών ακραίων τιμών (outliers) μιας μεταβλητής. Τα βασικά του στοιχεία είναι:

- **Κουτί (box)**: εκτείνεται από το πρώτο τεταρτημόριο (Q_1) έως το τρίτο τεταρτημόριο (Q_3), καλύπτοντας το **ενδοτεταρτημοριακό εύρος (IQR)**:

$$IQR = Q_3 - Q_1$$

Αντιπροσωπεύει το μέσο 50% των δεδομένων.


- **Διάμεσος (median)**: απεικονίζεται ως μια οριζόντια γραμμή εντός του κουτιού και αντιστοιχεί στην κεντρική τιμή της κατανομής.
- **Ακροδέκτες (whiskers)**: εκτείνονται τυπικά μέχρι τις μέγιστες και ελάχιστες τιμές που βρίσκονται εντός $1.5 \times IQR$ από το κουτί (δηλαδή εντός των φυσιολογικών ορίων):

$$\text{Lower whisker} = Q_1 - 1.5 \cdot IQR$$

$$\text{Upper whisker} = Q_3 + 1.5 \cdot \text{IQR}$$

- **Ακραίες τιμές (outliers):** δεδομένα που βρίσκονται εκτός των whiskers, δηλαδή πολύ μικρότερα ή πολύ μεγαλύτερα από τα «τυπικά» όρια.


Η σύγκριση των boxplots μεταξύ των κατηγοριών παρέχει ενδείξεις για τη διακριτική ικανότητα του χαρακτηριστικού. Όταν οι διάμεσοι και τα IQR διαφέρουν σημαντικά μεταξύ των κατηγοριών και υπάρχει μικρή επικάλυψη μεταξύ των κουτιών ή των whiskers, τότε το χαρακτηριστικό μπορεί να θεωρηθεί δυνητικά χρήσιμο για ταξινόμηση. Στη δικιά μας περίπτωση, οι οπτικοποιήσεις των boxplots επιβεβαιώνουν τα παραπάνω ευρήματα που έχουν προκύψει από τα KDE plots. Πιο συγκεκριμένα, βλέπουμε πως τα ίδια χαρακτηριστικά τα οποία διαφέρουν ως προς τις κατανομές παρουσιάζουν ταυτόχρονα και σημαντική διαφορά και στις διαμέσους μεταξύ των κλάσεων και μικρή επικάλυψη των interquartile ranges, γεγονός που υποδηλώνει ότι η κατανομή των τιμών είναι αρκετά διακριτή.



Σχήμα 4.12: Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά label.

Heatmaps Πέρα από τις οπτικές τεχνικές KDE και boxplots, ιδιαίτερα χρήσιμη είναι και η απεικόνιση των συσχετίσεων μεταξύ μεταβλητών και κλάσεων ή μεταξύ των ίδιων των χαρακτηριστικών με τη μορφή **θερμικών χαρτών** (heatmaps). Τα heatmaps βασίζονται στη χρωματική απεικόνιση των τιμών των πινάκων συσχέτισης και επιτρέπουν την ταχεία αναγνώριση σχέσεων, πλεονασμού ή ανεπιθύμητων εξαρτήσεων.

(α) Feature–Class heatmap Σε αυτή την προσέγγιση υπολογίζεται ο βαθμός συσχέτισης κάθε χαρακτηριστικού με τη μεταβλητή στόχο, δηλαδή καθεμία από τις τρεις κλάσεις normal, crackle, wheeze. Ο θερμικός χάρτης απεικονίζει το μέγεθος της συσχέτισης με ένταση χρώματος, επιτρέποντας τον εντοπισμό των χαρακτηριστικών με τον εντονότερο χρωματικό διαχωρισμό ή ισοδύναμα με τη μεγαλύτερη συνολική διακριτική ικανότητα. Η χρωματική κλίμακα επίσης αποτυπώνει την κανονικοποιημένη μέση τιμή του κάθε χαρακτηριστικού ανά κλάση, επιτρέποντας τον άμεσο εντοπισμό ισχυρών θετικών ή αρνητικών συσχετίσεων.



Σχήμα 4.13: Feature-Class heatmap των εξαγμένων χαρακτηριστικών.

Παρατηρείται ότι τα χαρακτηριστικά MFCC_1, MFCC_2, MFCC_6, καθώς και οι δείκτες Spectral Centroid και Spectral Bandwidth, εμφανίζουν έντονη διαφοροποίηση μεταξύ των κλάσεων, γεγονός που υποδηλώνει υψηλή διαχωριστική ικανότητα. Ειδικότερα, η κλάση Wheeze παρουσιάζει υψηλές τιμές στα χαρακτηριστικά MFCC_1 και Spectral Centroid, σε αντίθεση με τις κλάσεις Normal και Crackle που καταγράφουν χαμηλότερες τιμές. Αντίστοιχα, αρκετές ζώνες Log-Mel (όπως οι Log_Mel_0, Log_Mel_3, Log_Mel_5, Log_Mel_7) εμφανίζουν σαφείς διαφοροποιήσεις μεταξύ των τριών κλάσεων, ιδιαίτερα στην κλάση Crackle όπου τείνουν σε υψηλότερες τιμές και τους Wheeze σε χαμηλότερες.


(β) Feature-Feature ή Correlation heatmap Η ανάλυση αυτοσυσχέτισης (correlation matrix) βοηθά στην αναγνώριση έντονα συσχετιζόμενων μεταβλητών. Όταν δύο ή περισσότερα χαρακτηριστικά παρουσιάζουν πολύ υψηλό συσχετισμό ενδέχεται να παρέχουν παρόμοια πληροφορία επιβαρύνοντας άσκοπα το μοντέλο. Οι πιο συνηθισμένοι συντελεστές συσχέτισης είναι ο **συντελεστής συσχέτισης Pearson** για συνεχείς μεταβλητές με

γραμμικές κυρίως σχέσεις και οι **Spearman** ή **Kendall Tau** για μη γραμμικές ή ιεραρχικές σχέσεις. Στη δικιά μας περίπτωση **έχει επιλεγεί ο συντελεστής Pearson**, ο οποίος ορίζεται ως:

$$r_{X,Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (4.26)$$

όπου $X = (x_1, x_2, \dots, x_n)$ και $Y = (y_1, y_2, \dots, y_n)$ είναι δύο συνεχείς μεταβλητές με n δείγματα και $\bar{x}$ και $\bar{y}$ είναι οι μέσοι όροι των X και Y αντίστοιχα.

Χαμηλή συσχέτιση μεταξύ των επιλεγμένων χαρακτηριστικών ενδείκνυται για τη σταθερότητα και τη γενικευσιμότητα των μοντέλων, ιδίως σε γραμμικούς ή βασισμένους σε αποστάσεις ταξινομητές. Ωστόσο, η ταυτόχρονη διατήρηση συμπληρωματικών και μη συσχετισμένων χαρακτηριστικών μπορεί σε ορισμένες περιπτώσεις να βελτιώσει τη διαχωριστική ικανότητα του μοντέλου.



Σχήμα 4.14: Correlation heatmap των εξαγμένων χαρακτηριστικών.

Γενικά, παρατηρείται ότι τα **Log-Mel φίλτρα** εμφανίζουν πολύ υψηλή **θετική συσχέτιση**, ιδιαίτερα μεταξύ γειτονικών ζωνών (π.χ. **Log_Mel_0–Log_Mel_5**, **Log_Mel_10–Log_Mel_15**), γεγονός το οποίο επιβεβαιώνει ότι περιγράφουν σε μεγάλο βαθμό παρόμοιες φασματικές πληροφορίες και άρα δεν χρειάζεται να διατηρηθούν όλα. Αντίστοιχα, **οι χαμηλής τάξης συντελεστές MFCC** όπως **MFCC_0–MFCC_5** παρουσιάζουν και αυτοί **μέτρια έως υψηλή συσχέτιση** μεταξύ τους, καθώς προκύπτουν από τον ίδιο μετασχηματισμό και καταγράφουν την γενική φασματική κλίση. Ακόμη, **μέτρια συσχέτιση** παρατηρείται κυρίως μεταξύ των **Spectral Centroid**, **Spectral Bandwidth** και **Spectral Rolloff**, κάτι που είναι αναμενόμενο καθώς όλα αυτά τα χαρακτηριστικά αποτυπώνουν διαφορετικές όψεις της κατανομής της φασματικής ενέργειας. Αντίθετα, χαρακτηριστικά όπως το

Zero Crossing Rate, τοRMS Energy και το Onset Envelope εμφανίζουν **μέτρια προς χαμηλή συσχέτιση** με τα περισσότερα χαρακτηριστικά, γεγονός που υποδηλώνει ότι προσφέρουν συμπληρωματική πληροφορία η οποία δεν προκύπτει άμεσα από τις υπόλοιπες φασματικές περιγραφές.

ANOVA Test Η **Ανάλυση Διασποράς** ή ANOVA (Analysis of Variance) αποτελεί μία κλασική στατιστική μέθοδο για τη διερεύνηση του κατά πόσον η μέση τιμή ενός χαρακτηριστικού διαφέρει σημαντικά μεταξύ δύο ή περισσότερων ομάδων (στην περίπτωση μας, μεταξύ των κατηγοριών normal, crackle και wheeze). Η βασική υπόθεση της μεθόδου είναι η εξής:

«Οι ομάδες προέρχονται από πληθυσμούς με ίσες μέσες τιμές» (null hypothesis).

Η ANOVA εξετάζει εάν η διακύμανση μεταξύ των ομάδων είναι στατιστικά σημαντικά μεγαλύτερη από τη διακύμανση εντός των ομάδων. Ένα χαρακτηριστικό θεωρείται πληροφοριακό ως προς την κλάση όταν η διακύμανση εκτός των ομάδων είναι αρκετά μεγαλύτερη από την διακύμανση εντός της ομάδας. Το στατιστικό μέτρο που υπολογίζεται στην ANOVA είναι το **F-score** και ορίζεται ως εξής:

$$F = \frac{\text{Between-group variance}}{\text{Within-group variance}}$$

Πιο συγκεκριμένα, αν έχουμε K ομάδες (κλάσεις), N συνολικά παρατηρήσεις και ένα χαρακτηριστικό X , τότε το Between-group variance δίνεται από:

$$SS_{\text{between}} = \sum_{k=1}^K n_k (\bar{x}_k - \bar{x})^2 \quad (4.27)$$

και το Within-group variance από:

$$SS_{\text{within}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (x_{ki} - \bar{x}_k)^2 \quad (4.28)$$


όπου:

- $\bar{x}_k$: ο μέσος όρος του χαρακτηριστικού στην ομάδα k ,
- $\bar{x}$: ο συνολικός μέσος όρος του χαρακτηριστικού,
- n_k : το πλήθος δειγμάτων στην ομάδα k .

Ο τελικός δείκτης F προκύπτει ως:


$$F = \frac{SS_{\text{between}}/(K-1)}{SS_{\text{within}}/(N-K)}$$

Στο πλαίσιο ταξινόμησης, η ANOVA εφαρμόζεται ανεξάρτητα για κάθε χαρακτηριστικό ώστε να εκτιμηθεί η διακριτική του ικανότητα ως προς την ετικέτα ταξινόμησης. Τα χαρακτηριστικά κατατάσσονται βάσει του F-score και μάλιστα όσο μεγαλύτερο είναι το F , τόσο ισχυρότερη είναι η ένδειξη ότι υπάρχει σημαντική διαφορά μεταξύ των ομάδων.




Σχήμα 4.15: Κατάταξη χαρακτηριστικών βάσει F -score από ANOVA test ως προς το label.

Επίσης, ο διαχωρισμός γίνεται και με βάση το p -value, το οποίο αποτελεί την πιθανότητα να παρατηρηθεί ένα αποτέλεσμα τουλάχιστον τόσο ακραίο όσο το πραγματικά παρατηρηθέν, υπό την υπόθεση ότι η μηδενική υπόθεση (H_0) είναι αληθής. Σε ένα τεστ ANOVA η H_0 δηλώνει ότι «δεν υπάρχει στατιστικά σημαντική διαφορά μεταξύ των μέσων όρων των ομάδων». Αντιθέτως, η εναλλακτική υπόθεση (H_1) δηλώνει ότι τουλάχιστον ένας μέσος όρος διαφέρει. Αν $p < 0.05$ απορρίπτεται η H_0 , το οποίο σημαίνει ότι το χαρακτηριστικό παρουσιάζει σημαντικές διαφορές μεταξύ των ομάδων και άρα είναι διαχωριστικό.



Σχήμα 4.16: p -values των χαρακτηριστικών από ANOVA test.

Στην παρούσα εργασία, η στατιστική μελέτη ανέδειξε τη συμβολή κάθε χαρακτηριστικού στην διάκριση των κλάσεων και αποδεικνύεται πως η επιλογή **15–20 χαρακτηριστικών** από τα 41 συνολικά επαρκεί για μέγιστη απόδοση, καθιστώντας τη χρήση του πλήρους διανύσματος χαρακτηριστικών μη απαραίτητη και εν δυνάμει επιζήμια λόγω αυξημένου θορύβου ή πλεονασμού. Αυτή η διαπίστωση επιβεβαιώνεται και από τη παρακάτω γραφική παράσταση, από την οποία παρατηρούμε ότι η απόδοση της ταξινόμησης αυξάνεται σημαντικά όταν χρησιμοποιούμε τα κορυφαία 15-20 χαρακτηριστικά τα οποία είδαμε ότι παρουσιάζουν τη μέγιστη διακριτική ικανότητα. Από εκεί και έπειτα αγγίζει ένα κατώφλι στο οποίο συγκλίνει όσα επιπλέον χαρακτηριστικά και να κρατήσουμε.



Σχήμα 4.17: Μεταβολή απόδοσης ταξινόμησης ως προς το πλήθος χαρακτηριστικών που χρησιμοποιήθηκαν.

Πίνακας 4.1: Τα 20 κορυφαία επιλεγμένα χαρακτηριστικά

MFCC_5	MFCC_2	Spectral Rolloff	MFCC_6
On Set Envelope	MFCC_9	MFCC_8	Log_Mel_5
MFCC_11	Spectral Centroid	Spectral Bandwidth	Log_Mel_4
MFCC_7	RMS Energy	Spectral Flux	Log_Mel_6
MFCC_4	MFCC_3	MFCC_1	Zero Crossing Rate

4.4.3 Ρύθμιση υπερπαραμέτρων

Αφού έχουν κλιμακωθεί και έχουν διατηρηθεί τα χαρακτηριστικά με τη μεγαλύτερη συνεισφορά, τώρα είναι σημαντικό να γίνει **κατάλληλη επιλογή υπερπαραμέτρων** για κάθε μοντέλο ταξινόμησης. Πιο κάτω παρατίθενται οι υπερπαραμέτροι που ερευνήθηκαν μέσω **grid search** και **διασταυρούμενη επικύρωση (cross-validation)**:

k-Nearest Neighbors (k-NN)

- *k*: Πλήθος των κοντινότερων γειτόνων που χρησιμοποιούνται για την πρόβλεψη. Μικρές τιμές οδηγούν σε αυξημένη ευαισθησία στον θόρυβο, ενώ μεγάλες τιμές ενδέχεται να μειώσουν την απόδοση σε σύνθετα προβλήματα. Πραγματοποιήθηκε διερεύνηση στο διάστημα [1, 20]

Non-Linear Support Vector Machine (RBF kernel)

- C : Παράμετρος κανονικοποίησης που ρυθμίζει το trade-off μεταξύ του μεγάλου περιθωρίου και της σωστής ταξινόμησης των εκπαιδευτικών δειγμάτων. Μικρές τιμές οδηγούν σε πιο «μαλακό» υπερεπίπεδο, ενώ μεγάλες σε αυστηρότερο διαχωρισμό. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[0.1, 1, 10]$.
- γ : Καθορίζει την ακτίνα επιρροής ενός μεμονωμένου δείγματος στη διαμόρφωση της συνάρτησης απόφασης. Μικρές τιμές οδηγούν σε πιο ομαλές επιφάνειες απόφασης (underfitting), ενώ μεγάλες τιμές σε πιο πολύπλοκες και ευαίσθητες στα δεδομένα επιφάνειες (overfitting). Στη βιβλιοθήκη `scikit-learn`, η επιλογή *auto* ορίζει το γ ως $1/n_{\text{features}}$, ενώ η προεπιλογή *scale* το ορίζει ως $1/(n_{\text{features}} \cdot \text{Var}(X))$, λαμβάνοντας υπόψη και τη διασπορά των δεδομένων για πιο σταθερή απόδοση.


Random Forest (RF)

- **n_estimators**: Αριθμός δέντρων στο δάσος. Περισσότερα δέντρα μειώνουν τη διασπορά αλλά αυξάνουν τον υπολογιστικό χρόνο. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[50, 100, 200]$.
- **max_depth**: Μέγιστο επιτρεπτό βάθος κάθε δέντρου. Περιορίζει την πολυπλοκότητα του μοντέλου. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[5, 10, 20]$.
- **min_samples_split**: Ελάχιστος αριθμός δειγμάτων για να διασπαστεί ένας κόμβος. Χρησιμοποιείται για αποφυγή υπερεκπαίδευσης. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[2, 5, 10]$.

XGBoost

- **n_estimators**: Αριθμός προσθετικών δέντρων (boosting rounds). Υψηλές τιμές μπορούν να οδηγήσουν σε overfitting. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[50, 100, 200]$.
- **learning_rate** (η): Ρυθμός εκμάθησης. Καθορίζει πόσο «βαριά» επηρεάζει κάθε νέο δέντρο την τελική πρόβλεψη. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[3, 5, 10]$.
- **max_depth**: Μέγιστο βάθος των δέντρων. Ρυθμίζει την πολυπλοκότητα κάθε αδύναμου ταξινομητή. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές $[0.1, 1, 10]$.

Από τη διαδικασία αυτή προέκυψαν οι παρακάτω βέλτιστοι συνδυασμοί υπερπαραμέτρων για κάθε μοντέλο:



Σχήμα 4.18: Βέλτιστοι συνδυασμοί υπερπαραμέτρων για κάθε μοντέλο ταξινόμησης.

Για το k-NN επιλέχθηκε η δεύτερη καλύτερη τιμή του k , δηλαδή $k = 3$, αντί για $k = 1$ όπου ελέγχεται αποκλειστικά ο κοντινότερος γείτονας, με σκοπό την ανθεκτικότητα σε ακραίες τιμές. Για το Non-Linear SVM επιλέχθηκε $C = 10$ και για $\gamma = 1/(n_{\text{features}} \cdot \text{Var}(X))$, δηλαδή το $scale$. Για το Random Forest επιλέχθηκαν $n_{\text{estimators}} = 200$ και $min_samples_split = 2$. Τέλος, για το XGBoost έχουμε $n_{\text{estimators}} = 200$, $max_depth = 10$ και $learning_rate = 0.1$.

4.5 Αξιολόγηση Μοντέλων

Η αξιολόγηση των μοντέλων μηχανικής μάθησης αποτελεί κρίσιμο στάδιο μετά τον ορισμό, τη ρύθμιση και την εκπαίδευση των μοντέλων, καθώς παρέχει αντικειμενικά κριτήρια για την εκτίμηση της ποιότητας, της αξιοπιστίας και της γενικευσιμότητας του μοντέλου. Ειδικά σε εφαρμογές βιοϊατρικής σημασίας, όπως η διάγνωση αναπνευστικών παθήσεων, η επιλογή κατάλληλων μετρικών αξιολόγησης είναι ζωτικής σημασίας, καθώς οι εσφαλμένες προβλέψεις ενδέχεται να οδηγήσουν σε κλινικά σφάλματα.


Η διαδικασία αξιολόγησης περιλαμβάνει συνήθως την αποτίμηση της απόδοσης του μοντέλου σε σύνολα δεδομένων που δεν έχουν χρησιμοποιηθεί για την εκπαίδευση (out-of-sample evaluation), ώστε να εκτιμηθεί η πραγματική ικανότητα γενίκευσης. Αυτό επιτυγχάνεται μέσω τεχνικών όπως η διασταυρούμενη επικύρωση (cross-validation), καθώς και με τη χρήση ποσοτικών μετρικών απόδοσης. Όλες αυτές οι διαφορετικές κατηγορίες μετρικών αξιολόγησης που επιλέξαμε να εφαρμόσουμε αναλύονται σε βάθος στη συγκεκριμένη ενότητα.

4.5.1 Cross-Validation (k-fold)

Η **διασταυρούμενη επικύρωση** (cross-validation) αποτελεί μια θεμελιώδη τεχνική εκτίμησης της γενικευσιμότητας ενός μοντέλου, δηλαδή της ικανότητάς του να επιτυγχάνει καλή απόδοση σε άγνωστα δεδομένα. Αντί να αξιολογείται το μοντέλο σε ένα στατικό σύνολο ελέγχου, το cross-validation προτείνει την πολλαπλή επανεκπαίδευση και αξιολόγηση του μοντέλου σε διαφορετικές υποδιαίρεσεις του συνόλου δεδομένων.

Η πιο διαδεδομένη παραλλαγή είναι το **k-fold cross-validation**, όπου τα δεδομένα χωρίζονται σε k ισομεγέθη και μη επικαλυπτόμενα υποσύνολα (φολνς). Σε κάθε επανάληψη το μοντέλο εκπαιδεύεται στα $k - 1$ folds (training set) και αξιολογείται στο εναπομείναν fold (validation set). Η διαδικασία επαναλαμβάνεται k φορές, έτσι ώστε κάθε fold να χρησιμοποιηθεί μία φορά ως validation set. Στο τέλος, οι μετρικές απόδοσης υπολογίζονται ως ο μέσος όρος των επιμέρους αξιολογήσεων.

Stratified k-fold cross-validation Σε περιπτώσεις **κατηγοριών με ανισοκατανομή** όπως στη δικιά μας χρησιμοποιείται η παραλλαγή **stratified k-fold cross-validation**. Σε αυτήν την προσέγγιση η κατανομή των κατηγοριών διατηρείται περίπου ίδια σε κάθε fold, έτσι ώστε να διασφαλίζεται η παρουσία αναλογικά ίδιου ποσοστού δειγμάτων ανά κλάση σε κάθε υποσύνολο. Αυτό καθιστά την επικύρωση πιο αξιόπιστη, καθώς αποφεύγεται το ενδεχόμενο ορισμένα folds να μην περιέχουν επαρκή αριθμό δειγμάτων από κάποια κλάση, γεγονός το οποίο μπορεί να οδηγήσει σε παραμορφωμένες εκτιμήσεις της απόδοσης του μοντέλου.



Σχήμα 4.19: Stratified k-fold cross-validation.

Η τιμή του k επηρεάζει τον συμβιβασμό μεταξύ **υπολογιστικού κόστους** και **σταθερότητας της εκτίμησης**. Συνήθως επιλέγονται τιμές όπως $k = 5$ ή $k = 10$, οι οποίες έχουν αποδειχθεί εμπειρικά αξιόπιστες (Kohavi 1995). Στην δικιά μας περίπτωση έχει επιλεγεί **$k=5$** .

4.5.2 Μετρικές απόδοσης ανά κλάση

Σε προβλήματα ταξινόμησης και ειδικότερα σε πολυκατηγορικά με ανισοκατανομημένες κατηγορίες η αξιολόγηση της απόδοσης ενός μοντέλου απαιτεί λεπτομερή ανάλυση πέρα από το απλό ποσοστό ακρίβειας (accuracy). Οι **μετρικές ανά κλάση** επιτρέπουν τη διερεύνηση

της συμπεριφοράς του μοντέλου ξεχωριστά για κάθε κατηγορία και βοηθούν στην κατανόηση πιθανών μεροληψιών ή αδυναμιών.

Βασίζονται στον υπολογισμό των παρακάτω ποσοτήτων για κάθε κλάση C_i :

- **True Positives (TP)**: Πλήθος δειγμάτων της κλάσης C_i που ταξινομήθηκαν σωστά ως C_i .
- **False Positives (FP)**: Πλήθος δειγμάτων άλλων κλάσεων που ταξινομήθηκαν εσφαλμένα ως C_i .
- **False Negatives (FN)**: Πλήθος δειγμάτων της κλάσης C_i που ταξινομήθηκαν εσφαλμένα ως άλλη κλάση.
- **True Negatives (TN)**: Πλήθος δειγμάτων εκτός C_i που ταξινομήθηκαν σωστά ως μη C_i .

Με βάση τα παραπάνω, ορίζονται οι ακόλουθες μετρικές:

Ακρίβεια (Precision) Η ακρίβεια μετρά την αναλογία των σωστών προβλέψεων μιας κλάσης επί των συνολικών προβλέψεων για την εν λόγω κλάση:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4.29)$$

Αντανακλά την «καθαρότητα» των θετικών προβλέψεων. Υψηλή τιμή σημαίνει ότι οι θετικές προβλέψεις είναι κατά κύριο λόγο σωστές.

Ανάκληση (Recall ή Sensitivity) Η ανάκληση μετρά την ικανότητα του μοντέλου να αναγνωρίζει σωστά όλα τα δείγματα μιας κλάσης:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4.30)$$

Υψηλή τιμή υποδηλώνει ότι λίγα πραγματικά θετικά δείγματα αγνοήθηκαν από το μοντέλο.

Μέτρο F_1 (F1-score) Το μέτρο F_1 αποτελεί τον αρμονικό μέσο της ακρίβειας και της ανάκλησης της κλάσης:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.31)$$

Είναι χρήσιμο σε περιπτώσεις όπου απαιτείται ισορροπία μεταξύ των δύο, και είναι ευαίσθητο σε χαμηλές τιμές οποιασδήποτε από τις δύο μετρικές.

Ειδικότητα (Specificity) Η ειδικότητα είναι συμπληρωματική της ανάκλησης και μετρά την ικανότητα αναγνώρισης των αρνητικών περιπτώσεων για την εκάστοτε κλάση:

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (4.32)$$

Είναι ιδιαίτερα χρήσιμη σε ιατρικές διαγνώσεις όπου η αποφυγή ψευδώς θετικών προβλέψεων είναι κρίσιμη.

4.5.3 Μετρικές συνολικής απόδοσης

Η αξιολόγηση της συνολικής απόδοσης ενός ταξινομητή γίνεται συνήθως με τη βοήθεια **σύνθετων μετρικών συνολικής απόδοσης**, οι οποίες συνοψίζουν την επίδοση του μοντέλου σε όλες τις κατηγορίες ή όλες τις προβλέψεις με ενιαίο τρόπο. Οι πιο διαδεδομένες από αυτές είναι οι εξής:

Ακρίβεια (Accuracy) Η ακρίβεια ορίζει το ποσοστό των σωστών προβλέψεων επί του συνολικού αριθμού δειγμάτων:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.33)$$

Σε προβλήματα πολυκατηγορικής ταξινόμησης η ακρίβεια ισούται με το πλήθος των σωστά ταξινομημένων δειγμάτων διαιρούμενο με το σύνολο των δειγμάτων. Αν και απλή στην ερμηνεία, δεν είναι πάντα κατάλληλη για μη ισορροπημένα σύνολα δεδομένων, καθώς μπορεί να δώσει παραπλανητικά υψηλές τιμές αν το μοντέλο προβλέπει σωστά μόνο την πλειοψηφική κλάση.

F_1 score με macro και weighted μέσο όρο Το F_1 score που ορίστηκε στην προηγούμενη ενότητα μπορεί να συνοψιστεί σε συνολικό επίπεδο αντί σε επίπεδο κλάσης με διάφορους τρόπους:

- **Macro F_1 :** Υπολογίζει το F_1 score ξεχωριστά για κάθε κλάση και επιστρέφει τον μη σταθμισμένο μέσο όρο:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{i=1}^K F1_i \quad (4.34)$$

- **Weighted F_1 :** Υπολογίζει το F_1 κάθε κλάσης και παίρνει το σταθμισμένο άθροισμα με βάση τον αριθμό δειγμάτων ανά κλάση:

$$F1_{\text{weighted}} = \sum_{i=1}^K w_i \cdot F1_i \quad \text{όπου } w_i = \frac{n_i}{N} \quad (4.35)$$

Matthews Correlation Coefficient (MCC) Ο συντελεστής συσχέτισης του Matthews είναι μία από τις πιο αξιόπιστες μετρικές για πολυκατηγορική ταξινόμηση, καθώς λαμβάνει υπόψη όλες τις τιμές TP, TN, FP και FN και ορίζεται ως:

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (4.36)$$

Το MCC είναι εύκολα ερμηνεύσιμο και λαμβάνει τιμές από -1 το οποίο δηλώνει πλήρη αποτυχία ταξινόμησης έως $+1$ το οποίο δηλώνει τέλεια ταξινόμηση, με το 0 να υποδηλώνει τυχαία πρόβλεψη.

Μητρώο Σύγχυσης (Confusion Matrix) Το **μητρώο σύγχυσης** είναι ένας πίνακας διαστάσεων $K \times K$ (όπου K είναι ο αριθμός των κατηγοριών) που αποτυπώνει συνοπτικά την απόδοση του ταξινομητή. Κάθε κελί (i, j) του πίνακα δηλώνει τον αριθμό δειγμάτων της πραγματικής κατηγορίας C_i που προβλέφθηκαν ως C_j . Οι γραμμές του πίνακα αντιστοιχούν στις **πραγματικές** ετικέτες, ενώ οι στήλες του αντιστοιχούν στις **προβλεπόμενες** ετικέτες. Τέλος, η διαγώνιος περιλαμβάνει τις σωστές προβλέψεις για κάθε κλάση, ενώ τα εκτός διαγωνίου στοιχεία αντιστοιχούν σε σφάλματα ταξινόμησης.

Το μητρώο σύγχυσης αποδεικνύεται ιδιαίτερα χρήσιμο, καθώς επιτρέπει τον εντοπισμό ποιοτικών μοτίβων σφαλμάτων μεταξύ συγκεκριμένων κλάσεων, αλλά και την εξαγωγή όλων των επιμέρους per class μετρικών (precision, recall, specificity κ.ά.).

		Predicted Values	
		Positive	Negative
Actual Values	Positive	TP	FN
	Negative	FP	TN

Σχήμα 4.20: Μητρώο σύγχυσης.

4.5.4 Καμπύλες ROC και Precision-Recall

Οι καμπύλες ROC και Precision-Recall αποτελούν γραφικές μεθόδους αξιολόγησης της απόδοσης ενός ταξινομητή ειδικά σε πολυκατηγορικά προβλήματα με τεχνικές one-vs-rest. Εστιάζουν στη διακριτική ικανότητα του μοντέλου και στη συμπεριφορά του υπό μεταβολές του κατωφλίου ταξινόμησης (decision threshold).

Καμπύλη ROC (Receiver Operating Characteristic) Η καμπύλη ROC απεικονίζει τη σχέση μεταξύ της **ευαισθησίας** (True Positive Rate – TPR) και του **ψευδώς θετικού ποσοστού** (False Positive Rate – FPR) καθώς μεταβάλλεται το κατώφλι ταξινόμησης.

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN} \quad (4.37)$$

Η ιδανική καμπύλη ROC προσεγγίζει το άνω αριστερό σημείο του διαγράμματος ($TPR = 1, FPR = 0$), ενώ η διαγώνια γραμμή ($TPR = FPR$) αντιστοιχεί σε πρόβλεψη που προκύπτει από τυχαίο ταξινομητή.

Εμβαδόν υπό την καμπύλη (Area Under the Curve – AUC) Η τιμή AUC συνοψίζει την καμπύλη ROC σε έναν αριθμό. Η τιμή:

- $AUC = 1.0$ σημαίνει τέλεια ταξινόμηση.
- $AUC = 0.5$ ισοδυναμεί με τυχαία πρόβλεψη.
- $AUC < 0.5$ υποδηλώνει ότι το μοντέλο λειτουργεί χειρότερα από το τυχαίο.

Καμπύλη Precision–Recall (PR) Η καμπύλη PR απεικονίζει την Ακρίβεια (Precision) ως συνάρτηση της Ανάκλησης (Recall). Είναι ιδιαίτερα χρήσιμη σε προβλήματα με σοβαρή ανισοκατανομή κατηγοριών (π.χ. ανίχνευση σπανίων παθολογικών γεγονότων όπως τα wheezes), όπου η καμπύλη ROC μπορεί να δώσει υπερεκτιμημένα αποτελέσματα.

Η μορφή της καμπύλης PR είναι συνήθως πιο «αυστηρή» από την ROC και η μείωση της ακρίβειας καθώς αυξάνεται η ανάκληση αποκαλύπτει την «τίμημα» της ανίχνευσης περισσότερων θετικών δειγμάτων.

Εμβαδόν υπό την καμπύλη PR (Average Precision – AP) Το μέσο εμβαδόν κάτω από την PR καμπύλη ορίζεται ως:

$$AP = \sum_n (R_n - R_{n-1}) \cdot P_n \quad (4.38)$$

όπου P_n και R_n είναι η ακρίβεια και η ανάκληση στο κατώφλι n . Η μετρική αυτή συνοψίζει την PR καμπύλη σε έναν αριθμό, παρόμοια με την AUC της ROC.

Κεφάλαιο 5

Acoustic Domain Adaptation

5.1 Εισαγωγή στο domain shift

Στη μηχανική μάθηση, τα περισσότερα μοντέλα εκπαιδεύονται υπό την παραδοχή ότι τα δεδομένα εκπαίδευσης και δοκιμής αντλούνται από την ίδια κατανομή πιθανότητας $P(X, Y)$. Ωστόσο, σε πραγματικές συνθήκες, ειδικά σε τομείς όπως η βιοϊατρική, η ομιλία και το περιβάλλον, η παραδοχή αυτή συχνά καταρρέει. Το φαινόμενο αυτό περιγράφεται ως **μετατόπιση τομέα** (domain shift) και οδηγεί σε σημαντική υποβάθμιση της απόδοσης των μοντέλων όταν εφαρμόζονται σε νέα, ετερογενή δεδομένα.

Η ύπαρξη domain shift καθιστά συνεπώς και πολλά συμβατικά μοντέλα ανίχνευσης αναπνευστικών παθήσεων επιρρεπή σε σφάλματα, καθώς τείνουν να υπερπροσαρμόζονται στα στατιστικά χαρακτηριστικά του source domain στο οποίο εκπαιδεύτηκαν. Για παράδειγμα, ένα μοντέλο που έχει εκπαιδευτεί σε καθαρά ακουστικά δεδομένα μόνο σε γηραιότερο πληθυσμό και από μια συγκεκριμένη συσκευή μπορεί να αποδώσει φτωχά όταν εφαρμοστεί σε δεδομένα με θόρυβο περιβάλλοντος που προέρχονται από νεότερες πληθυσμιακές ομάδες με διαφορετική συσκευή καταγραφής.

Στη συνέχεια παρουσιάζονται οι βασικές έννοιες του κλάδου της **προσαρμογής τομέα** (domain adaptation) όπως ορίζονται από την τρέχουσα βιβλιογραφία:

Τομέας (Domain) Ορίζεται ως το ζεύγος $\mathcal{D} = \{\mathcal{X}, P(X)\}$, όπου $\mathcal{X}$ είναι ο χώρος χαρακτηριστικών και $P(X)$ είναι μια κατανομή πιθανότητας πάνω σε αυτόν. Κάθε σύνολο δεδομένων που προέρχεται από συγκεκριμένο περιβάλλον, συσκευή ή πληθυσμό μπορεί να θεωρηθεί ως τομέας. Για παράδειγμα, ο ήχος αναπνευστικών σημάτων που καταγράφηκε με διαφορετικά μικρόφωνα ή από διαφορετικούς πληθυσμούς, ανήκει σε διαφορετικούς τομείς.

Source and Target Domain Το source domain $\mathcal{D}_S = \{\mathcal{X}_S, P_S(X)\}$ περιλαμβάνει το διαθέσιμο σύνολο εκπαίδευσης (συχνά επισημασμένο με labels), ενώ το target domain $\mathcal{D}_T = \{\mathcal{X}_T, P_T(X)\}$ αφορά το περιβάλλον στο οποίο επιθυμούμε να εφαρμόσουμε το μοντέλο. Τυπικά, ισχύει ότι $\mathcal{X}_S = \mathcal{X}_T$, αλλά $P_S(X) \neq P_T(X)$, δηλαδή υπάρχει διαφορά στην κατανομή των χαρακτηριστικών μεταξύ των δύο περιοχών.

Μετατόπιση Τομέα (Domain Shift) Ορίζεται ως η απόκλιση μεταξύ της κατανομής των δεδομένων ή των ετικετών μεταξύ των source και target domains. Ορίζονται τρεις βασικοί τύποι μετατόπισης (Farahani et al. 2021):

- **Label ή prior shift:** Η περίπτωση κατά την οποία η κατανομή των ετικετών (**prior distribution**) διαφέρει μεταξύ των domains, ενώ οι υπό συνθήκη κατανομές (**posterior distributions**) παραμένουν ίδιες.

$$P_S(Y) \neq P_T(Y), \quad \text{αλλά} \quad P_S(Y | X) = P_T(Y | X)$$

Αυτό σημαίνει ότι το είδος των κατηγοριών και ο τρόπος που σχετίζονται με τα χαρακτηριστικά παραμένει ο ίδιος, αλλά αλλάζει η συχνότητα εμφάνισής τους.

- **Covariate shift:** Η πιο κοινή μορφή domain shift στην οποία οι a priori κατανομές των χαρακτηριστικών εισόδου $P(X)$ διαφέρουν μεταξύ των τομέων, αλλά ο μηχανισμός απόδοσης ετικετών παραμένει ίδιος. Δηλαδή:


$$P_S(X) \neq P_T(X), \quad \text{αλλά} \quad P_S(Y | X) = P_T(Y | X)$$

Αυτό μπορεί να οφείλεται σε διαφορετικές μεθόδους δειγματοληψίας, σε διαφορετικό περιβάλλον ή εξοπλισμό καταγραφής.

- **Concept shift:** Η περίπτωση κατά την οποία αλλάζει ο μηχανισμός που συσχετίζει τα χαρακτηριστικά με τις ετικέτες, δηλαδή αλλάζει η a posteriori κατανομή $P(Y | X)$, παρόλο που η κατανομή των εισόδων παραμένει η ίδια:

$$P_S(X) = P_T(X), \quad \text{αλλά} \quad P_S(Y | X) \neq P_T(Y | X)$$

Αυτό συνεπάγεται ότι το ίδιο δεδομένο μπορεί να ανήκει σε διαφορετική κατηγορία ανάλογα με τον τομέα. Είναι από τα πιο δύσκολα σενάρια και απαιτεί την ύπαρξη ετικετών και στους δύο τομείς για να αντιμετωπιστεί.



Σχήμα 5.1: Είδη μετατόπισης τομέα.

Στο πλαίσιο της συγκεκριμένης εργασίας για την αναγνώριση παθολογικών μοτίβων σε αναπνευστικούς ήχους, οι λόγοι εμφάνισης domain shift είναι ποικίλοι. Η μετατόπιση κατά

κύρια βάση προέρχεται λόγω των **διαφορετικών συσκευών καταγραφής** όπως μικρόφωνα, στηθοσκόπια κ.τ.λ. Ένας άλλος παράγοντας είναι η **αλλαγή πληθυσμιακής κατανομής** από την οποία προκύπτει το σύνολο δεδομένων, δηλαδή η ηλικία, το φύλο ή η γεωγραφική προέλευση των ασθενών. Τέλος, σημαντικό ρόλο διαδραματίζουν και οι **διαφορετικές συνθήκες ηχογράφησης**, δηλαδή η παρουσία θορύβου στο χώρο καταγραφής, ο τρόπος αναπνοής του ασθενούς, καθώς και η στάση σώματός του. Με βάση αυτά, θα λέγαμε ότι στη συγκεκριμένη περίπτωση άρα καλούμαστε να αντιμετωπίσουμε το φαινόμενο του *covariate shift*, καθώς η κατανομή των χαρακτηριστικών $P(X)$ διαφοροποιείται μεταξύ των πηγών λόγω των παραγόντων που αναφέραμε, ενώ παράλληλα η συνάρτηση στόχου $P(Y | X)$ παραμένει αμετάβλητη.

Για την αντιμετώπιση του προβλήματος αυτού, αναπτύχθηκε ο κλάδος της **προσαρμογής τομέα ή domain adaptation**, ο οποίος είναι ένα υποπεδίο της μεταφοράς μάθησης (transfer learning), με στόχο τη μεταφορά γνώσης από ένα τομέα πηγής σε ένα διαφορετικό αλλά σχετικό τομέα στόχο, μεγιστοποιώντας την απόδοση χωρίς επανεκπαίδευση του μοντέλου από το μηδέν.

5.2 Ανάγκη για acoustic domain adaptation


Ιδιαίτερο ενδιαφέρον παρουσιάζει η περίπτωση της **προσαρμογής σε ακουστικούς τομείς** (acoustic domain adaptation), καθώς τα ακουστικά και πόσο μάλλον τα αναπνευστικά σήματα παρουσιάζουν υψηλό βαθμό ευαισθησίας σε εξωτερικές παραμέτρους όπως η ποιότητα καταγραφής, το περιβάλλον ηχογράφησης, ο τύπος μικροφώνου ή αισθητήρα, αλλά και τα χαρακτηριστικά του ίδιου του ατόμου (φύλο, ηλικία, φυσιολογία). Η παραμικρή διαφοροποίηση σε αυτούς τους παράγοντες ενδέχεται να επηρεάσει σημαντικά την κατανομή των εξαγόμενων χαρακτηριστικών, οδηγώντας σε φαινόμενα μετατόπισης τομέα (domain shift).

Πιο συγκεκριμένα, τα ακουστικά δεδομένα είναι υψηλής διαστατικότητας και χρονικά εξαρτώμενα, με εγγενή ευαισθησία σε τυχαίες διακυμάνσεις θορύβου και αλλοιώσεις κατά τη διαδικασία καταγραφής. Στην περίπτωση των αναπνευστικών ήχων, η φυσική επαφή του αισθητήρα με το σώμα, η στάση του ασθενούς, το επίπεδο συνεργασίας και η παρουσία περιβαλλοντικού θορύβου αποτελούν όλους κρίσιμους παράγοντες που αλλοιώνουν τα στατιστικά χαρακτηριστικά του σήματος. Σύμφωνα με τον Wang (2018), σε σύγκριση με εικόνες ή κείμενο, τα ακουστικά δεδομένα εμφανίζουν εντονότερη εξάρτηση σε τομείς και η παραμικρή μεταβολή στις συνθήκες εισόδου μπορεί να επιφέρει σημαντική πτώση στην απόδοση ταξινόμησης αν δεν αντιμετωπιστεί κατάλληλα.

Κατά την ανάλυση των δεδομένων της παρούσας διπλωματικής, εντοπίστηκαν σαφείς διαφορές στα ακουστικά χαρακτηριστικά που εξάγονται από διαφορετικές πηγές καταγραφής, γι' αυτό και θα ασχοληθούμε αποκλειστικά με την αφαίρεση της μεροληψίας των συσκευών καταγραφής από τα δεδομένα μας. Παρά το γεγονός ότι η έννοια της «παθολογίας» παραμένει αμετάβλητη εννοιολογικά, το μοντέλο ταξινόμησης φάνηκε δυσκολεύεται να αναγνωρίσει τα ίδια πρότυπα σε δεδομένα από διαφορετικές συσκευές.

Για την διερεύνηση της ύπαρξης μετατόπισης τομέα μπορούμε αρχικά να ασχοληθούμε με


τις συσκευές καταγραφής αυτές κάθε αυτές και το τρόπο συμπεριφοράς τους, παρατηρώντας την απόκριση συχνότητάς τους που προκύπτει από τα .wav αρχεία που έχει καταγράψει η καθεμία.



Σχήμα 5.2: Απεικόνιση της μέσης απόκρισης συχνότητας των διαφορετικών συσκευών καταγραφής.

Η ανάλυση της μέσης απόκρισης συχνότητας για κάθε συσκευή καταγραφής αποκαλύπτει σαφείς διαφορές στο φασματικό προφίλ μεταξύ των συσκευών. Συγκεκριμένα, η συσκευή AKGC417L παρουσιάζει υψηλότερες τιμές ισχύος σε όλο το φάσμα, ιδίως κάτω από τα 1000 Hz, υποδηλώνοντας μεγαλύτερη ευαισθησία στην καταγραφή χαμηλών συχνοτήτων. Αντίθετα, οι συσκευές LittC2SE, Litt3200 και Meditron εμφανίζουν πιο απότομη εξασθένιση στις ίδιες περιοχές, με διακυμάνσεις ανάμεσα τους γύρω στα 400–800 Hz. Η ασυμφωνία αυτή τεκμηριώνει περαιτέρω την ύπαρξη **χάσματος μεταξύ των domains**, καθώς η φασματική πληροφορία αποτελεί θεμελιώδες συστατικό των χαρακτηριστικών εισόδου.


Στη συνέχεια, διερευνούμε τα ίδια τα ακουστικά χαρακτηριστικά που έχουμε εξάγει από τα .wav αρχεία. Μια γρήγορη τεχνική για να εκτιμήσουμε αρχικά το πόσο ξεκάθαρη είναι η συμπεριφορά κάθε συσκευής στα χαρακτηριστικά μας είναι να εκπαιδεύσουμε ένα απλό στατιστικό μοντέλο ώστε να προβλέπει από ποιά συσκευή προέρχεται κάθε διάνυμα χαρακτηριστικών. Όσο μεγαλύτερη είναι η ακρίβεια, τόσο πιο έντονη είναι η επίδραση του domain shift, καθώς το μοντέλο μπορεί εύκολα να διακρίνει τις διαφορετικές συσκευές. Όσο πιο κοντά στη τυχαία πρόβλεψη συγκλίνει το μοντέλο, δηλαδή 25 % εφόσον έχουμε τέσσερις συσκευές, τόσο πιο αποτελεσματική θα είναι και η επίδραση του domain adaptation αφού το μοντέλο θα δυσκολεύεται αρκετά να διαχωρίσει τις συσκευές μεταξύ τους.



Σχήμα 5.3: Μητρώο σύγχυσης για το μοντέλο ταξινόμησης συσκευών.

Από το μητρώο σύγχυσης καθώς και από το γεγονός ότι η μέση ακρίβεια του μοντέλου είναι 0.8043 ± 0.0176 μπορούμε για ακόμη μια φορά να συμπεράνουμε ότι οι συσκευές έχουν **σημαντική διαφοροποίηση** μεταξύ τους, η οποία είναι εύκολο να εντοπιστεί από οποιοδήποτε απλό στατιστικό μοντέλο.


Η μετατόπιση τομέα με βάση τη συσκευή επιβεβαιώνεται κιόλας οπτικά αν σχεδιάσουμε στις 2 διαστάσεις πάλι τα εξαγμένα ακουστικά χαρακτηριστικά αλλά ως προς τις διαφορετικές συσκευές τώρα αντί για τις διαφορετικές κλάσεις.



Σχήμα 5.4: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής.


Για την ακρίβεια, παρατηρείται ότι τα δείγματα που προέρχονται από τις τέσσερις διαφορετικές συσκευές σχηματίζουν διακριτά και εν μέρει απομονωμένα υποσύνολα στον χώρο των δύο πρώτων κύριων συνιστωσών. Η διακριτότητα αυτή κατά κύρια βάση προερχόμενη από τις συσκευές Litt3200 και AKGC417L μαρτυρά την ύπαρξη σαφών στατιστικών διαφορών μεταξύ των πηγών, γεγονός που συνιστά ένδειξη ύπαρξης **μετατόπισης τομέα** (domain shift).

Ακόμη, μπορούμε να οπτικοποιήσουμε όπως πριν τα KDE plots και τα boxplots των εξαγμένων χαρακτηριστικών ως προς τις συσκευές για να δούμε και στη πράξη πως διαφέρουν οι κατανομές κάθε τομέα που προκύπτει από τις συσκευές καταγραφής.



Σχήμα 5.5: KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά συσκευή καταγραφής.

Βλέπουμε ότι όντως οι καμπύλες KDE παρουσιάζουν σημαντικές **μετατοπίσεις** και **διαφορές στη μορφή της κατανομής** για το ίδιο χαρακτηριστικό μεταξύ συσκευών. Πολλά χαρακτηριστικά εμφανίζουν **ποικίλες κατανομές** με διαφορετικές κορυφές για κάθε συσκευή, γεγονός που μαρτυρά την επίδραση της συσκευής στην κατανομή των δεδομένων.



Σχήμα 5.6: Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά συσκευή καταγραφής.

Και από τα boxplots παρατηρούνται μεταβολές στη **διάμεσο** και στο **εύρος διακύμανσης** των τιμών για πολλά χαρακτηριστικά, ανάμεσα στις διαφορετικές συσκευές καταγραφής. Η παρουσία outliers και η ασυμμετρία στην κατανομή των τιμών εντείνει την παραβίαση της

υπόθεσης ισόνομης στατιστικής συμπεριφοράς των δεδομένων. Αυτές οι διαφορές αποτελούν ακράδαντες ενδείξεις για μεταβολή της a priori κατανομής $P(X)$, δηλαδή **covariate shift**.

Όπως επισημαίνεται στη βιβλιογραφία, η κατάλληλη προσαρμογή μπορεί να γίνει είτε μέσω αναπαράστασης χαρακτηριστικών σε κοινό χώρο (feature alignment), είτε μέσω μετασχηματισμού και ανακατασκευής των κατανομών ή ακόμη και με την ενίσχυση της ανθεκτικότητας του μοντέλου στο domain shift με τεχνικές βαθιάς μάθησης, τις οποίες θα εφαρμόσουμε και εμείς. Οι προσεγγίσεις αυτές παρουσιάζονται αναλυτικά στις επόμενες ενότητες.

5.3 Επιβλεπόμενο και Μη επιβλεπόμενο acoustic domain adaptation

Αρχικά, το πρόβλημα της προσαρμογής τομέα (domain adaptation) μπορεί να διαχωριστεί ανάλογα με τη διαθεσιμότητα των ετικετών των δεδομένων (labels) στο target domain σε δύο θεμελιώδεις κατηγορίες, οι οποίες περιγράφονται παρακάτω (Farahani et al. 2021):

Επιβλεπόμενο Domain Adaptation (Supervised DA) Στο σενάριο της **επιβλεπόμενης προσαρμογής** υποθέτουμε ότι τόσο το source domain όσο και το target domain διαθέτουν δεδομένα με labels, δηλαδή τις αντίστοιχες αναπνευστικές παθήσεις. Αυτό σημαίνει ότι μπορούμε να μάθουμε από κοινού το μοντέλο με πλήρη εποπτεία και από τα δύο περιβάλλοντα. Το κύριο πλεονέκτημα της επιβλεπόμενης προσαρμογής είναι η δυνατότητα πιο ακριβούς εκτίμησης της κατανομής $P_T(Y | X)$.

Μη επιβλεπόμενο Domain Adaptation (Unsupervised DA) Η **μη επιβλεπόμενη προσαρμογή** είναι το πιο κοινό αλλά και πιο δύσκολο σενάριο προσαρμογής τομέα. Υποθέτει ότι τα δεδομένα στο target domain είναι μη επισημασμένα, δηλαδή διαθέτουμε μόνο τα X_T χωρίς τις αντίστοιχες ετικέτες Y_T . Το μόνο επισημασμένο σύνολο είναι αυτό του source domain, δηλαδή (X_S, Y_S) . Η πρόκληση σε αυτήν την περίπτωση έγκειται στο γεγονός ότι πρέπει να μάθουμε μια συνάρτηση πρόβλεψης $f : X \rightarrow Y$ η οποία θα αποδίδει καλά στο target domain χωρίς να γνωρίζουμε τις ετικέτες του.

5.4 Βασικές κατηγορίες acoustic domain adaptation

Στη συνέχεια, με βάση όλα τα παραπάνω έχουν οριστεί τέσσερις βασικές κατηγορίες προσαρμογής τομέα (Farahani et al. 2021):

Closed-set Domain Adaptation Πρόκειται για το πιο κλασικό σενάριο όπου υποτίθεται ότι το **σύνολο ετικετών είναι το ίδιο** στο source και στο target domain, δηλαδή:

$$\mathcal{Y}_S = \mathcal{Y}_T$$

Ωστόσο, οι κατανομές πιθανότητας ενδέχεται να διαφέρουν:

$$P_S(X, Y) \neq P_T(X, Y)$$

Επομένως, παρότι το σύνολο των κατηγοριών είναι κοινό, υπάρχει απόκλιση στις στατιστικές ιδιότητες των δεδομένων, δημιουργώντας ανάγκη για μεταφορά γνώσης. Οι περισσότερες υπάρχουσες μέθοδοι προσαρμογής εμπίπτουν σε αυτή την κατηγορία.

Partial Domain Adaptation Στην περίπτωση αυτή, το **σύνολο ετικετών του target domain είναι υποσύνολο του source domain**:

$$\mathcal{Y}_T \subset \mathcal{Y}_S$$

Το source domain θεωρείται γενικό και περιέχει πολλές κατηγορίες, ενώ το target domain επικεντρώνεται μόνο σε ένα υποσύνολο. Αν εφαρμοστούν παραδοσιακές μέθοδοι ευθυγράμμισης ολόκληρων κατανομών, μπορεί να προκύψει το φαινόμενο της **αρνητικής μεταφοράς** (negative transfer), καθώς μεταφέρεται γνώση από κατηγορίες του source που δεν υπάρχουν στο target. Ειδικές τεχνικές έχουν προταθεί ώστε να αγνοείται η πληροφορία που δεν είναι σχετική με τις target classes.

Open Set Domain Adaptation Σε αυτό το σενάριο, **τα σύνολα ετικετών μεταξύ source και target domains επικαλύπτονται εν μέρει**, δηλαδή:

$$\mathcal{Y}_S \cap \mathcal{Y}_T \neq \emptyset, \quad \mathcal{Y}_S \not\subset \mathcal{Y}_T, \quad \mathcal{Y}_T \not\subset \mathcal{Y}_S$$

Υπάρχουν δηλαδή κοινές κατηγορίες, αλλά και ιδιωτικές για κάθε domain. Η πρόκληση είναι ο ακριβής εντοπισμός των κοινών κατηγοριών και η αποφυγή αρνητικής μεταφοράς από τις αποκλειστικές κλάσεις του source domain. Στην πράξη, μοντέλα προσαρμόζονται ώστε να προβλέπουν σωστά τις κοινές ετικέτες και να απορρίπτουν ως «άγνωστα» τα δείγματα από μη κοινές κατηγορίες.

Universal Domain Adaptation Είναι η γενικευμένη προσέγγιση της προσαρμογής τομέα, όπου **δεν απαιτείται εκ των προτέρων γνώση** για τη σχέση μεταξύ των συνόλων ετικετών:

$\mathcal{Y}_S$ και $\mathcal{Y}_T$ μπορεί να είναι οποιαδήποτε υποσύνολα του ενιαίου καθολικού συνόλου ετικετών.

Η προσέγγιση αυτή προσπαθεί πρώτα να αναγνωρίσει το κοινό υποσύνολο ετικετών και στη συνέχεια να προσαρμόσει κατάλληλα τις κατανομές στο κοινό αυτό υποσύνολο. Θεωρείται η πιο ρεαλιστική αλλά και η πιο απαιτητική προσέγγιση.

5.5 Βασικές προσεγγίσεις acoustic domain adaptation

Στη βιβλιογραφία (Farahani et al. 2021) οι βασικές προσεγγίσεις για υλοποίηση του domain adaptation μπορούν να κατηγοριοποιηθούν ως εξής:

Instance-Based Domain Adaptation Οι instance-based τεχνικές επιχειρούν να αντιμετωπίσουν το domain shift μέσω **ανακατανομής βαρών** στα δείγματα εκπαίδευσης του source domain, έτσι ώστε η βεβαρυμένη κατανομή τους να προσεγγίζει καλύτερα την κατανομή του target domain. Με αυτόν τον τρόπο, το μοντέλο εκπαιδεύεται σε δεδομένα που αν και προέρχονται από το source «μοιάζουν» στατιστικά με αυτά του target. Η θεμελιώδης υπόθεση είναι αυτή του covariate shift όπως αναφέραμε και παραπάνω:

$$P_S(y|x) = P_T(y|x), \quad P_S(x) \neq P_T(x),$$

δηλαδή η συνάρτηση απόφασης (σχέση μεταξύ χαρακτηριστικών x και ετικέτας y) παραμένει η ίδια στους δύο τομείς, αλλά η κατανομή των ίδιων των χαρακτηριστικών διαφέρει.

Ο **κίνδυνος** (risk) $R_T(h)$ στο target domain ορίζεται ως η αναμενόμενη τιμή της συνάρτησης κόστους $\ell(h(x), y)$ όταν τα δείγματα προέρχονται από την κατανομή $P_T(x, y)$. Ο ταξινομητής $h(\cdot)$ είναι η συνάρτηση που προβλέπει την κλάση y με βάση τα χαρακτηριστικά x . Υπό την παραδοχή ύπαρξης covariate shift, ο κίνδυνος στο target μπορεί να εκφραστεί ως αναμενόμενη τιμή πάνω στην κατανομή του source:

$$R_T(h) = \mathbb{E}_{(x,y) \sim P_S} \left[\frac{P_T(x)}{P_S(x)} \ell(h(x), y) \right]$$

όπου ο λόγος

$$w(x) = \frac{P_T(x)}{P_S(x)}$$

αποτελεί το **importance weight** κάθε δείγματος. Δείγματα του source που μοιάζουν περισσότερο με αυτά του target λαμβάνουν μεγαλύτερο βάρος, ενώ όσα διαφέρουν σημαντικά λαμβάνουν μικρότερο. Στο ακουστικό πεδίο, τα βάρη αυτά μπορούν να εκτιμηθούν χρησιμοποιώντας αλγόριθμους όπως το Kernel Mean Matching (KMM) ή το KL Importance Estimation Procedure (KLIEP).

Feature-Based Domain Adaptation Οι feature-based μέθοδοι στοχεύουν στην εύρεση ενός **κοινού ενδιάμεσου χώρου αναπαράστασης** στον οποίο οι κατανομές των χαρακτηριστικών του source και του target τομέα είναι όσο το δυνατόν πιο όμοιες. Η βασική ιδέα είναι να εφαρμοστεί ένας μετασχηματισμός

$$\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

πάνω στα αρχικά χαρακτηριστικά $\mathbf{x}$, έτσι ώστε οι νέες αναπαραστάσεις $\mathbf{f} = \Phi(\mathbf{x})$ να ικανοποιούν:

$$P_S(\mathbf{f}) \approx P_T(\mathbf{f}),$$

δηλαδή οι a priori κατανομές τους στον ενδιάμεσο χώρο να ευθυγραμμίζονται. Ο μετασχηματισμός $\Phi(\cdot)$ μπορεί να είναι γραμμικός (π.χ. ανάλυση σε κύριες συνιστώσες) ή μη γραμμικός (π.χ. νευρωνικά δίκτυα). Η ευθυγράμμιση επιτυγχάνεται συνήθως μέσω της ελαχιστοποίησης μιας μετρικής απόστασης μεταξύ των κατανομών source και target στον νέο χώρο. Μερικά παραδείγματα τέτοιων μετρικών είναι:

- **Maximum Mean Discrepancy (MMD)** Μετρά την απόσταση μεταξύ δύο κατανομών P και Q στον χώρο αναπαραστάσεων ενός Reproducing Kernel Hilbert Space (RKHS) $\mathcal{H}_k$:

$$\text{MMD}^2(P, Q) = \|\mathbb{E}_{\mathbf{x} \sim P}[\varphi(\mathbf{x})] - \mathbb{E}_{\mathbf{x} \sim Q}[\varphi(\mathbf{x})]\|_{\mathcal{H}_k}^2.$$

και μπορεί να υπολογιστεί απευθείας στα δείγματα χρησιμοποιώντας συναρτήσεις πυρήνα $k(\cdot, \cdot)$.

- **Correlation Alignment (CORAL)** Στοχεύει στην ευθυγράμμιση των **συνδιακυμάνσεων** των χαρακτηριστικών μεταξύ source και target. Αν C_S και C_T είναι τα αντίστοιχα μητρώα συνδιακύμανσης, τότε η απώλεια CORAL ορίζεται ως:

$$L_{\text{CORAL}} = \frac{1}{4d^2} \|C_S - C_T\|_F^2,$$

όπου $\|\cdot\|_F$ είναι η νόρμα Frobenius και d η διάσταση του χώρου χαρακτηριστικών.

- **Kullback–Leibler Divergence (KL)** Μετρά την πληροφοριακή απόκλιση της κατανομής P_T από την P_S :

$$D_{\text{KL}}(P_T \| P_S) = \sum_{\mathbf{f}} P_T(\mathbf{f}) \log \frac{P_T(\mathbf{f})}{P_S(\mathbf{f})}.$$

Η ελαχιστοποίηση της D_{KL} επιβάλλει στις δύο κατανομές να έχουν παρόμοια σχήματα και πιθανότητες.

Στην ανάλυση ακουστικών σημάτων, η feature-based προσαρμογή μπορεί να εφαρμοστεί τόσο σε χαμηλού επιπέδου ακουστικά χαρακτηριστικά, όσο και σε υψηλού επιπέδου αναπαραστάσεις (embeddings) που εξάγονται από μοντέλα βαθιάς μάθησης.

Deep Domain Adaptation Οι προσεγγίσεις deep domain adaptation ενσωματώνουν την προσαρμογή τομέα στη διαδικασία εκμάθησης υψηλότερων αναπαραστάσεων, αξιοποιώντας την ικανότητα των βαθιών νευρωνικών δικτύων να μαθαίνουν πολύπλοκους, μη γραμμικούς μετασχηματισμούς χαρακτηριστικών. Σε αυτές τις μεθόδους, ο μετασχηματισμός $\Phi_{\theta_f}(\cdot)$ που παράγει τις αναπαραστάσεις $\mathbf{f}$ μαθαίνεται ταυτόχρονα με τον μηχανισμό προσαρμογής, αντί να εφαρμόζεται εκ των υστέρων.

Οι κύριες κατηγορίες αυτής της προσέγγισης είναι:

- **Discrepancy-Based:** Σε αυτήν την κατηγορία, η στοίχιση των κατανομών επιβάλλεται μέσω πρόσθετων όρων κόστους που μετρούν τη διαφορά μεταξύ των κατανομών του source και του target στον ενδιάμεσο χώρο χαρακτηριστικών. Τυπικές μετρικές απόστασης που χρησιμοποιούνται είναι η Maximum Mean Discrepancy (MMD), η CORAL loss και η Central Moment Discrepancy (CMD). Μαθηματικά, η συνολική απώλεια μπορεί να γραφεί ως:

$$L_{\text{total}} = L_y + \lambda D(P_S(\mathbf{f}), P_T(\mathbf{f})),$$

όπου L_y είναι η απώλεια ταξινόμησης, $D(\cdot, \cdot)$ είναι η μετρική απόστασης μεταξύ κατανομών και λ ρυθμίζει τη σχετική της βαρύτητα. Στο ακουστικό πεδίο, αυτές οι μέθοδοι

εφαρμόζονται π.χ. σε embeddings που προέρχονται από CNNs για φασματικά δεδομένα, ώστε να ευθυγραμμιστούν τα στατιστικά τους ανεξαρτήτως μικροφώνου ή θορύβου.

- **Reconstruction-Based** Αυτές οι μέθοδοι χρησιμοποιούν μηχανισμούς ανακατασκευής για να μάθουν κοινές αναπαραστάσεις που είναι ικανές να αναπαράγουν τα δεδομένα και από τους δύο τομείς. Συχνά βασίζονται σε Autoencoders, όπου ο Encoder αναλαμβάνει να εξάγει την κοινή αναπαράσταση $\mathbf{z}$ και ο Decoder να την ανακατασκευάσει σε $\hat{\mathbf{x}}$. Η απώλεια ανακατασκευής είναι:

$$L_{\text{rec}} = \mathbb{E}_{\mathbf{x} \sim P_S} \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \mathbb{E}_{\mathbf{x} \sim P_T} \|\mathbf{x} - \hat{\mathbf{x}}\|^2.$$

Στο ακουστικό πεδίο, αυτό επιβάλλει οι ίδιες λανθάνουσες μεταβλητές να επανασυνθέτουν σωστά ηχογραφήσεις από διαφορετικά μικρόφωνα ή συνθήκες ηχογράφησης.

- **Adversarial-Based** Εμπνευσμένες από τα Generative Adversarial Networks (GANs), οι μέθοδοι αυτής της κατηγορίας εισάγουν έναν **Domain classifier** G_{θ_d} , ο οποίος επιχειρεί να προβλέψει από ποιο domain προέρχεται μια αναπαράσταση $\mathbf{f}$. Ταυτόχρονα, ο **Feature extractor** G_{θ_f} εκπαιδεύεται ανταγωνιστικά ώστε να παράγει domain-invariant αναπαραστάσεις, με στόχο να «μπερδεύει» τον discriminator. Η απώλεια γράφεται συνήθως ως:

$$\min_{\theta_f, \theta_y} L_y - \lambda L_d, \quad \min_{\theta_d} L_d,$$

όπου L_d είναι η απώλεια ταξινόμησης τομέα. Η ανταγωνιστική εκπαίδευση γίνεται συνήθως με ενσωμάτωση ενός **Gradient Reversal Layer (GRL)** στο δίκτυο που αντιστρέφει το πρόσημο του διανύσματος κλίσης στην οπισθοδιάδοση. Σε αυτή τη κατηγορία εμπίπτουν και τα **Domain-Adversarial Neural Networks (DANNs)**, **Conditional DANNs (CDANs)**. Στην ακουστική προσαρμογή, αυτή η στρατηγική επιτρέπει την εκμάθηση χαρακτηριστικών που είναι ταυτόχρονα διακριτικά για τις κλάσεις και ανθεκτικά στις διαφορές συσκευών, θορύβου ή περιβάλλοντος.

5.6 Επιλεγμένες Προσεγγίσεις

Στη δικιά μας περίπτωση, η βάση δεδομένων όπως θα αναλύσουμε και στο Κεφάλαιο 6 περιλαμβάνει καταγραφές αναπνευστικών σημάτων από διαφορετικές συσκευές και πληθυσμιακές ομάδες, συνοδευόμενες από επισημασμένες ετικέτες παθολογίας. Αυτή η διαθεσιμότητα labels τόσο στο source όσο και στο target domain επιτρέπει την αξιοποίηση τεχνικών **επιβλεπόμενης προσαρμογής τομέα** (supervised domain adaptation), οι οποίες οδηγούν σε πιο στοχευμένη και ακριβή γενίκευση σε σχέση με μη επιβλεπόμενες ή ημι-επιβλεπόμενες μεθόδους. Καθώς όμως πρόκειται για περίπτωση **multisource domain adaptation** μπορούμε να γενικεύσουμε την παραπάνω ιδέα θεωρώντας ως source domains τις τρεις από τις τέσσερις συσκευές καταγραφής και ως target domain την τέταρτη εναπομείνασα συσκευή. Σύμφωνα μάλιστα με τη βιβλιογραφία (Wang et al. 2019; Farahani et al. 2021), το supervised domain adaptation είναι κατάλληλο πόσο μάλλον όταν η ακρίβεια και η ευαισθησία

(sensitivity) είναι κρίσιμες, όπως σε βιοϊατρικά σενάρια όπου η παραμικρή υποβάθμιση στην απόδοση μπορεί να οδηγήσει σε λανθασμένες κλινικές αποφάσεις. Συνεπώς, η επιλογή της επιβλεπόμενης προσέγγισης στην παρούσα εργασία βασίζεται στο γεγονός αυτό, καθώς και στο ότι η αναγνώριση παθολογικών προτύπων απαιτεί χώρους αναπαράστασης οι οποίοι είναι class-sensitive όπως θα διαπιστώσουμε και παρακάτω.

Επιπλέον, αποφασίσαμε να εστιάσουμε σε τέσσερις διαφορετικές τεχνικές που καλύπτουν ένα ευρύ φάσμα από φιλοσοφίες προσαρμογής:

Spectrum Correction Ανήκει στην κατηγορία του **Feature-based Domain Adaptation**, καθώς στοχεύει στην ευθυγράμμιση των στατιστικών ιδιοτήτων των φασματικών χαρακτηριστικών μεταξύ των τομέων. Ουσιαστικά, πρόκειται για γραμμικό μετασχηματισμό των αρχικών χαρακτηριστικών ώστε να μειωθεί η απόσταση των κατανομών στον χώρο εισόδου.

Domain-Adversarial Neural Network (DANN) και Conditional DANN (CDAN)

Εντάσσονται και τα δύο στις **Deep Adversarial-based Domain Adaptation** προσεγγίσεις, καθώς ενσωματώνουν έναν Domain classifier που εκπαιδεύεται ανταγωνιστικά με τον Feature extractor μέσω Gradient Reversal Layer.

DANN με Variational Autoencoder (VAE) Συνδυάζει στοιχεία **Deep Reconstruction-based Domain Adaptation** και **Deep Adversarial-based Domain Adaptation**. Ο VAE μαθαίνει μια κανονικοποιημένη λανθάνουσα αναπαράσταση, ενώ το DANN εφαρμόζει πάνω σε αυτήν ανταγωνιστική εκπαίδευση για απομάκρυνση της πληροφορίας τομέα. Η υβριδική αυτή προσέγγιση επιτρέπει ταυτόχρονα σταθερή αναπαράσταση και domain invariance.

Συμπερασματικά, η επιλογή αυτών των τεσσάρων μεθόδων επιτρέπει την πειραματική αξιολόγηση και σύγκριση διαφορετικών στρατηγικών όπως: **προσαρμογή μέσω ευθυγράμμισης χαρακτηριστικών, προσαρμογή μέσω αναταγωνιστικής μάθησης, προσαρμογή υπό συνθήκη μέσω αναταγωνιστικής μάθησης και υβριδική προσαρμογή μέσω ανακατασκευής και αναταγωνιστικής μάθησης.**

5.6.1 Spectrum correction

Η τεχνική της **διόρθωσης φάσματος** (spectrum correction) προτάθηκε αποκλειστικά για την αντιμετώπιση του προβλήματος που προκύπτει όταν τα δεδομένα εκπαίδευσης και δοκιμής έχουν καταγραφεί με διαφορετικές συσκευές, οι οποίες παρουσιάζουν διαφορετικές συχνοτικές αποκρίσεις. Το πρόβλημα αυτό είναι γνωστό και ως device mismatch (Kosmider 2020).

Σε αντίθεση με πολλές τεχνικές προσαρμογής τομέα που εφαρμόζονται **μετά την εξαγωγή χαρακτηριστικών** (π.χ. feature-based adaptation), η διόρθωση φάσματος εφαρμόζεται **άμεσα πάνω στο σήμα ή στο φάσμα του** πριν την εξαγωγή χαρακτηριστικών. Έτσι, η διόρθωση επηρεάζει την πραγματική φασματική αναπαράσταση του σήματος, εξουδετερώνοντας τη συχνοτική παραμόρφωση που εισάγει η συσκευή καταγραφής και διατηρώντας

την πληροφορική ακεραιότητα του σήματος. Αυτό σημαίνει ότι οι μετέπειτα διαδικασίες ταξινόμησης «βλέπουν» ένα σήμα ήδη εναρμονισμένο ως προς την απόκριση συχνότητας, γεγονός το οποίο μειώνει την εξάρτηση του μοντέλου από συγκεκριμένα χαρακτηριστικά συσκευής και περιορίζει το domain shift στην πηγή του. Η διαδικασία της διόρθωσης βασίζεται στους συντελεστές διόρθωσης, των οποίων ο υπολογισμός περιγράφεται εκτενώς παρακάτω:

Έστω ότι το w_s είναι η μη παραμορφωμένη κυματομορφή ενός ηχητικού σήματος s , και $\tilde{w}_{s,d}$ είναι η παραμορφωμένη εκδοχή του όπως καταγράφηκε από μια συσκευή d . Αν $A_s(t, f)$ είναι το πλάτος στη συχνότητα f και χρονική στιγμή t για το σήμα s και $\tilde{A}_{s,d}(t, f)$ η αντίστοιχη ποσότητα για το παραμορφωμένο σήμα, τότε υποθέτουμε ότι η παραμόρφωση που εισάγει η συσκευή d μπορεί να προσεγγιστεί από την απόκριση συχνότητας $H_d(f)$ της συσκευής:

$$\tilde{A}_{s,d}(t, f) \approx H_d(f) A_s(t, f). \quad (5.1)$$

Για να γίνει μετατροπή της ηχογράφησης αυτής από τη συσκευή d έτσι ώστε να μοιάζει με ηχογράφηση από μια άλλη συσκευή αναφοράς r ορίζουμε τους συντελεστές διόρθωσης ως:

$$C_{d \rightarrow r}(f) := \frac{H_r(f)}{H_d(f)}, \quad (5.2)$$

και εφαρμόζουμε:

$$\tilde{A}_{s,r}(t, f) \approx C_{d \rightarrow r}(f) \tilde{A}_{s,d}(t, f). \quad (5.3)$$

Στην πράξη, οι αποκρίσεις συχνότητας $H_d(f)$ δεν είναι γνωστές και οι $C_{d \rightarrow r}(f)$ συνεπώς εκτιμώνται απευθείας από τα δεδομένα χρησιμοποιώντας μέσο όρο (συνήθως γεωμετρικό):

$$C_{d \rightarrow r}(f) \approx \text{mean}_{s,t} \frac{\tilde{A}_{s,r}(t, f)}{\tilde{A}_{s,d}(t, f)}, \quad (5.4)$$

Στην παρούσα εργασία ωστόσο, η διόρθωση φάσματος εφαρμόζεται με τρόπο που αντιστοιχεί στην **μη ευθυγραμμισμένη εκδοχή** (unaligned SC), όπως περιγράφεται από τους **muckenhirn2018spectrum**. Η επιλογή αυτή στηρίζεται στο γεγονός ότι η βάση δεδομένων RSDB δεν περιέχει ευθυγραμμισμένες καταγραφές του ίδιου ηχητικού συμβάντος από διαφορετικές συσκευές. Έτσι, η μέθοδος βασίζεται σε στατιστικές εκτιμήσεις των μέσων φασμάτων, οι οποίες επαρκούν για την εξαγωγή ενός σταθερού συντελεστή διόρθωσης. Πιο συγκεκριμένα, υπολογίζεται για κάθε συσκευή το μέσο λογαριθμικό φάσμα (average log-magnitude spectrum) από όλα τα διαθέσιμα ηχητικά δείγματα.

Αν θεωρήσουμε ως συσκευή αναφοράς (reference device) r και μία συσκευή πηγή (device) d , ο συντελεστής διόρθωσης φάσματος για κάθε συχνότητα f θα ορίζεται πλέον ως:

$$C_{d \rightarrow r}(f) \approx \frac{\text{mean}_{s,t} \tilde{A}_{s,r}(t, f)}{\text{mean}_{s,t} \tilde{A}_{s,d}(t, f)}. \quad (5.5)$$


όπου $\tilde{A}_{s,k}(t, f)$ είναι το λογαριθμικό μέτρο του φάσματος του σήματος s που καταγράφηκε από τη συσκευή k , στη χρονική στιγμή t και συχνότητα f .

Η διαδικασία περιλαμβάνει δύο βήματα. Πρώτα γίνεται ο υπολογισμός του μέσου λογαριθμικού φάσματος για κάθε συσκευή, αθροίζοντας σε όλα τα δείγματα και χρονικά πλαίσια

και έπειτα ακολουθεί ο υπολογισμός του λόγου του μέσου φάσματος της συσκευής αναφοράς προς αυτό της συσκευής πηγής. Με άλλα λόγια, βλέπουμε ότι οι τελικοί συντελεστές διόρθωσης που θα χρησιμοποιήσουμε ποσοτικοποιούν για κάθε frequency bin f το πόσο πρέπει να ενισχυθεί ή να εξασθενήσει το φάσμα της συσκευής πηγής ώστε να προσεγγίσει το φασματικό αποτύπωμα της συσκευής αναφοράς.

Στη δικιά μας υλοποίηση στόχος είναι να διορθώσουμε το φάσμα των τριών συσκευών καταγραφής ως προς αυτό της τέταρτης, έτσι ώστε να δημιουργείται η ψευδαίσθηση ότι έχουν καταγραφεί όλες οι εγγραφές από την ίδια συσκευή αναφοράς. Γί αυτό το λόγο επιλέχθηκε η συσκευή **Meditron** ως **συσκευή αναφοράς**, καθώς παρουσιάζει ορισμένα χαρακτηριστικά που την καθιστούν κατάλληλη για τον ρόλο αυτό. Πρώτον, πρόκειται για ψηφιακό ηλεκτρονικό στηθοσκόπιο υψηλής ευαισθησίας και χαμηλά επίπεδα θορύβου, το οποίο εξασφαλίζει υψηλή ποιότητα σήματος. Επιπλέον, διαθέτει ενσωματωμένο σύστημα καταγραφής και σταθερά χαρακτηριστικά απόκρισης συχνότητας, γεγονός που μειώνει την διακύμανση εντός της και επιτρέπει αξιόπιστη σύγκριση με ηχογραφήσεις από άλλες συσκευές.

Πιο κάτω βλέπουμε τους συντελεστές διόρθωσης που υπολογίστηκαν με το τρόπο που αναλύσαμε:



Σχήμα 5.7: Απεικόνιση των συντελεστών διόρθωσης ως προς τη συσκευή Meditron.

Αρχικά, το μέγεθος καθενός από τα τρία διανύσματα συντελεστών διόρθωσης είναι **(121,)**. Αυτό προκύπτει από το γεγονός ότι κάθε frame έχει διάρκεια 60 ms και με ρυθμό δειγματοληψίας 4 kHz το πλήθος δειγμάτων εντός του είναι:

$$60 \text{ ms} \times 4 \text{ kHz} = 240 \text{ samples}$$


Στο Short-Time Fourier Transform (STFT) ο αριθμός των frequency bins αντιστοιχεί σε $\lfloor \frac{N}{2} \rfloor + 1$, όπου N είναι το μέγεθος του FFT, δηλαδή το πλήθος δειγμάτων που υπολογίσαμε. Άρα στην προκειμένη περίπτωση θα έχουμε:

$$\lfloor \frac{240}{2} \rfloor + 1 = 121 \text{ frequency bins}$$


Επίσης, παρατηρείται ότι οι συσκευές **LittC2SE** και **Litt3200** εμφανίζουν σημαντικές αποκλίσεις από τη συσκευή αναφοράς **Meditron** κυρίως στα **μεσαία** ($40 \leq \text{bins} \leq 100$) και **υψηλά συχνοτικά διαστήματα** ($\text{bins} > 100$). Άρα, βλέπουμε ότι σε εύρος συχνοτήτων από περίπου 600-2000 Hz οι δύο αυτές συσκευές διαφέρουν φασματικά αρκετά και άρα ως προς τον τρόπο που καταγράφουν τους φυσιολογικούς ή παθολογικούς ήχους. Η **AKGC417L** από την άλλη δεν παρουσιάζει κάποιο ενδιαφέρον, καθώς εμφανίζει **πολύ μικρές αποκλίσεις** στο μεγαλύτερο μέρος του φάσματος, εκτός από μια έντονη κορυφή στα πολύ υψηλά bins ($\approx 115-121$), δηλαδή στις συχνότητες από 1900-2000 Hz οι οποίες δεν αποτυπώνουν κάποια σημαντική παθολογική πληροφορία.

Μετά τον υπολογισμό των διανυσμάτων διόρθωσης έπεται ο πολλαπλασιασμός των τιμών των frequency bins του φάσματος των εγγραφών κάθε μιας από τις τρεις συσκευές πηγές με τις αντίστοιχες τιμές των frequency bins στα διανύσματα διόρθωσής τους. Έτσι, προκύπτει για κάθε εγγραφή το τελικό διορθωμένο φάσμα, το οποίο στη συνέχεια μέσω Αντίστροφου STFT μετασχηματίζεται στο τελικό διορθωμένο αναπνευστικό ήχο από τον οποίο θα εξαχθούν τα νέα ακουστικά χαρακτηριστικά.


Παρακάτω ακολουθούν ορισμένα παραδείγματα που δείχνουν την επίδραση της μη ευθυγραμμισμένης φασματικής διόρθωσης:



Σχήμα 5.8: 1ο παράδειγμα φασματικής διόρθωσης.




Σχήμα 5.9: 2ο παράδειγμα φασματικής διόρθωσης.



Σχήμα 5.10: 3ο παράδειγμα φασματικής διόρθωσης.


Για την μελέτη της επίδρασης της διόρθωσης φάσματος ανατρέχουμε πάλι στις προαναφερθείσες τεχνικές, όπως η οπτικοποίηση των νέων χαρακτηριστικών ως προς τις συσκευές μέσω PCA, η οπτικοποίηση των KDE plots και boxplots τους, καθώς και η χρήση στατιστικού μοντέλου για τη ταξινόμηση των domains.



Σχήμα 5.11: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά τη διόρθωση φάσματος.

Είναι εμφανές ότι μετά την εφαρμογή της μεθόδου Spectrum Correction τα δεδομένα από τις τέσσερις συσκευές παρουσιάζουν σημαντική επικάλυψη στον διδιάστατο χώρο. Η απουσία ξεκάθαρων, διακριτών ομάδων ανά συσκευή υποδηλώνει ότι οι φασματικές διαφορές που σχετίζονταν με το domain shift έχουν μειωθεί ουσιαστικά, καθιστώντας το σύνολο δεδομένων πιο ομοιογενές ως προς τα φασματικά χαρακτηριστικά. Αυτό επιβεβαιώνει την αποτελεσματικότητα της διόρθωσης φάσματος όσον αφορά την άμβλυνση των συσκευοεξαρτώμενων διαφορών.

Όμοια και από τα boxplots βλέπουμε ότι οι κεντρικές τάσεις (διάμεσοι) των κατανομών χαρακτηριστικών για τις τέσσερις συσκευές συγκλίνουν σημαντικά, δείχνοντας ότι η μέθοδος εξισορροπεί τις μέσες τιμές των χαρακτηριστικών. Η μείωση της διασποράς (εύρος interquartile range) σε αρκετές διαστάσεις υποδεικνύει ότι η φασματική διόρθωση περιορίζει τη μεταβλητότητα μεταξύ συσκευών, ενισχύοντας την ομοιογένεια των δεδομένων. Τέλος, παρατηρείται μικρότερη απόκλιση στα άκρα (whiskers) και λιγότερη διαφοροποίηση στον αριθμό και στη θέση των outliers μεταξύ των συσκευών, γεγονός που σημαίνει ότι ακραίες τιμές ευθυγραμμίζονται καλύτερα.



Σχήμα 5.14: Μητρώο σύγχυσης για το μοντέλο ταξινόμησης συσκευών μετά τη διόρθωση φάσματος.

Τέλος, βλέπουμε ότι τόσο το μητρώο σύγχυσης όσο και η νέα μέση ακρίβεια 0.3089 ± 0.0277 που επιτεύχθηκε από το στατιστικό μοντέλο επιβεβαιώνουν την επίδραση της μεθόδου όσον αφορά την μείωση της διαχωρισιμότητας των συσκευών. Κάθε συσκευή προβλέπεται με πιθανότητα κοντά στο 25 %, γεγονός το οποίο υποδεικνύει την αδυναμία δημιουργίας ξεκάθαρης πρόβλεψης από ποιά συσκευή προήλθε κάθε δείγμα.


Ωστόσο, παρά το γεγονός ότι η φασματική διόρθωση επιτυγχάνει σημαντική ευθυγράμμιση των κατανομών των χαρακτηριστικών μεταξύ των συσκευών, παρατηρείται ότι η **διαχωρισιμότητα ως προς τις κλάσεις παραμένει περιορισμένη**.

Η εξήγηση έγκειται στο ότι η φασματική διόρθωση είναι μέθοδος που στοχεύει αποκλειστικά στη μείωση της απόστασης μεταξύ των κατανομών $P_S(\mathbf{x})$ και $P_T(\mathbf{x})$ (οριακές κατανομές) χωρίς να λαμβάνει υπόψη την υπό συνθήκη δομή $P(\mathbf{x} | y)$. Έτσι, αν και μειώνεται το domain shift που οφείλεται στη συσκευή, τα χαρακτηριστικά που αντιστοιχούν σε διαφορετικές κλάσεις εξακολουθούν να έχουν παρόμοιες κατανομές και να επικαλύπτονται σε μεγάλο βαθμό. Με άλλα λόγια, η διαδικασία στοχεύει στην **ευθυγράμμιση μεταξύ domains**, αλλά όχι στην **ενίσχυση της διακριτικής ικανότητας μεταξύ κλάσεων**. Αυτό καθιστά ανα-

γκαία την εφαρμογή μεθόδων που εκμεταλλεύονται ρητά την πληροφορία της κλάσης, όπως οι class-conditional τεχνικές τύπου CDAN που θα αναλυθούν παρακάτω, ώστε να επιτυγχάνεται ταυτόχρονα:

$$P_S(\mathbf{x}) \approx P_T(\mathbf{x}) \quad \text{και} \quad P_S(\mathbf{x} | y) \approx P_T(\mathbf{x} | y)$$

ενισχύοντας την διαχωρισιμότητα στο κοινό χώρο αναπαράστασης.



Σχήμα 5.15: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά τη διόρθωση φάσματος.

5.6.2 Domain Adversarial Neural Network (DANN) και παραλλαγές του

Η τεχνική Domain Adversarial Neural Network (DANN) αποτελεί μία εποπτευόμενη προσέγγιση προσαρμογής τομέα (supervised domain adaptation) σχεδιασμένη ώστε να μειώνει το πρόβλημα του domain mismatch μεταξύ source και target domains. Στη δικιά μας περίπτωση, το DANN είναι supervised, καθώς για την εκπαίδευσή του χρησιμοποιούμε τα labels για όλα τα domains, ενώ παράλληλα γίνεται διαχωρισμός και των τεσσάρων domains μεταξύ τους όχι απλώς αν προέρχονται από το source ή το target. Η βασική αρχή του DANN είναι η εκμάθηση μιας αναπαράστασης χαρακτηριστικών σε έναν κοινό υποχώρο που να είναι ταυτόχρονα **διακριτική ως προς την κλάση και αναλλοίωτη ως προς το τομέα**, η οποία επιτυγχάνεται μέσω της **ανταγωνιστικής εκπαίδευσης** (adversarial training). Επιπλέον, η μέθοδος δρα απευθείας στο διάνυσμα χαρακτηριστικών εισόδου, διασφαλίζοντας ότι η απομάκρυνση του domain shift πραγματοποιείται σε επίπεδο αναπαράστασης και όχι απλώς σε επίπεδο τελικής απόφασης (Wang et al. 2019).

Ένα DANN αποτελείται από τρεις βασικές υπομονάδες:

Εξαγωγέας χαρακτηριστικών (Feature extractor) G_{θ_f} Μετασχηματίζει τα αρχικά ακουστικά χαρακτηριστικά $\{\mathbf{x}_i\}_{i=1}^n$ σε έναν F -διάστατο διανυσματικό χώρο $\mathbf{f}$.

Ταξινομητής ετικέτας (Label classifier) G_{θ_y} Χαρτογραφεί το $\mathbf{f}$ σε πιθανότητες κλάσεων $\hat{\mathbf{y}}$ για το πρόβλημα ταξινόμησης των αναπνευστικών ήχων.


Ταξινομητής τομέα (Domain classifier) G_{θ_d} Εκτιμά την πιθανότητα $\hat{\mathbf{d}}$ σε ποιά από τις τέσσερις συσκευές (domains) ανήκει η κάθε εγγραφή.

Για κάθε δείγμα $\{\mathbf{x}_i, \mathbf{y}, \mathbf{d}\}$, με $\mathbf{y}$ να είναι κωδικοποίηση one-hot της κλάσης και $\mathbf{d}$ να είναι κωδικοποίηση one-hot του domain, η εμπρόσθια διάδοση γράφεται ως:

$$\mathbf{f} = G_{\theta_f}(\{\mathbf{x}_i\}) \quad (5.6)$$

$$\hat{\mathbf{y}} = G_{\theta_y}(\mathbf{f}) \quad (5.7)$$

$$\hat{\mathbf{d}} = G_{\theta_d}(\mathbf{f}) \quad (5.8)$$



Σχήμα 5.16: Αρχιτεκτονική ενός DANN.

Ο στόχος της εκπαίδευσης είναι να **ελαχιστοποιήσει τη συνάρτηση κόστους ταξινόμησης αναπνευστικών ήχων** L_y και ταυτόχρονα να **μεγιστοποιήσει τη συνάρτηση κόστους ταξινόμησης τομέα** L_d , ώστε ο εξαγωγέας χαρακτηριστικών να παράγει domain-invariant αναπαραστάσεις:

$$E(\theta_f, \theta_y, \theta_d) = L_y(G_{\theta_y}(G_{\theta_f}(\mathbf{x})), \mathbf{y}) - \lambda L_d(G_{\theta_d}(G_{\theta_f}(\mathbf{x})), \mathbf{d}) \quad (5.9)$$

όπου $\lambda > 0$ είναι υπερπαράμετρος που ρυθμίζει την ισορροπία μεταξύ ταξινόμησης ετικέτας και αναλλοιωσιμότητας τομέα. Η μεγιστοποίηση του L_d υλοποιείται μέσω της προσθήκης ενός **Στρώματος Αντίστροφης Κλίσης** (Gradient Reversal Layer (GRL)), το οποίο κατά την εμπρόσθια διάδοση λειτουργεί ως ταυτοτική συνάρτηση, δηλαδή απλώς διαδίδει αυτούσια την είσοδο, αλλά κατά την οπισθοδιάδοση πολλαπλασιάζει το διάνυσμα κλίσης με $-\lambda$. Έτσι, ο εξαγωγέας χαρακτηριστικών μαθαίνει αναπαραστάσεις που αποπροσανατολίζουν τον ταξινομητή τομέα, οδηγώντας σε εξαγωγή **domain invariant χαρακτηριστικών**.

Μετά την εκπαίδευση, το $G_{\theta_f}(\cdot)$ παράγει χαρακτηριστικά $\mathbf{f}$ που μεγιστοποιούν την ακρίβεια ταξινόμησης αναπνευστικών ήχων, ενώ ελαχιστοποιούν την πληροφορία για το τομέα καταγραφής, βελτιώνοντας έτσι την απόδοση σε συνθήκες mismatched devices.

Στη συγκεκριμένη εργασία χρησιμοποιείται **cross-entropy loss** για το L_y , **mean squared error loss** για το L_d και έπειτα από διερεύνηση αποφασίστηκε η τιμή $\lambda = 0.1$ για το συμβατικό DANN. Επίσης, οι επιλεγμένες αρχιτεκτονικές κάθε module στηρίζονται στη βασική αρχιτεκτονική ενός MLP με κάποιες επιπλέον προσθήκες, ενώ παράλληλα η εισαγωγή των δεδομένων στο δίκτυο γίνεται κάθε φορά σε παρτίδες (batches) μεγέθους 64. Αρχικά, η αρχιτεκτονική για τον Feature Extractor περιλαμβάνει τρεις γραμμικούς μετασχηματισμούς διαστάσεων, δηλαδή **3 Fully Connected Layers**, τα οποία πλαισιώνονται από **Batch Normalization Layers** μαζί με μη γραμμική συνάρτηση ενεργοποίησης **ReLU**, καθώς και **Dropout Layers**. Η προοδευτική αλλαγή διαστάσεων ($\mathbb{R}^n \rightarrow \mathbb{R}^{64} \rightarrow \mathbb{R}^{128} \rightarrow \mathbb{R}^{256}$) μαζί με τη συγκεκριμένη αρχιτεκτονική επιτρέπει στο δίκτυο να μάθει πολύπλοκες μη γραμμικές σχέσεις, ενώ η χρήση κανονικοποίησης στα ενδιάμεσα στάδια επιταχύνει τη σύγκλιση. Τέλος, η τυχαία αποκοπή 30 % των συνολικών νευρώνων κάθε στρώματος είναι μια σημαντική προσθήκη που συμβάλλει στη μείωση της υπερπροσαρμογής.

Layers	Output Shape	Param #
Linear	[64, 64]	2,688
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Dropout	[64, 64]	0
Linear	[64, 128]	8,320
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 256]	33,024
BatchNorm1d	[64, 256]	512
ReLU	[64, 256]	0

Πίνακας 5.2: Αρχιτεκτονική του Feature Extractor στο DANN.

Για τα Label Classifier και Domain Classifier χρησιμοποιείται το ίδιο σκεπτικό αλλά με 1 λιγότερο Fully Connected Layer, καθώς ο Feature Extractor επεξεργάζεται τα αρχικά χαρακτηριστικά και μαθαίνει έναν λανθάνοντα χώρο αναπαράστασης $\phi(x)$ που πρέπει να είναι ταυτόχρονα διακριτικός για την ταξινόμηση ($p(y|f)$) και ανθεκτικός σε πληροφορία τομέα ($p(d|f)$). Για τον σκοπό αυτό απαιτεί μεγαλύτερο βάθος και περισσότερες παραμέτρους, ώστε να απομονώσει και να επανασυνδυάσει τα κατάλληλα μοτίβα των χαρακτηριστικών. Αντίθετα, οι classifiers λαμβάνουν τις ενδιάμεσες αναπαραστάσεις διάστασης 256 και καλούνται να επιλύσουν απλούστερα προβλήματα με μικρό αριθμό εξόδων (π.χ. 3 κλάσεις για ετικέτες, 4 για τομείς), όπου επαρκούν ελαφρύτερα δίκτυα για την αποφυγή υπερπροσαρμογής. Στο Label Classifier το τελικό στρώμα έχει μέγεθος εξόδου ίσο με τον αριθμό κλάσεων, δηλαδή $C = 3$,

ενώ στο Domain Classifier Η αρχιτεκτονική του είναι παρόμοια με εκείνη του Label Classifier ίσο με τον αριθμό των τομέων, δηλαδή $K = 4$.

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 3]	195

Πίνακας 5.3: Αρχιτεκτονική του Label Classifier στο DANN.


Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 4]	260

Πίνακας 5.4: Αρχιτεκτονική του Domain Classifier στο DANN.

Η εκπαίδευση του δικτύου διαρκεί 200 epochs, η βελτιστοποίηση των συναρτήσεων κόστους γίνεται με τη χρήση Adam και χρησιμοποιείται ρυθμός μάθησης ίσος με $\eta = 0.001$. Επίσης, χρησιμοποιήθηκε εκθετικά αυξανόμενη τιμή στο διάστημα $[0, 1]$ για την αρνητική σταθερά α στο GRL σύμφωνα με το τύπο:

$$\alpha_{epoch} = \frac{2}{1 + e^{-10 \cdot \frac{epoch}{200}}} - 1$$

Παρακάτω βλέπουμε τις γραφικές παραστάσεις των συναρτήσεων κόστους L_y και L_d , καθώς και της συνολικής απώλειας:



Σχήμα 5.17: Συναρτήσεις κόστους του DANN.

Βλέπουμε ότι η συνολική απώλεια (Total Loss) παρουσιάζει σταθερή πτωτική τάση και για το train και για το validation set, γεγονός που υποδεικνύει ομαλή σύγκλιση του μοντέλου χωρίς ενδείξεις υπερπροσαρμογής. Η απώλεια ταξινόμησης (Classification Loss) μειώνεται και αυτή προοδευτικά σε όλη τη διάρκεια της εκπαίδευσης υποδεικνύοντας ότι ο Label Classifier βελτιώνει σταδιακά την ικανότητά του να διαχωρίζει τις κλάσεις αναπνευστικών ήχων. Τέλος, η απώλεια τομέα (Domain Loss) στα πρώτα epochs αυξάνεται γρήγορα και στη συνέχεια σταθεροποιείται κοντά στην τιμή 0.25, το οποίο σημαίνει ότι σταδιακά αρχίζει και αποπροσανατολίζεται. Το αποτέλεσμα αυτό είναι αναμενόμενο, καθώς σε πρόβλημα με 4 domains η ιδανική «κατάσταση σύγχυσης» αντιστοιχεί σε ομοιόμορφη κατανομή πιθανοτήτων ($p_i = 0.25$ για κάθε domain). Πιο συγκεκριμένα, εφόσον το σύστημα καλείται να διακρίνει μεταξύ $K = 4$ domains με one-hot ετικέτες $y = (y_1, y_2, y_3, y_4)$ τότε ο Domain Classifier για το σωστό domain j θα έχει κόστος:

$$(y_j - p_j)^2 = (1 - 0.25)^2 = 0.75^2 = 0.5625,$$

και για τα υπόλοιπα τρία:

$$(y_i - p_i)^2 = (0 - 0.25)^2 = 0.25^2 = 0.0625.$$


Άρα το συνολικό κόστος θα πρέπει να συγκλίνει κοντά στο:

$$MSE = \frac{1}{4} (0.5625 + 3 \times 0.0625) = \frac{1}{4} (0.5625 + 0.1875) = \frac{0.75}{4} = 0.1875.$$

Η σύγκλιση της καμπύλης κοντά στο συγκεκριμένο επίπεδο αποτελεί ένδειξη ότι οι εξαγόμενες αναπαραστάσεις έχουν αποπροσανατολιστεί ικανοποιητικά ως προς τον τομέα, ωστόσο υπάρχει κάποιο περιθώριο βελτίωσης εφόσον το 0.25 έχει κάποια μικρή απόκλιση από το 0.1875.


Συνολικά, οι καμπύλες δείχνουν ότι το DANN πέτυχε **επιθυμητή ισορροπία μεταξύ της βελτίωσης της ακρίβειας ταξινόμησης και της μείωσης της πληροφορίας τομέα** στις εξαγόμενες αναπαραστάσεις.

Στη πράξη, ως προς τη συσκευή παρατηρείται σημαντική ανάμειξη δειγμάτων από διαφορετικές συσκευές, παρ' όλα αυτά, μικρές συστάδες με κυριαρχία συγκεκριμένων συσκευών όπως η Litt3200 παραμένουν, υποδεικνύοντας ότι η πλήρης εξάλειψη του domain shift δεν έχει επιτευχθεί.



Σχήμα 5.18: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή DANN.

Επιπλέον, ως προς τις κλάσεις η απεικόνιση δείχνει ότι η διαχωριστικότητα μεταξύ των τριών κλάσεων παραμένει μερικώς περιορισμένη, με σημαντική επικάλυψη ιδιαίτερα μεταξύ των Normal και Crackle.



Σχήμα 5.19: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή DANN.

Συνολικά δηλαδή το DANN επιτυγχάνει εν μέρει τον κύριο στόχο του, δηλαδή την προσαρ-

μογή τομέα μέσω της απομάκρυνσης της πληροφορίας συσκευής, ωστόσο η διχωριστικότητα ως προς τις κλάσεις θα μπορούσε να βελτιωθεί περαιτέρω και αυτή με τεχνικές class-conditional alignment, όπως και το Spectrum Correction.

Αφού ορίστηκε το συμβατικό DANN ακολουθεί η περιγραφή δύο επιπλέον παραλλαγών του οι οποίες δοκιμάστηκαν:

Conditional Domain Adversarial Network (CDAN) Παρά την αποτελεσματικότητα του Domain Adversarial Neural Network (DANN) στην εκμάθηση domain-invariant χαρακτηριστικών, η μεθοδολογία αυτή βασίζεται στην υπόθεση ότι η απλή ευθυγράμμιση των a priori κατανομών των χαρακτηριστικών $P(\mathbf{f})$ μεταξύ source και target επαρκεί για την αντιμετώπιση του domain shift. Ωστόσο, σε πολλές πραγματικές εφαρμογές, οι κατανομές χαρακτηριστικών εμφανίζουν πολύπλοκες **πολυτροπικές δομές** (multimodal structures), καθώς τα δείγματα οργανώνονται σε πολλούς υποχώρους που αντιστοιχούν σε διαφορετικές κλάσεις. Σε τέτοια σενάρια, η απλή ευθυγράμμιση των $P(\mathbf{f})$ μπορεί να προκαλέσει mode mismatch, δηλαδή να ευθυγραμμίσει λάθος υποχώρους διαφορετικών κλάσεων, υποβαθμίζοντας την ακρίβεια ταξινόμησης.


Το Conditional Domain Adversarial Network (CDAN) επεκτείνει το συμβατικό DANN ενσωματώνοντας πληροφορία κλάσης κατά την εκπαίδευση του Domain classifier. Συγκεκριμένα, αντί ο Domain classifier G_{θ_d} να δέχεται ως είσοδο μόνο το διάνυσμα χαρακτηριστικών $\mathbf{f}$, δέχεται έναν **συνδυασμό** των χαρακτηριστικών και του διανύσματος προβλεπόμενων πιθανοτήτων κλάσης $\hat{\mathbf{y}} = G_{\theta_y}(\mathbf{f})$. Ο συνδυασμός αυτός κωδικοποιεί την **από κοινού κατανομή** $(\mathbf{f}, \hat{\mathbf{y}})$.

Με αυτόν τον τρόπο, η διαδικασία ευθυγράμμισης δεν επιχειρεί πλέον να φέρει κοντά μόνο τις a priori κατανομές $P(\mathbf{f})$ των τομέων, αλλά και τις **υπό συνθήκη κατανομές** $P(\mathbf{f} | \mathbf{y})$. Έτσι, οι υποχώροι χαρακτηριστικών που αντιστοιχούν στην ίδια κλάση ευθυγραμμίζονται μεταξύ source και target, ενώ αποφεύγεται η ανάμειξη υποχώρων διαφορετικών κλάσεων. Αυτή η στοχευμένη ευθυγράμμιση (class-conditional alignment) οδηγεί σε πιο διακριτές και σταθερές αναπαραστάσεις, ιδιαίτερα σε εφαρμογές με έντονο domain shift και πολλαπλές κλάσεις.

Η απλούστερη προσέγγιση για την κωδικοποίηση της από κοινού κατανομής θα ήταν η απλή συνένωση (concatenation) $[\mathbf{f} \oplus \hat{\mathbf{y}}]$, όμως αυτή αποτυγχάνει να συλλάβει πολλαπλασιαστικές αλληλεπιδράσεις μεταξύ των δύο μεταβλητών. Για τον λόγο αυτό, το CDAN εισάγει την τεχνική του multilinear conditioning:

$$T_{\otimes}(\mathbf{f}, \hat{\mathbf{y}}) = \mathbf{f} \otimes \hat{\mathbf{y}} \quad (5.10)$$

όπου ο τελεστής $\otimes$ δηλώνει το εξωτερικό γινόμενο, παράγοντας έναν χώρο διάστασης $d_f \times d_{\hat{\mathbf{y}}}$ που κωδικοποιεί την **συσχέτιση** (cross-covariance) μεταξύ χαρακτηριστικών και προβλέψεων κλάσεων. Έτσι, το G_{θ_d} μπορεί να συλλάβει την πολυτροπική δομή της κατανομής, εξασφαλίζοντας διακριτική ευθυγράμμιση.



Σχήμα 5.20: Αρχιτεκτονική ενός CDAN.

Η μέθοδος αυτή έχει αποδειχθεί ότι ξεπερνά την απόδοση προηγούμενων τεχνικών σε πληθώρα συνόλων δεδομένων, συμπεριλαμβανομένων και περιπτώσεων με έντονο domain shift (Long et al. 2018).

Οι αρχιτεκτονικές των Feature Extractor και Label Classifier αυτή την φορά έχουν α-πλουστευθεί σε σχέση με πριν, καθώς ο Domain Classifier δεν λαμβάνει πλέον ως είσοδο μόνο το διάνυσμα χαρακτηριστικών $\mathbf{f}$, αλλά το γινόμενο τανυστών $\mathbf{f} \otimes \hat{\mathbf{y}}$, το οποίο είναι ήδη με πλουσιότερη πληροφορία, μειώνοντας την ανάγκη για βαθύτερα δίκτυα με πολλαπλά επίπεδα εξαγωγής μη γραμμικών συσχετίσεων.

Layers	Output Shape	Param #
Linear	[64, 128]	5,376
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 256]	33,024
BatchNorm1d	[64, 256]	512
ReLU	[64, 256]	0


Πίνακας 5.5: Αρχιτεκτονική του Feature Extractor στο CDAN.

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 3]	387

Πίνακας 5.6: Αρχιτεκτονική του Label Classifier στο CDAN.


Η εκπαίδευση πραγματοποιείται ακριβώς με τον ίδιο τρόπο με πριν αλλά με τιμή $\lambda = 0.2$ και διαρκεί πάλι 200 epochs, η βελτιστοποίηση των συναρτήσεων κόστους γίνεται με τη χρήση Adam και χρησιμοποιείται ρυθμός μάθησης ίσος με $\eta = 0.001$. Τέλος, χρησιμοποιήθηκε η ίδια εκθετικά αυξανόμενη τιμή στο διάστημα $[0, 1]$ για την αρνητική σταθερά α στο GRL.

Παρακάτω βλέπουμε τις γραφικές παραστάσεις των συναρτήσεων κόστους L_y και L_d , καθώς και της συνολικής απώλειας. Η εξέλιξή τους δείχνει επίσης σταθερή βελτίωση της απόδοσης του μοντέλου καθ' όλη τη διάρκεια των epochs. Στο **Total Loss**, παρατηρείται συνεχής μείωση τόσο για τα δεδομένα εκπαίδευσης όσο και για τα δεδομένα επικύρωσης, γεγονός που υποδηλώνει ότι το μοντέλο προσαρμόζεται αποτελεσματικά χωρίς να εμφανίζει σημαντικά σημάδια υπερπροσαρμογής. Το **Classification Loss** ακολουθεί αντίστοιχη πτωτική πορεία και συγκλίνει πιο κοντά στο 0 αυτή τη φορά, επιβεβαιώνοντας ότι η προσαρμογή τομέα μέσω του class-conditional μηχανισμού δεν θυσιάζει την ακρίβεια στην πρόβλεψη της κλάσης, αλλά αντίθετα τη βελτιώνει σταθερά. Συνολικά, σε σύγκριση με τις προηγούμενες καμπύλες, παρατηρείται μια πιο ομαλή σύγκλιση και στις δύο περιπτώσεις, καθώς μειώνονται σταθερά χωρίς έντονες διακυμάνσεις. Όσον αφορά το **Domain Loss**, παρατηρείται γρήγορη αύξηση στις αρχικές εποχές μέχρι να σταθεροποιηθεί σε επίπεδο πιο κοντά στη θεωρητική τιμή σύγκυσης για $K = 4$ domains (0.1875). Αυτό υποδηλώνει βελτιωμένη ισορροπία ανάμεσα στη βελτίωση της ταξινόμησης και στην αποπλαισίωση των domain dependent χαρακτηριστικών, σε σχέση με τα προηγούμενα πειράματα όπου η απώλεια τομέα εμφάνιζε λίγο μεγαλύτερη απόκλιση.




Σχήμα 5.21: Συναρτήσεις κόστους του CDAN.

Αυτή τη φορά ως προς τη συσκευή παρατηρείται βελτιωμένη ανάμειξη δειγμάτων από διαφορετικές συσκευές, με λιγότερες ξεκάθαρες συστάδες που αντιστοιχούν σε συγκεκριμένα domains. Αν και εξακολουθούν να υπάρχουν υπολειμματικές διαφοροποιήσεις (π.χ. η Litt3200 παραμένει σε ένα διακριτό τμήμα του χώρου), η συνολική εικόνα δείχνει μεγαλύτερη ομοιογένεια σε σχέση με το DANN.



Σχήμα 5.22: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή CDAN.

Ως προς τις κλάσεις μπορούμε να πούμε πως η διαχωρισιμότητα μεταξύ των τριών κλάσεων έχει βελτιωθεί αισθητά. Ιδιαίτερα, η κλάση Wheeze σχηματίζει πλέον πιο συμπαγή και διακριτή συστάδα, ενώ η επικάλυψη μεταξύ Normal και Crackle έχει μειωθεί. Αυτό οφείλεται στο class-conditional alignment που επιτυγχάνει το CDAN, καθώς ο domain classifier λαμβάνει υπόψη τόσο τα χαρακτηριστικά $\mathbf{f}$ όσο και τις προβλέψεις κλάσης $\hat{y}$, ευθυγραμμίζοντας τις κατανομές υπό συνθήκη $P(\mathbf{f} | y)$ και όχι μόνο τις οριακές $P(\mathbf{f})$.



Σχήμα 5.23: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή CDAN.

Τα αποτελέσματα αυτά επιβεβαιώνουν τη θεωρητική υπεροχή του CDAN έναντι του DANN ειδικά όταν η πληροφορία της κλάσης παίζει κρίσιμο ρόλο στη διαδικασία του domain adaptation.

Συνεχίζουμε με μια ακόμη παραλλαγή του κλασικού DANN, ωστόσο σε αυτή τη περίπτωση επιχειρούμε να αλλάξουμε την αρχιτεκτονική του Feature Extractor και ταυτόχρονα να αλλάξουμε τη συνάρτηση κόστους του Domain Classifier από MSE σε Categorical Cross-Entropy.

Domain Adversarial Neural Network (DANN) με Variational Autoencoder (VAE) Η συγκεκριμένη προσέγγιση βασίζεται στην υλοποίηση του κλασικού DANN που αναλύσαμε μεταβάλλοντας ωστόσο τη δομή του Feature extractor από MLP σε Variational Autoencoder (VAE). Η ενσωμάτωση ενός VAE στο πλαίσιο του DANN στοχεύει στην εκμάθηση μιας λανθάνουσας αναπαράστασης χαρακτηριστικών $\mathbf{z}$ που να είναι **πληροφοριακή για την κλάση** και ταυτόχρονα **αναλλοίωτη ως προς τον τομέα** (Zonoozi et al. 2025).

Στο Variational Autoencoder (VAE), ο **Encoder** $q_\phi(\mathbf{z}|\mathbf{x})$ είναι ένα νευρωνικό δίκτυο το οποίο λαμβάνει ως είσοδο το διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^n$ και το μετασχηματίζει σε μια **πιθανοτική περιγραφή** μιας λανθάνουσας μεταβλητής $\mathbf{z} \in \mathbb{R}^m$. Σε αντίθεση με τον κλασικό Autoencoder που περιγράψαμε στο Κεφάλαιο 4 ο οποίος επιστρέφει μόνο ένα σημείο στον λανθάνοντα χώρο, ο VAE μαθαίνει δύο διανύσματα εξόδου:

$$\boldsymbol{\mu}_\phi(\mathbf{x}) \in \mathbb{R}^m \quad \text{και} \quad \boldsymbol{\sigma}_\phi(\mathbf{x}) \in \mathbb{R}^m,$$

τα οποία αντιστοιχούν στο μέσο (mean) και στην τυπική απόκλιση (standard deviation) μιας πολυδιάστατης κανονικής κατανομής. Η κατανομή αυτή περιγράφει τις πιθανές τιμές που μπορεί να λάβει η λανθάνουσα μεταβλητή $\mathbf{z}$ για το δοθέν $\mathbf{x}$:

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_\phi(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_\phi^2(\mathbf{x}))).$$


Έτσι, η κωδικοποίηση δεν είναι πλέον ντετερμινιστική, αλλά πιθανοτική. επιτρέποντας στο μοντέλο να συλλάβει την αβεβαιότητα και την ποικιλία των δυνατών αναπαραστάσεων.

Για να μπορέσουμε να δειγματοληπτήσουμε ένα συγκεκριμένο διάνυσμα $\mathbf{z}$ από την παραπάνω κατανομή κατά τη διάρκεια της εκπαίδευσης, χρησιμοποιούμε την **τεχνική επαναπαραμετροποίησης (reparameterization trick)**. Η ιδέα είναι να εκφράσουμε τη στοχαστική δειγματοληψία ως έναν ντετερμινιστικό υπολογισμό που περιέχει έναν εξωτερικό τυχαίο παράγοντα:

$$\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\sigma}_\phi(\mathbf{x}) \odot \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Με αυτόν τον τρόπο, η τυχαιότητα περιορίζεται στην ανεξάρτητη μεταβλητή $\boldsymbol{\epsilon}$, η οποία δεν εξαρτάται από τις παραμέτρους ϕ , επιτρέποντας η ροή του υπολογισμού να παραμείνει διαφορίσιμη. Κατά συνέπεια, το δίκτυο μπορεί να εκπαιδευτεί κανονικά μέσω οπισθοδιάδοσης, παρά το γεγονός ότι περιλαμβάνει διαδικασία δειγματοληψίας.

Ο **Decoder** $p_\theta(\mathbf{x}|\mathbf{z})$ στη συνέχεια ανακατασκευάζει την είσοδο $\hat{\mathbf{x}}$ από τη $\mathbf{z}$, η οποία θα τροφοδοτηθεί στα υπόλοιπα δύο modules.



Σχήμα 5.24: Αρχιτεκτονική ενός VAE.

Η εκπαίδευση του VAE βασίζεται στη μεγιστοποίηση της **κατώτερης προσέγγισης** (Evidence Lower Bound της λογαριθμικής πιθανοφάνειας $\log p_{\theta}(\mathbf{x})$). Η ELBO μπορεί να γραφεί ως:

$$\mathcal{L}_{VAE}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}|\mathbf{z})] - D_{KL}(q_{\phi}(\mathbf{z}|\mathbf{x}) || p(\mathbf{z})),$$

Ο όρος

$$L_{rec} = -\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}|\mathbf{z})]$$

είναι το **σφάλμα ανακατασκευής** (reconstruction loss), που μετρά πόσο καλά ο Decoder μπορεί να αναπαράγει την είσοδο $\mathbf{x}$ από τη λανθάνουσα αναπαράσταση $\mathbf{z}$.

Επίσης, ο όρος

$$L_{KL} = D_{KL}(q_{\phi}(\mathbf{z}|\mathbf{x}) || p(\mathbf{z}))$$

είναι η **Kullback–Leibler divergence**, η οποία μετρά την πληροφοριακή απόσταση μεταξύ της εκτιμώμενης κατανομής λανθάνουσας μεταβλητής $q_{\phi}(\mathbf{z}|\mathbf{x})$ και της εκ των προτέρων (prior) κατανομής $p(\mathbf{z})$ που στον VAE θεωρείται τυπικά ισοτροπική κανονική κατανομή $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$. Αυτός ο όρος δρα ως κανονικοποιητής, αναγκάζοντας τον λανθάνοντα χώρο να παραμένει συνεχής και οργανωμένος. Συνολικά, η συνάρτηση κόστους που ελαχιστοποιείται κατά την εκπαίδευση είναι:

$$L_{total}(\theta, \phi) = L_{rec} + \beta L_{KL}$$

όπου β είναι ένας υπερπαραμέτρος (β -VAE) που επιτρέπει τον έλεγχο της σχετικής βαρύτητας μεταξύ πιστότητας ανακατασκευής και κανονικοποίησης της λανθάνουσας κατανομής.

Στη συγκεκριμένη εργασία χρησιμοποιείται **KL-divergence loss** για το L_{KL} , **mean squared error loss** για το L_{rec} και έπειτα από διερεύνηση αποφασίστηκαν οι τιμές $\lambda = 1.0$ για το συμβατικό DANN και $\beta = 0.1$ για το VAE. Επίσης, οι επιλεγμένες αρχιτεκτονικές κάθε module φαίνονται παρακάτω:

Layers	Output Shape	Param #
Linear	[64, 512]	21,504
ReLU	[64, 512]	0
Linear	[64, 256]	131,328
ReLU	[64, 256]	0
Linear (μ)	[64, 16]	4,112
Linear (σ)	[64, 16]	4,112

Πίνακας 5.7: Αρχιτεκτονική του Encoder στο VAE.

Layers	Output Shape	Param #
Linear	[64, 256]	4,352
ReLU	[64, 256]	0
Linear	[64, 41]	10,537

Πίνακας 5.8: Αρχιτεκτονική του Decoder στο VAE.

Layers	Output Shape	Param #
Linear	[64, 128]	2,176
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Dropout	[64, 64]	0
Linear	[64, 3]	195

Πίνακας 5.9: Αρχιτεκτονική του Label Classifier.

Layers	Output Shape	Param #
Linear	[64, 64]	1,088
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Dropout	[64, 64]	0
Linear	[64, 4]	260

Πίνακας 5.10: Αρχιτεκτονική του Domain Classifier.

Για την εκπαίδευση στη δικιά μας περίπτωση η διάσταση του λανθάνοντα χώρου έχει οριστεί σε 16, η βελτιστοποίηση των συναρτήσεων κόστους γίνεται με τη χρήση Adam και


χρησιμοποιείται ρυθμός μάθησης ίσος με $\eta = 0.001$. Τέλος, πάλι χρησιμοποιήθηκε εκθετικά αυξανόμενη τιμή στο διάστημα $[0, 1]$ για την αρνητική σταθερά α στο GRL.

Όσον αφορά την διαδικασία εκπαίδευσης η ενσωμάτωση του VAE μπορεί να πραγματοποιηθεί με δύο διαφορετικές προσεγγίσεις:

(α) Ταυτόχρονη εκπαίδευση (Joint training) Στην πρώτη προσέγγιση, ο Encoder και ο Decoder του VAE, ο Label Classifier και ο Domain Classifier εκπαιδεύονται **ταυτόχρονα** σε ένα ενιαίο βήμα βελτιστοποίησης. Η συνολική συνάρτηση κόστους προκύπτει ως συνδυασμός των τριών όρων:

$$L_{\text{total}} = L_{\text{rec}} + \beta L_{\text{KL}} + L_y - \lambda L_d,$$

όπου L_{rec} και L_{KL} προέρχονται από το VAE, L_y είναι η απώλεια ταξινόμησης κλάσης και L_d η απώλεια ταξινόμησης τομέα. Σε αυτή τη ρύθμιση, η λανθάνουσα αναπαράσταση $\mathbf{z}$ διαμορφώνεται από κοινού ώστε να ικανοποιεί τόσο τον στόχο ανακατασκευής και κανονικοποίησης (όροι VAE), όσο και την απαίτηση για domain-invariance (όροι DANN). Το πλεονέκτημα αυτής της μεθόδου είναι ότι το δίκτυο προσαρμόζει συγχρονισμένα τη λανθάνουσα αναπαράσταση στις ανάγκες και των δύο υποστόχων. Με το συγκεκριμένο τρόπο εκπαίδευσης το δίκτυο εκπαιδεύεται για **100 epochs** και παρακάτω βλέπουμε τις καμπύλες των συναρτήσεων κόστους κατά τη διάρκειά της:



Σχήμα 5.25: Συναρτήσεις κόστους κατά την ταυτόχρονη εκπαίδευση.


Αρχικά, βλέπουμε πως η απώλεια ταξινόμησης παραμένει σε πολύ πιο χαμηλά επίπεδα σχεδόν κοντά στο 0, γεγονός που επιβεβαιώνει ότι ο ταξινομητής συνεχίζει να βελτιώνει την ικανότητά του να διαχωρίζει σωστά τις κλάσεις αναπνευστικών ήχων. Η απώλεια ανακατασκευής σταθεροποιείται και αυτή μετά από λίγα epochs γύρω στο 0.18, καταδεικνύοντας ότι ο αποκωδικοποιητής του VAE μπορεί να αναπαράγει το αρχικό σήμα με ικανοποιητική ακρίβεια.

Η απώλεια ταξινόμησης τομέα όμοια με πριν αυξάνεται και σταθεροποιείται γύρω από τη θεωρητική τιμή πλήρους σύγχυσης. Σε αυτή τη περίπτωση, με Categorical Cross-Entropy Loss και με $K = 4$ domains η θεωρητική βέλτιστη τιμή απώλειας είναι:


$$\mathcal{L}_{CE} = - \sum_{i=1}^K y_i \log p_i = - \log \frac{1}{K} = \log K = \log 4 \approx 1.386.$$

Η σύγκλιση των καμπυλών κοντά στο 1.38 επιβεβαιώνει ότι έχει επιτευχθεί ουσιαστικός αποπροσανατολισμός των χαρακτηριστικών σε σχέση με τον τομέα.

Τέλος, όσον αφορά την KL Divergence, το ζητούμενο είναι μια ενδιάμεση ισορροπία, δηλαδή να μην μηδενίζεται, καθώς τότε ο λανθάνων χώρος δεν θα μετέφερε επαρκή πληροφορία, αλλά ούτε να αυξάνεται ανεξέλεγκτα. Συγκεκριμένα, παρατηρείται ότι ξεκινά από τιμή περίπου 1 και σταθεροποιείται γύρω στο 2. Η συμπεριφορά αυτή είναι ενδεικτική επιτυχούς εκπαίδευσης, καθώς δείχνει ότι ο VAE έμαθε λανθάνουσες αναπαραστάσεις που διατηρούν την απαραίτητη πληροφορία για ανακατασκευή, παραμένοντας ταυτόχρονα αρκετά κοντά στην κανονική prior κατανομή $\mathcal{N}(0, I)$ ώστε να εξασφαλίζεται η γενίκευση του μοντέλου.



Σχήμα 5.26: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την ταυτόχρονη εκπαίδευση.




Σχήμα 5.27: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την ταυτόχρονη εκπαίδευση.

Συνολικά, τα αποτελέσματα δείχνουν ότι η ταυτόχρονη εκπαίδευση VAE και DANN συνδυάζει τα πλεονεκτήματα των δύο προσεγγίσεων, προσφέροντας **σταθερές και κανονικοποιημένες αναπαραστάσεις** με αυξημένη ανθεκτικότητα σε μεταβολές τομέα και υψηλή διακριτική ικανότητα ως προς τις κλάσεις.

(β) Διαδοχική εκπαίδευση (Sequential training) (Zonoozi et al. 2024) Στη δεύτερη προσέγγιση, το VAE εκπαιδεύεται **αυτόνομα** στο πρώτο στάδιο, χρησιμοποιώντας μόνο το $L_{\text{rec}} + \beta L_{\text{KL}}$ ώστε να μάθει έναν σταθερό, κανονικοποιημένο λανθάνοντα χώρο. Μετά την ολοκλήρωση της εκπαίδευσης του VAE, ο Encoder παγώνει (frozen encoder) και η λανθάνουσα αναπαράσταση $\mathbf{z}$ χρησιμοποιείται ως είσοδος σε ένα κλασικό DANN, το οποίο εκπαιδεύεται με βάση την απώλεια:

$$L_{\text{DANN}} = L_y - \lambda L_d.$$


Η προσέγγιση αυτή διαχωρίζει πλήρως τη μάθηση της αναπαράστασης από την domain-adversarial προσαρμογή, διευκολύνοντας τη σταθερότητα της εκπαίδευσης και αποφεύγοντας πιθανές αλληλεπιδράσεις μεταξύ των όρων κόστους. Με το συγκεκριμένο τρόπο εκπαίδευσης ο VAE εκπαιδεύεται πρώτα για **30 epochs** και έπειτα το DANN για άλλα **100 epochs**. Παρακάτω βλέπουμε τις καμπύλες των συναρτήσεων κόστους κατά τη διάρκειά των δύο φάσεων εκπαίδευσης:




Σχήμα 5.28: Συναρτήσεις κόστους κατά την διαδοχική εκπαίδευση.

Σε σύγκριση με τα προηγούμενα αποτελέσματα, το Reconstruction Loss σταθεροποιείται ταχύτερα και σε χαμηλότερη τιμή, ενώ η KL Divergence εμφανίζει πιο ελεγχόμενη πορεία, με αρχική αύξηση και σταδιακή σταθεροποίηση σε χαμηλότερο επίπεδο. Το Classification Loss μειώνεται γρήγορα και συγκλίνει χαμηλότερα, γεγονός που υποδηλώνει βελτιωμένη ταξινομητική ικανότητα. Τέλος, το Domain Loss φτάνει ξανά ομαλά στη θεωρητική τιμή πλήρους σύγχυσης για $K = 4$ domains ($\log 4 \approx 1.386$), δείχνοντας για ακόμη μια φορά σταθερή και αξιόπιστη αποπλαισίωση.

Όμοια και εδώ η εκ των προτέρων εκπαίδευση του VAE φαίνεται να έχει καταφέρει μάθει αναπαραστάσεις που διατηρούν πολύ καλά την πληροφορία της κλάσης, ενώ το DANN εξαλείφει την πληροφορία τομέα χωρίς να θυσιάζει τη διακριτική ικανότητα.



Σχήμα 5.29: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την διαδοχική εκπαίδευση.



Σχήμα 5.30: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την διαδοχική εκπαίδευση.

Κεφάλαιο 6

Ανάλυση και υλοποίηση συστήματος

6.1 Περιγραφή dataset και συσκευών εγγραφής

Η παρούσα εργασία βασίζεται στη δημόσια διαθέσιμη βάση δεδομένων αναπνευστικών ήχων **RSDB** του επιστημονικού διαγωνισμού ICBHI 2017 (International Conference on Biomedical and Health Informatics). Η βάση σχεδιάστηκε για την ανάπτυξη και αξιολόγηση αλγορίθμων αυτόματης ανάλυσης αναπνευστικών σημάτων, προσφέροντας ένα ευρύ φάσμα από καταγραφές τόσο από φυσιολογικά όσο και παθολογικά περιστατικά (Rocha et al. 2018). Η βάση δεδομένων δημιουργήθηκε από δύο ερευνητικές ομάδες:

ESSUA (Πορτογαλία) Οι ηχογραφήσεις έγιναν στο Respiratory Research and Rehabilitation Laboratory (Lab3R) και στο Hospital Infante D. Pedro καλύπτοντας ευρύ πλήθος ατόμων από βρέφη μέχρι ηλικιωμένους. Οι καταγραφές έγιναν σε 7 θέσεις θώρακα: τραχεία, αριστερά και δεξιά (πρόσθια, οπίσθια και πλάγια).

AUTH (Ελλάδα) Οι ηχογραφήσεις πραγματοποιήθηκαν στο Πανεπιστημιακό Νοσοκομείο Παπανικολάου και το Γενικό Νοσοκομείο Ημαθίας σε ενήλικες και ηλικιωμένους ασθενείς. Οι θέσεις καταγραφής ήταν 6, στην τραχεία και σε θέσεις στον θώρακα.

Η ανομοιογένεια της βάσης δεδομένων ενισχύεται από τη χρήση διαφορετικών συσκευών και μεθόδων καταγραφής, γεγονός που εισάγει φυσικό domain shift. Οι κύριες συσκευές καταγραφής που αξιοποιήθηκαν είναι:

Welch Allyn Master Elite Stethoscope (5079-400) [Litt3200] Ψηφιακό στηθοσκόπιο ιατρικής κατηγορίας, το οποίο ενσωματώνει ηλεκτρονικό αισθητήρα στην κεφαλή του και μετατρέπει τους ήχους σε ψηφιακό σήμα. Χρησιμοποιείται ευρέως σε κλινικά περιβάλλοντα και παρέχει καλή απόκριση χαμηλών συχνοτήτων, η οποία είναι κρίσιμη για την ανάλυση

αναπνευστικών ήχων. Η συσκευή χρησιμοποιήθηκε από την ομάδα του AUTH σε ενήλικες ασθενείς.

3M Littmann Classic II SE [LittC2SE] Κλασικό αναλογικό στηθοσκόπιο, το οποίο τροποποιήθηκε για τις ανάγκες της βάσης μέσω προσθήκης εξωτερικού μικροφώνου στον εύκαμπτο σωλήνα μεταφοράς του ήχου. Το μικρόφωνο κατέγραφε τον ήχο που μεταδιδόταν ακουστικά μέσω του σωλήνα, μετατρέποντάς τον σε σήμα κατάλληλο για ψηφιοποίηση. Αν και δεν πρόκειται για ψηφιακή συσκευή *per se*, η υλοποίηση αυτή επιτρέπει την καταγραφή με ευρεία συχνοτική κάλυψη. Η συσκευή χρησιμοποιήθηκε κυρίως σε ενήλικους ασθενείς σε ελεγχόμενο περιβάλλον.

AKGC417L Αποτελεί τύπο electret μικροφώνου τοποθετημένου σε υλικό τεφλόν, σχεδιασμένο για μη επεμβατικές μετρήσεις. Η συσκευή είναι αερόσυζευκτη (air-coupled) και προσφέρει εξαιρετικά ευαίσθητη καταγραφή ηχητικών σημάτων από την επιφάνεια του θώρακα, με ιδιαίτερα υψηλή συχνότητα δειγματοληψίας (**44.1 kHz**). Χρησιμοποιήθηκε από την ομάδα του ESSUA κυρίως σε νεαρούς ενήλικους πληθυσμούς και λόγω της υψηλής ανάλυσης, προσφέρει αναπαράσταση των λεπτομερειών σε ήχους τύπου crackles και wheezes.

Meditron Πρόκειται για ψηφιακό ηλεκτρονικό στηθοσκόπιο υψηλής ευαισθησίας που χρησιμοποιήθηκε ως τυπική συσκευή αναφοράς στον διαγωνισμό ICBHI. Καταγράφει σε **4 kHz** και παρέχει σήμα υψηλής καθαρότητας, ενώ διαθέτει ενσωματωμένο σύστημα καταγραφής σε υπολογιστή. Επιτρέπει εύκολη φορητή καταγραφή και συνήθως χρησιμοποιείται σε νοσοκομειακά και ερευνητικά περιβάλλοντα.

Συνολικά περιλαμβάνει **920 ηχογραφήσεις** από **126 ασθενείς** με καταγεγραμμένους **6898 αναπνευστικούς κύκλους**.

Οι ηχογραφήσεις αποκτήθηκαν σε διάρκεια 10–90 δευτερολέπτων και συνοδεύονται από σχολιασμό εξειδικευμένων ιατρών και φυσιοθεραπευτών σε annotation files ως προς την παρουσία:

- φυσιολογικών ήχων (**Normal**),
- παθολογικών ήχων (**Crackle, Wheeze**),
- συνδυασμού αυτών (**Both**).

Η κατηγορία Both στη συγκεκριμένη εργασία δεν μας απασχόλησε, συνεπώς αφαιρέθηκαν και από το σύνολο δεδομένων όλες οι εγγραφές με τη συγκεκριμένη ετικέτα. Άρα, διατηρούμε μόνο τους **6392** κύκλους από τους 6898 που επάρχουν συνολικά διαθέσιμοι.

Κλάση	AKGC417L	Litt3200	LittC2SE	Meditron
Normal	1537	266	287	823
Crackle	1234	22	64	171
Wheeze	401	88	98	122

Πίνακας 6.1: Κατανομή των κατηγοριών αναπνευστικών ήχων ανά συσκευή καταγραφής.

Επίσης, οι ήχοι συνοδεύονται και από επιπρόσθετο σχολιασμό ως προς τα όρια των αναπνευστικών κύκλων, τον τύπο παθολογικού ήχου και την παρουσία επιπρόσθετων στοιχείων (π.χ. βήχας, ομιλία, artifacts).

Όπως παρατηρείται στον Πίνακα 6.1, το σύνολο δεδομένων παρουσιάζει **έντονη ανισορροπία τόσο μεταξύ των κατηγοριών (φυσιολογικών και παθολογικών ήχων) όσο και μεταξύ των συσκευών καταγραφής**. Η πλειοψηφία των εγγραφών προέρχεται από τη συσκευή **AKGC417L** (6377 κύκλοι), ενώ άλλες συσκευές όπως η **Litt3200** και η **LittC2SE** συμμετέχουν με πολύ μικρότερο αριθμό (759 και 938 αντίστοιχα). Επιπλέον, η συχνότητα εμφάνισης των αναπνευστικών ηχητικών κατηγοριών είναι επίσης άνιση, με τους φυσιολογικούς ήχους (**Normal**) να υπερисχύουν αριθμητικά έναντι των παθολογικών **Crackle** και **Wheeze**.

Αυτή η ανισορροπία ενδέχεται να επηρεάσει σημαντικά την απόδοση των αλγορίθμων μηχανικής μάθησης. Συγκεκριμένα, η κυριαρχία του ενός τομέα οδηγεί σε **στατιστική προκατάληψη** προς τα χαρακτηριστικά της συγκεκριμένης συσκευής, με αποτέλεσμα το μοντέλο να υπερεκπαιδεύεται σε αυτά τα πρότυπα. Επίσης, η μειωμένη παρουσία παθολογικών ήχων ενισχύει το **πρόβλημα ανισορροπίας κλάσεων**, το οποίο οδηγεί σε μείωση της ευαισθησίας (sensitivity) και της δυνατότητας εντοπισμού σπάνιων συμβάντων.

Για την αντιμετώπιση αυτών των προκλήσεων έχουν εφαρμοστεί τεχνικές **εξισορρόπησης δεδομένων** για το training set, όπως το VTLP-Patch Augmentation. Η ισορροπία μεταξύ των κλάσεων στο σύνολο εκπαίδευσης είναι ιδιαίτερα σημαντική για την αποφυγή μεροληψίας κατά την εκμάθηση του ταξινομητή. Αντιθέτως, το test set δεν χρησιμοποιείται για εκπαίδευση, αλλά για αξιολόγηση. Συνεπώς, δεν είναι απαραίτητο να είναι ισορροπημένο, αλλά να αντικατοπτρίζει την πραγματική κατανομή των κλάσεων στον φυσικό πληθυσμό.

6.2 Τεχνολογίες και εργαλεία υλοποίησης

Υπολογιστικό σύστημα Όλες οι πειραματικές διαδικασίες και η υλοποίηση των αλγορίθμων πραγματοποιήθηκαν σε φορητό υπολογιστή εξοπλισμένο με επεξεργαστή **Intel Core i5-8350U**, τεχνολογίας Kaby Lake-R. Το σύστημα διαθέτει **16 GB μνήμης RAM DDR4**, καθώς και ενσωματωμένη κάρτα γραφικών **Intel UHD Graphics 620**. Η συγκεκριμένη διαμόρφωση προσφέρει επαρκή υπολογιστική ισχύ για την εκπαίδευση και αξιολόγηση μοντέλων βαθιάς μάθησης μικρής έως μέσης κλίμακας, ενώ η χρήση ενσωματωμένων γραφικών καθιστά το σύστημα ενεργειακά αποδοτικό και κατάλληλο για φορητή χρήση.

Περιβάλλον ανάπτυξης Η υλοποίηση πραγματοποιήθηκε σε γλώσσα προγραμματισμού Python και πιο συγκεκριμένα σε περιβάλλον **Python 3.6.8**. Η γλώσσα Python επιλέχθηκε ως κύριο εργαλείο υλοποίησης λόγω της ευρείας χρήσης της στην επιστημονική έρευνα και την επεξεργασία σημάτων, της μεγάλης ποικιλίας βιβλιοθηκών ανοιχτού κώδικα που υποστηρίζουν ανάλυση ήχου, μηχανική μάθηση και οπτικοποίηση, καθώς και της απλής και κατανοητής σύνταξής της που επιτρέπει ταχεία ανάπτυξη και πειραματισμό. Επιπλέον, για την ανάπτυξη του κώδικα χρησιμοποιήθηκε το εργαλείο **Visual Studio Code** και το **Jupyter Notebook** για την πειραματική ανάλυση και οπτικοποίηση.

Βιβλιοθήκες Παρατίθεται μια σύντομη λίστα με όλες τις βιβλιοθήκες Python που χρησιμοποιήθηκαν κατά την εκπόνηση της εργασίας:

Επεξεργασία σημάτων Για την ανάγνωση, επεξεργασία και φασματική ανάλυση των ηχητικών σημάτων αξιοποιήθηκαν βιβλιοθήκες όπως:

- `librosa` για εξαγωγή χαρακτηριστικών.
- `scipy.signal` για εφαρμογή φίλτρων, παραθύρωσης και μετασχηματισμούς Φουριερ.
- `soundfile` για ανάγνωση/εγγραφή αρχείων `.wav`.

Διαχείριση και προεπεξεργασία δεδομένων Η διαχείριση των δεδομένων έγινε με χρήση `pandas` και `numpy` για αποθήκευση, μετασχηματισμό και τυποποίηση των χαρακτηριστικών.


Οπτικοποίηση και ανάλυση δεδομένων Για την οπτικοποίηση των αποτελεσμάτων χρησιμοποιήθηκαν οι `matplotlib` και `seaborn` για γραφήματα συναρτήσεων κόστους, θερμικούς χάρτες, κατανομές χαρακτηριστικών και γενικότερα οποιασδήποτε στατιστικής ανάλυσης.

Μηχανική μάθηση Η εκπαίδευση των μοντέλων βαθιάς μάθησης για το domain adaptation πραγματοποιήθηκε μέσω του framework `pytorch`, το οποίο επιτρέπει ευέλικτη υλοποίηση νευρωνικών αρχιτεκτονικών μέσω του module `torch` και υποστηρίζει μηχανισμούς αυτόματης παραγωγής και βελτιστοποίησης. Χρησιμοποιήθηκαν επίσης:

- `torchvision` για τυπικές συναρτήσεις προεπεξεργασίας και data loaders.
- `scikit-learn` για τα συμβατικά μοντέλα ταξινόμησης μετρικές αξιολόγησης και μεθόδους μείωσης διαστάσεων (PCA, t-SNE).


6.3 Περιγραφή συνολικού pipeline

Στην παρακάτω εικόνα παρουσιάζεται το συνολικό pipeline που υλοποιήθηκε κατά την εκπόνηση της εργασίας.



Σχήμα 6.1: Pipeline υλοποίησης.

Ξεκινάμε με την διάσπαση των αρχείων καταγραφής .wav σε αναπνευστικούς κύκλους με βάση τα timestamps στα annotation files. Έτσι, προκύπτουν 6392 αναπνευστικοί κύκλοι, οι οποίοι αποτελούν το αρχικό μας σύνολο δεδομένων. Αυτό το σύνολο δεδομένων εισάγεται πρώτα στο **Preprocessing Module** από όπου προκύπτουν τα τελικά επεξεργασμένα αρχεία αναπνευστικών κύκλων σύμφωνα με τη διαδικασία που αναλύθηκε στην Ενότητα 3.3. Στη συνέχεια, το επεξεργασμένο σύνολο δεδομένων διασπάται σε training και test sets με αναλογία 80:20, δηλαδή 5113 κύκλους για το training set και 1279 για το test set:




Σχήμα 6.2: Training, test sets.

Το training set υφίσταται **Augmentation μέσω της τεχνικής VTLP-Patch** προκειμένου να εξισορροπηθεί και κάθε μία από τις τρεις κλάσεις να αντιστοιχεί στο ίδιο πλήθος εγγραφών. Ως αποτέλεσμα έχουμε πλέον 10018 αναπνευστικούς κύκλους, 8739 για το ισορροπημένο πλέον training set και 1279 για το test set, οι οποίοι εισάγονται στο **Feature Extraction Module**. Για κάθε αναπνευστικό κύκλο εξάγεται ξεχωριστά ένα **μητρώο**

χαρακτηριστικών ως προς frames με διαστάσεις **(101, 41)** όπως αναφέραμε και νωρίτερα. Επομένως στο τέλος παράγεται ένας **τανυστής τριών διαστάσεων (10018, 101, 41)**, ο οποίος έχει αποθηκευμένα όλα τα χαρακτηριστικά με βάση την εξέλιξή τους ως προς το χρόνο. Η χρήση όμως τανυστή χαρακτηριστικών της μορφής (N, T, F), όπου:

- N είναι το πλήθος των δειγμάτων (αναπνευστικοί κύκλοι),
- T είναι ο αριθμός χρονικών παραθύρων ανά δείγμα,
- F είναι το πλήθος εξαγμένων χαρακτηριστικών ανά παράθυρο

απαιτεί συχνά μετασχηματισμό σε μορφή δισδιάστατου πίνακα σταθερού μεγέθους ώστε να είναι κατάλληλος για είσοδο στους συμβατικούς αλγόριθμους μηχανικής μάθησης. Η πιο διαδεδομένη προσέγγιση είναι η **συνάθροιση (aggregation) των χαρακτηριστικών** ως προς τη δεύτερη διάσταση, δηλαδή του χρόνου T, μέσω του **μέσου όρου (mean)**. Με τον τρόπο αυτό, παράγεται ένα μητρώο διαστάσεων (N, F), όπου κάθε δείγμα συνοψίζεται σε ένα διανύσμα μέσης τιμής των χαρακτηριστικών του στον χρόνο. Αυτή η τεχνική εξομαλύνει τις ενδοχρονικές διακυμάνσεις, ελαχιστοποιεί τον χρονικό θόρυβο και οδηγεί σε πιο σταθερή αναπαράσταση. Συνεπώς, μετά το **Feature Extraction Module** έχουμε ένα συνολικό μητρώο με διαστάσεις **(10018, 41)**. Επίσης, παρακάτω βλέπουμε την κατανομή των δεδομένων του μητρώου, δηλαδή των τελικών χαρακτηριστικών, στα δύο σύνολα:



Σχήμα 6.3: Κατανομές χαρακτηριστικών σε training, test sets.

Το μητρώο αυτό χαρακτηριστικών προωθείται στο **Feature Selection Module** από όπου με βάση τη στατιστική ανάλυση που περιγράψαμε διατηρούμε τα 20 πιο σημαντικά χαρακτηριστικά. Έτσι, προκύπτει τώρα ένα μητρώο διαστάσεων **(10018, 20)** το οποίο θα περάσει από το **Domain Adaptation Module**. Ανάλογα με τη μέθοδο που εφαρμόζεται εντός του module, το μητρώο είτε διατηρεί τις ίδιες διαστάσεις είτε προκύπτουν νέες διαστάσεις με


βάση τον ενδιαμέσο χώρο αναπαράστασης χαρακτηριστικών (**10018, bottleneck**) από τα νευρωνικά δίκτυα.

Τέλος, το μητρώο που έχει προκύψει περνάει μέσα από το **Classification Module** όπου γίνεται η εκπαίδευση και η τελική ταξινόμηση των αναπνευστικών κύκλων παράγοντας ένα διάνυσμα διαστάσεων (**3,**) για κάθε κύκλο με τα softmax probabilities για κάθε κλάση. Αυτά θα χρησιμοποιηθούν για την δημιουργία της τελικής πρόβλεψης και την αξιολόγηση των μοντέλων με βάση τις διαφορετικές μετρικές που αναλύσαμε.

6.4 Υλοποίηση επιμέρους υπομονάδων

6.4.1 Preprocessing module

Το **Preprocessing module** έχει ως στόχο την τυποποίηση και καθαρισμό των εισερχόμενων αναπνευστικών κύκλων, ώστε να διασφαλιστεί η ομοιομορφία των δεδομένων πριν από τη διαδικασία εξαγωγής χαρακτηριστικών. Η υλοποίηση περιλαμβάνει τα εξής στάδια:



Σχήμα 6.4: Block diagram για το Preprocessing Module.

Παρακάτω βλέπουμε τον κώδικα ο οποίος υλοποιεί τις συναρτήσεις για τον καθορισμό της διάρκειας των αναπνευστικών κύκλων και τη δημιουργία του υπερπαρατού φίλτρου. Η συνάρτηση `fix_cycle_length` αρχικά υπολογίζει τον επιθυμητό αριθμό δειγμάτων `target_length` με βάση τον ρυθμό δειγματοληψίας και τη διάρκεια-στόχο. Εάν το μήκος του σήματος y είναι μικρότερο από την τιμή αυτή, το σήμα επαναλαμβάνεται κυκλικά με τη χρήση της `np.tile`) και στη συνέχεια περικόπεται στο ακριβές επιθυμητό μήκος. Εάν αντίθετα το σήμα είναι μεγαλύτερο, αποκόπτεται ώστε να διατηρείται μόνο το τμήμα που αντιστοιχεί στη διάρκεια-στόχο.

```

1 def fix_cycle_length(y: np.ndarray, sr: int, target_duration:
2   float) -> np.ndarray:
3     """Pad or truncate signal to fixed length.
4     Args:

```

```

5     y (np.ndarray): Input audio.
6     sr (int): Sampling rate.
7     target_duration (float): Desired duration in seconds.
8
9     Returns:
10    np.ndarray: Signal of fixed length.
11    """
12    target_length = int(sr * target_duration)
13    if len(y) < target_length:
14        repeat_times = int(np.ceil(target_length / len(y)))
15        y = np.tile(y, repeat_times)[:target_length]
16    else:
17        y = y[:target_length]
18    return y

```

Επίσης, η συνάρτηση `highpass_filter` αρχικά υπολογίζει τη συχνότητα Nyquist (μισό του ρυθμού δειγματοληψίας) και στη συνέχεια η συχνότητα αποκοπής `cutoff`, η οποία δίνεται σαν όρισμα, κανονικοποιείται με βάση την υπολογισμένη συχνότητα Nyquist. Με βάση αυτή την τιμή `normalized_cutoff` κατασκευάζονται έπειτα οι συντελεστές του φίλτρου Butterworth μέσω της συνάρτησης `butter`, καθορίζοντας τον τύπο φίλτρου ως `highpass` και την τάξη (`order`) του φίλτρου. Τέλος, το φιλτραρισμένο σήμα υπολογίζεται με τη χρήση της συνάρτησης `filtfilt`, η οποία εφαρμόζει το φίλτρο προς τα εμπρός και προς τα πίσω, εξασφαλίζοντας μηδενική φασματική παραμόρφωση (zero-phase filtering).

```

1 def highpass_filter(y: np.ndarray, cutoff: float, sr: int, order:
2   int = 5) -> np.ndarray:
3     """Apply high-pass Butterworth filter.
4
5     Args:
6         y (np.ndarray): Input audio signal.
7         cutoff (float): Cutoff frequency (Hz).
8         sr (int): Sampling rate.
9         order (int): Filter order.
10
11     Returns:
12         np.ndarray: Filtered audio signal.
13     """
14     nyquist = 0.5 * sr
15     normalized_cutoff = cutoff / nyquist
16     b, a = butter(order, normalized_cutoff, btype='highpass',
17                   analog=False)
18     return filtfilt(b, a, y)

```

Τέλος, βλέπουμε την υλοποίηση της συνάρτησης `preprocess_audio`, η οποία λαμβάνει αρχικά ως είσοδο τα αρχεία με κανονικοποιημένη διάρκεια, τα επαναδειγματοληπτεί και τα

αποθηκεύει στη μεταβλητή y με τη χρήση της `librosa.load`. Στη συνέχεια, εφαρμόζεται η συνάρτηση `librosa.util.normalize` ώστε το σήμα y να κανονικοποιηθεί ως προς το πλάτος του. Τέλος, καλείται η συνάρτηση `highpass_filter` που ορίσαμε προηγουμένως με συχνότητα αποκοπής `cutoff` 100 Hz και τάξη 5, η οποία επιστρέφει το τελικό επεξεργασμένο σήμα.


```

1 def preprocess_audio(audio_path: str, sr: int, cutoff: float =
    50.0) -> Tuple[np.ndarray, int]:
2     """Load, filter and normalize audio files.
3
4     Args:
5         audio_path (str): Path to audio (.wav).
6         sr (int): Sampling rate.
7         cutoff (float): High-pass filter cutoff frequency.
8
9     Returns:
10        tuple: Processed audio signal (np.array), sampling rate
11              (int).
12    """
13    y, sr = librosa.load(audio_path, sr=sr)
14    y = librosa.util.normalize(y)
15    y = highpass_filter(y, cutoff, sr, order=5)
16    return y, sr

```

6.4.2 Feature extraction module

Το **Feature extraction module** έχει ως στόχο την εξαγωγή των ακουστικών χαρακτηριστικών από τα προεπεξεργασμένα .wav αρχεία των αναπνευστικών κύκλων, δηλαδή την δημιουργία του τελικού μητρώου χαρακτηριστικών. Η υλοποίηση περιλαμβάνει τα εξής στάδια:



Σχήμα 6.5: Block diagram για το Feature Extraction Module.

Παρακάτω βλέπουμε τον κώδικα ο οποίος υλοποιεί τη συνάρτηση εξαγωγής των χαρακτηριστικών `extract_acoustic_features`. Η συνάρτηση λαμβάνει ως είσοδο τα αρχεία των αναπνευστικών κύκλων και για κάθε ένα από αυτά επιστρέφει το μητρώο με τα χαρακτηριστικά

που του αντιστοιχούν. Η διαδικασία του υπολογισμού του STFT μέσω του επιλεγμένου framing και windowing γίνεται αυτόματα μέσω του submodule `librosa.feature` της βιβλιοθήκης `librosa`:

```

1 def extract_acoustic_features(
2     y: np.ndarray,
3     sr: int,
4     frame_size: int,
5     hop_size: int,
6     n_mfcc: int,
7     n_mels: int,
8 ) -> np.ndarray:
9     """Extract frame-level acoustic features for every audio cycle
10        (MFCC, temporal, spectral and Log-Mel statistical
11        features)."""
12     # MFCCs
13     mfccs = librosa.feature.mfcc(
14         y=y, sr=sr, n_mfcc=n_mfcc, n_fft=frame_size,
15         hop_length=hop_size, window='hann'
16     )
17     # Spectral features
18     spectral_centroid = librosa.feature.spectral_centroid(y=y,
19         sr=sr, n_fft=frame_size, hop_length=hop_size)
20     spectral_bandwidth = librosa.feature.spectral_bandwidth(y=y,
21         sr=sr, n_fft=frame_size, hop_length=hop_size)
22     spectral_rolloff = librosa.feature.spectral_rolloff(y=y,
23         sr=sr, n_fft=frame_size, hop_length=hop_size)
24     spectral_flatness = librosa.feature.spectral_flatness(y=y,
25         n_fft=frame_size, hop_length=hop_size)
26     # Temporal features
27     rms = librosa.feature.rms(y=y, frame_length=frame_size,
28         hop_length=hop_size)
29     zero_crossing_rate = librosa.feature.zero_crossing_rate(y=y,
30         frame_length=frame_size, hop_length=hop_size)
31     # Spectral flux
32     spectral_flux = np.diff(spectral_centroid, axis=1)
33     spectral_flux = np.hstack([spectral_flux, spectral_flux[:,
34         -1:]])
35     # Log-mel spectrogram
36     mel_spectrogram = librosa.feature.melspectrogram(
37         y=y, sr=sr, n_fft=frame_size, hop_length=hop_size,
38         n_mels=n_mels, window='hann'
39     )

```

```

35     log_mel = librosa.power_to_db(mel_spectrogram, ref=np.max)
36
37     # On-set envelope
38     onset_env = librosa.onset.onset_strength(y=y, sr=sr,
39                                             hop_length=hop_size)[np.newaxis, :]
40
41     # Frame-level concatenation of features
42     features = np.vstack([
43         mfccs,
44         spectral_centroid,
45         spectral_bandwidth,
46         spectral_rolloff,
47         spectral_flatness,
48         rms,
49         zero_crossing_rate,
50         spectral_flux,
51         log_mel,
52         onset_env
53     ])
54
55     return features.T # (frames, features)

```

Η συνάρτηση αυτή καλείται επαναληπτικά για κάθε .wav αρχείο y μέσα σε ένα for loop και έτσι προκύπτει το μητρώο χαρακτηριστικών feats για κάθε αναπνευστικό κύκλο. Έπειτα, το μητρώο αυτό αποθηκεύεται στη λίστα features και στο τέλος αφού έχουν πραγματοποιηθεί όλες οι επαναλήψεις η λίστα αυτή θα περιέχει τα μητρώα απλο όλους τους κύκλους:

```

1     # Extract feature matrix for each respiratory cycle
2     feats = extract_acoustic_features(
3         y, sr,
4         frame_size=FRAME_SIZE,
5         hop_size=HOP_SIZE,
6         n_mfcc=N_MFCC,
7         n_mels=N_MELS
8     )
9
10    features.append(feats)

```

Στη συνέχεια, μέσω της συνάρτησης stack, όλα τα μητρώα συνδυάζονται σε ένα ενιαίο τανυστή τριών διαστάσεων τύπου NumPy array. Τέλος, ο τανυστής features που έχει προκύψει συμπιέζεται στο μητρώο δύο διαστάσεων μέσω της συνάρτησης mean, η οποία παίρνει τον μέσο όρο κάθε χαρακτηριστικού σε όλα τα frames ενός κύκλου:

```

1     # Create the feature tensor
2     features = np.stack(features)
3
4     # Convert the tensor into 2d matrix using frame-wise aggregation


```

```

over mean
5 features_mean = features.mean(axis=1)


```

6.4.3 Domain adaptation module



Σχήμα 6.6: Block diagram για το Domain Adaptation Module.

6.4.4 Classification module



Σχήμα 6.7: Block diagram για το Classification Module.

Κεφάλαιο 7

Επίλογος

7.1 Αποτελέσματα ταξινόμησης

Η διαδικασία της ταξινόμησης πραγματοποιήθηκε πάνω σε ένα σύνολο ελέγχου που περιέχει εγγραφές από όλες τις συσκευές καταγραφής. Το σενάριο αυτό προσομοιώνει ένα μεικτό περιβάλλον αξιολόγησης, όπου οι συνθήκες καταγραφής (συσκευές) ποικίλλουν εντός του συνόλου ελέγχου. Με τον τρόπο αυτό εκτιμάται η ικανότητα του μοντέλου να διατηρεί σταθερή απόδοση σε ετερογενή δεδομένα, αλλά και να εκμεταλλεύεται την πιθανή παρουσία κοινών χαρακτηριστικών μεταξύ διαφορετικών συσκευών.

7.1.1 Ανάλυση συνολικών αποτελεσμάτων

Πίνακας 7.1: Συνολικές μετρικές ταξινόμησης για κάθε μέθοδο προσαρμογής τομέα.

Method	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.710 ± 0.022	0.820 ± 0.027	0.715 ± 0.021
Spectrum Correction	0.730 ± 0.008 (+2.8%)	0.845 ± 0.013	0.728 ± 0.013
DANN	0.730 ± 0.018 (+2.8%)	0.828 ± 0.024	0.725 ± 0.029
CDAN	0.760 ± 0.014 (+7%)	0.863 ± 0.005	0.755 ± 0.024
DANN με VAE (1 φάση)	0.751 ± 0.010 (+5.8%)	0.840 ± 0.008	0.745 ± 0.017
DANN με VAE (2 φάσεις)	0.753 ± 0.009 (+6.1%)	0.848 ± 0.005	0.741 ± 0.008

Πίνακας 7.2: Μετρικές ταξινόμησης για τη κλάση Normal για κάθε μέθοδο προσαρμογής τομέα.

Method	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.783 ± 0.017	0.833 ± 0.073	0.610 ± 0.128	0.733 ± 0.035	0.458 ± 0.053
Spectrum Correction	0.793 ± 0.005	0.838 ± 0.042	0.640 ± 0.080	0.758 ± 0.033	0.505 ± 0.027
DANN	0.795 ± 0.014	0.855 ± 0.037	0.610 ± 0.098	0.748 ± 0.041	0.481 ± 0.059
CDAN	0.813 ± 0.010	0.845 ± 0.039	0.680 ± 0.098	0.780 ± 0.043	0.540 ± 0.036
DANN με VAE (1 φάση)	0.797 ± 0.008	0.793 ± 0.013	0.713 ± 0.005	0.785 ± 0.006	0.504 ± 0.013
DANN με VAE (2 φάσεις)	0.800 ± 0.008	0.798 ± 0.013	0.710 ± 0.008	0.783 ± 0.005	0.513 ± 0.010

Πίνακας 7.3: Μετρικές ταξινόμησης για τη κλάση Crackle για κάθε μέθοδο προσαρμογής τομέα.


Method	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.620 ± 0.050	0.620 ± 0.141	0.860 ± 0.074	0.668 ± 0.049	0.490 ± 0.062
Spectrum Correction	0.653 ± 0.017	0.630 ± 0.070	0.880 ± 0.030	0.690 ± 0.040	0.528 ± 0.019
DANN	0.655 ± 0.057	0.610 ± 0.86	0.890 ± 0.025	0.700 ± 0.045	0.510 ± 0.047
CDAN	0.700 ± 0.033	0.685 ± 0.068	0.888 ± 0.021	0.718 ± 0.019	0.584 ± 0.030
DANN με VAE (1 φάση)	0.673 ± 0.010	0.668 ± 0.010	0.873 ± 0.008	0.680 ± 0.013	0.543 ± 0.010
DANN με VAE (2 φάσεις)	0.680 ± 0.015	0.668 ± 0.022	0.873 ± 0.010	0.678 ± 0.005	0.543 ± 0.013

Πίνακας 7.4: Μετρικές ταξινόμησης για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής τομέα.


Method	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.505 ± 0.005	0.408 ± 0.083	0.978 ± 0.019	0.695 ± 0.067	0.495 ± 0.054
Spectrum Correction	0.608 ± 0.034	0.533 ± 0.062	0.968 ± 0.010	0.715 ± 0.042	0.567 ± 0.025
DANN	0.565 ± 0.087	0.468 ± 0.109	0.975 ± 0.010	0.725 ± 0.034	0.525 ± 0.068
CDAN	0.630 ± 0.080	0.550 ± 0.136	0.975 ± 0.017	0.785 ± 0.105	0.605 ± 0.044
DANN με VAE (1 φάση)	0.663 ± 0.005	0.658 ± 0.026	0.953 ± 0.008	0.685 ± 0.024	0.608 ± 0.009
DANN με VAE (2 φάσεις)	0.665 ± 0.009	0.653 ± 0.017	0.953 ± 0.005	0.675 ± 0.024	0.615 ± 0.005

7.1.2 Ανάλυση αποτελεσμάτων ανά μοντέλο ταξινόμησης


k-NN




Σχήμα 7.1: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN χωρίς προσαρμογή τομέα (baseline).




Σχήμα 7.2: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση Spectrum Correction.




Σχήμα 7.3: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση DANN.



Σχήμα 7.4: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση CDAN.




Σχήμα 7.5: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση DANN και VAE (1 φάση).




Σχήμα 7.6: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για k-NN με χρήση DANN και VAE (2 φάσεις).


XGBoost




Σχήμα 7.7: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost χωρίς προσαρμογή τομέα (baseline).




Σχήμα 7.8: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση Spectrum Correction.




Σχήμα 7.9: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση DANN.



Σχήμα 7.10: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση CDAN.




Σχήμα 7.11: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση DANN και VAE (1 φάση).




Σχήμα 7.12: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για XGBoost με χρήση DANN και VAE (2 φάσεις).


Random Forest




Σχήμα 7.13: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest χωρίς προσαρμογή τομέα (baseline).




Σχήμα 7.14: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση Spectrum Correction.




Σχήμα 7.15: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση DANN.



Σχήμα 7.16: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση CDAN.




Σχήμα 7.17: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση DANN και VAE (1 φάση).




Σχήμα 7.18: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Random Forest με χρήση DANN και VAE (2 φάσεις).


Non-linear SVM




Σχήμα 7.19: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM χωρίς προσαρμογή τομέα (baseline).




Σχήμα 7.20: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση Spectrum Correction.




Σχήμα 7.21: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση DANN.



Σχήμα 7.22: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση CDAN.



Σχήμα 7.23: Μητρώο σύγκρισης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση DANN και VAE (1 φάση).



Σχήμα 7.24: Μητρώο σύγχυσης, καμπύλη ROC και καμπύλη Precision-Recall για Non-linear SVM με χρήση DANN και VAE (2 φάσεις).

7.2 Συμπεράσματα

Στο πλαίσιο της συνολικής απόδοσης των μεθόδων, ιδιαίτερη βαρύτητα σαν μετρικές έχουν τα Macro AUC και Weighted F1 score, καθώς λαμβάνουν υπόψη την κατανομή των δειγμάτων ανά κλάση, οπότε προσφέρουν μια πιο αντικειμενική αποτίμηση της απόδοσης. Από την άλλη, το Accuracy παρέχει μια πιο γενική και συνοπτική εικόνα της συνολικής επίδοσης και μάλιστα σε ορισμένες περιπτώσεις η τιμή του μπορεί να είναι παραπλανητική λόγω της ανομοιομορφίας του συνόλου ελέγχου. Πιο συγκεκριμένα, η **μέγιστη ακρίβεια** ταξινόμησης που επιτεύχθηκε στην παρούσα εργασία από κάποιο μοντέλο είναι το **77%**, ενώ παράλληλα η καλύτερη **μέση ακρίβεια** που πετύχαμε είναι το 76%, το οποίο συνιστά μια αύξηση της τάξης του **7%** σε σχέση με το baseline. Συμπληρωματικά με την ακρίβεια, το βέλτιστο **μέσο Weighted F1 score** που πετύχαμε είναι 75.5%, ενώ το βέλτιστο **μέσο Macro AUC** είναι 0.863, τιμές οι οποίες βρίσκονται εντός του επιθυμητού εύρους και θεωρούνται ικανοποιητικές, καθώς βρίσκονται κοντά στα όρια των state-of-the-art υλοποιήσεων για αντίστοιχα σενάρια. Επόμενως και σε αυτή τη περίπτωση παρατηρούμε σημαντικές αυξήσεις των μετρικών της τάξης του **5.6%** και **5.2%** αντίστοιχα σε σχέση με το baseline. Αυτές οι τιμές καταδεικνύουν για ακόμη μια φορά ότι το προτεινόμενο σύστημα είναι σε θέση να διατηρήσει σταθερή και ανταγωνιστική απόδοση παρά την ετερογένεια των δεδομένων και τις προκλήσεις που εισάγει η διαφοροποίηση των συσκευών καταγραφής.

Ωστόσο, στο πλαίσιο της ιατρικής διάγνωσης αναπνευστικών παθήσεων ιδιαίτερη έμφαση δίνεται στις μετρικές που σχετίζονται άμεσα με την ασφάλεια του ασθενούς και άρα την αποτελεσματικότητα της διάγνωσης. Συγκεκριμένα, η **Ευαισθησία** (Sensitivity/Recall) θα λέγαμε ότι είναι καθοριστικής σημασίας, καθώς μετρά το ποσοστό των πραγματικών θετικών περιστατικών που ανιχνεύονται σωστά. Η αύξησή της μειώνει την πιθανότητα εμφάνισης ψευδώς αρνητικών προβλέψεων, δηλαδή περιπτώσεων όπου ασθενείς με παθολογικό αναπνευστικό ήχο δεν αναγνωρίζονται από το σύστημα. Συγκεκριμένα, για την κλάση **Normal**, η αύξηση κατά **2.6%** σημαίνει ότι το μοντέλο καταφέρνει να αναγνωρίζει με ακόμα μεγαλύτερη ακρίβεια τους υγιείς αναπνευστικούς ήχους, μειώνοντας έτσι τον κίνδυνο λανθασμένης κατάταξης φυσιολογικών περιπτώσεων ως παθολογικών. Παρότι η αρχική τιμή ήταν ήδη υψηλή (0.833), η περαιτέρω αύξηση στο 0.855 ενισχύει ακόμα περισσότερο την αξιοπιστία του συστήματος για

τη σωστή διάκριση των υγιών ασθενών. Η βελτίωση είναι ακόμη πιο κρίσιμη ωστόσο όταν σημειώνεται στις παθολογικές κλάσεις και μάλιστα στην κλάση **Crackle** παρατηρούμε ότι η ευαισθησία αυξήθηκε σημαντικά από 0.620 σε 0.685, δηλαδή κατά **10.5%**. Η πιο εντυπωσιακή βελτίωση βέβαια παρατηρείται στην κλάση **Wheeze**, όπου εκεί η ευαισθησία αυξήθηκε κατά **61.3%** (από 0.408 σε 0.658) και ήρθε σχεδόν στα ίδια επίπεδα με τη **Crackle**, παρά το γεγονός ότι διαθέτει τον μικρότερο αριθμό δειγμάτων στο σύνολο ελέγχου. Αυτό σημαίνει ότι πλέον το μοντέλο μόνο στο 34% των περιπτώσεων αποφαινεται λανθασμένα ότι ο ασθενής δεν έχει wheeze, αντί για το 59% που ήταν πριν.

Παράλληλα και η **Ειδικότητα** (Specificity) διαδραματίζει επίσης σημαντικό ρόλο, καθώς μετρά την ικανότητα του συστήματος να αναγνωρίζει σωστά τις αρνητικές περιπτώσεις, δηλαδή τα υγιή άτομα. Η υψηλή ειδικότητα μειώνει τον αριθμό ψευδώς θετικών προβλέψεων, αποτρέποντας την άσκοπη επιβάρυνση του συστήματος υγείας με περιττές εξετάσεις και μειώνοντας το άγχος των ασθενών. Ιδιαίτερα σε περιπτώσεις όπου η ευαισθησία έχει ήδη επιτευχθεί σε υψηλά επίπεδα, η ταυτόχρονη αύξηση και της ειδικότητας συμβάλλει στην εξισορρόπηση της απόδοσης και στην αύξηση της κλινικής αξιοπιστίας του συστήματος. Εδώ βλέπουμε ότι για τη κλάση **Crackle** η ειδικότητα, αν και ήδη αρκετά υψηλή (0.860), αυξήθηκε κατά **3.3%** φτάνοντας το 0.888, γεγονός το οποίο σημαίνει ότι μόνο στο 11% των περιπτώσεων το μοντέλο μπερδεύει την μη ύπαρξη **Crackle** με ύπαρξη. Για την κλάση **Wheeze** από την άλλη με ειδικότητα εξ αρχής στο **0.978** μπορούμε να πούμε με σιγουριά ότι το μοντέλο ποτέ δεν μπερδεύει την μη ύπαρξη **Wheeze** με ύπαρξη.

Η τόσο μεγάλη συνολική βελτίωση στις παθολογικές περιπτώσεις ελέγχου αποδεικνύει ότι το σύστημα είναι πλέον σε θέση να ανιχνεύει με συνέπεια τα περισσότερα περιστατικά ασθενών με παθολογίες χωρίς να θυσιάζει την ικανότητά του να αναγνωρίζει τους υγιείς, γεγονός που αυξάνει άμεσα τη χρησιμότητά του ως εργαλείο υποστήριξης της διάγνωσης στην κλινική πράξη. Επίσης, μπορούμε να εξάγουμε το συμπέρασμα ότι **το domain shift που προκύπτει από τις διαφορές στις συσκευές καταγραφής επηρεάζει συχνά εντονότερα τους παθολογικούς ήχους σε σχέση με τους φυσιολογικούς**, γι' αυτό κιόλας η εφαρμογή της προσαρμογής τομέα βελτίωσε πολύ περισσότερο τις μετρικές των παθολογικών κλάσεων.

Επιπρόσθετα, ένα ακόμη πολύ σημαντικό συμπέρασμα στο οποίο καταλήξαμε είναι πως **η συμπερίληψη της πληροφορίας της κλάσης στη διαδικασία ευθυγράμμισης των τομέων αποτελεί καθοριστικό παράγοντα για τη βελτίωση της συνολικής απόδοσης**. Αυτό μπορεί να διπιστωθεί εύκολα και από τις συνολικές μετρικές που υπολογίστηκαν, καθώς οι τεχνικές CDAN και DANN με χρήση VAE κατάφεραν να αυξήσουν την ακρίβεια δύο με δύομιση φορές περισσότερο σε σχέση με το κλασικό DANN και το Spectrum Correction. Συνεπώς βλέπουμε ότι σε αντίθεση με προσεγγίσεις που επιδιώκουν ολική ευθυγράμμιση των κατανομών χαρακτηριστικών ανεξαρτήτως κλάσης, η υπό όρους ευθυγράμμιση (class-conditional alignment) επιτρέπει την προσαρμογή με τρόπο που διατηρεί τη διαχωριστικότητα μεταξύ των κλάσεων. Αυτό πρακτικά σημαίνει ότι κατά τη σύγκλιση των κατανομών χαρακτηριστικών, η πληροφορία που σχετίζεται με το σε ποιά συσκευή ανήκει ένα δείγμα συσχετίζεται άμεσα με το πώς η συγκεκριμένη συσκευή καταγράφει κάθε κλάση.

Με αυτόν τον τρόπο, η διαδικασία προσαρμογής δεν εξαλείφει απλώς τις διαφορές μεταξύ συσκευών, αλλά μαθαίνει και τις χαρακτηριστικές παραμορφώσεις ή ιδιαιτερότητες καταγραφής κάθε συσκευής για κάθε τύπο ήχου, επιτυγχάνοντας έτσι πιο ακριβή και κλινικά αξιόπιστη αντιστοίχιση.

Τέλος, η ανάλυση των αποτελεσμάτων ανά ταξινομητή αποκαλύπτει και αυτή σημαντικές διαφοροποιήσεις στην απόδοση, τόσο σε όρους ακρίβειας όσο και στην ικανότητα γενίκευσης υπό διαφορετικά σενάρια προσαρμογής τομέα. Στο γενικό επίπεδο απόδοσης, προκύπτει ότι οι ταξινομητές k-NN και XGBoost παρουσιάζουν την υψηλότερη συνολική απόδοση, ενώ οι Random Forest και Non-Linear SVM εμφανίζονται ελαφρά ασθενέστεροι.

Ο αλγόριθμος k-NN, αν και απλός, αποδεικνύεται ιδιαίτερα αποτελεσματικός όταν συνδυάζεται με τεχνικές προσαρμογής τομέα. Αντίστοιχα, το XGBoost επιβεβαιώνει τη φήμη του ως ένα από τα πιο ισχυρά ensemble μοντέλα, εμφανίζοντας σταθερά υψηλές τιμές ακρίβειας και macro AUC. Σχεδόν σε όλα τα σενάρια domain adaptation οι καμπύλες ROC παραμένουν πάνω από αυτές των άλλων μοντέλων, ενώ οι καμπύλες Precision-Recall δείχνουν ανθεκτικότητα στις ψευδώς θετικές προβλέψεις.

Αντιθέτως, το Random Forest εμφανίζει χαμηλότερες επιδόσεις, με μειωμένη ικανότητα διάκρισης ειδικά στην κατηγορία Wheeze. Οι καμπύλες Precision-Recall καταδεικνύουν επίσης τη δυσκολία στη διατήρηση υψηλής ακρίβειας σε συνθήκες domain shift, ενώ η βελτίωση μετά τη προσαρμογή τομέα παραμένει περιορισμένη. Τέλος, το Non-Linear SVM καταγράφει τη χαμηλότερη συνολική απόδοση, με χαμηλότερα επίπεδα F1-score και αστάθεια στις μετρικές ευαισθησίας/ειδικότητας. Παρά τη σχετική βελτίωση μετά τη προσαρμογή τομέα, η συνολική του απόδοση δεν καθίσταται ανταγωνιστική σε σχέση με τα άλλα μοντέλα.

Επομένως, το **k-NN** και το **XGBoost** αναδεικνύονται ως **τα πλέον αποδοτικά μοντέλα** για την παρούσα εργασία, επιτυγχάνοντας τον καλύτερο συνδυασμό ακρίβειας, ισορροπίας ανά κλάση και ανθεκτικότητας σε φαινόμενα domain shift.

7.3 Μελλοντικές επεκτάσεις

Βιβλιογραφία

- [1] Elham Babaei, Nor Badrul Anuar, Ainuddin Wahid Abdul Wahab, Shahaboddin Shamshirband, and Anthony T. Chronopoulos. “An Overview of Audio Event Detection Methods from Feature Extraction to Classification”. In: *Applied Artificial Intelligence* (2017).
- [2] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [3] Jawad Ahmad Dar, Kamal Kr Srivastava, and Alok Mishra. “Lung anomaly detection from respiratory sound database (sound signals)”. In: *Computers in Biology and Medicine* (2023).
- [4] Gaoyang Dong, Yufei Shen, Jianhong Wang, Mingli Zhang, Ping Sun, Peiyu Sun, and Minghui Zhang. “Respiratory sounds classification by fusing the time-domain and 2D spectral features”. In: *Biomedical Signal Processing and Control* (2025).
- [5] Abolfazl Farahani, Sahar Voghoei, Khaled Rasheed, and Hamid R. Arabnia. “A Brief Review of Domain Adaptation”. In: *Advances in Data Science and Information Engineering*. Ed. by Ralf Stahlbock, Georg M. Weiss, Mahmoud Abou-Nasr, Chih-Yuan Yang, Hamid R. Arabnia, and Leonidas Deligiannidis. Springer International Publishing, 2021.
- [6] Apar Garg, Yassine Aribi, Turke Althobaiti, and Tanmay Bhowmik. “An analysis of acoustic features for accented speech classification”. In: *Egyptian Informatics Journal* (2025).
- [7] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2009.
- [8] Md Tamzeed Islam and Shahriar Nirjon. “Sound-Adapter: Multi-Source Domain Adaptation for Acoustic Classification Through Domain Discovery”. In: *Proceedings of the 19th ACM Conference on Embedded Networked Sensor Systems (SenSys '21)*. Association for Computing Machinery, 2021.
- [9] Ian T. Jolliffe and Jorge Cadima. *Principal Component Analysis: A Review and Recent Developments*. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 2016.

- [10] June-Woo Kim, Sangmin Bae, Won-Yang Cho, Byungjo Lee, and Ho-Young Jung. “Stethoscope-Guided Supervised Contrastive Learning for Cross-Domain Adaptation on Respiratory Sound Classification”. In: *ICASSP 2024–2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024.
- [11] Yoonjoo Kim, YunKyong Hyon, Sung Soo Sung, Sunju Lee, Geon Yoo, Chauek Chung, and Taeyoung Ha. “Respiratory sound classification for crackles, wheezes, and rhonchi in the clinical field using deep learning”. In: *Scientific Reports* (2021).
- [12] Ron Kohavi. “A study of cross-validation and bootstrap for accuracy estimation and model selection”. In: *Proceedings of the 14th International Joint*. Morgan Kaufmann, 1995.
- [13] Michał Kośmider. “Spectrum Correction: Acoustic Scene Classification with Mismatched Recording Devices”. In: *Proceedings of the Annual Conference of the International Speech Communication Association (INTERSPEECH)*. ISCA, 2020.
- [14] Alexander Lerch. *An Introduction to Audio Content Analysis: Applications in Signal Processing and Music Informatics*. IEEE Press, Wiley, 2012.
- [15] Mingsheng Long, Zhangjie Cao, Jianmin Wang, and Michael I. Jordan. “Conditional Adversarial Domain Adaptation”. In: *Proceedings of the 32nd International Conference on Neural Information Processing Systems (NeurIPS)*. Curran Associates, Inc., 2018.
- [16] Laurens van der Maaten and Geoffrey Hinton. “Visualizing data using t-SNE”. In: *Journal of Machine Learning Research* (2008).
- [17] Francesco Mercaldo, Luca Brunese, Mario Cesarelli, Fabio Martinelli, and Antonella Santone. “Respiratory Disease Detection through Spectrogram Analysis with Explainable Deep Learning”. In: *Proceedings of the 8th International Conference on Smart and Sustainable Technologies (SpliTech)*. IEEE, 2023.
- [18] Renard Xavier Adhi Pramono, Stuart Bowyer, and Esther Rodriguez-Villegas. “Automatic adventitious respiratory sound analysis: A systematic review”. In: *PLOS ONE* (2017).
- [19] Renard Xavier Adhi Pramono, Syed Anas Imtiaz, and Esther Rodriguez-Villegas. “Evaluation of features for classification of wheezes and normal respiratory sounds”. In: *PLOS ONE* (2019).
- [20] Kostas N. Priftis, Leontios J. Hadjileontiadis, and Mark L. Everard, eds. *Breath Sounds: From Basic Science to Clinical Practice*. Springer, 2018.
- [21] B. M. Rocha, D. Filos, L. Mendes, I. Vogiatzis, E. Perantoni, E. Kaimakamis, P. Natsiavas, A. Oliveira, C. Jácome, A. Marques, R. P. Paiva, I. Chouvarda, P. Carvalho, and N. Maglaveras. “A Respiratory Sound Database for the Development of Automated Classification”. In: *Precision Medicine Powered by pHealth and Connected Health* (2018).

- [22] Malay Sarkar, Irappa Madabhavi, Narasimhalu Niranjana, and Megha Dogra. “Auscultation of the respiratory system”. In: *Annals of Thoracic Medicine* (2015).
- [23] Rui Wang, Mou Wang, Xiao-Lei Zhang, and Susanto Rahardja. “Domain Adaptation Neural Network for Acoustic Scene Classification in Mismatched Conditions”. In: *Proceedings of the Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*. IEEE, 2019.
- [24] Mahta Hassan Pour Zonoozi, Vahid Seydi, and Mahmood Deypir. “An unsupervised adversarial domain adaptation based on variational auto-encoder”. In: *Machine Learning* (2025).
- [25] Mahta Hassan Pour Zonoozi, Vahid Seydi, and Mahmood Deypir. “Variational inference based adversarial domain adaptation”. In: *Pattern Analysis and Applications* (2024).

Απόδοση ξενόγλωσσων όρων

Απόδοση

αδερφός
αμεταβλητότητα
ανάκτηση πληροφορίας
αντιμεταθετικότητα
απόγονος
απορρόφηση
βάση δεδομένων
γνώρισμα
διαπροσωπεία
διαφορά
δικτυακός κατάλογος
δικτυωτή δομή
δομικές επερωτήσεις
δομικές σχέσεις
δομικό σχήμα
εγκυρότητα
ένωση

Ξενόγλωσσος όρος

sibling
idempotency
information retrieval
commutativity
descendant
absorption
database
attribute
interface
difference
portal catalog
lattice
structural queries
structural relationships
schema
validity
union

