



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ
ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

Ταξινόμηση παθολογικών αναπνευστικών ήχων με τεχνικές μηχανικής μάθησης και προσαρμογής πεδίου

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ ΤΟΥ
ΦΟΙΤΗΤΗ

ΜΙΛΤΙΑΔΗ ΜΑΝΤΕ
Α.Μ. 1084661

ΤΡΙΜΕΛΗΣ ΕΠΙΤΡΟΠΗ
Κ. ΣΩΤΗΡΙΟΣ ΝΙΚΟΛΕΤΣΕΑΣ
ΚΑ ΕΥΗ ΠΑΠΑΪΩΑΝΝΟΥ
Κ. ΧΡΗΣΤΟΣ ΜΑΚΡΗΣ

?? ΣΕΠΤΕΜΒΡΙΟΥ 2025

Overview

ΔΙΑΡΘΡΩΣΗ ΠΑΡΟΥΣΙΑΣΗΣ

1

Ορισμός προβλήματος

5

Προσαρμογή πεδίου

2

Βασικό θεωρητικό υπόβαθρο

6

Ταξινόμηση & Αξιολόγηση

3

Προεπεξεργασία

7

Συμπεράσματα

4

Εξαγωγή χαρακτηριστικών


8

Συζήτηση & Μελλοντικές επεκτάσεις





Εκπαίδευση

Δοκιμή



1 Ορισμός προβλήματος


- Είναι γνωστό ότι οι αναπνευστικές παθήσεις όπως η χρόνια αποφρακτική πνευμονοπάθεια (ΧΑΠ), το άσθμα και η πνευμονία αποτελούν παγκοσμίως μείζονα αιτία νοσηρότητας και θνησιμότητας, επηρεάζοντας εκατομμύρια ανθρώπους και επιβαρύνοντας σημαντικά τα συστήματα υγείας.
- Η παρουσία **παθολογικών αναπνευστικών ήχων (crackles, wheezes)** στους αναπνευστικούς κύκλους καθώς και τα χαρακτηριστικά των ήχων αυτών αποτελούν **σημαντικούς βιοδείκτες** για την κλινική αξιολόγηση των παραπάνω νοσημάτων.
- Η ανάλυση των αναπνευστικών ήχων μέσω της **παραδοσιακής διαδικασίας ακρόασης** θα λέγαμε ότι προσφέρει μία **μη επεμβατική, χαμηλού κόστους και άμεσα διαθέσιμη μέθοδο** κλινικής αξιολόγησης. Ωστόσο, η ερμηνεία των ήχων και των συμπτωμάτων τους από τον ιατρό είναι μια διαδικασία η οποία **χαρακτηρίζεται από μεγάλο βαθμό υποκειμενικότητας**.
- Η **ανάπτυξη λοιπόν αυτοματοποιημένων μεθόδων ανάλυσης και ταξινόμησης αναπνευστικών ήχων**, βασισμένων σε τεχνικές μηχανικής μάθησης και βαθιάς μάθησης, δύναται να λειτουργήσει υποστηρικτικά στη διαδικασία λήψης ιατρικών αποφάσεων, μειώνοντας την **εξάρτηση από την υποκειμενική κρίση**.
- Ωστόσο, η **διαφοροποίηση των δεδομένων ή συνθηκών εκπαίδευσης σε σχέση με το περιβάλλον αξιολόγησης** των μοντέλων μπορεί να οδηγήσει σε **αξιοσημείωτη υποβάθμιση της απόδοσης** του συστήματος. Το φαινόμενο αυτό είναι γνωστό ως **domain shift** ή **μετατόπιση πεδίου** και στο πλαίσιο της επεξεργασίας ακουστικών δεδομένων μπορεί να προκύψει από πληθώρα παραγόντων, όπως η **διαφοροποίηση στα τεχνικά χαρακτηριστικά των συσκευών ηχογράφησης**, στις **συνθήκες ηχογράφησης** ή ακόμα και στο **προφίλ των ασθενών** από όπου συλλέγονται τα δεδομένα (ηλικία, φύλο, φυσική κατάσταση κ.τ.λ.).
- Στόχος είναι λοιπόν η **εκμάθηση σταθερών αναπαραστάσεων** που παραμένουν **ανεξάρτητες από τις συνθήκες καταγραφής ή τα χαρακτηριστικά της πηγής των δεδομένων**, διατηρώντας παράλληλα την ικανότητα του συστήματος να **διακρίνει με ακρίβεια τις κλάσεις ενδιαφέροντος**. Αυτή η διαδικασία ονομάζεται **προσαρμογή πεδίου**.



ΠΑΘΟΛΟΓΙΚΟΙ ΑΝΑΠΝΕΥΣΤΙΚΟΙ ΗΧΟΙ

Οι **ρόγχοι (crackles)** γενικά είναι **διαλείποντες, μη μουσικοί, βραχείας διάρκειας και εκρηκτικοί** ήχοι. Πρόκειται δηλαδή για ήχους που εμφανίζονται **στιγμιαία** και **ασυνεχώς** κατά τη διάρκεια του αναπνευστικού κύκλου, κυρίως **κατά την εισπνοή**. Επίσης, **δεν έχουν σταθερό τόνο** ή μελωδία και κάθε επιμέρους ήχος διαρκεί **ελάχιστα χιλιοστά του δευτερολέπτου**. Τέλος, ο χαρακτηρισμός εκρηκτικοί αποδίδει πιο διαισθητικά την ακουστική τους αίσθηση, καθώς πρόκειται για ήχους που ξεκινούν απότομα και θυμίζουν **μικρές εκρήξεις** ή σπάσιμο φυσαλίδων, γεγονός που αποδίδεται στις ταχείες μεταβολές πίεσης και τάσης κατά το άνοιγμα ή το κλείσιμο των αεραγωγών.

Οι **συριγμοί (wheezes)** είναι **συνεχόμενοι, μουσικοί, υψηλής συχνότητας** ήχοι που παράγονται κυρίως κατά τη φάση της **εκπνοής**, αν και σε σοβαρότερες περιπτώσεις μπορεί να εμφανίζονται και κατά την εισπνοή ή να έχουν **διφασικό χαρακτήρα**. Σαν ήχοι παρουσιάζουν **παρατεταμένη διάρκεια** και ακολουθούν σχετικά **σταθερό χρονικό μοτίβο**. Ο χαρακτηρισμός μουσικοί υποδηλώνει ότι διαθέτουν **σχεδόν σταθερή συχνότητα**, γεγονός που τους προσδίδει ακουστικά την αίσθηση ενός **λεπού σφυρίγματος**.



Η ΒΑΣΗ ΔΕΔΟΜΕΝΩΝ RSDB

Η παρούσα εργασία βασίζεται στη δημόσια διαθέσιμη βάση δεδομένων αναπνευστικών ήχων **RSDB** του επιστημονικού διαγωνισμού ICBHI 2017 (International Conference on Biomedical and Health Informatics). Συνολικά περιλαμβάνει **920 ηχογραφήσεις** από **126 ασθενείς**, οι οποίες πραγματοποιήθηκαν πάνω σε 7 θέσεις θώρακα: **τραχεία, αριστερά και δεξιά (πρόσθια, οπίσθια και πλάγια)**.







Συνολικά διατίθενται **6898 αναπνευστικοί κύκλοι**, με διάρκεια από έως ,καθένας από τους οποίους συνοδεύεται από σχολιασμό εξειδικευμένων ιατρών και φυσιοθεραπευτών σε annotation files ως προς την παρουσία:

- φυσιολογικών ήχων (**Normal**),
- παθολογικών ήχων (**Crackle, Wheeze**),
- συνδυασμού αυτών (**Both**).

Επίσης συνοδεύεται και από δημογραφικά μεταδεδομένα, όπως **φύλο, ηλικία, βάρος, ύψος** και **δείκτης BMI**.

Οι κύριες συσκευές καταγραφής που αξιοποιήθηκαν είναι:


- **Welch Allyn Master Elite Stethoscope (5079-400) [Lit3200]**: Ψηφιακό στηθοσκόπιο
- **3M Littmann Classic II SE [LitC2SE]**: Κλασικό αναλογικό στηθοσκόπιο
- **AKGC417L**: Αποτελεί τύπο electret μικροφώνου σχεδιασμένο για μη επεμβατικές μετρήσεις. Η συσκευή είναι αερόσυζευκτη (air-coupled) και προσφέρει εξαιρετικά ευαίσθητη καταγραφή ηχητικών σημάτων από την επιφάνεια του θώρακα.
- **Meditron**: Πρόκειται για ψηφιακό ηλεκτρονικό στηθοσκόπιο υψηλής ευαισθησίας που χρησιμοποιήθηκε ως τυπική συσκευή αναφοράς στον διαγωνισμό ICBHI.



Η κατηγορία **Both** στη συγκεκριμένη εργασία δεν μας απασχόλησε, συνεπώς **αφαιρέθηκαν όλες οι εγγραφές με τη συγκεκριμένη ετικέτα**. Έτσι, παρέμειναν **6392** αναπνευστικοί κύκλοι, οι οποίοι χωρίστηκαν σε **training** και **test set** με αναλογία **80:20**.



Η ανομοιογένεια της βάσης δεδομένων που παρατηρούμε ενισχύεται ακόμα παραπάνω από τη χρήση **διαφορετικών συσκευών και μεθόδων καταγραφής**, γεγονός που εισάγει φυσικό **domain shift**.

2 Βασικό θεωρητικό υπόβαθρο






Το αναπνευστικό σύστημα

περιλαμβάνει τη **ροή του αέρα** από την **τραχεία** και τους **βρόγχους** προς τις **κυψελίδες**, όπου πραγματοποιείται η **ανταλλαγή αερίων**. Κατά τη δίοδο του αέρα δημιουργούνται **στροβιλισμοί** και **δονήσεις**, οι οποίες αποτελούν την πηγή των αναπνευστικών ήχων.



Οι **δονήσεις** αυτές καταγράφονται μέσω **στηθοσκοπίων** και **ηλεκτρονικών αισθητήρων**. Η **μεμβράνη (diaphragm)** του στηθοσκοπίου ή του μικροφώνου **ταλαντώνεται** από τις μεταβολές της πίεσης και μετατρέπει τους ήχους σε **ηλεκτρικό σήμα**, το οποίο στη συνέχεια **ψηφιοποιείται**.

Η καταγραφή πραγματοποιείται μέσω τοποθέτησης των ειδικών συσκευών σε συγκεκριμένα σημεία του **θώρακα** και της **ράχης**, ώστε να αποτυπώνονται οι ήχοι που προέρχονται από διαφορετικά τμήματα των πνευμόνων. Η επιλογή των θέσεων είναι κρίσιμη για την αξιόπιστη διάγνωση και ανάλυση.




Το αναλογικό σήμα του αναπνευστικού ήχου που προκύπτει από την καταγραφή οδηγείται αρχικά σε **ενίσχυση** και στη συνέχεια σε μετατροπέα αναλογικού σε ψηφιακό σήμα (**A/D converter**). Εκεί εφαρμόζεται **δειγματοληψία**, δηλαδή καταγραφή τιμών του σήματος σε τακτά χρονικά διαστήματα και **κβάντιση**, δηλαδή αποτύπωση των τιμών σε διακριτά επίπεδα πλάτους. Το αποτέλεσμα είναι μια **ψηφιακή ακολουθία**, η οποία υφίσταται **δυναμική κωδικοποίηση** και μπορεί πλέον να αποθηκευτεί και να υποβληθεί σε υπολογιστική επεξεργασία.

Μετά τη ψηφιοποίηση του αναπνευστικού σήματος μπορούμε να το αναπαραστήσουμε είτε στο **πεδίο του χρόνου** είτε στο **πεδίο του χρόνου-συχνότητας**. Η **κυματομορφή** (waveform) αποτελεί την απλούστερη αναπαράσταση στο πεδίο του χρόνου, η οποία παρουσιάζει τις **στιγμιαίες διακυμάνσεις του σήματος** και επιτρέπει την οπτική διάκριση των φάσεων της αναπνοής και τυχόν ανωμαλιών.

Το **φασματογράφημα** προκύπτει εφαρμόζοντας τον **Μετασχηματισμό Fourier Βραχέως Χρόνου (STFT)**, ο οποίος αναλύει το σήμα σε μικρότερα χρονικά τμήματα. Με αυτόν τον τρόπο, απεικονίζεται ταυτόχρονα η **εξέλιξη** του σήματος **στον χρόνο** και η **κατανομή της ενέργειας** στις διάφορες **συχνότητες**. Η χρωματική κλίμακα αποδίδει την ένταση του ήχου ανά συχνότητα και χρονική στιγμή, επιτρέποντας την ανίχνευση χαρακτηριστικών προτύπων που δεν είναι ορατά στην απλή κυματομορφή.

Βασική Αρχή Λειτουργίας STFT

1. Το σήμα **διασπάται** σε διαδοχικά τοπικά χρονικά **καρέ** (frames) μέσα στα οποία το σήμα θεωρείται προσεγγιστικά **στάσιμο**.
2. Συχνά εφαρμόζεται και **επικάλυψη** (overlap) μεταξύ διαδοχικών καρέ, δηλαδή διατηρείται **κοινό ένα τμήμα του σήματος** μεταξύ τους. Έτσι αποφεύγονται ασυνέχειες ή απότομες μεταβολές μεταξύ καρέ.
3. Σε κάθε καρέ το σήμα **πολλαπλασιάζεται με μια συνάρτηση παραθύρου** $w[n]$, η οποία δίνει μεγαλύτερη έμφαση στο κέντρο και μειώνει σταδιακά την επιρροή των άκρων. Έτσι, αποφεύγεται η διαρροή φασματικής πληροφορίας. Οι πιο διαδεδομένες συναρτήσεις είναι τα παράθυρα **Hann, Hamming**.
4. Εντός κάθε καρέ εφαρμόζεται στο τελικό σήμα ο **Διακριτός Μετασχηματισμός Fourier** (DFT). Αφού υπολογιστεί εξάγεται η **ισχύς της απόκρισης πλάτους** που προέκυψε, η οποία χρωματίζεται κατάλληλα ανάλογα με την **ένταση** του σήματος που αντιστοιχεί στη συχνότητα k κατά τη χρονική στιγμή m .





ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΘΟΔΟΛΟΓΙΑ




ΤΟ **PREPROCESSING MODULE** ΕΧΕΙ ΩΣ ΣΤΟΧΟ ΤΗΝ ΤΥΠΟΠΟΙΗΣΗ ΚΑΙ ΚΑΘΑΡΙΣΜΟ ΤΩΝ ΕΙΣΕΡΧΟΜΕΝΩΝ ΑΝΑΠΝΕΥΣΤΙΚΩΝ ΚΥΚΛΩΝ, ΩΣΤΕ ΝΑ ΔΙΑΣΦΑΛΙΣΤΕΙ Η ΟΜΟΙΟΜΟΡΦΙΑ ΤΩΝ ΔΕΔΟΜΕΝΩΝ ΠΡΙΝ ΑΠΟ ΤΗ ΔΙΑΔΙΚΑΣΙΑ ΕΞΑΓΩΓΗΣ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ.

ΤΟ **FEATURE EXTRACTION MODULE** ΕΧΕΙ ΩΣ ΣΤΟΧΟ ΤΗΝ ΕΞΑΓΩΓΗ ΤΩΝ ΑΚΟΥΣΤΙΚΩΝ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΑΠΟ ΤΑ ΠΡΟΕΠΕΞΕΡΓΑΣΜΕΝΑ .WAV ΑΡΧΕΙΑ ΤΩΝ ΑΝΑΠΝΕΥΣΤΙΚΩΝ ΚΥΚΛΩΝ, ΔΗΛΑΔΗ ΤΗΝ ΔΗΜΙΟΥΡΓΙΑ ΤΟΥ ΤΕΛΙΚΟΥ ΜΗΤΡΩΟΥ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ.

ΤΟ **DOMAIN ADAPTATION MODULE** ΕΧΕΙ ΩΣ ΣΤΟΧΟ ΔΥΟ ΠΡΑΓΜΑΤΑ: ΝΑ ΑΦΑΙΡΕΣΕΙ ΜΕΣΩ DEEP ADVERSARIAL-BASED ΤΕΧΝΙΚΩΝ ΑΠΟ ΤΑ ΔΕΔΟΜΕΝΑ ΤΗ ΜΕΡΟΛΗΨΙΑ ΤΗΣ ΣΥΣΚΕΥΗΣ ΚΑΝΟΝΤΑΣ ΤΑ ΠΕΡΙΣΣΟΤΕΡΟ ΕΠΙΚΑΛΥΠΤΟΜΕΝΑ ΩΣ ΠΡΟΣ ΤΙΣ ΣΥΣΚΕΥΕΣ ΚΑΙ ΤΑΥΤΟΧΡΟΝΑ ΝΑ ΚΑΝΕΙ ΤΑ ΔΕΔΟΜΕΝΑ ΑΚΟΜΗ ΠΙΟ ΔΙΑΧΩΡΙΣΙΜΑ ΩΣ ΠΡΟΣ ΤΙΣ ΚΛΑΣΕΙΣ.

ΤΟ **CLASSIFICATION MODULE** ΣΤΟ ΤΕΛΟΣ ΕΧΕΙ ΩΣ ΣΤΟΧΟ ΤΗΝ ΔΗΜΙΟΥΡΓΙΑ ΤΩΝ ΠΡΟΒΛΕΨΕΩΝ ΓΙΑ ΤΙΣ ΚΛΑΣΕΙΣ ΧΡΗΣΙΜΟΠΟΙΩΝΤΑΣ ΤΟΥΣ ΚΛΑΣΙΚΟΥΣ ΑΛΓΟΡΙΘΜΟΥΣ ΤΑΞΙΝΟΜΗΣΗΣ ΜΕ ΕΙΣΟΔΟ ΤΙΣ ΕΝΣΩΜΑΤΩΣΕΙΣ ΜΕ ΤΑ ΔΕΔΟΜΕΝΑ, ΔΗΛΑΔΗ ΤΟ ΝΕΟ ΜΗΤΡΩΟ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΠΟΥ ΕΞΗΧΘΗ ΑΠΟ ΤΟ DOMAIN ADAPTATION MODULE.

3 Προεπεξεργασία



ΕΠΑΝΑΔΕΙΓΜΑΤΟΛΗΨΙΑ











ΚΑΝΟΝΙΚΟΠΟΙΗΣΗ
ΔΙΑΡΚΕΙΑΣ



ΚΑΝΟΝΙΚΟΠΟΙΗΣΗ
ΠΛΑΤΟΥΣ



ΑΠΟΘΟΡΥΒΟΠΟΙΗΣΗ



ΕΠΑΝΑΔΕΙΓΜΑΤΟΛΗΨΙΑ



ΚΑΝΟΝΙΚΟΠΟΙΗΣΗ
ΔΙΑΡΚΕΙΑΣ



ΚΑΝΟΝΙΚΟΠΟΙΗΣΗ
ΠΛΑΤΟΥΣ



ΑΠΟΘΟΡΥΒΟΠΟΙΗΣΗ

Πρόκειται για τη διαδικασία **μετατροπής της συχνότητας δειγματοληψίας** ενός διακριτού σήματος από μια **αρχική τιμή f_s** σε μια νέα, **επιθυμητή συχνότητα $f's$** . Ουσιαστικά, το σήμα $x[n]$ αναδομείται σε μια νέα μορφή $x'[m]$ που αντιστοιχεί σε διαφορετική χρονική ανάλυση. Η ανάγκη για επαναδειγματοληψία προκύπτει από το γεγονός ότι τα σήματα έχουν καταγραφεί με διαφορετικές συχνότητες ανάλογα με τη συσκευή καταγραφής. Η **κοινή συχνότητα δειγματοληψίας** έχει επιλεχθεί να είναι τα **4 kHz**.

Συσκευή	Συχνότητα δειγματοληψίας
Meditron	4 kHz
Litt3200	4 kHz
LittC2SE	4 kHz
AKGC417L	44.1 kHz


Πρόκειται για τη διαδικασία **καθορισμού των χρονικών ορίων** της διάρκειας κάθε αναπνευστικού κύκλου σε **κοινή κλίμακα**. Η σταθερότητα αυτή των διαστάσεων διευκολύνει την λειτουργία των μοντέλων μηχανικής μάθησης. Ως **κοινή διάρκεια** έχουν επιλεχθεί τα **3 s** και συνεπώς σήματα με **μεγαλύτερη διάρκεια** αποκόπτονται μέσω **trimming** αφαιρώντας τις τιμές των δειγμάτων από το τέλος μέχρι να φτάσουμε στην επιθυμητή διάρκεια. Από την άλλη, σήματα με **μικρότερη διάρκεια** συμπληρώνονται μέσω **circular padding**, δηλαδή γίνεται κυκλική επανάληψη των δειγμάτων του σήματος σαν να ήταν περιοδικό. Έτσι δεν εισάγουμε απότομες μεταβάσεις στο σήμα, οι οποίες ενδέχεται να εκληφθούν ως τεχνητοί θόρυβοι ή παθολογικά γεγονότα.

Πρόκειται για τη διαδικασία **μετατροπής των σημάτων σε κοινή κλίμακα έντασης**. Πιο συγκεκριμένα, το σήμα $x[n]$ διαιρείται με τη μέγιστη απόλυτη τιμή του ώστε το νέο σήμα να έχει μέγιστο πλάτος ίσο με 1. Το επιλεγμένο **εύρος τιμών για το πλάτος** όλων των αναπνευστικών κύκλων έχει τεθεί στο διάστημα **[-1, 1]**.

Πρόκειται για τη διαδικασία **απομάκρυνσης θορυβώδων ή ανεπιθύμητων συνιστωσών** που δεν σχετίζονται με την επιθυμητή φυσιολογική ή παθολογική πληροφορία. την περίπτωση των αναπνευστικών σημάτων, αυτοί οι θόρυβοι μπορεί να προέρχονται από ήχους του περιβάλλοντος, καρδιακούς ήχους που επικαλύπτουν το αναπνευστικό σήμα σε χαμηλές συχνότητες ή και μηχανικούς θορύβους από το ίδιο το στηθοσκόπιο. Έτσι, εφαρμόστηκε **ψηφιακό φίλτρο Butterworth 5ης τάξης για διέλευση υψηλών συχνοτήτων (high-pass)** με στόχο την απομάκρυνση των **ανεπιθύμητων χαμηλών συχνοτήτων** από τη καρδιά και το περιβάλλον, οι οποίες κυμαίνονται στο διάστημα **0-100 Hz**. Για το λόγο αυτό, επιλέχθηκε ως **συχνότητα αποκοπής** η **$f_c=100$ Hz**.

ΕΠΑΥΞΗΣΗ ΑΝΑΠΝΕΥΣΤΙΚΩΝ ΚΥΚΛΩΝ

VTLP Effect Visualization - Sample 1 of Training set



Η τεχνική **Vocal Tract Length Perturbation (VTLP)** εφαρμόζεται για την επαύξηση των αναπνευστικών κύκλων μέσω παραμόρφωσης στη συχνотική κλίμακα, **προσομοιώνοντας διαφοροποιήσεις στη φυσιολογία του φωνητικού/αναπνευστικού σωλήνα**. Με αυτόν τον τρόπο δημιουργούνται ελαφρώς παραλλαγμένες εκδοχές του ίδιου σήματος, διατηρώντας τη φασματική του δομή αλλά **εμπλουτίζοντας το σύνολο εκπαίδευσης**. Το Patch Augmentation συνδυάζει πολλαπλές τέτοιες παραμορφώσεις, ενισχύοντας τη γενίκευση του μοντέλου και μειώνοντας τον κίνδυνο υπερεκπαίδευσης.

Βασική Αρχή Λειτουργίας VTLP-Patch Augmentation


$$L(t) = \begin{cases} t\alpha, & t \leq \frac{F_{hi} \cdot \min(\alpha, 1)}{\alpha} \\ \frac{S/2 - F_{hi} \cdot \min(\alpha, 1)}{S/2 - F_{hi}} \cdot (S/2 - t), & \text{αλλιώς} \end{cases}$$

$$x_w(t) = \lambda \cdot x_o \left(F^{-1} (F \cdot L(t)) \right) + \eta(t)$$

όπου:

- $x_o(t)$ είναι το κανονικοποιημένο αρχικό σήμα,
- $F(\cdot)$ ο μετασχηματισμός STFT του $x_o(t)$,
- $F^{-1}(\cdot)$ ο αντίστροφος μετασχηματισμός STFT,
- λ ο συντελεστής ενίσχυσης της έντασης,
- $\eta(t)$ προσθετικός λευκός θόρυβος (*Gaussian white noise*).

4 Εξαγωγή χαρακτηριστικών



Για την εξαγωγή των ακουστικών χαρακτηριστικών χρησιμοποιείται πάλι ο **STFT** ως θεμελιώδες εργαλείο. Για την υλοποίηση του STFT οι αναπνευστικοί κύκλοι διάρκειας 3s διαχωρίστηκαν σε **frames διάρκειας 60ms** και **βήμα επικάλυψης 30ms**, δηλαδή ποσοστό **50%**.

1. Για κάθε προεπεξεργασμένο αναπνευστικό κύκλο ξεχωριστά εξάγονται **41 διαφορετικά χαρακτηριστικά** σε επίπεδο **frames**. Συνεπώς για κάθε κύκλο παράγεται ένα **μητρώο χαρακτηριστικών** με διαστάσεις (**#frames, #features**).
2. Τα μητρώα χαρακτηριστικών από όλους τους αναπνευστικούς κύκλους **συγχωνεύονται σε έναν τανυστή 3 διαστάσεων** με σχήμα (**#cycles, #frames, #features**).
3. Για να εξαχθεί μια **συμπαγής 2D αναπαράσταση** για τους κλασικούς αλγορίθμους ταξινόμησης, ο τανυστής χαρακτηριστικών **aggregation ως προς τον μέσο όρο κατά μήκος των frames**, έτσι ώστε να μειωθεί η διαστατικότητα των δεδομένων, αλλά παράλληλα διατηρηθεί η ουσιαστική πληροφορία σε επίπεδο αναπνευστικού κύκλου, αφού τα στατιστικά χαρακτηριστικά (mean) αποτυπώνουν επαρκώς τα μοτίβα που μας ενδιαφέρουν.
4. Έτσι, καταλήγουμε στο τελικό σύνολο αριθμητικών δεδομένων, δηλαδή ένα μητρώο με διαστάσεις (**#cycles, #features**).

ΠΕΡΙΓΡΑΦΗ ΕΞΑΓΜΕΝΩΝ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ

Zero Crossing Rate

Είναι ένα θεμελιώδες χρονικό χαρακτηριστικό που μετρά τον αριθμό των φορών που το πλάτος του σήματος αλλάζει πρόσημο εντός ενός χρονικού παραθύρου.

Εκφράζει δηλαδή τη συχνότητα με την οποία το σήμα «διέρχεται» από το μηδέν.

Root Mean Square Energy

Αποτελεί ένα μέτρο της στιγμιαίας ισχύος ή έντασης του σήματος εντός ενός καρέ. Υπολογίζεται ως η τετραγωνική ρίζα του μέσου τετραγώνου των

τιμών του σήματος και αποτυπώνει τη συνολική ενέργεια που «περιέχει» το σήμα σε δεδομένο χρονικό διάστημα.

Onset Envelope

Περιγράφει την εξέλιξη της στιγμιαίας ενεργοποίησης στο σήμα και χρησιμοποιείται για την ανίχνευση χρονικών συμβάντων (onsets), δηλαδή απότομων αλλαγών

στην ενέργεια ή τη δομή του σήματος, όπως η εμφάνιση παροδικού παθολογικού ήχου.

Specttral Centroid

Εκφράζει το «κέντρο μάζας» του φάσματος ενός σήματος και σχετίζεται άμεσα με το αντιληπτό «ύψος» ή την «οξύτητα» του ήχου, δηλαδή το pitch.

Spectral Bandwidth

Ποσοτικοποιεί τη διασπορά του φάσματος γύρω από το κέντρο βάρους του. Υπολογίζεται μαθηματικά ως η σταθμισμένη τυπική απόκλιση των συχνοτήτων από το spectral centroid

Spectral Flux

Μετρά την ποσότητα μεταβολής του φάσματος από καρέ σε καρέ. Εκφράζει πόσο αλλάζει το φασματικό περιεχόμενο στο χρόνο και υπολογίζεται ως η Ευκλείδεια απόσταση μεταξύ φασμάτων διαδοχικών χρονικών frames.

Spectral Flatness

Είναι ένας δείκτης αρμονικότητας ή θορυβώδους φύσης του σήματος. Η τιμή κυμαίνεται μεταξύ 0 και 1. Τείνει στο 1 για φάσματα τύπου λευκού θορύβου (flat)

και στο 0 για φάσματα με αιχμές σε επιλεγμένες συχνότητες (αρμονικά ή μουσικά σήματα).

Spectral Rolloff

Ορίζει τη συχνότητα κάτω από την οποία βρίσκεται ένα προκαθορισμένο ποσοστό της συνολικής φασματικής ενέργειας, συνήθως 85% ή 95%. Η τιμή του spectral

rolloff σχετίζεται επίσης με την ασυμμετρία της μορφής του φάσματος. Χρησιμοποιείται για

τη διάκριση μεταξύ ήχων με φασματική συμπίκνωση και ήχων με εκτεταμένο φάσμα.

MFCCs

Αποτελούν ένα από τα πιο διαδεδομένα χαρακτηριστικά στην ανάλυση ήχου και λόγου. Εξάγονται εφαρμόζοντας Fourier Transform, στη συνέχεια Mel-filterbank για προσομοίωση της ανθρώπινης ακοής και τέλος DCT (Discrete Cosine Transform) ώστε να εξαχθούν οι συντελεστές στο cepstral domain. Συμπυκνώνουν την καμπύλη φάσματος σε λίγους συντελεστές (συνήθως 12-13) που περιγράφουν αποτελεσματικά τα φωνητικά/ αναπνευστικά σήματα.

Log-Mel Filterbank Energies

Υπολογίζονται εφαρμόζοντας Mel-scaled φίλτρα στο φάσμα ισχύος του σήματος και κατόπιν λογαριθμίζοντας τα αποτελέσματα. Είναι ένα χαρακτηριστικό που συνοψίζει την πληροφορία «πόση ενέργεια υπάρχει σε ένα συγκεκριμένο εύρος συχνοτήτων, τη δεδομένη χρονική στιγμή, μετρώντας την όπως την αντιλαμβάνεται το ανθρώπινο αυτί». Συνήθως είναι σε πλήθος 40 ή 80 στο τελικό διάνυσμα χαρακτηριστικών.


Ο Π Τ Ι Κ Ο Π Ο Ι Η Σ Η Χ Α Ρ Α Κ Τ Η Ρ Ι Σ Τ Ι Κ Ω Ν

Σημειώνουμε αρχικά ότι παράγονται συνολικά περίπου **101 frames**, σύμφωνα με τον τύπο:

$$\left\lfloor \frac{3s - 60ms}{30ms} \right\rfloor + 1 = 98$$


Ωστόσο, η χρήση του ορίσματος **center=True** (π.χ. στη librosa.stft()) μπορεί να οδηγήσει σε επιπλέον καρέ πέρα από τα αυστηρά χρονικά όρια, γι' αυτό και στη πράξη βλέπουμε ότι προκύπτουν 101 αντί για 98.

- Τα **Crackles** εμφανίζουν **υψηλότερες τιμές σε Spectral Flux, Spectral Roll-off**, υποδεικνύοντας την απότομη και παροδική φύση τους.
- Τα **Wheezes** παρουσιάζουν **αυξημένο Spectral Flatness** και **μικρότερο ZCR**, κάτι που συμφωνεί με την πιο «αρμονική» και συνεχόμενη μορφή τους.
- Στα **MFCCs** και **Log-Mel Energies**, οι παθολογικοί ήχοι διατηρούν ξεχωριστές χρονικο-συχνοτικές υπογραφές, ιδιαίτερα σε **μεσαίες και υψηλές συχνότητες**, κάτι που τους καθιστά διαχωρίσιμους από τους φυσιολογικούς.




ΣΤΑΤΙΣΤΙΚΗ ΑΝΑΛΥΣΗ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ

KERNEL DENSITY PLOT





Πιο **διαχωριστικά** χαρακτηριστικά φαίνεται πως είναι οι **πρώτοι συντελεστές MFCC (1-3)**, το **Spectral Centroid**, το **Spectral Rolloff**, το **Zero Crossing Rate** και το **Spectral Flux**, ενώ **λιγότερο χρήσιμα** εμφανίζονται η **RMS Energy** και το **Spectral Flatness**.

BOXPLOT



Τα **Crackle** ξεχωρίζουν με το **Zero Crossing Rate** και τους **υψηλούς συντελεστές MFCC**, λόγω των απότομων αιχμών και βραχειών εκρήξεων. Αντίθετα, τα **Wheeze** διαχωρίζονται κυρίως μέσω του **Spectral Centroid**, του **Rolloff** και των **χαμηλών MFCCs**, καθώς έχουν μεγαλύτερη ενέργεια στις υψηλές συχνότητες.

ANOVA




Τα πιο **διαχωριστικά** χαρακτηριστικά, με βάση το **F-score** είναι τα **χαμηλά MFCCs (6,8,10,12)**, το **Spectral Centroid**, το **Spectral Bandwidth** και το **ZCR**. Αντίθετα, τα **υψηλά MFCCs** και **Log-Mel Energies** και δείκτες όπως το **RMS Energy & Flatness** έχουν **περιορισμένη συμβολή**.


FEATURE-CLASS HEATMAP



CORRELATION HEATMAP

ΕΠΙΛΟΓΗ 20
ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ


- **Crackle:** Διαχωρίζονται κυρίως από τους **υψηλούς και μεσαίους συντελεστές MFCC**, το **Onset Envelope**, ορισμένα **Log-Mel energies** και το **Spectral Flux**.
- **Normal:** Παρουσιάζουν **μέτριες προς υψηλές θετικές συσχετίσεις** με το **ZCR**, **RMS Energy** και τα **Spectral Centroid**, **Bandwidth**, **Flux** ενώ **υψηλή αρνητική συσχέτιση** υπάρχει με τα περισσότερα **MFCCs** και τα **υψηλά Log-Mel energies**.
- **Wheeze:** Έχουν **ισχυρές θετικές συσχετίσεις** με τα περισσότερα **MFCCs**, ενώ **αρνητικές** με τα **Spectral Centroid**, **Bandwidth**, **ZCR**, **RMS Energy** και τα **χαμηλότερα Log-Mel energies**.




- Τα **MFCCs** εμφανίζουν **υψηλή εσωτερική συσχέτιση**, ιδιαίτερα οι χαμηλοί-μεσαίοι MFCCs (1-10) μεταξύ τους.
- Το **Spectral Centroid**, το **Spectral Rolloff** και το **Spectral Bandwidth** παρουσιάζουν **πολύ υψηλή συσχέτιση** μεταξύ τους (κόκκινο block), κάτι αναμενόμενο καθώς όλα αποτυπώνουν μετατοπίσεις του φάσματος προς υψηλότερες συχνότητες.
- Το **ZCR** έχει **θετική συσχέτιση** με **χαρακτηριστικά υψηλών συχνοτήτων** (Centroid, Rolloff), αλλά **αρνητική με χαμηλούς MFCCs**.
- Το **RMS Energy** και το **Spectral Flux** εμφανίζουν **μέτριες συσχετίσεις** με διάφορους **MFCCs**, αλλά όχι τόσο ισχυρές όσο τα παραπάνω.
- Το **Spectral Flatness** σχετίζεται **αρνητικά με χαμηλής ενέργειας χαρακτηριστικά (RMS)**, καθώς περιγράφει «λευκότητα» του σήματος.
- Τα **Log-Mel energies** παρουσιάζουν **υψηλή θετική συσχέτιση** σε γειτονικά φίλτρα, ενώ χαμηλές-υψηλές συχνότητες έχουν **αρνητική συσχέτιση**, αντικατοπτρίζοντας τη μετατόπιση της ενέργειας στο φάσμα.

MFCC_5 *MFCC_2*
On Set Envelope *MFCC_9*
MFCC_11 *Spectral Centroid*
MFCC_7 *RMS Energy*
MFCC_4 *MFCC_3*

Spectral Rolloff *MFCC_6*
MFCC_8 *Log_Mel_5*
Spectral Bandwidth *Log_Mel_4*
Spectral Flux *Log_Mel_6*
MFCC_1 *Zero Crossing Rate*





5 Προσαρμογή πεδίου



- Υπάρχει **εμφανής μετατόπιση πεδίου**, καθώς βλέπουμε ότι **οι κατανομές** στην πλειοψηφία των επιλεγμένων χαρακτηριστικών **διαφέρουν στη μορφή** και είναι **μετατοπισμένες**, ειδικά όσον αφορά τη συσκευή **Litt3200**. Τα φαίνεται επίσης να ομαδοποιούνται περισσότερο με βάση τη συσκευή καταγραφής, παρά την κατηγορία ήχου, δημιουργώντας καθαρές συστάδες στο επίπεδο. Αυτό **μειώνει τη διαχωριστικότητα των χαρακτηριστικών ανά κατηγορία**, αφού οι διαφορές που εισάγει κάθε συσκευή (domain) υπερκαλύπτουν τις πραγματικές διαφορές μεταξύ των παθήσεων.

Σκοπός του συγκεκριμένου module είναι, με τη χρήση τεχνικών **deep adversarial-based domain adaptation**, να επιτευχθεί όχι μόνο η **μέγιστη επικάλυψη των domains** (διαφορετικών συσκευών), αλλά ταυτόχρονα και η **ενίσχυση της διαχωριστικότητας των κλάσεων**, ώστε τα μοντέλα να εστιάζουν στην παθολογία και όχι στην πηγή καταγραφής. Για να επιτευχθεί αυτό δημιουργούνται νέες **ενδιάμεσες αναπαραστάσεις** των αρχικών χαρακτηριστικών σε χώρους κατάλληλων διαστάσεων όπου εξασφαλίζονται και οι δύο συνθήκες.




DOMAIN ADVERSARIAL NEURAL NETWORK (DANN)

Η αρχιτεκτονική του DANN χωρίζεται σε τρία βασικά τμήματα:

- **Feature extractor** (πράσινο): μαθαίνει μια αναπαράσταση των δεδομένων.
- **Label classifier** (μπλε): προβλέπει την κατηγορία του ήχου (π.χ. Crackle, Wheeze, Normal).
- **Domain classifier** (ροζ): προσπαθεί να αναγνωρίσει τη συσκευή καταγραφής.


Layers	Output Shape	Param #
Linear	[64, 64]	2,688
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Dropout	[64, 64]	0
Linear	[64, 128]	8,320
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 256]	33,024
BatchNorm1d	[64, 256]	512
ReLU	[64, 256]	0

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 3]	195



- Το κρίσιμο στοιχείο είναι το **Gradient Reversal Layer (GRL)**, το οποίο κατά το **forward pass** λειτουργεί σαν **ταυτοτική συνάρτηση**, αλλά στο **backward pass** αντιστρέφει το πρόσημο των κλίσεων πολλαπλασιάζοντας το gradient με μια αρνητική σταθερά $-\alpha$.
- Με αυτόν τον τρόπο, ο Feature Extractor «ενθαρρύνεται» να μάθει **αναπαραστάσεις που δυσκολεύουν τον Domain Classifier**, δηλαδή αναπαραστάσεις invariant ως προς το domain, ενώ παραμένουν χρήσιμες για τη σωστή ταξινόμηση των κατηγοριών.
- Εκπαιδεύεται με το classification loss για σωστή πρόβλεψη κλάσης και το domain loss, το οποίο σταθμίζεται με την υπερπαράμετρο λ ώστε να **ελέγχεται η επίδραση του domain invariance μέσω του GRL**.


Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 3]	195



Το DANN εκπαιδεύτηκε για **200 εποχές**, με ρυθμό μάθησης $\eta = 0.001$ και $\lambda=0.1$. Επίσης, το αρνητικό διάνυσμα $-a$ με το οποίο πολλαπλασιάζεται το gradient στο GRL **αυξάνεται εκθετικά** κατά τη διάρκεια της εκπαίδευσης στο διάστημα **[0, 1]**.


- **Total Loss:** Μειώνεται σταθερά και **συγκλίνει** γύρω στο **0.4 (val)** και **0.3 (train)**, τιμές αρκετά χαμηλές που δείχνουν καλή ισορροπία ανάμεσα σε classification και domain losses.
- **Classification Loss:** Μειώνεται σταθερά καθώς ξεκινάει από 0.9 και **συγκλίνει** γύρω στο **0.4**, που είναι καλή τιμή για cross-entropy loss. Αυτό δείχνει ότι **οι προβλέψεις του μοντέλου είναι σχετικά «σίγουρες»** και η διαχωριστικότητα των κατηγοριών είναι αρκετά καλή χωρίς σημάδια υπερεκπαίδευσης.
- **Domain Loss:** Ξεκινάει από χαμηλά και **αυξάνεται συγκλίνοντας** γύρω στο **0.25-0.27**, τιμή που θεωρείται σχετικά υψηλή για MSE loss. Αυτό είναι επιθυμητό στη δικιά μας περίπτωση, καθώς σημαίνει ότι **ο Domain Classifier δεν μπορεί να ξεχωρίσει εύκολα τις συσκευές**, κάνοντας σχεδόν τυχαίες προβλέψεις.

- Βλέπουμε ότι οι κατηγορίες **Normal** και **Wheeze** σχηματίζουν **σαφείς και ξεχωριστές συστάδες**, δείχνοντας ότι τα χαρακτηριστικά τα διαχωρίζουν αποτελεσματικά. Η **συνολική διαχωριστικότητα** συνεπώς μεταξύ παθολογιών **έχει βελτιωθεί αισθητά**, αλλά **δεν είναι πλήρης λόγω των Crackle**.
- Οι συσκευές παρουσιάζουν μια **μέτρια επικάλυψη** χωρίς ξεκάθαρα όρια, γεγονός που δείχνει ότι **το domain shift έχει περιοριστεί** σε μεγάλο βαθμό αλλά **εξακολουθεί να υπάρχει**.



CONDITIONAL DOMAIN ADVERSARIAL NETWORK (CDAN)


Layers	Output Shape	Param #
Linear	[64, 128]	5,376
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 256]	33,024
BatchNorm1d	[64, 256]	512
ReLU	[64, 256]	0



Layers	Output Shape	Param #
Linear	[64, 128]	32,896
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 3]	387

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 3]	195



- Στο DANN η στοίχιση domains γίνεται **μόνο με βάση τα features**, ανεξάρτητα από το σε ποια κλάση ανήκει το δείγμα. Αυτό μπορεί να οδηγήσει σε «λάθος» στοίχιση (π.χ. instances από wheezes να στοιχίζονται με crackles, μόνο και μόνο επειδή προέρχονται από την ίδια συσκευή).
- Το CDAN επεκτείνει τη βασική ιδέα του DANN, εισάγοντας την έννοια του **conditional adversarial learning**. Έτσι, εκτός από τις αναπαραστάσεις των χαρακτηριστικών **λαμβάνονται υπόψη και οι προβλέψεις της κλάσης** που αντιστοιχούν σε αυτές, ώστε **η στοίχιση των domains να εξαρτάται και από την πληροφορία που φέρει η κλάση**.
- Αυτό υλοποιείται με το **multilinear map**, το οποίο τροφοδοτεί τον Domain classifier. Στην πράξη, υλοποιείται ως το **εξωτερικό γινόμενο** (outer product) μεταξύ του **διανύσματος χαρακτηριστικών** και του **διανύσματος πιθανοτήτων κατηγορίας**.



Το CDAN εκπαιδεύτηκε για **200 εποχές**, με ρυθμό μάθησης $\eta = 0.001$ και $\lambda=0.2$. Επίσης, το αρνητικό διάνυσμα $-a$ με το οποίο πολλαπλασιάζεται το gradient στο GRL **αυξάνεται εκθετικά** κατά τη διάρκεια της εκπαίδευσης **στο διάστημα [0, 1]**.

- Οι κατηγορία **Wheeze** σχηματίζει **συμπαγείς και ευδιάκριτες συστάδες** με καθαρά όρια. Τα **Crackle** παραμένουν **πιο διασκορπισμένα**, αλλά με **βελτιωμένο διαχωρισμό** από τη κλάση Normal σε σχέση με πριν. Τέλος, τα δείγματα της κλάσης **Normal** εμφανίζουν μερική επικάλυψη με τις παθολογικές κατηγορίες, αλλά η **συνολική δομή** είναι πιο **οργανωμένη**.
- Οι συσκευές παρουσιάζουν **πλήρη επικάλυψη**, γεγονός που δείχνει ότι **το domain shift έχει περιοριστεί σχεδόν τέλεια**.


- **Total Loss**: Κατεβαίνει ομαλά και σταθεροποιείται σε χαμηλό επίπεδο κοντά στο **0.1-0.2**, βρίσκοντας **καλύτερη ισορροπία** ισορροπία ανάμεσα στο classification loss και στο domain loss, χωρίς σημάδια υπερεκπαίδευσης.
- **Classification Loss**: Σταθεροποιείται ελαφρώς χαμηλότερα γύρω στο **0.4 (val)** και **0.3 (train)** έχοντας ωστόσο ελαφρώς μεγαλύτερη απόκλιση ανάμεσα σε εκπαίδευση και επικύρωση. Ωστόσο, τα χαρακτηριστικά που μαθαίνονται είναι **πιο διαχωρίσιμα ανά κατηγορία**, άρα βελτιώνεται η πραγματική απόδοση στη πράξη.
- **Domain Loss**: Ξεκινάει πάλι από χαμηλά και **αυξάνεται συγκλίνοντας** σε ελαφρώς χαμηλότερες τιμές από το DANN, γύρω στο **0.20-0.23**, πολύ πιο κοντά στην τιμή 0.1875 που αντιστοιχεί στο τυχαίο σφάλμα (random guess) για MSE με 4 domains.



DANN ME VAE ΩΣ FEATURE EXTRACTOR

Layers	Output Shape	Param #
Linear	[64, 512]	21,504
ReLU	[64, 512]	0
Linear	[64, 256]	131,328
ReLU	[64, 256]	0
Linear (μ)	[64, 16]	4,112
Linear (σ)	[64, 16]	4,112

- Ο **Encoder** χαρτογραφεί τα δεδομένα εισόδου $\mathbf{x}$ σε έναν **λανθάνοντα χώρο διανυσμάτων $\mathbf{z}$** , τα οποία ορίζουν μια **πιθανοτική κατανομή $q(\mathbf{z}|\mathbf{x})$** .
- Έτσι, για κάθε **instance $\mathbf{x}$** αντί να παράγει μόνον ένα σημείο, δηλαδή ένα σταθερό embedding, παράγει τις παραμέτρους μιας ολόκληρης κατανομής με **μέση τιμή $\mu(\mathbf{x})$** και **διασπορά $\sigma(\mathbf{x})$** .




Ο VAE εκπαιδεύεται ελαχιστοποιώντας το **reconstruction loss** (πιστή ανακατασκευή) και **KL-divergence** (κανονικοποίηση του λανθάνοντα χώρου), με τον υπερπαράμετρο β να ελέγχει το **βάρος του KL**.

$$\mathcal{L}_{recon} + \beta \mathcal{L}_{KL}$$

Layers	Output Shape	Param #
Linear	[64, 256]	4,352
ReLU	[64, 256]	0
Linear	[64, 41]	10,537

- Ο **Decoder** λαμβάνει ως είσοδο ένα δείγμα από τον λανθάνοντα χώρο $\mathbf{z}$ και **επιχειρεί να ανακατασκευάσει** το αρχικό δεδομένο $\mathbf{x}$.
- Η επιλογή του $\mathbf{z}$ γίνεται μέσω του **reparameterization trick** ($\mathbf{z} = \mu(\mathbf{x}) + \sigma(\mathbf{x}) \cdot \epsilon$, $\epsilon \sim N(0, I)$), δηλαδή μέσω δειγματοληψίας από τυχαίο θόρυβο ϵ που μετασχηματίζεται με βάση τη μέση τιμή και τη διασπορά, ώστε η διαδικασία να παραμένει διαφορίσιμη. Ουσιαστικά, υλοποιεί την πιθανότητα $p_{\theta}(\mathbf{x}|\mathbf{z})$, δηλαδή το γενετικό μοντέλο που «παράγει» δεδομένα από λανθάνουσες αναπαραστάσεις.
- Έτσι εξασφαλίζεται ότι ο **λανθάνων χώρος** είναι **συνεχής** και **κανονικοποιημένος**, διευκολύνοντας το DANN να βρει ενδιάμεσες αναπαραστάσεις που είναι **περισσότερο invariant** ως προς το **domain**.



$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{\text{dom}} + \mathcal{L}_{\text{recon}} + \beta \mathcal{L}_{\text{KL}}$$




Το DANN και ο VAE εκπαιδεύτηκαν **ταυτόχρονα** για **100 εποχές**, με ρυθμό μάθησης **$\eta = 0.001$** , **$\lambda=0.2$** και **$\beta=1.0$** . Επίσης, το αρνητικό διάνυσμα **$-a$** με το οποίο πολλαπλασιάζεται το gradient στο GRL **αυξάνεται εκθετικά** κατά τη διάρκεια της εκπαίδευσης **στο διάστημα $[0, 1]$** .

- Βλέπουμε ότι οι κατηγορίες **Crackle**, **Normal** και **Wheeze** σχηματίζουν **πολύ καθαρές συστάδες** με πολύ **βελτιωμένη διαχωρισιμότητα** σε σχέση με πριν. Ίσως μόνο η κατηγορία Crackle να εμφανίζει μερική επικάλυψη, αλλά χωρίς να επηρεάζει σημαντικά τη συνολική διάκριση των κλάσεων.
- Οι συσκευές παρουσιάζουν **έντονη επικάλυψη** χωρίς σαφή όρια, γεγονός που υποδηλώνει ότι **το domain shift έχει εξουδετερωθεί** αρκετά έντονα.

- **Classification Loss:** Ξεκινάει σχετικά ψηλά αλλά **μειώνεται απότομα** και **σταθεροποιείται σε χαμηλά επίπεδα** (**train** γύρω στο **0.025**, **val** γύρω στο **0.075**). Η απόκλιση train-val παραμένει σταθερή και μικρή, χωρίς σημάδια υπερεκπαίδευσης, γεγονός που δείχνει ότι το μοντέλο μαθαίνει καλά τα όρια μεταξύ κατηγοριών.
- **Domain Loss:** **Αυξάνεται σταδιακά** και **συγκλίνει** σε τιμές γύρω στο **1.25–1.35**. Για cross-entropy με 4 domains, η τυχαία πρόβλεψη αντιστοιχεί σε loss ≈ 1.386 , επομένως οι τιμές που παρατηρούνται είναι αρκετά κοντά στο τυχαίο baseline.
- **KL Divergence:** **Αυξάνεται μονοτονικά** και **σταθεροποιείται** κοντά στο **2.0**, κάτι που σημαίνει ότι το VAE αναγκάζεται να μάθει πιο εκτεταμένη κατανομή στο latent space.
- **Reconstruction Loss:** **Μειώνεται απότομα** στην αρχή και στη συνέχεια **σταθεροποιείται** γύρω στο **0.18–0.20**. Οι καμπύλες train-val είναι κοντά, κάτι που δείχνει ότι το VAE μαθαίνει συνεπή και σταθερή αναπαράσταση χωρίς υπερεκπαίδευση.






Το DANN και ο VAE εκπαιδεύτηκαν **διαδοχικά**, πρώτα ο **VAE** για **30 εποχές** και **μετά το DANN** για **άλλες 70**. Μετά την εκπαίδευση του VAE ο **Decoder «πάγωσε»** και **χρησιμοποιήθηκε μόνο ο εκπαιδευμένος Encoder σαν Feature Extractor** για το DANN. Χρησιμοποιήθηκε ρυθμός μάθησης **$\eta = 0.001$** , **$\lambda = 0.2$** και **$\beta = 1.0$** . Επίσης, το αρνητικό διάνυσμα **$-a$** με το οποίο πολλαπλασιάζεται το gradient στο GRL **αυξάνεται εκθετικά** κατά τη διάρκεια της εκπαίδευσης **στο διάστημα $[0, 1]$** .

- Βλέπουμε ότι οι κατηγορίες Normal και Wheeze είναι πλέον **πολύ πιο καθαρά διαχωρισμένες**, με **ελάχιστη επικάλυψη**. Η κατηγορία Crackle εξακολουθεί να βρίσκεται ενδιάμεσα από τις δύο άλλες, γεγονός που την καθιστά ίσως πιο δύσκολη στη διάκριση.
- Από την άλλη, οι συσκευές παρουσιάζουν και πάλι **μέγιστη επικάλυψη**, κάτι που δείχνει ότι **το domain shift έχει απομακρυνθεί πλήρως**.


- **Reconstruction Loss:** Ξεκινάει από υψηλές τιμές και **πέφτει απότομα** στις πρώτες εποχές, **σταθεροποιούμενο** σε **χαμηλό επίπεδο** ξανά, πολύ **κοντά στο 0.4**. Οι καμπύλες train-val παραμένουν για ακόμη μια φορά σχεδόν ταυτόσημες.
- **KL Divergence:** **Αυξάνεται έντονα** στην αρχή, φτάνει σε ένα κατώφλι γύρω στις 20 εποχές και στη συνέχεια **μειώνεται ελάχιστα και σταθεροποιείται**. Αυτό δείχνει ότι το latent space αρχικά «διαστέλλεται» και μετά ισορροπεί σε πιο σταθερή κατανομή.
- **Classification Loss:** Ξεκινάει πολύ ψηλά αλλά **μειώνεται απότομα** και **συγκλίνει** σε **χαμηλά επίπεδα κοντά στο 0**.
- **Domain Loss:** Μετά την έναρξη του DANN **αυξάνεται σταδιακά** και **συγκλίνει** σε επίπεδο κοντά στο **1.35**, πολύ κοντά ξανά στη τυχαία πρόβλεψη.




Ιδιαίτερη έμφαση δόθηκε στη σύγκριση της απόδοσης της προτεινόμενης μεθοδολογίας με την τεχνική της **διόρθωσης φάσματος (spectrum correction)**, η οποία προτάθηκε από τον *Michal Kosmider (2020)* και αποδείχθηκε ιδιαίτερα αποτελεσματική στην πρόκληση της μετατόπισης πεδίου που εισάγει η **ανομοιογένεια συσκευών**.

Η βασική ιδέα της μεθόδου στηρίζεται σε ένα γραμμικό μοντέλο παραμόρφωσης, σύμφωνα με το οποίο η απόκριση συχνότητας κάθε συσκευής θεωρείται ότι πολλαπλασιάζει το πραγματικό σήμα, εισάγοντας μια χαρακτηριστική αλλοίωση στο φάσμα. Η διόρθωση φάσματος λοιπόν στοχεύει στη **μετατροπή του φάσματος** μιας ηχογράφησης που έχει καταγραφεί από μία συσκευή, ώστε να **προσεγγίζει το αντίστοιχο φάσμα από μία συσκευή αναφοράς**. Αυτό επιτυγχάνεται πολλαπλασιάζοντας το φάσμα της ηχογράφησης με τον λόγο των φασματικών συνιστωσών μεταξύ της συσκευής αναφοράς και της υπό διόρθωση συσκευής. Ο λόγος αυτός αποτελεί τους **συντελεστές διόρθωσης**.

Επομένως, η τεχνική της διόρθωσης φάσματος αποτελεί ένα εξαιρετικά σχετικό σημείο αναφοράς, το οποίο επιτρέπει την άμεση σύγκριση ανάμεσα στα αποτελέσματα που επιφέρει η προσαρμογή πεδίου επιδρώντας αφενός **πάνω στο αυτούσιο σήμα** και αφετέρου **πάνω στο χώρο χαρακτηριστικών** που παράγει.



6 Ταξινόμηση



Για την ταξινόμηση των παθολογικών ήχων με βάση τις ενδιάμεσες αναπαραστάσεις που εξήχθησαν από το Domain Adaptation Module χρησιμοποιήθηκαν τέσσερις διαφορετικοί αλγόριθμοι ταξινόμησης:

- **k - NN:** χρησιμοποιήθηκε **k=3** ως **πλήθος πλησιέστερων γειτόνων**
- **Non-Linear SVM:** χρησιμοποιήθηκαν **C=10.0** για την **επίδραση του regularization** και **γ='scale'** για την **ακτίνα κάθε δείγματος**
- **Random Forest:** χρησιμοποιήθηκαν **n_estimators=200** ως **πλήθος των δέντρων απόφασης** στο δάσος και **min_samples_split = 2** για τον **ελάχιστο αριθμό δειγμάτων** για να διασπαστεί ένας κόμβος του δέντρου
- **XGBoost:** χρησιμοποιήθηκαν **n_estimators=200** ως **πλήθος των δέντρων απόφασης** στο δάσος, **learning_rate = 0.1** για τον **ρυθμό μάθησης** και **max_depth = 10** για το **μέγιστο βάθος** των δέντρων

Επίσης, οι αριθμητικές τιμές των χαρακτηριστικών κανονικοποιήθηκαν στο διάστημα **[-1, 1]** με χρήση του **Min-Max Scaler**, προκειμένου οι αλγόριθμοι που είναι ευαίσθητοι στο εύρος των τιμών των χαρακτηριστικών και βασίζονται σε αποστάσεις (k-NN, SVM) να λειτουργούν αντικειμενικά.

ΑΞΙΟΛΟΓΗΣΗ Κ-ΝΝ

TOTAL

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.71	0.84	0.71
Spectrum Correction	0.73 (+2.8%)	0.84	0.73
DANN	0.75 (+5.6%)	0.84	0.75
CDAN	0.77 (+8.5%)	0.86	0.77
DANN με VAE (1 φάση)	0.76 (+7%)	0.84	0.71
DANN με VAE (2 φάσεις)	0.76 (+7%)	0.85	0.74

NORMAL

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.78	0.73	0.78	0.77	0.50
Spectrum Correction	0.79	0.78	0.75	0.80	0.52
DANN	0.80	0.80	0.73	0.80	0.54
CDAN	0.82	0.81	0.76	0.82	0.57
DANN με VAE (1 φάση)	0.80	0.81	0.71	0.79	0.52
DANN με VAE (2 φάσεις)	0.79	0.80	0.72	0.79	0.52

CRACKLE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.66	0.61	0.90	0.71	0.53
Spectrum Correction	0.67	0.73	0.83	0.63	0.53
DANN	0.68	0.71	0.85	0.66	0.55
CDAN	0.72	0.75	0.86	0.69	0.59
DANN με VAE (1 φάση)	0.68	0.68	0.87	0.68	0.55
DANN με VAE (2 φάσεις)	0.69	0.70	0.86	0.67	0.56

WHEEZE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.51	0.44	0.99	0.66	0.56
Spectrum Correction	0.61	0.56	0.96	0.67	0.56
DANN	0.67	0.60	0.97	0.73	0.61
CDAN	0.67	0.61	0.97	0.74	0.63
DANN με VAE (1 φάση)	0.66	0.62	0.96	0.70	0.61
DANN με VAE (2 φάσεις)	0.66	0.63	0.96	0.70	0.62

ΑΞΙΟΛΟΓΗΣΗ SVM

TOTAL

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.68	0.78	0.66
Spectrum Correction	0.74 (+8.8%)	0.84	0.74
DANN	0.71 (+4.4%)	0.79	0.69
CDAN	0.77 (+13.2%)	0.86	0.77
DANN με VAE (1 φάση)	0.74 (+8.8%)	0.85	0.74
DANN με VAE (2 φάσεις)	0.74 (+8.8%)	0.84	0.73

NORMAL

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.76	0.86	0.49	0.69	0.39
Spectrum Correction	0.80	0.85	0.64	0.76	0.50
DANN	0.77	0.80	0.86	0.71	0.42
CDAN	0.82	0.83	0.73	0.80	0.56
DANN με VAE (1 φάση)	0.79	0.79	0.72	0.79	0.50
DANN με VAE (2 φάσεις)	0.78	0.78	0.71	0.78	0.50

CRACKLE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.62	0.55	0.91	0.71	0.50
Spectrum Correction	0.66	0.62	0.89	0.71	0.54
DANN	0.60	0.53	0.89	0.67	0.46
CDAN	0.72	0.71	0.89	0.73	0.61
DANN με VAE (1 φάση)	0.67	0.66	0.88	0.68	0.54
DANN με VAE (2 φάσεις)	0.67	0.66	0.87	0.68	0.54

WHEEZE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.49	0.35	0.99	0.79	0.48
Spectrum Correction	0.64	0.56	0.97	0.75	0.60
DANN	0.51	0.40	0.97	0.69	0.47
CDAN	0.68	0.65	0.96	0.71	0.63
DANN με VAE (1 φάση)	0.66	0.67	0.95	0.66	0.62
DANN με VAE (2 φάσεις)	0.66	0.67	0.95	0.65	0.61

AΞΙΟΛΟΓΗΣΗ RF

TOTAL

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.71	0.83	0.70
Spectrum Correction	0.72 (+1.4%)	0.85	0.71
DANN	0.72 (+1.4%)	0.83	0.70
CDAN	0.74 (+4.2%)	0.86	0.72
DANN με VAE (1 φάση)	0.74 (+4.2%)	0.84	0.74
DANN με VAE (2 φάσεις)	0.74 (+4.2%)	0.85	0.75

NORMAL

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.80	0.90	0.54	0.72	0.47
Spectrum Correction	0.79	0.88	0.55	0.72	0.47
DANN	0.79	0.89	0.52	0.72	0.44
CDAN	0.80	0.90	0.54	0.72	0.49
DANN με VAE (1 φάση)	0.78	0.78	0.71	0.78	0.49
DANN με VAE (2 φάσεις)	0.80	0.81	0.70	0.78	0.52

CRACKLE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.55	0.50	0.88	0.63	0.40
Spectrum Correction	0.63	0.56	0.90	0.70	0.50
DANN	0.60	0.54	0.91	0.70	0.48
CDAN	0.65	0.59	0.91	0.73	0.54
DANN με VAE (1 φάση)	0.68	0.67	0.87	0.69	0.55
DANN με VAE (2 φάσεις)	0.67	0.65	0.88	0.68	0.53

WHEEZE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.45	0.33	0.98	0.69	0.43
Spectrum Correction	0.56	0.44	0.98	0.76	0.54
DANN	0.48	0.35	0.99	0.77	0.47
CDAN	0.51	0.35	1.00	0.94	0.54
DANN με VAE (1 φάση)	0.67	0.68	0.95	0.66	0.62
DANN με VAE (2 φάσεις)	0.67	0.65	0.95	0.69	0.61

AΞΙΟΛΟΓΗΣΗ XGBOOST

TOTAL

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.73	0.84	0.72
Spectrum Correction	0.73	0.86	0.73
DANN	0.74 (+1.4%)	0.84	0.74
CDAN	0.76 (+4.1%)	0.87	0.76
DANN με VAE (1 φάση)	0.75 (+2.7%)	0.84	0.73
DANN με VAE (2 φάσεις)	0.75 (+2.7%)	0.85	0.74

NORMAL

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.79	0.84	0.63	0.75	0.48
Spectrum Correction	0.79	0.84	0.62	0.75	0.53
DANN	0.80	0.85	0.65	0.76	0.52
CDAN	0.81	0.84	0.69	0.78	0.54
DANN με VAE (1 φάση)	0.79	0.79	0.71	0.78	0.50
DANN με VAE (2 φάσεις)	0.79	0.80	0.71	0.78	0.51

CRACKLE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.65	0.82	0.75	0.62	0.53
Spectrum Correction	0.65	0.60	0.90	0.72	0.54
DANN	0.72	0.64	0.89	0.76	0.55
CDAN	0.70	0.69	0.89	0.72	0.59
DANN με VAE (1 φάση)	0.66	0.66	0.86	0.66	0.53
DANN με VAE (2 φάσεις)	0.66	0.66	0.88	0.68	0.54







WHEEZE

Μέθοδος	F1 score	Sensitivity	Specificity	Precision	MCC
Baseline	0.57	0.51	0.95	0.64	0.51
Spectrum Correction	0.62	0.57	0.96	0.69	0.57
DANN	0.59	0.51	0.97	0.71	0.55
CDAN	0.66	0.59	0.97	0.75	0.62
DANN με VAE (1 φάση)	0.66	0.66	0.94	0.65	0.60
DANN με VAE (2 φάσεις)	0.67	0.66	0.95	0.66	0.61

Καλύτερα σε **Accuracy & F1-Score** αποδεικνύονται τα **k-NN** και **SVM (0.77)**, ενώ το **XGBoost** υπερτερεί ελαφρώς στο **Macro AUC (0.87)**. Επίσης, το **CDAN** φαίνεται να είναι η τεχνική προσαρμογής πεδίου η οποία επέφερε τη **μεγαλύτερη αύξηση** σε σχέση με το baseline **με πολύ μικρή διαφορά από το DANN με VAE ως Feature Extractor**. Συνεπώς, αν έπρεπε να διαλέξουμε μια περίπτωση υλοποίησης, το **SVM με CDAN** είναι η **βέλτιστη επιλογή**, καθώς συνδυάζει:

- τις υψηλότερες συνολικές επιδόσεις,
- τη μεγαλύτερη βελτίωση σε σχέση με το baseline (+ 13.2%),
- και πιο ισορροπημένη συμπεριφορά ανάμεσα στις κλάσεις.

Παρακάτω φαίνονται ενδεικτικά το **μητρώο σύγχυσης**, οι **καμπύλες ROC** και οι **καμπύλες Precision-Recall** που προκύπτουν πριν και μετά από την εφαρμογή του συγκεκριμένου βέλτιστου σεναρίου:



7 Συμπεράσματα

- Η τόσο μεγάλη συνολική βελτίωση στις παθολογικές περιπτώσεις ελέγχου αποδεικνύει ότι το σύστημα είναι πλέον σε θέση να **ανιχνεύει με συνέπεια τα περισσότερα περιστατικά ασθενών με παθολογίες** χωρίς να θυσιάζει την ικανότητά του να αναγνωρίζει τους υγιείς, γεγονός που αυξάνει άμεσα τη χρησιμότητά του ως εργαλείο υποστήριξης της διάγνωσης στην κλινική πράξη.
- Επίσης, μπορούμε να εξάγουμε το συμπέρασμα ότι **η μετατόπιση πεδίου που προκύπτει από τις διαφορές στις συσκευές καταγραφής επηρεάζει συχνά εντονότερα τους παθολογικούς ήχους σε σχέση με τους φυσιολογικούς**, γι' αυτό κιόλας η εφαρμογή της προσαρμογής πεδίου βελτίωσε πολύ περισσότερο τις μετρικές των παθολογικών κλάσεων.
- Τέλος, ένα ακόμη πολύ σημαντικό συμπέρασμα στο οποίο καταλήξαμε είναι πως **η συμπερίληψη της πληροφορίας της κλάσης στη διαδικασία ευθυγράμμισης των κατανομών των πεδίων αποτελεί καθοριστικό παράγοντα για τη βελτίωση** της συνολικής απόδοσης. Αυτό πρακτικά σημαίνει ότι κατά τη σύγκλιση των κατανομών χαρακτηριστικών, η πληροφορία που σχετίζεται με το σε ποιιά συσκευή ανήκει ένα δείγμα συσχετίζεται άμεσα με το πώς η συγκεκριμένη συσκευή καταγράφει κάθε κλάση. Γι' αυτό αποδεικνύεται κιόλας από τις μετρικές πως οι μέθοδοι **CDAN** και **DANN με VAE αποδίδουν πολύ καλύτερα** σε σχέση με το **συμβατικό DANN** και το **Spectrum Correction**.

8 Συζήτηση & Μελλοντικές Επεκτάσεις

- Μια πρώτη επέκταση της προτεινόμενης μεθοδολογίας αφορά την αυτόματη και πιο εκτενή **εξαγωγή χαρακτηριστικών με χρήση τεχνικών βαθιάς μάθησης** (CNNs RNNs, Transformers) αντί για χειροκίνητα επιλεγμένα χαρακτηριστικά. Η **χειροκίνητη επιλογή** στηρίζεται συνήθως σε **προϋπάρχουσα γνώση** και σε στατιστικά ή φασματικά μεγέθη, τα οποία αν και αποτυπώνουν σημαντικές πτυχές των αναπνευστικών ήχων, ενδέχεται να μην καταφέρνουν να συλλάβουν την πλήρη πολυπλοκότητα και τα λεπτομερή μοτίβα που χαρακτηρίζουν διαφορετικές παθολογίες.
 - Ένα ακόμη πεδίο μελλοντικής διερεύνησης αφορά την **ενσωμάτωση τεχνικών κανονικοποίησης φάσματος**, όπως η διόρθωση φάσματος (**spectrum correction**), στο προτεινόμενο μεθοδολογικό πλαίσιο. Η συγκεκριμένη προσέγγιση, όπως έχει ήδη αποδειχθεί στη βιβλιογραφία, επιτυγχάνει τη μείωση της επίδρασης που ασκεί η ετερογένεια των συσκευών καταγραφής. Η ενσωμάτωση της τεχνικής αυτής στο pipeline που αναπτύχθηκε στην παρούσα εργασία μπορεί να λειτουργήσει ως **στάδιο προεπεξεργασίας** πριν την εφαρμογή των μεθόδων προσαρμογής πεδίου βαθιάς μάθησης, δημιουργώντας ένα πιο «ουδέτερο» σετ χαρακτηριστικών και ενισχύοντας την αποτελεσματικότητα της επακόλουθης εκπαίδευσης.
 - Τέλος, σε επίπεδο πρακτικής εφαρμογής, οι μελλοντικές επεκτάσεις μπορούν να επικεντρωθούν **στην ενσωμάτωση των αναπτυγμένων μοντέλων σε φορητές συσκευές και συστήματα τηλεϊατρικής**. Η ανάπτυξη ελαφρών και αποδοτικών υλοποιήσεων που μπορούν να λειτουργήσουν σε πραγματικό χρόνο σε κινητές συσκευές ή σε συσκευές παρακολούθησης θα συμβάλει στη διάδοση της τεχνολογίας σε κλινικά και κατ' οίκον περιβάλλοντα, υποστηρίζοντας την έγκαιρη διάγνωση και παρακολούθηση των ασθενών.



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ
ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

Σας ευχαριστώ πολύ!

ΜΗΛΤΙΑΔΗΣ ΜΑΝΤΕΣ
Α.Μ. 1084661