



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Ταξινόμηση παθολογικών αναπνευστικών ήχων
με τεχνικές μηχανικής μάθησης και
προσαρμογής πεδίου

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

ΜΑΝΤΕ ΜΗΛΤΙΑΔΗ
Α.Μ. 1084661

Επιβλέπων: κ. Σωτήριος Νικολετσέας

Πάτρα, Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Ταξινόμηση παθολογικών αναπνευστικών ήχων
με τεχνικές μηχανικής μάθησης και
προσαρμογής πεδίου

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΜΑΝΤΕ ΜΗΛΤΙΑΔΗ
Α.Μ. 1084661

Επιβλέπων: κ. Σωτήριος Νικολετσέας

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....

κ. Σωτήριος Νικολετσέας
Καθηγητής

.....

κα Εύη Παπαϊωάννου
Επίκουρη Καθηγήτρια

.....

κ. Χρήστος Μακρής
Αναπληρωτής Καθηγητής

Πάτρα, Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Copyright ©–All rights reserved Μηλτιάδης Μαντές, 2025.

Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

Υπεύθυνη Δήλωση

Βεβαιώνω ότι είμαι συγγραφέας αυτής της πτυχιακής εργασίας, και ότι κάθε βοήθεια την οποία είχα για την προετοιμασία της είναι πλήρως αναγνωρισμένη και αναφέρεται στην πτυχιακή εργασία. Επίσης έχω αναφέρει τις όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε αυτές αναφέρονται ακριβώς είτε παραφρασμένες. Επίσης, βεβαιώνω ότι αυτή η πτυχιακή εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για τις απαιτήσεις του προγράμματος σπουδών του τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

(Υπογραφή)

.....

Μηλτιάδης Μαντές

Περίληψη

Οι αναπνευστικές παθήσεις αποτελούν ένα από τα σημαντικότερα πεδία πρόληψης και έγκαιρης διάγνωσης στη σύγχρονη ιατρική, με τους αναπνευστικούς ήχους να παρέχουν κρίσιμη πληροφορία για την κλινική αξιολόγηση. Η αυτοματοποιημένη ανάλυση των ήχων αυτών μπορεί να υποστηρίξει τη διαγνωστική διαδικασία, περιορίζοντας την υποκειμενικότητα και ενισχύοντας την αξιοπιστία της. Ωστόσο, μία από τις βασικές προκλήσεις που ανακύπτουν είναι η μειωμένη δυνατότητα γενίκευσης των υπολογιστικών μοντέλων, όταν τα δεδομένα εκπαίδευσης διαφοροποιούνται ως προς τις στατιστικές τους ιδιότητες σε σχέση με τα δεδομένα ελέγχου.

Η παρούσα διπλωματική εργασία επικεντρώνεται στη μελέτη της πρόκλησης αυτής, γνωστής ως μετατόπιση πεδίου, αλλά και στην εφαρμογή μεθοδολογιών που αποσκοπούν στη μετρίαση της επίδρασής της. Ιδιαίτερη έμφαση δόθηκε στη μεροληψία που εισάγεται από τις διαφορετικές συσκευές και τις ποικίλες συνθήκες καταγραφής, καθώς η ετερογένεια αυτή μπορεί να επηρεάσει σημαντικά την αξιοπιστία των μοντέλων. Για τον σκοπό αυτόν ακολουθήθηκε ένα συστηματικό ερευνητικό πλαίσιο, το οποίο περιλάμβανε την προσεκτική προεπεξεργασία των ηχογραφήσεων ώστε να διασφαλιστεί η καθαρότητα και η συγκρισιμότητα των δεδομένων, την εξαγωγή χαρακτηριστικών που αποτυπώνουν αντιπροσωπευτικά τις ιδιότητες των αναπνευστικών ήχων, καθώς και την αξιολόγηση τόσο κλασικών όσο και σύγχρονων προσεγγίσεων μηχανικής μάθησης σε ένα ετερογενές και πολυδιάστατο σύνολο δεδομένων. Η πειραματική διαδικασία σχεδιάστηκε ώστε να προσομοιάζει ρεαλιστικές συνθήκες, με ηχογραφήσεις από μεγάλο εύρος ασθενών, καταγεγραμμένες μέσω διαφορετικών συσκευών και σε ποικίλες θέσεις τοποθέτησης.

Τα αποτελέσματα ανέδειξαν ότι η στοχευμένη προσαρμογή πεδίου βελτιώνει ουσιαστικά την απόδοση των μοντέλων, οδηγώντας σε πιο σταθερή και αξιόπιστη ταξινόμηση ανεξάρτητα από τον χρησιμοποιούμενο εξοπλισμό. Συμπερασματικά, η εργασία καταδεικνύει ότι η ενσωμάτωση τεχνικών προσαρμογής πεδίου αποτελεί καθοριστικό βήμα για την ανάπτυξη υπολογιστικών συστημάτων με μεγαλύτερη γενικευσιμότητα και αξιοπιστία στην ταξινόμηση παθολογικών αναπνευστικών ήχων, ενισχύοντας την προοπτική αξιοποίησης τέτοιων μεθόδων στην κλινική πράξη για την υποστήριξη της έγκαιρης διάγνωσης και τη βελτίωση της παρεχόμενης φροντίδας υγείας.

Λέξεις Κλειδιά

παθολογικοί αναπνευστικοί ήχοι, ταξινόμηση, αυτόματη ανάλυση, μετατόπιση πεδίου, ανταγωνιστική προσαρμογή πεδίου, ετερογένεια συσκευών

Abstract

Respiratory diseases constitute one of the most critical areas of prevention and early diagnosis in modern medicine, with respiratory sounds providing essential information for clinical assessment. The automated analysis of these sounds can support the diagnostic process by reducing subjectivity and enhancing reliability. Nevertheless, one of the main challenges that arises is the reduced generalization capability of computational models when training data differ in their statistical properties from the testing data.

This thesis focuses on studying this challenge, commonly referred to as domain shift, as well as on applying methodologies aimed at mitigating its impact. Particular emphasis was placed on the bias introduced by different recording devices and heterogeneous recording conditions, since such variability can significantly affect model reliability. To address this issue, a systematic research framework was adopted, comprising careful preprocessing of the recordings to ensure data quality and comparability, extraction of representative features capturing the properties of respiratory sounds, and evaluation of both classical and modern machine learning approaches on a heterogeneous and multidimensional dataset. The experimental process was designed to approximate realistic conditions, including recordings from a wide range of patients, collected with different devices and at various recording positions.

The results demonstrated that targeted domain adaptation substantially improves model performance, leading to more stable and reliable classification regardless of the equipment used. In conclusion, this work highlights that the integration of domain adaptation techniques constitutes a critical step towards the development of computational systems with higher ability of generalization and reliability in the classification of pathological respiratory sounds, reinforcing the potential of such methods to support early diagnosis and improve the quality of healthcare delivery.

Keywords

adventitious respiratory sounds, classification, automatic analysis, domain shift, adversarial domain adaptation, device mismatch

Στην οικογένεια και στους φίλους μου!

Ευχαριστίες

Θα ήθελα καταρχάς να εκφράσω την ειλικρινή μου ευγνωμοσύνη στον επιβλέποντα καθηγητή μου, κ. Σωτήριο Νικολετσέα, για την εμπιστοσύνη και την ευκαιρία που μου έδωσε ώστε να ασχοληθώ με ένα τόσο ενδιαφέρον και επίκαιρο θέμα. Η διαθεσιμότητά του και η ενθάρρυνση που μου προσέφερε συνέβαλαν σημαντικά στην εξέλιξή μου τόσο σε ακαδημαϊκό όσο και σε προσωπικό επίπεδο. Ακόμη, θα ήθελα να ευχαριστήσω τον Υποψήφιο Διδάκτορα Γιώργο Κοντογιάννη, για τη βοήθεια αλλά και για τις ουσιαστικές διορθώσεις καθ' όλη τη διάρκεια υλοποίησης αυτής της εργασίας. Ευχαριστώ επίσης τα μέλη της επιτροπής αξιολόγησης, κα Εύη Παπαϊωάννου και κ. Χρήστο Μακρή, για το ενδιαφέρον και το χρόνο που αφιέρωσαν για την αξιολόγηση της εργασίας μου. Ιδιαίτερες ευχαριστίες οφείλω στην οικογένειά μου για τη συνεχή στήριξή αλλά και την υπομονή τους σε όλη τη διάρκεια των σπουδών μου. Η αμέριστη ηθική και συναισθηματική τους υποστήριξη αποτέλεσε για μένα πολύτιμο στήριγμα. Τέλος, ευχαριστώ τους φίλους και συμφοιτητές μου για τη συντροφιά, τη συνεργασία και τις στιγμές που μοιραστήκαμε όλα αυτά τα χρόνια, καθώς και για την ενθάρρυνση που μου προσέφεραν στις πιο απαιτητικές στιγμές της φοιτητικής μου πορείας.

Περιεχόμενα

Περίληψη	i
Abstract	iii
Ευχαριστίες	vi
Περιεχόμενα	ix
Κατάλογος Σχημάτων	xii
Κατάλογος Πινάκων	xiv
1 Εισαγωγή	1
1.1 Διάρθρωση της διπλωματικής εργασίας	1
1.2 Σημασία του προβλήματος	2
1.3 Προηγούμενες έρευνες και προκλήσεις	4
1.4 Στόχοι και συνεισφορά της διπλωματικής εργασίας	6
2 Αναπνευστικά σήματα: από τη φυσιολογία στην προσαρμογή πεδίου	8
2.1 Ανατομία και φυσιολογία του αναπνευστικού συστήματος	8
2.1.1 Παραγωγή αναπνευστικών ήχων	8
2.1.2 Διαχωρισμός φυσιολογικών και παθολογικών ήχων	10
2.2 Αναπνευστικά σήματα	12
2.2.1 Ορισμός, μεγέθη και ιδιότητες	12
2.2.2 Τρόποι καταγραφής	16
2.2.3 Ψηφιοποίηση	18
2.3 Η βάση δεδομένων RSDB	20
2.4 Αναπαράσταση αναπνευστικών σημάτων	23
2.4.1 Πεδίο χρόνου (Κυματομορφή)	24
2.4.2 Πεδίο χρόνου-συχνότητας (Φασματογράφημα)	25
2.5 Μετατόπιση πεδίου	29
2.6 Προσαρμογή πεδίου	31
2.6.1 Επιβλεπόμενη και μη επιβλεπόμενη προσαρμογή πεδίου	32

2.6.2	Βασικές κατηγορίες προσαρμογής πεδίου	32
2.6.3	Βασικές προσεγγίσεις προσαρμογής πεδίου	34
3	Προτεινόμενη μεθοδολογία	39
3.1	Προεπεξεργασία αναπνευστικών σημάτων	40
3.1.1	Επαναδειγματοληψία	41
3.1.2	Καθορισμός χρονικών ορίων	42
3.1.3	Κανονικοποίηση πλάτους	44
3.1.4	Αποθορυβοποίηση	45
3.2	Επαύξηση αναπνευστικών κύκλων	47
3.3	Εξαγωγή χαρακτηριστικών	48
3.3.1	Χρονικά χαρακτηριστικά	50
3.3.2	Φασματικά χαρακτηριστικά	52
3.3.3	MFCCs	54
3.3.4	Ζώνες ενέργειας Log-Mel	56
3.4	Προσαρμογή πεδίου για μείωση της επίδρασης της ετερογένειας συσκευών εγ- γραφής	57
3.4.1	Πολυεπίπεδο Αντίληπτρο	62
3.4.2	Αυτοκωδικοποιητής	64
3.4.3	Domain Adversarial Neural Network (DANN)	65
3.4.4	Conditional Domain Adversarial Network (CDAN)	68
3.4.5	Domain Adversarial Neural Network (DANN) με Variational Au- toencoder (VAE)	70
3.5	Ταξινόμηση παθολογικών ήχων	73
3.5.1	k-Πλησιέστεροι Γείτονες	74
3.5.2	Μηχανές Υποστήριξης Διανυσμάτων	75
3.5.3	Τυχαίο Δάσος	76
3.5.4	Ακραία Ενισχυτική Μάθηση Κλίσης	78
3.5.5	Ρύθμιση μοντέλων	79
3.5.6	Αξιολόγηση μοντέλων	81
4	Πειραματική διαδικασία και αποτελέσματα	85
4.1	Τεχνολογίες και εργαλεία υλοποίησης	85
4.2	Διερευνητική ανάλυση του συνόλου δεδομένων	86
4.3	Διέρυνση μετατόπισης πεδίου	93
4.4	Εκπαίδευση νευρωνικών δικτύων για προσαρμογή πεδίου	95
4.5	Ρύθμιση υπερπαραμέτρων αλγορίθμων ταξινόμησης	103
4.6	Αποτελέσματα αλγορίθμων ταξινόμησης	103
4.6.1	Συνολικές μετρικές	104
4.6.2	Μετρικές ανά κλάση	105

5	Επίλογος	112
5.1	Συμπεράσματα	112
5.2	Μελλοντικές επεκτάσεις	114

Κατάλογος Σχημάτων

2.1	Αναπνευστικό δέντρο. (Oiseth et al. 2024)	8
2.2	Στρωτή ροή αέρα. (Sarkar et al. 2015)	9
2.3	Τυρβώδης ροή αέρα. (Sarkar et al. 2015)	9
2.4	Οπτική αναπαράσταση του διαχωρισμού μεταξύ φυσιολογικών και παθολογικών αναπνευστικών ήχων. (Διαδίκτυο)	10
2.5	Θέσεις καταγραφής αναπνευστικών ήχων κατά την ακρόαση. (Squires 2022)	16
2.6	Συσκευές καταγραφής αναπνευστικών ήχων. (Διαδίκτυο)	17
2.7	Βασικά τμήματα ακουστικού στηθοσκοπίου. (Babalola et al. 2023)	17
2.8	Διαδικασία ψηφιοποίησης αναπνευστικών ηχητικών σημάτων.(Διαδίκτυο)	18
2.9	Θέσεις καταγραφής των αναπνευστικών ήχων στη βάση δεδομένων RSDB. (Rocha et al. 2018)	20
2.10	Σύντομη οπτική περιγραφή της βάσης δεδομένων RSDB.	21
2.11	Απεικόνιση της μέσης απόκρισης συχνότητας των διαφορετικών συσκευών καταγραφής.	22
2.12	Διαχωρισμός σε training, test sets.	23
2.13	Κυματομορφές από ενδεικτικές αναπνευστικές καταγραφές.	25
2.14	Τεμαχισμός σήματος σε frames με επικάλυψη. (Διαδίκτυο)	27
2.15	Παράθυρο Hann (Διαδίκτυο).	28
2.16	Παράθυρο Hamming (Διαδίκτυο).	28
2.17	Φασματογραφήματα από ενδεικτικές αναπνευστικές καταγραφές.	29
2.18	Είδη μετατόπισης πεδίου. (Ganin et al. 2016)	31
2.19	Βασική αρχή λειτουργίας της προσαρμογής πεδίου. (Kundu 2022)	32
2.20	Είδη προσαρμογής πεδίου. (Fan et al. 2022)	34
2.21	Βασικές προσεγγίσεις προσαρμογής πεδίου. (Fayek et al. 2024)	34
3.1	Pipeline υλοποίησης.	39
3.2	Block diagram για το Preprocessing Module.	40
3.3	Ενδεικτικό παράδειγμα εφαρμογής trimming.	44
3.4	Ενδεικτικό παράδειγμα εφαρμογής padding.	44
3.5	Ενδεικτικό παράδειγμα εφαρμογής κανονικοποίησης πλάτους.	45
3.6	Είδη ψηφιακών φίλτρων.	46
3.7	Ενδεικτικό παράδειγμα εφαρμογής high-pass φίλτρου.	47

3.8	Ενδεικτικό παράδειγμα εφαρμογής VTLP-Patch Aug.	48
3.9	Block diagram για το Feature Extraction Module.	49
3.10	Μέση χρονική εξέλιξη του ZCR για κάθε κατηγορία ήχου.	51
3.11	Μέση χρονική εξέλιξη του RMS Energy για κάθε κατηγορία ήχου.	51
3.12	Μέση χρονική εξέλιξη του Onset Envelope για κάθε κατηγορία ήχου.	52
3.13	Μέση χρονική εξέλιξη του Spectral Centroid για κάθε κατηγορία ήχου.	52
3.14	Χρονική εξέλιξη του Spectral Bandwidth για κάθε κατηγορία ήχου.	53
3.15	Μέση χρονική εξέλιξη του Spectral Flux για κάθε κατηγορία ήχου.	53
3.16	Μέση χρονική εξέλιξη του Spectral Flatness για κάθε κατηγορία ήχου.	54
3.17	Μέση χρονική εξέλιξη του Spectral Rolloff για κάθε κατηγορία ήχου.	54
3.18	Διαδικασία εξαγωγής MFCCs.	55
3.19	Παραδείγματα MFCCs από ενδεικτικούς αναπνευστικούς κύκλους.	56
3.20	Μέση χρονική εξέλιξη των MFCCs.	56
3.21	Μέση χρονική εξέλιξη των Log-Mel filterbank energies.	57
3.22	Block diagram για το Domain Adaptation Module.	58
3.23	Σχέση ανάμεσα σε τεχνητή νοημοσύνη, μηχανική μάθηση και βαθιά μάθηση. (Shrivastava 2024)	58
3.24	Εκπαίδευση νευρωνικών δικτύων. (Προσαρμογή από Zhang et al. 2023)	60
3.25	Αρχιτεκτονική ενός MLP.	63
3.26	Αρχιτεκτονική ενός Autoencoder. (Akkus et al. 2023)	64
3.27	Αρχιτεκτονική ενός DANN. (Wang et al. 2019)	66
3.28	Αρχιτεκτονική ενός CDAN. (Long et al. 2018)	69
3.29	Αρχιτεκτονική ενός VAE. (Puchalski et al. 2023)	71
3.30	Block diagram για το Classification Module.	74
3.31	Ταξινομητής k-NN (Sachinsoni 2023).	74
3.32	Γραμμικός ταξινομητής SVM. (Διαδίκτυο).	75
3.33	Ταξινομητής Random Forest. (Διαδίκτυο)	77
3.34	Ταξινομητής XGBoost. (Διαδίκτυο)	78
3.35	Μητρώο σύγχυσης.(Διαδίκτυο)	82
3.36	Καμπύλη ROC.(Διαδίκτυο)	83
4.1	KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά label.	89
4.2	Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά label.	90
4.3	Feature-Class heatmap των εξαγμένων χαρακτηριστικών.	91
4.4	Correlation heatmap των εξαγμένων χαρακτηριστικών.	91
4.5	Κατάταξη χαρακτηριστικών βάσει F -score από ANOVA test ως προς το label. . . .	92
4.6	p -values των χαρακτηριστικών από ANOVA test.	92
4.7	Μεταβολή απόδοσης ταξινόμησης του k-NN ως προς το πλήθος χαρακτηριστικών. .	93
4.8	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συ- σκευές καταγραφής.	94
4.9	2D απεικόνιση των δεδομένων του dataset με χρήση PCA.	94

4.10	Μητρώο σύγχυσης για το μοντέλο ταξινόμησης συσκευών.	95
4.11	Συναρτήσεις κόστους του DANN.	96
4.12	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή DANN.	97
4.13	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή DANN.	97
4.14	Συναρτήσεις κόστους του CDAN.	98
4.15	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή CDAN.	99
4.16	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή CDAN.	99
4.17	Συναρτήσεις κόστους κατά την ταυτόχρονη εκπαίδευση.	100
4.18	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την ταυτόχρονη εκπαίδευση.	101
4.19	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την ταυτόχρονη εκπαίδευση.	101
4.20	Συναρτήσεις κόστους κατά την διαδοχική εκπαίδευση.	102
4.21	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την διαδοχική εκπαίδευση.	102
4.22	2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την διαδοχική εκπαίδευση.	102
4.23	Βέλτιστοι συνδυασμοί υπερπαραμέτρων για κάθε μοντέλο ταξινόμησης.	103
4.24	Αποτελέσματα k-NN: μητρώα σύγχυσης, καμπύλες ROC και Precision–Recall για κάθε μέθοδο προσαρμογής πεδίου.	108
4.25	Αποτελέσματα SVM: μητρώα σύγχυσης, καμπύλες ROC και Precision–Recall για κάθε μέθοδο προσαρμογής πεδίου.	109
4.26	Αποτελέσματα Random Forest: μητρώα σύγχυσης, καμπύλες ROC και Precision–Recall για κάθε μέθοδο προσαρμογής πεδίου.	110
4.27	Αποτελέσματα XGBoost: μητρώα σύγχυσης, καμπύλες ROC και Precision–Recall για κάθε μέθοδο προσαρμογής πεδίου.	111

Κατάλογος Πινάκων

1.1	Σύνοψη <i>state-of-the-art</i> αποτελεσμάτων στην αυτόματη ανάλυση αναπνευστικών ήχων και στην ακουστική προσαρμογή πεδίου.	5
2.1	Διαφορές φυσιολογικών και παθολογικών αναπνευστικών ήχων (Pramono, Bowyer, et al. 2017)	12
2.2	Κατανομή των κατηγοριών αναπνευστικών ήχων ανά συσκευή καταγραφής. . .	22
2.3	Απόσταση Wasserstein και JS Divergence των κατανομών των χαρακτηριστικών των πεδίων πηγής από το πεδίο στόχο Meditron.	37
3.1	Συχνότητες καταγραφής αναπνευστικών σημάτων από τις διαφορετικές συσκευές.	42
3.2	Πλήθος εξαγμένων χαρακτηριστικών.	49
3.3	Συνοπτική παρουσίαση συναρτήσεων ενεργοποίησης.	62
3.4	Αρχιτεκτονική του Feature Extractor στο DANN.	67
3.5	Αρχιτεκτονική του Label Classifier στο DANN.	68
3.6	Αρχιτεκτονική του Domain Classifier στο DANN.	68
3.7	Αρχιτεκτονική του Feature Extractor στο CDAN.	70
3.8	Αρχιτεκτονική του Label Classifier στο CDAN.	70
3.9	Αρχιτεκτονική του Encoder στο VAE.	72
3.10	Αρχιτεκτονική του Decoder στο VAE.	72
4.1	Περιγραφικά στατιστικά μεγέθη για τα εξαγμένα χαρακτηριστικά.	88
4.2	Τα 20 κορυφαία επιλεγμένα χαρακτηριστικά	93
4.3	Συνολικές μετρικές ταξινόμησης k-NN για κάθε μέθοδο προσαρμογής πεδίου. .	104
4.4	Συνολικές μετρικές ταξινόμησης SVM για κάθε μέθοδο προσαρμογής πεδίου. .	104
4.5	Συνολικές μετρικές ταξινόμησης Random Forest για κάθε μέθοδο προσαρμογής πεδίου.	104
4.6	Συνολικές μετρικές ταξινόμησης XGBoost για κάθε μέθοδο προσαρμογής πεδίου.	104
4.7	Μετρικές ταξινόμησης k-NN για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.	105
4.8	Μετρικές ταξινόμησης k-NN για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.	105
4.9	Μετρικές ταξινόμησης k-NN για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.	105

4.10 Μετρικές ταξινόμησης SVM για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.	105
4.11 Μετρικές ταξινόμησης SVM για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.	106
4.12 Μετρικές ταξινόμησης SVM για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.	106
4.13 Μετρικές ταξινόμησης Random Forest για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.	106
4.14 Μετρικές ταξινόμησης Random Forest για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.	106
4.15 Μετρικές ταξινόμησης Random Forest για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.	107
4.16 Μετρικές ταξινόμησης XGBoost για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.	107
4.17 Μετρικές ταξινόμησης XGBoost για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.	107
4.18 Μετρικές ταξινόμησης XGBoost για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.	107

Κεφάλαιο 1

Εισαγωγή

1.1 Διάρθρωση της διπλωματικής εργασίας

Η παρούσα διπλωματική εργασία οργανώνεται σε πέντε (5) κύρια κεφάλαια, ακολουθώντας μια ροή η οποία ξεκινάει από τη θεωρητική θεμελίωση και καταλήγει στην πειραματική αξιολόγηση και τα τελικά συμπεράσματα και επεκτάσεις. Συγκεκριμένα:

- **Κεφάλαιο 1 – Εισαγωγή**

Παρουσιάζεται το υπόβαθρο και το γενικό πλαίσιο της εργασίας, η σημασία της ανάλυσης και ταξινόμησης αναπνευστικών ήχων, καθώς και οι προκλήσεις που εισάγει η μετατόπιση πεδίου στην ταξινόμηση αναπνευστικών ήχων σύμφωνα και με προηγούμενες μελέτες. Διατυπώνονται επίσης οι στόχοι, η συνεισφορά και η δομή της εργασίας, καθώς και τυχόν κενά στην υπάρχουσα βιβλιογραφία.

- **Κεφάλαιο 2 – Αναπνευστικά σήματα: από τη φυσιολογία στην προσαρμογή πεδίου**

Περιγράφεται συνοπτικά η διαδικασία με βάση την οποία ένας αναπνευστικός ήχος παράγεται από το ανθρώπινο σώμα, καταγράφεται κατά την ακρόαση και αποθηκεύεται. Πιο συγκεκριμένα, παρουσιάζεται η λειτουργία του αναπνευστικού συστήματος, ενώ παράλληλα διατυπώνονται οι βασικές διαφορές ανάμεσα σε φυσιολογικούς και παθολογικούς αναπνευστικούς ήχους. Επίσης, παρουσιάζονται ορισμένες εισαγωγικές έννοιες της θεωρίας σημάτων και γίνεται αναφορά στις υπάρχουσες μεθόδους ακρόασης και καταγραφής τους, καθώς και στη διαδικασία ψηφιοποίησης με σκοπό την αποθήκευσή τους. Μετά από αυτό, δίνονται ορισμένες γενικές πληροφορίες για τη βάση δεδομένων που χρησιμοποιήθηκε, αλλά και των τρόπων αναπαράστασης των αναπνευστικών καταγραφών που διαθέτει. Τέλος, γίνεται μια θεωρητική εισαγωγή στην έννοια της μετατόπισης πεδίου που προκύπτει από την ανομοιογένεια στις συσκευές καταγραφής της βάσης δεδομένων, καθώς και των διαθέσιμων προσεγγίσεων για την αντιμετώπισή της. Για την ακρίβεια, δίνεται έμφαση στις βαθιές αρχιτεκτονικές προσαρμογής πεδίου, οι οποίες ενσωματώνουν την προσαρμογή στη διαδικασία εκμάθησης αναπαραστάσεων, οι οποίες αποδεικνύονται κατάλληλες για πολύπλοκα ακουστικά περιβάλλοντα με υψηλή

ετερογένεια.

- **Κεφάλαιο 3 – Προτεινόμενη μεθοδολογία**

Παρουσιάζεται ολόκληρο το *pipeline* της μεθοδολογίας η οποία ακολουθήθηκε κατά την εκπόνηση αυτής της εργασίας. Αρχικά, αναλύονται οι τεχνικές προεπεξεργασίας που εφαρμόστηκαν πάνω στα καταγεγραμμένα σήματα, καθώς και οι μέθοδοι εξαγωγής χαρακτηριστικών, από τις οποίες προκύπτουν τα τελικά αριθμητικά χαρακτηριστικά που θα δοθούν σαν είσοδοι στα μοντέλα ταξινόμησης. Ακολουθεί επίσης μια σύντομη περιγραφή των χαρακτηριστικών αυτών και της σημασίας τους στη διάγνωση αναπνευστικών παθήσεων. Στη συνέχεια, αναλύονται οι επιλεγμένες μέθοδοι προσαρμογής πεδίου που υλοποιήθηκαν στην συγκεκριμένη εργασία και δίνεται έμφαση στις αρχιτεκτονικές νευρωνικών δικτύων βαθιάς μηχανικής μάθησης και στον τρόπο εκπαίδευσής τους. Τέλος, αναλύονται θεμελιώδεις αρχές τόσο της επιβλεπόμενης όσο και της μη επιβλεπόμενης μηχανικής μάθησης και γίνεται θεωρητική θεμελίωση κάποιων παραδοσιακών (*k-NN*, *SVM*, *Random Forest*) αλλά και πιο σύγχρονων (*XGBoost*) αλγορίθμων ταξινόμησης.

- **Κεφάλαιο 4 – Πειραματική διαδικασία και αποτελέσματα**

Περιγράφονται τα εργαλεία και η διαδικασία υλοποίησης της προτεινόμενης μεθοδολογίας, καθώς και όλες οι γραφικές παραστάσεις που προκύπτουν συνοδευόμενες από αντίστοιχο σχολιασμό. Μετά το πέρας της ταξινόμησης παρατίθενται όχι μόνο οι μετρικές αλλά και επιπρόσθετα αποτελέσματα αξιολόγησης της απόδοσης των μοντέλων, όπως μητρώα σύγχυσης, καμπύλες *ROC* και καμπύλες *Precision-Recall*, τα οποία προκύπτουν από τη ταξινόμηση των αναπνευστικών ήχων τόσο συνολικά όσο και ξεχωριστά για κάθε κατηγορία ήχου. Σκοπός είναι να παρουσιαστεί η συμπεριφορά κάθε μοντέλου ταξινόμησης σε ατομικό επίπεδο ώστε να αποφανθούμε ποιός αλγόριθμος ταξινόμησης αποδίδει συνδυαστικά καλύτερα στη δικιά μας περίπτωση.

- **Κεφάλαιο 5 – Επίλογος**

Παρουσιάζονται τα συνολικά αποτελέσματα της ταξινόμησης, τα συμπεράσματα της έρευνας, καθώς και οι μελλοντικές προοπτικές βελτίωσης και επέκτασης του συστήματος.

1.2 Σημασία του προβλήματος

Είναι γνωστό ότι οι αναπνευστικές παθήσεις όπως η χρόνια αποφρακτική πνευμονοπάθεια (ΧΑΠ), το άσθμα και η πνευμονία αποτελούν παγκοσμίως μείζονα αιτία νοσηρότητας και θνησιμότητας, επηρεάζοντας εκατομμύρια ανθρώπους και επιβαρύνοντας σημαντικά τα συστήματα υγείας. Η έγκαιρη και ακριβής διάγνωση αυτών των παθήσεων είναι καίριας σημασίας για την αποτελεσματική αντιμετώπισή τους αλλά και για τη βελτίωση της πρόγνωσης των ασθενειών.

Η παρουσία παθολογικών αναπνευστικών ήχων στους αναπνευστικούς κύκλους καθώς και τα χαρακτηριστικά των ήχων αυτών αποτελούν σημαντικούς βιοδείκτες για την κλινική αξιολόγηση των παραπάνω νοσημάτων. Πιο συγκεκριμένα, ήχοι όπως τα wheezes (συριγμοί) και τα crackles (ρόγχοι) προκύπτουν από μη φυσιολογικές ροές αέρα ή αποφράξεις στους

αεραγωγούς και συνδέονται άμεσα με τις προαναφερθείσες παθήσεις. Για παράδειγμα, οι συριγμοί παρατηρούνται συχνά στο άσθμα και στη ΧΑΠ λόγω στένωσης των βρόγχων, ενώ οι λεπτοί ρόγχοι σχετίζονται με πνευμονία ή πνευμονική ίνωση. Η ανίχνευση, η καταγραφή και η ανάλυση αυτών των ήχων παρέχουν στον θεράποντα ιατρό κρίσιμη πληροφορία τόσο για τη διάγνωση όσο και την παρακολούθηση της πορείας της νόσου.

Η ανάλυση των αναπνευστικών ήχων μέσω της παραδοσιακής διαδικασίας ακρόασης θα λέγαμε ότι προσφέρει μία μη επεμβατική, χαμηλού κόστους και άμεσα διαθέσιμη μέθοδο κλινικής αξιολόγησης. Ωστόσο, η ερμηνεία των ήχων και των συμπτωμάτων τους από τον κλινικό ιατρό είναι μια διαδικασία η οποία χαρακτηρίζεται από μεγάλο βαθμό υποκειμενικότητας, καθώς βασίζεται σε αστάθμητους παράγοντες όπως η εμπειρία του ιατρού, η ακουστική οξύτητα αλλά και οι εκάστοτε συνθήκες ακρόασης. Η ανάπτυξη λοιπόν αυτοματοποιημένων μεθόδων ανάλυσης και ταξινόμησης αναπνευστικών ήχων, βασισμένων σε τεχνικές μηχανικής μάθησης και βαθιάς μάθησης, δύναται να λειτουργήσει υποστηρικτικά στη διαδικασία λήψης ιατρικών αποφάσεων, μειώνοντας την εξάρτηση από την υποκειμενική κρίση.

Παρά τα πλεονεκτήματα και τις υψηλές επιδόσεις που μπορούν να επιτύχουν οι σύγχρονες τεχνικές μηχανικής μάθησης, η αξιοπιστία και η γενίκευση των αποτελεσμάτων τους πολλές φορές τίθενται υπό αμφισβήτηση, καθώς και αυτές όπως και ο ανθρώπινος παράγοντας δεν μπορούν πάντα να λειτουργήσουν αντικειμενικά. Για την ακρίβεια, ένα συχνό φαινόμενο το οποίο αντιμετωπίζουν τα μοντέλα μηχανικής μάθησης με αποτέλεσμα να επηρεάζεται αρνητικά η απόδοσή τους είναι η διαφοροποίηση των δεδομένων ή συνθηκών εκπαίδευσης σε σχέση με το περιβάλλον αξιολόγησής τους. Το φαινόμενο αυτό είναι γνωστό ως *domain shift* ή μετατόπιση πεδίου στα ελληνικά και στο πλαίσιο της επεξεργασίας ακουστικών δεδομένων μπορεί να προκύψει από πληθώρα παραγόντων. Κάποιοι από αυτούς είναι η διαφοροποίηση στον τύπο και τα τεχνικά χαρακτηριστικά των συσκευών ηχογράφησης (π.χ. διαφορετικά ηλεκτρονικά στηθοσκόπια ή μικρόφωνα), οι συνθήκες ηχογράφησης (θόρυβος περιβάλλοντος, ακουστική χώρου) ή ακόμα και οι διαφορές στο προφίλ των ασθενών από όπου συλλέγονται τα δεδομένα (ηλικία, φύλο, φυσική κατάσταση κ.τ.λ.).

Η ύπαρξη τέτοιας ετερογένειας στα δεδομένα μπορεί να οδηγήσει σε αξιοσημείωτη υποβάθμιση της απόδοσης ενός συστήματος όταν αυτό εφαρμόζεται σε δεδομένα που αποκλίνουν στατιστικά από εκείνα που χρησιμοποιήθηκαν κατά την εκπαίδευσή του. Συνεπώς, καθίσταται απαραίτητη η ανάπτυξη τεχνικών και στρατηγικών βελτίωσης της ανθεκτικότητας των μοντέλων σε μεταβολές του πεδίου εφαρμογής, ειδικά σε πραγματικές συνθήκες όπου η ομοιογένεια των δεδομένων δεν είναι σχεδόν ποτέ εγγυημένη.

Η ανάπτυξη και εφαρμογή τεχνικών προσαρμογής πεδίου (*domain adaptation techniques*) αποτελεί κρίσιμο βήμα για την αντιμετώπιση των προκλήσεων που προκύπτουν από τις διαφορές μεταξύ των συνόλων δεδομένων. Ο βασικός στόχος αυτών των τεχνικών είναι η εκμάθηση αναπαραστάσεων που παραμένουν σταθερές και αξιόπιστες ακόμη και όταν μεταβάλλονται οι συνθήκες καταγραφής ή τα χαρακτηριστικά της πηγής των δεδομένων, διατηρώντας παράλληλα την ικανότητα του συστήματος να διακρίνει με ακρίβεια τις κλάσεις ενδιαφέροντος, δηλαδή τις παθήσεις των αναπνευστικών ήχων. Με αυτόν τον τρόπο, επιτυγχάνεται η ενίσχυση της γενικευσιμότητας και της αξιοπιστίας των μοντέλων διάγνωσης, καθώς εξασφαλίζεται υψηλή

απόδοση κατά τις δοκιμές σε ποικίλα περιβάλλοντα.

Σε κοινωνικό και πρακτικό επίπεδο, η επιτυχής αντιμετώπιση του προβλήματος της μετατόπισης τομέα θα μπορούσε να οδηγήσει στην ανάπτυξη φορητών ή διαδικτυακών διαγνωστικών εργαλείων, αξιοποιήσιμων σε περιβάλλοντα χαμηλών πόρων ή σε συνθήκες τηλεϊατρικής, διευρύνοντας έτσι την πρόσβαση σε έγκαιρη διάγνωση και παρακολούθηση αναπνευστικών παθήσεων σε παγκόσμια κλίμακα.

1.3 Προηγούμενες έρευνες και προκλήσεις

Η ανάλυση και αυτόματη ταξινόμηση αναπνευστικών ήχων έχει αναδειχθεί τα τελευταία χρόνια σε ένα πεδίο έντονης ερευνητικής δραστηριότητας, με στόχο την ανάπτυξη υπολογιστικών συστημάτων που μπορούν να υποστηρίξουν ή να βελτιώσουν τη διαγνωστική διαδικασία σε πνευμονοπάθειες. Η συστηματική μελέτη της βιβλιογραφίας επιτρέπει την αναγνώριση των τάσεων, των καινοτομιών αλλά και των υφιστάμενων περιορισμών, δημιουργώντας το απαραίτητο υπόβαθρο για τον σχεδιασμό και την υλοποίηση νέων προσεγγίσεων.

Συγκεκριμένα, έχουν πραγματοποιηθεί σημαντικές συστηματικές μελέτες, οι οποίες έχουν καταγράψει τις κυρίαρχες διαθέσιμες μεθοδολογίες, τα χρησιμοποιούμενα σύνολα δεδομένων, τα χαρακτηριστικά και τις επιδόσεις των μοντέλων. Κοινό εύρημα όλων αυτών των προσεγγίσεων είναι ότι η προσαρμογή πεδίου μπορεί να επιφέρει σημαντικές βελτιώσεις στην ακρίβεια της ταξινόμησης, αλλά η αποτελεσματικότητά της συνεχίζει να εξαρτάται σε μεγάλο βαθμό από τη φύση και την ένταση της μετατόπισης, καθώς και από τη διαθεσιμότητα επισημασμένων δεδομένων στο πεδίο στόχο (*target domain*). Συνολικά έχει παρατηρηθεί ότι αν και πολλές από τις υφιστάμενες έρευνες επιτυγχάνουν υψηλά ποσοστά ακρίβειας σε ελεγχόμενα πειράματα, η μεταφορά αυτών των αποτελεσμάτων σε πραγματικές κλινικές συνθήκες εξακολουθεί να παραμένει δύσκολη. Παράλληλα, η έλλειψη μεγάλων, ισορροπημένων και δημοσίως διαθέσιμων βάσεων δεδομένων αποτελεί εξίσου σημαντικό εμπόδιο. Οι περισσότερες έρευνες βλέπουμε ότι στηρίζονται σε σχετικά μικρά ή ιδιόκτητα σύνολα δεδομένων, γεγονός που περιορίζει αρκετά τη δυνατότητα σύγκρισης των αποτελεσμάτων και τη γενίκευση των συμπερασμάτων. Η δημιουργία κοινών πρωτοκόλλων καταγραφής, επισημείωσης και αξιολόγησης θα μπορούσε να επιτρέψει την καλύτερη αξιοποίηση και σύγκριση των μεθόδων.

Σε επίπεδο επιδόσεων, οι πλέον πρόσφατες έρευνες καταδεικνύουν ότι οι τεχνικές *state-of-the-art* μπορούν να επιτύχουν πολύ υψηλά ποσοστά ακρίβειας και άλλων δεικτών απόδοσης, ειδικά όταν τα δεδομένα εκπαίδευσης και αξιολόγησης προέρχονται από παρόμοιες συνθήκες. Ενδεικτικά, η χρήση **συνελικτικών νευρωνικών δικτύων (CNNs) σε φασματογραφικές αναπαραστάσεις** των ηχητικών δεδομένων έχει αναφερθεί να φτάνει ακρίβεια της τάξης του **90%** στην αναγνώριση τύπων αναπνευστικών ήχων (Y. Kim et al. 2021; Mercaldo et al. 2020). Ακόμη, **τεχνικές μεταφοράς μάθησης (transfer learning) και αντιθετικής εκπαίδευσης (contrastive learning)** αποδεικνύεται πως μπορούν να διατηρήσουν την ακρίβεια σε εξίσου σταθερά επίπεδα κοντά στο **80–85%** ακόμη και σε σενάρια *cross-domain*, δηλαδή πολλαπλών πεδίων, όπως και στη δικιά μας περίπτωση (J.-W. Kim et al. 2024). Τέλος, προσεγγίσεις προσαρμογής πεδίου με χρήση κατάλληλων **νευρωνικών**

δικτύων βαθιάς μάθησης έχουν καταφέρει να επιτύχουν βελτιώσεις της τάξης του 5–15 ποσοστιαίων μονάδων σε περιπτώσεις έντονης ετερογένειας συσκευών καταγραφής (*device mismatch*) σε σχέση με το τρέχον *baseline* (Wang et al. 2019; Islam et al. 2021). Ωστόσο, οι επιδόσεις αυτές φαίνεται πως μειώνονται αισθητά όταν η μετατόπιση πεδίου είναι πολυπαραγοντική, δηλαδή οφείλεται σε πολύπλευρες μεταβολές όπως ταυτόχρονη αλλαγή συσκευής, περιβάλλοντος και πληθυσμιακών χαρακτηριστικών. Το γεγονός που υποδεικνύει ότι η απόλυτη γενίκευση παραμένει ανεκπλήρωτος στόχος.

Μέθοδος	Σενάριο χρήσης	Απόδοση
<i>CNN</i> με <i>Transfer Learning</i> (Y. Kim et al. 2021)	<i>Same-domain</i>	90–92%
<i>Explainable CNN</i> (<i>XAI</i>) (Mercaldo et al. 2020)	<i>Same-domain</i>	~88%
<i>Spectrum Correction</i> (Kośmider 2020)	<i>Device mismatch</i>	+10–15%*
<i>Sound-Adapter</i> (<i>MSDA</i>) (Islam et al. 2021)	<i>Cross-domain</i>	+8–14%*
<i>Supervised Contrastive Learning</i> (J.-W. Kim et al. 2024)	<i>Cross-domain</i>	80–85%
<i>Co-Tuning</i> με <i>Stochastic Normalization</i> (Nguyen et al. 2022)	<i>Same-domain</i>	~89%

* αύξηση σε ποσοστιαίες μονάδες σε σχέση με το *baseline accuracy* χωρίς προσαρμογή τομέα.

Πίνακας 1.1: Σύνοψη *state-of-the-art* αποτελεσμάτων στην αυτόματη ανάλυση αναπνευστικών ήχων και στην ακουστική προσαρμογή πεδίου.

Ιδιαίτερη έμφαση έχει δοθεί στη μελέτη της τεχνικής **διόρθωσης φάσματος** (*spectrum correction*), η οποία προτάθηκε από τον *Michał Kośmider* (2020) και αποδείχθηκε ιδιαίτερα αποτελεσματική στην πρόκληση του *device mismatch*. Σε αντίθεση με πιο σύνθετες μεθοδολογίες προσαρμογής πεδίου που ενσωματώνονται στη διαδικασία εκπαίδευσης των νευρωνικών δικτύων, η συγκεκριμένη προσέγγιση διαφοροποιείται διότι αποτελεί μια απλή αλλά ισχυρή τεχνική κανονικοποίησης του φάσματος η οποία επιδρά κατευθείαν πάνω στις καταγραφές των σημάτων. Η βασική ιδέα της μεθόδου στηρίζεται σε ένα γραμμικό μοντέλο παραμόρφωσης, σύμφωνα με το οποίο η απόκριση συχνότητας κάθε συσκευής θεωρείται ότι πολλαπλασιάζει το πραγματικό σήμα, εισάγοντας μια χαρακτηριστική αλλοίωση στο φάσμα. Η διόρθωση φάσματος λοιπόν στοχεύει στη μετατροπή του φάσματος μιας ηχογράφησης που έχει καταγραφεί από μία συσκευή, ώστε να προσεγγίζει το αντίστοιχο φάσμα από μία συσκευή αναφοράς. Αυτό επιτυγχάνεται μέσω του υπολογισμού συντελεστών διόρθωσης για κάθε συχνότητα, οι οποίοι εκτιμώνται ως λόγος των φασματικών συνιστωσών μεταξύ της συσκευής αναφοράς και της υπό διόρθωση συσκευής. Αξιοσημείωτο είναι ότι η διόρθωση φάσματος μπορεί να εφαρμοστεί τόσο στον χώρο συχνότητων, όσο και απευθείας στον χρόνο, με τη χρήση φίλτρων πεπερασμένης χρονικής απόκρισης (*FIR filters*), χωρίς απώλεια στην απόδοση.

Για τη δική μας εργασία η προσέγγιση αυτή παρουσιάζει ιδιαίτερο ενδιαφέρον, καθώς η υπό μελέτη βάση δεδομένων εμφανίζει έντονη ετερογένεια ως προς τις συσκευές καταγραφής, όπως και η αντίστοιχη βάση δεδομένων *DCASE* που μελετήθηκε από τον *Kośmider*. Επομένως, η τεχνική της διόρθωσης φάσματος αποτελεί ένα εξαιρετικά σχετικό σημείο αναφοράς, το οποίο επιτρέπει την άμεση σύγκριση με τη μεθοδολογία που προτείνουμε.

Συνολικά λοιπόν θα μπορούσαμε να πούμε ότι οι πλέον πρόσφατες προσεγγίσεις στην αυ-

τόματη ανάλυση και ταξινόμηση αναπνευστικών ήχων επιτυγχάνουν ποσοστά ακρίβειας που κυμαίνονται από περίπου 90% σε συμβατικά *same-domain* σενάρια έως και 80–85% σε απαιτητικά *cross-domain* περιβάλλοντα όπου υφίσταται έντονη μετατόπιση. Σενάρια από την άλλη όπως το δικό μας με σημαντική ετερογένεια συσκευών (*device mismatch*) ή *multi-source* δεδομένα δείχνουν ότι οι μέθοδοι προσαρμογής πεδίου μπορούν να αποφέρουν ναι μεν σημαντικές αλλά μικρότερες βελτιώσεις της τάξης των 5–15 ποσοστιαίων μονάδων σε σχέση με το τρέχον *baseline*.

1.4 Στόχοι και συνεισφορά της διπλωματικής εργασίας

Παρατηρείται ότι η υπάρχουσα βιβλιογραφία αφήνει σε δεύτερο πλάνο την προσεκτικά επιμελημένη χειροκίνητη εξαγωγή χαρακτηριστικών από τις αναπαραστάσεις των αναπνευστικών σημάτων, καθώς οι περισσότερες έρευνες τείνουν να χρησιμοποιούν πιο σύνθετες μορφές αναπαράστασης των ήχων ως είσοδο για τα μοντέλα, όπως για παράδειγμα τα φασματογραφήματα (*spectrograms*) με τη μορφή εικόνας. Επίσης, τα σενάρια προσαρμογής πεδίου συνήθως περιλαμβάνουν πολύπλευρο *domain shift* με αποτέλεσμα να μην απομονώνεται καθαρά η συμβολή της άρσης του *device mismatch* στην ακρίβεια της ταξινόμησης. Ως συνέπεια, παραμένει μερικώς αναπάντητο το κατά πόσο και μέχρι ποιο βαθμό η στοχευμένη απομάκρυνση του *device bias* από τα ίδια τα εξαγμένα χαρακτηριστικά μπορεί να επιφέρει συγκρίσιμη ή και ανώτερη απόδοση σε συνδυασμό με πολύ μικρότερο υπολογιστικό αποτύπωμα. Τέλος, από τη μία γνωρίζουμε ότι η διόρθωση φάσματος (*spectrum correction*) παρέχει άμεσο κέρδος σε *cross-device* σενάρια με χαμηλό κόστος, αλλά υστερεί όταν οι κατανομές των επιμέρους χαρακτηριστικών πέρα από τη συσχετιζόμενη πληροφορία συσκευής εμπεριέχουν και ουσιώδη διακριτική πληροφορία για τις κλάσεις. Από την άλλη, οι μέθοδοι προσαρμογής με βαθιά μάθηση μπορούν να ενσωματώσουν ρητά την πληροφορία της κλάσης στη διαδικασία προσαρμογής, ελαχιστοποιώντας τον κίνδυνο αυτής της απώλειας. Συνολικά όμως θα λέγαμε πως απουσιάζει μία συστηματική, *head-to-head* σύγκριση μεταξύ αυτών των δύο προσεγγίσεων σε ελεγχόμενα σενάρια με μετατόπιση η οποία έχει προκύψει αποκλειστικά από συσκευές. Η αξιολόγηση και αντιπαραβολή των δύο προσεγγίσεων καθιστά εφικτή την εκτίμηση του κατά πόσο πιο προηγμένες τεχνικές προσαρμογής πεδίου όπως αυτές που εφαρμόζονται στην παρούσα εργασία μπορούν να ξεπεράσουν ή να συμπληρώσουν μια πιο απλή αλλά αποτελεσματική στρατηγική κανονικοποίησης, όπως η διόρθωση φάσματος.

Στόχος είναι συνεπώς να καλυφθεί το παραπάνω κενό υλοποιώντας ένα καθαρό πρωτόκολλο αυστηρής απομόνωσης και αφαίρεσης του μεροληψίας της συσκευής με την υπόθεση ότι βρισκόμαστε σε σταθερά περιβάλλοντα και πληθυσμό, όπου αυτό είναι εφικτό, ώστε να μετρηθεί αποκλειστικά η επίδραση του *device mismatch*. Επίσης, η χρήση ελαφρύτερων μοντέλων ως τελικά μοντέλα ταξινόμησης των αναπνευστικών ήχων στοχεύει στην αποτίμηση της καθαρής ωφέλειας της προσαρμογής τομέα ανεξάρτητα από πολύπλοκους βαθείς ταξινομητές.

Στο πλαίσιο της παρούσας διπλωματικής εργασίας, όπου η ανάπτυξη, βελτιστοποίηση και εκπαίδευση των μοντέλων πραγματοποιείται με περιορισμένους υπολογιστικούς πόρους και διαθέσιμα δεδομένα, ένα ρεαλιστικό εύρος απόδοσης για απαιτητικά σενάρια *cross-device* όπως

το δικό μας εκτιμάται κοντά στο **75–78%**, εξασφαλίζοντας παράλληλα σαφές κέρδος τουλάχιστον **5-10 ποσοστιαίων μονάδων** σε σχέση με το *baseline* απόδοσης χωρίς προσαρμογή. Επιδόσεις που υπερβαίνουν το 80% θα θεωρούνταν ιδιαίτερα ικανοποιητικές με βάση και τη διαθέσιμη βιβλιογραφία, δεδομένων των προκλήσεων που εισάγει η ετερογένεια του σήματος και των κατανομών μεταξύ των πεδίων. Επιπλέον, στη συγκεκριμένη εργασία περιλαμβάνεται και η διεξοδική ανάλυση ευαισθησίας ως προς τα επιμέρους χαρακτηριστικά και τις διαφορετικές συσκευές καταγραφής, μέσω πειραμάτων και οπτικοποίησης του *device invariance* πριν και μετά την εφαρμογή των μεθόδων προσαρμογής.


Κεφάλαιο 2

Αναπνευστικά σήματα: από τη φυσιολογία στην προσαρμογή πεδίου

2.1 Ανατομία και φυσιολογία του αναπνευστικού συστήματος


2.1.1 Παραγωγή αναπνευστικών ήχων

Το ανθρώπινο αναπνευστικό σύστημα αποτελείται από ένα δίκτυο οργάνων και αεραγωγών που έχουν ως κύρια λειτουργία την ανταλλαγή μορίων αερίων, δηλαδή την πρόσληψη οξυγόνου και την αποβολή διοξειδίου του άνθρακα. Η αναπνευστική οδός χωρίζεται σε ανώτερη και κατώτερη, περιλαμβάνοντας τη ρινική και στοματική κοιλότητα, τον φάρυγγα, τον λάρυγγα, την τραχεία, τους βρόγχους και τελικά τις κυψελίδες των πνευμόνων, όπου πραγματοποιείται η ανταλλαγή των δύο αερίων. Κατά τη δίοδο του αέρα μέσα από αυτές τις δομές, δημιουργούνται μηχανικές δονήσεις και στροβιλισμοί που αποτελούν την κύρια πηγή των αναπνευστικών ήχων. Οι δονήσεις αυτές συνδέονται άμεσα με τη μορφολογία του **αναπνευστικού δέντρου** (*bronchial tree*), δηλαδή του συστήματος διαδοχικών διακλαδώσεων που ξεκινά από την τραχεία, συνεχίζει προς τους βρόγχους και καταλήγει στα βρογχιόλια και τις κυψελίδες.




Σχήμα 2.1: Αναπνευστικό δέντρο. (Oiseth et al. 2024)

Σε κάθε επίπεδο διακλάδωσης του δέντρου, η ταχύτητα και η φύση της ροής του αέρα μεταβάλλονται. Η ροή του αέρα πιο συγκεχυμένα μπορεί να είναι είτε στρωτή, είτε τυρβώδης. Η στρωτή ροή είναι ομαλή και χωρίς σημαντικές διακυμάνσεις πίεσης, ενώ από την άλλη η τυρβώδης ροή χαρακτηρίζεται από στροβιλισμούς και έντονες διακυμάνσεις πίεσης που οδηγούν στη δημιουργία ακουστικών κυμάτων.



Σχήμα 2.2: Στρωτή ροή αέρα. (Sarkar et al. 2015)



Σχήμα 2.3: Τυρβώδης ροή αέρα. (Sarkar et al. 2015)

Η γεωμετρία του αναπνευστικού δέντρου θα λέγαμε ότι λειτουργεί, συνεπώς, ως φυσικό φίλτρο που διαμορφώνει τα ακουστικά χαρακτηριστικά των αναπνευστικών ήχων ανάλογα με το σημείο προέλευσής τους. Με τον τρόπο αυτό, το αναπνευστικό δέντρο δεν αποτελεί απλώς αγωγό για τη ροή του αέρα, αλλά και το βασικό ακουστικό υπόστρωμα που καθορίζει την τελική μορφή των αναπνευστικών ήχων.

Κατά την έναρξη της παραγωγής του αναπνευστικού ήχου, παρατηρείται ύπαρξη τυρβώδους ροής στις μεγάλες και ανώτερες αεροφόρες οδούς (τραχεία, κύριοι βρόγχοι) ή σε περιοχές στένωσης και αλλαγής διατομής, παράγοντας ήχους υψηλότερης έντασης και ευρύτερου φασματικού περιεχομένου. Καθώς όμως ο αέρας προχωρά προς τις μικρότερες διακλαδώσεις του δέντρου, η ροή γίνεται πιο ομαλή και στρωτή, με αποτέλεσμα ήχους χαμηλότερης έντασης και συχνотικής κατανομής. Οι διακυμάνσεις αυτές της πίεσης που δημιουργούνται από τις μεταβολές στη ροή του αέρα μεταδίδονται μέσω του πνευμονικού παρεγχύματος και του θωρακικού τοιχώματος και συνεπώς υφίστανται φασματική απορρόφηση αλλά και διασπορά κατά τη διάδοση. Το τελικό ακουστικό σήμα που καταγράφεται από έναν αισθητήρα ή στηθοσκόπιο είναι επομένως το αποτέλεσμα τόσο της πρωτογενούς παραγωγής ήχου (πηγή), όσο και της τροποποίησής του λόγω των ιδιοτήτων διάδοσης του ιστού και της γεωμετρίας του θωρακικού τοιχώματος.


Σε φυσιολογικές συνθήκες, οι ήχοι αναπνοής προέρχονται κυρίως από ήπια τύρβη σε μεγάλες αεροφόρες διαμέτρους, με ευρύ φασματικό περιεχόμενο (τυπικά 100–1200 Hz) και χαμηλή ένταση. Η φασματική ενέργεια κατανέμεται ομαλά, χωρίς έντονες αρμονικές αιχμές. Αντίθετα, σε παθολογικές καταστάσεις, όπως φλεγμονές, υπερέκκριση βλέννας ή στένωση αεραγωγών (π.χ. άσθμα, ΧΑΠ), εμφανίζονται χαρακτηριστικά ηχητικά μοτίβα, τα οποία μπο-

ρεί να οφείλονται αφενός σε δονήσεις τοιχωμάτων στενωμένων αεραγωγών και αφετέρου σε απότομο άνοιγμα ή κλείσιμο μικρών αεραγωγικών δομών κατά την πρόιμη εισπνοή ή στην όψιμη εκπνοή.

Συνολικά, η παραγωγή και μετάδοση των αναπνευστικών ήχων αποτελεί το αποτέλεσμα **σύνθετης αλληλεπίδρασης** μεταξύ τριών παραγόντων: του **αεροδυναμικού καθεστώτος ροής**, της **ανατομικής γεωμετρίας των αεραγωγών** και των **μηχανικών και ακουστικών ιδιοτήτων των ιστών** κατά τη διάδοση του κύματος (Priftis et al. 2018; Sarkar et al. 2015).

2.1.2 Διαχωρισμός φυσιολογικών και παθολογικών ήχων

Οι ήχοι που παράγονται κατά τη διάρκεια της αναπνοής διακρίνονται καταρχάς σε δύο βασικές κατηγορίες: τους **ήχους αναπνοής** (*breath sounds*) και τους **πρόσθετους ήχους** (*adventitious sounds*). Η διαχωρισμότητα αυτών των δύο κατηγοριών βασίζεται κυρίως σε φυσιολογικά, ακουστικά και μορφολογικά χαρακτηριστικά που σχετίζονται με την αεροδυναμική ροή του αέρα, τη δομή των αεραγωγών και την πιθανή παρουσία παθολογικών μεταβολών στο πνευμονικό παρέγχυμα (Priftis et al. 2018).



Σχήμα 2.4: Οπτική αναπαράσταση του διαχωρισμού μεταξύ φυσιολογικών και παθολογικών αναπνευστικών ήχων. (Διαδίκτυο)

Οι **ήχοι αναπνοής** περιλαμβάνουν αρχικά τους **φυσιολογικούς ήχους** (*normal breath sounds*), όπως οι τραχειακοί, οι κυψελιδικοί και οι βρογχικοί, οι οποίοι παράγονται από τη στρωτή ροή του αέρα στους πνεύμονες και είναι γενικά συνεχείς, προβλέψιμοι και ομαλοί. Αντιπροσωπεύουν θα μπορούσαμε να πούμε την αναμενόμενη ηχητική δραστηριότητα ενός υγιούς πνεύμονα κατά την αναπνοή. Ωστόσο, η παρουσία αλλοιώσεων στους φυσιολογικούς ήχους, όπως εξασθένιση, ενίσχυση ή μετατόπισή τους σε μη αναμενόμενες περιοχές, οδηγεί στην δεύτερη υποκατηγορία των **μη φυσιολογικών ήχων αναπνοής** (*abnormal breath sounds*). Αυτοί οι ήχοι εξακολουθούν να ανήκουν στη βασική κατηγορία των αναπνευστικών ήχων, αλλά διαφοροποιούνται σε σχέση με τη φυσιολογική ακουστική εικόνα ενός υγιούς

πνεύμονα.

Από την άλλη πλευρά, οι **πρόσθετοι ήχοι** (*adventitious sounds*) αποτελούν νέα ακουστικά συμβάντα που δεν υπάρχουν υπό φυσιολογικές συνθήκες και επικαλύπτουν ή προστίθενται στους βασικούς ήχους αναπνοής. Πρόκειται για ήχους που παράγονται συνήθως λόγω μηχανικής απόφραξης, φλεγμονής, εκκρίσεων ή αλλαγών στην ελαστικότητα των πνευμόνων. Οι πιο συχνές υποκατηγορίες τέτοιων ήχων είναι οι **ρόγχοι** (*crackles*), οι **συριγμοί** (*wheezes*) και οι **ρογχώδεις ήχοι** (*rhonchi*), ενώ σε κάποιες περιπτώσεις περιλαμβάνονται και άλλοι συνεχείς ή μη κατηγοριοποιημένοι ήχοι. Οι πρόσθετοι ήχοι ανήκουν και αυτοί στην ευρύτερη κατηγορία των μη φυσιολογικών ήχων αναπνοής, αλλά διακρίνονται επειδή συνιστούν σαφώς προστιθέμενες ακουστικές εκδηλώσεις και όχι απλώς παραλλαγές των φυσιολογικών. Τέτοιοι ήχοι σχετίζονται με πληθώρα παθολογικών καταστάσεων, όπως η Πνευμονία, η Χρόνια Αποφρακτική Πνευμονοπάθεια (ΧΑΠ), το Άσθμα, η Καρδιακή Ανεπάρκεια και οι διάμεσες Πνευμονοπάθειες.

Για τους σκοπούς της παρούσας εργασίας, η ανάλυση θα εστιάσει σε δύο από τις συνηθέστερες μορφές *adventitious* ήχων: τους **ρόγχους** (*crackles*) και τους **συριγμούς** (*wheezes*), οι οποίοι αποτελούν καθοριστικούς δείκτες στη διαγνωστική αξιολόγηση και μπορούν να ανιχνευθούν τόσο με την παραδοσιακή ακρόαση όσο και με σύγχρονες τεχνικές ανάλυσης σήματος.

Ρόγχοι (Crackles) Οι ρόγχοι γενικά είναι **διαλείποντες, μη μουσικοί, βραχείας διάρκειας και εκρηκτικοί ήχοι**. Ο όρος διαλείποντες αναφέρεται στο γεγονός ότι δεν πρόκειται για συνεχείς ή σταθερούς ήχους, αλλά για ήχους που εμφανίζονται στιγμιαία και ασυνεχώς κατά τη διάρκεια του αναπνευστικού κύκλου, κυρίως κατά την εισπνοή. Επίσης, η περιγραφή μη μουσικοί δηλώνει ότι οι ρόγχοι δεν έχουν σταθερό τόνο ή μελωδία σε αντίθεση με τους συριγμούς που εμφανίζουν συχνотικά μοτίβα με μουσικό χαρακτήρα. Η βραχεία διάρκεια υποδηλώνει ότι κάθε επιμέρους ήχος διαρκεί ελάχιστα χιλιοστά του δευτερολέπτου, γεγονός που καθιστά τον εντοπισμό τους ιδιαίτερα δύσκολο χωρίς εξειδικευμένο εξοπλισμό. Τέλος, ο χαρακτηρισμός εκρηκτικοί αποδίδει πιο διαισθητικά την ακουστική τους αίσθηση, καθώς πρόκειται για ήχους που ξεκινούν απότομα και θυμίζουν μικρές εκρήξεις ή σπάσιμο φυσαλίδων, γεγονός που αποδίδεται στις ταχείες μεταβολές πίεσης και τάσης κατά το άνοιγμα ή το κλείσιμο των αεραγωγών. Διακρίνονται σε δύο βασικούς τύπους: τους **λεπτούς ρόγχους** (*fine crackles*) και τους **χονδροειδείς ρόγχους** (*coarse crackles*). Ωστόσο, στη παρούσα εργασία δεν θα μας απασχολήσει η διάκριση ανάμεσα στις δύο κατηγορίες ρόγχων, οπότε θα θεωρούνται μια ενιαία κατηγορία πρόσθετου παθολογικού ήχου.

Συριγμοί (Wheezes) Οι συριγμοί είναι **συνεχόμενοι, μουσικοί, υψηλής συχνότητας ήχοι** που παράγονται κυρίως κατά τη φάση της εκπνοής, αν και σε σοβαρότερες περιπτώσεις μπορεί να εμφανίζονται και κατά την εισπνοή ή να έχουν διφασικό χαρακτήρα. Ο όρος συνεχόμενοι δηλώνει ότι παρουσιάζουν παρατεταμένη διάρκεια και ακολουθούν σχετικά σταθερό χρονικό μοτίβο. Ο χαρακτηρισμός μουσικοί υποδηλώνει ότι διαθέτουν σταθερή ή σχεδόν σταθερή συχνότητα, γεγονός που τους προσδίδει ακουστικά την αίσθηση ενός τόνου ή

λεπτού σφυρίγματος, σε αντίθεση με τους μη μουσικούς και ακανόνιστους ήχους των *crackles*.

Τύπος ήχου	Συνέχεια	Διάρκεια	Χρονισμός	Ύψος (<i>Pitch</i>)	Ηχητική ποιότητα
<i>Normal</i>	Συνεχής	Μεταβλητή	Εισπνοή και Εκπνοή	Χαμηλό-μέσο (100–600 <i>Hz</i>)	Ήπιος, μη μου- σικός
<i>Wheeze</i>	Συνεχής	>80 <i>ms</i>	Κυρίως εκ- πνοή, πιο σπάνια ει- σπνοή ή και τα δύο	Υψηλό (>400 <i>Hz</i>)	Σφυριχτός, μουσικός
<i>Fine Crackle</i>	Ασυνεχής	±5 <i>ms</i>	Κυρίως ει- σπνοή (τέλη εισπνοής)	Υψηλό (650 <i>Hz</i>)	Μη μουσικός, εκρηκτικός
<i>Coarse Crackle</i>	Ασυνεχής	±15 <i>ms</i>	Πρώιμη εισπνοή, εκ- πνοή ή και τα δύο	Χαμηλό (350 <i>Hz</i>)	Μη μουσικός, εκρηκτικός

Πίνακας 2.1: Διαφορές φυσιολογικών και παθολογικών αναπνευστικών ήχων (Pramono, Bowyer, et al. 2017)

2.2 Αναπνευστικά σήματα

2.2.1 Ορισμός, μεγέθη και ιδιότητες

Σήμα Ορίζεται ως μια συνάρτηση μίας ή παραπάνω μεταβλητών που μεταφέρει πληροφορία σχετικά με τη συμπεριφορά ή τα χαρακτηριστικά ενός φυσικού φαινομένου. Ένα σήμα μπορεί να παριστά ακουστική πίεση, θερμοκρασία, τάση, φωτεινότητα, ή οποιοδήποτε φυσικό μέγεθος μεταβάλλεται ως προς το χρόνο ή οποιαδήποτε άλλη ανεξάρτητη μεταβλητή. Μια τέτοια κατηγορία σημάτων είναι τα ηχητικά ή ακουστικά σήματα.

Ηχητικό σήμα (Lerch 2012) Είναι η φυσική αναπαράσταση της διαταραχής που προκαλείται από την κίνηση μορίων ενός μέσου εξαιτίας της ταλάντωσης μιας ηχητικής πηγής. Η διαταραχή αυτή μεταδίδεται υπό μορφή μηχανικών κυμάτων πίεσης και γίνεται αντιληπτή από το ανθρώπινο αυτί ως ήχος. Στην περίπτωση των **αναπνευστικών ήχων**, η ηχητική πηγή δεν είναι ένα εξωτερικό αντικείμενο, αλλά η ίδια η ροή του αέρα στους αεραγωγούς του αναπνευστικού συστήματος. Συνεπώς, με βάση αυτό μπορούμε να ορίσουμε και το αναπνευστικό σήμα ως μια υποκατηγορία ηχητικού σήματος ως εξής:

Αναπνευστικό σήμα Αποτελεί τη χρονική καταγραφή των αναπνευστικών ήχων, όπως αυτοί ανιχνεύονται σε επιλεγμένες επιφάνειες του θωρακικού τοιχώματος ή της τραχείας με κατάλληλες συσκευές καταγραφής, όπως αισθητήρες, μικρόφωνα ή στηθοσκόπια. Το σήμα αυτό περιλαμβάνει πληροφορία για την ένταση, τη συχνότητα, τη διάρκεια και τη χροιά του αναπνευστικού ήχου και μεταβάλλεται φυσιολογικά κατά τη φάση της εισπνοής και της εκπνοής.

Η ανάλυση των αναπνευστικών σημάτων παρέχει σημαντικές ενδείξεις για την καλή ή κακή λειτουργία του αναπνευστικού συστήματος του ασθενούς και αποτελεί αντικείμενο τόσο της ιατρικής διαγνωστικής όσο και της σύγχρονης ψηφιακής επεξεργασίας σήματος. Από φυσική άποψη, πρόκειται για **μη περιοδικά, μη αρμονικά, χαμηλής έως μέσης συχνότητας ηχητικά σήματα**, των οποίων το ενεργειακό φάσμα εκτείνεται κατά κύριο λόγο στην περιοχή των **100–1200 Hz**.

Στο πλαίσιο της επεξεργασίας σήματος, το αναπνευστικό σήμα αναπαρίσταται ως μια μαθηματική συνάρτηση του χρόνου:

$$x(t), \quad t \in \mathbb{R}$$

όπου $x(t)$ είναι το στιγμιαίο πλάτος του ηχητικού σήματος σε σχέση με τον χρόνο t .

Αρχικά, είναι σημαντικό να ορίσουμε πρώτα κάποια βασικά μεγέθη της θεωρίας σημάτων, μεταξύ των οποίων:

Πλάτος (Amplitude) Είναι η μέγιστη τιμή της απόλυτης τιμής του σήματος σε κάποιο χρονικό διάστημα.

$$A = \max_t |x(t)| \quad (2.1)$$

Στα ηχητικά σήματα αντιστοιχεί στη μέγιστη ακουστική πίεση.

Συχνότητα (Frequency) Ορίζεται για περιοδικά σήματα ως ο αριθμός κύκλων ανά δευτερόλεπτο. Αν η περίοδος του σήματος είναι T , τότε η συχνότητα είναι:

$$f = \frac{1}{T} \quad (2.2)$$

Φάση (Phase) Για αρμονικά σήματα της μορφής $x(t) = A \cos(2\pi ft + \phi)$, η ϕ είναι η αρχική φάση και αντιπροσωπεύει τη χρονική μετατόπιση ενός κύματος ως προς κάποιο σημείο αναφοράς. Στη φασματική ανάλυση, η φάση καθορίζει τη χρονική ευθυγράμμιση μεταξύ συχνοτικών συνιστωσών. Αν και δεν γίνεται απευθείας αντιληπτή από το ανθρώπινο αυτί, είναι κρίσιμη σε εφαρμογές όπως η υπέρθεση σημάτων, η ανασύνθεση κυματομορφών και η τρισδιάστατη ακουστική απεικόνιση.

Ενέργεια (Energy) Η συνολική ενέργεια ενός σήματος εκφράζει το σύνολο της «έντασης» που περιέχει το σήμα σε όλο τον χρόνο. Ορίζεται ως:

$$E = \int_{-\infty}^{\infty} |x(t)|^2 dt \quad (2.3)$$

και αποτελεί ένα μέτρο χρήσιμο για σήματα πεπερασμένης διάρκειας, όπως π.χ. ένας εισπνευστικός ήχος που καταγράφηκε για μερικά δευτερόλεπτα. Όσο μεγαλύτερη η ενέργεια, τόσο εντονότερο είναι και το σήμα.

Ισχύς (Power) Για σήματα θεωρητικά άπειρης διάρκειας ή περιοδικά σήματα, η ενέργεια καθίσταται απεριόριστη, οπότε χρησιμοποιείται η **μέση ισχύς**:

$$P = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T |x(t)|^2 dt \quad (2.4)$$

Η ισχύς αντιπροσωπεύει τη ρυθμό μετάδοσης ενέργειας και είναι χρήσιμη στην αξιολόγηση σήματος σε συνεχή λειτουργία. Αναπνευστικά σήματα περιοδικής φύσης συχνά προσεγγίζονται ως σήματα ισχύος.

Ένταση ήχου (Sound Intensity) Η ένταση ήχου είναι ένα φυσικό μέγεθος που εκφράζει τη ροή ηχητικής ενέργειας ανά μονάδα επιφάνειας και μονάδα χρόνου. Ορίζεται ως:

$$I = \frac{P}{A} \quad (2.5)$$

όπου P είναι η ακουστική ισχύς (σε W) και A η επιφάνεια διάδοσης. Η ένταση εκφράζεται συχνά σε λογαριθμική κλίμακα (dB):

$$L_I = 10 \log_{10} \left(\frac{I}{I_0} \right) \text{ dB} \quad (2.6)$$

με $I_0 = 10^{-12} \text{ W/m}^2$ ως τιμή αναφοράς στο κατώφλι ακοής. Για αναπνευστικά σήματα, η ένταση σχετίζεται με τη δύναμη της ροής του αέρα στους αεραγωγούς και διαφέρει σημαντικά μεταξύ φυσιολογικής και παθολογικής αναπνοής.

Ύψος ήχου (Pitch) Είναι η ψυχοακουστική αντίληψη του ύψους ενός ήχου, δηλαδή αν ακούγεται ψηλός ή βαθύς. Ενώ στα αρμονικά σήματα σχετίζεται άμεσα με τη θεμελιώδη συχνότητα ($f_0 = 1/T_0$), στους πολύπλοκους και μη αρμονικούς ήχους όπως οι αναπνευστικοί μπορεί να είναι δύσκολο να προσδιοριστεί.

Τα αναπνευστικά σήματα ως μαθηματικές συναρτήσεις χαρακτηρίζονται επίσης και από συγκεκριμένες ιδιότητες που επηρεάζουν καθοριστικά τον τρόπο με τον οποίο αναλύονται και επεξεργάζονται. Η κατανόηση αυτών των ιδιοτήτων είναι απαραίτητη τόσο για την επιλογή κατάλληλων τεχνικών επεξεργασίας όσο και για την ερμηνεία των αποτελεσμάτων, ιδιαίτερα όταν πρόκειται για βιοϊατρικά ακουστικά σήματα όπως οι αναπνευστικοί ήχοι. Οι βασικές ιδιότητες των αναπνευστικών σημάτων που σχετίζονται με την παρούσα μελέτη είναι:

Περιοδικότητα Ένα σήμα $x(t)$ λέγεται περιοδικό αν υπάρχει θετική σταθερά T (περίοδος) τέτοια ώστε:

$$x(t) = x(t + T), \quad \forall t \in \mathbb{R}. \quad (2.7)$$

Τα περιοδικά σήματα έχουν επαναλαμβανόμενη δομή στον χρόνο, γεγονός που επιτρέπει την ανάλυσή τους μέσω αρμονικών συνιστωσών με χρήση σειράς *Fourier*. **Στην περίπτωση των αναπνευστικών σημάτων η περιοδικότητα δεν ισχύει σε αυστηρό μαθηματικό επίπεδο.** Το αναπνευστικό σήμα μεταβάλλεται από κύκλο σε κύκλο, τόσο ως προς τη διάρκεια εισπνοής/εκπνοής όσο και ως προς την ένταση και τη φασματική του δομή. Επομένως, το σήμα θεωρείται **μη περιοδικό**. Ωστόσο, σε ορισμένες παθολογικές καταστάσεις όπως οι συριγμοί παρατηρείται μια ημι-περιοδική συμπεριφορά, δηλαδή το σήμα παρουσιάζει περιοχές σχεδόν περιοδικού μοτίβου, λόγω της στροβιλώδους ροής του αέρα σε στενωμένους αεραγωγούς.

Στασιμότητα Αφορά τη χρονική σταθερότητα των στατιστικών χαρακτηριστικών του αναπνευστικού σήματος. Υπάρχουν δύο βασικοί τύποι:

- **Ασθενής στασιμότητα:** Ένα στοχαστικό σήμα $x(t)$ είναι ασθενώς στάσιμο όταν:

1. Η μέση τιμή του είναι σταθερή και ανεξάρτητη από το χρόνο:

$$\mathbb{E}[x(t)] = \mu, \quad \forall t \quad (2.8)$$

2. Η συνάρτηση αυτοσυσχέτισής του εξαρτάται μόνο από τη χρονική διαφορά $t_1 - t_2$:

$$R_{xx}(t_1, t_2) = R_{xx}(t_1 - t_2) = R_{xx}(\tau) \quad (2.9)$$

- **Ισχυρή στασιμότητα:** Ισχύει όταν η κατανομή πιθανότητας οποιουδήποτε συνδυασμού τιμών του σήματος είναι ανεξάρτητη της χρονικής μετατόπισης, δηλαδή:

$$F_{x(t_1), x(t_2), \dots, x(t_n)} = F_{x(t_1+\tau), x(t_2+\tau), \dots, x(t_n+\tau)}, \quad \forall t_i, \forall \tau \quad (2.10)$$


Τα αναπνευστικά σήματα δεν είναι στάσιμα, καθώς η μέση τιμή, η διακύμανση και το φασματικό περιεχόμενο μεταβάλλονται στη διάρκεια του αναπνευστικού κύκλου και μεταξύ διαφορετικών κύκλων. Αυτό περιορίζει την εφαρμογή κλασικών τεχνικών φασματικής ανάλυσης (όπως *FFT* σε ολόκληρο το σήμα) και απαιτεί τη χρήση εργαλείων όπως ο *Short Time Fourier Transform (STFT)*, ο οποίος θα αναλυθεί εκτενέστερα παρακάτω.

Στοχαστικότητα Ένα σήμα μπορεί να είναι ντετερμινιστικό (*deterministic*) αν η μορφή του μπορεί να προβλεφθεί από έναν συγκεκριμένο μαθηματικό τύπο χωρίς αβεβαιότητα. Από την άλλη, είναι στοχαστικό (*stochastic*) όταν περιέχει τυχαίες συνιστώσες και περιγράφεται μόνο μέσω στατιστικών μέτρων (μέση τιμή, διακύμανση, κατανομή πιθανότητας). **Τα αναπνευστικά σήματα έχουν στοχαστική φύση** για δύο βασικούς λόγους. Πρώτον, η παραγωγή ήχου εξαρτάται από τη φυσιολογία και την ανατομία του κάθε ατόμου, αλλά και από δυναμικούς παράγοντες όπως ο όγκος και η ταχύτητα ροής του αέρα. Δεύτερον, τα σήματα από συσκευές επηρεάζονται από εξωτερικούς ή μη αναπνευστικούς ήχους (καρδιακοί ήχοι, ομιλία, θόρυβος περιβάλλοντος), προσθέτοντας στοχαστική διακύμανση.

2.2.2 Τρόποι καταγραφής

Η καταγραφή των αναπνευστικών ήχων αποτελεί απαραίτητη προϋπόθεση για την αντικειμενική ανάλυση και αξιολόγησή τους με τη βοήθεια σύγχρονων τεχνικών ψηφιακής επεξεργασίας σήματος (*Digital Signal Processing, DSP*). Για τον σκοπό αυτό, χρησιμοποιούνται εξειδικευμένες ιατρικές συσκευές ικανές να συλλάβουν με υψηλή ακρίβεια τα χαμηλά επίπεδα έντασης και το ευρύ φασματικό περιεχόμενο των ήχων που παράγονται κατά την αναπνοή. Οι συσκευές αυτές μάλιστα μπορούν να τοποθετηθούν κατά την ακρόαση σε διαφορετικά σημεία της **θωρακικής κοιλότητας** και της **τραχείας**, με κάθε περιοχή να προσφέρει διαφορετική διαγνωστική πληροφορία. Η πρόσθια θωρακική επιφάνεια χρησιμοποιείται κυρίως για την καταγραφή ήχων που προέρχονται από τους άνω λοβούς των πνευμόνων, ενώ η οπίσθια θωρακική επιφάνεια θεωρείται η πλέον αξιόπιστη για την ανίχνευση ήχων από τους κάτω λοβούς, όπου συχνά εντοπίζονται παθολογικά ευρήματα. Επιπλέον, οι πλάγιες περιοχές του θώρακα συμβάλλουν στην αξιολόγηση των μεσαίων και κατώτερων λοβών, συμπληρώνοντας την κλινική εικόνα. Τέλος, ιδιαίτερη σημασία έχουν οι καταγραφές από την τραχεία και την υπερστερνική περιοχή, οι οποίες παρέχουν τους λεγόμενους τραχειακούς αναπνευστικούς ήχους, οι οποίοι χαρακτηρίζονται από διαφορετικό φασματικό προφίλ σε σχέση με τους πνευμονικούς και συχνά χρησιμοποιούνται ως σημείο αναφοράς.

Η επιλογή της κατάλληλης θέσης καταγραφής εξαρτάται από τον κλινικό στόχο της εξέτασης. Οι τραχειακοί ήχοι είναι συνήθως ισχυρότεροι και καθαρότεροι, επιτρέποντας ευκολότερη ανίχνευση, ενώ οι ήχοι από τις περιφερικές περιοχές των πνευμόνων μπορούν να αποκαλύψουν λεπτές παθολογικές αλλοιώσεις, όπως κροταλίσματα ή συρίττοντες ήχους. Συνεπώς, η ορθολογική επιλογή σημείων καταγραφής αποτελεί καθοριστικό παράγοντα για την ακρίβεια και την αξιοπιστία τόσο της κλινικής ακρόασης όσο και της αυτόματης ανάλυσης μέσω συστημάτων μηχανικής μάθησης.




Σχήμα 2.5: Θέσεις καταγραφής αναπνευστικών ήχων κατά την ακρόαση. (Squires 2022)

Όσον αφορά τα είδη των συσκευών καταγραφής, χρησιμοποιούνται κατά κύρια βάση τα **στηθοσκόπια**, τα οποία διακρίνονται σε **ακουστικά** και **ψηφιακά**, αλλά και **ηλεκτρονικοί αισθητήρες υψηλής ευαισθησίας** σε εξειδικευμένα κλινικά περιβάλλοντα.



Σχήμα 2.6: Συσκευές καταγραφής αναπνευστικών ήχων. (Διαδίκτυο)

Ακουστικό στηθοσκόπιο Το ακουστικό στηθοσκόπιο αποτελεί το ιστορικά καθιερωμένο εργαλείο κλινικής ακρόασης, βασιζόμενο στη μηχανική μετάδοση του ήχου μέσω ελαστικών σωλήνων από το θωρακικό τοίχωμα στο αυτί του εξεταστή. Παρά τη διαχρονική του αξία, παρουσιάζει ορισμένους περιορισμούς, όπως το ότι δεν υποστηρίζει απευθείας καταγραφή ή ψηφιακή ανάλυση ή ότι η ποιότητα του ακουστικού σήματος επηρεάζεται από θορύβους περιβάλλοντος και από την ακουστική οξύτητα του εξεταστή. Συνεπώς, η ερμηνεία του ήχου εξαρτάται σε μεγάλο βαθμό από την εμπειρία και την υποκειμενική κρίση του χρήστη. Το κλασικό ακουστικό στηθοσκόπιο αποτελείται από τέσσερα βασικά τμήματα: τους ακροδέκτες των αυτιών (*ear tips*) που εφαρμόζουν στα αυτιά του ιατρού, οι σωλήνες αυτιών (*ear tubes*) που μεταφέρουν τον ήχο, ο εύκαμπτος σωλήνας (*tube*) που κατευθύνει τις δονήσεις από την κεφαλή και η κεφαλή, η οποία περιλαμβάνει τη μεμβράνη (*diaphragm*) για υψηλές συχνότητες και το κουδούνι (*bell*) για χαμηλές συχνότητες.



Σχήμα 2.7: Βασικά τμήματα ακουστικού στηθοσκοπίου. (Babalola et al. 2023)

Ψηφιακό ή ηλεκτρονικό στηθοσκόπιο Η τεχνολογική εξέλιξη οδήγησε στην ανάπτυξη των ηλεκτρονικών ή ψηφιακών στηθοσκοπίων, τα οποία ενσωματώνουν μικρόφωνα επαφής υψηλής ευαισθησίας και ηλεκτρονικά κυκλώματα για ενίσχυση, φιλτράρισμα και ψηφιοποίηση του ηχητικού σήματος. Σε σύγκριση με τα κλασικά στηθοσκόπια, προσφέρουν πολλαπλά πλεονεκτήματα, όπως η δυνατότητα καταγραφής για μεταγενέστερη ανάλυση και αρχειοθέτηση, η αποθορυβοποίηση μέσω ψηφιακών φίλτρων και η φασματική ανάλυση σε πραγματικό χρόνο. Ορισμένα σύγχρονα μοντέλα συνοδεύονται επιπλέον από λογισμικό που εμφανίζει την κυματομορφή και το φάσμα σε πραγματικό χρόνο, παρέχοντας στον κλινικό ιατρό πρόσθετες οπτικές πληροφορίες για την αξιολόγηση.


Συστήματα πολλαπλών αισθητήρων και ειδικές συσκευές ηχογράφησης Πέραν των στηθοσκοπίων, για ερευνητικούς και κλινικούς σκοπούς χρησιμοποιούνται συχνά συστοιχίες μικροφώνων ή εξειδικευμένοι αισθητήρες τοποθετημένοι σε προκαθορισμένα ση-

μεία του θώρακα ή της τραχείας. Οι διατάξεις αυτές παρέχουν υψηλή πιστότητα καταγραφής σε ένα ευρύ φάσμα συχνοτήτων, μιας και υποστηρίζουν συχνότητες δειγματοληψίας συνήθως 4 kHz έως 44.1 kHz ή και περισσότερο.

Στην πράξη, η διαδικασία της καταγραφής ξεκινά από τη φυσική ταλάντωση της μεμβράνης, η οποία όπως βλέπουμε αποτελεί το επίπεδο κυκλικό τμήμα στο άκρο της κεφαλής του στηθοσκοπίου και έρχεται σε άμεση επαφή με το θωρακικό τοίχωμα. Η μεμβράνη συγκεκριμένα δέχεται τις μεταβολές της πίεσης του αέρα που παράγονται από την αναπνοή και έπειτα οι μηχανικές αυτές δονήσεις μετατρέπονται αρχικά σε **ηλεκτρικό σήμα αναλογικής μορφής** μέσω ενός μικροφώνου ή πιεζοηλεκτρικού μετατροπέα. Το ηλεκτρικό αυτό σήμα ενισχύεται και οδηγείται στον μετατροπέα αναλογικού σε ψηφιακό σήμα (*A/D converter*), όπου εφαρμόζεται η διαδικασία της **ψηφιοποίησης**, η οποία περιγράφεται αναλυτικά στην επόμενη υποενότητα. Έτσι, η αρχική ταλάντωση της μεμβράνης, που αποτελεί φυσικό φαινόμενο, καταλήγει να αναπαρίσταται ως μια ακολουθία από δυαδικούς αριθμούς, κατάλληλη για αποθήκευση και επεξεργασία σε υπολογιστικά συστήματα. Τα αποτελέσματα, δηλαδή οι δυαδικές ακολουθίες που συλλέγονται από τις παραπάνω συσκευές, αποθηκεύονται μετά τη λήξη της καταγραφής συνήθως σε μορφή αρχείων *.wav*, τα οποία αποτελούν ένα από τα πιο διαδεδομένα πρότυπα για την αποθήκευση ηχητικών δεδομένων χωρίς απώλειες.

2.2.3 Ψηφιοποίηση

Γενικά, τα αναπνευστικά σήματα ανήκουν στην κατηγορία των **αναλογικών συνεχών σημάτων**, καθώς το πλάτος και ο χρόνος αποτελούν συνεχείς μεταβλητές. Συνεπώς, η μελέτη των αναπνευστικών ήχων σε ψηφιακή μορφή απαιτεί πρώτα από όλα τη μετατροπή του φυσικού ηχητικού σήματος, το οποίο συνιστά συνεχές αναλογικό μέγεθος, σε διακριτό αριθμητικό σήμα, δηλαδή σε ψηφιακή μορφή κατάλληλη για επεξεργασία από το υπολογιστικό σύστημα. Η διαδικασία αυτή ονομάζεται **ψηφιοποίηση** (*digitization*) και περιλαμβάνει 3 βασικά στάδια: τη **δειγματοληψία** (*sampling*), τη **κβάντιση** (*quantization*) και τη **κωδικοποίηση** (*encoding*) (Lerch 2012).



Σχήμα 2.8: Διαδικασία ψηφιοποίησης αναπνευστικών ηχητικών σημάτων.(Διαδίκτυο)

Δειγματοληψία Η δειγματοληψία είναι η διαδικασία κατά την οποία το συνεχές αναπνευστικό σήμα $x(t)$ μετράται και καταγράφεται σε διακριτά χρονικά διαστήματα. Δημιουργείται

έτσι μια ακολουθία τιμών $x[n] = x(nT_s)$, όπου T_s είναι το **διάστημα δειγματοληψίας** και $f_s = \frac{1}{T_s}$ η **συχνότητα δειγματοληψίας** με μονάδα μέτρησης τα Hz. Σύμφωνα με το **Θεώρημα Nyquist–Shannon** προκειμένου να ανακατασκευαστεί πλήρως το αρχικό αναλογικό αναπνευστικό σήμα από τα δείγματά του χωρίς παραμόρφωση, η συχνότητα δειγματοληψίας πρέπει να είναι τουλάχιστον διπλάσια της μέγιστης συχνότητας του σήματος:

$$f_s \geq 2f_{\max} \quad (2.11)$$

Η ακατάλληλη δειγματοληψία οδηγεί σε φαινόμενα επιχώλωσης φασματικών συνιστωσών (*aliasing*), τα οποία δεν μπορούν να αποκατασταθούν εκ των υστέρων οδηγώντας έτσι σε απώλεια πληροφορίας. Για τους αναπνευστικούς ήχους συγκεκριμένα, των οποίων το σημαντικό φασματικό περιεχόμενο εντοπίζεται κυρίως μεταξύ 50 και 1200 Hz, η ελάχιστη απαιτούμενη συχνότητα δειγματοληψίας είναι 2.4 kHz. Στην πράξη ωστόσο χρησιμοποιούνται συσκευές καταγραφής με τιμές συχνότητας δειγματοληψίας όπως 4 kHz, 8 kHz ή και 44.1 kHz (τυπική συχνότητα *CD*), ώστε να διατηρείται υψηλή η πιστότητα του σήματος.

Κβάντιση Αφού το αναπνευστικό σήμα έχει μετατραπεί σε διακριτή ακολουθία χρονικών στιγμών $x[n]$, το επόμενο βήμα είναι να μετατραπούν τα συνεχόμενα πλάτη των δειγμάτων σε διακριτές αριθμητικές τιμές. Η διαδικασία αυτή ονομάζεται **κβάντιση** και πραγματοποιείται μέσω του μετατροπέα A/D (*analog-to-digital converter*) μέσω του οποίου προκύπτει η κβαντισμένη διακριτή ακολουθία $\tilde{x}[n]$. Πιο συγκεκριμένα, ο κβαντιστής χωρίζει το εύρος τιμών του πλάτους σε $L = 2^B$ επίπεδα, όπου B είναι ο αριθμός των **bit ανά δείγμα** (*bit depth*). Όσο μεγαλύτερο είναι το βάθος *bit*, τόσο μεγαλύτερη είναι και η ακρίβεια της αναπαράστασης, αλλά παράλληλα τόσο αυξάνεται και ο απαιτούμενος αποθηκευτικός χώρος. Η διαφορά μεταξύ της πραγματικής τιμής του πλάτους και της πλησιέστερης κβαντισμένης τιμής ονομάζεται **σφάλμα κβάντισης** και ορίζεται ως $e[n] = x[n] - \tilde{x}[n]$. Το σφάλμα αυτό λειτουργεί σαν πρόσθετος θόρυβος και μπορεί να υποβαθμίσει την ποιότητα του σήματος, ειδικά σε χαμηλής έντασης σήματα όπως οι ήχοι του αναπνευστικού. Τέλος, η ποιότητα της ψηφιακής αναπαράστασης εκφράζεται συχνά μέσω του **λόγου σήματος προς σφάλμα κβάντισης** (*Signal-to-Quantization-Noise Ratio, SQNR*), ο οποίος μετρείται σε κλίμακα dB.


Κωδικοποίηση Η διαδικασία της ψηφιοποίησης ολοκληρώνεται με την **κωδικοποίηση** (*encoding*) κατά την οποία οι κβαντισμένες τιμές μετατρέπονται σε δυαδικές ακολουθίες. Κάθε τιμή αντιστοιχίζεται σε έναν μοναδικό συνδυασμό από bits ανάλογα με το βάθος κβάντισης B , δημιουργώντας έτσι τη ψηφιακή αναπαράσταση του σήματος. Για παράδειγμα, σε 8-bit κβάντιση υπάρχουν $2^8 = 256$ επίπεδα και κάθε τιμή κωδικοποιείται με 8 *bits*. Η κωδικοποιημένη μορφή είναι αυτή που χρησιμοποιείται τελικά από το υπολογιστικό σύστημα για αποθήκευση, επεξεργασία ή μετάδοση. Η κωδικοποίηση δεν μεταβάλλει τη φυσική πληροφορία του σήματος, αλλά είναι απαραίτητο βήμα για την ακριβή ψηφιακή αναπαράστασή του.

2.3 Η βάση δεδομένων RSDB

Η παρούσα εργασία βασίζεται στη δημόσια διαθέσιμη βάση δεδομένων αναπνευστικών ήχων **RSDB** του επιστημονικού διαγωνισμού *ICBHI 2017 (International Conference on Biomedical and Health Informatics)*. Η βάση σχεδιάστηκε για την ανάπτυξη και αξιολόγηση αλγορίθμων αυτόματης ανάλυσης αναπνευστικών σημάτων, προσφέροντας ένα ευρύ φάσμα από καταγραφές τόσο από φυσιολογικά όσο και παθολογικά περιστατικά (Rocha et al. 2018). Η βάση δεδομένων δημιουργήθηκε από δύο ερευνητικές ομάδες:

ESSUA (Πορτογαλία) Οι ηχογραφήσεις έγιναν στο *Respiratory Research and Rehabilitation Laboratory (Lab3R)* και στο *Hospital Infante D. Pedro* καλύπτοντας ευρύ πλήθος ατόμων από βρέφη μέχρι ηλικιωμένους. Οι καταγραφές έγιναν σε 7 θέσεις θώρακα: τραχεία, αριστερά και δεξιά (πρόσθια, οπίσθια και πλάγια).

AUTH (Ελλάδα) Οι ηχογραφήσεις πραγματοποιήθηκαν στο Πανεπιστημιακό Νοσοκομείο Παπανικολάου και το Γενικό Νοσοκομείο Ημαθίας σε ενήλικες και ηλικιωμένους ασθενείς. Οι θέσεις καταγραφής ήταν 6, στην τραχεία και σε θέσεις στον θώρακα.



Σχήμα 2.9: Θέσεις καταγραφής των αναπνευστικών ήχων στη βάση δεδομένων RSDB. (Rocha et al. 2018)

Συνολικά περιλαμβάνει **920 ηχογραφήσεις** αποθηκευμένες σε .wav αρχεία οι οποίες έχουν αποκτηθεί από **126 ασθενείς** με καταγεγραμμένους **6898 αναπνευστικούς κύκλους**. Οι ηχογραφήσεις αποκτήθηκαν σε διάρκεια 10–90 δευτερολέπτων και συνοδεύονται από επιπρόσθετο σχολιασμό εξειδικευμένων ιατρών και φυσιοθεραπευτών σε *annotation files* ως προς την παρουσία φυσιολογικών ήχων (**Normal**), παθολογικών ήχων (**Crackle**, **Wheeze**) ή συνδυασμού αυτών (**Both**). Επίσης, υπάρχει σχολιασμός ως προς τα όρια των αναπνευστικών κύκλων αλλά και ως προς την παρουσία επιπρόσθετων στοιχείων (π.χ. βήχας, ομιλία, *artifacts*). Τέλος, συνοδεύονται και από ένα αρχείο με **δημογραφικά δεδομένα**, όπως φύλο, ηλικία, βάρος, ύψος και δείκτης *BMI*.

Οι κύριες συσκευές καταγραφής που αξιοποιήθηκαν είναι:


Welch Allyn Master Elite Stethoscope (5079-400) [Litt3200] Ψηφιακό στήθοσκόπιο ιατρικής κατηγορίας, το οποίο ενσωματώνει ηλεκτρονικό αισθητήρα στην κεφαλή του και μετατρέπει τους ήχους σε ψηφιακό σήμα. Χρησιμοποιείται ευρέως σε κλινικά περιβάλλοντα και παρέχει καλή απόκριση χαμηλών συχνοτήτων, η οποία είναι κρίσιμη για την ανάλυση

αναπνευστικών ήχων. Η συσκευή χρησιμοποιήθηκε από την ομάδα του *AUTH* σε ενήλικες ασθενείς.

3M Littmann Classic II SE [LittC2SE] Κλασικό αναλογικό στηθοσκόπιο, το οποίο τροποποιήθηκε για τις ανάγκες της βάσης μέσω προσθήκης εξωτερικού μικροφώνου στον εύκαμπτο σωλήνα μεταφοράς του ήχου. Το μικρόφωνο κατέγραφε τον ήχο που μεταδιδόταν ακουστικά μέσω του σωλήνα, μετατρέποντάς τον σε σήμα κατάλληλο για ψηφιοποίηση. Αν και δεν πρόκειται για ψηφιακή συσκευή *per se*, η υλοποίηση αυτή επιτρέπει την καταγραφή με ευρεία συχνοτική κάλυψη. Η συσκευή χρησιμοποιήθηκε κυρίως σε ενήλικους ασθενείς σε ελεγχόμενο περιβάλλον.

AKGC417L Αποτελεί τύπο *electret* μικροφώνου τοποθετημένου σε υλικό τεφλόν, σχεδιασμένο για μη επεμβατικές μετρήσεις. Η συσκευή είναι αερόσυζευκτη (*air-coupled*) και προσφέρει εξαιρετικά ευαίσθητη καταγραφή ηχητικών σημάτων από την επιφάνεια του θώρακα, με ιδιαίτερα υψηλή συχνότητα δειγματοληψίας (**44.1 kHz**). Χρησιμοποιήθηκε από την ομάδα του *ESSUA* κυρίως σε νεαρούς ενήλικους πληθυσμούς και λόγω της υψηλής ανάλυσης, προσφέρει αναπαράσταση των λεπτομερειών σε ήχους τύπου *crackles* και *wheezes*.

Meditron Πρόκειται για ψηφιακό ηλεκτρονικό στηθοσκόπιο υψηλής ευαισθησίας που χρησιμοποιήθηκε ως τυπική συσκευή αναφοράς στον διαγωνισμό *ICBHI*. Καταγράφει σε **4 kHz** και παρέχει σήμα υψηλής καθαρότητας, ενώ διαθέτει ενσωματωμένο σύστημα καταγραφής σε υπολογιστή. Επιτρέπει εύκολη φορητή καταγραφή και συνήθως χρησιμοποιείται σε νοσοκομειακά και ερευνητικά περιβάλλοντα.




Σχήμα 2.10: Σύνοψη οπτική περιγραφή της βάσης δεδομένων RSDB.

Η κατηγορία *Both* στη συγκεκριμένη εργασία δεν μας απασχόλησε, συνεπώς αφαιρέθηκαν και από το σύνολο δεδομένων όλες οι εγγραφές με τη συγκεκριμένη ετικέτα. Άρα, διατηρούμε μόνο τους **6392** κύκλους από τους 6898 που επάχουν συνολικά διαθέσιμοι. Παρακάτω βλέπουμε το πλήθος των αναπνευστικών κύκλων που διατηρήθηκαν ως προς τις κλάσεις και τις συσκευές καταγραφής. Όπως παρατηρείται, η πλειοψηφία των εγγραφών προέρχεται από τη συσκευή **AKGC417L** (3965 κύκλοι), ενώ άλλες συσκευές όπως η **Litt3200** και η **LittC2SE** συμμετέχουν με πολύ μικρότερο αριθμό (376 και 449 αντίστοιχα). Η ανομοιογένεια αυτή εισάγει από μόνη της φυσική μετατόπιση πεδίου και με λίγα λόγια οδηγεί στο πρόβλημα της ετερογένειας συσκευών (*device mismatch*). Η έννοια της μετατόπισης πεδίου αναλύεται ωστόσο εκτενώς στην επόμενη ενότητα.

Κλάση	AKGC417L	Litt3200	LittC2SE	Meditron
Normal	1922	336	347	1037
Crackle	1543	29	77	215
Wheeze	500	112	126	148

Πίνακας 2.2: Κατανομή των κατηγοριών αναπνευστικών ήχων ανά συσκευή καταγραφής.

Γενικά, τα ακουστικά σήματα και σε ακόμη μεγαλύτερο βαθμό τα αναπνευστικά είναι υψηλής διαστατικότητας και χρονικά εξαρτώμενα, με αποτέλεσμα να υπάρχει εγγενής ευαισθησία σε τυχαίες διακυμάνσεις θορύβου και αλλοιώσεις κατά τη διαδικασία καταγραφής. Συνεπώς, παρουσιάζουν υψηλή ευαισθησία σε εξωτερικές παραμέτρους, όπως η ποιότητα της συσκευής, το περιβάλλον ηχογράφησης και τα τεχνικά χαρακτηριστικά του μικροφώνου ή αισθητήρα.




Σχήμα 2.11: Απεικόνιση της μέσης απόκρισης συχνότητας των διαφορετικών συσκευών καταγραφής.

Η ανάλυση της μέσης απόκρισης συχνότητας για κάθε συσκευή καταγραφής αποκαλύπτει σαφείς διαφορές στο φασματικό προφίλ μεταξύ των συσκευών. Συγκεκριμένα, η συσκευή **AKGC417L** παρουσιάζει υψηλότερες τιμές ισχύος σε όλο το φάσμα, ιδίως κάτω από τα 1000 Hz, υποδηλώνοντας μεγαλύτερη ευαισθησία στην καταγραφή χαμηλών συχνοτήτων. Αντίθε-

τα, οι συσκευές LittC2SE, Litt3200 και Meditron εμφανίζουν πιο απότομη εξασθένιση στις ίδιες περιοχές, με διακυμάνσεις ανάμεσα τους γύρω στα 400–800 Hz. Η ασυμφωνία αυτή τεκμηριώνει περαιτέρω την ύπαρξη **χάσματος μεταξύ των συσκευών**, καθώς η φασματική πληροφορία αποτελεί θεμελιώδες συστατικό των χαρακτηριστικών εισόδου.

Επιπλέον, η συχνότητα εμφάνισης των αναπνευστικών ηχητικών κατηγοριών είναι επίσης άνιση, με τους **φυσιολογικούς ήχους (Normal)** να υπερσχύουν αριθμητικά έναντι των **παθολογικών Crackle και Wheeze**. Αυτή η ανισορροπία ενδέχεται επίσης να επηρεάσει σημαντικά την απόδοση των αλγορίθμων μηχανικής μάθησης, καθώς μπορεί να οδηγήσει σε μείωση της ευαισθησίας (sensitivity) και της δυνατότητας εντοπισμού σπάνιων συμβάντων. Για την αντιμετώπιση αυτών των προκλήσεων έχουν εφαρμοστεί τεχνικές **εξισορρόπησης δεδομένων** για το training set, όπως το VTLP-Patch Augmentation. Η ισορροπία μεταξύ των κλάσεων στο σύνολο εκπαίδευσης είναι ιδιαίτερα σημαντική για την αποφυγή μεροληψίας κατά την εκμάθηση του ταξινομητή. Αντιθέτως, το test set δεν χρησιμοποιείται για εκπαίδευση, αλλά για αξιολόγηση. Συνεπώς, δεν είναι απαραίτητο να είναι ισορροπημένο, αλλά να αντικατοπτρίζει την πραγματική κατανομή των κλάσεων στον φυσικό πληθυσμό. Για την ακρίβεια, το τελικό σύνολο από αναπνευστικούς κύκλους διασπάται σε training και test sets με **αναλογία 80:20**, δηλαδή 5113 κύκλους για το training set και 1279 για το test set:



Σχήμα 2.12: Διαχωρισμός σε training, test sets.

2.4 Αναπαράσταση αναπνευστικών σημάτων

Η αναπαράσταση του ακουστικού σήματος από το αρχείο .wav αποτελεί θεμελιώδες στάδιο στην ανάλυση και επεξεργασία του, καθώς καθορίζει τον τρόπο με τον οποίο η πληροφορία αποτυπώνεται, ερμηνεύεται και εξάγεται για χρήση σε εφαρμογές αναγνώρισης προτύπων και διάγνωσης. Στην περίπτωση των αναπνευστικών ήχων, η επιλογή κατάλληλης αναπαράστασης είναι ιδιαίτερα κρίσιμη, καθώς τα σήματα αυτά χαρακτηρίζονται από υψηλή διακύμανση, μη στασιμότητα και συχνά περιέχουν σύνθετες παροδικές ή περιοδικές δομές που σχετίζονται με φυσιολογικές ή παθολογικές καταστάσεις.

Η αναπνευστική ηχογράφηση αποτελεί χρονική αποτύπωση της πίεσης του αέρα κατά την εισπνοή και την εκπνοή και περιλαμβάνει πληροφορία που εκτείνεται τόσο στο πεδίο του χρόνου (χρονική εξέλιξη πλάτους) όσο και στο πεδίο της συχνότητας (φασματική κατανομή ενέργειας). Η ενότητα αυτή λοιπόν παρουσιάζει τις κύριες μορφές αναπαράστασης που χρησιμοποιούνται

στην παρούσα εργασία, ξεκινώντας από το **πεδίο του χρόνου**, όπου απεικονίζεται η **κυματομορφή του σήματος** και συνεχίζοντας με το **πεδίο του χρόνου-συχνότητας**, όπου εφαρμόζεται ο *Short Time Fourier Transform (STFT)* για την παραγωγή φασματοχρονικών αναπαραστάσεων. Οι αναπαραστάσεις αυτές χρησιμεύουν αφενός για την οπτική αξιολόγηση του σήματος, αφετέρου για την εξαγωγή διαγνωστικά χρήσιμων χαρακτηριστικών που αξιοποιούνται από τα μοντέλα μηχανικής μάθησης.

2.4.1 Πεδίο χρόνου (Κυματομορφή)

Η αναπαράσταση ενός σήματος στο πεδίο του χρόνου είναι η πιο άμεση μορφή απεικόνισης και ανάλυσής του. Πρόκειται για την απεικόνιση του πλάτους του σήματος ως προς τον άξονα του χρόνου, δηλαδή της συνάρτησης $x(t)$ για αναλογικά σήματα ή $x[n]$ για διακριτά. Το γράφημα που προκύπτει ονομάζεται *κυματομορφή (waveform)* και αποτελεί την πρώτη οπτική προσέγγιση της πληροφορίας που φέρει το σήμα.

Στην περίπτωση των αναπνευστικών σημάτων, η αναπαράσταση στο πεδίο του χρόνου αποδίδει με φυσικό τρόπο την ένταση και την ακολουθία των αναπνευστικών φάσεων (εισπνοή, εκπνοή), καθώς και την χρονική εξέλιξη ενδεχόμενων παθολογικών ηχητικών συμβάντων (π.χ. *crackles*, *wheezes*). Η διάρκεια των επιμέρους φάσεων, η συμμετρία ή η ασυμμετρία τους, καθώς και η παρουσία περιοχών ησυχίας ή αιχμών είναι χαρακτηριστικά που καθίστανται άμεσα παρατηρήσιμα στο χρονικό διάγραμμα.

Ωστόσο, η ανάλυση στο πεδίο του χρόνου παρουσιάζει περιορισμούς εφόσον δεν αποκάλυπτει τη συχνοτική σύνθεση του σήματος ούτε την ενεργειακή κατανομή ανά συχνότητα. Παρόλο που ορισμένες πληροφορίες όπως η σχετική ένταση, η διάρκεια ή ο ρυθμός εμφάνισης μπορούν να εξαχθούν απευθείας, πολλές φορές απαιτείται η συμπληρωματική ανάλυση στο πεδίο της συχνότητας ή στο πεδίο χρόνου-συχνότητας για την πλήρη κατανόηση της δομής του σήματος.


Πιο κάτω παρουσιάζονται ενδεικτικά οι κυματομορφές από ορισμένες καταγραφές του συνόλου δεδομένων που χρησιμοποιήθηκε, πάνω στις οποίες σημειώνονται η αρχή και το τέλος κάθε αναπνευστικού κύκλου της καταγραφής, καθώς και η πάθηση η οποία εντοπίζεται σε αυτόν.

Η πρώτη κυματομορφή εμφανίζει **χαμηλής έντασης, μη περιοδικά σήματα με συμμετρικές φάσεις εισπνοής και εκπνοής, χωρίς απότομες κορυφές ή επαναλαμβανόμενα μοτίβα**. Η μορφολογία της χαρακτηρίζεται από ακανόνιστες διακυμάνσεις σε εύρος πλάτους, χωρίς έντονες χρονικά εντοπισμένες αποκλίσεις. Αυτά τα χαρακτηριστικά είναι αντιπροσωπευτικά των **φυσιολογικών κυψελιδικών ήχων**, που σχετίζονται με ήπια, διάχυτη ροή αέρα στους περιφερικούς αεραγωγούς. Η απουσία περιοδικότητας, απότομων συμβάντων ή στενών φασματικών αιχμών αποτελεί ένδειξη μη ύπαρξης παθολογικών αλλοιώσεων.

Αντίθετα, η δεύτερη κυματομορφή περιέχει εκτεταμένες χρονικές περιοχές με παρουσία *crackles*, δηλαδή **απότομες, ασύμμετρες αιχμές σύντομης διάρκειας, με οξείες κορυφές και ταχεία αποκατάσταση**. Τα ηχητικά αυτά γεγονότα είναι τυπικά

φαινόμενα μικρών αεραγωγών, συνήθως σε περιπτώσεις πνευμονικής ίνωσης, πνευμονίας ή καρδιογενούς πνευμονικού οιδήματος. Η χρονική πυκνότητα και κατανομή αυτών των ριπών ενισχύει την υπόθεση παρουσίας παθολογίας στην αναπνευστική οδό.

Η τρίτη κυματομορφή εμφανίζει παρατεταμένο τμήμα με *wheezes*, δηλαδή **περιοδικά ή ημι-περιοδικά μοτίβα αυξομειούμενης έντασης με σχεδόν σταθερό ρυθμό**. Αυτή η συμπεριφορά υποδηλώνει την ύπαρξη στενώσεων ή απόφραξης σε μεσαίους αεραγωγούς, καθώς τα *wheezes* προκαλούνται από στροβιλώδη ροή αέρα σε περιορισμένα ανοίγματα.



Σχήμα 2.13: Κυματομορφές από ενδεικτικές αναπνευστικές καταγραφές.

2.4.2 Πεδίο χρόνου-συχνότητας (Φασματογράφημα)

Η αναπαράσταση ενός σήματος στο πεδίο της συχνότητας είναι καίριας σημασίας και επιτρέπει την αποκάλυψη της φασματικής του σύνθεσης, δηλαδή των συχνοτήτων που το απαρτίζουν και της σχετικής έντασης καθενιάς. Ενώ στο πεδίο του χρόνου παρατηρείται η χρονική μεταβολή του πλάτους του σήματος, η φασματική αναπαράσταση απαντά στο ερώτημα: «*Ποιες συχνότητες συνθέτουν αυτό το σήμα και σε ποιο βαθμό*». Για παράδειγμα, ενώ στο πεδίο του χρόνου ένα σήμα μπορεί να εμφανίζεται ως πολύπλοκη και ακανόνιστη κυματομορφή, στο πεδίο συχνοτήτων μπορεί να αποδοθεί ως συνδυασμός ημιτονοειδών κυμάτων διαφόρων συχνοτήτων, φάσεων και πλάτων. Αυτό καθιστά δυνατή την απομόνωση, ενίσχυση ή καταστολή συγκεκριμένων συχνοτικών συνιστωσών κατά την επεξεργασία σήματος.

Η βασική μέθοδος για τη μετάβαση από το χρονικό στο συχνοτικό πεδίο είναι ο **Μετασχηματισμός Fourier** ο οποίος για σήματα συνεχούς χρόνου υπολογίζεται ως εξής:

$$X(f) = \int_{-\infty}^{\infty} x(t)e^{-j2\pi ft} dt \quad (2.12)$$

Η τιμή $|X(f)|$ εκφράζει τη «συνεισφορά» της συχνότητας f στο συνολικό σήμα και ονομάζεται **απόκριση πλάτους**. Επιπλέον, η **φασματική πυκνότητα ισχύος** (*spectral power density*) ορίζεται ως:

$$S(f) = |X(f)|^2$$

και εκφράζει πόση ισχύς συγκεντρώνεται σε κάθε συχνότητα. Στην πράξη, η φασματική πυκνότητα είναι ιδιαίτερα χρήσιμη για τη διάκριση μεταξύ φυσιολογικών και παθολογικών αναπνευστικών ήχων.

Ωστόσο, η πλειονότητα των σημάτων που επεξεργάζονται οι υπολογιστές είναι σήματα διακριτού χρόνου πεπερασμένου μήκους $x[n]$, τα οποία όπως αναφέραμε προέρχονται από τη δειγματοληψία των αντίστοιχων σημάτων συνεχούς χρόνου. Για την ανάλυσή τους στο πεδίο της συχνότητας χρησιμοποιείται λοιπόν ο **Διακριτός Μετασχηματισμός Fourier** (*Discrete Fourier Transform, DFT*), ο οποίος ορίζεται ως:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi \frac{k}{N}n}, \quad k = 0, 1, \dots, N-1 \quad (2.13)$$

όπου N είναι ο αριθμός των δειγμάτων του σήματος.

Ο *DFT* παρέχει μια **διακριτή συχνοτική αναπαράσταση** του σήματος με N φασματικά δείγματα που κατανέμονται ομοιόμορφα στο διάστημα $[0, f_s)$, όπου f_s η συχνότητα δειγματοληψίας. Η εφαρμογή του στην πράξη γίνεται μέσω του αλγορίθμου *Fast Fourier Transform (FFT)*, ο οποίος βασίζεται στη στρατηγική του *Διαίρει και Βασίλευε* και έτσι μειώνεται δραστικά η υπολογιστική πολυπλοκότητα.

Στην περίπτωση των αναπνευστικών σημάτων, η φασματική ανάλυση υλοποιείται με έναν ελαφρώς διαφορετικό τρόπο από αυτόν που μόλις περιγράψαμε. Η διαφορά έγκειται στο γεγονός ότι ο κλασικός Διακριτός Μετασχηματισμός *Fourier* θεωρεί ότι το σήμα είναι στάσιμο και σταθερό στο χρόνο, δηλαδή όλες οι συχνοτικές συνιστώσες του υπάρχουν καθ' όλη τη διάρκειά του. Αυτή η υπόθεση συνεπώς τον καθιστά ακατάλληλο για να εφαρμοστεί πάνω σε ολόκληρα σήματα που είναι μη στάσιμα και στοχαστικά όπως τα περισσότερα αναπνευστικά ηχητικά σήματα. Για να αναλύσουμε τη **χρονική εξέλιξη του φάσματος** ενός τέτοιου σήματος, χρησιμοποιούμε λοιπόν τον **Μετασχηματισμό Fourier Βραχέως Χρόνου** (*Short-Time Fourier Transform, STFT*).

Απο μαθηματική σκοπιά ο *STFT* για τα διακριτά σήματα θεμελιώνεται ως εξής:

$$X(m, k) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n-m] \cdot e^{-j2\pi \frac{k}{N}n} \quad (2.14)$$

όπου $w[n]$ είναι η συνάρτηση παραθύρου μήκους N , m ο δείκτης χρονικής θέσης του παραθύρου και k ο δείκτης συχνότητας.


Στην πρακτική υλοποίηση, όπου το σήμα έχει πεπερασμένο μήκος και το παράθυρο εφαρμόζεται σε τμήματα N δειγμάτων, η εξίσωση μετασχηματίζεται σε:

$$X(m, k) = \sum_{n=0}^{N-1} x[n+m] \cdot w[n] \cdot e^{-j2\pi \frac{k}{N}n} \quad (2.15)$$

Η βασική ιδέα του *STFT* είναι να χωρίσει το σήμα σε διαδοχικά **τοπικά χρονικά καρέ** (*frames*) μέσα στα οποία το σήμα θεωρείται προσεγγιστικά στάσιμο και να εφαρμόσει τον Διακριτό Μετασχηματισμό *Fourier* χωριστά σε κάθε καρέ. Κατά τον χρονικό τεμαχισμό ενός σήματος σε καρέ σταθερού μήκους, εφαρμόζεται συχνά και **επικάλυψη** (*overlap*) μεταξύ διαδοχικών καρέ, δηλαδή διατηρείται κοινό ένα τμήμα του σήματος μεταξύ τους. Ο βαθμός επικάλυψης καθορίζεται από τη διαφορά μεταξύ του μήκους του καρέ (*frame size*) L και του βήματος μετατόπισης (*hop size*) H , με ποσοστό επικάλυψης:

$$\text{overlap} = \frac{L - H}{L} \times 100\% \quad (2.16)$$

Η χρήση επικάλυψης είναι ιδιαίτερα σημαντική για σήματα όπως οι αναπνευστικοί ήχοι, καθώς τα παθολογικά ηχητικά συμβάντα, όπως τα *crackles*, είναι εξαιρετικά σύντομα και ενδέχεται να πέσουν στα «σύνορα» μεταξύ δύο μη επικαλυπτόμενων καρέ. Σε αυτή την περίπτωση, είτε θα εμφανιστούν τμηματικά, είτε θα χαθούν πλήρως. Με την επικάλυψη, η πιθανότητα σύλληψής τους σε πλήρες καρέ αυξάνεται σημαντικά και έτσι αποφεύγονται ασυνέχειες ή απότομες μεταβολές μεταξύ καρέ.



Σχήμα 2.14: Τεμαχισμός σήματος σε frames με επικάλυψη. (Διαδίκτυο)


Στη συνέχεια ακολουθεί η διαδικασία της παραθύρωσης (*windowing*), η οποία είναι απαραίτητη ώστε να περιοριστούν τα φαινόμενα **φασματικής διαρροής** που προκύπτουν από την απότομη αποκοπή ενός σήματος σε καρέ πεπερασμένου μήκους. Για τον σκοπό αυτό, κάθε καρέ πολλαπλασιάζεται με μια συνάρτηση παραθύρου $w[n]$, η οποία δίνει μεγαλύτερη έμφαση στο κέντρο και μειώνει σταδιακά την επιρροή των άκρων. Υπάρχουν διάφοροι τύποι παραθύρων:

Ορθογώνιο παράθυρο (*Rectangular window*) Είναι το απλούστερο παράθυρο, χωρίς εξομάλυνση στα άκρα. Παρουσιάζει γενικά σημαντική φασματική διαρροή λόγω των απότομων μεταβάσεων και χρησιμοποιείται κυρίως όταν το σήμα έχει ήδη ομαλά άκρα.

$$w[n] = 1, \quad 0 \leq n < N \quad (2.17)$$

Hann window Παρέχει καλή καταστολή πλευρικών λοβών και χρησιμοποιείται ευρέως στη φασματική ανάλυση για τον υπολογισμό του *STFT*. Έχει μικρό κύριο λοβό και απότομη απόσβεση εκτός αυτού.


$$w[n] = 0.5 \left(1 - \cos \left(\frac{2\pi n}{N-1} \right) \right) \quad (2.18)$$



Σχήμα 2.15: Παράθυρο Hann (Διαδίκτυο).

Hamming window Είναι παρόμοιο με το παράθυρο *Hann* αλλά με μεγαλύτερο κύριο λοβό και μικρότερη πλευρική διαρροή.

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right) \quad (2.19)$$




Σχήμα 2.16: Παράθυρο Hamming (Διαδίκτυο).

Το αποτέλεσμα αυτής της διαδικασίας είναι μια **διδιάστατη αναπαράσταση** $X(m, k)$ που δείχνει την κατανομή συχνοτήτων του σήματος σε κάθε χρονική στιγμή. Από εκεί προκύπτει το τελικό **φασματογράφημα**, δηλαδή ο χάρτης έντασης $|X(m, k)|^2$ με τον χρόνο στον οριζόντιο άξονα, τη συχνότητα στον κατακόρυφο και το χρώμα να δηλώνει την ενέργεια, δηλαδή την ένταση του σήματος στη συχνότητα k για το δείγμα m (Lerch 2012).

Η διαδικασία αυτή που περιγράφουμε είναι ιδιαίτερα κρίσιμη για την ανίχνευση παθολογικών γεγονότων μικρής διάρκειας, όπως τα *crackles*, τα οποία έχουν διάρκεια μόλις 5–20 ms και θα ήταν αδύνατο να εντοπιστούν σε μακροσκοπική ανάλυση. Επιπλέον, ο τεμαχισμός σε καρέ ευνοεί την εφαρμογή τεχνικών μηχανικής μάθησης, καθώς επιτρέπει την εξαγωγή τοπικών χαρακτηριστικών από κάθε καρέ και κατ' επέκταση την εκπαίδευση ταξινομητών με υψηλότερη χρονική ανάλυση.

Πιο κάτω παρατίθενται ενδεικτικά φασματογραφήματα που αντιστοιχούν στις κυματομορφές των καταγραφών της βάσης δεδομένων μας. Τα συγκεκριμένα γραμμικά φασματογραφήματα απεικονίζουν την κατανομή ενέργειας του σήματος σε συνάρτηση συχνότητας και χρόνου, χωρίς επιπρόσθετη κλιμάκωση ή συμπίεση της συχνοτικής πληροφορίας. Αν και προσφέρουν άμεση και ακριβή απεικόνιση του φάσματος, δεν αποτελούν την επικρατέστερη μέθοδο αναπαράστασης σε εφαρμογές μηχανικής μάθησης. Αντίθετα, στις περισσότερες σύγχρονες προσεγγίσεις δίνεται προτεραιότητα στα Log-Mel spectrograms, τα οποία προκύπτουν από

τη συνδυασμένη εφαρμογή φίλτρων Mel και λογαριθμικής κλίμακας στην ενεργειακή κατανομή. Η μετατροπή στη κλίμακα Mel ευθυγραμμίζεται καλύτερα με την ανθρώπινη ακουστική αντίληψη, δίνοντας μεγαλύτερη ανάλυση σε χαμηλές συχνότητες όπου εντοπίζονται κρίσιμες πληροφορίες για την αναγνώριση παθολογικών αναπνευστικών ήχων. Παράλληλα, η λογαριθμική συμπίεση της ενέργειας καθιστά την αναπαράσταση πιο ανθεκτική σε διαφοροποιήσεις έντασης και βελτιώνει τη διακριτική ικανότητα των νευρωνικών δικτύων. Γι' αυτό το λόγο από εδώ και πέρα θα αναφερόμαστε μόνο σε Log-Mel φασματογραφήματα και μάλιστα η διαδικασία δημιουργίας των Log-Mel ενεργειών περιγράφεται αναλυτικότερα στην πιο κάτω ενότητα κατά την εξαγωγή των φασματικών χαρακτηριστικών.



Σχήμα 2.17: Φασματογραφήματα από ενδεικτικές αναπνευστικές καταγραφές.

2.5 Μετατόπιση πεδίου

Στη μηχανική μάθηση, τα περισσότερα μοντέλα εκπαιδεύονται υπό την παραδοχή ότι τα δεδομένα εκπαίδευσης και δοκιμής αντλούνται από την ίδια κατανομή πιθανότητας $P(X, Y)$. Ωστόσο, σε πραγματικές συνθήκες, ειδικά σε τομείς όπως η βιοϊατρική, η ομιλία και το περιβάλλον,

λον, η παραδοχή αυτή συχνά καταρρέει. Το φαινόμενο αυτό περιγράφεται ως **μετατόπιση πεδίου** (*domain shift*) και οδηγεί σε σημαντική υποβάθμιση της απόδοσης των μοντέλων όταν εφαρμόζονται σε νέα, ετερογενή δεδομένα. Η ύπαρξη *domain shift* καθιστά συνεπώς και πολλά συμβατικά μοντέλα ανίχνευσης αναπνευστικών παθήσεων επιρρεπή σε σφάλματα, καθώς τείνουν να υπερπροσαρμόζονται στα στατιστικά χαρακτηριστικά του *source domain* στο οποίο εκπαιδεύτηκαν. Για παράδειγμα, ένα μοντέλο που έχει εκπαιδευτεί σε καθαρά ακουστικά δεδομένα μόνο σε γηραιότερο πληθυσμό και από μια συγκεκριμένη συσκευή μπορεί να αποδώσει φτωχά όταν εφαρμοστεί σε δεδομένα με θόρυβο περιβάλλοντος που προέρχονται από νεότερες πληθυσμιακές ομάδες με διαφορετική συσκευή καταγραφής.

Στη συνέχεια παρουσιάζονται οι βασικές έννοιες του κλάδου της **προσαρμογής πεδίου** (*domain adaptation*) όπως ορίζονται από την τρέχουσα βιβλιογραφία:

Πεδίο (Domain) Ορίζεται ως το ζεύγος $\mathcal{D} = \{\mathcal{X}, P(X)\}$, όπου $\mathcal{X}$ είναι ο χώρος χαρακτηριστικών και $P(X)$ είναι μια κατανομή πιθανότητας πάνω σε αυτόν. Κάθε σύνολο δεδομένων που προέρχεται από συγκεκριμένο περιβάλλον, συσκευή ή πληθυσμό μπορεί να θεωρηθεί ως τομέας. Για παράδειγμα, ο ήχος αναπνευστικών σημάτων που καταγράφηκε με διαφορετικά μικρόφωνα ή από διαφορετικούς πληθυσμούς, ανήκει σε διαφορετικούς τομείς.

Πεδίο Πηγή και Στόχος (Source and Target Domain) Το *source domain* $\mathcal{D}_S = \{\mathcal{X}_S, P_S(X)\}$ περιλαμβάνει το διαθέσιμο σύνολο εκπαίδευσης (συχνά επισημασμένο με *labels*), ενώ το *target domain* $\mathcal{D}_T = \{\mathcal{X}_T, P_T(X)\}$ αφορά το περιβάλλον στο οποίο επιθυμούμε να εφαρμόσουμε το μοντέλο. Τυπικά, ισχύει ότι $\mathcal{X}_S = \mathcal{X}_T$, αλλά $P_S(X) \neq P_T(X)$, δηλαδή υπάρχει διαφορά στην κατανομή των χαρακτηριστικών μεταξύ των δύο περιοχών.

Μετατόπιση Πεδίου (Domain Shift) Ορίζεται ως η απόκλιση μεταξύ της κατανομής των δεδομένων ή των ετικετών μεταξύ των *source* και *target domains*. Ορίζονται τρεις βασικοί τύποι μετατόπισης (Farahani et al. 2021):

- **Label ή prior shift:** Η περίπτωση κατά την οποία η κατανομή των ετικετών (**prior distribution**) διαφέρει μεταξύ των *domains*, ενώ οι υπό συνθήκη κατανομές (**posterior distributions**) παραμένουν ίδιες.

$$P_S(Y) \neq P_T(Y), \quad \text{αλλά} \quad P_S(Y | X) = P_T(Y | X) \quad (2.20)$$

Αυτό σημαίνει ότι το είδος των κατηγοριών και ο τρόπος που σχετίζονται με τα χαρακτηριστικά παραμένει ο ίδιος, αλλά αλλάζει η συχνότητα εμφάνισής τους.

- **Covariate shift:** Η πιο κοινή μορφή *domain shift* στην οποία οι *a priori* κατανομές των χαρακτηριστικών εισόδου $P(X)$ διαφέρουν μεταξύ των τομέων, αλλά ο μηχανισμός απόδοσης ετικετών παραμένει ίδιος. Δηλαδή:


$$P_S(X) \neq P_T(X), \quad \text{αλλά} \quad P_S(Y | X) = P_T(Y | X) \quad (2.21)$$

Αυτό μπορεί να οφείλεται σε διαφορετικές μεθόδους δειγματοληψίας, σε διαφορετικό περιβάλλον ή εξοπλισμό καταγραφής.

- **Concept shift:** Η περίπτωση κατά την οποία αλλάζει ο μηχανισμός που συσχετίζει τα χαρακτηριστικά με τις ετικέτες, δηλαδή αλλάζει η *a posteriori* κατανομή $P(Y | X)$, παρόλο που η κατανομή των εισόδων παραμένει η ίδια:

$$P_S(X) = P_T(X), \quad \text{αλλά} \quad P_S(Y | X) \neq P_T(Y | X) \quad (2.22)$$

Αυτό συνεπάγεται ότι το ίδιο δεδομένο μπορεί να ανήκει σε διαφορετική κατηγορία ανάλογα με τον τομέα. Είναι από τα πιο δύσκολα σενάρια και απαιτεί την ύπαρξη ετικετών και στους δύο τομείς για να αντιμετωπιστεί.



Σχήμα 2.18: Είδη μετατόπισης πεδίου. (Ganin et al. 2016)

Στο πλαίσιο της συγκεκριμένης εργασίας για την αναγνώριση παθολογικών μοτίβων σε αναπνευστικούς ήχους, οι λόγοι εμφάνισης μετατόπισης πεδίου είναι ποικίλοι. Η μετατόπιση κατά κύρια βάση προέρχεται λόγω των **διαφορετικών συσκευών καταγραφής** όπως μικρόφωνα, στηθοσκόπια κ.τ.λ. Ένας άλλος παράγοντας είναι η **αλλαγή πληθυσμιακής κατανομής** από την οποία προκύπτει το σύνολο δεδομένων, δηλαδή η ηλικία, το φύλο ή η γεωγραφική προέλευση των ασθενών. Τέλος, σημαντικό ρόλο διαδραματίζουν και οι **διαφορετικές συνθήκες ηχογράφησης**, δηλαδή η παρουσία θορύβου στο χώρο καταγραφής, ο τρόπος αναπνοής του ασθενούς, καθώς και η στάση σώματός του. Με βάση αυτά, θα λέγαμε ότι στη συγκεκριμένη περίπτωση άρα καλούμαστε να αντιμετωπίσουμε το φαινόμενο του *covariate shift*, καθώς η κατανομή των χαρακτηριστικών $P(X)$ διαφοροποιείται μεταξύ των πηγών λόγω των παραγόντων που αναφέραμε, ενώ παράλληλα η συνάρτηση στόχου $P(Y | X)$ παραμένει αμετάβλητη.

2.6 Προσαρμογή πεδίου

Για την αντιμετώπιση του προβλήματος της μετατόπισης πεδίου αναπτύχθηκε ο κλάδος της **προσαρμογής πεδίου** (*domain adaptation*), ο οποίος είναι ένα υποπεδίο της μεταφοράς μάθησης (*transfer learning*), με στόχο τη μεταφορά γνώσης από ένα πεδίο πηγή σε ένα διαφορετικό αλλά σχετικό πεδίο στόχο, μεγιστοποιώντας την απόδοση χωρίς επανεκπαίδευση του μοντέλου από το μηδέν. Η προσαρμογή πεδίου ουσιαστικά λειτουργεί ως μια γέφυρα ανάμεσα σε ετερογενείς πηγές δεδομένων, συμβάλλοντας έτσι στην άρση της μεροληψίας

που εισάγουν οι διαφορετικές κατανομές και καθιστά τα μοντέλα πιο σταθερά, αξιόπιστα και εφαρμόσιμα σε πραγματικά περιβάλλοντα.



Σχήμα 2.19: Βασική αρχή λειτουργίας της προσαρμογής πεδίου. (Kundu 2022)

2.6.1 Επιβλεπόμενη και μη επιβλεπόμενη προσαρμογή πεδίου

Αρχικά, το πρόβλημα της προσαρμογής πεδίου μπορεί να διαχωριστεί ανάλογα με τη διαθεσιμότητα των ετικετών των δεδομένων (*labels*) στο *target domain* σε δύο θεμελιώδεις κατηγορίες, οι οποίες περιγράφονται παρακάτω (Farahani et al. 2021):

Επιβλεπόμενη προσαρμογή πεδίου (*Supervised domain adaptation*) Στο σενάριο της **επιβλεπόμενης προσαρμογής** υποθέτουμε ότι τόσο το *source domain* όσο και το *target domain* διαθέτουν δεδομένα με *labels*, δηλαδή τις αντίστοιχες αναπνευστικές παθήσεις. Αυτό σημαίνει ότι μπορούμε να μάθουμε από κοινού το μοντέλο με πλήρη εποπτεία και από τα δύο περιβάλλοντα. Το κύριο πλεονέκτημα της επιβλεπόμενης προσαρμογής είναι η δυνατότητα πιο ακριβούς εκτίμησης της κατανομής $P_T(Y | X)$.

Μη επιβλεπόμενη προσαρμογή πεδίου (*Unsupervised domain adaptation*) Η **μη επιβλεπόμενη προσαρμογή** είναι το πιο κοινό αλλά και πιο δύσκολο σενάριο προσαρμογής τομέα. Υποθέτει ότι τα δεδομένα στο *target domain* είναι μη επισημασμένα, δηλαδή διαθέτουμε μόνο τα X_T χωρίς τις αντίστοιχες ετικέτες Y_T . Το μόνο επισημασμένο σύνολο είναι αυτό του *source domain*, δηλαδή (X_S, Y_S) . Η πρόκληση σε αυτήν την περίπτωση έγκειται στο γεγονός ότι πρέπει να μάθουμε μια συνάρτηση πρόβλεψης $f : X \rightarrow Y$ η οποία θα αποδίδει καλά στο *target domain* χωρίς να γνωρίζουμε τις ετικέτες του.

2.6.2 Βασικές κατηγορίες προσαρμογής πεδίου

Στη συνέχεια, με βάση όλα τα παραπάνω έχουν οριστεί τέσσερις βασικές κατηγορίες προσαρμογής πεδίου (Farahani et al. 2021):

Προσαρμογή πεδίου κλειστού συνόλου (*Closed-set domain adaptation*) Πρόκειται για το πιο κλασικό σενάριο όπου υποτίθεται ότι το **σύνολο ετικετών είναι το ίδιο** στο *source* και στο *target domain*, δηλαδή:

$$\mathcal{Y}_S = \mathcal{Y}_T \quad (2.23)$$

Ωστόσο, οι κατανομές πιθανότητας ενδέχεται να διαφέρουν:

$$P_S(X, Y) \neq P_T(X, Y) \quad (2.24)$$

Επομένως, παρότι το σύνολο των κατηγοριών είναι κοινό, υπάρχει απόκλιση στις στατιστικές ιδιότητες των δεδομένων, δημιουργώντας ανάγκη για μεταφορά γνώσης. Οι περισσότερες υπάρχουσες μέθοδοι προσαρμογής εμπίπτουν σε αυτή την κατηγορία.

Μερική προσαρμογή πεδίου (*Partial domain adaptation*) Στην περίπτωση αυτή, το **σύνολο ετικετών του target domain είναι υποσύνολο του source domain**:

$$\mathcal{Y}_T \subset \mathcal{Y}_S \quad (2.25)$$

Το *source domain* θεωρείται γενικό και περιέχει πολλές κατηγορίες, ενώ το *target domain* επικεντρώνεται μόνο σε ένα υποσύνολο. Αν εφαρμοστούν παραδοσιακές μέθοδοι ευθυγράμμισης ολόκληρων κατανομών, μπορεί να προκύψει το φαινόμενο της **αρνητικής μεταφοράς** (*negative transfer*), καθώς μεταφέρεται γνώση από κατηγορίες του source που δεν υπάρχουν στο target. Ειδικές τεχνικές έχουν προταθεί ώστε να αγνοείται η πληροφορία που δεν είναι σχετική με τις *target classes*.

Προσαρμογή πεδίου ανοιχτού συνόλου (*Open-set domain adaptation*) Σε αυτό το σενάριο, τα **σύνολα ετικετών μεταξύ source και target domains επικαλύπτονται εν μέρει**, δηλαδή:


$$\mathcal{Y}_S \cap \mathcal{Y}_T \neq \emptyset, \quad \mathcal{Y}_S \not\subset \mathcal{Y}_T, \quad \mathcal{Y}_T \not\subset \mathcal{Y}_S \quad (2.26)$$

Υπάρχουν δηλαδή κοινές κατηγορίες, αλλά και ιδιωτικές για κάθε *domain*. Η πρόκληση είναι ο ακριβής εντοπισμός των κοινών κατηγοριών και η αποφυγή αρνητικής μεταφοράς από τις αποκλειστικές κλάσεις του *source domain*. Στην πράξη, μοντέλα προσαρμόζονται ώστε να προβλέπουν σωστά τις κοινές ετικέτες και να απορρίπτουν ως «άγνωστα» τα δείγματα από μη κοινές κατηγορίες.

Καθολική προσαρμογή πεδίου (*Universal domain adaptation*) Είναι η γενικευμένη προσέγγιση της προσαρμογής τομέα, όπου **δεν απαιτείται εκ των προτέρων γνώση** για τη σχέση μεταξύ των συνόλων ετικετών:

$\mathcal{Y}_S$ και $\mathcal{Y}_T$ μπορεί να είναι οποιαδήποτε υποσύνολα του ενιαίου καθολικού συνόλου ετικετών.


Η προσέγγιση αυτή προσπαθεί πρώτα να αναγνωρίσει το κοινό υποσύνολο ετικετών και στη συνέχεια να προσαρμόσει κατάλληλα τις κατανομές στο κοινό αυτό υποσύνολο. Θεωρείται η πιο ρεαλιστική αλλά και η πιο απαιτητική προσέγγιση.



Σχήμα 2.20: Είδη προσαρμογής πεδίου. (Fan et al. 2022)

2.6.3 Βασικές προσεγγίσεις προσαρμογής πεδίου

Στη βιβλιογραφία (Farahani et al. 2021) οι μέθοδοι προσαρμογής πεδίου μπορούν να κατηγοριοποιηθούν σε δύο κύριες κατευθύνσεις: τις **ρηχές** (*shallow*) και τις **βαθείς** (*deep*) προσεγγίσεις.



Σχήμα 2.21: Βασικές προσεγγίσεις προσαρμογής πεδίου. (Fayek et al. 2024)

Οι ρηχές προσεγγίσεις βασίζονται κυρίως σε κλασικές τεχνικές μηχανικής μάθησης και διακρίνονται σε δύο κατηγορίες. Στις **instance-based** μεθόδους επιχειρείται η αναπροσαρμογή των δειγμάτων εκπαίδευσης ώστε να γίνουν πιο αντιπροσωπευτικά για το πεδίο στόχο, συνήθως με τη χρήση βαρών ή τεχνικών επαναδειγματοληψίας. Στις **feature-based** μεθόδους, το βάρος δίνεται στη μετατροπή ή προβολή των χαρακτηριστικών σε έναν κοινό χώρο, όπου οι κατανομές του τομέα πηγής και του τομέα στόχου γίνονται πιο ομοιογενείς.

Αντίθετα, οι βαθιές προσεγγίσεις αξιοποιούν τη δύναμη της βαθιάς μάθησης και περιλαμβάνουν δύο κύριες κατηγορίες. Οι **παραδοσιακές μέθοδοι βαθιάς μάθησης** στηρίζονται στη χρήση νευρωνικών δικτύων για την εκμάθηση αναπαραστάσεων με ικανότητα γενίκευσης σε διαφορετικούς τομείς. Οι **ανταγωνιστικές (adversarial) μέθοδοι** αξιοποιούν τεχνικές εκπαίδευσης με αντιπάλους, όπου ένας ταξινομητής πεδίου επιχειρεί να διακρίνει αν ένα δείγμα προέρχεται από το πεδίο πηγής ή στόχο, ενώ το κύριο δίκτυο μαθαίνει αναπαραστάσεις που «αποκρύπτουν» την πληροφορία του πεδίου, επιτυγχάνοντας έτσι ουδέτερη ως προς το πεδίο εκμάθηση.

Instance-based domain adaptation Οι *instance-based* τεχνικές επιχειρούν να αντιμετωπίσουν το *domain shift* μέσω **ανακατανομής βαρών** στα δείγματα εκπαίδευσης του *source domain*, έτσι ώστε η βεβαρυμένη κατανομή τους να προσεγγίζει καλύτερα την κατανομή του *target domain*. Με αυτόν τον τρόπο, το μοντέλο εκπαιδεύεται σε δεδομένα που αν και προέρχονται από το *source* «μοιάζουν» στατιστικά με αυτά του *target*. Η θεμελιώδης υπόθεση είναι αυτή του *covariate shift* όπως αναφέραμε και παραπάνω:

$$P_S(y|x) = P_T(y|x), \quad P_S(x) \neq P_T(x) \quad (2.27)$$

δηλαδή η συνάρτηση απόφασης (σχέση μεταξύ χαρακτηριστικών x και ετικέτας y) παραμένει η ίδια στους δύο τομείς, αλλά η κατανομή των ίδιων των χαρακτηριστικών διαφέρει.

Ο **κίνδυνος (risk)** $R_T(h)$ στο *target domain* ορίζεται ως η αναμενόμενη τιμή της συνάρτησης κόστους $\ell(h(x), y)$ όταν τα δείγματα προέρχονται από την κατανομή $P_T(x, y)$. Ο ταξινομητής $h(\cdot)$ είναι η συνάρτηση που προβλέπει την κλάση y με βάση τα χαρακτηριστικά x . Υπό την παραδοχή ύπαρξης *covariate shift*, ο κίνδυνος στο *target* μπορεί να εκφραστεί ως αναμενόμενη τιμή πάνω στην κατανομή του *source*:

$$R_T(h) = \mathbb{E}_{(x,y) \sim P_S} \left[\frac{P_T(x)}{P_S(x)} \ell(h(x), y) \right] \quad (2.28)$$

όπου ο λόγος

$$w(x) = \frac{P_T(x)}{P_S(x)}$$

αποτελεί το **importance weight** κάθε δείγματος. Δείγματα του *source* που μοιάζουν περισσότερο με αυτά του *target* λαμβάνουν μεγαλύτερο βάρος, ενώ όσα διαφέρουν σημαντικά λαμβάνουν μικρότερο.

Feature-based domain adaptation Οι *feature-based* μέθοδοι στοχεύουν στην εύρεση ενός **κοινού ενδιάμεσου χώρου αναπαράστασης** στον οποίο οι κατανομές των χαρακτηριστικών του *source* και του *target* τομέα είναι όσο το δυνατόν πιο όμοιες. Η βασική ιδέα είναι να εφαρμοστεί ένας μετασχηματισμός

$$\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

πάνω στα αρχικά χαρακτηριστικά $\mathbf{x}$, έτσι ώστε οι νέες αναπαραστάσεις $\mathbf{f} = \Phi(\mathbf{x})$ να ικανοποιούν τη σχέση:

$$P_S(\mathbf{f}) \approx P_T(\mathbf{f}) \quad (2.29)$$

δηλαδή οι *a priori* κατανομές τους στον ενδιαμέσο χώρο να ευθυγραμμίζονται. Ο μετασχηματισμός $\Phi(\cdot)$ μπορεί να είναι γραμμικός (π.χ. ανάλυση σε κύριες συνιστώσες) ή μη γραμμικός (π.χ. νευρωνικά δίκτυα). Η ευθυγράμμιση επιτυγχάνεται συνήθως μέσω της ελαχιστοποίησης μιας μετρικής απόστασης μεταξύ των κατανομών *source* και *target* στον νέο χώρο. Μερικά παραδείγματα τέτοιων μετρικών είναι:

- **Kullback–Leibler Divergence (KL)** Μετρά την πληροφοριακή απόκλιση της κατανομής P_T από την P_S και ορίζεται ως:

$$D_{KL}(P_T \parallel P_S) = \sum_{\mathbf{f}} P_T(\mathbf{f}) \log \frac{P_T(\mathbf{f})}{P_S(\mathbf{f})} \quad (2.30)$$

Ουσιαστικά, δείχνει πόση «πληροφορία χάνεται» όταν χρησιμοποιούμε την P_S για να προσεγγίσουμε την P_T . Μια τιμή $D_{KL} = 0$ σημαίνει ότι οι δύο κατανομές είναι ταυτόσημες, ενώ μεγαλύτερες τιμές δηλώνουν αυξημένη απόκλιση. Ένα πρακτικό μειονέκτημα είναι ότι η KL δεν είναι συμμετρική ($D_{KL}(P_T \parallel P_S) \neq D_{KL}(P_S \parallel P_T)$) και μπορεί να είναι άπειρη αν υπάρχουν περιοχές όπου $P_S(\mathbf{f}) = 0$ και $P_T(\mathbf{f}) > 0$.

- **Jensen–Shannon Divergence (JS)** Αποτελεί συμμετρική και φραγμένη παραλλαγή της KL -divergence, η οποία ορίζεται ως:

$$D_{JS}(P \parallel Q) = \frac{1}{2} D_{KL}(P \parallel M) + \frac{1}{2} D_{KL}(Q \parallel M) \quad (2.31)$$

δηλαδή ως ο μέσος όρος δύο αποκλίσεων KL , χρησιμοποιώντας μια ενδιαμέση κατανομή $M = \frac{1}{2}(P + Q)$. Σε αντίθεση με την KL , η JS παίρνει πάντα τιμές στο διάστημα $[0, 1]$, καθιστώντας την πιο σταθερή και ευκολότερη στην ερμηνεία. Στην πράξη, όσο μικρότερη είναι η JS -divergence, τόσο πιο όμοια θεωρούνται οι κατανομές των χαρακτηριστικών *source* και *target*.

- **Wasserstein Distance (Earth Mover’s Distance)** Εκφράζει το «κόστος» μεταφοράς μάζας από τη μία κατανομή στην άλλη αν φανταστούμε ότι οι πιθανότητες αντιστοιχούν σε μάζα που πρέπει να μετακινηθεί στον χώρο. Ορίζεται ως:

$$W(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|] \quad (2.32)$$

όπου $\Pi(P, Q)$ είναι το σύνολο όλων των κοινών κατανομών με περιθώρια P και Q . Αντιστοιχεί λοιπόν στο ελάχιστο «έργο μεταφοράς» μάζας από την P στην Q . Σε αντίθεση με τις KL και JS , οι οποίες εστιάζουν στη διαφορά πιθανοτήτων σε κάθε σημείο, η απόσταση *Wasserstein* λαμβάνει υπόψη τη **γεωμετρία του χώρου** και τις αποστάσεις μεταξύ δειγμάτων.

<i>Source</i> → <i>Target</i>	<i>Wasserstein Distance</i>	<i>JS Divergence</i>
AKGC417L → Meditron	5.0414	0.2264
LittC2SE → Meditron	11.5904	0.2923
Litt3200 → Meditron	25.9013	0.6171

Πίνακας 2.3: Απόσταση Wasserstein και JS Divergence των κατανομών των χαρακτηριστικών των πεδίων πηγής από το πεδίο στόχο Meditron.

Βαθιά προσαρμογή πεδίου (*Deep domain adaptation*) Οι προσεγγίσεις deep domain adaptation ενσωματώνουν την προσαρμογή τομέα στη διαδικασία εκμάθησης υψηλότερων αναπαραστάσεων, αξιοποιώντας την ικανότητα των βαθιών νευρωνικών δικτύων να μαθαίνουν πολύπλοκους, μη γραμμικούς μετασχηματισμούς χαρακτηριστικών. Σε αυτές τις μεθόδους, ο μετασχηματισμός $\Phi_{\theta_f}(\cdot)$ που παράγει τις αναπαραστάσεις $\mathbf{f}$ μαθαίνεται ταυτόχρονα με τον μηχανισμό προσαρμογής, αντί να εφαρμόζεται εκ των υστέρων.

Οι κύριες κατηγορίες αυτής της προσέγγισης είναι:

- **Discrepancy-based:** Σε αυτήν την κατηγορία, η στοίχιση των κατανομών επιβάλλεται μέσω πρόσθετων όρων κόστους που μετρούν τη διαφορά μεταξύ των κατανομών του *source* και του *target* στον ενδιάμεσο χώρο χαρακτηριστικών. Τυπικές μετρικές απόστασης που χρησιμοποιούνται είναι η *Maximum Mean Discrepancy (MMD)*, η *CORAL loss* και η *Central Moment Discrepancy (CMD)*. Μαθηματικά, η συνολική απώλεια μπορεί να γραφεί ως:

$$L_{\text{total}} = L_y + \lambda D(P_S(\mathbf{f}), P_T(\mathbf{f})) \quad (2.33)$$

όπου L_y είναι η απώλεια ταξινόμησης, $D(\cdot, \cdot)$ είναι η μετρική απόστασης μεταξύ κατανομών και λ ρυθμίζει τη σχετική της βαρύτητα.

- **Reconstruction-based** Αυτές οι μέθοδοι χρησιμοποιούν μηχανισμούς ανακατασκευής για να μάθουν κοινές αναπαραστάσεις που είναι ικανές να αναπαράγουν τα δεδομένα και από τους δύο τομείς. Συχνά βασίζονται σε **autoencoders**, όπου ο *encoder* αναλαμβάνει να εξάγει την κοινή αναπαράσταση $\mathbf{z}$ και ο *decoder* να την ανακατασκευάσει σε $\hat{\mathbf{x}}$. Η απώλεια ανακατασκευής είναι:

$$L_{\text{rec}} = \mathbb{E}_{\mathbf{x} \sim P_S} \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \mathbb{E}_{\mathbf{x} \sim P_T} \|\mathbf{x} - \hat{\mathbf{x}}\|^2 \quad (2.34)$$

- **Adversarial-based** Εμπνευσμένες από τα *Generative Adversarial Networks (GANs)*, οι μέθοδοι αυτής της κατηγορίας εισάγουν έναν **Domain classifier** G_{θ_d} , ο οποίος επιχειρεί να προβλέψει από ποιά *domain* προέρχεται μια αναπαράσταση $\mathbf{f}$. Ταυτόχρονα, ο **Feature extractor** G_{θ_f} εκπαιδεύεται ανταγωνιστικά ώστε να παράγει *domain-invariant* αναπαραστάσεις, με στόχο να «μπερδεύει» τον *Domain classifier*. Η απώλεια γράφεται συνήθως ως:

$$\min_{\theta_f, \theta_y} L_y - \lambda L_d, \quad \min_{\theta_d} L_d \quad (2.35)$$

όπου L_d είναι η απώλεια ταξινόμησης τομέα. Η ανταγωνιστική εκπαίδευση γίνεται συνήθως με ενσωμάτωση ενός **Gradient Reversal Layer (GRL)** στο δίκτυο που αντιστρέφει το πρόσημο του διανύσματος κλίσης στην οπισθοδιάδοση. Αυτή η στρατηγική επιτρέπει την εκμάθηση χαρακτηριστικών που είναι ταυτόχρονα διακριτικά για τις κλάσεις και ανθεκτικά στις διαφορές συσκευών, θορύβου ή περιβάλλοντος.


Στη δικιά μας περίπτωση, η βάση δεδομένων όπως αναλύσαμε περιλαμβάνει καταγραφές αναπνευστικών σημάτων από διαφορετικές συσκευές και πληθυσμιακές ομάδες, συνοδευόμενες από επισημασμένες ετικέτες παθολογίας. Αυτή η διαθεσιμότητα ετικετών τόσο στο *source* όσο και στο *target domain* επιτρέπει την αξιοποίηση τεχνικών **επιβλεπόμενης προσαρμογής πεδίου** (*supervised domain adaptation*), οι οποίες οδηγούν σε πιο στοχευμένη και ακριβή γενίκευση σε σχέση με μη επιβλεπόμενες ή ημι-επιβλεπόμενες μεθόδους. Καθώς όμως πρόκειται για περίπτωση **multisource domain adaptation** μπορούμε να γενικεύσουμε την παραπάνω ιδέα θεωρώντας ως *source domains* τις τρεις από τις τέσσερις συσκευές καταγραφής και ως *target domain* την τέταρτη εναπομείνασα συσκευή. Σύμφωνα μάλιστα με τη βιβλιογραφία (Wang et al. 2019; Farahani et al. 2021), το *supervised domain adaptation* είναι κατάλληλο πόσο μάλλον όταν η ακρίβεια και η ευαισθησία (*sensitivity*) είναι κρίσιμες, όπως σε βιοϊατρικά σενάρια όπου η παραμικρή υποβάθμιση στην απόδοση μπορεί να οδηγήσει σε λανθασμένες κλινικές αποφάσεις. Συνεπώς, η επιλογή της επιβλεπόμενης προσέγγισης στην παρούσα εργασία βασίζεται στο γεγονός αυτό, καθώς και στο ότι η αναγνώριση παθολογικών προτύπων απαιτεί χώρους αναπαράστασης οι οποίοι είναι *class-sensitive* όπως θα διαπιστώσουμε και παρακάτω.

Επιπλέον, αποφασίσαμε να εστιάσουμε στην κατηγορία των **deep adversarial-based domain adaptation** μεθόδων. Ο κύριος λόγος είναι ότι οι στρατηγικές αυτές έχουν αποδειχθεί ιδιαίτερα αποτελεσματικές σε περιπτώσεις όπου το *domain shift* προκύπτει από πολύπλοκες και μη γραμμικές διαφοροποιήσεις, όπως συμβαίνει με τα ακουστικά σήματα με μεγάλη ετερογένεια στις συσκευές καταγραφής. Παράλληλα, υπερτερούν και έναντι των *reconstruction-based* μεθόδων, οι οποίες επικεντρώνονται κυρίως στην πιστή ανακατασκευή του σήματος, κάτι που συχνά δεν συνεπάγεται βελτιστοποίηση της διαχωριστικής ικανότητας ως προς τις κλάσεις.

Κεφάλαιο 3

Προτεινόμενη μεθοδολογία

Στο συγκεκριμένο κεφάλαιο παρουσιάζεται το συνολικό pipeline της μεθοδολογίας που υλοποιήθηκε κατά την εκπόνηση της εργασίας.



Σχήμα 3.1: Pipeline υλοποίησης.

Ξεκινάμε εισάγοντας τα *training* και *test sets* στο **Preprocessing Module** από όπου προκύπτουν τα τελικά επεξεργασμένα αρχεία αναπνευστικών κύκλων. Στη συνέχεια, το training set υφίσταται επάυξηση μέσω της τεχνικής **VTLP-Patch** προκειμένου να εξισορροπηθεί και κάθε μία από τις τρεις κλάσεις να αντιστοιχεί στο ίδιο πλήθος εγγραφών. Ως αποτέλεσμα έχουμε πλέον **10018** αναπνευστικούς κύκλους, **8739** για το ισορροπημένο πλέον **training set** και **1279** για το **test set**, οι οποίοι εισάγονται στο **Feature Extraction Module**. Για κάθε αναπνευστικό κύκλο εξάγεται ξεχωριστά ένα **μητρώο χαρακτηριστικών** ως προς *frames* με διαστάσεις (T, F) , όπου:


- T είναι ο αριθμός χρονικών παραθύρων ανά δείγμα,
- F είναι το πλήθος εξαγμένων χαρακτηριστικών ανά *frame*

Επομένως στο τέλος παράγεται ένας **τανυστής τριών διαστάσεων** (N, T, F) , όπου N είναι το πλήθος των δειγμάτων (αναπνευστικοί κύκλοι), ο οποίος έχει αποθηκευμένα όλα τα

χαρακτηριστικά με βάση την εξέλιξή τους ως προς το χρόνο. Η χρήση όμως του τρισδιάστατου τανυστή χαρακτηριστικών απαιτεί μετασχηματισμό σε μορφή διδιάστατου μητρώου σταθερού μεγέθους ώστε να είναι κατάλληλος για είσοδο στους συμβατικούς αλγόριθμους μηχανικής μάθησης. Η πιο διαδεδομένη προσέγγιση είναι η **συνάθροιση (aggregation) των χαρακτηριστικών** ως προς τη δεύτερη διάσταση, δηλαδή του χρόνου T , μέσω του **μέσου όρου (mean)**. Με τον τρόπο αυτό, παράγεται ένα μητρώο διαστάσεων (N, F) , όπου κάθε δείγμα συνοψίζεται σε ένα διάνυσμα μέσης τιμής των χαρακτηριστικών του στον χρόνο. Αυτή η τεχνική εξομαλύνει τις ενδοχρονικές διακυμάνσεις, ελαχιστοποιεί τον χρονικό θόρυβο και οδηγεί σε πιο σταθερή αναπαράσταση. Το μητρώο αυτό χαρακτηριστικών (N, F) υφίσταται στατιστική ανάλυση μέσω *Exploratory Dataset Analysis* και μετά το **Feature Selection** διατηρούμε τα 20 πιο σημαντικά χαρακτηριστικά. Έτσι, προκύπτει τώρα ένα μητρώο διαστάσεων $(10018, 20)$, το οποίο θα περάσει από το **Domain Adaptation Module**. Τέλος, το μητρώο που έχει προκύψει περνάει μέσα από το **Classification Module** όπου γίνεται η εκπαίδευση και η τελική ταξινόμηση των αναπνευστικών κύκλων παράγοντας ένα διάνυσμα διαστάσεων **(3,)** για κάθε κύκλο με τα *softmax probabilities* για κάθε κλάση. Αυτά θα χρησιμοποιηθούν για την δημιουργία της τελικής πρόβλεψης και την αξιολόγηση των μοντέλων με βάση τις διαφορετικές μετρικές που αναλύσαμε.

3.1 Προεπεξεργασία αναπνευστικών σημάτων

Το **Preprocessing module** έχει ως στόχο την τυποποίηση και καθαρισμό των εισερχόμενων αναπνευστικών κύκλων, ώστε να διασφαλιστεί η ομοιομορφία των δεδομένων πριν από τη διαδικασία εξαγωγής χαρακτηριστικών. Η υλοποίηση περιλαμβάνει τα εξής στάδια:



Σχήμα 3.2: Block diagram για το Preprocessing Module.

Η **προεπεξεργασία (preprocessing)** αποτελεί κρίσιμο στάδιο στην ανάλυση βιοϊατρικών σημάτων και προϋπόθεση για την επιτυχή εξαγωγή χαρακτηριστικών και τη βελτιστοποίηση της απόδοσης των μεταγενέστερων μοντέλων μηχανικής μάθησης. Τα αναπνευστικά ηχητικά σήματα αν και φέρουν χρήσιμη διαγνωστική πληροφορία καταγράφονται υπό συνθήκες που εισάγουν σημαντικούς θορύβους, ετερογένεια και μη επιθυμητές παραλλαγές, όπως διαφορές στην ένταση, τη διάρκεια ή τη συχνότητα δειγματοληψίας. Αυτοί οι παράγοντες μπορούν να αλλοιώσουν την αναπαράσταση του σήματος και να επηρεάσουν δυσμενώς τη γενίκευση των

μοντέλων ταξινόμησης. Για τον λόγο αυτό, στην παρούσα εργασία υιοθετείται μια πλήρης ακολουθία προεπεξεργασίας, η οποία περιλαμβάνει τα εξής στάδια: **επαναδειγματοληψία σε κοινή συχνότητα, χρονική προσαρμογή διάρκειας, κανονικοποίηση πλάτους, αποθορυβοποίηση και εφαρμογή τεχνικών επαύξησης δεδομένων όπως η παραμόρφωση φωνητικού σωλήνα (VTLP)**. Κάθε ένα από αυτά τα στάδια σχεδιάστηκε ώστε να διατηρεί τη διαγνωστική πληροφορία του σήματος, ενώ παράλληλα να περιορίζει τις ανεπιθύμητες διακυμάνσεις που σχετίζονται με εξωγενείς παράγοντες.

Η ενότητα αυτή περιγράφει αναλυτικά τα επιμέρους βήματα προεπεξεργασίας που εφαρμόστηκαν, τεκμηριώνοντας τόσο τις θεωρητικές αρχές της ψηφιακής επεξεργασίας σημάτων όσο και τις πρακτικές επιλογές παραμέτρων που υιοθετήθηκαν.

3.1.1 Επαναδειγματοληψία

Η **επαναδειγματοληψία** (*resampling*) αποτελεί ένα από τα βασικά βήματα προεπεξεργασίας στην ανάλυση ψηφιακών αναπνευστικών σημάτων. Πρόκειται για τη διαδικασία μετατροπής της συχνότητας δειγματοληψίας ενός διακριτού σήματος από μια αρχική τιμή f_s σε μια νέα, επιθυμητή συχνότητα f'_s . Ουσιαστικά, το σήμα $x[n]$ αναδομείται σε μια νέα μορφή $x'[m]$ που αντιστοιχεί σε διαφορετική χρονική ανάλυση. Η ανάγκη για επαναδειγματοληψία προκύπτει από το γεγονός ότι τα σήματα έχουν καταγραφεί με διαφορετικές συχνότητες ανάλογα με τον εξοπλισμό, τη μεθοδολογία ή το χρονικό πλαίσιο της καταγραφής. Συνεπώς, η μετατροπή όλων των σημάτων σε κοινή συχνότητα αναφοράς f'_s επιτρέπει την ομοιόμορφη επεξεργασία και σύγκρισή τους.

Μαθηματικά, η επαναδειγματοληψία ενός διακριτού σήματος $x[n]$ από συχνότητα f_s σε νέα συχνότητα f'_s επιτυγχάνεται μέσω δύο βασικών μεθοδολογιών, ανάλογα με τη σχέση μεταξύ f_s και f'_s :

Υποδειγματοληψία (Downsampling) Εφαρμόζεται όταν $f'_s < f_s$. Διατηρείται μόνο ένα κάθε M -οστό δείγμα του αρχικού σήματος:

$$x_d[n] = x[nM] \quad (3.1)$$

Υπερδειγματοληψία (Upsampling) Εφαρμόζεται όταν $f'_s > f_s$. Εισάγονται $L - 1$ μηδενικά μεταξύ κάθε δύο διαδοχικών δειγμάτων:

$$x_u[n] = \begin{cases} x\left[\frac{n}{L}\right], & \text{αν } n \bmod L = 0 \\ 0, & \text{διαφορετικά} \end{cases} \quad (3.2)$$

Στο πλαίσιο της παρούσας εργασίας, η επαναδειγματοληψία εφαρμόστηκε προκειμένου να εξομοιωθεί η συχνότητα δειγματοληψίας όλων των αναπνευστικών σημάτων σε κοινό ρυθμό. Το χρησιμοποιούμενο σύνολο δεδομένων όπως είδαμε περιλαμβάνει καταγραφές από τέσσερις διαφορετικές συσκευές, εκ των οποίων οι τρεις καταγράφουν σε συχνότητα **4 kHz**, ενώ η τέταρτη χρησιμοποιεί συχνότητα **44.1 kHz** που αποτελεί κοινό πρότυπο στην εμπορική ή μουσική ηχογράφηση, αλλά υπερβαίνει κατά πολύ τις ανάγκες της παρούσας εφαρμογής.

Λαμβάνοντας λοιπόν υπόψη την συγλεριμένη ετερογένεια κρίθηκε απαραίτητη η **επανα-δειγματοληψία μέσω *downsampling*** των σημάτων που καταγράφηκαν από τη συσκευή **AKGC417L** με συχνότητα **4 kHz** αντί για **44.1 kHz**, ώστε να εξομοιωθούν με τις υπόλοιπες καταγραφές.

Συσκευή	Συχνότητα δειγματοληψίας
Meditron	4 kHz
Litt3200	4 kHz
LittC2SE	4 kHz
AKGC417L	44.1 kHz

Πίνακας 3.1: Συχνότητες καταγραφής αναπνευστικών σημάτων από τις διαφορετικές συσκευές.

Η επιλογή της συγκεκριμένης συχνότητας βασίζεται στο γεγονός ότι καλύπτει πλήρως το φασματικό εύρος των αναπνευστικών ήχων που μας ενδιαφέρουν (100–1200 Hz), καθώς βάσει του θεωρήματος *Nyquist-Shannon* με συχνότητα δειγματοληψίας 4 kHz θα καλύπτουμε εύρος συχνοτήτων από 0-2 kHz, εξισορροπώντας παράλληλα τη διατήρηση κρίσιμης πληροφορίας με την αποδοτικότητα σε αποθήκευση και υπολογιστική ισχύ. Πιο συγκεκριμένα, η χρήση υψηλότερων συχνοτήτων θα αύξανε σημαντικά το μέγεθος των αρχείων και τις απαιτήσεις σε επεξεργαστικό χρόνο, χωρίς να προσφέρει ουσιαστικό όφελος στην αναπαράσταση αναπνευστικών σημάτων που περιέχουν χαμηλοσυχνοτική πληροφορία. Αντιθέτως, υπερβολικά χαμηλές συχνότητες μπορεί να οδηγούσαν σε απώλεια κρίσιμων πληροφοριών.

3.1.2 Καθορισμός χρονικών ορίων

Ένα από τα κρίσιμα βήματα στην προεπεξεργασία των αναπνευστικών σημάτων είναι ο **καθορισμός των χρονικών ορίων** της διάρκειας κάθε αναπνευστικού κύκλου σε κοινή κλίμακα, ώστε όλοι οι κύκλοι να έχουν ίσο μήκος στο πεδίο του χρόνου. Οι μεγάλες αποκλίσεις στη χρονική διάρκεια των κύκλων είναι συνήθως αποτέλεσμα φυσιολογικών παραγόντων (ηλικία, θέση σώματος, βάθος αναπνοής) ή παθολογικών καταστάσεων (δύσπνοια, απόφραξη αεραγωγών κ.ά.). Αυτή η μεταβλητότητα ωστόσο οδηγεί σε σήματα διαφορετικού μήκους, τα οποία είναι δύσκολο να συγκριθούν ή να υποβληθούν σε ενιαία ανάλυση. Επιπλέον, για την εκπαίδευση των μοντέλων μηχανικής και βαθιάς μάθησης θα χρειαστούμε δεδομένα εισόδου με καθορισμένο μέγεθος, καθώς η σταθερότητα των διαστάσεων διευκολύνει την εξαγωγή χαρακτηριστικών, την κανονικοποίηση και την αξιολόγηση των μοντέλων.

Ο καθορισμός των ορίων του σήματος μπορεί να πραγματοποιηθεί με 2 διαφορετικές τεχνικές, ανάλογα με το αν θέλουμε να μειώσουμε ή να αυξήσουμε τη διάρκεια του αρχικού σήματος:

Αποκοπή (*Trimming*) Η τεχνική της **αποκοπής** είναι η διαδικασία κατά την οποία αφαιρούνται συγκεκριμένα τμήματα ενός σήματος μήκους L , με σκοπό τη μείωση του μήκους του

ή την εξάλειψη μη χρήσιμης πληροφορίας, διατηρώντας μόνο τα κρίσιμα ακουστικά δεδομένα. Η τεχνική αυτή είναι ιδιαίτερα χρήσιμη σε αναπνευστικά σήματα όταν το σήμα περιέχει εκτεταμένες περιόδους σιγής ή χαμηλής ενέργειας μεταξύ αναπνοών. Η πιο συνήθης πρακτική είναι η αφαίρεση δειγμάτων ξεκινώντας από το τέλος του σήματος, δηλαδή $x[L-1], x[L-2], \dots, x[N+1]$ μέχρις ότου να φτάσουμε στο επιθυμητό μήκος $N < L$.

Συμπλήρωση (*Padding*) Η τεχνική της **συμπλήρωσης μήκους** περιλαμβάνει την προσθήκη τεχνητών δειγμάτων σε συγκεκριμένες θέσεις του σήματος μήκους L (συνήθως στην αρχή ή/και στο τέλος) ώστε το συνολικό μήκος να ισούται με μία προκαθορισμένη σταθερή τιμή $N > L$. Υπάρχουν διάφορες στρατηγικές *padding*, με τις πιο διαδεδομένες να είναι:

- **Συμπλήρωση με μηδενικά (*Zero padding*)**: Στη συγκεκριμένη περίπτωση προστίθενται μηδενικές τιμές στο τέλος (ή στην αρχή) του σήματος:

$$x_{\text{padded}}[n] = \begin{cases} x[n], & 0 \leq n < L \\ 0, & L \leq n < N \end{cases} \quad (3.3)$$

Αν και απλή σαν μέθοδος μπορεί να εισάγει ασυνέχειες στα άκρα, ειδικά σε φασματικές αναπαραστάσεις.

- **Συμπλήρωση με κατοπτρισμό (*Reflection padding*)**: Το σήμα συμπληρώνεται με αντίγραφα τμημάτων του εαυτού του, σε συμμετρική διάταξη:

$$x_{\text{padded}}[n] = [x[L-1], \dots, x[0], x[0], \dots, x[L-1]] \quad (3.4)$$

Είναι ιδιαίτερα χρήσιμο σαν μεθοδολογία σε περιπτώσεις όπου θέλουμε συνεχή άκρα και αποφυγή οξύτητας λόγω μηδενισμού.

- **Συμπλήρωση με επανάληψη άκρου (*Replication padding*)**: Το τελικό δείγμα του σήματος επαναλαμβάνεται μέχρι να καλυφθεί το επιθυμητό μήκος:

$$x_{\text{padded}}[n] = [x[0], \dots, x[L-1], x[L-1], \dots, x[L-1]] \quad (3.5)$$

Είναι κατάλληλο όταν το σήμα σταθεροποιείται στο τέλος.


- **Κυκλική συμπλήρωση (*Circular padding*)**: Σε αυτή την τεχνική, η συμπλήρωση γίνεται με *κυκλική επανάληψη* του ίδιου του σήματος, σαν να θεωρείται το σήμα περιοδικό. Δηλαδή, οι τιμές που απαιτούνται στο τέλος του σήματος αντιγράφονται από την αρχή του, και αντίστροφα αν χρειαστεί *padding* και στην αρχή:

$$x_{\text{padded}}[n] = [x[L-k], \dots, x[L-1], x[0], \dots, x[L-1], x[0], \dots, x[k-1]] \quad (3.6)$$


Όσον αφορά τη δικιά μας περίπτωση, όπως φαίνεται και από το Σχήμα 2.10, θέλουμε η κοινή διάρκεια όλων των αρχείων να είναι κάποια τιμή κοντά στη μέση τιμή της διάρκειας της

αναπνευστικών κύκλων, δηλαδή 2 s, έτσι ώστε να εξομαλυνθούν οι υπερβολικά μικρές ή υπερβολικά μεγάλες χρονικές διάρκειες. Μετά από δοκιμές με διάφορες χρονικές διάρκειες από 3 ως 8 s καταλήξαμε στο συμπέρασμα ότι **όλα τα σήματα είναι κρίσιμο να κανονικοποιηθούν σε σταθερή διάρκεια ίση με 3 s**, καθώς το χρονικό αυτό παράθυρο επαρκεί για τη καταγραφή τόσο της εισπνευστικής όσο και της εκπνευστικής φάσης, επιτρέποντας ταυτόχρονα την ανίχνευση και διάκριση παθολογικών προτύπων χωρίς αραίωση της κρίσιμης πληροφορίας. Επιπλέον, αποφεύγεται η περιττή αύξηση του μήκους εισόδου στα μοντέλα, η οποία θα μείωνε τη διακριτική ικανότητα των ταξινομητών.

Για τους κύκλους με **μεγαλύτερη χρονική διάρκεια από 3 s** εφαρμόσαμε *trimming* όπως περιγράφηκε προηγουμένως, ενώ για κύκλους με **μικρότερη χρονική διάρκεια από 3 s** επιλέξαμε *circular padding* για το λόγο ότι έτσι δεν εισάγουμε απότομες μεταβάσεις στο σήμα, οι οποίες ενδέχεται να εκληφθούν ως τεχνητοί θόρυβοι ή παθολογικά γεγονότα από τα μοντέλα ταξινόμησης.



Σχήμα 3.3: Ενδεικτικό παράδειγμα εφαρμογής trimming.




Σχήμα 3.4: Ενδεικτικό παράδειγμα εφαρμογής padding.

3.1.3 Κανονικοποίηση πλάτους

Κατά την ψηφιακή επεξεργασία ακουστικών σημάτων και ειδικότερα αναπνευστικών ήχων είναι σύνηθες να παρατηρείται σημαντική **διακύμανση στο πλάτος** των καταγραφών. Οι διακυμάνσεις αυτές καθιστούν δύσκολη τη σύγκριση σημάτων και την εκπαίδευση μοντέλων μηχανικής μάθησης, καθώς η μεταβολή στην ένταση μπορεί να επισκιάσει ή να παραποιήσει τα διαγνωστικά ηχητικά χαρακτηριστικά. Για τον λόγο αυτό, εφαρμόζεται η διαδικασία της **κανονικοποίησης πλάτους** (*amplitude normalization*), η οποία στοχεύει στη μετατροπή όλων των σημάτων σε κοινή κλίμακα έντασης. Πιο συγκεκριμένα, το σήμα $x[n]$ διαιρείται με

τη μέγιστη απόλυτη τιμή του ώστε το νέο σήμα να έχει μέγιστο πλάτος ίσο με 1. Με αυτόν τον τρόπο εξασφαλίζεται ότι όλες οι καταγραφές έχουν κοινό μέγιστο πλάτος, ανεξάρτητα από την αρχική ένταση. Η κανονικοποίηση πλάτους δεν επηρεάζει το φασματικό περιεχόμενο του σήματος αλλά μεταβάλλει την ακουστική ενέργεια ή το δυναμικό εύρος, ώστε όλα τα σήματα να είναι συγκρίσιμα ως προς την ένταση και να διευκολύνουν την εκπαίδευση ταξινομητών, οι οποίοι διαφορετικά θα εστίαζαν σε άσχετες διαφορές έντασης.

Στην παρούσα μελέτη, εφαρμόστηκε **κανονικοποίηση του πλάτους των σημάτων των αναπνευστικών κύκλων στο διάστημα $[-1,1]$** .



Σχήμα 3.5: Ενδεικτικό παράδειγμα εφαρμογής κανονικοποίησης πλάτους.


3.1.4 Αποθορυβοποίηση

Σαν τελικό βήμα προεπεξεργασίας είναι συνήθως απαραίτητο να εφαρμοστεί κάποια μορφή **αποθορυβοποίησης (denoising)**, καθώς τα καταγραφόμενα σήματα είναι συχνά επιβαρυνμένα με **θορυβώδεις ή ανεπιθύμητες συνιστώσες** που δεν σχετίζονται με την επιθυμητή φυσιολογική ή παθολογική πληροφορία. Στην περίπτωση των αναπνευστικών σημάτων, αυτοί οι θόρυβοι μπορεί να προέρχονται από **ήχους του περιβάλλοντος** (π.χ. συνομιλίες, κίνηση, ηλεκτρονικά όργανα), **καρδιακούς ήχους** που επικαλύπτουν το αναπνευστικό σήμα σε χαμηλές συχνότητες ή και **μηχανικούς θορύβους** από το ίδιο το στηθοσκόπιο ή την επιφάνεια του σώματος.

Στις πιο διαδεδομένες μεθόδους αποθορυβοποίησης συγκαταλέγονται τα **ψηφιακά φίλτρα**, τα οποία επιτρέπουν ή απορρίπτουν τη διέλευση συχνοτήτων από συγκεκριμένες περιοχές του φάσματος του σήματος. Γενικά, από τα ψηφιακά φίλτρα θα λέγαμε ότι τα φίλτρα *Butterworth* αποτελούν μια από τις πιο διαδεδομένες κατηγορίες λόγω της απλότητας και της σταθερότητάς τους. Κύριο χαρακτηριστικό τους είναι η απόλυτα επίπεδη απόκριση πλάτους στη ζώνη διέλευσης, χωρίς κυματώσεις, γεγονός που τα καθιστά ιδιαίτερα κατάλληλα για επεξεργασία βιοϊατρικών σημάτων, όπου είναι κρίσιμη η αποφυγή τεχνητών παραμορφώσεων. Επιπλέον, παρουσιάζουν μονοτονική μείωση στο εύρος αποκοπής, εξασφαλίζοντας ομαλή μετάβαση από τη ζώνη διέλευσης στη ζώνη αποκοπής. Τα ψηφιακά φίλτρα *Butterworth* διακρίνονται σε τέσσερις βασικές κατηγορίες:

- **Φίλτρο διέλευσης χαμηλών συχνοτήτων (low-pass):** διατηρεί τις χαμηλές συχνότητες και κόβει τις υψηλές οι οποίες βρίσκονται πάνω από ένα όριο αποκοπής f_c .


- **Φίλτρο διέλευσης υψηλών συχνοτήτων (*high-pass*):** διατηρεί τις υψηλές συχνότητες και κόβει τις χαμηλές οι οποίες βρίσκονται κάτω από ένα όριο αποκοπής f_c .
- **Ζωνοπερατό φίλτρο (*band-pass*):** διατηρεί μόνο μια συγκεκριμένη ζώνη συχνοτήτων $[f_1, f_2]$.
- **Ζωνοφρακτικό φίλτρο (*band-stop*):** αποκόπτει μόνο μια συγκεκριμένη ζώνη συχνοτήτων $[f_1, f_2]$.



Σχήμα 3.6: Είδη ψηφιακών φίλτρων.

Στην παρούσα μελέτη εφαρμόστηκε ψηφιακό φίλτρο *Butterworth* διέλευσης υψηλών συχνοτήτων (*high-pass*) με στόχο την απομάκρυνση ανεπιθύμητων χαμηλών συχνοτήτων από τα αναπνευστικά σήματα. Το φίλτρο αυτό σχεδιάστηκε ώστε να εξουδετερώνει τους **καρδιακούς ήχους**, οι οποίοι κυριαρχούν κάτω από τα **50–100 Hz** και τον **θόρυβο περιβάλλοντος** που βρίσκεται σε πολύ χαμηλές συχνότητες (**0–50 Hz**). Για το λόγο αυτό, επιλέχθηκε ως συχνότητα αποκοπής η $f_c=100\text{ Hz}$, με αποτέλεσμα **οι εναπομείνουσες συχνότητες των σημάτων που θα αξιοποιήσουμε να βρίσκονται εντός της ζώνης [100 Hz, 2000 Hz]**. Το φάσμα ενδιαφέροντος ούτως ή άλλως των αναπνευστικών ήχων όπως είδαμε εκτείνεται κυρίως στην περιοχή **100–1200 Hz**, με τις περισσότερες διαγνωστικές πληροφορίες να συγκεντρώνονται μάλιστα μεταξύ **150–600 Hz**. Η αποκοπή συνεπώς των συχνοτήτων κάτω από το συγκεκριμένο κατώφλι των **100 Hz** δεν αφαιρεί κάποια σημαντική πληροφορία.

Παρακάτω βλέπουμε ένα ενδεικτικό παράδειγμα αναπνευστικού κύκλου πριν και μετά την εφαρμογή υψιπερατού φίλτρου. Στην αρχική του μορφή παρατηρείται έντονη ενέργεια στις πολύ χαμηλές συχνότητες, η οποία ενδέχεται να προέρχεται από ανεπιθύμητους θορύβους όπως καρδιακοί ήχοι και θόρυβοι περιβάλλοντος κατά την εγγραφή. Μετά την εφαρμογή του φίλτρου η ενέργεια στις πολύ χαμηλές συχνότητες έχει περιοριστεί σημαντικά, ενώ το κυρίως φασματικό περιεχόμενο στην περιοχή **100–1200 Hz** όπου εντοπίζονται οι σημαντικότερες πληροφορίες των φυσιολογικών και παθολογικών αναπνευστικών ήχων, διατηρείται αχέραιο. Βλέπουμε επίσης ότι ενισχύεται ορατότητα των διακριτών συχνοτικών υπογραφών όπως οι εκρηκτικές αυξήσεις ενέργειας στα *crackles*).



Σχήμα 3.7: Ενδεικτικό παράδειγμα εφαρμογής high-pass φίλτρου.

3.2 Επαύξηση αναπνευστικών κύκλων

Στην περίπτωση των αναπνευστικών σημάτων, οι φυσιολογικές διακυμάνσεις στο μήκος του φωνητικού σωλήνα, στη γεωμετρία των αεραγωγών, αλλά και στη στάθμη εγγραφής μεταξύ διαφορετικών συσκευών ή ατόμων, επηρεάζουν σημαντικά το φασματικό αποτύπωμα των ηχητικών δεδομένων. Για την ενίσχυση λοιπόν της γενίκευσης των μοντέλων και την αύξηση της ανθεκτικότητας στα παραπάνω είδη παραλλαγών, εφαρμόστηκε η τεχνική **Vocal Tract Length Perturbation με τοπική τροποποίηση (VTLP-Patch Augmentation)**, η οποία προσομοιώνει μεταβολές στο μήκος του φωνητικού σωλήνα μεταβάλλοντας το φασματικό περιεχόμενο του σήματος (Dong et al. 2025).

Η βασική ιδέα πίσω από το *VTLP* είναι η τροποποίηση του άξονα συχνотήτων με μια συνάρτηση ανακατανομής $L(t)$, η οποία αλλάζει τη θέση των φασματικών συχνοτήτων και πιο συγκεκριμένα παραμορφώνει επιλεκτικά τις χαμηλές συχνότητες που περιλαμβάνουν τα περισσότερα φασματικά χαρακτηριστικά ενδιαφέροντος, ενώ παράλληλα διατηρεί σταθερές τις υψηλότερες. Αυτό πραγματοποιείται ώστε να προσομοιωθούν οι φυσιολογικές διαφορές μεταξύ ατόμων ή περιβάλλοντος καταγραφής. Η ανακατανομή αυτή βασίζεται στην εισαγωγή ενός τυχαίου παράγοντα κλιμάκωσης $\alpha \in [0.9, 1.1]$ και εφαρμόζεται μη γραμμικά σε συχνότητες μικρότερες ή μεγαλύτερες ενός ορίου F_{hi} . Στη δικιά μας περίπτωση **ως μέγιστη συχνότητα έχει επιλεγθεί το $F_{hi} = 2000 \text{ Hz}$** , η οποία είναι η μέγιστη συχνότητα που μπορούμε να αναπαραστήσουμε βάσει της συχνότητας δειγματοληψίας που έχουμε επιλέξει.

Ο μαθηματικός ορισμός της συνάρτησης $L(t)$ είναι:

$$L(t) = \begin{cases} t\alpha, & t \leq \frac{F_{hi} \cdot \min(\alpha, 1)}{\alpha} \\ \frac{S/2 - F_{hi} \cdot \min(\alpha, 1)}{S/2 - F_{hi}} \cdot (S/2 - t), & \text{αλλιώς} \end{cases} \quad (3.7)$$


Η διαδικασία **VTLP-Patch Aug** εφαρμόζεται ακολουθώντας τα εξής βήματα: Πρώτα, εκτελείται ο μετασχηματισμός *Fourier (STFT)* στο κανονικοποιημένο σήμα $x_o(t)$. Στη συνέχεια, εφαρμόζεται η μη γραμμική παραμόρφωση στους φασματικούς άξονες πολλαπλασιάζοντας τη συνάρτηση παραμόρφωσης $L(t)$ με το μετασχηματισμό *Fourier* του $x_o(t)$. Έπειτα, γίνεται ανακατασκευή του σήματος που προέκυψε μέσω αντίστροφου *STFT* και προστίθεται *Gaussian* λευκός θόρυβος $\eta(t)$ για αύξηση της φασματικής ανθεκτικότητας. Η τιμή λ χρησιμοποιείται ως *gain factor* για ενίσχυση της ακουστικής ενέργειας. Το αποτέλεσμα είναι μια

παραλλαγμένη εκδοχή $x_w(t)$ του αρχικού σήματος $x_o(t)$ με τροποποιημένο φάσμα αλλά διατηρημένα τα δομικά του χαρακτηριστικά, επιτρέποντας έτσι στο σύστημα να μάθει να αγνοεί μη χρήσιμες φυσιολογικές διακυμάνσεις (π.χ. διαφορετικό σωματότυπο) και να επικεντρώνεται σε παθολογικά μορφολογικά πρότυπα. Πιο κάτω αποτυπώνεται η μαθηματική έκφραση που περιγράφει τη διαδικασία υπολογισμού του νέου παραμορφωμένου σήματος:

$$x_w(t) = \lambda \cdot x_o \left(F^{-1} (F \cdot L(t)) \right) + \eta(t) \quad (3.8)$$

Στο πλαίσιο της συγκεκριμένης εργασίας, τέτοιες παραλλαγές εφαρμόστηκαν στο αρχικό σύνολο αναπνευστικών κύκλων με σκοπό τη δημιουργία πλουσιότερου συνόλου εκπαίδευσης, ενισχύοντας τη δυνατότητα γενίκευσης των μοντέλων.


Το Σχήμα 3.8 απεικονίζει την επίδραση της τεχνικής *VTLP-Patch Augmentation* τόσο οπτικά μέσω των φασματογραμμάτων όσο και αριθμητικά μέσω της απεικόνισης της συνάρτησης παραμόρφωσης του άξονα συχνότητων. Παρατηρείται ότι όντως μέσω της εφαρμογής της μη γραμμικής παραμόρφωσης στον άξονα συχνότητων μετατοπίζεται ελαφρώς η θέση των ενεργών φασματικών περιοχών (π.χ. ενισχύσεις ή μετακινήσεις κορυφών), διατηρώντας όμως τη γενική μορφολογία και ροή του σήματος.



Σχήμα 3.8: Ενδεικτικό παράδειγμα εφαρμογής VTLP-Patch Aug.

3.3 Εξαγωγή χαρακτηριστικών

Το *Feature extraction module* έχει ως στόχο την εξαγωγή των ακουστικών χαρακτηριστικών από τα προεπεξεργασμένα .wav αρχεία των αναπνευστικών κύκλων, δηλαδή την δημιουργία του τελικού μητρώου χαρακτηριστικών. Η υλοποίηση περιλαμβάνει τα εξής στάδια:



Σχήμα 3.9: Block diagram για το Feature Extraction Module.

Η **εξαγωγή χαρακτηριστικών** (*feature extraction*) αποτελεί κρίσιμο στάδιο όσον αφορά τη διαδικασία ανάλυσης και ταξινόμησης των αναπνευστικών σημάτων. Στην ουσία, τα εξαγμένα χαρακτηριστικά συμπυκνώνουν τη πληροφορία αυτή που αντιλαμβάνεται το ανθρώπινο αυτί διαισθητικά ακούγοντας το σήμα σε αριθμητικές τιμές που είναι εύχρηστες και κατανοητές αποκλειστικά από το υπολογιστικό σύστημα. Έτσι, αντί να χρησιμοποιείται απευθείας η ωμή κυματομορφή, η οποία περιλαμβάνει μεγάλο όγκο δεδομένων και πιθανώς μη χρήσιμες πληροφορίες, εξάγονται στοχευμένες μετρικές που αποτυπώνουν τα βασικά ακουστικά, χρονικά και φασματικά γνωρίσματα του σήματος. Στην περίπτωση των αναπνευστικών ήχων, τα χαρακτηριστικά αυτά συμβάλλουν στην αναγνώριση των παθολογικών προτύπων μέσα από τη μορφολογική, ενεργειακή και συχνοτική ανάλυση των δεδομένων. Παρακάτω φαίνεται το είδος και το πλήθος των χαρακτηριστικών που επιλέξαμε να εξάγουμε στην παρούσα υλοποίηση:

Είδος χαρακτηριστικών	Πλήθος
Χρονικά	3
Φασματικά	5
<i>MFCCs</i>	13
<i>Log-Mel filterbanks</i>	20

Πίνακας 3.2: Πλήθος εξαγμένων χαρακτηριστικών.

Το εργαλείο που αποτελεί τον ακρογωνιαίο λίθο για την εξαγωγή όλων αυτών των χαρακτηριστικών δεν είναι άλλο από το **Short Time Fourier Transform (STFT)**, του οποίου ο τρόπος λειτουργίας αναλύθηκε εκτενώς στην Υποενότητα 2.3.2. Συνεπώς, ο *STFT* θα λέγαμε ότι δεν λειτουργεί μόνον ως ένα εργαλείο απεικόνισης της πληροφορίας στο πεδίο χρόνου-συχνότητας, αλλά παράλληλα και εργαλείο για την εξαγωγή σημασιολογικά ισχυρών μεταβλητών που περιγράφουν το αναπνευστικό ηχητικό σήμα, επιτρέποντας τη μετατροπή του από κυματομορφή χαμηλής πληροφορίας σε δομημένα διανύσματα εισόδου για στατιστικά ή νευρωνικά μοντέλα μηχανικής και βαθιάς μάθησης (Babae et al. 2017; Dar et al. 2023; Dong et al. 2025; Pramono, Bowyer, et al. 2017; Garg et al. 2025; Mercaldo et al. 2023).

Για τον υπολογισμό του *STFT* καθώς και την μετέπειτα εξαγωγή των ακουστικών χαρακτηριστικών επιλέξαμε να σπάσουμε τους αναπνευστικούς κύκλους διάρκειας 3 s σε **frames των 60 ms με 50% επικάλυψη**, δηλαδή βήμα μετατόπισης (*hop size*) ίσο με 30 ms. Έ-

τσι, επιτυγχάνουμε επαρκή χρονική ανάλυση για τον εντοπισμό συμβάντων που εμφανίζονται σε σύντομες χρονικές φάσεις του αναπνευστικού κύκλου, χωρίς να θυσιάζεται η διακριτική ικανότητα στο πεδίο της συχνότητας. Ακόμη, η χρήση επικάλυψης 50% εξασφαλίζει ότι κάθε σημείο του σήματος συμμετέχει σε τουλάχιστον δύο καρτέ. Με βάση αυτά ο συνολικός αριθμός παραγόμενων καρτέ ανά αναπνευστικό κύκλο είναι περίπου:

$$\left\lfloor \frac{3s - 60ms}{30ms} \right\rfloor + 1 = 98 \text{ καρτέ}$$

Ωστόσο, στην πράξη ενδέχεται να παραχθούν περισσότερα καρτέ λόγω του τρόπου υλοποίησης της παραθύρωσης από τη χρησιμοποιούμενη βιβλιοθήκη. Συγκεκριμένα, η αυτόματη προσθήκη μηδενικών στην αρχή ή/και στο τέλος του σήματος, καθώς και η χρήση του ορίσματος `center=True` (π.χ. στη `librosa.stft()`), μπορεί να οδηγήσει σε επιπλέον καρτέ πέρα από τα αυστηρά χρονικά όρια. Γι' αυτό το λόγο παρατηρούμε πως και στη δική μας περίπτωση λαμβάνουμε εν τέλει 101 καρτέ αντί για 98 που υπολογίσαμε θεωρητικά.

3.3.1 Χρονικά χαρακτηριστικά

Τα **χρονικά χαρακτηριστικά** (*temporal features*) περιγράφουν κυρίως **πτυχές της χρονικής εξέλιξης του πλάτους ή της ενεργειακής κατανομής** του αναπνευστικού σήματος. Παρακάτω αναλύονται τα χρονικά χαρακτηριστικά που επιλέχθηκαν κατά την υλοποίηση της συγκεκριμένης εργασίας, καθώς και η φυσική τους σημασία:

Zero Crossing Rate Είναι ένα θεμελιώδες χρονικό χαρακτηριστικό που μετρά τον αριθμό των φορών που το πλάτος του σήματος αλλάζει πρόσημο εντός ενός χρονικού παραθύρου. Εκφράζει δηλαδή τη συχνότητα με την οποία το σήμα «διέρχεται» από το μηδέν. Η τιμή του σχετίζεται με την περιεκτικότητα του σήματος σε υψηλές συχνότητες και αποτελεί ένδειξη της «τραχύτητας» ή της ταχύτητας των ταλαντώσεών του.


Ο μαθηματικός ορισμός για διακριτό σήμα $x[n]$ μήκους N είναι:

$$ZCR = \frac{1}{2N} \sum_{n=1}^N |\text{sgn}(x[n]) - \text{sgn}(x[n-1])| \quad (3.9)$$

όπου η συνάρτηση πρόσημο ορίζεται ως:

$$\text{sgn}(x) = \begin{cases} 1, & x > 0 \\ -1, & x < 0 \\ 0, & x = 0 \end{cases}$$

Στην πράξη, τα σήματα που περιέχουν γρήγορες ταλαντώσεις και υψηλό φασματικό περιεχόμενο παρουσιάζουν υψηλότερο ZCR σε σχέση με πιο αργούς ήχους. Στη δικιά μας περίπτωση βλέπουμε ότι σαν χαρακτηριστικό προσφέρει σημαντική διαχωριστική πληροφορία τόσο ανάμεσα στους παθολογικούς ήχους όσο και ανάμεσα στους φυσιολογικούς και τους παθολογικούς:




Σχήμα 3.10: Μέση χρονική εξέλιξη του ZCR για κάθε κατηγορία ήχου.

Root Mean Square Energy Αποτελεί ένα μέτρο της στιγμιαίας ισχύος ή έντασης του σήματος εντός ενός καρέ. Υπολογίζεται ως η τετραγωνική ρίζα του μέσου τετραγώνου των τιμών του σήματος και αποτυπώνει τη συνολική ενέργεια που «περιέχει» το σήμα σε δεδομένο χρονικό διάστημα.

Μαθηματικά για διακριτό σήμα $x[n]$ μήκους N ορίζεται ως:


$$RMS = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2} \quad (3.10)$$

Το *RMS Energy* χρησιμοποιείται για την αναγνώριση περιόδων ενεργής αναπνευστικής δραστηριότητας και διαχωρίζει περιοχές υψηλής έντασης (π.χ. *wheezes*, *crackles*) από περιοχές ησυχίας ή χαμηλής έντασης.



Σχήμα 3.11: Μέση χρονική εξέλιξη του RMS Energy για κάθε κατηγορία ήχου.

Onset Envelope Περιγράφει την εξέλιξη της στιγμιαίας ενεργοποίησης στο σήμα και χρησιμοποιείται για την ανίχνευση χρονικών συμβάντων (*onsets*), δηλαδή απότομων αλλαγών στην ενέργεια ή τη δομή του σήματος, όπως η εμφάνιση παροδικού παθολογικού ήχου. Αν και δεν έχει έναν μοναδικό μαθηματικό ορισμό, στην πράξη προκύπτει από το φάσμα πλάτους ή ενέργειας κάθε καρέ, συχνά με χρήση φίλτρων ή παραγώγων για την ενίσχυση των μεταβολών.



Σχήμα 3.12: Μέση χρονική εξέλιξη του Onset Envelope για κάθε κατηγορία ήχου.


3.3.2 Φασματικά χαρακτηριστικά

Τα **φασματικά χαρακτηριστικά** (*spectral features*) περιγράφουν την κατανομή της ενέργειας ενός ηχητικού σήματος στο πεδίο της συχνότητας και προκύπτουν από τη φασματική ανάλυση του σήματος μέσω του μετασχηματισμού *STFT*. Σε αντίθεση με τα χρονικά χαρακτηριστικά, τα οποία αποτυπώνουν τις μεταβολές του πλάτους στο χρόνο, τα φασματικά χαρακτηριστικά εστιάζουν στη συχνοτική δομή του σήματος και χρησιμοποιούνται εκτενώς στην ανάλυση και ταξινόμηση αναπνευστικών ήχων. Παρακάτω παρουσιάζονται τα βασικότερα χαρακτηριστικά που εξήχθησαν στην παρούσα εργασία.

Spectral Centroid Εκφράζει το «κέντρο μάζας» του φάσματος ενός σήματος και σχετίζεται άμεσα με το αντιληπτό «ύψος» ή την «οξύτητα» του ήχου, δηλαδή το *pitch*. Ορίζεται ως ο σταθμισμένος μέσος όρος των συχνοτήτων f_k , όπου το βάρος είναι το μέτρο του φάσματος $|X_k|$:

$$SC = \frac{\sum_{k=0}^{N-1} f_k \cdot |X_k|}{\sum_{k=0}^{N-1} |X_k|} \quad (3.11)$$

Υψηλές τιμές *spectral centroid* υποδεικνύουν την παρουσία έντονης ενέργειας σε υψηλές συχνότητες, χαρακτηριστικό γνώρισμα των συριγμών, ενώ χαμηλές τιμές αντιστοιχούν σε πιο βαθύ ήχο, όπως στους φυσιολογικούς ήχους.




Σχήμα 3.13: Μέση χρονική εξέλιξη του Spectral Centroid για κάθε κατηγορία ήχου.

Spectral Bandwidth Ποσοτικοποιεί τη διασπορά του φάσματος γύρω από το κέντρο βάρους του. Υπολογίζεται μαθηματικά ως η σταθμισμένη τυπική απόκλιση των συχνοτήτων από το *spectral centroid*:

$$SBW = \sqrt{\frac{\sum_{k=0}^{N-1} |X_k| \cdot (f_k - SC)^2}{\sum_{k=0}^{N-1} |X_k|}} \quad (3.12)$$

Στην πράξη, μεγάλο εύρος υποδηλώνει σήμα με κατανομή ενέργειας σε ευρύ φάσμα, όπως τα *crackles*, ενώ στενό *bandwidth* παρατηρείται σε *wheezes* που εμφανίζουν συγκέντρωση φασματικής ενέργειας σε περιορισμένες συχνότητες.




Σχήμα 3.14: Χρονική εξέλιξη του Spectral Bandwidth για κάθε κατηγορία ήχου.

Spectral Flux Μετρά την ποσότητα μεταβολής του φάσματος από καρέ σε καρέ. Εκφράζει πόσο αλλάζει το φασματικό περιεχόμενο στο χρόνο και υπολογίζεται ως η Ευκλείδεια απόσταση μεταξύ φασμάτων διαδοχικών χρονικών καρέ:

$$SF = \sum_{k=0}^{N-1} (|X_k[n]| - |X_k[n-1]|)^2 \quad (3.13)$$

Η υψηλή τιμή *spectral flux* υποδεικνύει απότομες αλλαγές στο φάσμα, χαρακτηριστικό των *crackles*, ενώ η χαμηλή ροή παρατηρείται σε πιο σταθερά και συνεχόμενα σήματα, όπως τα *wheezes*.




Σχήμα 3.15: Μέση χρονική εξέλιξη του Spectral Flux για κάθε κατηγορία ήχου.

Spectral Flatness Είναι ένας δείκτης αρμονικότητας ή θορυβώδους φύσης του σήματος. Υπολογίζεται ως ο λόγος της γεωμετρικής προς την αριθμητική μέση τιμή του φάσματος:


$$SFt = \frac{\left(\prod_{k=0}^{N-1} |X_k|\right)^{1/N}}{\frac{1}{N} \sum_{k=0}^{N-1} |X_k|} \quad (3.14)$$

Η τιμή κυμαίνεται μεταξύ 0 και 1. Τείνει στο 1 για φάσματα τύπου λευκού θορύβου (*flat*) και στο 0 για φάσματα με αιχμές σε επιλεγμένες συχνότητες (αρμονικά ή μουσικά σήματα). Οι φυσιολογικοί ήχοι έχουν γενικά υψηλότερο *flatness*, ενώ τα *wheezes* λόγω της στενής φασματικής συγκέντρωσης εμφανίζουν χαμηλότερες τιμές.



Σχήμα 3.16: Μέση χρονική εξέλιξη του Spectral Flatness για κάθε κατηγορία ήχου.

Spectral Rolloff Ορίζει τη συχνότητα κάτω από την οποία βρίσκεται ένα προκαθορισμένο ποσοστό της συνολικής φασματικής ενέργειας, συνήθως 85% ή 95%. Η τιμή του *spectral rolloff* σχετίζεται επίσης με την ασυμμετρία της μορφής του φάσματος. Χρησιμοποιείται για τη διάκριση μεταξύ ήχων με φασματική συμπύκνωση και ήχων με εκτεταμένο φάσμα.



Σχήμα 3.17: Μέση χρονική εξέλιξη του Spectral Rolloff για κάθε κατηγορία ήχου.

3.3.3 MFCCs

Τα **Mel-Frequency Cepstral Coefficients (MFCCs)** αποτελούν μία από τις πιο διαδεδομένες και καθιερωμένες περιγραφές ηχητικών σημάτων, καθώς παρέχουν μία συμπαγή και θεμελιωμένη αναπαράσταση του φάσματος. Στο πεδίο της αναγνώρισης ήχου και ειδικότερα στη μελέτη αναπνευστικών σημάτων, τα *MFCCs* έχουν αποδειχθεί εξαιρετικά αποτελεσματικά στην καταγραφή της φασματικής υφής ενός σήματος, αποτυπώνοντας τις δομικές του ιδιαιτερότητες σε ένα σύνολο αριθμητικών χαρακτηριστικών σταθερής διάστασης.

Η κύρια θεωρητική αρχή των *MFCCs* είναι η προσαρμογή της φασματικής ανάλυσης στην ακουστική λειτουργία του ανθρώπινου αυτιού. Συγκεκριμένα, το ανθρώπινο ακουστικό σύστημα δεν αντιλαμβάνεται όλες τις συχνότητες με την ίδια ανάλυση, καθώς παρουσιάζει αυξημένη ευαισθησία σε χαμηλές συχνότητες και μειωμένη σε υψηλές. Για να ενσωματωθεί αυτή η ιδιότητα στην ανάλυση, εφαρμόζεται ένας μη γραμμικός μετασχηματισμός των συχνοτήτων από την γραμμική κλίμακα σε μια κλίμακα που καλύπτει την υποκειμενική αντίληψη του ακροατή,

γνωστή ως **κλίμακα Mel**.

Η σχέση μεταξύ γραμμικής συχνότητας f και συχνότητας Mel δίνεται προσεγγιστικά από τη σχέση:

$$M(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right) \quad (3.15)$$

Η παραπάνω σχέση προκύπτει από εμπειρικά δεδομένα ακουστικών πειραμάτων και διασφαλίζει ότι μικρές αυξήσεις στη συχνότητα σε χαμηλές περιοχές γίνονται αντιληπτές ως ισοδύναμες με μεγαλύτερες αυξήσεις σε υψηλές περιοχές. Για παράδειγμα, ένα διάστημα από 200–400 Hz θεωρείται ακουστικά «ισοδύναμο» με ένα διάστημα από 2000–3000 Hz.

Η διαδικασία υπολογισμού των *MFCCs* περιλαμβάνει όπως αναφέραμε τον υπολογισμό του φάσματος πλάτους μέσω *STFT*, το οποίο στη συνέχεια φιλτράρεται με ένα *bank* M φίλτρων (συνήθως $M = 26$) με τριγωνική απόκριση, κατανομημένα μη γραμμικά στη συχνότητα, σύμφωνα με την κλίμακα Mel. Έπειτα, γίνεται υπολογισμός του λογαρίθμου της ενέργειας κάθε φίλτρου:


$$E_m = \log \left(\sum_{k=0}^{N-1} |X(k)|^2 \cdot H_m(k) \right), \quad m = 1, 2, \dots, M \quad (3.16)$$

όπου $H_m(k)$ είναι η απόκριση του m -οστού Mel φίλτρου στη συχνότητα k . Η λογαριθμική κλίμακα εφαρμόζεται εδώ για δύο βασικούς λόγους: (α) για ενίσχυση των ασθενών συνιστωσών του φάσματος και (β) για να καταστήσει τις διαφορές πιο γραμμικά διακριτές, διευκολύνοντας τη μάθηση από τα νευρωνικά δίκτυα.

Τέλος, τα *MFCCs* εξάγονται με τη μορφή συμπυκνωμένων συντελεστών εφαρμόζοντας Διακριτό Μετασχηματισμό Συνημιτόνου (*Discrete Cosine Transformation, DCT*) στην M -διάστατη λογαριθμική φασματική αναπαράσταση:

$$c_n = \sum_{m=1}^M E_m \cdot \cos \left[\frac{\pi n}{M} \left(m - \frac{1}{2} \right) \right], \quad n = 0, 1, \dots, K-1 \quad (3.17)$$

όπου K είναι ο αριθμός των συντελεστών που διατηρούνται (συνήθως 12 ή 13).




Σχήμα 3.18: Διαδικασία εξαγωγής MFCCs.


Τα παραγόμενα *MFCCs* σχηματίζουν ένα συμπαγές και χαμηλής διάστασης φασματικό αποτύπωμα κάθε καρέ, το οποίο είναι σχετικά ανεπηρέαστο από γραμμικές παραμορφώσεις

στο φάσμα και φιλικό προς ταξινομητές. Οι πρώτοι συντελεστές φέρουν πληροφορία για τη γενική φασματική κλίση, ενώ οι επόμενοι περιέχουν όλο και πιο λεπτομερή υφή.

Στην παρούσα εργασία **χρησιμοποιήθηκαν τα πρώτα 13 MFCCs** ανά καρτέ, τα οποία σε συνδυασμό με τα υπόλοιπα φασματικά και χρονικά χαρακτηριστικά προσφέρουν υψηλής πληροφορίας αναπαράσταση των αναπνευστικών ήχων, διευκολύνοντας την ταξινόμησή τους σε φυσιολογικούς ή παθολογικούς. Κατά τη διαδικασία απεικόνιση των MFCCs, η κατακόρυφη διάσταση αντιστοιχεί στον δείκτη κάθε MFCC και η οριζόντια στις χρονικές στιγμές του κάθε κύκλου.



Σχήμα 3.19: Παραδείγματα MFCCs από ενδεικτικούς αναπνευστικούς κύκλους.




Σχήμα 3.20: Μέση χρονική εξέλιξη των MFCCs.

3.3.4 Ζώνες ενέργειας Log-Mel

Οι λογαριθμικές ζώνες *Mel* (*Log-Mel filterbank energies*) σε αντίθεση με τα MFCCs τα οποία συμπυκνώνουν την πληροφορία σε λίγους συντελεστές, διατηρούν πλήρως τη δομή των ζωνών συχνοτήτων, καθιστώντας τες ιδιαίτερα χρήσιμες σε μεθόδους βαθιάς μάθησης, καθώς προσφέρουν περισσότερη χωρική λεπτομέρεια. Με άλλα λόγια, οι λογαριθμικές ζώνες *Mel* είναι ένα χαρακτηριστικό που συνοψίζει την πληροφορία «πόση ενέργεια υπάρχει σε ένα συγκεκριμένο εύρος συχνοτήτων, τη δεδομένη χρονική στιγμή, μετρώντας την όπως την αντιλαμβάνεται το ανθρώπινο αυτί».

Προκύπτουν μέσω της ίδιας διαδικασίας εξαγωγής που περιγράψαμε και για τα *MFCCs* χωρίς ωστόσο την εφαρμογή του *DCT* σαν τελικό βήμα. Έτσι, το αποτέλεσμα θα είναι ένα πιο μεγάλο διάνυσμα M -διαστάσεων, συνήθως $M = 40$ ή 80 , το οποίο αποτυπώνει χαρακτηριστικά μοτίβα υψηλής ευκρίνειας, όπως στενές φασματικές αιχμές σε *wheezes* ή εκρηκτικές παροδικές ενέργειες σε *crackles*. Στη δικιά μας περίπτωση ωστόσο **χρησιμοποιήθηκαν τα πρώτα 20 Log-Mel filterbank energies** τόσο ως αυτόνομα χαρακτηριστικά όσο και ως βάση για την εξαγωγή των *MFCCs* που αναλύσαμε παραπάνω, προσφέροντας υψηλής πληροφορίας περιγραφή της φασματικής κατανομής των αναπνευστικών ήχων.




Σχήμα 3.21: Μέση χρονική εξέλιξη των Log-Mel filterbank energies.

Κάθε χαρακτηριστικό που εξάγεται θα αποθηκεύεται σε ένα διάνυσμα με διάσταση **(101,)** το οποίο θα αντιπροσωπεύει τη χρονική εξέλιξή του ως προς τα *frames*. Αφού εξαχθούν και τα 41 χαρακτηριστικά που θα αναλύσουμε παρακάτω, τότε θα ενωθούν όλα τα διανύσματα χαρακτηριστικών σε ένα ενιαίο μητρώο με διαστάσεις **(41, 101)**. Αυτή η διαδικασία που περιγράψαμε επαναλαμβάνεται για κάθε αναπνευστικό κύκλο ξεχωριστά.


3.4 Προσαρμογή πεδίου για μείωση της επίδρασης της ετερογένειας συσκευών εγγραφής

Το *Domain adaptation module* έχει ως στόχο δύο πράγματα: να αφαιρέσει μέσω *adversarial-based* τεχνικών βαθιάς μάθησης από τα δεδομένα τη μεροληψία της συσκευής κάνοντας τα περισσότερο επικαλυπτόμενα ως προς τις συσκευές και ταυτόχρονα να κάνει τα δεδομένα ακόμη πιο διαχωρίσιμα ως προς τις κλάσεις. Έτσι, παράγεται ένα νέο μητρώο χαρακτηριστικών το οποίο περιέχει τις μετασχηματισμένες ενδιάμεσες αναπαραστάσεις των αρχικών χαρακτηριστικών.



Σχήμα 3.22: Block diagram για το Domain Adaptation Module.

Γενικά, η **μηχανική μάθηση** (*machine learning, ML*) αποτελεί έναν υποτομέα της τεχνητής νοημοσύνης (*AI*), ο οποίος επικεντρώνεται στην ανάπτυξη αλγορίθμων και υπολογιστικών μοντέλων που δίνουν τη δυνατότητα στους υπολογιστές να μαθαίνουν από εμπειρικά δεδομένα και να βελτιώνουν σταδιακά την απόδοσή τους σε συγκεκριμένες εργασίες χωρίς να απαιτείται ρητός προγραμματισμός για κάθε δυνατή περίπτωση (Bishop 2006; Hastie et al. 2009). Ειδικότερα, ο όρος **machine learning** εισήχθη για πρώτη φορά από τον *Arthur Samuel* το 1959, ο οποίος τον περιέγραψε ως «την ικανότητα των υπολογιστών να μαθαίνουν χωρίς να έχουν προγραμματιστεί ρητά για αυτό». Από τις πρώιμες προσπάθειες στην αυτόματη αναγνώριση μοτίβων και την τεχνητή νοημοσύνη, η μηχανική μάθηση εξελίχθηκε σε έναν θεμελιώδη κλάδο της σύγχρονης επιστήμης δεδομένων, ειδικά με την ανάπτυξη του υπολογιστικού δυναμικού και τη διαθεσιμότητα μεγάλων συνόλων δεδομένων (*big data*). Η **βαθιά μάθηση** (*deep learning, DL*) από την άλλη αποτελεί έναν εξειδικευμένο υποτομέα της μηχανικής μάθησης με κύριο χαρακτηριστικό τη χρήση πολυεπίπεδων νευρωνικών δικτύων (*deep neural networks*), τα οποία έχουν τη δυνατότητα να μαθαίνουν αυτόνομα ιεραρχικές αναπαραστάσεις των δεδομένων από τις ακατέργαστες εισόδους. Η «βαθιά» δομή των δικτύων αντιπροσωπεύει τον μεγάλο αριθμό των στρωμάτων (*layers*) που μπορεί να κυμαίνεται από μερικές δεκάδες έως πολλά εκατοντάδες. Μέσω αυτής της προσέγγισης η βαθιά μάθηση επιτυγχάνει εξαιρετικά αποτελέσματα σε απαιτητικές εφαρμογές, όπως η επεξεργασία εικόνας, ήχου και γλώσσας, συχνά υπερέχοντας σε απόδοση έναντι των παραδοσιακών μεθόδων μηχανικής μάθησης.



Σχήμα 3.23: Σχέση ανάμεσα σε τεχνητή νοημοσύνη, μηχανική μάθηση και βαθιά μάθηση. (Shrivastava 2024)

Η **επιβλεπόμενη μηχανική μάθηση** (*supervised machine learning*) αποτελεί έναν από τους θεμελιώδεις τομείς της μηχανικής μάθησης. Σύμφωνα με τον *Bishop et al. 2006* πρόκειται για τη διαδικασία κατά την οποία ένα υπολογιστικό σύστημα μαθαίνει να προσεγγίζει μια συνάρτηση $f : \mathcal{X} \rightarrow \mathcal{Y}$, η οποία αντιστοιχίζει δεδομένα εισόδου $x \in \mathcal{X}$ σε επιθυμητές εξόδους ή ετικέτες $y \in \mathcal{Y}$, με βάση ένα σύνολο παραδειγμάτων εκπαίδευσης. Το σύνολο εκπαίδευσης αποτελείται από ζεύγη (x_i, y_i) , όπου x_i είναι ένα διάνυσμα χαρακτηριστικών και y_i η αντίστοιχη ετικέτα. Η **μη επιβλεπόμενη μηχανική μάθηση** (*unsupervised machine learning*) από την άλλη αφορά μεθόδους κατά τις οποίες το μοντέλο εκπαιδεύεται σε δεδομένα που **δεν συνοδεύονται από ετικέτες εξόδου**. Ο στόχος είναι να ανακαλυφθούν εσωτερικές δομές, συσχετίσεις ή πρότυπα μέσα στα δεδομένα χωρίς την εποπτεία κάποιου «δασκάλου».

Η εκπαίδευση πραγματοποιείται συνήθως μέσω της **ελαχιστοποίησης της εμπειρικής απώλειας** (*empirical risk minimization*), δηλαδή της ελαχιστοποίησης μιας συνάρτησης κόστους $L(y, f(x))$ που μετρά τη διαφορά μεταξύ της προβλεπόμενης και της πραγματικής ετικέτας. Μετά την εκπαίδευση η έξοδος του μοντέλου είναι ένα διάνυσμα από **logits**, δηλαδή μη κανονικοποιημένες τιμές που αντιστοιχούν στο βαθμό ενεργοποίησης κάθε κατηγορίας:

$$z = f(x) = [z_1, z_2, \dots, z_K] \in \mathbb{R}^K \quad (3.18)$$

όπου K είναι ο αριθμός των κατηγοριών και z_k η «βαθμολογία» της k -οστής κατηγορίας.

Οι **πιθανότητες κάθε κατηγορίας** προκύπτουν με την εφαρμογή της **softmax** συνάρτησης:


$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad \text{για κάθε } k = 1, \dots, K \quad (3.19)$$

Η κατηγορία με τη μέγιστη πιθανότητα επιλέγεται ως τελική πρόβλεψη του μοντέλου:

$$\hat{y} = \arg \max_k \hat{p}_k \quad (3.20)$$

Η χρήση των *logits* και της *softmax* επιτρέπει την ερμηνεία της εξόδου ως κανονικοποιημένων πιθανοτήτων για κάθε κατηγορία, κάτι που είναι ιδιαίτερα χρήσιμο για προβλήματα σε ιατρικές διαγνώσεις όπου η βεβαιότητα της πρόβλεψης έχει σημασία.

Στην παρούσα εργασία, τα νευρωνικά δίκτυα (*neural networks*) χρησιμοποιήθηκαν όχι με τη βασική τους λειτουργία ως ταξινομητές, αλλά ως μέθοδοι μη επιβλεπόμενης βαθιάς μηχανικής μάθησης για αναπαράσταση και συμπίεση των ακουστικών χαρακτηριστικών στο πλαίσιο της προσαρμογής πεδίου. Τα νευρωνικά δίκτυα γενικά αποτελούν ένα από τα σημαντικότερα υποδείγματα βαθιάς μηχανικής μάθησης, εμπνευσμένα από τη λειτουργία των βιολογικών νευρωνικών συστημάτων. Αποτελούνται από διαδοχικά επίπεδα υπολογιστικών μονάδων (νευρώνες), τα οποία επεξεργάζονται σήματα εισόδου και μεταδίδουν πληροφορία μέσω μη γραμμικών συναρτήσεων ενεργοποίησης. Η εκπαίδευση ενός νευρωνικού δικτύου περιλαμβάνει τα εξής βασικά βήματα:



Σχήμα 3.24: Εκπαίδευση νευρωνικών δικτύων. (Προσαρμογή από Zhang et al. 2023)

Εμπρόσθια διάδοση (*forward pass*) Τα δεδομένα εισόδου διέρχονται από όλα τα επίπεδα του δικτύου. Σε κάθε επίπεδο, οι νευρώνες εφαρμόζουν έναν γραμμικό μετασχηματισμό ακολουθούμενο από μια μη γραμμική συνάρτηση ενεργοποίησης, παράγοντας τις αντίστοιχες εξόδους.

Υπολογισμός σφάλματος Στην έξοδο, η πρόβλεψη $\hat{y}$ συγκρίνεται με την πραγματική ετικέτα y και υπολογίζεται η τιμή της συνάρτησης κόστους (*loss function*) $L(\theta)$, όπου θ το σύνολο των παραμέτρων (βάρη και μεροληψίες). Η ελαχιστοποίηση της συνάρτησης κόστους οδηγεί στην προσαρμογή των παραμέτρων του μοντέλου, ώστε να βελτιωθεί η ακρίβεια των προβλέψεών του. Μαθηματικά, αν έχουμε ένα σύνολο εκπαίδευσης $\{(x_i, y_i)\}_{i=1}^N$, η συνολική απώλεια δίνεται από:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{y}_i) \quad (3.21)$$

όπου $L(y_i, \hat{y}_i)$ είναι η ατομική απώλεια για το i -οστό παράδειγμα.

Παρακάτω παρουσιάζονται οι πιο διαδεδομένες από αυτές όσον αφορά τη ταξινόμηση: και εδώ

- **Δυαδική Διασταυρούμενη Εντροπία (*Binary Cross-Entropy*)**: χρησιμοποιείται για δυαδική ταξινόμηση με έξοδο από *sigmoid*. Υποθέτει ότι η πρόβλεψη $\hat{y}$ αντιστοιχεί σε πιθανότητα.

$$L(y, \hat{y}) = -[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y})] \quad (3.22)$$

- **Κατηγορική Διασταυρούμενη Εντροπία (*Categorical Cross-Entropy*)**: χρησιμοποιείται για προβλήματα πολυκατηγορικής ταξινόμησης με έξοδο *softmax*. Η y_k είναι 1 για τη σωστή κατηγορία και 0 για τις υπόλοιπες (*one-hot encoding*).

$$L(y, \hat{y}) = - \sum_{k=1}^K y_k \log(\hat{y}_k) \quad (3.23)$$

- **Αραιή Κατηγορική Διασταυρούμενη Εντροπία (*Sparse Categorical Cross-Entropy*)**: όμοια με την προηγούμενη, αλλά η ετικέτα y εκφράζεται ως ακέραιος αριθμός (π.χ. κατηγορία 0, 1, ..., $K-1$) αντί για *one-hot*. Είναι αριθμητικά πιο αποδοτική.
- **Μέσο Τετραγωνικό Σφάλμα (*Mean Squared Error, MSE*)**: χρησιμοποιείται κυρίως κατά την παλινδρόμηση και ορίζεται ως:

$$L(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2 \quad (3.24)$$

Οπισθοδιάδοση (*backpropagation*) Με χρήση του κανόνα αλυσίδας του διαφορικού λογισμού, υπολογίζονται οι παράγωγοι της συνάρτησης κόστους ως προς κάθε παράμετρο, δηλαδή το διάνυσμα κλίσης (*gradient*). Η διαδικασία αυτή μεταφέρει την πληροφορία σφάλματος προς τα πίσω, από την έξοδο προς τα πρώτα επίπεδα.

Ενημέρωση παραμέτρων Οι παράμετροι ενημερώνονται επαναληπτικά στην κατεύθυνση που μειώνει το σφάλμα μέσω κάποιου αλγορίθμου βελτιστοποίησης (*optimizer*). Η διαδικασία αυτή πραγματοποιείται πιο συγκεκριμένα μέσω επαναληπτικών ενημερώσεων των παραμέτρων με βάση την κατεύθυνση του αρνητικού βαθμωτού διανύσματος, δηλαδή με τη μέθοδο του ***Gradient Descent***. Η βασική ιδέα είναι ότι η παράγωγος (ή το διάνυσμα κλίσης) της συνάρτησης κόστους $L(\theta)$ ως προς τις παραμέτρους θ δείχνει την κατεύθυνση της μεγαλύτερης αύξησης της συνάρτησης. Συνεπώς, για να επιτευχθεί ελαχιστοποίηση, τα βάρη πρέπει να ενημερώνονται προς την αντίθετη κατεύθυνση του *gradient* με βάση τη παρακάτω σχέση:

$$\theta^{(t+1)} = \theta^{(t)} - \eta \cdot \nabla_{\theta} L(\theta) \quad (3.25)$$

όπου:

- η : ο ρυθμός μάθησης (*learning rate*), δηλαδή το μέγεθος του βήματος προς την κατεύθυνση της μείωσης του σφάλματος,
- $\nabla_{\theta} L(\theta)$: η κλίση ή αλλιώς *gradient* της συνάρτησης κόστους ως προς τις παραμέτρους.

Διάφορες παραλλαγές του αλγορίθμου έχουν αναπτυχθεί για να αντιμετωπιστούν προβλήματα όπως η αργή σύγκλιση, οι τοπικά ελάχιστες τιμές ή οι εξασθενημένες κλίσεις. Η πιο διαδεδομένη από αυτές, την οποία εφαρμόζουμε και εμείς, είναι ο αλγόριθμος *Adaptive Moment Estimation (Adam)*.

Ανάμεσα στις εξόδους κάθε κρυφού στρώματος νευρώνων τοποθετούνται τέλος και κατάλληλες **συναρτήσεις ενεργοποίησης** (*activation functions*), οι οποίες εισάγουν **μη γραμμικότητα** στο μοντέλο, επιτρέποντας στο δίκτυο να μάθει και να προσεγγίσει πολύπλοκες, μη γραμμικές σχέσεις μεταξύ εισόδων και εξόδων. Χωρίς αυτές ένα απλο νευρωνικό δίκτυο θα μπορούσε να εκφράσει μόνο γραμμικούς μετασχηματισμούς, ανεξαρτήτως βάθους.

Υπάρχουν διάφοροι τύποι ενεργοποιήσεων και η επιλογή τους εξαρτάται από τη φύση του προβλήματος και το σημείο του δικτύου στο οποίο χρησιμοποιούνται.

Συνάρτηση	Τύπος	Χρήση / Ιδιότητες
<i>Sigmoid</i>	$f(z) = \frac{1}{1+e^{-z}}$	Έξοδος στο $(0, 1)$. Χρησιμοποιείται σε δυαδική ταξινόμηση. Παρουσιάζει <i>vanishing gradients</i> σε βαθιά δίκτυα.
<i>tanh</i>	$f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Έξοδος στο $(-1, 1)$ με μηδενικό μέσο όρο, επιταχύνει τη σύγκλιση σε σχέση με τη <i>Sigmoid</i> . Υπόκειται επίσης σε <i>vanishing gradients</i> .
<i>ReLU</i>	$f(z) = \max(0, z)$	Δημοφιλέστερη για κρυφά επίπεδα λόγω απλότητας και αποδοτικότητας. Αποφεύγει <i>vanishing gradients</i> , αλλά μπορεί να δημιουργήσει <i>dead neurons</i> .
<i>Leaky ReLU</i>	$f(z) = \begin{cases} z, & z > 0 \\ \alpha z, & z \leq 0 \end{cases}, \alpha \ll 1$	Αντιμετωπίζει το πρόβλημα <i>dead neurons</i> με μικρή κλίση για αρνητικές τιμές. Συνήθως $\alpha = 0.01$.
<i>Softmax</i>	$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$	Χρησιμοποιείται στο επίπεδο εξόδου για πολυκατηγορική ταξινόμηση. Παράγει πιθανότητες που έχουν συνολικό άθροισμα 1.

Πίνακας 3.3: Συνοπτική παρουσίαση συναρτήσεων ενεργοποίησης.

Η διαδικασία αυτή επαναλαμβάνεται για πολλές εποχές εκπαίδευσης (*epochs*) ξεκινώντας από μια αρχική τυχαία τιμή των παραμέτρων μέχρι το δίκτυο να συγκλίνει σε μια κατάσταση όπου η συνάρτηση κόστους είναι ελάχιστη ή ικανοποιητικά μικρή. Κατά την εκπαίδευση, εφαρμόζονται τεχνικές κανονικοποίησης (*regularization*), ρύθμισης υπερπαραμέτρων και βελτιστοποίησης, ώστε να αποφευχθεί η υπερπροσαρμογή και να επιτευχθεί καλύτερη γενίκευση. Αξίζει να σημειωθεί ότι η επιλογή του ρυθμού μάθησης είναι καθοριστική. Αν το η είναι πολύ μικρό, η εκπαίδευση θα συγκλίνει μεν, αλλά πολύ αργά. Από την άλλη, αν το η είναι πολύ μεγάλο, υπάρχει κίνδυνος το μοντέλο να ταλαντώνεται και να εγκλωβίζεται γύρω από τοπικό ελάχιστο ή ακόμη και να αποκλίνει.


Για την υλοποίηση των βαθιών αρχιτεκτονικών στη δικιά μας περίπτωση έγινε χρήση δύο διαφορετικών παραλλαγών αρχιτεκτονικών, όπως τα **Πολυεπίπεδα Αντίληπτρα** (*Multi-Layer Perceptrons, MLP*) και οι **Αυτοκωδικοποιητές** (*Autoencoders, AE*).

3.4.1 Πολυεπίπεδο Αντίληπτρο

Το **Πολυεπίπεδο Αντίληπτρο** (*Multilayer Perceptron, MLP*) αποτελεί ένα από τα βασικά και πλέον θεμελιώδη μοντέλα τεχνητού νευρωνικού δικτύου και ανήκει στην ευρύτερη οικογένεια των **Τεχνητών Νευρωνικών Δικτύων** (*Artificial Neural Networks*) που αναφέραμε πιο πάνω. Πρόκειται για ένα πλήρως συνδεδεμένο ανατροφοδοτούμενο δίκτυο (*fully-connected feedforward network*) στο οποίο η πληροφορία ρέει μόνο από την είσοδο

προς την έξοδο χωρίς την ύπαρξη ανατροφοδότησης ή κυκλικών συνδέσεων. Κάθε νευρώνας συνδέεται με όλους τους νευρώνες του επόμενου επιπέδου, γεγονός που επιτρέπει στο *MLP* να μάθει πολύπλοκες μη γραμμικές συναρτήσεις από τα δεδομένα. Σύμφωνα με το **Θεώρημα Καθολικής Προσέγγισης** (*Universal Approximation Theorem*), ένα *MLP* με τουλάχιστον ένα κρυφό επίπεδο και επαρκή αριθμό νευρώνων μπορεί να προσεγγίσει οποιαδήποτε συνεχώς διαφορίσιμη συνάρτηση με αυθαίρετη ακρίβεια (Bishop 2006).

Η τυπική αρχιτεκτονική ενός *MLP* περιλαμβάνει τρία βασικά τμήματα:



Σχήμα 3.25: Αρχιτεκτονική ενός MLP.

Επίπεδο εισόδου (*Input layer*) Το πρώτο επίπεδο του δικτύου, το οποίο δέχεται τα δεδομένα εισόδου με τη μορφή διανυσμάτων χαρακτηριστικών $x = [x_1, x_2, \dots, x_n] \in \mathbb{R}^n$. Κάθε νευρώνας του επιπέδου αυτού αντιστοιχεί σε ένα χαρακτηριστικό του συνόλου δεδομένων και δεν εκτελεί κάποια επεξεργασία, αλλά απλώς μεταφέρει την πληροφορία στα επόμενα επίπεδα.

Κρυφά επίπεδα (*Hidden layers*) Σε αυτά πραγματοποιείται η ουσιαστική επεξεργασία και η εκμάθηση των αναπαραστάσεων. Κάθε νευρώνας του επιπέδου l υπολογίζει έναν γραμμικό συνδυασμό των εισόδων του και εφαρμόζει μια μη γραμμική **συνάρτηση ενεργοποίησης**:

$$a_j^{(l)} = f \left(\sum_{i=1}^{d_{l-1}} w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right) \quad (3.26)$$

όπου:

- $a_j^{(l)}$: η έξοδος του j -οστού νευρώνα του επιπέδου l ,
- $w_{ji}^{(l)}$: το βάρος μεταξύ του i -οστού νευρώνα του προηγούμενου επιπέδου και του j -οστού του τρέχοντος επιπέδου,
- $b_j^{(l)}$: η τιμή μεροληψίας (*bias*),
- $f(\cdot)$: η συνάρτηση ενεργοποίησης.

Επίπεδο εξόδου (Output layer) Παράγει την τελική έξοδο $\hat{y} = [y_1, y_2, \dots, y_m] \in \mathbb{R}^m$ του μοντέλου. Η μορφή του εξαρτάται από τον τύπο του προβλήματος. Για πολυκατηγορική ταξινόμηση περιλαμβάνει m νευρώνες (όπου m το πλήθος των κατηγοριών) με *softmax* ενεργοποίηση για παραγωγή πιθανοτήτων.


Το *MLP* εκπαιδεύεται με επιβλεπόμενη μάθηση και αποτελεί τη βάση για πιο σύνθετες αρχιτεκτονικές βαθιάς μάθησης οι οποίες θα αναλυθούν παρακάτω, προσφέροντας μια αξιόπιστη και εύκολα ερμηνεύσιμη λύση για προβλήματα όπου τα δεδομένα είναι δομημένα ως διανύσματα σταθερού μήκους.

3.4.2 Αυτοκωδικοποιητής

Ο **Αυτοκωδικοποιητής (Autoencoder)** είναι ένας τύπος τεχνητών νευρωνικών δικτύων που σχεδιάζονται με σκοπό την μη επιβλεπόμενη μάθηση αναπαράστασεων. Η βασική τους λειτουργία είναι η μάθηση μιας αποδοτικής συμπίεσμνης κωδικοποίησης (*encoding*) των δεδομένων εισόδου χωρίς την ανάγκη ετικετών. Η έννοια των *autoencoders* εισήχθη για πρώτη φορά από τους Rumelhart et al. (1986) και έκτοτε έχει χρησιμοποιηθεί ευρέως στην εξαγωγή χαρακτηριστικών, μείωση διαστατικότητας και ανίχνευση ανωμαλιών.

Η εκπαίδευση ενός *autoencoder* είναι πλήρως ανακατασκευαστική, μιας και το δίκτυο λαμβάνει ως είσοδο ένα παράδειγμα x , το συμπιέζει σε μια ενδιάμεση αναπαράσταση z , και στη συνέχεια προσπαθεί να ανακατασκευάσει την είσοδο παράγοντας μια έξοδο x' . Στόχος είναι η ελαχιστοποίηση μιας συνάρτησης σφάλματος ανακατασκευής ανάλογα με τον τύπο των δεδομένων.

Ένας τυπικός *autoencoder* αποτελείται από δύο κύριες συνιστώσες:



Σχήμα 3.26: Αρχιτεκτονική ενός Autoencoder. (Akkus et al. 2023)

$$x \xrightarrow{\text{Encoder}} z \xrightarrow{\text{Decoder}} x'$$

Κωδικοποιητής (Encoder) Χαρτογραφεί την είσοδο $x \in \mathbb{R}^n$ σε έναν συμπίεσμένο (latent) χώρο χαρακτηριστικών $z \in \mathbb{R}^m$ με $m < n$, υλοποιώντας έναν μη γραμμικό μετασχηματισμό $z = g_\theta(x)$, όπου θ οι παράμετροι του encoder. Σκοπός του είναι να απομονώσει τις πιο ουσιώδεις πληροφορίες από την αρχική είσοδο.

Αποκωδικοποιητής (Decoder) Χαρτογραφεί την αναπαράσταση z πίσω στον αρχικό χώρο των δεδομένων, παράγοντας $x' = f_\phi(z) \in \mathbb{R}^n$, όπου ϕ οι παράμετροι του αποκωδικοποιητή. Ο στόχος είναι η ανακατασκευή του x όσο το δυνατόν πιστότερα, ώστε $x' \approx x$.

Ο ρόλος του z είναι η αποτύπωση των πιο σημαντικών πληροφοριών του x σε συμπιεσμένη μορφή, εξαλείφοντας τον θόρυβο ή τις περιττές διαστάσεις. Η εκπαίδευση πραγματοποιείται με τη μέθοδο του *Gradient Descent* και τη χρήση του *backpropagation*, όπως και στα υπόλοιπα νευρωνικά δίκτυα.

Τα *autoencoders* εκπαιδεύονται με επιβλεπόμενο τρόπο ως προς το $x \rightarrow x'$, αλλά συνολικά συνιστούν μία μορφή μη επιβλεπόμενης μάθησης, καθώς δεν απαιτούν εξωτερικές ετικέτες (*labels*). Γενικά, βρίσκουν ευρεία εφαρμογή, ειδικά σε προβλήματα όπως η εξαγωγή ή το **φιλτράρισμα χαρακτηριστικών για επακόλουθη ταξινόμηση**, τα οποία συνδυάζονται εύκολα με πιο σύνθετα μοντέλα όπως τα *GANs* ή τα *domain-adversarial networks*. Υπάρχουν αρκετές παραλλαγές των κλασικών *autoencoders*, ωστόσο αυτή που θα μας απασχολήσει στη συγκεκριμένη εργασία είναι ο **Variational Autoencoder (VAE)**, ο οποίος αξιοποιείται για τη μη επιβλεπόμενη **συμπύκνωση των εξαγμένων χαρακτηριστικών** από υα αναπνευστικά σήματα, επιτρέποντας την αναπαράστασή τους σε διακριτικό χώρο χαρακτηριστικών προτού χρησιμοποιηθούν στα μοντέλα ταξινόμησης. Ο ρόλος του VAE είναι αντί να μαθαίνει μια σταθερή κωδικοποίηση z , να **μοντελοποιεί κατανομές πιθανότητας** $q(z|x)$ επιτρέποντας τη δειγματοληψία και δημιουργία νέων δεδομένων. Η δομή και η λειτουργία του ωστόσο θα αναληθούν περαιτέρω παρακάτω.


Η ραγδαία πρόοδος των υπολογιστικών δυνατοτήτων και η διαθεσιμότητα μεγάλων συνόλων δεδομένων οδήγησαν στη ραγδαία ανάπτυξη της περιοχής των **βαθιών νευρωνικών δικτύων** (*deep neural networks*), η οποία έχει μεταμορφώσει πλήθος εφαρμογών, από την επεξεργασία εικόνας και ήχου, μέχρι τη φυσική γλώσσα και τη βιοϊατρική ανάλυση. Παρακάτω παρουσιάζονται οι βασικές αρχιτεκτονικές βαθιών νευρωνικών δικτύων που υλοποιήθηκαν στη παρούσα εργασία:

3.4.3 Domain Adversarial Neural Network (DANN)

Η τεχνική του *Domain Adversarial Neural Network (DANN)* αποτελεί μία εποπτευόμενη προσέγγιση *supervised domain adaptation* σχεδιασμένη ώστε να μειώνει το πρόβλημα του *domain mismatch* μεταξύ *source* και *target domains*. Στη δικιά μας περίπτωση γίνεται διαχωρισμός και των τεσσάρων *domains* μεταξύ τους όχι απλώς αν προέρχονται από το *source* ή το *target*. Η βασική αρχή του DANN είναι η εκμάθηση μιας αναπαράστασης χαρακτηριστικών σε έναν κοινό υποχώρο που να είναι ταυτόχρονα **διακριτική ως προς την κλάση και αναλλοίωτη ως προς το τομέα**, η οποία επιτυγχάνεται μέσω της **ανταγωνιστικής εκπαίδευσης** (*adversarial training*). Επιπλέον, η μέθοδος δρα απευθείας στο διάνυμα χαρακτηριστικών εισόδου, διασφαλίζοντας ότι η απομάκρυνση του *domain shift* πραγματοποιείται σε επίπεδο αναπαράστασης και όχι απλώς σε επίπεδο τελικής απόφασης (Wang et al. 2019).

Ένα τυπικό DANN μπορεί στην ουσία να θεωρηθεί ως ένα *multitask neural network*. Η

βασική αρμοδιότητά του αφορά την ταξινόμηση των αναπνευστικών ήχων, ενώ η δευτερεύουσα είναι η πρόβλεψη του πεδίου προέλευσης. Πιο συγκεκριμένα, αποτελείται από τρεις βασικές υπομονάδες:



Σχήμα 3.27: Αρχιτεκτονική ενός DANN. (Wang et al. 2019)

Εξαγωγέας χαρακτηριστικών (Feature extractor) G_{θ_f} Μετασχηματίζει τα αρχικά ακουστικά χαρακτηριστικά $\{x_i\}_{i=1}^n$ σε έναν F -διάστατο διανυσματικό χώρο f .

Ταξινομητής ετικέτας (Label classifier) G_{θ_y} Χαρτογραφεί το f σε πιθανότητες κλάσεων $\hat{y}$ για το πρόβλημα ταξινόμησης των αναπνευστικών ήχων.

Ταξινομητής πεδίου (Domain classifier) G_{θ_d} Εκτιμά την πιθανότητα $\hat{d}$ σε ποιά από τις τέσσερις συσκευές (*domains*) ανήκει η κάθε εγγραφή.

Για κάθε δείγμα $\{x_i, y, d\}$, με y να είναι κωδικοποίηση *one-hot* της κλάσης και d να είναι κωδικοποίηση *one-hot* του *domain*, η εμπρόσθια διάδοση γράφεται ως:

$$f = G_{\theta_f}(\{x_i\}) \quad (3.27)$$

$$\hat{y} = G_{\theta_y}(f) \quad (3.28)$$

$$\hat{d} = G_{\theta_d}(f) \quad (3.29)$$

Ο στόχος της εκπαίδευσης είναι να **ελαχιστοποιήσει τη συνάρτηση κόστους ταξινόμησης αναπνευστικών ήχων L_y** και ταυτόχρονα να **μεγιστοποιήσει τη συνάρτηση κόστους ταξινόμησης πεδίου L_d** , ώστε ο εξαγωγέας χαρακτηριστικών να παράγει *domain-invariant* αναπαραστάσεις:

$$E(\theta_f, \theta_y, \theta_d) = L_y(G_{\theta_y}(G_{\theta_f}(x)), y) - \lambda L_d(G_{\theta_d}(G_{\theta_f}(x)), d) \quad (3.30)$$

όπου $\lambda > 0$ είναι υπερπαράμετρος που ρυθμίζει την ισορροπία μεταξύ ταξινόμησης ετικέτας και αναλλοιωσιμότητας τομέα. Η μεγιστοποίηση του L_d υλοποιείται μέσω της προσθήκης ενός **Στρώματος Αντίστροφης Κλίσης (Gradient Reversal Layer (GRL))**, το οποίο κατά την εμπρόσθια διάδοση λειτουργεί ως ταυτοτική συνάρτηση, δηλαδή απλώς διαδίδει αυτούσια την είσοδο, αλλά κατά την οπισθοδιάδοση πολλαπλασιάζει το διάνυσμα κλίσης με $-\alpha$.

Έτσι, ο εξαγωγέας χαρακτηριστικών μαθαίνει αναπαραστάσεις που αποπροσανατολίζουν τον ταξινομητή τομέα, οδηγώντας σε εξαγωγή **domain invariant** χαρακτηριστικών.

Μετά την εκπαίδευση, το $G_{\theta_f}(\cdot)$ παράγει χαρακτηριστικά $\mathbf{f}$ που μεγιστοποιούν την ακρίβεια ταξινόμησης αναπνευστικών ήχων, ενώ ελαχιστοποιούν την πληροφορία για το τομέα καταγραφής, βελτιώνοντας έτσι την απόδοση σε συνθήκες *mismatched devices*.

Για το συμβατικό DANN οι επιλεγμένες αρχιτεκτονικές κάθε *module* στηρίζονται στη βασική αρχιτεκτονική ενός MLP με κάποιες επιπλέον προσθήκες, ενώ παράλληλα η εισαγωγή των δεδομένων στο δίκτυο γίνεται κάθε φορά σε παρτίδες (*batches*) μεγέθους 64.

Η αρχιτεκτονική για τον *Feature Extractor* περιλαμβάνει τρεις γραμμικούς μετασχηματισμούς διαστάσεων, δηλαδή **3 Fully Connected Layers**, τα οποία πλαισιώνονται από **Batch Normalization Layers** μαζί με μη γραμμική συνάρτηση ενεργοποίησης **ReLU**, καθώς και **Dropout Layers**. Η προοδευτική αλλαγή διαστάσεων ($\mathbb{R}^n \rightarrow \mathbb{R}^{64} \rightarrow \mathbb{R}^{128} \rightarrow \mathbb{R}^{256}$) μαζί με τη συγκεκριμένη αρχιτεκτονική επιτρέπει στο δίκτυο να μάθει πολύπλοκες μη γραμμικές σχέσεις, ενώ η χρήση κανονικοποίησης στα ενδιάμεσα στάδια επιταχύνει τη σύγκλιση. Πιο συγκεκριμένα, τα στρώματα *Batch Normalization* εκτελούν κανονικοποίηση των ενεργοποιήσεων κάθε ενδιάμεσου στρώματος σε επίπεδο *mini-batch*, ώστε να εξισορροπείται η κατανομή των δεδομένων εισόδου κάθε επιπέδου. Η πρακτική αυτή μειώνει το φαινόμενο του *internal covariate shift*, σταθεροποιεί τη ροή των κλίσεων και επιτρέπει τη χρήση μεγαλύτερου ρυθμού μάθησης, με αποτέλεσμα ταχύτερη και πιο αξιόπιστη εκπαίδευση. Επιπλέον, λειτουργεί και ως ήπια μορφή κανονικοποίησης, συμβάλλοντας έμμεσα στη βελτίωση της γενικευσιμότητας του δικτύου. Αντίστοιχα, τα στρώματα *Dropout* εφαρμόζουν τυχαία αποκοπή νευρώνων κατά την εκπαίδευση, με ποσοστό 30 % στο συγκεκριμένο δίκτυο. Η τεχνική αυτή αποτρέπει την υπερβολική συσχέτιση μεταξύ νευρώνων, μειώνοντας έτσι το φαινόμενο της υπερπροσαρμογής. Με την τυχαία ενεργοποίηση υποσυνόλων του δικτύου σε κάθε επανάληψη, ουσιαστικά εκπαιδεύονται πολλαπλά υπομοντέλα ταυτόχρονα, γεγονός που οδηγεί σε πιο ανθεκτικά και γενικεύσιμα χαρακτηριστικά.

Layers	Output Shape	Param #
Linear	[64, 64]	2,688
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Dropout	[64, 64]	0
Linear	[64, 128]	8,320
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 256]	33,024
BatchNorm1d	[64, 256]	512
ReLU	[64, 256]	0

Πίνακας 3.4: Αρχιτεκτονική του Feature Extractor στο DANN.

Για τα *Label Classifier* και *Domain Classifier* χρησιμοποιείται το ίδιο σκεπτικό αλλά με 1 λιγότερο *Fully Connected Layer*, καθώς ο *Feature Extractor* επεξεργάζεται τα αρχικά χαρακτηριστικά και μαθαίνει έναν λανθάνοντα χώρο αναπαράστασης $\phi(x)$ που πρέπει να είναι ταυτόχρονα διακριτικός για την ταξινόμηση ($p(y|f)$) και ανθεκτικός σε πληροφορία τομέα ($p(d|f)$). Για τον σκοπό αυτό απαιτεί μεγαλύτερο βάθος και περισσότερες παραμέτρους, ώστε να απομονώσει και να επανασυνδυάσει τα κατάλληλα μοτίβα των χαρακτηριστικών. Αντίθετα, οι *classifiers* λαμβάνουν τις ενδιαμέσες αναπαραστάσεις διάστασης 256 και καλούνται να επιλύσουν απλούστερα προβλήματα με μικρό αριθμό εξόδων (π.χ. 3 κλάσεις για ετικέτες, 4 για πεδία), όπου επαρκούν ελαφρύτερα δίκτυα για την αποφυγή υπερπροσαρμογής. Στο *Label Classifier* το τελικό στρώμα έχει μέγεθος εξόδου ίσο με τον αριθμό κλάσεων, δηλαδή `num_classes = 3`, ενώ στο *Domain Classifier* ίσο με τον αριθμό των πεδίων, δηλαδή `num_domains = 4`.

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 3]	195

Πίνακας 3.5: Αρχιτεκτονική του Label Classifier στο DANN.

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 64]	8,256
BatchNorm1d	[64, 64]	128
ReLU	[64, 64]	0
Linear	[64, 4]	260

Πίνακας 3.6: Αρχιτεκτονική του Domain Classifier στο DANN.

3.4.4 Conditional Domain Adversarial Network (CDAN)

Παρά την αποτελεσματικότητα του *DANN* στην εκμάθηση *domain-invariant* χαρακτηριστικών, η μεθοδολογία αυτή βασίζεται στην υπόθεση ότι η απλή ευθυγράμμιση των *a priori* κατανομών των χαρακτηριστικών $P(\mathbf{f})$ μεταξύ *source* και *target* επαρκεί για την αντιμετώπιση

του *domain shift*. Ωστόσο, σε πολλές πραγματικές εφαρμογές, οι κατανομές χαρακτηριστικών εμφανίζουν πολύπλοκες δομές, καθώς τα δείγματα οργανώνονται σε πολλούς υποχώρους που αντιστοιχούν σε διαφορετικές κλάσεις. Σε τέτοια σενάρια, η απλή ευθυγράμμιση των $P(\mathbf{f})$ μπορεί να προκαλέσει *mode mismatch*, δηλαδή να ευθυγραμμίσει λάθος υποχώρους διαφορετικών κλάσεων, υποβαθμίζοντας την ακρίβεια ταξινόμησης.


Το *Conditional Domain Adversarial Network (CDAN)* (Long et al. 2018) επεκτείνει το συμβατικό *DANN* ενσωματώνοντας πληροφορία κλάσης κατά την εκπαίδευση του *Domain classifier*. Συγκεκριμένα, αντί ο *Domain classifier* G_{θ_d} να δέχεται ως είσοδο μόνο το διάνυσμα χαρακτηριστικών $\mathbf{f}$, δέχεται έναν **συνδυασμό** των χαρακτηριστικών και του διάνυσματος προβλεπόμενων πιθανοτήτων κλάσης $\hat{\mathbf{y}} = G_{\theta_y}(\mathbf{f})$. Ο συνδυασμός αυτός κωδικοποιεί την **από κοινού κατανομή** $(\mathbf{f}, \hat{\mathbf{y}})$.

Με αυτόν τον τρόπο, η διαδικασία ευθυγράμμισης δεν επιχειρεί πλέον να φέρει κοντά μόνο τις *a priori* κατανομές $P(\mathbf{f})$ των τομέων, αλλά και τις **υπό συνθήκη κατανομές** $P(\mathbf{f} | \mathbf{y})$. Έτσι, οι υποχώροι χαρακτηριστικών που αντιστοιχούν στην ίδια κλάση ευθυγραμμίζονται μεταξύ *source* και *target*, ενώ αποφεύγεται η ανάμειξη υποχώρων διαφορετικών κλάσεων. Αυτή η στοχευμένη ευθυγράμμιση (*class-conditional alignment*) οδηγεί σε πιο διακριτές και σταθερές αναπαραστάσεις, ιδιαίτερα σε εφαρμογές με έντονο *domain shift* και πολλαπλές κλάσεις.

Η απλούστερη προσέγγιση για την κωδικοποίηση της από κοινού κατανομής θα ήταν η απλή συνένωση (*concatenation*) $[\mathbf{f} \oplus \hat{\mathbf{y}}]$, όμως αυτή αποτυγχάνει να συλλάβει πολλαπλασιαστικές αλληλεπιδράσεις μεταξύ των δύο μεταβλητών. Για τον λόγο αυτό, το *CDAN* εισάγει την τεχνική του *multilinear conditioning*:

$$T_{\otimes}(\mathbf{f}, \hat{\mathbf{y}}) = \mathbf{f} \otimes \hat{\mathbf{y}} \quad (3.31)$$

όπου ο τελεστής $\otimes$ δηλώνει το εξωτερικό γινόμενο, παράγοντας έναν χώρο διάστασης $d_f \times d_{\hat{y}}$ που κωδικοποιεί την **συσχέτιση** (*cross-covariance*) μεταξύ χαρακτηριστικών και προβλέψεων κλάσεων. Έτσι, το G_{θ_d} μπορεί να συλλάβει την πολυτροπική δομή της κατανομής, εξασφαλίζοντας διακριτική ευθυγράμμιση.



Σχήμα 3.28: Αρχιτεκτονική ενός CDAN. (Long et al. 2018)

Για το *CDAN* οι αρχιτεκτονικές των *Feature Extractor* και *Label Classifier* αυτή την φορά έχουν απλουστευθεί σε σχέση με πριν, καθώς ο *Domain Classifier* δεν λαμβάνει πλέον ως είσοδο μόνο το διάνυσμα χαρακτηριστικών $\mathbf{f}$, αλλά το γινόμενο τανυστών $\mathbf{f} \otimes \hat{\mathbf{y}}$, το οποίο είναι ήδη με πλουσιότερη πληροφορία, μειώνοντας την ανάγκη για βαθύτερα δίκτυα με πολλαπλά επίπεδα εξαγωγής μη γραμμικών συσχετίσεων.

Layers	Output Shape	Param #
Linear	[64, 128]	5,376
BatchNorm1d	[64, 128]	256
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 256]	33,024
BatchNorm1d	[64, 256]	512
ReLU	[64, 256]	0

Πίνακας 3.7: Αρχιτεκτονική του Feature Extractor στο CDAN.

Layers	Output Shape	Param #
Linear	[64, 128]	32,896
ReLU	[64, 128]	0
Dropout	[64, 128]	0
Linear	[64, 3]	387

Πίνακας 3.8: Αρχιτεκτονική του Label Classifier στο CDAN.

3.4.5 Domain Adversarial Neural Network (DANN) με Variational Autoencoder (VAE)

Η συγκεκριμένη προσέγγιση βασίζεται στην υλοποίηση του κλασικού *DANN* που αναλύσαμε μεταβάλλοντας ωστόσο τη δομή του *Feature extractor* από *MLP* σε *Variational Autoencoder (VAE)*. Η ενσωμάτωση ενός *VAE* στο πλαίσιο του *DANN* στοχεύει στην εκμάθηση μιας λανθάνουσας αναπαράστασης χαρακτηριστικών $\mathbf{z}$ που να είναι **πληροφοριακή για την κλάση** και ταυτόχρονα **αναλλοίωτη ως προς τον τομέα** (Zonoozi et al. 2025).

Στο *Variational Autoencoder (VAE)*, ο **Encoder** $q_\phi(\mathbf{z}|\mathbf{x})$ είναι ένα νευρωνικό δίκτυο το οποίο λαμβάνει ως είσοδο το διάνυσμα χαρακτηριστικών $\mathbf{x} \in \mathbb{R}^n$ και το μετασχηματίζει σε μια **πιθανοτική περιγραφή** μιας λανθάνουσας μεταβλητής $\mathbf{z} \in \mathbb{R}^m$. Σε αντίθεση με τον κλασικό *Autoencoder* που περιγράψαμε στο Κεφάλαιο 4 ο οποίος επιστρέφει μόνο ένα σημείο στον λανθάνοντα χώρο, ο *VAE* μαθαίνει δύο διανύσματα εξόδου:

$$\boldsymbol{\mu}_\phi(\mathbf{x}) \in \mathbb{R}^m \quad \text{και} \quad \boldsymbol{\sigma}_\phi(\mathbf{x}) \in \mathbb{R}^m \quad (3.32)$$

τα οποία αντιστοιχούν στο μέσο (*mean*) και στην τυπική απόκλιση (*standard deviation*) μιας

πολυδιάστατης κανονικής κατανομής. Η κατανομή αυτή περιγράφει τις πιθανές τιμές που μπορεί να λάβει η λανθάνουσα μεταβλητή $\mathbf{z}$ για το δοθέν $\mathbf{x}$:

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_\phi(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_\phi^2(\mathbf{x}))) \quad (3.33)$$


Έτσι, η κωδικοποίηση δεν είναι πλέον ντετερμινιστική, αλλά πιθανοτική. επιτρέποντας στο μοντέλο να συλλάβει την αβεβαιότητα και την ποικιλία των δυνατών αναπαραστάσεων.

Για να μπορέσουμε να δειγματοληψήσουμε ένα συγκεκριμένο διάνυσμα $\mathbf{z}$ από την παραπάνω κατανομή κατά τη διάρκεια της εκπαίδευσης, χρησιμοποιούμε την **τεχνική επαναπαραμετροποίησης (reparameterization trick)**. Η ιδέα είναι να εκφράσουμε τη στοχαστική δειγματοληψία ως έναν ντετερμινιστικό υπολογισμό που περιέχει έναν εξωτερικό τυχαίο παράγοντα:

$$\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\sigma}_\phi(\mathbf{x}) \odot \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (3.34)$$

Με αυτόν τον τρόπο, η τυχαιότητα περιορίζεται στην ανεξάρτητη μεταβλητή $\boldsymbol{\varepsilon}$, η οποία δεν εξαρτάται από τις παραμέτρους ϕ , επιτρέποντας η ροή του υπολογισμού να παραμείνει διαφορίσιμη. Κατά συνέπεια, το δίκτυο μπορεί να εκπαιδευτεί κανονικά μέσω οπισθοδιάδοσης, παρά το γεγονός ότι περιλαμβάνει διαδικασία δειγματοληψίας.

Ο **Decoder** $p_\theta(\mathbf{x}|\mathbf{z})$ στη συνέχεια ανακατασκευάζει την είσοδο $\hat{\mathbf{x}}$ από τη $\mathbf{z}$, η οποία θα τροφοδοτηθεί στα υπόλοιπα δύο *modules*.



Σχήμα 3.29: Αρχιτεκτονική ενός VAE. (Puchalski et al. 2023)

Η εκπαίδευση του VAE βασίζεται στη μεγιστοποίηση της **κατώτερης προσέγγισης** (*Evidence Lower Bound* της λογαριθμικής πιθανοφάνειας $\log p_\theta(\mathbf{x})$). Η *ELBO* μπορεί να γραφεί ως:

$$\mathcal{L}_{\text{VAE}}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x}|\mathbf{z})] - D_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z})) \quad (3.35)$$

Ο όρος

$$L_{\text{rec}} = -\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x}|\mathbf{z})]$$

είναι το **σφάλμα ανακατασκευής** (*reconstruction loss*) που μετρά πόσο καλά ο *Decoder* μπορεί να αναπαράγει την είσοδο $\mathbf{x}$ από τη λανθάνουσα αναπαράσταση $\mathbf{z}$.

Επίσης, ο όρος

$$L_{\text{KL}} = D_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}))$$

είναι η **Kullback–Leibler divergence**, η οποία μετρά την πληροφοριακή απόσταση μεταξύ της εκτιμώμενης κατανομής λανθάνουσας μεταβλητής $q_{\phi}(\mathbf{z}|\mathbf{x})$ και της εκ των προτέρων (*prior*) κατανομής $p(\mathbf{z})$ που στον *VAE* θεωρείται τυπικά ισοτροπική κανονική κατανομή $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$. Αυτός ο όρος δρα ως κανονικοποιητής, αναγκάζοντας τον λανθάνοντα χώρο να παραμένει συνεχής και οργανωμένος. Συνολικά, η συνάρτηση κόστους που ελαχιστοποιείται κατά την εκπαίδευση είναι:

$$L_{\text{total}}(\theta, \phi) = L_{\text{rec}} + \beta L_{\text{KL}}$$

όπου β είναι ένας υπερπαραμέτρος (β -*VAE*) που επιτρέπει τον έλεγχο της σχετικής βαρύτητας μεταξύ πιστότητας ανακατασκευής και κανονικοποίησης της λανθάνουσας κατανομής.

Οι επιλεγμένες αρχιτεκτονικές κάθε *module* για το *DANN* μαζί με *VAE* φαίνονται παρακάτω. Στο *module Encoder* ορίζεται ένα νευρωνικό δίκτυο με δύο διαδοχικά γραμμικά επίπεδα και συναρτήσεις ενεργοποίησης *ReLU*, καθώς και δύο γραμμικές εξόδους για τον υπολογισμό της μέσης τιμής (μ) και του λογαρίθμου της διασποράς ($\log\text{var}$) της λανθάνουσας κατανομής. Οι αρχιτεκτονικές των *modules Label Classifier* και *Domain Classifier* παραμένουν οι ίδιες και επομένως δεν παρουσιάζονται ξανά.

Layers	Output Shape	Param #
Linear	[64, 512]	21,504
ReLU	[64, 512]	0
Linear	[64, 256]	131,328
ReLU	[64, 256]	0
Linear (μ)	[64, 16]	4,112
Linear (σ)	[64, 16]	4,112

Πίνακας 3.9: Αρχιτεκτονική του Encoder στο VAE.

Layers	Output Shape	Param #
Linear	[64, 256]	4,352
ReLU	[64, 256]	0
Linear	[64, 41]	10,537

Πίνακας 3.10: Αρχιτεκτονική του Decoder στο VAE.

Όσον αφορά την διαδικασία εκπαίδευσης η ενσωμάτωση του *VAE* μπορεί να πραγματοποιηθεί με δύο διαφορετικές προσεγγίσεις:

(α) **Ταυτόχρονη εκπαίδευση (*Joint training*)** Στην πρώτη προσέγγιση, ο *Encoder* και ο *Decoder* του *VAE*, ο *Label Classifier* και ο *Domain Classifier* εκπαιδεύονται **ταυτόχρονα** σε ένα ενιαίο βήμα βελτιστοποίησης. Η συνολική συνάρτηση κόστους προκύπτει ως συνδυασμός των τριών όρων:

$$L_{\text{total}} = L_{\text{rec}} + \beta L_{\text{KL}} + L_y - \lambda L_d,$$

όπου L_{rec} και L_{KL} προέρχονται από το *VAE*, L_y είναι η απώλεια ταξινόμησης κλάσης και L_d η απώλεια ταξινόμησης τομέα. Σε αυτή τη ρύθμιση, η λανθάνουσα αναπαράσταση $\mathbf{z}$ διαμορφώνεται από κοινού ώστε να ικανοποιεί τόσο τον στόχο ανακατασκευής και κανονικοποίησης (όροι *VAE*), όσο και την απαίτηση για domain-invariance (όροι *DANN*). Το πλεονέκτημα αυτής της μεθόδου είναι ότι το δίκτυο προσαρμόζει συγχρονισμένα τη λανθάνουσα αναπαράσταση στις ανάγκες και των δύο υποστόχων.

(β) **Διαδοχική εκπαίδευση (*Sequential training*)** (Zonoozi et al. 2024) Στη δεύτερη προσέγγιση, ο *VAE* εκπαιδεύεται **αυτόνομα** στο πρώτο στάδιο, χρησιμοποιώντας μόνο το $L_{\text{rec}} + \beta L_{\text{KL}}$ ώστε να μάθει έναν σταθερό, κανονικοποιημένο λανθάνοντα χώρο. Μετά την ολοκλήρωση της εκπαίδευσης του *VAE*, ο *Encoder* παγώνει (*frozen encoder*) και η λανθάνουσα αναπαράσταση $\mathbf{z}$ χρησιμοποιείται ως είσοδος σε ένα κλασικό *DANN*, το οποίο εκπαιδεύεται με βάση την απώλεια:


$$L_{\text{DANN}} = L_y - \lambda L_d.$$

Η προσέγγιση αυτή διαχωρίζει πλήρως τη μάθηση της αναπαράστασης από την *domain-adversarial* προσαρμογή, διευκολύνοντας τη σταθερότητα της εκπαίδευσης και αποφεύγοντας πιθανές αλληλεπιδράσεις μεταξύ των όρων κόστους.

3.5 Ταξινόμηση παθολογικών ήχων

Το ***Classification module*** στο τέλος έχει ως στόχο την δημιουργία των προβλέψεων για τις κλάσεις χρησιμοποιώντας τους κλασικούς αλγορίθμους ταξινόμησης με είσοδο τις ενσωματώσεις με τα δεδομένα, δηλαδή το νέο μητρώο χαρακτηριστικών που εξήχθη από το Domain adaptation module. Τα μοντέλα για την ακρίβεια ρυθμίζονται με τους κατάλληλους συνδυασμούς υπερπαραμέτρων, στη συνέχεια εκπαιδεύονται πάνω στα κλιμακωμένα δεδομένα και τέλος παράγουν τα διανύσματα με τα logits από όπου προκύπτει η τελική πρόβλεψη παθολογικού ήχου.

Στη συγκεκριμένη εργασία αξιοποιήθηκαν για τη ταξινόμηση ορισμένοι κλασικοί αλγόριθμοι ταξινόμησης επιβλεπόμενης μηχανικής μάθησης.



Σχήμα 3.30: Block diagram για το Classification Module.


3.5.1 k-Πλησιέστεροι Γείτονες

Ο αλγόριθμος των **k-Πλησιέστερων Γειτόνων** (*k-Nearest Neighbors*, *k-NN* είναι μια απλή αλλά ιδιαίτερα ισχυρή μη παραμετρική μέθοδος ταξινόμησης η οποία βασίζεται στην υπόθεση ότι τα δείγματα που βρίσκονται κοντά μεταξύ τους στον χώρο χαρακτηριστικών πιθανότατα ανήκουν και στην ίδια κατηγορία (Hastie et al. 2009). Σαν αλγόριθμος είναι εύκολος στην κατανόηση και στην υλοποίηση, καθώς δεν απαιτεί εκπαίδευση, γεγονός που τον καθιστά αρκετά ευέλικτο. Ωστόσο, χρειάζεται προσεκτικό χειρισμό, καθώς δείχνει ευαισθησία σε θορυβώδη και σε μη ισορροπημένα δεδομένα, ενώ παράλληλα επηρεάζεται σημαντικά από τη διάσταση του χώρου χαρακτηριστικών.

Η βασική ιδέα υλοποίησής του είναι η εξής: για την ταξινόμηση ενός άγνωστου δείγματος x , εντοπίζονται οι k πιο κοντινοί γείτονες από το σύνολο εκπαίδευσης, βάσει μιας επιλεγμένης μετρικής απόστασης. Η επιλογή της μετρικής απόστασης επηρεάζει σημαντικά την απόδοση του *k-NN* με τις συνηθέστερες επιλογές να είναι:

- **Ευκλείδεια απόσταση** (ℓ_2 -norm): $d(x_i, x_j) = \sqrt{\sum_{l=1}^d (x_i^{(l)} - x_j^{(l)})^2}$
- **Απόσταση Manhattan** (ℓ_1 -norm): $d(x_i, x_j) = \sum_{l=1}^d |x_i^{(l)} - x_j^{(l)}|$
- **Απόσταση Minkowski, Cosine, Mahalanobis** κ.ά.

Τέλος, η ετικέτα του x προβλέπεται ως η πιο συχνή κατηγορία (πλειοψηφία) ανάμεσα στους γείτονες αυτούς.



Σχήμα 3.31: Ταξινομητής k-NN (Sachinsoni 2023).

Μαθηματικά, ο συγκεκριμένος αλγόριθμος ορίζεται ως εξής: Έστω $x \in \mathbb{R}^d$ το δείγμα προς ταξινόμηση και το σύνολο εκπαίδευσης $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$. Ορίζουμε:

$\mathcal{N}_k(x)$ = το σύνολο των k πλησιέστερων γειτόνων του x ως προς κάποια μετρική d

Η προβλεπόμενη ετικέτα $\hat{y}$ δίνεται από:

$$\hat{y} = \arg \max_{c \in \mathcal{Y}} \sum_{(x_i, y_i) \in \mathcal{N}_k(x)} \mathbb{I}(y_i = c) \quad (3.36)$$

όπου $\mathbb{I}$ είναι η ενδεικτική συνάρτηση και $\mathcal{Y}$ το σύνολο των κατηγοριών.


3.5.2 Μηχανές Υποστήριξης Διανυσμάτων

Οι Μηχανές Υποστήριξης Διανυσμάτων (*Support Vector Machines, SVMs*) αποτελούν έναν από τους ισχυρότερους και θεωρητικά πιο καλοθεμελιωμένους αλγόριθμους επιβλεπόμενης μάθησης για προβλήματα ταξινόμησης και παλινδρόμησης. Η θεμελιώδης ιδέα του *SVM* είναι να εντοπίσει ένα **υπερεπίπεδο** (*hyperplane*) στον χώρο χαρακτηριστικών, το οποίο να διαχωρίζει γραμμικά τις κλάσεις των δεδομένων με το **μέγιστο δυνατό περιθώριο** (*maximum margin*), δηλαδή με τη μεγαλύτερη δυνατή απόσταση από τα πλησιέστερα σημεία εκπαίδευσης κάθε κατηγορίας (Vapnik 2010).

Έστω ότι έχουμε ένα σύνολο δειγμάτων $x_i \in \mathbb{R}^d$ με αντίστοιχες ετικέτες $y_i \in \{-1, +1\}$. Το ζητούμενο είναι να προσδιοριστεί ένας γραμμικός διαχωριστής της μορφής:

$$f(x) = \mathbf{w}^\top x + b = 0 \quad (3.37)$$

ο οποίος διαχωρίζει σωστά όλα τα δείγματα και μεγιστοποιεί την απόσταση μεταξύ του υπερεπιπέδου και των πλησιέστερων σημείων κάθε κατηγορίας (γνωστά ως *support vectors*). Η απόσταση αυτή αντιστοιχεί στο **περιθώριο ταξινόμησης** και είναι ίση με $\frac{2}{\|\mathbf{w}\|}$.



Σχήμα 3.32: Γραμμικός ταξινομητής SVM. (Διαδίκτυο).

Η εκπαίδευση του κλασικού γραμμικού *SVM* περιλαμβάνει την επίλυση του εξής προβλήματος ελαχιστοποίησης:

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{υπό τους περιορισμούς:} \quad y_i(\mathbf{w}^\top x_i + b) \geq 1, \quad \forall i \quad (3.38)$$

Αυτή η διατύπωση μεγιστοποιεί το περιθώριο, διατηρώντας σωστό διαχωρισμό των δεδομένων. Στην πράξη, χρησιμοποιείται και η **χαλαρή διατύπωση** (*soft-margin SVM*), όπου επιτρέπονται κάποια σφάλματα ταξινόμησης:

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{υπό τους περιορισμούς:} \quad y_i(\mathbf{w}^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (3.39)$$

Η παράμετρος C ελέγχει το *trade-off* μεταξύ μεγάλου περιθωρίου και μικρών σφαλμάτων (*regularization*).

Η χρήση του μέγιστου περιθωρίου καθιστά τα *SVM* ιδιαίτερα ανθεκτικά στη γενίκευση, αφού η λύση εξαρτάται μόνο από ένα υποσύνολο των σημείων εκπαίδευσης, τα *support vectors*. Σε πολλές περιπτώσεις όμως όπως και στη δική μας τα δεδομένα μπορεί να είναι αρκετά σύνθετα και να μην είναι γραμμικά διαχωρίσιμα. Για αυτόν τον λόγο χρησιμοποιήθηκε **μη γραμμικό SVM**, το οποίο εφαρμόζει το *kernel trick*, δηλαδή έναν μη γραμμικό μετασχηματισμό των δεδομένων σε χώρο μεγαλύτερων διαστάσεων όπου ο διαχωρισμός γίνεται γραμμικός. Το μη γραμμικό *SVM* είναι ανθεκτικό στην υπερεκπαίδευση (*overfitting*) ιδίως όταν χρησιμοποιούνται κανονικοποιημένα χαρακτηριστικά. Ωστόσο, μπορεί να απαιτήσει αρκετά υψηλό υπολογιστικό κόστος ειδικά σε μεγάλα *datasets*.

Στις πιο διαδεδομένες συναρτήσεις πυρήνα συγκαταλέγονται οι εξής:

- **Πολυωνυμικός πυρήνας** (*Polynomial kernel*): $K(x_i, x_j) = (\mathbf{x}_i^\top \mathbf{x}_j + c)^d$
- **Πυρήνας RBF** (*Gaussian kernel*): $K(x_i, x_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$
Η παράμετρος $\gamma > 0$ καθορίζει την «εμβέλεια» επιρροής κάθε δείγματος.
- **Σιγμοειδής πυρήνας** (*Sigmoid kernel*): $K(x_i, x_j) = \tanh(\alpha \mathbf{x}_i^\top \mathbf{x}_j + \beta)$

Στην συγκεκριμένη εργασία έχει χρησιμοποιηθεί ως συνάρτηση πυρήνα η **RBF** με κατάλληλο συνδυασμό υπερπαραμέτρων γ και C ο οποίος αναλύεται παρακάτω.

3.5.3 Τυχαίο Δάσος

Το **Τυχαίο Δάσος** (*Random Forest, RF*) είναι μια ισχυρή και ευρέως χρησιμοποιούμενη μέθοδος επιβλεπόμενης μάθησης, που ανήκει στην κατηγορία των **μεθόδων συλλογικής μάθησης** (*ensemble learning*). Αποτελεί εξέλιξη της μεθόδου των **δέντρων απόφασης** (*decision trees*) με στόχο τη βελτίωση της ακρίβειας και της γενίκευσης (Breiman 2001).

Η βασική ιδέα του είναι η κατασκευή ενός μεγάλου αριθμού δέντρων απόφασης κατά την εκπαίδευση και η συνδυασμένη χρήση των προβλέψεών τους κατά την ταξινόμηση. Η

τελική απόφαση προκύπτει είτε μέσω **πλειοψηφικής ψήφου** (στην ταξινόμηση) είτε μέσω **μέσου όρου** (στην παλινδρόμηση). Ο αλγόριθμος είναι μη παραμετρικός, δηλαδή δεν απαιτεί καμία υπόθεση για την κατανομή των δεδομένων και λειτουργεί αποτελεσματικά ακόμα και σε *datasets* υψηλής διαστατικότητας ή με αλληλεξαρτώμενες μεταβλητές.


Κάθε δέντρο εκπαιδεύεται σε διαφορετικό υποσύνολο του αρχικού συνόλου εκπαίδευσης, το οποίο επιλέγεται με δειγματοληψία με επανάθεση (*bootstrap sampling*). Σε κάθε κόμβο δέντρου η διαίρεση επιλέγεται από ένα τυχαίο υποσύνολο χαρακτηριστικών (και όχι από το πλήρες σύνολο), περιορίζοντας τη συσχέτιση μεταξύ των δέντρων και αυξάνοντας τη διασπορά. Οι δύο αυτοί μηχανισμοί μειώνουν τη μεταβλητότητα του μοντέλου και αυξάνουν τη γενίκευση, χωρίς να αυξάνουν αισθητά τη μεροληψία (*bias*), δημιουργώντας έναν «πληθυσμό» από ισχυρούς αλλά διαφοροποιημένους ταξινομητές.

Ένα από τα πιο συχνά χρησιμοποιούμενα κριτήρια για την επιλογή διαχωρισμών στους κόμβους είναι ο **δείκτης Gini** (*Gini impurity index*). Ο δείκτης αυτός μετρά την «καθαρότητα» ενός κόμβου, δηλαδή το πόσο ομοιογενή είναι τα δείγματα που περιέχει ως προς την κλάση στην οποία ανήκουν. Ορίζεται μαθηματικά ως:

$$Gini(t) = 1 - \sum_{i=1}^C p_i^2 \quad (3.40)$$

όπου p_i είναι η αναλογία των δειγμάτων της κλάσης i στον κόμβο t και C ο συνολικός αριθμός κλάσεων.

Κατά την εκπαίδευση, ο αλγόριθμος εξετάζει πιθανές διασπάσεις σε κάθε κόμβο και υπολογίζει τη μείωση του δείκτη *Gini* που αυτές προκαλούν. Η διάσπαση που επιλέγεται είναι αυτή που επιφέρει τη μεγαλύτερη μείωση της αβεβαιότητας, οδηγώντας σε «καθαρότερους» υποκόμβους. Με τον τρόπο αυτό, κάθε δέντρο βελτιώνει σταδιακά την ικανότητά του να διαχωρίζει τις κλάσεις, ενώ το *Random Forest*, συνδυάζοντας πολλά τέτοια δέντρα με διαφορετικά υποσύνολα δεδομένων και χαρακτηριστικών, επιτυγχάνει ισχυρή και γενικεύσιμη απόδοση.



Σχήμα 3.33: Ταξινομητής Random Forest. (Διαδίκτυο)

Όμοια με πριν, στη δικιά μας υλοποίηση έχει χρησιμοποιηθεί *Random Forest* με κατάλληλο συνδυασμό υπερπαραμέτρων ο οποίος αναλύεται παρακάτω.

3.5.4 Ακραία Ενισχυτική Μάθηση Κλίσης

Ο αλγόριθμος **Ακραίας Ενισχυτικής Μάθησης Κλίσης** (*XGBoost*, *eXtreme Gradient Boosting*) είναι ένας εξελιγμένος αλγόριθμος *ensemble learning*, ο οποίος βασίζεται στη μέθοδο **gradient boosting** και έχει αποδειχθεί ιδιαίτερα αποτελεσματικός σε πληθώρα προβλημάτων ταξινόμησης (Chen et al. 2016).


Το *XGBoost* πιο συγκεκριμένα κατασκευάζει ένα ισχυρό τελικό μοντέλο συνδυάζοντας πολλούς «ασθενείς» ταξινομητές, συνήθως δέντρα απόφασης μικρού βάθους. Το *gradient boosting* είναι μια επαναληπτική μέθοδος που προσθέτει διαδοχικά μοντέλα ώστε να μειώσει το σφάλμα του συνόλου. Σε κάθε επανάληψη t , κατασκευάζεται ένα νέο δέντρο $f_t(x)$ που προσεγγίζει το αρνητικό *gradient* της συνάρτησης απώλειας (*loss function*) σε σχέση με τις προβλέψεις του προηγούμενου μοντέλου. Ορισμένες από τις καινοτομίες του είναι λοιπόν ότι **εισάγει όρους κανονικοποίησης L_1 και L_2** περιορίζοντας την πολυπλοκότητα των δέντρων και βελτιώνοντας τη γενίκευση και ότι **χρησιμοποιούνται στατιστικά βάρη δειγμάτων** για αποδοτική εύρεση *split points* ακόμα και με μεγάλα ή μη ισορροπημένα δεδομένα.

Ο συνολικός στόχος του *XGBoost* είναι η ελαχιστοποίηση μιας κανονικοποιημένης συνάρτησης κόστους της μορφής:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (3.41)$$

όπου:

- l : συνάρτηση απώλειας,
- f_t : το νέο δέντρο στο βήμα t ,
- $\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \|w\|^2$: όρος κανονικοποίησης που εξαρτάται από τον αριθμό κόμβων T και τα βάρη w των φύλλων.



Σχήμα 3.34: Ταξινομητής XGBoost. (Διαδίκτυο)

Η επίδοση ενός μοντέλου μηχανικής μάθησης εξαρτάται όχι μόνο από την αρχιτεκτονική του ή τον αλγόριθμο που χρησιμοποιείται, αλλά και από την κατάλληλη **ρύθμιση** (*tuning*) των παραμέτρων και των εισόδων του. Η διαδικασία ρύθμισης περιλαμβάνει τεχνικές που αποσκοπούν στη βελτιστοποίηση της γενικευσιμότητας του μοντέλου, μειώνοντας ταυτόχρονα την πιθανότητα υπερπροσαρμογής (*overfitting*) ή υποπροσαρμογής (*underfitting*).

3.5.5 Ρύθμιση μοντέλων

Στα περισσότερα μοντέλα, διακρίνουμε δύο βασικούς τύπους παραμέτρων:

- **Εσωτερικές παράμετροι** (*learnable parameters*): Μαθαίνονται κατά τη διαδικασία εκπαίδευσης (π.χ. βάρη σε ένα νευρωνικό δίκτυο) και δεν χρειάζεται να οριστούν από τον χρήστη χειροκίνητα.
- **Υπερπαράμετροι** (*hyperparameters*): Ρυθμίζονται πριν την εκπαίδευση από τον χρήστη και επηρεάζουν τη συμπεριφορά του μοντέλου (π.χ. ρυθμός μάθησης, αριθμός γειτόνων στο *k-NN*, αριθμός δέντρων στο *Random Forest* κ.τ.λ.).

Είναι ιδιαίτερα σημαντικό να γίνει **κατάλληλη επιλογή υπερπαραμέτρων** για κάθε μοντέλο ταξινόμησης. Πιο κάτω παρατίθενται οι υπερπαράμετροι που ερευνηθήκαν μέσω **αναζήτησης πλέγματος** (*grid search*) και **διασταυρούμενη επικύρωση** (*cross-validation*):

k-Nearest Neighbors (k-NN)

- *k*: Πλήθος των κοντινότερων γειτόνων που χρησιμοποιούνται για την πρόβλεψη. Μικρές τιμές οδηγούν σε αυξημένη ευαισθησία στον θόρυβο, ενώ μεγάλες τιμές ενδέχεται να μειώσουν την απόδοση σε σύνθετα προβλήματα. Πραγματοποιήθηκε διερεύνηση στο διάστημα [1, 20]

Non-Linear Support Vector Machine (RBF kernel)

- *C*: Παράμετρος κανονικοποίησης που ρυθμίζει το *trade-off* μεταξύ του μεγάλου περιθωρίου και της σωστής ταξινόμησης των εκπαιδευτικών δειγμάτων. Μικρές τιμές οδηγούν σε πιο «μαλακό» υπερεπίπεδο, ενώ μεγάλες σε αυστηρότερο διαχωρισμό. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [0.1, 1, 10].
- *γ*: Καθορίζει την ακτίνα επιρροής ενός μεμονωμένου δείγματος στη διαμόρφωση της συνάρτησης απόφασης. Μικρές τιμές οδηγούν σε πιο ομαλές επιφάνειες απόφασης (*underfitting*), ενώ μεγάλες τιμές σε πιο πολύπλοκες και ευαίσθητες στα δεδομένα επιφάνειες (*overfitting*). Στη βιβλιοθήκη *scikit-learn*, η επιλογή *auto* ορίζει το *γ* ως $1/n_{\text{features}}$, ενώ η προεπιλογή *scale* το ορίζει ως $1/(n_{\text{features}} \cdot \text{Var}(X))$, λαμβάνοντας υπόψη και τη διασπορά των δεδομένων για πιο σταθερή απόδοση.

Random Forest (RF)

- **n_estimators**: Αριθμός δέντρων στο δάσος. Περισσότερα δέντρα μειώνουν τη διασπορά αλλά αυξάνουν τον υπολογιστικό χρόνο. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [50, 100, 200].
- **max_depth**: Μέγιστο επιτρεπτό βάθος κάθε δέντρου. Περιορίζει την πολυπλοκότητα του μοντέλου. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [5, 10, 20].
- **min_samples_split**: Ελάχιστος αριθμός δειγμάτων για να διασπαστεί ένας κόμβος. Χρησιμοποιείται για αποφυγή υπερεκπαίδευσης. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [2, 5, 10].

XGBoost

- **n_estimators**: Αριθμός προσθετικών δέντρων (*boosting rounds*). Υψηλές τιμές μπορούν να οδηγήσουν σε *overfitting*. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [50, 100, 200].
- **learning_rate** (η): Ρυθμός εκμάθησης. Καθορίζει πόσο «βαριά» επηρεάζει κάθε νέο δέντρο την τελική πρόβλεψη. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [3, 5, 10].
- **max_depth**: Μέγιστο βάθος των δέντρων. Ρυθμίζει την πολυπλοκότητα κάθε αδύναμου ταξινομητή. Δοκιμάστηκαν κατά τη διερεύνηση οι τιμές [0.1, 1, 10].

Επιπλέον, η ποιότητα του χώρου χαρακτηριστικών που εισάγονται στο μοντέλο επηρεάζει άμεσα τη μάθηση. Για αυτόν τον λόγο, η **κλιμάκωση χαρακτηριστικών** (*feature scaling*) είναι ένα κρίσιμο βήμα στην προεπεξεργασία των δεδομένων, ιδίως όταν τα χαρακτηριστικά εισόδου έχουν διαφορετικές μονάδες μέτρησης, μεγέθη ή διακυμάνσεις. Πολλοί αλγόριθμοι μηχανικής μάθησης είναι ευαίσθητοι στο εύρος των τιμών των χαρακτηριστικών, καθώς βασίζονται σε αποστάσεις (π.χ. *k-NN*, *SVM*) ή στη γραμμικότητα (νευρωνικά δίκτυα), οπότε είναι κρίσιμο όλα τα δεδομένα να εκφράζονται στην **ίδια κλίμακα**. Η κλιμάκωση, ωστόσο, πρέπει να εφαρμόζεται **μετά τη διάσπαση** των δεδομένων σε σύνολο εκπαίδευσης και ελέγχου, ώστε οι στατιστικές (μέση τιμή, διακύμανση κ.λπ.) να υπολογίζονται **μόνο από τα δεδομένα εκπαίδευσης** και να εφαρμόζονται ομοιόμορφα και στο *validation/test set*. Αυτό αποτρέπει τη διαρροή πληροφορίας (*data leakage*).

Στην παρούσα εργασία χρησιμοποιήθηκε η **κανονικοποίηση Min-Max στο διάστημα [-1, 1]** πριν την εφαρμογή των περισσότερων αλγορίθμων ταξινόμησης, εξαιρουμένων των δέντρων απόφασης και παραγώγων τους (*RF*, *XGBoost*), οι οποίοι δεν επηρεάζονται από την κλίμακα των χαρακτηριστικών. Πιο συγκεκριμένα, η κανονικοποίηση *Min-Max* μετασχηματίζει γραμμικά τα δεδομένα ενός χαρακτηριστικού ώστε να περιορίζονται εντός προκαθορισμένου διαστήματος $[a, b]$ μέσω της σχέσης:

$$x' = a + \frac{(b - a)(x - \min(x))}{\max(x) - \min(x)} \quad (3.42)$$

όπου:

- x είναι η αρχική τιμή του χαρακτηριστικού,
- x' η κανονικοποιημένη τιμή,
- $\min(x)$ και $\max(x)$ είναι οι ελάχιστες και μέγιστες τιμές του χαρακτηριστικού στο σύνολο εκπαίδευσης,
- $[a, b]$ είναι το επιθυμητό εύρος τιμών.

Αυτού του τύπου η κανονικοποίηση διατηρεί την αναλογική σχέση μεταξύ των δειγμάτων και τα κατανέμει συμμετρικά γύρω από το μηδέν.

3.5.6 Αξιολόγηση μοντέλων

Σε προβλήματα ταξινόμησης και ειδικότερα σε πολυκατηγορικά με ανισοκατανομημένες κατηγορίες η αξιολόγηση της απόδοσης ενός μοντέλου απαιτεί λεπτομερή ανάλυση πέρα από το απλό ποσοστό ακρίβειας. Οι **μετρικές ανά κλάση** επιτρέπουν τη διερεύνηση της συμπεριφοράς του μοντέλου ξεχωριστά για κάθε κατηγορία και βοηθούν στην κατανόηση πιθανών μεροληψιών ή αδυναμιών.

Βασίζονται στον υπολογισμό των παρακάτω ποσοτήτων για κάθε κλάση C_i :

- **True Positives (TP)**: Πλήθος δειγμάτων της κλάσης C_i που ταξινομήθηκαν σωστά ως C_i .
- **False Positives (FP)**: Πλήθος δειγμάτων άλλων κλάσεων που ταξινομήθηκαν εσφαλμένα ως C_i .
- **False Negatives (FN)**: Πλήθος δειγμάτων της κλάσης C_i που ταξινομήθηκαν εσφαλμένα ως άλλη κλάση.
- **True Negatives (TN)**: Πλήθος δειγμάτων εκτός C_i που ταξινομήθηκαν σωστά ως μη C_i .

Μητρώο Σύγχυσης (Confusion Matrix) Το **μητρώο σύγχυσης** είναι ένας πίνακας διαστάσεων $K \times K$ (όπου K είναι ο αριθμός των κατηγοριών) που αποτυπώνει συνοπτικά την απόδοση του ταξινομητή. Κάθε κελί (i, j) του πίνακα δηλώνει τον αριθμό δειγμάτων της πραγματικής κατηγορίας C_i που προβλέφθηκαν ως C_j . Οι γραμμές του πίνακα αντιστοιχούν στις **πραγματικές** ετικέτες, ενώ οι στήλες του αντιστοιχούν στις **προβλεπόμενες** ετικέτες. Τέλος, η διαγώνιος περιλαμβάνει τις σωστές προβλέψεις για κάθε κλάση, ενώ τα εκτός διαγωνίου στοιχεία αντιστοιχούν σε σφάλματα ταξινόμησης.

Το μητρώο σύγχυσης αποδεικνύεται ιδιαίτερα χρήσιμο, καθώς επιτρέπει τον εντοπισμό ποιοτικών μοτίβων σφαλμάτων μεταξύ συγκεκριμένων κλάσεων, αλλά και την εξαγωγή όλων των επιμέρους μετρικών ανά κλάση, οι οποίες αναλύονται στη συνέχεια.

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Σχήμα 3.35: Μητρώο σύγχυσης.(Διαδίκτυο)

Ακρίβεια (*Precision*) Η ακρίβεια μετρά την αναλογία των σωστών προβλέψεων μιας κλάσης επί των συνολικών προβλέψεων για την εν λόγω κλάση:

$$Precision = \frac{TP}{TP + FP} \quad (3.43)$$

Αντανακλά την «καθαρότητα» των θετικών προβλέψεων. Υψηλή τιμή σημαίνει ότι οι θετικές προβλέψεις είναι κατά κύριο λόγο σωστές.

Ανάκληση ή Ευαισθησία (*Recall* ή *Sensitivity*) Η ανάκληση μετρά την ικανότητα του μοντέλου να αναγνωρίζει σωστά όλα τα δείγματα μιας κλάσης:

$$Recall = \frac{TP}{TP + FN} \quad (3.44)$$

Υψηλή τιμή υποδηλώνει ότι λίγα πραγματικά θετικά δείγματα αγνοήθηκαν από το μοντέλο.

Μέτρο F1 (*F1-score*) Το μέτρο F_1 αποτελεί τον αρμονικό μέσο της ακρίβειας και της ανάκλησης της κλάσης:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3.45)$$

Είναι χρήσιμο σε περιπτώσεις όπου απαιτείται ισορροπία μεταξύ των δύο, και είναι ευαίσθητο σε χαμηλές τιμές οποιασδήποτε από τις δύο μετρικές.

Ειδικότητα (*Specificity*) Η ειδικότητα είναι συμπληρωματική της ανάκλησης και μετρά την ικανότητα αναγνώρισης των αρνητικών περιπτώσεων για την εκάστοτε κλάση:

$$Specificity = \frac{TN}{TN + FP} \quad (3.46)$$

Είναι ιδιαίτερα χρήσιμη σε ιατρικές διαγνώσεις όπου η αποφυγή ψευδώς θετικών προβλέψεων είναι κρίσιμη.

Οι καμπύλες *ROC* και *Precision-Recall* αποτελούν γραφικές μεθόδους αξιολόγησης της απόδοσης ενός ταξινομητή ειδικά σε πολυκατηγορικά προβλήματα με τεχνικές *one-vs-rest*. Εστιάζουν στη διακριτική ικανότητα του μοντέλου και στη συμπεριφορά του υπό μεταβολές του κατωφλίου ταξινόμησης (*decision threshold*).


Καμπύλη ROC (Receiver Operating Characteristic) Η καμπύλη ROC απεικονίζει τη σχέση μεταξύ της **ευαισθησίας** (True Positive Rate, TPR) και του **ψευδώς θετικού ποσοστού** (False Positive Rate, FPR) καθώς μεταβάλλεται το κατώφλι ταξινόμησης.

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN} \quad (3.47)$$

Η ιδανική καμπύλη ROC προσεγγίζει το άνω αριστερό σημείο του διαγράμματος ($TPR = 1, FPR = 0$), ενώ η διαγώνια γραμμή ($TPR = FPR$) αντιστοιχεί σε πρόβλεψη που προκύπτει από τυχαίο ταξινομητή.

Εμβαδόν υπό την καμπύλη (Area Under the Curve, AUC) Η τιμή AUC συνοψίζει την καμπύλη ROC σε έναν αριθμό. Η τιμή:

- $AUC = 1.0$ σημαίνει τέλεια ταξινόμηση.
- $AUC = 0.5$ ισοδυναμεί με τυχαία πρόβλεψη.
- $AUC < 0.5$ υποδηλώνει ότι το μοντέλο λειτουργεί χειρότερα από το τυχαίο.



Σχήμα 3.36: Καμπύλη ROC.(Διαδίκτυο)

Καμπύλη Precision–Recall (PR) Η καμπύλη PR απεικονίζει την Ακρίβεια (Precision) ως συνάρτηση της Ανάκλησης (Recall). Είναι ιδιαίτερα χρήσιμη σε προβλήματα με σοβαρή ανισοκατανομή κατηγοριών (π.χ. ανίχνευση σπανίων παθολογικών γεγονότων όπως τα *wheezes*), όπου η καμπύλη ROC μπορεί να δώσει υπερεκτιμημένα αποτελέσματα.

Η μορφή της καμπύλης PR είναι συνήθως πιο «αυστηρή» από την ROC και η μείωση της ακρίβειας καθώς αυξάνεται η ανάκληση αποκαλύπτει την «τίμηση» της ανίχνευσης περισσότερων θετικών δειγμάτων.

Εμβαδόν υπό την καμπύλη PR (Average Precision, AP) Το μέσο εμβαδόν κάτω από την PR καμπύλη ορίζεται ως:

$$AP = \sum_n (R_n - R_{n-1}) \cdot P_n \quad (3.48)$$

όπου P_n και R_n είναι η ακρίβεια και η ανάκληση στο κατώφλι n . Η μετρική αυτή συνοψίζει την PR καμπύλη σε έναν αριθμό, παρόμοια με την AUC της ROC .

Επιπλέον, η αξιολόγηση της συνολικής απόδοσης ενός ταξινομητή γίνεται συνήθως με τη βοήθεια **σύνθετων μετρικών συνολικής απόδοσης**, οι οποίες συνοψίζουν την επίδοση του μοντέλου σε όλες τις κατηγορίες ή όλες τις προβλέψεις με ενιαίο τρόπο. Οι πιο διαδεδομένες από αυτές είναι οι εξής:

Ακρίβεια (Accuracy) Η ακρίβεια ορίζει το ποσοστό των σωστών προβλέψεων επί του συνολικού αριθμού δειγμάτων:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.49)$$

Σε προβλήματα πολυκατηγορικής ταξινόμησης η ακρίβεια ισούται με το πλήθος των σωστά ταξινομημένων δειγμάτων διαιρούμενο με το σύνολο των δειγμάτων. Αν και απλή στην ερμηνεία, δεν είναι πάντα κατάλληλη για μη ισορροπημένα σύνολα δεδομένων, καθώς μπορεί να δώσει παραπλανητικά υψηλές τιμές αν το μοντέλο προβλέπει σωστά μόνο την πλειοψηφική κλάση.

Μέσο $F1$ score Το $F1$ score που ορίστηκε στην προηγούμενη ενότητα μπορεί να συνοψιστεί σε συνολικό επίπεδο αντί σε επίπεδο κλάσης με διάφορους τρόπους:

- **Macro $F1$:** Υπολογίζει το $F1$ score ξεχωριστά για κάθε κλάση και επιστρέφει τον μη σταθμισμένο μέσο όρο:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{i=1}^K F1_i \quad (3.50)$$

- **Weighted $F1$:** Υπολογίζει το $F1$ κάθε κλάσης και παίρνει το σταθμισμένο άθροισμα με βάση τον αριθμό δειγμάτων ανά κλάση:

$$F1_{\text{weighted}} = \sum_{i=1}^K w_i \cdot F1_i \quad \text{όπου } w_i = \frac{n_i}{N} \quad (3.51)$$

Matthews Correlation Coefficient (MCC) Ο συντελεστής συσχέτισης του Matthews είναι μία από τις πιο αξιόπιστες μετρικές για πολυκατηγορική ταξινόμηση, καθώς λαμβάνει υπόψη όλες τις τιμές TP , TN , FP , FN και ορίζεται ως:

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (3.52)$$

Το MCC είναι εύκολα ερμηνεύσιμο και λαμβάνει τιμές από -1 το οποίο δηλώνει πλήρη αποτυχία ταξινόμησης έως $+1$ το οποίο δηλώνει τέλεια ταξινόμηση, με το 0 να υποδηλώνει τυχαία πρόβλεψη.

Κεφάλαιο 4

Πειραματική διαδικασία και αποτελέσματα

4.1 Τεχνολογίες και εργαλεία υλοποίησης

Υπολογιστικό σύστημα Όλες οι πειραματικές διαδικασίες και η υλοποίηση των αλγορίθμων πραγματοποιήθηκαν σε φορητό υπολογιστή εξοπλισμένο με επεξεργαστή **Intel Core i5-8350U**, τεχνολογίας *Kaby Lake-R*. Το σύστημα διαθέτει **16 GigaByte μνήμης RAM DDR4**, καθώς και ενσωματωμένη κάρτα γραφικών **Intel UHD Graphics 620**. Η συγκεκριμένη διαμόρφωση προσφέρει επαρκή υπολογιστική ισχύ για την εκπαίδευση και αξιολόγηση μοντέλων βαθιάς μάθησης μικρής έως μέσης κλίμακας, ενώ η χρήση ενσωματωμένων γραφικών καθιστά το σύστημα ενεργειακά αποδοτικό και κατάλληλο για φορητή χρήση.

Περιβάλλον ανάπτυξης Η υλοποίηση πραγματοποιήθηκε σε γλώσσα προγραμματισμού *Python* και πιο συγκεκριμένα σε περιβάλλον **Python 3.6.8**. Η γλώσσα *Python* επιλέχθηκε ως κύριο εργαλείο υλοποίησης λόγω της ευρείας χρήσης της στην επιστημονική έρευνα και την επεξεργασία σημάτων, της μεγάλης ποικιλίας βιβλιοθηκών ανοιχτού κώδικα που υποστηρίζουν ανάλυση ήχου, μηχανική μάθηση και οπτικοποίηση, καθώς και της απλής και κατανοητής σύνταξής της που επιτρέπει ταχεία ανάπτυξη και πειραματισμό. Επιπλέον, για την ανάπτυξη του κώδικα χρησιμοποιήθηκε το εργαλείο **Visual Studio Code** και το **Jupyter Notebook** για την πειραματική ανάλυση και οπτικοποίηση.

Βιβλιοθήκες Παρατίθεται μια σύντομη λίστα με όλες τις βιβλιοθήκες *Python* που χρησιμοποιήθηκαν κατά την εκπόνηση της εργασίας:

Επεξεργασία σημάτων Για την ανάγνωση, επεξεργασία και φασματική ανάλυση των ηχητικών σημάτων αξιοποιήθηκαν βιβλιοθήκες όπως:

- **librosa** για εξαγωγή χαρακτηριστικών.
- **scipy.signal** για εφαρμογή φίλτρων, παραθύρωσης και μετασχηματισμούς Φουριερ.

- `soundfile` για ανάγνωση/εγγραφή αρχείων `.wav`.

Διαχείριση και προεπεξεργασία δεδομένων Η διαχείριση των δεδομένων έγινε με χρήση `pandas` και `numpy` για αποθήκευση, μετασχηματισμό και τυποποίηση των χαρακτηριστικών.

Οπτικοποίηση και ανάλυση δεδομένων Για την οπτικοποίηση των αποτελεσμάτων χρησιμοποιήθηκαν οι `matplotlib` και `seaborn` για γραφήματα συναρτήσεων κόστους, θερμικούς χάρτες, κατανομές χαρακτηριστικών και γενικότερα οποιασδήποτε στατιστικής ανάλυσης.

Μηχανική μάθηση Η εκπαίδευση των μοντέλων βαθιάς μάθησης για το *domain adaptation* πραγματοποιήθηκε μέσω του framework `pytorch`, το οποίο επιτρέπει ευέλικτη υλοποίηση νευρωνικών αρχιτεκτονικών μέσω του module `torch` και υποστηρίζει μηχανισμούς αυτόματης παραγωγής και βελτιστοποίησης. Χρησιμοποιήθηκε επίσης η `scikit-learn` για τα συμβατικά μοντέλα ταξινόμησης μετρικές αξιολόγησης και μεθόδους μείωσης διαστάσεων (*PCA*, *t-SNE*).

4.2 Διερευνητική ανάλυση του συνόλου δεδομένων

Αφού εξάγουμε τα χαρακτηριστικά από τα προεπεξεργασμένα ηχητικά αρχεία μεταβαίνουμε στην στατιστική διερεύνηση αυτών. Πιο συγκεκριμένα, από τα *KDE plots* παρατηρείται ότι για χαρακτηριστικά όπως τα *MFCC_3*, *MFCC_5*, *MFCC_7*, *Spectral Rolloff*, καθώς και το *RMS Energy*, οι καμπύλες πυκνότητας των κλάσεων παρουσιάζουν **έντονη επικάλυψη**. Για παράδειγμα, στο *MFCC_5* οι κλάσεις *Normal* και *Wheeze* συγκεντρώνονται στην ίδια περιοχή τιμών, με αποτέλεσμα το χαρακτηριστικό να μην προσφέρει σαφή διαχωρισμό. Αντίστοιχα, στο *Spectral Rolloff* οι κατανομές και των τριών κλάσεων έχουν παρόμοιο εύρος και κεντρική θέση, γεγονός που υποδηλώνει χαμηλή διακριτική ισχύ. Αντίθετα, σε χαρακτηριστικά όπως τα *ZCR*, *Spectral Bandwidth*, *Spectral Centroid*, *Spectral Flatness*, καθώς και οι συντελεστές *MFCC_0*, *MFCC_8*, *MFCC_12*, οι κατανομές παρουσιάζουν **σαφή διαφοροποίηση** μεταξύ των κλάσεων. Ενδεικτικά, στο *Spectral Centroid* οι τιμές της κλάσης *Wheeze* μετατοπίζονται σε υψηλότερες συχνότητες σε σχέση με τις *Normal*, ενώ στο *ZCR* η κλάση *Crackle* εμφανίζει υψηλότερες τιμές σε σχέση με τις υπόλοιπες. Η μετατόπιση αυτή στις κορυφές των κατανομών καθιστά τα συγκεκριμένα χαρακτηριστικά περισσότερο διαχωριστικά. Συνολικά, καθίσταται σαφές ότι η μορφή των περισσότερων κατανομών ποικίλλει, με ορισμένες να προσεγγίζουν την κανονική κατανομή (*Gaussian-like*), ενώ άλλες εμφανίζουν μεγαλύτερη κυρτότητα ή ασυμμετρία.

Επίσης, οι οπτικοποιήσεις των *boxplots* επιβεβαιώνουν και αυτές σε μεγάλο βαθμό τα ευρήματα που προέκυψαν από τα *KDE plots*. Συγκεκριμένα, παρατηρείται ότι για χαρακτηριστικά όπως τα *ZCR*, *Spectral Centroid*, *Spectral Bandwidth* και οι συντελεστές *MFCC_0*, *MFCC_8*, *MFCC_12*, οι διάμεσοι των κλάσεων εμφανίζονται σε διαφορετικά

επίπεδα και οι περιοχές μεταξύ πρώτου και τρίτου τεταρτημορίου (*interquartile ranges*) παρουσιάζουν περιορισμένη επικάλυψη. Για παράδειγμα, στο *Spectral Centroid* η κλάση *Wheeze* εμφανίζει σαφώς υψηλότερες τιμές σε σχέση με τις *Normal*, ενώ στο *ZCR* η κλάση *Crackle* διαχωρίζεται με εμφανώς υψηλότερες τιμές σε σχέση με τις υπόλοιπες. Αντίθετα, σε χαρακτηριστικά όπως τα *MFCC_3*, *MFCC_5*, *MFCC_7* και το *Spectral Rolloff*, οι διάμεσοι βρίσκονται σε παρόμοια επίπεδα και οι περιοχές διασποράς τους επικαλύπτονται σημαντικά, γεγονός που υποδηλώνει χαμηλή διακριτική ικανότητα. Συνολικά, τα *boxplots* αποκαλύπτουν ότι τα χαρακτηριστικά *ZCR*, *Spectral Centroid*, *Spectral Bandwidth* και επιλεγμένα *MFCCs* αποτελούν πιο ισχυρούς δείκτες διαφοροποίησης των κλάσεων, ενώ άλλα, όπως το *Spectral Rolloff* ή οι μεσαίοι συντελεστές *MFCC*, δεν συνεισφέρουν ουσιαστικά στη διάκριση.

Στο πλαίσιο της ταξινόμησης, η **ANOVA** εφαρμόστηκε ανεξάρτητα για κάθε χαρακτηριστικό που εξάγαμε ώστε να εκτιμηθεί η διακριτική του ικανότητα ως προς την ετικέτα ταξινόμησης. Τα χαρακτηριστικά κατατάσσονται βάσει του *F-score* και μάλιστα όσο μεγαλύτερο είναι το *F*, τόσο ισχυρότερη είναι η ένδειξη ότι υπάρχει σημαντική διαφορά μεταξύ των ομάδων. Τα χαρακτηριστικά με τις υψηλότερες τιμές *F* φαίνεται πως είναι τα *Spectral Centroid*, *Spectral Bandwidth*, *ZCR* και οι συντελεστές *MFCC_0*, *MFCC_8*, *MFCC_12*. Ενδεικτικά, ο δείκτης *F* του *MFCC_12* με τιμή κοντά στο 1000 ξεπερνά κατά πολύ αυτόν των υπολοίπων χαρακτηριστικών, γεγονός που δείχνει ότι η μέση τιμή του διαφέρει έντονα μεταξύ των κλάσεων. Αντίθετα, χαρακτηριστικά όπως τα μεσαία *MFCCs* (*MFCC_3*, *MFCC_5*, *MFCC_7*) και το *Spectral Rolloff* εμφανίζουν πολύ χαμηλές τιμές *F*, στοιχείο που σημαίνει ότι οι μέσοι όροι τους δεν διαφοροποιούνται σημαντικά μεταξύ των κλάσεων και επομένως δεν είναι κατάλληλοι για διαχωρισμό.


Επιπρόσθετα, από το **Feature-Class heatmap** παρατηρείται ότι τα χαρακτηριστικά *MFCC_1*, *MFCC_2*, *MFCC_6*, καθώς και οι δείκτες *Spectral Centroid* και *Spectral Bandwidth*, εμφανίζουν έντονη διαφοροποίηση μεταξύ των κλάσεων, γεγονός που υποδηλώνει υψηλή διαχωριστική ικανότητα. Ειδικότερα, η κλάση *Wheeze* παρουσιάζει υψηλές τιμές στα χαρακτηριστικά *MFCC_1* και *Spectral Centroid*, σε αντίθεση με τις κλάσεις *Normal* και *Crackle* που καταγράφουν χαμηλότερες τιμές. Αντίστοιχα, αρκετές ζώνες *Log-Mel* (όπως οι *Log_Mel_0*, *Log_Mel_3*, *Log_Mel_5*, *Log_Mel_7*) εμφανίζουν σαφείς διαφοροποιήσεις μεταξύ των τριών κλάσεων, ιδιαίτερα στην κλάση *Crackle* όπου τείνουν σε υψηλότερες τιμές και τους *Wheeze* σε χαμηλότερες.

Τέλος, από το **Correlation heatmap** παρατηρείται ότι τα **Log-Mel Energies** εμφανίζουν πολύ υψηλή θετική συσχέτιση, ιδιαίτερα μεταξύ γειτονικών ζωνών (π.χ. *Log-Mel_0*–*Log_Mel_5*, *Log_Mel_10*–*Log_Mel_15*), γεγονός το οποίο επιβεβαιώνει ότι περιγράφουν σε μεγάλο βαθμό παρόμοιες φασματικές πληροφορίες και άρα δεν χρειάζεται να διατηρηθούν όλα. Αντίστοιχα, οι χαμηλής τάξης συντελεστές *MFCC* όπως *MFCC_0*–*MFCC_5* παρουσιάζουν και αυτοί μέτρια έως υψηλή συσχέτιση μεταξύ τους, καθώς προκύπτουν από τον ίδιο μετασχηματισμό και καταγράφουν την γενική φασματική κλίση. Ακόμη, μέτρια συσχέτιση παρατηρείται κυρίως μεταξύ των *Spectral Centroid*, *Spectral Bandwidth* και *Spectral Rolloff*, κάτι που είναι αναμενόμενο καθώς όλα αυτά τα χαρακτηριστικά αποτυ-


πώνουν διαφορετικές όψεις της κατανομής της φασματικής ενέργειας. Αντίθετα, χαρακτηριστικά όπως το *Zero Crossing Rate*, το *RMS Energy* και το *Onset Envelope* εμφανίζουν μέτρια προς χαμηλή συσχέτιση με τα περισσότερα χαρακτηριστικά, γεγονός που υποδηλώνει ότι προσφέρουν συμπληρωματική πληροφορία η οποία δεν προκύπτει άμεσα από τις υπόλοιπες φασματικές περιγραφές.

Χαρακτηριστικό	Mean	Std	Min	25%	50%	75%	Max	IQR
<i>MFCC_0</i>	-374.33	82.68	-647.94	-425.34	-370.07	-319.87	-127.40	105.47
<i>MFCC_1</i>	109.57	32.80	-38.16	89.41	108.36	130.56	232.01	41.15
<i>MFCC_2</i>	8.06	21.73	-86.95	-6.17	7.86	22.91	73.62	29.08
<i>MFCC_3</i>	14.85	15.49	-51.19	8.26	17.59	25.00	55.19	16.74
<i>MFCC_4</i>	-20.04	12.41	-72.77	-28.08	-19.13	-11.82	23.20	16.26
<i>MFCC_5</i>	-4.29	8.76	-35.36	-10.24	-4.64	1.20	34.63	11.44
<i>MFCC_6</i>	-25.61	10.52	-66.37	-33.22	-26.61	-18.99	14.91	14.23
<i>MFCC_7</i>	-11.40	6.50	-40.67	-15.19	-11.07	-7.23	19.96	7.96
<i>MFCC_8</i>	-25.88	8.72	-56.88	-33.10	-26.43	-18.92	7.22	14.18
<i>MFCC_9</i>	-14.54	5.74	-38.21	-17.80	-14.22	-10.64	10.98	7.17
<i>MFCC_10</i>	-25.14	7.61	-50.53	-31.14	-24.99	-18.94	2.23	12.20
<i>MFCC_11</i>	-13.17	5.00	-37.66	-15.89	-12.93	-9.96	11.79	5.94
<i>MFCC_12</i>	-21.26	7.28	-48.25	-27.48	-21.07	-15.02	7.34	12.46
<i>Spectral Centroid</i>	363.12	106.79	183.45	283.15	341.49	417.07	1090.55	133.93
<i>Spectral Bandwidth</i>	334.16	85.90	142.47	266.69	332.59	393.30	593.95	126.62
<i>Zero Crossing Rate</i>	652.66	252.97	241.25	453.96	597.52	796.45	1651.98	342.49
<i>RMS Energy</i>	0.02	0.02	0.00	0.01	0.01	0.02	0.21	0.02
<i>Spectral Rolloff</i>	0.12	0.05	0.01	0.08	0.12	0.16	0.52	0.08
<i>Spectral Flux</i>	0.11	0.04	0.06	0.08	0.10	0.12	0.49	0.04
<i>Spectral Flatness</i>	0.84	2.33	-7.68	-0.68	0.57	2.21	13.70	2.89
<i>Log_Mel_0</i>	-15.94	6.60	-45.96	-19.41	-14.84	-11.04	-3.69	8.37
<i>Log_Mel_1</i>	-14.55	5.92	-44.27	-17.22	-13.23	-10.43	-0.16	6.79
<i>Log_Mel_2</i>	-19.39	6.87	-53.44	-22.84	-18.15	-14.29	-6.29	8.55
<i>Log_Mel_3</i>	-24.76	7.35	-59.68	-28.65	-23.54	-19.33	-7.02	9.32
<i>Log_Mel_4</i>	-29.00	7.26	-63.48	-32.92	-27.94	-24.12	-6.57	8.80
<i>Log_Mel_5</i>	-32.28	7.02	-62.56	-36.30	-31.67	-28.20	-6.61	8.11
<i>Log_Mel_6</i>	-35.00	7.20	-66.11	-39.18	-35.15	-31.13	-4.60	8.05
<i>Log_Mel_7</i>	-37.72	7.64	-71.37	-42.25	-38.20	-33.42	-7.28	8.83
<i>Log_Mel_8</i>	-40.06	8.39	-77.28	-45.12	-40.29	-35.03	-10.14	10.09
<i>Log_Mel_9</i>	-42.03	9.13	-78.96	-47.61	-41.90	-36.42	-12.72	11.19
<i>Log_Mel_10</i>	-43.73	9.61	-79.66	-49.29	-43.30	-37.65	-15.08	11.63
<i>Log_Mel_11</i>	-45.24	10.13	-79.76	-50.71	-44.57	-38.93	-13.62	11.78
<i>Log_Mel_12</i>	-46.51	10.47	-79.80	-51.94	-45.57	-40.12	-12.68	11.81
<i>Log_Mel_13</i>	-47.64	10.85	-79.82	-53.05	-46.61	-41.11	-11.52	11.94
<i>Log_Mel_14</i>	-48.40	11.16	-79.83	-53.92	-47.40	-41.66	-13.93	12.27
<i>Log_Mel_15</i>	-49.14	11.26	-79.83	-54.81	-48.11	-42.52	-14.34	12.29
<i>Log_Mel_16</i>	-50.16	11.22	-79.98	-55.92	-49.20	-43.43	-16.80	12.49
<i>Log_Mel_17</i>	-51.58	11.26	-80.00	-57.49	-50.59	-44.75	-18.12	12.74
<i>Log_Mel_18</i>	-53.25	11.19	-80.00	-59.54	-52.35	-46.32	-16.03	13.21
<i>Log_Mel_19</i>	-57.07	10.22	-80.00	-63.25	-56.53	-50.65	-19.46	12.60
<i>On Set Envelope</i>	0.36	0.14	0.09	0.26	0.34	0.43	1.54	0.17


Πίνακας 4.1: Περιγραφικά στατιστικά μεγέθη για τα εξαγμένα χαρακτηριστικά.




Σχήμα 4.1: KDE plots των μέσων εξαγμένων χαρακτηριστικών ανά label.




Σχήμα 4.2: Boxplots των μέσων εξαγμένων χαρακτηριστικών ανά label.




Σχήμα 4.3: Feature-Class heatmap των εξαγμένων χαρακτηριστικών.



Σχήμα 4.4: Correlation heatmap των εξαγμένων χαρακτηριστικών.




Σχήμα 4.5: Κατάταξη χαρακτηριστικών βάσει F -score από ANOVA test ως προς το label.



Σχήμα 4.6: p -values των χαρακτηριστικών από ANOVA test.

Από τις γραφικές παραστάσεις των *KDE*, *boxplots* ως κορυφαία διακριτικά χαρακτηριστικά παρουσιάζονται τα *Spectral Centroid*, *Spectral Bandwidth*, *Spectral Flatness*, *ZCR*, καθώς και οι συντελεστές *MFCC_0*, *MFCC_8* και *MFCC_12*. Από το *Feature-Class heatmap* αναδεικνύονται επιπλέον τα *MFCC_1*, *MFCC_2*, *MFCC_6* και ορισμένες ζώνες *Log-Mel* (ιδίως οι *Log_Mel_0*, *Log_Mel_3*, *Log_Mel_5*, *Log_Mel_7*). Τέλος, τα αποτελέσματα της ANOVA επιβεβαιώνουν τα παραπάνω, κατατάσσοντας επίσης πολύ ψηλά τα *Spectral Centroid*, *ZCR*, *Spectral Bandwidth* και συγκεκριμένους συντελεστές *MFCC*. Συνεπώς, η συγκεκριμένη στατιστική μελέτη απέδειξε πως η επιλογή **15–20 κορυφαίων χαρακτηριστικών** από τα 41 συνολικά επαρκεί για την επίτευξη της μέγιστης απόδοσης, καθιστώντας τη χρήση του πλήρους διανύσματος χαρακτηριστικών μη απαραίτητη και εν δυνάμει επιζήμια λόγω αυξημένου θορύβου ή πλεονασμού. Αυτή η διαπίστωση επιβεβαιώνεται και από τη παρακάτω γραφική παράσταση, από την οποία παρατηρούμε ότι η απόδοση της ταξινόμησης με χρήση του αλγορίθμου *k-NN* αυξάνεται ραγδαία έως 67 % όταν χρησιμοποιούμε τα κορυφαία 15-20 χαρακτηριστικά τα οποία είδαμε ότι παρουσιάζουν τη μέγιστη διακριτική ικανότητα. Από εκεί και έπειτα αγγίζει ένα κατώφλι στο οποίο συγχλίνει όσα επιπλέον χαρακτηριστικά και να κρατήσουμε, γεγονός που επιβεβαιώνει ότι η χρήση επιπλέον χαρακτηριστικών δεν προσφέρει καμία νέα ή χρήσιμη πληροφορία στα μοντέλα.



Σχήμα 4.7: Μεταβολή απόδοσης ταξινόμησης του k-NN ως προς το πλήθος χαρακτηριστικών.

Το τελικό υποσύνολο με τα πιο διακριτικά χαρακτηριστικά που αξίζει να διατηρηθούν φαίνεται παρακάτω:


<i>MFCC_5</i>	<i>MFCC_2</i>	<i>Spectral Rolloff</i>	<i>MFCC_6</i>
<i>On Set Envelope</i>	<i>MFCC_9</i>	<i>MFCC_8</i>	<i>Log_Mel_5</i>
<i>MFCC_11</i>	<i>Spectral Centroid</i>	<i>Spectral Bandwidth</i>	<i>Log_Mel_4</i>
<i>MFCC_7</i>	<i>RMS Energy</i>	<i>Spectral Flux</i>	<i>Log_Mel_6</i>
<i>MFCC_4</i>	<i>MFCC_3</i>	<i>MFCC_1</i>	<i>Zero Crossing Rate</i>

Πίνακας 4.2: Τα 20 κορυφαία επιλεγμένα χαρακτηριστικά


4.3 Διερεύνηση μετατόπισης πεδίου

Για την διερεύνηση της ύπαρξης μετατόπισης πεδίου πάνω στα δικά μας δεδομένα που μελετήσαμε μπορούμε αρχικά να ασχοληθούμε με την οπτικοποίηση των εξαγμένων ακουστικών χαρακτηριστικών αν τα σχεδιάσουμε πάλι στις 2 διαστάσεις αλλά ως προς τις διαφορετικές συσκευές τώρα αντί για τις διαφορετικές κλάσεις. Για την ακρίβεια, παρατηρείται ότι τα δείγματα που προέρχονται από τις τέσσερις διαφορετικές συσκευές σχηματίζουν διακριτά και εν μέρει απομονωμένα υποσύνολα στον χώρο των δύο πρώτων κύριων συνιστωσών. Η διακριτότητα αυτή κατά κύρια βάση προερχόμενη από τις συσκευές Litt3200 και AKGC417L μαρτυρά την ύπαρξη σαφών στατιστικών διαφορών μεταξύ των πηγών, γεγονός που συνιστά ένδειξη ύπαρξης μετατόπισης πεδίου. Αντίθετα, όταν η ίδια οπτικοποίηση πραγματοποιηθεί με βάση τις κλάσεις των αναπνευστικών ήχων, παρατηρείται ότι τα δείγματα των κατηγοριών εμφανίζουν σημαντική αλληλοεπικάλυψη στον χώρο των δύο πρώτων κύριων συνιστωσών. Αν και υπάρχουν περιοχές όπου οι παθολογικοί ήχοι τείνουν να ομαδοποιούνται, η γενικότερη ει-

κόνα καταδεικνύει ότι η διάκριση μεταξύ των κλάσεων δεν είναι ευδιάκριτη σε αυτό το επίπεδο αναπαράστασης. Το εύρημα αυτό είναι συνεπές με τη φύση των αναπνευστικών ήχων, οι οποίοι συχνά παρουσιάζουν παρόμοια ακουστικά χαρακτηριστικά με μόνο λεπτές διαφορές που μπορούν να αποτυπωθούν επαρκώς μέσω πιο εξειδικευμένων χαρακτηριστικών ή μη γραμμικών μοντέλων.




Σχήμα 4.8: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής.



Σχήμα 4.9: 2D απεικόνιση των δεδομένων του dataset με χρήση PCA.

Επίσης, μια καλή και γρήγορη τεχνική για να εκτιμήσουμε το πόσο ξεκάθαρη είναι η συμπε-

ριφορά κάθε συσκευής στα χαρακτηριστικά μας είναι να εκπαιδεύσουμε ένα απλό στατιστικό μοντέλο ώστε να προβλέπει από ποιά συσκευή προέρχεται κάθε διάνυσμα χαρακτηριστικών. Όσο μεγαλύτερη είναι η ακρίβεια, τόσο πιο έντονη είναι η επίδραση του *domain shift*, καθώς το μοντέλο μπορεί εύκολα να διακρίνει τις διαφορετικές συσκευές. Όσο πιο κοντά στη τυχαία πρόβλεψη συγκλίνει το μοντέλο, δηλαδή 25 % εφόσον έχουμε τέσσερις συσκευές, τόσο πιο αποτελεσματική θα είναι και η επίδραση του *domain adaptation* αφού το μοντέλο θα δυσκολεύεται αρκετά να διαχωρίσει τις συσκευές μεταξύ τους. Από το μητρώο σύγχυσης καθώς και από το γεγονός ότι η μέση ακρίβεια του μοντέλου είναι 0.8043 ± 0.0176 μπορούμε για ακόμη μια φορά να συμπεράνουμε ότι οι συσκευές έχουν **σημαντική διαφοροποίηση** μεταξύ τους, η οποία είναι εύκολο να εντοπιστεί από οποιοδήποτε απλό στατιστικό μοντέλο.




Σχήμα 4.10: Μητρώο σύγχυσης για το μοντέλο ταξινόμησης συσκευών.

4.4 Εκπαίδευση νευρωνικών δικτύων για προσαρμογή πεδίου

Για το συμβατικό *DANN* χρησιμοποιήθηκε *categorical cross-entropy loss* για το L_y , *mean squared error loss* για το L_d και έπειτα από διερεύνηση αποφασίστηκε η τιμή $\lambda = 0.1$. Η εκπαίδευση του δικτύου διαρκεί 200 *epochs*, η βελτιστοποίηση των συναρτήσεων κόστους γίνεται με τη χρήση *Adam* και χρησιμοποιείται ρυθμός μάθησης ίσος με $\eta = 0.001$. Επίσης, χρησιμοποιήθηκε εκθετικά αυξανόμενη τιμή στο διάστημα $[0, 1]$ για την αρνητική σταθερά α στο *GRL* σύμφωνα με τη φόρμουλα:

$$\alpha_{epoch} = \frac{2}{1 + e^{-10 \cdot \frac{epoch}{200}}} - 1$$

Παρακάτω βλέπουμε τις γραφικές παραστάσεις των συναρτήσεων κόστους L_y και L_d , καθώς και της συνολικής απώλειας:



Σχήμα 4.11: Συναρτήσεις κόστους του DANN.

Βλέπουμε ότι η συνολική απώλεια (*Total Loss*) παρουσιάζει σταθερή πτωτική τάση και για το *train* και για το *validation set*, γεγονός που υποδεικνύει ομαλή σύγκλιση του μοντέλου χωρίς ενδείξεις υπερπροσαρμογής. Η απώλεια ταξινόμησης (*Classification Loss*) μειώνεται και αυτή προοδευτικά σε όλη τη διάρκεια της εκπαίδευσης υποδεικνύοντας ότι ο *Label Classifier* βελτιώνει σταδιακά την ικανότητά του να διαχωρίζει τις κλάσεις αναπνευστικών ήχων. Τέλος, η απώλεια πεδίου (*Domain Loss*) στα πρώτα *epochs* αυξάνεται γρήγορα και στη συνέχεια σταθεροποιείται κοντά στην τιμή 0.25, το οποίο σημαίνει ότι σταδιακά αρχίζει και αποπροσανατολίζεται. Το αποτέλεσμα αυτό είναι αναμενόμενο, καθώς σε πρόβλημα με 4 *domains* η ιδανική «κατάσταση σύγχυσης» αντιστοιχεί σε ομοιόμορφη κατανομή πιθανοτήτων ($p_i = 0.25$ για κάθε *domain*). Πιο συγκεκριμένα, εφόσον το σύστημα καλείται να διακρίνει μεταξύ $K = 4$ *domains* με *one-hot* ετικέτες $y = (y_1, y_2, y_3, y_4)$ τότε ο *Domain Classifier* για το σωστό *domain* j θα έχει κόστος:

$$(y_j - p_j)^2 = (1 - 0.25)^2 = 0.75^2 = 0.5625,$$

και για τα υπόλοιπα τρία:

$$(y_i - p_i)^2 = (0 - 0.25)^2 = 0.25^2 = 0.0625.$$

Άρα το συνολικό κόστος θα πρέπει να συγκλίνει κοντά στο:


$$MSE = \frac{1}{4} (0.5625 + 3 \times 0.0625) = \frac{1}{4} (0.5625 + 0.1875) = \frac{0.75}{4} = 0.1875.$$

Η σύγκλιση της καμπύλης κοντά στο συγκεκριμένο επίπεδο αποτελεί ένδειξη ότι οι εξαγόμενες αναπαραστάσεις έχουν αποπροσανατολιστεί ικανοποιητικά ως προς τον τομέα, ωστόσο υπάρχει κάποιο περιθώριο βελτίωσης εφόσον το 0.25 έχει κάποια μικρή απόκλιση από το 0.1875.


Συνολικά, οι καμπύλες δείχνουν ότι το DANN πέτυχε **επιθυμητή ισορροπία μεταξύ της βελτίωσης της ακρίβειας ταξινόμησης και της μείωσης της πληροφορίας τομέα** στις εξαγόμενες αναπαραστάσεις.

Στη πράξη, ως προς τη συσκευή παρατηρείται σημαντική ανάμειξη δειγμάτων από διαφορετικές συσκευές, παρ' όλα αυτά, μικρές συστάδες με κυριαρχία συγκεκριμένων συσκευών όπως η Litt3200 παραμένουν, υποδεικνύοντας ότι η πλήρης εξάλειψη του *domain shift* δεν έχει επιτευχθεί. Επιπλέον, ως προς τις κλάσεις η απεικόνιση δείχνει ότι η διαχωρισιμότητα μεταξύ

των τριών κλάσεων παραμένει μερικώς περιορισμένη, με σημαντική επικάλυψη ιδιαίτερα μεταξύ των *Normal* και *Crackle*. Συνολικά δηλαδή το *DANN* επιτυγχάνει εν μέρει τον κύριο στόχο του, δηλαδή την προσαρμογή τομέα μέσω της απομάκρυνσης της πληροφορίας συσκευής, ωστόσο η διχωρισιμότητα ως προς τις κλάσεις θα μπορούσε να βελτιωθεί περαιτέρω και αυτή με τεχνικές *class-conditional alignment*, όπως και το *Spectrum Correction*.



Σχήμα 4.12: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή *DANN*.




Σχήμα 4.13: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή *DANN*.

Για το *CDAN* η εκπαίδευση πραγματοποιείται ακριβώς με τον ίδιο τρόπο με πριν αλλά με τιμή $\lambda = 0.2$ και διαρκεί πάλι 200 *epochs*, η βελτιστοποίηση των συναρτήσεων κόστους γίνεται


με τη χρήση *Adam* και χρησιμοποιείται ρυθμός μάθησης ίσος με $\eta = 0.001$. Τέλος, χρησιμοποιήθηκε η ίδια εκθετικά αυξανόμενη τιμή στο διάστημα $[0, 1]$ για την αρνητική σταθερά α στο *GRL*.

Παρακάτω βλέπουμε τις γραφικές παραστάσεις των συναρτήσεων κόστους L_y και L_d , καθώς και της συνολικής απώλειας. Η εξέλιξή τους δείχνει επίσης σταθερή βελτίωση της απόδοσης του μοντέλου καθ' όλη τη διάρκεια των *epochs*. Στο **Total Loss**, παρατηρείται συνεχής μείωση τόσο για τα δεδομένα εκπαίδευσης όσο και για τα δεδομένα επικύρωσης, γεγονός που υποδηλώνει ότι το μοντέλο προσαρμόζεται αποτελεσματικά χωρίς να εμφανίζει σημαντικά σημάδια υπερπροσαρμογής. Το **Classification Loss** ακολουθεί αντίστοιχη πτωτική πορεία και συγκλίνει πιο κοντά στο 0 αυτή τη φορά, επιβεβαιώνοντας ότι η προσαρμογή τομέα μέσω του *class-conditional* μηχανισμού δεν θυσιάζει την ακρίβεια στην πρόβλεψη της κλάσης, αλλά αντίθετα τη βελτιώνει σταθερά. Συνολικά, σε σύγκριση με τις προηγούμενες καμπύλες, παρατηρείται μια πιο ομαλή σύγκλιση και στις δύο περιπτώσεις, καθώς μειώνονται σταθερά χωρίς έντονες διακυμάνσεις. Όσον αφορά το **Domain Loss**, παρατηρείται γρήγορη αύξηση στις αρχικές εποχές μέχρι να σταθεροποιηθεί σε επίπεδο πιο κοντά στη θεωρητική τιμή σύγχυσης για $K = 4$ domains (0.1875). Αυτό υποδηλώνει βελτιωμένη ισορροπία ανάμεσα στη βελτίωση της ταξινόμησης και στην αποπλαισίωση των *domain dependent* χαρακτηριστικών, σε σχέση με τα προηγούμενα πειράματα όπου η απώλεια τομέα εμφάνιζε λίγο μεγαλύτερη απόκλιση.




Σχήμα 4.14: Συναρτήσεις κόστους του CDAN.

Αυτή τη φορά ως προς τη συσκευή παρατηρείται πολύ πιο βελτιωμένη ανάμειξη δειγμάτων από διαφορετικές συσκευές, με σχεδόν καθόλου ξεκάθαρα σχηματισμένες συστάδες. Συνεπώς, η συνολική εικόνα δείχνει μεγαλύτερη ομοιογένεια σε σχέση με το *DANN*. Ως προς τις κλάσεις μπορούμε να πούμε πως η διαχωρισσιμότητα μεταξύ των τριών κλάσεων έχει βελτιωθεί επίσης αισθητά. Ιδιαίτερα, η κλάση *Wheeze* σχηματίζει πλέον πιο συμπαγή και διακριτή συστάδα, ενώ η επικάλυψη μεταξύ *Normal* και *Crackle* έχει μειωθεί σε μεγάλο βαθμό. Αυτό οφείλεται στο *class-conditional alignment* που επιτυγχάνει το CDAN, καθώς ο *Domain classifier* λαμβάνει υπόψη τόσο τα χαρακτηριστικά $\mathbf{f}$ όσο και τις προβλέψεις κλάσης $\hat{\mathbf{y}}$, ευθυγραμμίζοντας τις κατανομές υπό συνθήκη $P(\mathbf{f} | y)$ και όχι μόνο τις οριακές $P(\mathbf{f})$. Τα αποτελέσματα αυτά επιβεβαιώνουν τη θεωρητική υπεροχή του CDAN έναντι του *DANN* ειδικά όταν η πληροφορία της κλάσης παίζει κρίσιμο ρόλο στη διαδικασία του *domain adaptation*.




Σχήμα 4.15: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την εφαρμογή CDAN.



Σχήμα 4.16: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την εφαρμογή CDAN.

Τέλος, για το *DANN* με *VAE* στη συγκεκριμένη εργασία χρησιμοποιείται ***KL-divergence loss*** για το L_{KL} , ***mean squared error loss*** για το L_{rec} και έπειτα από διερεύνηση αποφασίστηκαν οι τιμές $\lambda = 1.0$ για το συμβατικό *DANN* και $\beta = 0.1$ για το *VAE*. Για την εκπαίδευση η διάσταση του λανθάνοντα χώρου του *VAE* έχει οριστεί σε 16, η βελτιστοποίηση των συναρτήσεων κόστους γίνεται με τη χρήση *Adam* και χρησιμοποιείται ρυθμός μάθησης ίσος με $\eta = 0.001$. Τέλος, πάλι χρησιμοποιήθηκε εκθετικά αυξανόμενη τιμή στο διάστημα $[0, 1]$ για την αρνητική σταθερά α στο *GRL*.

(α) **Ταυτόχρονη εκπαίδευση (Joint training)** Με το συγκεκριμένο τρόπο εκπαίδευσης το δίκτυο εκπαιδεύεται για **100 epochs** και παρακάτω βλέπουμε τις καμπύλες των συναρτήσεων κόστους κατά τη διάρκειά της:



Σχήμα 4.17: Συναρτήσεις κόστους κατά την ταυτόχρονη εκπαίδευση.

Αρχικά, βλέπουμε πως η απώλεια ταξινόμησης παραμένει σε πολύ πιο χαμηλά επίπεδα σχεδόν κοντά στο 0, γεγονός που επιβεβαιώνει ότι ο ταξινομητής συνεχίζει να βελτιώνει την ικανότητά του να διαχωρίζει σωστά τις κλάσεις αναπνευστικών ήχων. Η απώλεια ανακατασκευής σταθεροποιείται και αυτή μετά από λίγα *epochs* γύρω στο 0.18, καταδεικνύοντας ότι ο αποκωδικοποιητής του VAE μπορεί να αναπαράγει το αρχικό σήμα με ικανοποιητική ακρίβεια.


Η απώλεια ταξινόμησης πεδίου όμοια με πριν αυξάνεται και σταθεροποιείται γύρω από τη θεωρητική τιμή πλήρους σύγχυσης. Σε αυτή τη περίπτωση, με *Categorical Cross-Entropy Loss* και με $K = 4$ domains η θεωρητική βέλτιστη τιμή απώλειας είναι:

$$\mathcal{L}_{CE} = - \sum_{i=1}^K y_i \log p_i = - \log \frac{1}{K} = \log K = \log 4 \approx 1.386.$$


Η σύγκλιση των καμπυλών κοντά στο 1.38 επιβεβαιώνει ότι έχει επιτευχθεί ουσιαστικός αποπροσανατολισμός των χαρακτηριστικών σε σχέση με το πεδίο.

Τέλος, όσον αφορά την *KL Divergence*, το ζητούμενο είναι μια ενδιάμεση ισορροπία, δηλαδή να μην μηδενίζεται, καθώς τότε ο λανθάνων χώρος δεν θα μετέφερε επαρκή πληροφορία, αλλά ούτε να αυξάνεται ανεξέλεγκτα. Συγκεκριμένα, παρατηρείται ότι ξεκινά από τιμή περίπου 1 και σταθεροποιείται γύρω στο 2. Η συμπεριφορά αυτή είναι ενδεικτική επιτυχούς εκπαίδευσης, καθώς δείχνει ότι ο VAE έμαθε λανθάνουσες αναπαραστάσεις που διατηρούν την απαραίτητη πληροφορία για ανακατασκευή, παραμένοντας ταυτόχρονα αρκετά κοντά στην κανονική *a priori* κατανομή $\mathcal{N}(0, I)$ ώστε να εξασφαλίζεται η γενίκευση του μοντέλου.

Συνολικά, τα αποτελέσματα δείχνουν ότι η ταυτόχρονη εκπαίδευση VAE και DANN συνδυάζει τα πλεονεκτήματα των δύο προσεγγίσεων, προσφέροντας **σταθερές και κανονικοποιημένες αναπαραστάσεις** με αυξημένη ανθεκτικότητα σε μεταβολές τομέα και υψηλή διακριτική ικανότητα ως προς τις κλάσεις.




Σχήμα 4.18: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την ταυτόχρονη εκπαίδευση.




Σχήμα 4.19: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την ταυτόχρονη εκπαίδευση.


(β) **Διαδοχική εκπαίδευση (*Sequential training*)** (Zonoozi et al. 2024) Με το συγκεκριμένο τρόπο εκπαίδευσης ο *VAE* εκπαιδεύεται πρώτα για **30 epochs** και έπειτα το *DANN* για άλλα **100 epochs**. Παρακάτω βλέπουμε τις καμπύλες των συναρτήσεων κόστους κατά τη διάρκειά των δύο φάσεων εκπαίδευσης. Σε σύγκριση με τα προηγούμενα αποτελέσματα, το *Reconstruction Loss* σταθεροποιείται ταχύτερα και σε χαμηλότερη τιμή, ενώ η *KL Divergence* εμφανίζει πιο ελεγχόμενη πορεία, με αρχική αύξηση και σταδιακή σταθεροποίηση σε χαμηλότερο επίπεδο. Το *Classification Loss* μειώνεται γρήγορα και συγκλίνει χαμηλότερα, γεγονός που υποδηλώνει βελτιωμένη ταξινομητική ικανότητα. Τέλος, το *Domain Loss* φτάνει ξανά ομαλά στη θεωρητική τιμή πλήρους σύγχυσης για $K = 4$ domains ($\log 4 \approx 1.386$), δείχνοντας για ακόμη μια φορά σταθερή και αξιόπιστη αποπλαισίωση.



Σχήμα 4.20: Συναρτήσεις κόστους κατά την διαδοχική εκπαίδευση.



Σχήμα 4.21: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές συσκευές καταγραφής μετά την διαδοχική εκπαίδευση.




Σχήμα 4.22: 2D απεικόνιση των εξαγμένων χαρακτηριστικών ως προς τις διαφορετικές κλάσεις μετά την διαδοχική εκπαίδευση.

Όμοια και εδώ η εκ των προτέρων εκπαίδευση του *VAE* φαίνεται να έχει καταφέρει μάνθει αναπαραστάσεις που διατηρούν πολύ καλά την πληροφορία της κλάσης, ενώ το *DANN* εξαλείφει την πληροφορία τομέα χωρίς να θυσιάζει τη διακριτική ικανότητα.

4.5 Ρύθμιση υπερπαραμέτρων αλγορίθμων ταξινόμησης

Από τη διαδικασία αυτή προέκυψαν οι παρακάτω βέλτιστοι συνδυασμοί υπερπαραμέτρων για κάθε μοντέλο:



Σχήμα 4.23: Βέλτιστοι συνδυασμοί υπερπαραμέτρων για κάθε μοντέλο ταξινόμησης.

Για το *k-NN* επιλέχθηκε η δεύτερη καλύτερη τιμή του k , δηλαδή $k = 3$, αντί για $k = 1$ όπου ελέγχεται αποκλειστικά ο κοντινότερος γείτονας, με σκοπό την ανθεκτικότητα σε ακραίες τιμές. Για το *Non-Linear SVM* επιλέχθηκε $C = 10$ και για $\gamma = 1/(n_{\text{features}} \cdot \text{Var}(X))$, δηλαδή το *scale*. Για το *Random Forest* επιλέχθηκαν $n_{\text{estimators}} = 200$ και $\text{min_samples_split} = 2$. Τέλος, για το *XGBoost* έχουμε $n_{\text{estimators}} = 200$, $\text{max_depth} = 10$ και $\text{learning_rate} = 0.1$.

4.6 Αποτελέσματα αλγορίθμων ταξινόμησης

Η διαδικασία της ταξινόμησης πραγματοποιήθηκε πάνω σε ένα σύνολο ελέγχου που περιέχει εγγραφές από όλες τις συσκευές καταγραφής. Το σενάριο αυτό προσομοιώνει ένα μεικτό περιβάλλον αξιολόγησης, όπου οι συνθήκες καταγραφής (συσκευές) ποικίλλουν εντός του συ-

νόλου ελέγχου. Με τον τρόπο αυτό εκτιμάται η ικανότητα του εκάστοτε μοντέλου να διατηρεί σταθερή απόδοση σε ετερογενή δεδομένα, αλλά και να εκμεταλλεύεται την πιθανή παρουσία κοινών χαρακτηριστικών μεταξύ διαφορετικών συσκευών.

4.6.1 Συνολικές μετρικές

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.71	0.84	0.71
Spectrum Correction	0.73 (+2.8%)	0.84	0.73
DANN	0.75 (+5.6%)	0.84	0.75
CDAN	0.77 (+8.5%)	0.86	0.77
DANN με VAE (1 φάση)	0.76 (+7%)	0.84	0.71
DANN με VAE (2 φάσεις)	0.76 (+7%)	0.85	0.74

Πίνακας 4.3: Συνολικές μετρικές ταξινόμησης k-NN για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.68	0.78	0.66
Spectrum Correction	0.74 (+8.8%)	0.84	0.74
DANN	0.71 (+4.4%)	0.79	0.69
CDAN	0.77 (+13.2%)	0.86	0.77
DANN με VAE (1 φάση)	0.74 (+8.8%)	0.85	0.74
DANN με VAE (2 φάσεις)	0.74 (+8.8%)	0.84	0.73

Πίνακας 4.4: Συνολικές μετρικές ταξινόμησης SVM για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.71	0.83	0.70
Spectrum Correction	0.72 (+1.4%)	0.85	0.71
DANN	0.72 (+1.4%)	0.83	0.70
CDAN	0.74 (+4.2%)	0.86	0.72
DANN με VAE (1 φάση)	0.74 (+4.2%)	0.84	0.74
DANN με VAE (2 φάσεις)	0.74 (+4.2%)	0.85	0.75

Πίνακας 4.5: Συνολικές μετρικές ταξινόμησης Random Forest για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	Accuracy	Macro AUC	Weighted F1 score
Baseline	0.73	0.84	0.72
Spectrum Correction	0.73	0.86	0.73
DANN	0.74 (+1.4%)	0.84	0.74
CDAN	0.76 (+4.1%)	0.87	0.76
DANN με VAE (1 φάση)	0.75 (+2.7%)	0.84	0.73
DANN με VAE (2 φάσεις)	0.75 (+2.7%)	0.85	0.74

Πίνακας 4.6: Συνολικές μετρικές ταξινόμησης XGBoost για κάθε μέθοδο προσαρμογής πεδίου.

4.6.2 Μετρικές ανά κλάση

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.78	0.73	0.78	0.77	0.50
<i>Spectrum Correction</i>	0.79	0.78	0.75	0.80	0.52
<i>DANN</i>	0.80	0.80	0.73	0.80	0.54
<i>CDAN</i>	0.82	0.81	0.76	0.82	0.57
<i>DANN με VAE (1 φάση)</i>	0.80	0.81	0.71	0.79	0.52
<i>DANN με VAE (2 φάσεις)</i>	0.79	0.80	0.72	0.79	0.52

Πίνακας 4.7: Μετρικές ταξινόμησης k-NN για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.66	0.61	0.90	0.71	0.53
<i>Spectrum Correction</i>	0.67	0.73	0.83	0.63	0.53
<i>DANN</i>	0.68	0.71	0.85	0.66	0.55
<i>CDAN</i>	0.72	0.75	0.86	0.69	0.59
<i>DANN με VAE (1 φάση)</i>	0.68	0.68	0.87	0.68	0.55
<i>DANN με VAE (2 φάσεις)</i>	0.69	0.70	0.86	0.67	0.56

Πίνακας 4.8: Μετρικές ταξινόμησης k-NN για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.51	0.44	0.99	0.66	0.56
<i>Spectrum Correction</i>	0.61	0.56	0.96	0.67	0.56
<i>DANN</i>	0.67	0.60	0.97	0.73	0.61
<i>CDAN</i>	0.67	0.61	0.97	0.74	0.63
<i>DANN με VAE (1 φάση)</i>	0.66	0.62	0.96	0.70	0.61
<i>DANN με VAE (2 φάσεις)</i>	0.66	0.63	0.96	0.70	0.62

Πίνακας 4.9: Μετρικές ταξινόμησης k-NN για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.76	0.86	0.49	0.69	0.39
<i>Spectrum Correction</i>	0.80	0.85	0.64	0.76	0.50
<i>DANN</i>	0.77	0.80	0.86	0.71	0.42
<i>CDAN</i>	0.82	0.83	0.73	0.80	0.56
<i>DANN με VAE (1 φάση)</i>	0.79	0.79	0.72	0.79	0.50
<i>DANN με VAE (2 φάσεις)</i>	0.78	0.78	0.71	0.78	0.50

Πίνακας 4.10: Μετρικές ταξινόμησης SVM για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.62	0.55	0.91	0.71	0.50
<i>Spectrum Correction</i>	0.66	0.62	0.89	0.71	0.54
<i>DANN</i>	0.60	0.53	0.89	0.67	0.46
<i>CDAN</i>	0.72	0.71	0.89	0.73	0.61
<i>DANN με VAE (1 φάση)</i>	0.67	0.66	0.88	0.68	0.54
<i>DANN με VAE (2 φάσεις)</i>	0.67	0.66	0.87	0.68	0.54

Πίνακας 4.11: Μετρικές ταξινόμησης SVM για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.49	0.35	0.99	0.79	0.48
<i>Spectrum Correction</i>	0.64	0.56	0.97	0.75	0.60
<i>DANN</i>	0.51	0.40	0.97	0.69	0.47
<i>CDAN</i>	0.68	0.65	0.96	0.71	0.63
<i>DANN με VAE (1 φάση)</i>	0.66	0.67	0.95	0.66	0.62
<i>DANN με VAE (2 φάσεις)</i>	0.66	0.67	0.95	0.65	0.61

Πίνακας 4.12: Μετρικές ταξινόμησης SVM για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.80	0.90	0.54	0.72	0.47
<i>Spectrum Correction</i>	0.79	0.88	0.55	0.72	0.47
<i>DANN</i>	0.79	0.89	0.52	0.72	0.44
<i>CDAN</i>	0.80	0.90	0.54	0.72	0.49
<i>DANN με VAE (1 φάση)</i>	0.78	0.78	0.71	0.78	0.49
<i>DANN με VAE (2 φάσεις)</i>	0.80	0.81	0.70	0.78	0.52

Πίνακας 4.13: Μετρικές ταξινόμησης Random Forest για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.55	0.50	0.88	0.63	0.40
<i>Spectrum Correction</i>	0.63	0.56	0.90	0.70	0.50
<i>DANN</i>	0.60	0.54	0.91	0.70	0.48
<i>CDAN</i>	0.65	0.59	0.91	0.73	0.54
<i>DANN με VAE (1 φάση)</i>	0.68	0.67	0.87	0.69	0.55
<i>DANN με VAE (2 φάσεις)</i>	0.67	0.65	0.88	0.68	0.53

Πίνακας 4.14: Μετρικές ταξινόμησης Random Forest για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.45	0.33	0.98	0.69	0.43
<i>Spectrum Correction</i>	0.56	0.44	0.98	0.76	0.54
<i>DANN</i>	0.48	0.35	0.99	0.77	0.47
<i>CDAN</i>	0.51	0.35	1.00	0.94	0.54
<i>DANN με VAE (1 φάση)</i>	0.67	0.68	0.95	0.66	0.62
<i>DANN με VAE (2 φάσεις)</i>	0.67	0.65	0.95	0.69	0.61

Πίνακας 4.15: Μετρικές ταξινόμησης Random Forest για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.79	0.84	0.63	0.75	0.48
<i>Spectrum Correction</i>	0.79	0.84	0.62	0.75	0.53
<i>DANN</i>	0.80	0.85	0.65	0.76	0.52
<i>CDAN</i>	0.81	0.84	0.69	0.78	0.54
<i>DANN με VAE (1 φάση)</i>	0.79	0.79	0.71	0.78	0.50
<i>DANN με VAE (2 φάσεις)</i>	0.79	0.80	0.71	0.78	0.51


Πίνακας 4.16: Μετρικές ταξινόμησης XGBoost για τη κλάση Normal για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.65	0.82	0.75	0.62	0.53
<i>Spectrum Correction</i>	0.65	0.60	0.90	0.72	0.54
<i>DANN</i>	0.72	0.64	0.89	0.76	0.55
<i>CDAN</i>	0.70	0.69	0.89	0.72	0.59
<i>DANN με VAE (1 φάση)</i>	0.66	0.66	0.86	0.66	0.53
<i>DANN με VAE (2 φάσεις)</i>	0.66	0.66	0.88	0.68	0.54


Πίνακας 4.17: Μετρικές ταξινόμησης XGBoost για τη κλάση Crackle για κάθε μέθοδο προσαρμογής πεδίου.

Μέθοδος	<i>F1 score</i>	<i>Sensitivity</i>	<i>Specificity</i>	<i>Precision</i>	<i>MCC</i>
<i>Baseline</i>	0.57	0.51	0.95	0.64	0.51
<i>Spectrum Correction</i>	0.62	0.57	0.96	0.69	0.57
<i>DANN</i>	0.59	0.51	0.97	0.71	0.55
<i>CDAN</i>	0.66	0.59	0.97	0.75	0.62
<i>DANN με VAE (1 φάση)</i>	0.66	0.66	0.94	0.65	0.60
<i>DANN με VAE (2 φάσεις)</i>	0.67	0.66	0.95	0.66	0.61


Πίνακας 4.18: Μετρικές ταξινόμησης XGBoost για τη κλάση Wheeze για κάθε μέθοδο προσαρμογής πεδίου.




Σχήμα 4.24: Αποτελέσματα k-NN: μητρώα σύγκρισης, καμπύλες ROC και Precision-Recall για κάθε μέθοδο προσαρμογής πεδίου.



Σχήμα 4.25: Αποτελέσματα SVM: μητρώα σύγχυσης, καμπύλες ROC και Precision-Recall για κάθε μέθοδο προσαρμογής πεδίου.



Σχήμα 4.26: Αποτελέσματα Random Forest: μητρώα σύγκρισης, καμπύλες ROC και Precision-Recall για κάθε μέθοδο προσαρμογής πεδίου.



Σχήμα 4.27: Αποτελέσματα XGBoost: μητρώα σύγκρισης, καμπύλες ROC και Precision-Recall για κάθε μέθοδο προσαρμογής πεδίου.

Κεφάλαιο 5

Επίλογος

5.1 Συμπεράσματα

Στο πλαίσιο της συνολικής απόδοσης των μεθόδων, το *Accuracy* παρέχει μια πιο γενική και συνοπτική εικόνα της συνολικής επίδοσης αν και σε ορισμένες περιπτώσεις η τιμή του μπορεί να είναι παραπλανητική λόγω της ανομοιομορφίας του συνόλου ελέγχου. Πιο συγκεκριμένα, η **μέγιστη ακρίβεια** ταξινόμησης που επιτεύχθηκε στην παρούσα εργασία μετά τη προσαρμογή πεδίου είναι το **77%**, ενώ παράλληλα η **μέγιστη αύξηση της ακρίβειας σε σχέση με το *baseline*** είναι το **13.2 %**, αποτελέσματα τα οποία προέρχονται από το **μη-γραμμικό *SVM***. Την ίδια ή σχεδόν την ίδια απόδοση φαίνεται πως άγγιζαν και οι αλγόριθμοι *k-NN* και *XGBoost* με τιμές ακρίβειας 0.77 και 0.76 αντίστοιχα. Ωστόσο, σε αυτές τις δύο περιπτώσεις η αύξηση συγκριτικά με το *baseline* ήταν μικρότερη και πιο συγκεκριμένα 8.5 % και 4.1 % αντίστοιχα. Από την άλλη, το *Random Forest* φαίνεται να εμφανίζει τις χαμηλότερες επιδόσεις, καθώς η βελτίωση μετά τη προσαρμογή πεδίου παραμένει περιορισμένη αγγίζοντας μόλις το 74 %.

Συμπληρωματικά με την ακρίβεια, ιδιαίτερη βαρύτητα σαν μετρικές έχουν τα *Macro AUC* και *Weighted F1 score*, καθώς λαμβάνουν υπόψη την κατανομή των δειγμάτων ανά κλάση, οπότε προσφέρουν μια πιο αντικειμενική αποτίμηση της απόδοσης. Το βέλτιστο ***Weighted F1 score*** που πετύχαμε είναι επίσης **77 %** από τα ίδια μοντέλα, ενώ το βέλτιστο ***Macro AUC*** είναι **0.87**, το οποίο προέρχεται από το ***XGBoost***. Οι τιμές αυτές των συγκεκριμένων μετρικών βρίσκονται εντός του επιθυμητού εύρους και θεωρούνται ικανοποιητικές, καθώς βρίσκονται κοντά στα όρια των *state-of-the-art* υλοποιήσεων για αντίστοιχα σενάρια. Επομένως και σε αυτή τη περίπτωση παρατηρούμε σημαντικές αυξήσεις των μετρικών της τάξης του **16.7 %** και **10.3 %** αντίστοιχα σε σχέση με το *baseline*. Αυτές οι τιμές καταδεικνύουν για ακόμη μια φορά ότι το προτεινόμενο σύστημα είναι σε θέση να διατηρήσει σταθερή και ανταγωνιστική απόδοση παρά την ετερογένεια των δεδομένων και τις προκλήσεις που εισάγει η διαφοροποίηση των συσκευών καταγραφής.

Συνεπώς, τα μοντέλα ***SVM*** και ***k-NN*** αναδεικνύονται ως **τα πλέον αποδοτικά μοντέλα** για την παρούσα εργασία, επιτυγχάνοντας τον καλύτερο συνδυασμό ακρίβειας, ισορροπίας ανά κλάση και ανθεκτικότητας σε φαινόμενα *domain shift*. Ο αλγόριθμος *k-NN* ειδι-

κότερα, αν και απλός, αποδεικνύεται ιδιαίτερα αποτελεσματικός όταν συνδυάζεται με τεχνικές προσαρμογής πεδίου. Τέλος, το *XGBoost* επιβεβαιώνει και αυτό τη φήμη του ως ένα από τα πιο ισχυρά *ensemble* μοντέλα, εμφανίζοντας σταθερά υψηλές τιμές ακρίβειας και *Macro AUC*. Σχεδόν σε όλα τα σενάρια προσαρμογής πεδίου οι καμπύλες *ROC* παραμένουν αρκετά υψηλά, ενώ οι καμπύλες *Precision-Recall* δείχνουν ανθεκτικότητα στις ψευδώς θετικές προβλέψεις.

Ωστόσο, στο πλαίσιο της ιατρικής διάγνωσης αναπνευστικών παθήσεων ιδιαίτερη έμφαση δίνεται στις μετρικές που σχετίζονται άμεσα με την ασφάλεια του ασθενούς και άρα την αποτελεσματικότητα της διάγνωσης. Συγκεκριμένα, η **Ευαισθησία** (*Sensitivity/Recall*) θα λέγαμε ότι είναι καθοριστικής σημασίας, καθώς μετρά το ποσοστό των πραγματικών θετικών περιστατικών που ανιχνεύονται σωστά. Η αύξησή της μειώνει την πιθανότητα εμφάνισης ψευδώς αρνητικών προβλέψεων, δηλαδή περιπτώσεων όπου ασθενείς με παθολογικό αναπνευστικό ήχο δεν αναγνωρίζονται από το σύστημα. Η βελτίωση είναι ακόμη πιο κρίσιμη μάλιστα όταν σημειώνεται στις κλάσεις ιατρικού ενδιαφέροντος, δηλαδή στις παθολογικές κλάσεις. Πιο συγκεκριμένα, στην κλάση **Crackle** παρατηρούμε ότι η ευαισθησία αυξήθηκε σημαντικά από 0.61 σε 0.75, δηλαδή κατά **23%**, από το μοντέλο **k-NN**. Η πιο εντυπωσιακή βελτίωση βέβαια παρατηρείται στην κλάση **Wheeze**, όπου η ευαισθησία με χρήση **Random Forest** αυξήθηκε κατά **106.06%** (από 0.33 σε 0.68) και ήρθε σε αρκετά ικανοποιητικά επίπεδα, παρά το γεγονός ότι διαθέτει τον μικρότερο αριθμό δειγμάτων στο σύνολο ελέγχου. Αυτό σημαίνει ότι πλέον το μοντέλο μόνο στο 32% των περιπτώσεων αποφαίνεται λανθασμένα ότι η αναπνευστική καταγραφή του ασθενούς περιέχει **Wheeze**, αντί για το 67% που ήταν πριν.

Παράλληλα και η **Ειδικότητα** (*Specificity*) διαδραματίζει και αυτή σημαντικό ρόλο, καθώς μετρά την ικανότητα του συστήματος να αναγνωρίζει σωστά τις αρνητικές περιπτώσεις, δηλαδή τα υγιή άτομα. Η υψηλή ειδικότητα μειώνει τον αριθμό ψευδώς θετικών προβλέψεων, αποτρέποντας την άσκοπη επιβάρυνση του συστήματος υγείας με περιττές εξετάσεις και μειώνοντας το άγχος των ασθενών. Ιδιαίτερα σε περιπτώσεις όπου η ευαισθησία έχει ήδη επιτευχθεί σε υψηλά επίπεδα, η ταυτόχρονη αύξηση και της ειδικότητας συμβάλλει στην εξισορρόπηση της απόδοσης και στην αύξηση της κλινικής αξιοπιστίας του συστήματος. Εδώ βλέπουμε ότι για τη κλάση **Crackle** η ειδικότητα με χρήση **XGBoost**, αν και ήδη αρκετά ικανοποιητική (0.75), παρουσίασε αύξηση **20 %** φτάνοντας το 0.90, γεγονός το οποίο σημαίνει ότι μόνο στο 10% των περιπτώσεων το μοντέλο μπερδεύει την μη ύπαρξη **Crackle** με ύπαρξη. Για την κλάση **Wheeze** από την άλλη με ειδικότητα εξ αρχής στο **σχεδόν 100 %** σε όλες τις περιπτώσεις μπορούμε να πούμε με σιγουριά ότι το μοντέλο ποτέ δεν μπερδεύει την μη ύπαρξη **Wheeze** με ύπαρξη.

Η τόσο μεγάλη συνολική βελτίωση στις παθολογικές περιπτώσεις ελέγχου αποδεικνύει ότι το σύστημα είναι πλέον σε θέση να ανιχνεύει με συνέπεια τα περισσότερα περιστατικά ασθενών με παθολογίες χωρίς να θυσιάζει την ικανότητά του να αναγνωρίζει τους υγιείς, γεγονός που αυξάνει άμεσα τη χρησιμότητά του ως εργαλείο υποστήριξης της διάγνωσης στην κλινική πράξη. Επίσης, μπορούμε να εξάγουμε το συμπέρασμα ότι **η μετατόπιση πεδίου που προκύπτει από τις διαφορές στις συσκευές καταγραφής επηρεάζει συχνά εντονότερα τους παθολογικούς ήχους σε σχέση με τους φυσιολογικούς**, γι' αυτό κιόλας η εφαρμογή της προσαρμογής πεδίου βελτίωσε πολύ περισσότερο τις μετρικές

των παθολογικών κλάσεων.

Επιπρόσθετα, ένα ακόμη πολύ σημαντικό συμπέρασμα στο οποίο καταλήξαμε είναι πως η **συμπερίληψη της πληροφορίας της κλάσης στη διαδικασία ευθυγράμμισης των κατανομών των πεδίων αποτελεί καθοριστικό παράγοντα για τη βελτίωση της συνολικής απόδοσης**. Αυτό μπορεί να διαπιστωθεί εύκολα παρατηρώντας όλες τις διαφορετικές μετρικές που υπολογίστηκαν, καθώς οι τεχνικές *CDAN* και *DANN* με χρήση *VAE* σαν *Feature Extractor* κατάφεραν να επιφέρουν τη μεγαλύτερη αύξηση σχεδόν σε κάθε περίπτωση σε σχέση με το κλασικό *DANN* και το *Spectrum Correction*. Για παράδειγμα, όσον αφορά τη συνολική ακρίβεια βλέπουμε ότι κατάφεραν να την αυξήσουν στη πλειοψηφία των πειραμάτων τουλάχιστον δύο με δύομιση φορές περισσότερο σε σχέση με το κλασικό *DANN* και το *Spectrum Correction*. Συνεπώς βλέπουμε ότι σε αντίθεση με προσεγγίσεις που επιδιώκουν ολική ευθυγράμμιση των κατανομών χαρακτηριστικών ανεξαρτήτως κλάσης, η υπό όρους ευθυγράμμιση (*class-conditional alignment*) επιτρέπει την προσαρμογή με τρόπο που διατηρεί τη διαχωριστικότητα μεταξύ των κλάσεων. Αυτό πρακτικά σημαίνει ότι κατά τη σύγκλιση των κατανομών χαρακτηριστικών, η πληροφορία που σχετίζεται με το σε ποιά συσκευή ανήκει ένα δείγμα συσχετίζεται άμεσα με το πώς η συγκεκριμένη συσκευή καταγράφει κάθε κλάση. Με αυτόν τον τρόπο, η διαδικασία προσαρμογής δεν εξαλείφει απλώς τις διαφορές μεταξύ συσκευών, αλλά μαθαίνει και τις χαρακτηριστικές παραμορφώσεις ή ιδιαιτερότητες καταγραφής κάθε συσκευής για κάθε τύπο ήχου, επιτυγχάνοντας έτσι πιο ακριβή και κλινικά αξιόπιστη αντιστοίχιση.

5.2 Μελλοντικές επεκτάσεις

Η παρούσα διπλωματική εργασία κατέδειξε τη σημασία της αυτόματης ανάλυσης αναπνευστικών ήχων μέσω τεχνικών μηχανικής μάθησης και μεθόδων προσαρμογής πεδίου, εστιάζοντας ιδιαίτερα στην πρόκληση που δημιουργείται από την ετερογένεια συσκευών καταγραφής και συνθηκών ηχογράφησης. Παρότι τα αποτελέσματα είναι ενθαρρυντικά, ανοίγονται πολλά πλέθ κατευθύνσεις για περαιτέρω διερεύνηση και βελτίωση, οι οποίες μπορούν να ενισχύσουν την ακρίβεια, τη γενικευσιμότητα και την πρακτική εφαρμοσιμότητα των αναπτυγμένων μεθόδων.

Μια πρώτη επέκταση της προτεινόμενης μεθοδολογίας αφορά την αυτόματη και πιο εκτενή **εξαγωγή χαρακτηριστικών με χρήση τεχνικών βαθιάς μάθησης** αντί για χειροκίνητα επιλεγμένα χαρακτηριστικά. Για την ακρίβεια, η χειροκίνητη επιλογή στηρίζεται συνήθως σε προϋπάρχουσα γνώση και σε στατιστικά ή φασματικά μεγέθη, τα οποία αν και αποτυπώνουν σημαντικές πτυχές των αναπνευστικών ήχων, ενδέχεται να μην καταφέρνουν να συλλάβουν την πλήρη πολυπλοκότητα και τα λεπτομερή μοτίβα που χαρακτηρίζουν διαφορετικές παθολογίες. Αντίθετα, η αξιοποίηση αρχιτεκτονικών βαθιάς μάθησης, όπως τα συνελικτικά νευρωνικά δίκτυα (*CNNs*), τα αναδρομικά δίκτυα (*RNNs*) ή οι πιο πρόσφατοι μετασχηματιστές (*Transformers*), παρέχει τη δυνατότητα αυτόματης εκμάθησης χαρακτηριστικών απευθείας από τα δεδομένα, χωρίς την ανάγκη εκτεταμένης προεπεξεργασίας ή χειροκίνητου σχεδιασμού. Τα *CNNs*, για παράδειγμα, έχουν αποδειχθεί ιδιαίτερα αποδοτικά στην ανάλυση φασματο-

γραφικών αναπαραστάσεων, αναγνωρίζοντας τοπικά πρότυπα και χωρικές συσχετίσεις στις συχνότητες.

Συνολικά, η μετάβαση από χειροκίνητα σε αυτόματα χαρακτηριστικά μπορεί να αυξήσει σημαντικά τη διακριτική ισχύ των μοντέλων, να μειώσει την υποκειμενικότητα στη διαδικασία επιλογής, και να οδηγήσει σε συστήματα πιο ανθεκτικά στη μετατόπιση πεδίου, καθώς τα χαρακτηριστικά θα προκύπτουν άμεσα από τα ίδια τα δεδομένα και όχι από προϋποθέσεις που ενδέχεται να ισχύουν μόνο σε συγκεκριμένα σενάρια.

Ένα ακόμη πεδίο μελλοντικής διερεύνησης αφορά την ενσωμάτωση τεχνικών κανονικοποίησης φάσματος, όπως η **διόρθωση φάσματος** (*spectrum correction*), στο προτεινόμενο μεθοδολογικό πλαίσιο. Η συγκεκριμένη προσέγγιση, όπως έχει ήδη αποδειχθεί στη βιβλιογραφία, επιτυγχάνει τη μείωση της επίδρασης που ασκεί η ετερογένεια των συσκευών καταγραφής, μετασχηματίζοντας το φάσμα των ηχογραφήσεων ώστε να προσεγγίζει εκείνο μιας συσκευής αναφοράς. Η ενσωμάτωση της τεχνικής αυτής στο *pipeline* που αναπτύχθηκε στην παρούσα εργασία μπορεί να λειτουργήσει ως στάδιο προεπεξεργασίας πριν την εφαρμογή των μεθόδων προσαρμογής πεδίου βαθιάς μάθησης, δημιουργώντας ένα πιο «ουδέτερο» σετ χαρακτηριστικών και ενισχύοντας την αποτελεσματικότητα της επακόλουθης εκπαίδευσης. Με αυτόν τον τρόπο, θα μπορούσε να εξεταστεί αν ο συνδυασμός απλών τεχνικών κανονικοποίησης με πιο πολύπλοκα σχήματα ανταγωνιστικής μάθησης οδηγεί σε συστήματα πιο ανθεκτικά στη μετατόπιση πεδίου.

Επιπλέον, η ίδια η τεχνική της διόρθωσης φάσματος δύναται να επεκταθεί και να βελτιωθεί. Μια ενδιαφέρουσα πιθανή κατεύθυνση αφορά τη βελτίωση του τρόπου υπολογισμού των συντελεστών διόρθωσης φάσματος, ώστε η διαδικασία να είναι περισσότερο ανθεκτική στον θόρυβο που χαρακτηρίζει τις εκάστοτε καταγραφές. Πιο συγκεκριμένα, η ιδέα βασίζεται στην εισαγωγή σταθμισμένων εκτιμητών, όπου η συμβολή κάθε παρατήρησης καθορίζεται από δείκτες ποιότητας του σήματος, όπως ο λόγος σήματος προς θόρυβο (*SNR*). Με αυτόν τον τρόπο, οι θορυβώδεις ή λιγότερο αξιόπιστες καταγραφές θα αποκτούν μειωμένη βαρύτητα στην εκτίμηση των συντελεστών της εκάστοτε συσκευής, ενώ οι καθαρότερες θα συνεισφέρουν περισσότερο. Ο συνδυασμός σταθμισμένων εκτιμήσεων με στατιστικά ανθεκτικούς υπολογισμούς (π.χ. χρήση διαμέσου ή αντί του κλασικού μέσου όρου) ενισχύει περαιτέρω την αξιοπιστία των αποτελεσμάτων. Επιπλέον, η εφαρμογή τεχνικών εξομάλυνσης κατά μήκος της συχνότητας, για παράδειγμα μέσω κάποιας παρεμβολής *spline* ή *regularization* που ελέγχει την καμπυλότητα της γραφικής του διανύσματος συντελεστών διόρθωσης, μπορεί να αποτρέψει την εμφάνιση τεχνητών διακυμάνσεων και να διασφαλίσει μεγαλύτερη ομαλότητα.

Τέλος, σε επίπεδο πρακτικής εφαρμογής, οι μελλοντικές επεκτάσεις μπορούν να επικεντρωθούν στην ενσωμάτωση των αναπτυγμένων μοντέλων σε φορητές συσκευές και συστήματα τηλεϊατρικής. Η ανάπτυξη ελαφρών και αποδοτικών υλοποιήσεων που μπορούν να λειτουργήσουν σε πραγματικό χρόνο σε κινητές συσκευές ή σε συσκευές παρακολούθησης θα συμβάλει στη διάδοση της τεχνολογίας σε κλινικά και κατ' οίκον περιβάλλοντα, υποστηρίζοντας την έγκαιρη διάγνωση και παρακολούθηση των ασθενών.

Βιβλιογραφία

- [1] Cem Akkus, Luyang Chu, Vladana Djakovic, and Steffen Jauch-Walser. “Multimodal Deep Learning”. In: *arXiv preprint arXiv:2301.04856* (2023).
- [2] Elham Babaei, Nor Badrul Anuar, Ainuddin Wahid Abdul Wahab, Shahaboddin Shamshirband, and Anthony T. Chronopoulos. “An Overview of Audio Event Detection Methods from Feature Extraction to Classification”. In: *Applied Artificial Intelligence* (2017).
- [3] S. A. Babalola, S. I. Oluka, Nnenna Harmony Nwobodo-Nzeribe, S. Afam Eneh, and C. Lawrence Ozoemena. “Historical Development, Design Features and Function of a Stethoscope”. In: *International Journal of Research Publication and Reviews* (2023).
- [4] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [5] Leo Breiman. “Random Forests”. In: *Machine Learning* 45 (2001).
- [6] Tianqi Chen and Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016.
- [7] Jawad Ahmad Dar, Kamal Kr Srivastava, and Alok Mishra. “Lung anomaly detection from respiratory sound database (sound signals)”. In: *Computers in Biology and Medicine* (2023).
- [8] Gaoyang Dong, Yufei Shen, Jianhong Wang, Mingli Zhang, Ping Sun, Peiyu Sun, and Minghui Zhang. “Respiratory sounds classification by fusing the time-domain and 2D spectral features”. In: *Biomedical Signal Processing and Control* (2025).
- [9] Min Fan, Ziyun Cai, Tengfei Zhang, and Baoyun Wang. “A survey of deep domain adaptation based on label set classification”. In: *Neural Computing and Applications* (2022).
- [10] Abolfazl Farahani, Sahar Voghoei, Khaled Rasheed, and Hamid R. Arabnia. “A Brief Review of Domain Adaptation”. In: *Advances in Data Science and Information Engineering*. Ed. by Ralf Stahlbock, Georg M. Weiss, Mahmoud Abou-Nasr, Chih-Yuan Yang, Hamid R. Arabnia, and Leonidas Deligiannidis. Springer International Publishing, 2021.

- [11] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor Lempitsky. “Domain-Adversarial Training of Neural Networks”. In: *Journal of Machine Learning Research* 17 (2016).
- [12] Apar Garg, Yassine Aribi, Turke Althobaiti, and Tanmay Bhowmik. “An analysis of acoustic features for accented speech classification”. In: *Egyptian Informatics Journal* (2025).
- [13] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2009.
- [14] Md Tamzeed Islam and Shahriar Nirjon. “Sound-Adapter: Multi-Source Domain Adaptation for Acoustic Classification Through Domain Discovery”. In: *Proceedings of the 19th ACM Conference on Embedded Networked Sensor Systems (SenSys '21)*. Association for Computing Machinery, 2021.
- [15] Ian T. Jolliffe and Jorge Cadima. *Principal Component Analysis: A Review and Recent Developments*. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 2016.
- [16] June-Woo Kim, Sangmin Bae, Won-Yang Cho, Byungjo Lee, and Ho-Young Jung. “Stethoscope-Guided Supervised Contrastive Learning for Cross-Domain Adaptation on Respiratory Sound Classification”. In: *ICASSP 2024–2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024.
- [17] Yoonjoo Kim, YunKyong Hyon, Sung Soo Sung, Sunju Lee, Geon Yoo, Chauek Chung, and Taeyoung Ha. “Respiratory sound classification for crackles, wheezes, and rhonchi in the clinical field using deep learning”. In: *Scientific Reports* (2021).
- [18] Ron Kohavi. “A study of cross-validation and bootstrap for accuracy estimation and model selection”. In: *Proceedings of the 14th International Joint*. Morgan Kaufmann, 1995.
- [19] Michał Kośmider. “Spectrum Correction: Acoustic Scene Classification with Mismatched Recording Devices”. In: *Proceedings of the Annual Conference of the International Speech Communication Association (INTERSPEECH)*. ISCA, 2020.
- [20] Alexander Lerch. *An Introduction to Audio Content Analysis: Applications in Signal Processing and Music Informatics*. IEEE Press, Wiley, 2012.
- [21] Mingsheng Long, Zhangjie Cao, Jianmin Wang, and Michael I. Jordan. “Conditional Adversarial Domain Adaptation”. In: *Proceedings of the 32nd International Conference on Neural Information Processing Systems (NeurIPS)*. Curran Associates, Inc., 2018.
- [22] Laurens van der Maaten and Geoffrey Hinton. “Visualizing data using t-SNE”. In: *Journal of Machine Learning Research* (2008).

- [23] Francesco Mercaldo, Luca Brunese, Mario Cesarelli, Fabio Martinelli, and Antonella Santone. “Respiratory Disease Detection through Spectrogram Analysis with Explainable Deep Learning”. In: (2020).
- [24] Francesco Mercaldo, Luca Brunese, Mario Cesarelli, Fabio Martinelli, and Antonella Santone. “Respiratory Disease Detection through Spectrogram Analysis with Explainable Deep Learning”. In: *Proceedings of the 8th International Conference on Smart and Sustainable Technologies (SpliTech)*. IEEE, 2023.
- [25] Truc Nguyen and Franz Pernkopf. “Lung Sound Classification Using Co-Tuning and Stochastic Normalization”. In: *IEEE Transactions on Biomedical Engineering* 69 (2022).
- [26] Renard Xaviero Adhi Pramono, Stuart Bowyer, and Esther Rodriguez-Villegas. “Automatic adventitious respiratory sound analysis: A systematic review”. In: *PLOS ONE* (2017).
- [27] Renard Xaviero Adhi Pramono, Syed Anas Imtiaz, and Esther Rodriguez-Villegas. “Evaluation of features for classification of wheezes and normal respiratory sounds”. In: *PLOS ONE* (2019).
- [28] Kostas N. Priftis, Leontios J. Hadjileontiadis, and Mark L. Everard, eds. *Breath Sounds: From Basic Science to Clinical Practice*. Springer, 2018.
- [29] B. M. Rocha, D. Filos, L. Mendes, I. Vogiatzis, E. Perantoni, E. Kaimakamis, P. Natsiavas, A. Oliveira, C. Jácome, A. Marques, R. P. Paiva, I. Chouvarda, P. Carvalho, and N. Maglaveras. “A Respiratory Sound Database for the Development of Automated Classification”. In: *Precision Medicine Powered by pHealth and Connected Health* (2018).
- [30] Malay Sarkar, Irappa Madabhavi, Narasimhalu Niranjana, and Megha Dogra. “Auscultation of the respiratory system”. In: *Annals of Thoracic Medicine* (2015).
- [31] Eleanor Squires. “Assessment and examination of the respiratory system”. In: *Independent Nurse* (2022).
- [32] Vladimir Vapnik. *The Nature of Statistical Learning Theory*. 2nd. Springer, 2010.
- [33] Rui Wang, Mou Wang, Xiao-Lei Zhang, and Susanto Rahardja. “Domain Adaptation Neural Network for Acoustic Scene Classification in Mismatched Conditions”. In: *Proceedings of the Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*. IEEE, 2019.
- [34] Wenyi Zhang, Xiaohua Shen, Haoran Zhang, Zhaohui Yin, Jiayu Sun, Xisheng Zhang, and Lejun Zou. “Feature importance measure of a multilayer perceptron based on the presingle-connection layer”. In: *Neural Computing and Applications* (2023).

-
- [35] Mahta Hassan Pour Zonoozi, Vahid Seydi, and Mahmood Deypir. “An unsupervised adversarial domain adaptation based on variational auto-encoder”. In: *Machine Learning* (2025).
 - [36] Mahta Hassan Pour Zonoozi, Vahid Seydi, and Mahmood Deypir. “Variational inference based adversarial domain adaptation”. In: *Pattern Analysis and Applications* (2024).